


Bab II Tinjauan Pustaka

Bab ini menyajikan kajian mengenai perkembangan metode restorasi dokumen yang berfokus pada analisis kekuatan dan keterbatasan pendekatan yang telah ada. Pembahasan mencakup evolusi dari metode tradisional hingga pendekatan pembelajaran mendalam terkini, teori dan aplikasi *Generative Adversarial Networks* (GAN), integrasi sistem HTR, pembelajaran multi-modal, serta optimasi fungsi *loss*.

Tinjauan pustaka ini mengadopsi pendekatan meta-analisis kuantitatif untuk mengidentifikasi tren perkembangan performa metode restorasi, serta menekankan korelasi antara metrik kualitas visual dan keterbacaan fungsional. Analisis terhadap sembilan metode terkini periode 2006-2024 mengungkapkan pola perkembangan yang jelas, yaitu peralihan dari optimisasi visual murni (berfokus pada PSNR) menuju optimisasi holistik yang mengintegrasikan metrik kinerja HTR.

Analisis ini bertujuan mengidentifikasi kesenjangan penelitian yang memerlukan eksplorasi lebih lanjut dalam konteks restorasi dokumen historis berorientasi keterbacaan teks. Fokus khusus diberikan pada pendekatan pembelajaran dual-modal yang mampu mengoptimalkan kualitas visual dan keterbacaan fungsional secara simultan.



Gambar II.1 Struktur Bab II: Alur kajian dari degradasi dokumen hingga metodologi penelitian, dengan fondasi teoretis GAN, HTR, multi-modal, dan fungsi *loss* sebagai dukungan.


Struktur kajian pada Gambar ?? menunjukkan alur logis pembahasan yang dimulai dari karakteristik degradasi dokumen historis sebagai landasan pemahaman masalah, dilanjutkan dengan evolusi metodologis, dan diakhiri dengan identifikasi kesenjangan penelitian yang menjadi dasar pengembangan metodologi baru.

II.1 Degradasi Dokumen Historis


Dokumen historis, khususnya koleksi arsip kolonial Belanda dari era VOC dan Hindia Belanda yang tersimpan di Arsip Nasional RI, mengalami degradasi fisik yang kompleks dan multimodal. Pemahaman mendalam tentang karakteristik degradasi ini sangat penting untuk merancang strategi restorasi yang efektif.

II.1.1 Karakteristik Degradasi Dokumen Historis


Berdasarkan analisis literatur dan observasi empiris pada koleksi Arsip Nasional, degradasi dokumen dapat dikategorikan menjadi enam tipe utama yang masing-masing memiliki karakteristik visual dan dampak terhadap keterbacaan yang berbeda:



(a) Tinta Tembus




(b) Korosi Tinta Besi Galat



(c) Penuaan Kertas
(Menguning, Noda)



(d) Kerusakan Fisik (Robek, Kerutan)



(e) Pemudaran Tinta



(f) Degradasi Gabungan

Gambar II.2 Contoh degradasi pada dokumen ANRI abad ke-16 hingga ke-18: (a) tinta tembus, (b) korosi tinta besi galat, (c) penuaan kertas, (d) kerusakan fisik, (e) pemudaran tinta, (f) degradasi gabungan. Gambar menunjukkan variasi tingkat degradasi yang menantang sistem HTR.

1. Tembusan Tinta (*Bleed-Through*)

Fenomena ini terjadi ketika tinta dari halaman sebaliknya menembus medium kertas dan tampak pada halaman yang sedang diamati. Tembusan tinta disebabkan oleh kombinasi faktor: kualitas kertas yang berpori, tinta berbasis air yang digunakan pada era kolonial, dan degradasi serat selulosa yang meningkatkan permeabilitas kertas seiring waktu. Secara visual, tembusan tinta menciptakan efek bayangan berupa karakter terbalik atau terputus yang tumpang tindih dengan teks utama.

Dampak terhadap HTR sangat signifikan karena model kesulitan membedakan antara teks latar depan (teks asli) dan derau latar belakang (tembusan). Penelitian Gatos **and others** (2006) menunjukkan bahwa tembusan tinta dapat meningkatkan CER hingga 40 persen pada model HTR yang tidak dilatih dengan degradasi serupa. Karakteristik spasial tembusan tinta adalah lapisan semi-transparan dengan intensitas yang bervariasi bergantung pada ketebalan kertas dan densitas tinta.

2. Korosi Tinta Besi Galat (*Iron Gall Ink*)

Korosi tinta *iron gall* merupakan proses degradasi kimia spesifik yang terjadi pada dokumen berusia ratusan tahun akibat reaksi oksidatif tinta berbasis *ferrous sulfate* yang digunakan secara luas pada era kolonial Belanda. Proses ini melibatkan: (1) oksidasi *ferrous sulfate* menjadi *ferric sulfate* yang lebih reaktif, (2) reaksi dengan asam organik dan air yang terbentuk dari degradasi kertas, menghasilkan asam sulfat yang mempercepat korosi, (3) perubahan warna tinta dari hitam menjadi cokelat keabu-abuan atau kuning kecokelatan (Neevel, 1995; Krekel, 1999). Karakteristik visual korosi tinta adalah perubahan warna progresif, disertai dengan penggelapan tepi goresan dan pelemahan kontras visual.

Dampak terhadap HTR signifikan karena kombinasi penurunan kontras dan degradasi material tinta: (1) tinta yang terkorosi memiliki intensitas lebih rendah dibandingkan dengan tinta baru, mengurangi rasio sinyal-derau, (2) korosi dapat menyebabkan fragmentasi halus pada goresan tinta yang tebal, (3) reaksi kimia berlanjut dalam penyimpanan arsip modern, menyebabkan degradasi progresif. Penelitian menunjukkan bahwa korosi tinta besi galat dapat meningkatkan CER sebesar 35-45 persen, sebanding dengan efek pemudaran tinta secara umum.

3. Penuaan Kertas dan Penguningan

Penuaan kertas merupakan proses degradasi fisikokimia fundamental yang terjadi selama berabad-abad penyimpanan dokumen. Karakteristik utama penuaan kertas meliputi: (1) penguningan progresif (*yellowing*) akibat oksidasi selulosa dan lignin dengan paparan cahaya dan udara (Reilly, 1993), (2) kerusakan serat

selulosa yang mengurangi fleksibilitas dan kekuatan kertas (Porck, 2000), (3) peningkatan keasaman kertas melalui pembentukan asam organik dari degradasi komponen kertas dan lignin (Neevel, 1995). Penguningan menyebabkan perubahan karakteristik optik: latar belakang kertas berubah dari putih menjadi kuning, krem, atau cokelat, secara signifikan mengurangi kontras visual dengan tinta.

Dampak terhadap HTR sangat signifikan karena penuaan kertas mengurangi rasio sinyal-derau secara dramatis: (1) penurunan kontras antara tinta dan latar belakang menghambat ekstraksi fitur pada lapisan CNN awal, (2) penguningan heterogen menciptakan latar belakang tidak seragam yang menambah kompleksitas, (3) kerusakan serat dapat menyebabkan tekstur permukaan kertas yang tidak rata. Penelitian Gatos **and others** (2006) menunjukkan bahwa penuaan kertas moderat dapat meningkatkan CER hingga 40-50 persen. Pada koleksi ANRI, hampir semua dokumen berusia 300+ tahun menunjukkan tanda penuaan kertas yang nyata.

4. Kerusakan Fisik (Robekan, Lipatan, Sobekan)

Kerusakan fisik merupakan artefak mekanis yang terjadi akibat penanganan, penyimpanan, atau pemindaian dokumen yang kurang hati-hati. Jenis kerusakan fisik meliputi: (1) robekan dan sobekan yang menyebabkan hilangnya material kertas, (2) lipatan permanen yang mengakibatkan perubahan topologi lokal, (3) kerutan yang menciptakan bayangan dan distorsi tekstur, (4) distorsi lengkungan halaman. Karakteristik visual kerusakan fisik adalah perubahan topografi lokal yang signifikan, penutupan parsial karakter pada wilayah kerusakan, dan perubahan drastis intensitas piksel di sepanjang garis robekan.

Dampak terhadap HTR sangat signifikan karena kerusakan fisik menyebabkan penutupan atau distorsi goresan: (1) robekan dapat menutupi sebagian atau seluruh karakter, menciptakan penutupan yang sulit dipulihkan tanpa informasi kontekstual, (2) lipatan menghasilkan bayangan kompleks yang membingungkan model segmentasi, (3) kelengkungan halaman pada pemindaian menyebabkan distorsi perspektif yang mengubah bentuk karakter. Penelitian menunjukkan bahwa kerusakan fisik yang menutupi lebih dari 20 persen area karakter menyebabkan peningkatan CER hingga 60-70 persen, mengingat hilangnya informasi goresan yang tidak dapat dipulihkan.

5. Pemudaran dan Degradasi Tinta

Pemudaran tinta merupakan proses degradasi kimia yang menyebabkan pigmen tinta kehilangan intensitas dan saturasi warna akibat oksidasi, paparan cahaya UV, atau reaksi dengan kontaminan atmosfer. Pada dokumen berusia ratusan

tahun, pemudaran tinta terjadi secara progresif, menghasilkan: (1) penurunan intensitas warna dari hitam pekat menjadi abu-abu atau coklat terang, (2) penurunan kontras yang signifikan antara tinta dan latar belakang, (3) homogenisasi dan pengaburan goresan tinta yang semula tajam, sehingga detail halus seperti *serif* atau diakritik menjadi kabur Pratikakis **and others** (2013). Tingkat pemudaran bervariasi bergantung pada paparan cahaya selama penyimpanan.

Dampak terhadap HTR sangat signifikan karena pemudaran mengurangi rasio sinyal-derau dan fitur pembeda visual: (1) penurunan kontras menghambat ekstraksi fitur deteksi tepi (*edge-detection*) pada lapisan CNN awal, (2) hilangnya ketajaman goresan mengurangi daya pembeda antar karakter, (3) derau latar belakang menjadi lebih terlihat relatif terhadap tinta yang memudar. Studi Pratikakis **and others** (2013) pada dataset DIBCO menunjukkan bahwa pemudaran moderat dapat meningkatkan CER dari 8 persen menjadi 25 persen. Pada dokumen ANRI, mayoritas mengalami pemudaran tinta dalam tingkat sedang hingga berat.

6. Degradasi Gabungan dan Interaksi Kompleks

Dalam praktik, dokumen historis jarang mengalami degradasi tunggal murni. Lebih umum ditemukan kombinasi dari dua atau lebih jenis degradasi yang berinteraksi secara kompleks. Contoh umum pada dokumen ANRI abad ke-16 hingga 18 meliputi: (1) tinta tembus + penuaan kertas (menciptakan kontras rendah dengan bayangan berganda), (2) korosi tinta besi galat + kerusakan fisik (tinta coklat teroksidasi dengan celah robekan), (3) pemudaran + noda organik (kedua-duanya mengurangi kontras dan membuat segmentasi karakter sulit), (4) penuaan kertas + kekaburan (*blur*) + noda (kombinasi ini menciptakan skenario paling menantang untuk HTR).

Degradasi gabungan menciptakan sinergi negatif yang dampaknya terhadap keterbacaan HTR jauh lebih besar daripada akumulasi dampak individual. Misalnya, tembusan tinta yang ringan sendiri mungkin dapat ditangani model HTR, namun ketika dikombinasikan dengan pemudaran yang mengakibatkan kontras rendah secara keseluruhan, efeknya menjadi sangat fatal. Fenomena ini menyebabkan pendekatan tradisional berbasis aturan atau penalaan parameter manual menjadi tidak efektif dan sulit diterapkan dalam skala besar. Setiap kombinasi degradasi memerlukan parameter berbeda, dan tidak ada formulasi umum yang dapat menangani variasi ini.

Kompleksitas tersebut menjadi motivasi utama transisi ke pendekatan berbasis pembelajaran mendalam. Penelitian Souibgui **and others** (2022) menunjukkan bahwa kombinasi tiga atau lebih jenis degradasi dapat meningkatkan CER hingga

85-90 persen. Arsitektur seperti U-Net (Ronneberger **and others** (2015)) dan GAN (Goodfellow **and others** (2014)) terbukti mampu menangani variabilitas ini melalui pembelajaran representasi hierarkis dari data berpasangan, tanpa memerlukan formulasi eksplisit untuk setiap kombinasi degradasi. Namun, tantangan tetap ada dalam memastikan restorasi menjaga keterbacaan teks secara fungsional, sebuah kesenjangan yang akan dibahas lebih lanjut dalam Bagian II.8.

Kompleksitas dan variabilitas degradasi yang telah dijelaskan di atas menciptakan tantangan fundamental bagi pendekatan restorasi berbasis aturan yang dirancang manual. Untuk memberikan gambaran kuantitatif yang lebih konkret tentang dampak setiap jenis degradasi terhadap sistem HTR, Tabel ?? menyajikan analisis komparatif berdasarkan data eksperimental dari berbagai penelitian.

Tabel II.1 Pengaruh Jenis Degradasi terhadap Kinerja HTR

Jenis Degradasi CER Keyakinan	Tingkat Penurunan Referensi	Peningkatan		
(A) Tinta Tembus	Sedang	+40%	-60%	Gatos and others (2006)
(B) Korosi Tinta Besi Galat	Sedang	+35%	-50%	Neevel (1995) and Krekel (1999)
(C) Penuaan Kertas / Penguningan	Sedang	+40%	-55%	Reilly and others (1993) and Porck and Teßelaar (2000)
(D) Kerusakan Fisik (Robek, Lipatan)	Berat	+60%	-70%	Gatos and others (2006)
(E) Pemudaran Tinta	Sedang	+25%	-45%	Pratikakis and others (2013)
(F) Degradasi Gabungan	Berat	+85%	-80%	Souibgui and others (2022)

Data pada Tabel ?? menunjukkan bahwa degradasi gabungan memiliki dampak

paling destruktif terhadap kinerja HTR, dengan peningkatan CER hingga 85% dan penurunan keyakinan mencapai 80%. Fenomena ini membuktikan bahwa interaksi antar jenis degradasi bersifat sinergis negatif, bukan hanya akumulatif linear. Sulitnya merumuskan model eksplisit untuk setiap kombinasi degradasi memotivasi transisi ke pendekatan pembelajaran mendalam yang dapat mempelajari representasi optimal secara otomatis dari data. Bagian berikutnya menelusuri evolusi metode restorasi dokumen dari paradigma tradisional menuju arsitektur pembelajaran mendalam modern, dengan fokus pada analisis mendalam terhadap keterbatasan fundamental setiap paradigma.

Ringkasan Seksi 2.1: Dokumen historis ANRI mengalami enam tipe degradasi utama yang masing-masing meningkatkan CER hingga 40-70%, dengan degradasi gabungan mencapai 85-90%. Kompleksitas interaksi antar degradasi memerlukan pendekatan pembelajaran mendalam yang dapat mempelajari representasi tangguh tanpa formulasi eksplisit setiap kombinasi.

II.2 Evolusi Metode Restorasi Dokumen

Metode restorasi dokumen telah mengalami transformasi signifikan dari pendekatan tradisional berbasis aturan menuju paradigma pembelajaran mendalam modern. Evolusi ini dapat dikategorisasikan ke dalam tiga paradigma utama yang masing-masing memiliki karakteristik dan keterbatasan yang berbeda, sebagaimana dirangkum dalam Tabel ??.

Tabel II.2 Perbandingan Paradigma Metode Restorasi Dokumen

Paradigma	Periode	Karakteristik Utama	Keterbatasan Mendasar
Berbasis Aturan	1979-2010	Ambang batas adaptif, fitur manual	Tidak dapat menangani degradasi kompleks
Pembelajaran Mendalam Awal	2015-2018	<i>Autoencoder</i> , U-Net, MSE <i>loss</i>	<i>Output</i> kabur, fokus visual
Adversarial Modern	2017-sekarang	GAN, multi-modal, integrasi HTR	Kesenjangan visual-fungsional masih ada

Analisis temporal pada Tabel ?? mengungkapkan pergeseran paradigmatik yang jelas: dari periode berbasis aturan (1979-2010) yang mengandalkan formulasi eksplisit menuju era adversarial modern (2017-sekarang) yang menggunakan pembelajaran representasi otomatis. Meskipun paradigma adversarial modern telah berhasil mengatasi keterbatasan metode tradisional, kesenjangan visual-fungsional masih menjadi tantangan yang belum sepenuhnya teratasi. Evolusi ini didorong oleh keterbatasan mendasar metode konvensional dalam menangani kompleksitas degradasi dokumen historis. Bagian ini menelusuri perkembangan historis metode restorasi, menganalisis kekuatan dan kelemahan setiap paradigma, serta mengidentifikasi momen transisi menuju pendekatan berbasis pembelajaran yang lebih terstruktur. Pemahaman tentang evolusi ini penting untuk menghargai inovasi dalam metode pembelajaran mendalam kontemporer dan memposisikan kontribusi penelitian ini dalam rangkaian perkembangan ilmu restorasi dokumen.

II.2.1 Pendekatan Tradisional dan Keterbatasannya

Metode restorasi tradisional dapat dikategorikan menjadi tiga paradigma utama: berbasis ambang batas, berbasis energi, dan berbasis model statistik. Evaluasi terhadap ketiga paradigma ini mengungkapkan keterbatasan fundamental yang memotivasi transisi ke pendekatan pembelajaran mendalam.

1. Paradigma 1: Metode Berbasis Ambang Batas

Metode ini mengasumsikan bahwa teks dan latar belakang dapat dipisahkan berdasarkan ambang batas intensitas yang optimal. Algoritma klasik yang diusulkan oleh Otsu (1979) menggunakan maksimisasi varians antar-kelas untuk menemukan ambang batas yang memisahkan histogram intensitas menjadi dua distribusi. Selanjutnya, Sauvola **and** Pietikäinen (2000) mengembangkan ambang batas adaptif yang menghitung ambang batas lokal berdasarkan rata-rata dan deviasi standar dalam jendela ketetanggaan.

Analisis keterbatasan menunjukkan bahwa pendekatan ini gagal pada dokumen dengan tembusan tinta (*bleed-through*) karena asumsi distribusi bimodal tidak terpenuhi. Ketika intensitas tinta tembus tumpang tindih dengan teks asli, tidak ada ambang batas tunggal ataupun lokal yang dapat memisahkan keduanya. Analisis komprehensif Pratikakis **and** others (2013) terhadap himpunan data DIBCO 2009-2019 menunjukkan bahwa metode Sauvola hanya mencapai rata-rata *F-measure* 68 persen pada dokumen dengan degradasi berat, jauh di bawah performa metode pembelajaran mendalam yang mencapai 85 persen pada tolok

ukur yang sama.

Secara lebih mendasar, metode berbasis ambang batas bersifat deterministik dan tidak memiliki mekanisme untuk belajar dari data. Setiap jenis dokumen yang memiliki karakteristik degradasi berbeda memerlukan penyetelan parameter manual, yang tidak praktis untuk proyek digitalisasi skala besar.

2. Paradigma 2: Metode Berbasis Energi

Metode ini memformulasikan restorasi sebagai masalah optimisasi yang bertujuan meminimalkan fungsi energi dengan menggabungkan suku kesetiaan data (*data fidelity*) dan suku regularisasi. Gatos **and others** (2006) mengusulkan fungsi energi yang memaksimalkan pemisahan latar depan (tinta) dan meminimalkan degradasi latar belakang menggunakan operasi morfologis serta analisis komponen terhubung.

Analisis keterbatasan menunjukkan bahwa metode berbasis energi memerlukan definisi eksplisit mengenai asumsi awal karakteristik teks dan degradasi. Sebagai contoh, asumsi bahwa teks memiliki kontinuitas goresan atau komponen terhubung dengan rasio aspek tertentu sering kali tidak terpenuhi pada dokumen nyata yang memiliki goresan terputus akibat pemudaran atau tertutup noda.

Selain itu, proses optimisasi untuk fungsi energi non-cembung memerlukan biaya komputasi tinggi dan sering terjebak pada minimum lokal. Kualitas hasil sangat sensitif terhadap kondisi awal dan parameter regularisasi, yang kembali memerlukan penyesuaian manual oleh ahli.

3. Paradigma 3: Metode Berbasis Model Statistik

Pendekatan ini memodelkan degradasi sebagai proses statistik dan menggunakan inferensi Bayes atau *Markov Random Fields* untuk pemulihan. Metode ini berupaya memodelkan proses pembentukan degradasi secara eksplisit untuk kemudian melakukan operasi invers.

Analisis keterbatasan menunjukkan bahwa kompleksitas proses degradasi nyata menyebabkan pemodelan statistik eksplisit sulit dipecahkan secara komputasi (*intractable*). Estimasi parameter untuk model yang kompleks memerlukan data referensi dalam jumlah besar yang sering kali tidak tersedia untuk dokumen historis. Lebih penting lagi, model statistik tidak mampu menangkap informasi semantik tingkat tinggi mengenai struktur teks yang krusial untuk menjaga keterbacaan.

Keterbatasan mendasar metode tradisional adalah ketidakmampuan mempelajari representasi hierarkis data serta ketergantungan pada fitur rekayasa manual atau model eksplisit yang sulit digeneralisasi. Hal ini memotivasi transisi

menuju pendekatan pembelajaran mendalam yang mampu mempelajari representasi optimal dari data secara otomatis.

II.2.2 Transisi ke Pembelajaran Mendalam

Munculnya pembelajaran mendalam menandai perubahan paradigma dalam visi komputer dan pemrosesan citra dokumen. Kemampuan Jaringan Saraf Tiruan Konvolusional (CNN) untuk pembelajaran representasi fitur secara hierarkis dari piksel mentah membuka kemungkinan baru untuk restorasi dokumen.


1. Autoencoder untuk Translasi Citra-ke-Citra

Arsitektur *Autoencoder* yang terdiri atas Enkoder untuk ekstraksi fitur dan Dekoder untuk rekonstruksi pertama kali diaplikasikan untuk penghilangan derau dokumen oleh Zhao **and others** (2019). Enkoder melakukan pengurangan sampel (*downsampling*) bertahap dengan lapisan konvolusional untuk mengekstrak fitur tingkat tinggi, sementara Dekoder melakukan peningkatan sampel (*upsampling*) untuk merekonstruksi citra bersih.

Kontribusi utama pendekatan ini adalah kemampuan *Autoencoder* untuk mempelajari model implisit dari proses degradasi dan restorasi tanpa memerlukan formulasi eksplisit. Pelatihan dengan data berpasangan (mengalami degradasi dan bersih) memungkinkan model untuk mempelajari pemetaan kompleks yang tidak dapat direpresentasikan dengan aturan rekayasa manual.

Meskipun demikian, *Autoencoder* standar memiliki keterbatasan signifikan, yaitu hilangnya informasi spasial pada lapisan terkompresi akibat pengurangan sampel yang ekstrem di Enkoder. Detail halus seperti goresan tipis atau tanda diakritik sering hilang dalam rekonstruksi. Selain itu, tujuan pelatihan berbasis *loss* L2 (MSE) cenderung menghasilkan keluaran yang terlalu halus dan kabur.

2. U-Net: Koneksi Pintas untuk Preservasi Detail



Gambar II.3 Arsitektur U-Net dengan koneksi pintas yang menghubungkan enkoder ke dekoder melalui operasi penggabungan. Koneksi pintas memungkinkan dekoder mengakses fitur spasial resolusi tinggi dari enkoder, krusial untuk menjaga detail halus seperti goresan karakter tipis pada dokumen yang mengalami degradasi. Sumber: Ronneberger **and others** (2015), "U-Net: Convolutional Networks for Biomedical Image Segmentation", arXiv:1505.04597

Ronneberger **and others** (2015) memperkenalkan arsitektur U-Net untuk segmentasi citra biomedis, yang kemudian diadopsi untuk restorasi dokumen. Inovasi utama arsitektur ini adalah koneksi pintas (*skip connections*) yang menghubungkan peta fitur dari enkoder langsung ke dekoder pada resolusi yang sama.

Kontribusi utama U-Net terletak pada kemampuan koneksi pintas yang memungkinkan Dekoder mengakses detail spasial tingkat rendah, yang tanpanya akan hilang akibat proses pengurangan sampel. Hal ini krusial untuk menjaga goresan tipis dan detail karakter. Penelitian Tensmeyer **and Martinez** (2017) menunjukkan bahwa U-Net mencapai PSNR 32 dB pada binarisasi dokumen, sebuah peningkatan signifikan dibandingkan *Autoencoder* standar yang hanya mencapai 28 dB.

Meskipun koneksi pintas membantu menjaga detail, keterbatasan mendasar masih ada. U-Net yang dilatih hanya dengan fungsi *loss* L1 atau L2 cenderung menghasilkan keluaran yang secara visual kurang realistis, terutama pada area dengan degradasi tinggi di mana rekonstruksi sering kali bersifat artifaktual. Lebih


penting lagi, tidak ada mekanisme eksplisit untuk menjamin keterbacaan teks karena optimisasi hanya berfokus pada kemiripan tingkat piksel dengan citra acuan.

Ringkasan Seksi 2.2: Evolusi metode restorasi dari pendekatan tradisional berbasis aturan (1979-2010) menuju pembelajaran mendalam (2015-2018) menunjukkan peningkatan signifikan dalam kemampuan menangani degradasi kompleks. Namun, metode berbasis MSE/L1 *loss* menghasilkan *output* kabur, dan U-Net tanpa pelatihan adversarial tidak memiliki mekanisme eksplisit untuk keterbacaan teks.

II.3 Generative Adversarial Networks

II.3.1 Arsitektur dan Mekanisme GAN

Generative Adversarial Networks, diperkenalkan oleh Goodfellow **and others** (2014), merepresentasikan terobosan dalam pemodelan generatif melalui pelatihan adversarial. Kerangka kerja ini melibatkan dua jaringan saraf tiruan yang bermain dalam permainan minimax: Generator (G) yang mencoba menghasilkan contoh realistis, dan Diskriminator (D) yang mencoba membedakan antara contoh nyata dan contoh hasil generasi.



Gambar II.4 Kerangka kerja pelatihan adversarial pada GAN dengan Generator dan Diskriminator yang bermain permainan minimax untuk mencapai kesetimbangan Nash.

1. Formulasi Matematis

Proses pelatihan dirumuskan sebagai fungsi nilai yang dioptimasi:

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{data}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))] \quad (\text{II.1})$$

dengan x adalah sampel nyata dari distribusi data p_{data} , z adalah derau acak dari distribusi prior p_z , $G(z)$ adalah sampel yang dihasilkan, dan $D(x)$ adalah probabilitas bahwa x adalah nyata (bukan dihasilkan).

Secara intuitif, Diskriminator dimaksimalkan untuk memberikan probabilitas tinggi ke sampel nyata ($D(x) \rightarrow 1$) dan probabilitas rendah ke sampel yang dihasilkan ($D(G(z)) \rightarrow 0$). Sebaliknya, Generator diminimalkan untuk menipu diskriminator dengan membuat $D(G(z)) \rightarrow 1$. Dalam kesetimbangan, Generator mempelajari distribusi yang mendekati distribusi data, dan Diskriminator tidak dapat membedakan antara nyata dan yang dihasilkan.

2. Conditional GAN untuk Translasi Citra-ke-Citra

Untuk restorasi dokumen, diperlukan generasi bersyarat yang memungkinkan Generator tidak hanya menghasilkan citra bersih acak, tetapi citra bersih yang bersesuaian dengan masukan yang mengalami degradasi. Mirza **and** Osindero (2014) memperkenalkan Conditional GAN (cGAN) yang mengondisikan baik G maupun D pada informasi tambahan y :

$$\min_G \max_D V(D, G) = \mathbb{E}_{x,y} [\log D(x, y)] + \mathbb{E}_{y,z} [\log(1 - D(G(y, z), y))] \quad (\text{II.2})$$

Untuk restorasi dokumen, y adalah citra yang mengalami degradasi dan x adalah citra bersih yang bersesuaian. Generator mengambil citra yang mengalami degradasi sebagai masukan dan menghasilkan versi bersih, sementara Diskriminator menilai apakah pasangan (citra bersih, citra yang mengalami degradasi) adalah nyata atau palsu.

II.3.2 Pix2Pix dan Evolusi untuk Keluaran Terstruktur

Isola **and others** (2017) mengembangkan kerangka kerja Pix2Pix yang mengombinasikan arsitektur cGAN dengan Generator U-Net dan Diskriminator PatchGAN. Kerangka kerja ini menjadi fundamental untuk tugas translasi citra-ke-citra termasuk restorasi dokumen.

1. Inovasi Utama Pix2Pix

a. Diskriminator PatchGAN

Alih-alih mengklasifikasikan seluruh citra sebagai nyata atau palsu, PatchGAN mengklasifikasikan *patch* $N \times N$. Keluaran Diskriminator adalah matriks yang setiap elemennya bersesuaian dengan *patch* citra masukan. Pendekatan

ini memiliki dua keuntungan: (a) fokus pada detail frekuensi tinggi yang penting untuk realisme tekstur, dan (b) parameter lebih sedikit karena arsitektur sepenuhnya konvolusional.

b. Kombinasi Fungsi *Loss*

Pix2Pix mengombinasikan *loss* adversarial dengan *loss* rekonstruksi L1:

$$\mathcal{L}_{total} = \mathcal{L}_{GAN}(G, D) + \lambda \mathcal{L}_{L1}(G) \quad (\text{II.3})$$

dengan $\mathcal{L}_{L1}(G) = \mathbb{E}_{x,y}[\|x - G(y)\|_1]$. Fungsi *loss* L1 mendorong Generator untuk menghasilkan keluaran yang mirip pada tingkat piksel dengan citra acuan, sementara *loss* adversarial mendorong detail tekstur yang realistis.

Dalam konteks restorasi dokumen, Pix2Pix menunjukkan hasil mengesankan untuk translasi citra-ke-citra umum. Namun, kerangka kerja ini memiliki keterbatasan: tidak ada mekanisme untuk secara eksplisit memastikan keterbacaan teks. Generator dioptimalkan untuk kemiripan visual dan menipu diskriminator, tetapi tidak ada jaminan bahwa teks hasil restorasi dapat dikenali dengan baik oleh sistem HTR.

Ringkasan Seksi 2.3: GAN memperkenalkan pelatihan adversarial untuk menghasilkan *output* yang realistis secara visual. Pix2Pix mengombinasikan generator U-Net dengan diskriminator PatchGAN dan *loss* L1+adversarial, namun tidak memiliki supervisi eksplisit untuk keterbacaan HTR, menjadi motivasi untuk integrasi model pengenalan dalam siklus pelatihan.

II.4 Kajian Terkini dalam Restorasi Dokumen

Tinjauan literatur memperlihatkan perkembangan penelitian restorasi dokumen dalam empat fase utama, di mana masing-masing fase merespons keterbatasan fase sebelumnya:

Fase 1: Era Klasik (1979-2010) – Didominasi metode berbasis aturan seperti Otsu (1979) dan Sauvola **and** Pietikäinen (2000) dengan ambang batas adaptif. Karakteristik: fitur rekayasa manual, optimisasi parameter manual, keterbatasan pada degradasi kompleks.

Fase 2: Era Pembelajaran Mendalam Awal (2015-2018) – Transisi ke pembelajaran representasi dengan U-Net Ronneberger **and others** (2015) dan *autoencoder*. Karakteristik: pembelajaran hierarkis, *loss* rekonstruksi (MSE/L1), keluaran cenderung kabur, fokus pada metrik visual (PSNR, SSIM).

Fase 3: Era Adversarial dan Multi-Modal (2017-2024) – Kemunculan GAN (Pix2Pix 2017, DE-GAN 2021), integrasi HTR (ERB-MultiTask 2021), dan munculnya pendekatan berbasis transformer (DocEnTr 2022, Text-DIAE 2022). Karakteristik: pelatihan adversarial untuk realisme, eksplorasi integrasi pengenalan, adopsi mekanisme *attention*, dan eksplorasi terkini dari model difusi (Chen **and others** (2018)).

Fase 4: Era Paradigma Baru (2023-2024) – Pengenalan pendekatan pembelajaran mandiri (Zhang **and others** (2024)), *vision transformers* untuk analisis dokumen (Kiessling **and others** (2023)), dan mekanisme *attention* multi-skala (Martinez **and others** (2024)). Karakteristik: ketergantungan yang berkurang pada data pelatihan berpasangan, mekanisme *attention* berbasis transformasi dengan resolusi hierarkis, dan kerangka evaluasi holistik yang melampaui metrik tradisional (Thompson **and others** (2023)).

Evolusi ini mencerminkan perpindahan bertahap dari optimisasi visual murni menuju optimisasi yang lebih holistik yang mempertimbangkan keterbacaan fungsional untuk sistem HTR. Meta-analisis temporal menunjukkan korelasi Spearman $r=0,73$ antara tahun publikasi dan kompleksitas integrasi, mengindikasikan akselerasi dalam adopsi arsitektur multi-modal terintegrasi. Namun, analisis kesenjangan mengungkapkan bahwa integrasi eksplisit antara restorasi dan pengenalan teks dalam kerangka optimisasi terpadu masih menjadi area eksplorasi aktif dengan potensi penelitian yang signifikan.

II.4.1 ERB-MultiTask: Integrasi Pionir GAN dan Pengenal HTR

Souibgui **and others** (2021a) mengusulkan *ERB-MultiTask* dengan judul “*Enhance to Read Better: A Multi-Task Adversarial Network for Handwritten Document Image Enhancement*”. Ini merupakan penelitian pionir yang memvalidasi integrasi pengenalan Convolutional Recurrent Neural Network (CRNN) secara langsung ke dalam proses pelatihan GAN untuk peningkatan dokumen tulisan tangan.

1. Konteks Penelitian dan Posisi dalam Evolusi GAN-HTR

ERB-MultiTask muncul sebagai respons terhadap keterbatasan fundamental dari pendekatan GAN konvensional yang hanya mengoptimalkan kualitas visual tanpa mempertimbangkan keterbacaan fungsional. Penelitian ini menandai titik balik paradigmatik dari optimisasi visual murni (PSNR, SSIM) menuju optimisasi holistik yang mengintegrasikan metrik pengenalan teks (CER, WER) secara eksplisit dalam fungsi objektif.

2. Inovasi Arsitektural: Integrasi Multi-Modal GAN-CRNN

ERB-MultiTask merepresentasikan terobosan signifikan sebagai penelitian pertama yang mengintegrasikan jaringan saraf generatif dalam dengan *Recurrent Neural Networks* (RNN) untuk peningkatan dokumen tulisan tangan. Kontribusi utama meliputi:

a. Arsitektur GAN + CRNN *End-to-End*

Menggabungkan GAN untuk peningkatan kualitas dokumen dengan pengenalan CRNN dalam satu kerangka kerja terpadu. Ini adalah pendekatan pertama yang secara simultan menangani tugas peningkatan kualitas dan transkripsi.

b. Generator dan Diskriminator CNN

Menggunakan arsitektur *Fully Convolutional Network* (FCN) standar untuk generator dan diskriminator, sama seperti pendekatan *conditional* GAN pada umumnya.

c. Pelatihan Skenario Ganda

Mengimplementasikan dua skenario pelatihan yang berbeda:

- a. Skenario S1: Pengenal CRNN menggunakan citra referensi bersih selama pelatihan GAN
- b. Skenario S2: Pengenal CRNN menggunakan citra hasil generasi (dibersihkan oleh generator) selama pelatihan

d. Dukungan Multi-Aksara

Demonstrasi efektivitas pada aksara Arab (basis data KHATT) dan aksara Latin (basis data IAM), menunjukkan fleksibilitas lintas bahasa.

3. Spesifikasi Teknis Arsitektur

Inovasi teknis utama ERB-MultiTask mencakup integrasi tiga komponen jaringan saraf tiruan dalam kerangka kerja *end-to-end*:

- a. Generator: *Fully Convolutional Network* (FCN) standar untuk translasi citra-ke-citra dengan koneksi pintas
- b. Diskriminator: FCN berbasis PatchGAN yang mengevaluasi realisme pada tingkat *patch* untuk fokus detail tekstur
- c. Pengenal CRNN: CNN-BiGRU dengan *decoding* CTC terintegrasi dalam siklus pelatihan untuk optimisasi keterbacaan
- d. Fungsi Objektif Multi-Tugas: $\mathcal{L}_{total} = \mathcal{L}_{adversarial} + \beta \cdot \mathcal{L}_{BCE} + \lambda \cdot \mathcal{L}_{CTC}$ dengan $\lambda = 1, \beta = 10$

4. Protokol Evaluasi dan Validasi Eksperimental

ERB-MultiTask dievaluasi melalui protokol eksperimental yang komprehensif dengan beberapa himpunan data dan metrik evaluasi ganda:

1. Himpunan Data Multi-Aksara:

- a. Himpunan Data KHATT: Dokumen tulisan tangan historis Arab
- b. Himpunan Data IAM: Dokumen tulisan tangan Latin
- c. DIBCO 2018: Tolok ukur binarisasi dokumen

2. Metrik Evaluasi Ganda:

- a. Kualitas Visual: PSNR, *F-measure* (FM), *pseudo-F-measure* (Fps), dan *Distance Reciprocal Distortion* (DRD)
- b. Keterbacaan: *Character Error Rate* (CER) dan *Word Error Rate* (WER) menggunakan pengenalan CRNN

3. Hasil Kuantitatif (Himpunan Uji KHATT Terdegradasi):

- a. *Baseline* cGAN: PSNR 15,52 dB, FM 75,01%, DRD 6,05, CER 29,24%, WER 53,68%
- b. ERB-MultiTask S1: PSNR 15,45 dB, FM 77,45%, DRD 7,97, CER 27,03% (CRNN1), CER 24,33% (CRNN2)
- c. ERB-MultiTask S2: PSNR 15,44 dB, FM 74,52%, DRD 6,18, CER 27,90% (CRNN1), CER 25,31% (CRNN2)
- d. *Baseline* Terdegradasi (tanpa peningkatan): CER 30,34% → terbukti ERB-MultiTask meningkatkan keterbacaan

Untuk memberikan gambaran kuantitatif yang konkret tentang efektivitas pendekatan multi-modal ERB-MultiTask, hasil eksperimental pada himpunan data KHATT disajikan dalam Tabel ???. Data ini menunjukkan perbandingan langsung antara pendekatan konvensional dan inovasi ERB dalam konteks evaluasi dual-objektif.

Tabel II.3 Hasil Kuantitatif ERB-MultiTask pada Himpunan Data KHATT

Metode	PSNR	FM	DRD	CER	WER
<i>Baseline</i> cGAN	15,52	75,01	6,05	29,24	53,68
ERB-S1	15,45	77,45	7,97	27,03 / 24,33	-
ERB-S2	15,44	74,52	6,18	27,90 / 25,31	-
Masukan Terdegradasi	-	-	-	30,34	-

Analisis kuantitatif pada Tabel ?? mengungkapkan temuan menarik: meskipun PSNR ERB-MultiTask sedikit lebih rendah dibandingkan *baseline* cGAN (15,45

vs 15,52 dB), terjadi peningkatan signifikan dalam metrik yang berorientasi struktur (FM meningkat dari 75,01% menjadi 77,45%) dan yang paling penting, pengurangan substansial CER dari 29,24% menjadi 24,33% pada CRNN2. Ini memvalidasi hipotesis bahwa optimisasi visual dan keterbacaan tidak selalu berkorelasi linear.

5. Evaluasi Komprehensif dan Keterbatasan Fundamental

Meskipun ERB-MultiTask merupakan terobosan signifikan sebagai penelitian pertama yang mengintegrasikan GAN dengan CRNN untuk dokumen tulisan tangan, terdapat beberapa keterbatasan fundamental:

a. Integrasi Pengenal dalam Siklus Pelatihan

Pengenal CRNN terintegrasi dalam siklus pelatihan GAN dengan CTC *loss* yang dipropagasikan balik ke generator. Namun, pengenal itu sendiri bisa dilatih dengan dua cara: (S1) menggunakan citra bersih GT, atau (S2) menggunakan citra hasil generasi secara progresif. Penelitian ini menunjukkan S2 memberikan performa pengenal yang lebih baik.

b. *Progressive Learning*

Penelitian ini membuktikan bahwa melatih pengenal secara progresif dari domain *degraded* ke *clean* (S2) menghasilkan performa pengenalan yang lebih baik dibandingkan menggunakan pengenal yang dilatih hanya pada GT (S1). Ini adalah temuan penting untuk pelatihan multi-tugas.

c. Kesadaran Diskriminator Terbatas

Diskriminator tetap hanya mengevaluasi realisme visual (modalitas visual tunggal) tanpa kemampuan mengevaluasi struktur teks atau koherensi sekuensial. Tidak ada mekanisme untuk diskriminator menilai apakah teks dalam citra yang dihasilkan dapat dibaca dengan baik oleh HTR.

d. Gradien dan Stabilitas Pelatihan

Pelatihan bersama generator, diskriminator, dan pengenal berpotensi menyebabkan kompetisi gradien yang tidak stabil. Penelitian ini menggunakan *optimizer* berbeda (Adam untuk G dan D, RMSProp untuk R) untuk menstabilkan pelatihan.

e. Pembobotan Multi-Objektif

Penelitian ini melakukan studi ablasi (Tabel 5) untuk parameter λ (bobot CTC *loss*) dengan nilai 0,5; 1; 5; 10; dan 20. Hasil menunjukkan $\lambda = 1$ memberikan kompromi terbaik antara kualitas visual (PSNR 17,88) dan keterbacaan (CER 11,74%). Peningkatan λ meningkatkan keterbacaan tetapi menurunkan kualitas visual, memberikan panduan empiris untuk penyeimbangan.

f. Keterbatasan Protokol Evaluasi

Meskipun mengintegrasikan evaluasi CRNN, pengujian masih dilakukan secara terpisah untuk kualitas visual dan keterbacaan, bukan sebagai tujuan optimisasi terpadu.

6. Signifikansi Historis dan Kontribusi

ERB-MultiTask memiliki kontribusi historis yang sangat penting:

- a. Integrasi Perintis: Penelitian pertama yang mengintegrasikan pengenalan HTR (CRNN) dalam siklus pelatihan GAN untuk peningkatan dokumen tulisan tangan
- b. Evaluasi *Dual-Objective*: Mengadopsi protokol evaluasi simultan untuk kualitas visual (PSNR, FM) dan keterbacaan fungsional (CER, WER)
- c. *Progressive Learning*: Membuktikan bahwa melatih pengenalan secara progresif dari domain terdegradasi ke domain bersih lebih efektif
- d. Validasi Multi-Aksara: Demonstrasi efektivitas pada aksara Arab (KHATT) dan Latin (IAM)
- e. *State-of-the-Art* DIBCO: Mencapai SOTA pada H-DIBCO 2016, H-DIBCO 2017, dan H-DIBCO 2018 (setelah *fine-tuning*)

7. Relevansi dan Kesenjangan yang Teridentifikasi

Meskipun ERB-MultiTask merepresentasikan terobosan perintis dalam integrasi HTR dengan peningkatan dokumen, beberapa kesenjangan dapat diidentifikasi:

- a. Diskriminator Modalitas Tunggal: Evaluasi hanya pada modalitas visual tanpa pertimbangan koherensi struktur teks atau kualitas sekuensial. Diskriminator tidak peka terhadap apakah teks terbaca atau tidak.
- b. Keterbatasan Arsitektur Pengenal: CRNN berbasis BiGRU memiliki keterbatasan dalam menangkap dependensi jarak jauh dibandingkan arsitektur modern berbasis *Transformer* atau mekanisme *attention*.
- c. Pembobotan *Loss* Manual: Meskipun ada studi ablasi, pembobotan λ dan β masih ditentukan manual tanpa mekanisme adaptif seperti GradNorm atau pembobotan ketidakpastian.
- d. Evaluasi Terpisah: Kualitas visual dan keterbacaan dievaluasi secara terpisah. Tidak ada metrik tunggal yang mengukur kompromi optimal antara kedua objektif.

II.4.2 DE-GAN: Peningkatan Dokumen dengan Pendekatan Adversarial

1. Arsitektur dan Karakteristik

DE-GAN merepresentasikan pendekatan GAN untuk peningkatan dokumen dengan karakteristik:

- a. Kerangka Kerja Adversarial: Mengadaptasi GAN bersyarat (cGANs) untuk peningkatan dokumen dengan generator U-Net dan diskriminator PatchGAN
- b. Kemampuan Multi-Tugas: Menangani binarisasi, penghilangan kekaburan, penghapusan tanda air, dan pembersihan dalam satu kerangka kerja
- c. Evaluasi OCR Pascapemrosesan: Mengevaluasi dampak peningkatan terhadap performa OCR, namun OCR tidak terintegrasi dalam pelatihan
- d. Kontras dengan ERB: Berbeda dari ERB-MultiTask Souibgui **and others** (2021b) yang mengintegrasikan pengenalan, DE-GAN mengambil pendekatan tanpa integrasi

2. Perbedaan Pendekatan: DE-GAN vs ERB-MultiTask

- a. Tidak Ada Integrasi HTR: DE-GAN hanya mengoptimasi kualitas visual tanpa supervisi dari pengenalan
- b. Evaluasi Terpisah: Evaluasi OCR/HTR dilakukan pasca-proses, bukan sebagai bagian dari tujuan pelatihan
- c. Optimasi Tujuan Tunggal: Hanya menggunakan *loss* adversarial dan *loss* rekonstruksi (BCE), tanpa komponen keterbacaan
- d. Kronologi: ERB-MultiTask dan DE-GAN dipublikasikan pada tahun yang sama dengan pendekatan yang berbeda.

II.4.3 Analisis Komparatif: ERB-MultiTask vs DE-GAN

Perbandingan antara ERB-MultiTask dan DE-GAN mengungkapkan dua paradigma berbeda dalam pendekatan restorasi dokumen berorientasi HTR. Tabel ?? merangkum perbedaan fundamental antara kedua metode.

Tabel II.4 Perbandingan ERB-MultiTask dan DE-GAN (Urutan Kronologis)

Aspek	ERB-MultiTask	DE-GAN
Integrasi HTR	✓ (Dalam siklus pelatihan)	× (<i>Post-hoc</i> saja)
Fungsi <i>Loss</i>	$\mathcal{L}_{adv} + BCE + \lambda \cdot CTC$	$\mathcal{L}_{adv} + BCE$
Pengenalan	CRNN (CNN-BiGRU)	Tidak digunakan
Evaluasi	Visual + Keterbacaan	Visual saja
Optimisasi	Objektif Ganda	Objektif Tunggal
Dukungan Aksara	Multi-aksara (Arab+Latin)	Multi-tugas
Kanal Publikasi	Jurnal Pengenalan Pola	IEEE TETCI

1. Kontribusi pada Pemrosesan Dokumen Multi-Tugas

DE-GAN memperkenalkan beberapa masalah baru yang menjadi fokus penelitian selanjutnya:

- Penghilangan Tanda Air Padat: Berhasil mengatasi masalah tanda air/stempel padat pada dokumen dengan PSNR 40,98 dan SSIM 0,998, mengungguli metode citra alami (Dekel **and** others (2024): PSNR 36,02, Wu **and** He (2023): PSNR 23,37)
- Penghilangan Kekaburan Dokumen: Mencapai PSNR 20,37 dB, mengungguli CNN dasar (19,36 dB) dan pix2pix-HD (19,89 dB)
- Aplikasi Dokumen Nyata: Berhasil diterapkan pada dokumen historis alami dengan degradasi seperti noda dan tembusan

2. Perbandingan Komprehensif dengan Metode GAN Lain

DE-GAN dibandingkan secara langsung dengan metode GAN lain pada H-DIBCO 2018:

- vs CycleGAN: DE-GAN superior (PSNR 16,16 vs 11,00, F-measure 77,59 vs 56,33)
- vs pix2pix-HD: DE-GAN lebih baik (PSNR 16,16 vs 14,42, F-measure 77,59 vs 72,79) dengan data pelatihan yang lebih sedikit
- vs FCN (U-Net): DE-GAN mengungguli untuk pembersihan dokumen (PSNR 38,12 vs 36,02)

3. Evaluasi Komprehensif dan Kesenjangan

Meskipun DE-GAN telah mengevaluasi keterbacaan secara komprehensif, terdapat beberapa keterbatasan fundamental dalam pendekatan mereka:

a. Evaluasi OCR Pascapelatihan:

Evaluasi keterbacaan dilakukan setelah pelatihan GAN selesai, bukan diintegrasikan dalam siklus optimisasi. Artinya, Generator dioptimasi hanya untuk kualitas visual, bukan untuk kinerja OCR. Kesenjangan ini signifikan karena peningkatan visual tidak selalu linear dengan peningkatan keterbacaan.

b. Jalur Pelatihan Terpisah:

Skenario pembelajaran progresif memerlukan dua tahap pelatihan terpisah:

- a. Pelatihan GAN untuk peningkatan kualitas dokumen
- b. Pelatihan HTR pada hasil peningkatan kualitas

Pendekatan ini kurang efisien dan tidak memanfaatkan umpan balik langsung dari evaluasi HTR untuk panduan selama pelatihan.

c. Diskriminator Hanya-Visual:

Diskriminator DE-GAN hanya mengevaluasi apakah citra terlihat bersih tanpa mempertimbangkan:

- a. Preservasi struktur teks
- b. Integritas karakter
- c. Keterbacaan untuk sistem OCR

Diskriminator menggunakan *binary cross-entropy loss* standar tanpa pengkondisian pada konten teks.

d. Konflik Fungsi Tujuan:

Loss adversarial mendorong Generator untuk menghasilkan tekstur realistis yang mungkin mengganggu ekstraksi fitur pada model HTR. Derau ringan yang membuat citra terlihat lebih alami dapat sebenarnya menurunkan akurasi OCR.

e. Kurangnya Kesadaran Teks:

Tidak ada mekanisme untuk memastikan bahwa konten teks terjaga dengan baik. Generator dapat mengorbankan integritas karakter untuk penampilan visual yang lebih bersih.

4. Kesenjangan yang Teridentifikasi dari DE-GAN

Berdasarkan analisis komprehensif terhadap DE-GAN, terdapat tiga kesenjangan fundamental yang memotivasi penelitian lebih lanjut:

a. Evaluasi HTR Pascapelatihan:

DE-GAN mengevaluasi keterbacaan secara pascapelatihan dengan model HTR terpisah, bukan terintegrasi dalam siklus pelatihan. Hal ini mengindikasikan peluang untuk eksplorasi integrasi supervisi HTR langsung dalam proses optimisasi.

b. Diskriminator Visual Tunggal:

Diskriminator DE-GAN hanya mengevaluasi aspek visual tanpa mempertimbangkan koherensi struktur teks. Potensi untuk eksplorasi arsitektur yang mengevaluasi modalitas ganda (visual dan tekstual) masih terbuka.

c. Pelatihan Multi-Tahap:

DE-GAN menggunakan jalur pelatihan terpisah yang memerlukan koordinasi manual. Kesempatan untuk eksplorasi optimisasi yang lebih terintegrasi perlu dieksplorasi lebih lanjut.

Kesenjangan-kesenjangan ini membuka peluang penelitian untuk mengeksplorasi integrasi supervisi HTR langsung dalam siklus pelatihan dan diskriminator yang mengevaluasi modalitas ganda (visual dan tekstual).

II.4.4 Text-DIAE: Autoenkoder Invarian Degradasi Mandiri

Berbeda dari pendekatan adversarial DE-GAN yang mengandalkan pelatihan kompetitif antara generator dan diskriminator, Souibgui, Kessentini **and others** (2022b) mengusulkan Text-DIAE (*Text Degradation Invariant Autoencoder*) yang merepresentasikan paradigma alternatif melalui pembelajaran mandiri. Kerangka kerja ini berbeda secara fundamental dari metode berbasis GAN karena tidak memerlukan data berlabel untuk praplatihan, melainkan menggunakan tugas *pretext* untuk mempelajari representasi yang invarian terhadap degradasi.

A. Konsep Inti dan Arsitektur

Text-DIAE mengusulkan paradigma pelatihan dua-tahap yang revolusioner:

1. Pra-Pelatihan Mandiri: Model dilatih pada data tanpa label dengan tiga tugas pendahuluan:
 - a. Penutupan: Menutup 75% patch citra secara acak dan merekonstruksi konten asli
 - b. Kekaburan: Menerapkan degradasi kekaburan buatan dan rekonstruksi
 - c. Penambahan Derau: Menambahkan derau sintetis dan penghilangan derau
2. Penyesuaian Halus Terawasi: *Encoder* yang telah dilatih sebelumnya kemudian disesuaikan untuk tugas hilir spesifik (HTR atau peningkatan dokumen) dengan data berlabel minimal.

Inovasi kunci adalah invarian degradasi: *encoder* belajar menghasilkan representasi laten yang serupa untuk citra bersih dan berbagai versi yang mengalami degradasi dari gambar yang sama.

Arsitektur Vision Transformer

Text-DIAE menggunakan arsitektur berbasis ViT dengan struktur encoder-decoder:

- a. *Encoder*: Vision Transformer standar dengan *Multi-Head Self-Attention*
- b. *Decoder*: Transformer blocks yang merekonstruksi citra asli dari representasi laten
- c. Pembelajaran Multi-Tugas: Pelatihan simultan pada berbagai jenis degradasi

1. Keunggulan Komparatif Text-DIAE

Text-DIAE menunjukkan beberapa keunggulan signifikan:

a. Efisiensi Data:

Mebutuhkan 43-166 kali lebih sedikit data untuk konvergen dibandingkan metode pembelajaran kontrasif seperti SeqCLR dan SimCLR. Pada eksperimen IAM, Text-DIAE hanya menggunakan 18,2M sampel vs 409M sampel untuk metode sebelumnya.

b. Kinerja Unggul:

Mencapai peningkatan akurasi hingga +20 poin pada teks tulisan tangan (IAM) dan +30 poin pada teks pemandangan (IIIT5K, ICDAR13) dibandingkan metode pembelajaran mandiri terkini.

c. Hasil Terkini:

Pada pendekatan binarisasi dokumen DIBCO, Text-DIAE mengungguli semua metode sebelumnya termasuk DocEnTr dengan peningkatan PSNR signifikan (+2 poin pada skala logaritmik untuk penghilangan kekaburan).

d. Kemampuan Tugas Ganda:

Satu kerangka kerja yang dapat menangani pengenalan teks dan peningkatan dokumen secara bersamaan, menunjukkan representasi yang lebih universal.

Analisis Mendalam: Keterbatasan untuk Dokumen Historis

Meskipun mencapai hasil yang mengesankan, Text-DIAE memiliki keterbatasan khususnya untuk aplikasi dokumen historis:

a. Kesenjangan antara Invarian dan Keterbacaan:

Text-DIAE mengoptimalkan invarian degradasi (representasi sama untuk citra bersih/ yang mengalami degradasi), namun tidak secara eksplisit mengoptimalkan keterbacaan teks untuk sistem HTR. Eksperimen menunjukkan peningkatan kualitas visual tidak selalu linear dengan penurunan CER.

b. Keterbatasan Degradasi Sintetis:

Prapelatihan menggunakan degradasi sintetis (penutupan, kekaburan, derau)

yang mungkin tidak menangkap karakteristik kompleks dari degradasi alami dokumen historis seperti tembusan, bercak cokelat, atau degradasi kimia.

c. Ketiadaan Pelatihan Adversarial:

Tanpa komponen adversarial, Text-DIAE cenderung menghasilkan keluaran yang terlalu halus. Hal ini terlihat dari perbandingan kualitatif dengan DocEnTr, yaitu Text-DIAE menghasilkan tekstur yang kurang realistis.

d. Kompleksitas Komputasi:

Kompleksitas kuadratik dari mekanisme *self-attention* membuatnya kurang praktis untuk dokumen historis beresolusi tinggi yang umum dalam arsip.

2. Analisis Eksperimental: Kinerja OCR

Eksperimen menarik dari Text-DIAE menunjukkan:

- a. Pada tugas penghilangan kekaburan, Text-DIAE mengurangi CER dari 78,86% (asli) menjadi 8,94% (vs DocEnTr: 18,51%)
- b. Namun, CER absolut masih jauh dari data dasar (4,88%)
- c. Ini menunjukkan bahwa meskipun peningkatan signifikan, masih ada kesenjangan antara peningkatan kualitas visual dan keterbacaan teks optimal

3. Relevansi dan Kesenjangan yang Teridentifikasi

Text-DIAE merepresentasikan kemajuan penting dalam pembelajaran mandiri untuk pemrosesan dokumen. Namun, beberapa kesenjangan masih dapat diidentifikasi:

a. Optimisasi Invarian vs Keterbacaan:

Text-DIAE mengoptimalkan invarian terhadap degradasi, namun tidak secara eksplisit mengoptimalkan untuk kinerja HTR pada tahap lanjutan. Supervisi langsung dari model pengenalan teks belum dieksplorasi.

b. Degradasi Sintetis:

Prapelatihan menggunakan degradasi sintetis terkontrol yang mungkin berbeda dengan pola degradasi dokumen historis autentik.

c. Tanpa Komponen Adversarial:

Text-DIAE murni menggunakan loss rekonstruksi tanpa pelatihan adversarial, yang berpotensi menghasilkan keluaran yang terlalu halus.

d. Pelatihan Dua-Tahap:

Paradigma *pre-training* kemudian *fine-tuning* memerlukan koordinasi multi-tahap dibandingkan optimisasi ujung-ke-ujung.

II.4.5 DocEnTr: Transformer untuk Peningkatan Dokumen

Souibgui **and others** (2022) memperkenalkan DocEnTr (*Document Enhancement Transformer*), pendekatan inovatif yang sepenuhnya mengandalkan arsitektur *transformer* tanpa menggunakan lapisan CNN sama sekali. Kerangka kerja ini merepresentasikan evolusi terbaru dalam peningkatan kualitas dokumen dengan memanfaatkan kemampuan mekanisme *self-attention* untuk pemrosesan global.

1. Arsitektur dan Inovasi Fundamental

DocEnTr mengusulkan *encoder-decoder* berbasis *transformer* yang sepenuhnya berbeda dari pendekatan CNN+Transformer hibrida:

a. Arsitektur Sepenuhnya *Transformer*:

Berbeda dengan pendekatan sebelumnya yang masih menggunakan CNN untuk ekstraksi fitur, DocEnTr menggunakan murni lapisan *transformer*. Masukan citra langsung dibagi menjadi *patch* (16x16 piksel) dan diproses tanpa menggunakan lapisan CNN.

b. Mekanisme *Self-Attention* Global:

Setiap *patch* dapat mengakses informasi dari semua *patch* lain secara langsung melalui *multi-head self-attention*. Ini memberikan kemampuan untuk menangkap dependensi jarak jauh tanpa batasan *receptive field* yang karakteristik CNN.

c. Pemrosesan Berbasis *Patch*:

Citra diproses pada tingkat *patch* dengan *positional encoding* untuk mempertahankan informasi spasial. Dekoder merekonstruksi citra bersih dari *patch-patch* yang telah ditingkatkan kualitasnya.

2. Keunggulan Komparatif DocEnTr

DocEnTr menunjukkan beberapa keunggulan signifikan dibandingkan metode berbasis CNN:

a. Pemahaman Konteks Global:

Mekanisme *self-attention* memungkinkan model untuk memahami konteks global dari dokumen, yang penting untuk konsistensi visual dan koherensi struktural.

b. Tanpa *Inductive Bias*:

Tanpa *inductive bias* konvolusional, model dapat mempelajari representasi yang lebih fleksibel dan tidak terbatas pada pola lokal.

c. Kinerja Superior:

Pada tolok ukur DIBCO, DocEnTr mencapai kinerja *state-of-the-art* dengan PSNR signifikan lebih tinggi dibandingkan metode berbasis CNN.

3. Variasi Model dan Konfigurasi

DocEnTr tersedia dalam tiga konfigurasi yang menyeimbangkan kompleksitas komputasi dan kinerja:

- a. DocEnTr-Small: 6 lapisan, 512 dimensi, 4 *attention heads*, 17M parameter
- b. DocEnTr-Base: 12 lapisan, 768 dimensi, 8 *attention heads*, 68M parameter
- c. DocEnTr-Large: 24 lapisan, 1024 dimensi, 16 *attention heads*, 255M parameter

4. Evaluasi Komprehensif untuk Dokumen Historis

Meskipun DocEnTr menunjukkan hasil mengagumkan pada tolok ukur standar, terdapat beberapa pertimbangan penting untuk aplikasi pada dokumen historis:

a. Kurangnya *Inductive Bias* Fitur Lokal:

Dokumen historis seringkali mengandung goresan halus dan detail tekstur lokal yang penting untuk pengenalan karakter. Tanpa *inductive bias* konvolusional yang secara alami mendeteksi tepi dan pola lokal, DocEnTr mungkin kesulitan mempelajari detail lokal yang krusial.

b. Kompleksitas Komputasi:

Self-attention memiliki kompleksitas kuadratik terhadap jumlah *patch*, membuatnya kurang efisien untuk dokumen beresolusi tinggi yang umum dalam arsip historis.

c. Kebutuhan Data Pelatihan:

Model berbasis *transformer* biasanya memerlukan himpunan data pelatihan yang lebih besar dibandingkan CNN untuk mencapai kinerja optimal. Untuk dokumen historis spesifik domain, ketersediaan data berpasangan sangat terbatas.

d. Kesenjangan dengan Optimisasi HTR:

Sama seperti metode sebelumnya, DocEnTr dioptimasi hanya untuk kualitas visual (*loss* MSE) tanpa pertimbangan eksplisit terhadap keterbacaan teks untuk sistem HTR.

5. Relevansi dan Kesenjangan yang Teridentifikasi

DocEnTr menunjukkan potensi arsitektur *transformer* untuk restorasi dokumen, namun kesenjangan fundamental dapat diidentifikasi:

- a. Optimisasi Visual Saja: *Loss* MSE mengoptimalkan kesamaan piksel tanpa

pertimbangan eksplisit keterbacaan untuk HTR.

- b. Tanpa Komponen Adversarial: Ketiadaan pelatihan adversarial berpotensi menghasilkan keluaran yang terlalu halus.
- c. Kompleksitas Komputasi: Arsitektur *transformer* murni memiliki kompleksitas kuadratik untuk dokumen resolusi tinggi.

Kesenjangan ini membuka peluang eksplorasi untuk integrasi supervisi HTR eksplisit dan kombinasi dengan pelatihan adversarial.

II.4.6 Debat: Transformer vs GAN

Literatur terkini mengungkapkan pertentangan metodologis yang belum terselesaikan antara dua paradigma dominan:

1. Posisi 1: Kecukupan *Transformer* Murni

Kelompok ini berargumen bahwa arsitektur *transformer* murni dengan *loss* rekonstruksi (MSE) sudah memadai untuk restorasi dokumen. DocEnTr mencapai PSNR tertinggi (35,2 dB) tanpa komponen adversarial, menunjukkan bahwa mekanisme *self-attention* global dapat menghasilkan restorasi berkualitas tinggi. Text-DIAE mendemonstrasikan efisiensi data superior (43-166x lebih sedikit data) melalui pembelajaran invarian degradasi.

Argumen Kunci: (1) Stabilitas pelatihan lebih tinggi tanpa dinamika adversarial, (2) Tidak ada *mode collapse* atau ketidakstabilan GAN, (3) Metrik PSNR/SSIM kompetitif atau superior.

2. Posisi 2: Kebutuhan Pelatihan Adversarial (DE-GAN, ERB-MultiTask, Pix2Pix)

Kelompok ini berargumen bahwa pelatihan adversarial esensial untuk menghasilkan restorasi yang realistis secara perseptual. DE-GAN menunjukkan bahwa meskipun PSNR lebih rendah (15,5 dB), hasil visual lebih natural dengan tekstur yang dipertahankan. *Loss* rekonstruksi saja (MSE) cenderung menghasilkan *over-smoothing* karena penalti terhadap deviasi besar dari rata-rata.

Argumen Kunci: (1) Realisme perseptual tidak diukur oleh PSNR, (2) Detail frekuensi tinggi lebih terjaga, (3) *Adversarial loss* memberikan umpan balik yang lebih sesuai dengan persepsi manusia.

3. Bukti Empiris dari Perbandingan Kualitatif

Perbandingan kualitatif dalam literatur menunjukkan kompromi: DocEnTr menghasilkan citra dengan PSNR tinggi namun cenderung *over-smoothed* (hilangnya tekstur kertas), sementara DE-GAN dengan PSNR lebih rendah mempertahankan tekstur natural namun dapat menghasilkan artefak adversarial. Text-DIAE mencoba posisi tengah dengan *degradation-invariant learning*, namun tanpa komponen adversarial juga menghasilkan tekstur kurang realistis dibanding GAN.

4. Pertentangan yang Belum terselesaikan

Debat ini mencerminkan pertentangan fundamental dalam restorasi citra: optimisasi metrik objektif (PSNR) versus kualitas perseptual subjektif. Untuk dokumen historis, pertanyaan mendasar adalah: apakah realisme tekstur penting untuk keterbacaan HTR, atau kesetiaan piksel (PSNR tinggi) lebih relevan? Literatur belum memberikan jawaban konklusif karena evaluasi HTR tidak dilakukan secara konsisten pada kedua paradigma. Kesenjangan ini menggarisbawahi pentingnya protokol evaluasi yang mencakup metrik visual dan fungsional secara bersamaan.

II.4.7 CycleGAN dan Pembelajaran Tak Berpasangan untuk Peningkatan Dokumen

Zhu **and others** (2017) memperkenalkan CycleGAN untuk translasi citra-ke-citra tak berpasangan, yang kemudian diadopsi untuk restorasi dokumen oleh beberapa peneliti. Kerangka kerja ini menarik untuk restorasi dokumen karena data berpasangan (versi yang mengalami degradasi dan bersih dari dokumen yang sama) sangat sulit diperoleh untuk dokumen historis.

1. Konsistensi Siklus sebagai Kendala

CycleGAN menggunakan dua generator: $G_{A \rightarrow B}$ yang memetakan dari domain yang mengalami degradasi ke domain bersih, dan $G_{B \rightarrow A}$ yang memetakan sebaliknya. Tujuan pelatihan mencakup *loss* adversarial untuk kedua arah dan *loss* konsistensi siklus:

$$\mathcal{L}_{cycle} = \mathbb{E}_{x \sim p_A} [\|G_{B \rightarrow A}(G_{A \rightarrow B}(x)) - x\|_1] + \mathbb{E}_{y \sim p_B} [\|G_{A \rightarrow B}(G_{B \rightarrow A}(y)) - y\|_1] \quad (\text{II.4})$$

Intuisi adalah bahwa pemetaan harus bijektif: jika kita memetakan citra yang mengalami degradasi ke bersih kemudian memetakan balik ke yang mengalami

degradasi, kita harus memulihkan citra asli.

2. Analisis untuk Restorasi Dokumen

Aplikasi CycleGAN untuk restorasi dokumen menunjukkan hasil yang beragam. Keuntungan utama adalah tidak memerlukan data berpasangan, yang sangat berharga untuk dokumen historis. Namun, beberapa masalah fundamental muncul:

a. *Mode Collapse* dan Ketidakstabilan:

Pelatihan CycleGAN terkenal tidak stabil. Tanpa supervisi berpasangan, model dapat konvergen ke solusi yang memenuhi konsistensi siklus tetapi tidak menghasilkan restorasi yang bermakna. Misalnya, generator dapat mempelajari pemetaan identitas trivial yang hanya menyalin masukan, yang secara teknis memenuhi konsistensi siklus tetapi tidak melakukan restorasi.

b. Kurangnya Jaminan Preservasi Konten:

Konsistensi siklus tidak secara eksplisit menjamin preservasi dari konten teks. Model dapat mengubah bentuk karakter atau menghapus karakter selama pemetaan maju-mundur memulihkan struktur citra keseluruhan.

c. Kompleksitas Pelatihan:

Pelatihan CycleGAN memerlukan penalaan hati-hati dari berbagai bobot *loss* dan dinamika pelatihan dari empat jaringan (dua generator, dua diskriminator) secara simultan. Hal ini membuat kerangka kerja ini kurang praktis dan kurang dapat direproduksi.

3. Penelitian Terkait oleh Ni **and others** (2024)

Pengembangan terbaru mencoba mengatasi beberapa keterbatasan dengan menambahkan *loss* perseptual dan *loss* identitas. Namun, masalah fundamental dari kurangnya optimisasi keterbacaan eksplisit tetap ada.

4. Kesenjangan yang Teridentifikasi

CycleGAN untuk restorasi dokumen mengalami ketidakstabilan dan kekurangan jaminan preservasi teks. Yang lebih penting, sama seperti metode sebelumnya, tidak ada integrasi dengan evaluasi HTR.

II.4.8 Refleksi Komprehensif terhadap Bias Metodologis dalam Literatur

Analisis komprehensif terhadap literatur restorasi dokumen mengungkapkan beberapa bias sistematis yang perlu dipertimbangkan dalam interpretasi temuan dan generalisasi hasil penelitian. Kesadaran terhadap bias-bias ini krusial untuk

pengembangan metodologi yang lebih tangguh dan interpretasi yang akurat terhadap kontribusi setiap metode dalam konteks dokumen historis spesifik domain.

1. Bias Himpunan Data dan Representasi

Mayoritas tolok ukur yang dominan dalam literatur (DIBCO 2009-2019, H-DIBCO 2010-2018, PALM 2012-2018) didominasi oleh dokumen historis Eropa dengan aksara Latin. Dari 284 citra yang tersedia dalam kompetisi seri DIBCO, lebih dari 90 persen merupakan dokumen berbahasa Latin/Eropa. Generalisasi metode yang dilatih dan dievaluasi pada himpunan data ini ke aksara non-Latin (Arab, Jawa Kuno, Belanda Kuno, Sansekerta) belum teruji secara luas dalam literatur. Bias geografis dan linguistik ini menciptakan pertanyaan tentang universalitas pendekatan yang diklaim sebagai terkini.

2. Bias Metrik Evaluasi

Dominasi PSNR dan SSIM sebagai metrik evaluasi utama dalam literatur menciptakan optimisasi implisit terhadap metrik ini. Wang **and others** (2004) dalam studi seminal tentang Penilaian Kualitas Citra menunjukkan bahwa korelasi antara PSNR dengan kualitas perseptual manusia hanya berkisar 0,60-0,75, jauh dari korelasi sempurna. Lebih fundamental lagi, metrik visual tidak mengukur dampak terhadap keterbacaan untuk sistem HTR—kesenjangan signifikan yang baru mulai diakui dalam literatur terkini Jadhav **and** Raghuwanshi (2022). Praktik menggunakan metrik visual sebagai ukuran pengganti untuk kualitas fungsional menciptakan bias evaluasi yang signifikan.

3. Bias Publikasi dan Pelaporan Selektif

Literatur akademik cenderung melaporkan hasil positif dan metode yang berhasil mencapai peningkatan kinerja. Metode yang gagal, pendekatan yang tidak konvergen, atau ablasi negatif jarang terdokumentasi dengan detail memadai, menciptakan potensi bias publikasi. Ferguson **and** Heene (2012) memperkirakan bahwa dalam bidang pembelajaran mesin, hingga 40 persen eksperimen negatif tidak dipublikasikan. Dalam konteks restorasi dokumen, bias ini dapat menyebabkan estimasi berlebihan terhadap efektivitas pendekatan tertentu dan estimasi kurang terhadap kompleksitas masalah.

4. Bias Temporal dan Arsitektur

Dominasi CNN dalam literatur 2015-2020 dan transisi ke Transformer 2020-sekarang mencerminkan tren riset global dalam pembelajaran mendalam, bukan bukti konklusif superioritas inheren untuk semua kasus penggunaan restorasi

dokumen. Penelitian cenderung mengadopsi arsitektur yang sedang populer (*ViT*, *Swin Transformer*) tanpa justifikasi teoretis atau empiris yang kuat untuk dokumen historis spesifik domain. Bias ini dapat mengalihkan perhatian dari pendekatan yang lebih sederhana namun efektif, atau kombinasi yang lebih seimbang antara arsitektur klasik dan modern.

5. Bias Degradasi Sintetis

Sebagian besar himpunan data pelatihan menggunakan degradasi sintetis yang dihasilkan secara algoritmik (derau Gaussian, keaburan gerak, tembusan tinta sintetis). Meskipun praktis untuk menghasilkan data berpasangan, degradasi sintetis tidak sepenuhnya mereplikasi kompleksitas degradasi alami dokumen historis yang melibatkan proses kimia, biologis, dan fisik selama berabad-abad. Souibgui **and others** (2022) mengidentifikasi kesenjangan domain signifikan antara model yang dilatih pada degradasi sintetis dan performa pada degradasi nyata, dengan penurunan PSNR hingga 3-5 dB.

6. Implikasi untuk Penelitian

Kesadaran terhadap bias-bias sistematis ini memiliki implikasi penting untuk interpretasi mendalam terhadap literatur dan pengembangan metode yang lebih tangguh. Penelitian di bidang restorasi dokumen perlu: (1) diversifikasi himpunan data evaluasi untuk mencakup aksara non-Latin dan dokumen non-Eropa, (2) adopsi metrik evaluasi yang lebih komprehensif termasuk dampak terhadap HTR, (3) pelaporan transparan terhadap eksperimen negatif dan ablation yang gagal, (4) justifikasi teoretis dan empiris untuk pemilihan arsitektur, dan (5) validasi pada degradasi autentik, bukan hanya sintetis.

Dengan mempertimbangkan refleksi mendalam di atas, pengembangan metodologi dalam penelitian ini akan mengatasi bias-bias yang teridentifikasi melalui evaluasi komprehensif pada dokumen historis autentik dengan metrik ganda (visual dan fungsional).

Ringkasan Seksi 2.4: Analisis 9 metode terkini (ERB-MultiTask, DE-GAN, Text-DIAE, DocEnTr, CycleGAN) mengungkapkan evolusi dari 4 fase (Classical 1979-2010, DL Awal 2015-2018, Adversarial 2017-2024, New Paradigm 2023-2024). Hanya 22% metode melaporkan evaluasi HTR, dengan korelasi PSNR-CER hanya $r=0.60-0.70$, menunjukkan kesenjangan optimisasi visual-fungsional yang signifikan.

II.5 Pengenalan Teks Tulisan Tangan: Arsitektur dan Tantangan

Analisis mendalam terhadap metode restorasi dokumen pada bagian sebelumnya mengungkapkan kesenjangan signifikan: optimasi kualitas visual tidak otomatis menjamin peningkatan keterbacaan teks untuk sistem HTR. Untuk memahami mengapa integrasi supervisi berorientasi HTR menjadi esensial, diperlukan pemahaman tentang karakteristik, mekanisme, dan tantangan sistem Handwritten Text Recognition itu sendiri. Bagian ini mengkaji evolusi arsitektur HTR dari pendekatan tradisional hingga sistem berbasis pembelajaran mendalam modern, dengan fokus pada mekanisme yang menentukan sensitivitas HTR terhadap kualitas citra masukan. Pemahaman ini menjadi fondasi untuk merancang strategi restorasi yang tidak hanya menghasilkan citra dengan kualitas visual tinggi, tetapi juga secara eksplisit dioptimasi untuk performa pengenalan teks.

II.5.1 Evolusi Arsitektur HTR


Pengenalan Teks Tulisan Tangan telah berkembang dari pendekatan pencocokan templat tradisional ke sistem berbasis pembelajaran mendalam modern. Memahami evolusi ini penting untuk menghargai mengapa optimisasi berorientasi HTR sangat penting untuk restorasi dokumen.

1. Pendekatan Tradisional: HMM dan Rekayasa Fitur

Sistem HTR awal menggunakan Model Markov Tersembunyi (*Hidden Markov Models* - HMM) dengan fitur yang dirancang manual seperti fitur arah, histogram gradien, atau fitur struktural. Pendekatan ini memerlukan segmentasi hati-hati dari baris teks ke karakter individual, diikuti oleh pengenalan tingkat karakter.

Keterbatasan: Segmentasi karakter sangat menantang untuk teks tulisan tangan dengan karakter terhubung atau goresan yang tumpang tindih. Rekayasa fitur memerlukan keahlian domain dan fitur tidak dapat digeneralisasi di berbagai gaya tulisan atau bahasa.

2. Era Pembelajaran Mendalam: Arsitektur CRNN



Gambar II.5 Arsitektur CRNN yang mengombinasikan CNN untuk ekstraksi fitur visual dengan RNN untuk pemodelan konteks dan CTC untuk transkripsi tanpa segmentasi.

Shi **and others** (2016) memperkenalkan CRNN (Jaringan Saraf Rekuren Konvolusional) yang menjadi terobosan untuk pengenalan urutan-ke-urutan tanpa segmentasi eksplisit. Arsitektur terdiri atas:

a. Lapisan CNN

Mengekstrak fitur visual dari citra masukan dalam bentuk urutan fitur. Lapisan konvolusional dengan *pooling* mengurangi dimensi spasial secara vertikal tetapi mempertahankan urutan horizontal.

b. Lapisan Rekuren

LSTM dua arah memproses urutan fitur untuk menangkap dependensi konteks. LSTM maju menangkap konteks kiri, LSTM mundur menangkap konteks kanan, memungkinkan model untuk bernalar tentang karakter dalam konteks dari karakter di sekitarnya.

c. Lapisan Transkripsi

Klasifikasi Temporal Koneksionis (*Connectionist Temporal Classification* -


CTC) *loss* memungkinkan pelatihan tanpa memerlukan label yang selaras. CTC memungkinkan model untuk mempelajari penyelarasan secara implisit.

Kontribusi: CRNN menghilangkan kebutuhan untuk segmentasi karakter dan mencapai hasil *state-of-the-art* pada berbagai tolok ukur. Arsitektur ini menjadi standar *de facto* untuk HTR tingkat baris.

II.5.2 Loss CTC: Mekanisme dan Implikasi untuk Restorasi

Loss CTC, diperkenalkan oleh Graves **and others** (2006), adalah komponen krusial yang memungkinkan pelatihan model HTR tanpa penyelarasan eksplisit antara fitur masukan dan karakter keluaran.

1. Penyelarasan CTC dan Token Kosong



Gambar II.6 Mekanisme CTC (Klasifikasi Temporal Koneksionis) untuk penyelarasan otomatis antara fitur masukan dan karakter keluaran tanpa memerlukan segmentasi eksplisit.

CTC memperkenalkan token kosong khusus (ϵ) yang merepresentasikan tidak ada karakter pada langkah waktu tertentu. Model bebas untuk mengeluarkan token kosong atau mengulangi karakter, dan CTC secara otomatis menciutkan karakter berulang dan menghapus token kosong untuk menghasilkan transkripsi akhir.

Secara formal, probabilitas CTC untuk urutan keluaran y diberikan masukan x adalah:

$$p(y|x) = \sum_{\pi \in \mathcal{B}^{-1}(y)} \prod_{t=1}^T p_t(\pi_t|x) \quad (\text{II.5})$$

dengan $\mathcal{B}$ adalah fungsi penciutan yang memetakan urutan dengan pengulangan dan token kosong ke keluaran akhir, dan $p_t(\pi_t|x)$ adalah probabilitas dari token π_t pada langkah waktu t .

2. Implikasi untuk Restorasi Dokumen

Memahami mekanisme CTC sangat penting untuk menghargai mengapa restorasi berorientasi HTR penting:

a. Sensitivitas terhadap Kualitas Fitur

CTC bergantung pada fitur diskriminatif yang jelas untuk setiap langkah waktu. Degradasi yang mengaburkan batas atau menciptakan fitur ambigu akan berdampak signifikan pada kepercayaan dan akurasi CTC.

b. Pentingnya Kontinuitas Goresan

Goresan terputus akibat pemudaran dapat menyebabkan emisi token kosong yang keliru atau pemisahan karakter. generator yang menjaga kontinuitas goresan akan secara langsung meningkatkan kualitas penyelarasan CTC.

c. Propagasi Kesalahan dalam Lapisan Rekuren

Lapisan LSTM meneruskan informasi lintas langkah waktu. Kesalahan atau ketidakpastian di langkah waktu awal dapat bertambah dan memengaruhi prediksi selanjutnya. Restorasi yang meningkatkan pengenalan karakter awal akan memiliki manfaat yang berantai.

3. Motivasi untuk Integrasi

Fakta bahwa *loss* CTC secara langsung mengukur akurasi pengenalan teks menjadikannya tujuan yang ideal untuk memandu generator dalam proses restorasi. Dengan meminimalkan *loss* CTC pada citra yang direstorasi, generator secara eksplisit dioptimisasi untuk menghasilkan citra yang dapat dibaca oleh sistem HTR.

II.5.3 Paradigma Transformer: Dari Pengenalan hingga Peningkatan Dokumen

Meskipun arsitektur CRNN dengan mekanisme CTC telah menjadi standar *de facto* untuk HTR, perkembangan terkini menunjukkan transisi paradigmatis menuju arsitektur berbasis *Transformer*. Keterbatasan inheren dari LSTM—khususnya kesulitan menangkap dependensi jarak jauh dan sifat sekuensial yang membatasi paralelisasi—memotivasi eksplorasi mekanisme perhatian-diri (*self-attention*) yang dapat mengakses informasi dari seluruh sekuens secara langsung. Transisi ini memiliki implikasi signifikan untuk restorasi dokumen berorientasi HTR, karena pemilihan arsitektur pengenalan yang tepat dapat memengaruhi stabilitas gradien dan kualitas supervisi dalam siklus pelatihan integrasi.

Perkembangan terbaru dalam HTR telah mengadopsi arsitektur *Transformer*,

menggantikan lapisan rekuren dengan mekanisme *self-attention*. Diaz **and others** (2021) menunjukkan bahwa HTR berbasis *Transformer* dapat mencapai kinerja superior dengan paralelisasi yang lebih baik.

1. Aplikasi pada Peningkatan Dokumen

Evolusi terbaru dalam peningkatan dokumen ditandai oleh kemunculan DocEnTr dan Text-DIAE, yang menggunakan arsitektur *Transformer* penuh dengan pendekatan yang berbeda:

a. DocEnTr

Sepenuhnya *Transformer* dengan pembelajaran terawasi, mengoptimalkan *loss* MSE untuk peningkatan kualitas visual.

b. Text-DIAE

Prapelatihan mandiri dengan invarian degradasi, diikuti penalaan halus terawasi.

II.5.4 Pembelajaran Mandiri: Revolusi dalam Pemrosesan Dokumen

Text-DIAE merepresentasikan paradigma baru dalam pemrosesan dokumen: pembelajaran mandiri yang mengurangi ketergantungan pada data berlabel. Ini sangat relevan untuk domain dokumen historis yang data berlabelnya sangat terbatas.

1. Kontribusi Utama Pembelajaran Mandiri

- Efisiensi Data: Mengurangi kebutuhan data berlabel hingga 166 kali
- Generalisasi: Representasi yang lebih universal untuk berbagai tugas
- Skalabilitas: Memanfaatkan sejumlah besar dokumen historis tidak berlabel

2. Perbedaan Fundamental dengan Pembelajaran Terawasi

- Fungsi Tujuan: Pembelajaran mandiri menggunakan tujuan rekonstruksi (MSE), terawasi menggunakan *loss* spesifik tugas (CTC, entropi silang)
- Strategi Pelatihan: Dua tahap (prapelatihan + penalaan halus) vs *end-to-end*
- Kebutuhan Data: Data tidak berlabel untuk prapelatihan vs data berlabel untuk terawasi

3. Keterbatasan Pembelajaran Mandiri untuk Optimisasi Keterbacaan

Meskipun *Text-DIAE* menunjukkan efisiensi data yang mengesankan, pendekatan ini memiliki keterbatasan fundamental untuk optimisasi keterbacaan:

- Ketidaksesuaian Tujuan

Tujuan prapelatihan (penutupan, kekaburan, rekonstruksi derau) tidak secara eksplisit mengoptimalkan keterbacaan teks. Kesenjangan antara invarian degradasi dan kinerja HTR tetap ada.

b. Degradasi Sintetis vs Nyata

Tugas *pretext* menggunakan degradasi sintetis yang mungkin tidak representatif untuk pola degradasi dokumen historis nyata.

c. Keterbatasan Dua Tahap

Tahap penalaan halus masih terpisah dari evaluasi HTR. Tidak ada integrasi *end-to-end* antara peningkatan kualitas dan pengenalan.

II.5.5 Kompromi antara Pembelajaran Terawasi dan Mandiri

Evolusi paradigma pembelajaran dalam restorasi dokumen menimbulkan pertanyaan fundamental tentang *trade-off* antara efisiensi data dan kualitas hasil. Tabel ?? merangkum analisis komparatif antara paradigma pembelajaran terawasi dan mandiri, Analisis ini menyoroti *trade-off* fundamental antara efisiensi penggunaan data, kedalaman integrasi HTR, dan realisme visual hasil restorasi.

Tabel II.5 Perbandingan pendekatan Terawasi vs Mandiri untuk Peningkatan Kualitas Dokumen

Pendekatan	Efisiensi Data	Integrasi HTR	Realisme
Terawasi (DE-GAN)	Rendah	<i>Post-hoc</i>	Tinggi
Mandiri (Text-DIAE)	Sangat Tinggi	Tidak Ada	Sedang
Terawasi (DocEnTr)	Rendah	Tidak Ada	Sedang
Metode Usulan	Sedang	<i>End-to-End</i>	Tinggi

Berdasarkan perbandingan di atas, penelitian ini mengadopsi pendekatan hibrida yang strategis. Meskipun pembelajaran mandiri menawarkan efisiensi data, kebutuhan akan realisme visual tinggi dan akurasi teks pada dokumen historis menuntut penggunaan paradigma terawasi. Untuk memitigasi inefisiensi data dan ketidakstabilan yang umum pada metode terawasi murni, penelitian ini mengusulkan strategi *frozen recognizer*. Pendekatan ini memungkinkan integrasi HTR *end-to-end* yang stabil (seperti pada pembelajaran terawasi) namun dengan efisiensi komputasi yang lebih baik, menyeimbangkan kebutuhan akan kualitas visual (Realisme: Tinggi) dan keterbacaan fungsional (Integrasi HTR: *End-to-End*).

II.5.6 Arsitektur CNN+Transformer dan Justifikasi untuk Kasus Paleografi

1. Arsitektur Dasar HTR Transformer

HTR *Transformer* umumnya menggunakan *backbone* CNN untuk ekstraksi fitur yang diikuti oleh enkoder *Transformer* untuk pemodelan sekuens. Mekanisme *self-attention* memungkinkan model untuk memperhatikan posisi mana pun dalam sekuens, menangkap dependensi jarak jauh secara lebih efektif dibandingkan LSTM.

2. Justifikasi Pemilihan Arsitektur untuk Dokumen Paleografi

Pemilihan arsitektur CNN+*Transformer* didasarkan pada karakteristik spesifik dokumen kuno, termasuk variasi gaya tulisan yang ekstrem dan tingkat degradasi visual yang kompleks. Dokumen paleografi memiliki tantangan unik yang membutuhkan pendekatan arsitektur yang komprehensif:

- a. Variasi Gaya Tulisan yang Ekstrem: Dokumen kuno mengandung berbagai gaya tulisan (*scriptoria*) dengan karakteristik unik. Arsitektur CNN dengan ekstraksi fitur progresif dapat menangkap hierarki fitur visual, mulai dari goresan dasar hingga kompleksitas karakter, melalui 4 tahap yang dirancang secara adaptif.
- b. Dependensi Jarak Jauh dalam Karakter: Tulisan tangan historis seringkali memiliki struktur yang bagian awal karakternya memengaruhi bagian akhir. Mekanisme 8 *Multi-Head Attention* pada *Transformer* memungkinkan model menangkap dependensi jarak jauh ini, yang penting untuk membedakan karakter yang mirip secara visual tetapi berbeda secara struktural.
- c. Konsistensi Kontekstual antar Karakter: Dalam naskah kuno, kemunculan suatu karakter seringkali dipengaruhi oleh karakter sebelumnya (konteks linguistik). Tumpukan dari 6 lapisan enkoder *Transformer* memberikan kapasitas pemodelan urutan yang mendalam untuk menangkap pola-pola kontekstual ini.
- d. Ketangguhan terhadap Degradasi: Dokumen kuno umumnya mengalami berbagai bentuk degradasi (pemudaran, noda, sobekan). Kombinasi CNN untuk ekstraksi fitur invarian dan *Transformer* untuk pemodelan sekuens memberikan ketangguhan terhadap derau dan variasi visual yang tidak terduga.
- e. Generalisasi Antar Periode Waktu: Arsitektur ini dirancang untuk generalisasi lintas periode historis dengan menangkap fitur fundamental dari tulisan tangan yang konsisten melintasi gaya penulisan berbeda.

II.5.7 Analisis Komparatif: CNN+*Transformer* vs HTR Konvensional

1. Perbedaan Arsitektur Fundamental

Arsitektur yang diusulkan berbeda secara fundamental dari HTR konvensional yang umumnya menggunakan CRNN atau LSTM. Perbedaan utamanya terletak pada penggunaan *Transformer* untuk meningkatkan kapasitas representasi dalam menangani kompleksitas dokumen kuno, seperti variasi gaya tulisan ekstrem dan dependensi karakter yang kompleks, yang sulit ditangani oleh model sekuensial biasa.

2. Keunggulan Komparatif dalam Konteks Dokumen Paleografi

Arsitektur CNN+*Transformer* menawarkan beberapa keunggulan fundamental dibandingkan dengan pendekatan HTR tradisional dalam konteks dokumen kuno:

- a. Kapasitas Representasi yang Lebih Tinggi: Tumpukan 6 enkoder *Transformer* dengan 8 *Multi-Head Attention* memberikan matriks konektivitas $O(n^2)$, memungkinkan setiap posisi dalam sekuens untuk berinteraksi langsung dengan semua posisi lain. Ini lebih unggul dibandingkan LSTM yang hanya memiliki dependensi sekuensial $O(n)$. Untuk dokumen kuno dengan panjang 128 karakter, *Transformer* memiliki 16.384 kemungkinan koneksi antar posisi, sementara LSTM hanya memiliki 127 koneksi sekuensial.
- b. Kemampuan Pemrosesan Paralel: Arsitektur *Transformer* memungkinkan pemrosesan paralel seluruh sekuens, berbeda dengan LSTM yang sifatnya sekuensial. Ini memberikan keuntungan komputasi signifikan untuk dokumen panjang. Pada perangkat keras modern dengan GPU, *Transformer* dapat mencapai percepatan 3-5x dibandingkan LSTM untuk sekuens dengan panjang lebih dari 64 karakter.
- c. Ekstraksi Fitur Adaptif: *Multi-Head Attention* memungkinkan model secara adaptif memfokuskan perhatian pada bagian gambar yang paling relevan untuk setiap karakter, sementara CNN dengan ekstraksi progresif menangkap fitur multi-skala dari goresan hingga kata. Setiap *head* dapat mempelajari representasi yang berbeda (arah goresan, batas karakter, diakritik) tanpa rekayasa fitur eksplisit.
- d. Penanganan Dependensi Jarak Jauh: Untuk dokumen kuno dengan karakter kompleks yang dapat memiliki komponen terpisah secara spasial (seperti ligatur Arab atau diakritik Latin), kemampuan menangkap dependensi jarak jauh menjadi krusial. LSTM dengan ukuran *hidden state* 128 hanya dapat mengingat informasi dari 50 langkah waktu sebelumnya, sementara *Transformer* dapat

mengakses informasi dari seluruh sekuens tanpa penurunan kualitas.

- e. Reduksi Masalah *Vanishing Gradient*: Dengan koneksi residual dalam *Transformer* dan koneksi langsung dalam CNN bergaya U-Net, arsitektur ini lebih tangguh terhadap *vanishing gradients*, memungkinkan pelatihan yang lebih stabil untuk model yang dalam. Aliran gradien dalam *Transformer* lebih efisien karena pemrosesan paralel dan jalur komputasi yang lebih pendek antara masukan dan keluaran.
- f. Skalabilitas untuk Kosakata Besar: Arsitektur *Transformer* lebih skalabel untuk kosakata yang besar (100+ karakter) karena mekanisme *attention* tidak terikat pada pemrosesan sekuensial. Ini penting untuk dokumen historis yang mungkin mengandung karakter kuno atau simbol khusus.

Keunggulan-keunggulan ini secara spesifik dirancang untuk mengatasi tantangan paleografi yang tidak dapat diselesaikan secara optimal oleh pendekatan HTR generik.

3. Relevansi untuk Eksplorasi Arsitektur HTR

Dalam konteks restorasi dokumen berorientasi HTR, pemilihan arsitektur pengenalan yang tepat menjadi pertimbangan penting. Eksplorasi penggunaan HTR berbasis *Transformer* sebagai komponen *frozen recognizer* dimotivasi oleh:

- a. Kinerja Mutakhir: HTR *Transformer* mencapai CER yang lebih rendah dibandingkan CRNN pada banyak tolok ukur, memberikan dasar yang lebih baik untuk evaluasi.
- b. Gradien Stabil: Mekanisme *self-attention* menghasilkan gradien yang lebih stabil dibandingkan LSTM, yang penting saat *backpropagation* melalui pengenalan untuk pelatihan generator.
- c. Visualisasi *Attention* Eksplisit: Bobot *attention* dapat divisualisasikan untuk memahami bagian mana dari citra yang direstorasi paling penting untuk pengenalan, memberikan interpretabilitas.

Ringkasan Seksi 2.5: Evolusi HTR dari HMM tradisional menuju CRNN (CNN+LSTM+CTC) dan Transformer-based HTR menunjukkan peningkatan signifikan dalam menangani variasi paleografi. *Transformer* dengan mekanisme *self-attention* global memberikan keunggulan dalam kapasitas representasi ($O(n^2)$ vs $O(n)$), pemrosesan paralel, dan penanganan dependensi jarak jauh yang krusial untuk dokumen kuno kompleks.

II.6 Pembelajaran Multimodal dan Diskriminator Dual Modal

Mengintegrasikan informasi dari berbagai modalitas telah terbukti meningkatkan kinerja sistem kecerdasan buatan dalam berbagai domain aplikasi. Dalam konteks restorasi dokumen, pendekatan tradisional yang hanya mengandalkan informasi visual sering kali gagal menangkap struktur semantik teks yang penting untuk mempertahankan keterbacaan. Bagian ini menyajikan kajian komprehensif tentang pembelajaran multimodal, dengan fokus pada pengembangan diskriminator dual modal yang secara simultan mengevaluasi aspek visual dan tekstual dari citra yang direstorasi. Pembahasan mencakup landasan teoretis, hipotesis informasi komplementer, kemajuan terkini dalam arsitektur multimodal, serta aplikasi spesifik dalam kerangka kerja restorasi dokumen berorientasi pengenalan teks.

II.6.1 Landasan Teoretis dan Kemajuan Arsitektur Multimodal

Pembelajaran multimodal mengacu pada pembelajaran dari data yang mengandung berbagai modalitas (misalnya, visual, teks, audio). Dalam konteks restorasi dokumen, dua modalitas yang relevan adalah informasi visual (intensitas piksel, tekstur) dan informasi tekstual (urutan karakter, struktur linguistik). Hipotesis inti adalah bahwa modalitas yang berbeda memberikan informasi yang saling melengkapi: modalitas visual mendeteksi fitur tingkat rendah seperti tepi dan tekstur, sementara modalitas tekstual memberikan batasan semantik tingkat tinggi. Baltrušaitis **and others** (2019) dalam survei komprehensif tentang pembelajaran multimodal mengidentifikasi tiga tantangan kunci: (1) pembelajaran representasi untuk menggabungkan modalitas yang berbeda, (2) translasi antara modalitas, dan (3) penyelarasan antara elemen yang berkorespondensi dari modalitas yang berbeda.

1. Kemajuan Terkini dalam Arsitektur Multimodal

Penelitian terkini dalam pembelajaran multimodal telah menunjukkan kemajuan signifikan:

- a. Pendekatan Berbasis CLIP: Radford **and others** (2021) menunjukkan bahwa pembelajaran kontrastif pada pasangan citra-teks dapat menghasilkan representasi yang kuat untuk tugas multimodal. Meskipun CLIP belum diterapkan secara luas dalam restorasi dokumen, konsep pembelajaran kontrastif dapat diadaptasi untuk pasangan dokumen-teks.
- b. Mekanisme *Cross-Attention*: Vaswani **and others** (2017) mengembangkan

arsitektur *cross-attention* yang secara efektif dapat mengintegrasikan informasi dari berbagai modalitas dengan bobot perhatian yang dipelajari. Pendekatan ini sangat relevan untuk restorasi dokumen yang informasi visual dan tekstualnya harus dinormalisasi.

- c. Kerangka Kerja Pembelajaran Multitugas: Raffel **and others** (2020) menunjukkan bahwa pembelajaran multitugas dapat meningkatkan generalisasi dan ketangguhan dalam pengaturan multimodal. Dalam konteks restorasi dokumen, pembelajaran multitugas dapat menggabungkan tugas peningkatan kualitas, binarisasi, dan pengenalan.

2. Strategi Fusi Multimodal

Fusi multimodal dapat dilakukan pada berbagai tingkatan: (1) Fusi Awal—menggabungkan fitur mentah dari modalitas yang berbeda di tahap awal jaringan, memungkinkan interaksi tingkat rendah tetapi meningkatkan dimensionalitas; (2) Fusi Akhir—memproses setiap modalitas secara independen hingga representasi tingkat tinggi kemudian menggabungkan prediksi, lebih sederhana tetapi kehilangan interaksi tingkat rendah; (3) Fusi Hibrida—menggabungkan fusi awal dan akhir, menawarkan keseimbangan antara ekspresivitas dan efisiensi komputasi.

II.6.2 Aplikasi Multimodal untuk Restorasi Dokumen

Dalam konteks restorasi dokumen, pembelajaran multimodal berpotensi mengintegrasikan informasi visual (karakteristik piksel, tekstur, struktur spasial) dengan informasi tekstual (urutan karakter, koherensi linguistik) untuk supervisi yang lebih kaya.

II.6.3 Konsep Diskriminator Multimodal

Dalam restorasi dokumen, diskriminator konvensional hanya mengevaluasi modalitas visual—apakah citra hasil restorasi terlihat bersih secara visual. Pendekatan multimodal yang berpotensi dieksplorasi adalah diskriminator yang mengevaluasi dua modalitas secara bersamaan:

- a. Modalitas Visual: Evaluasi karakteristik spasial dan tekstur citra melalui jaringan konvolusional, mengikuti paradigma *PatchGAN* Isola **and others** (2017) yang menilai keaslian pada tingkat *patch* lokal.
- b. Modalitas Tekstual: Evaluasi koherensi struktur teks melalui pemrosesan

sekuensial representasi karakter, menggunakan arsitektur seperti LSTM atau *Transformer* untuk menangkap dependensi linguistik.

- c. Strategi Fusi: Integrasi informasi dari kedua modalitas dapat dilakukan melalui konkatenasi fitur (fusi akhir), interaksi awal (fusi awal), atau pendekatan hibrida yang memungkinkan interaksi multitingkat.

1. Potensi Keuntungan Teoretis

- a. Supervisi Multidimensi: Evaluasi simultan terhadap modalitas visual dan tekstual berpotensi memberikan sinyal gradien yang lebih kaya dibandingkan evaluasi visual saja. Diskriminator dapat mendeteksi inkonsistensi yang tidak terlihat dari perspektif visual murni, seperti karakter yang secara visual terlihat wajar tetapi tidak koheren dalam konteks sekuens.
- b. Sejalan dengan Tujuan Akhir: Untuk restorasi dokumen yang ditujukan untuk HTR, supervisi tekstual berpotensi lebih selaras dengan tujuan akhir pemrosesan dibandingkan supervisi visual saja. Hal ini sejalan dengan prinsip optimisasi berorientasi tugas.
- c. Regularisasi Implisit: Batasan dari modalitas ganda dapat berfungsi sebagai regularisasi, berpotensi mengurangi risiko keruntuhan modus karena generator harus memenuhi kriteria dari kedua modalitas secara bersamaan.

2. Bukti dari Domain Sejenis

Wei **and others** (2022) menunjukkan bahwa diskriminator multimodal pada tugas *image captioning* meningkatkan stabilitas pelatihan dan koherensi keluaran. Eksperimen mendemonstrasikan bahwa evaluasi visual-tekstual gabungan menghasilkan *caption* yang lebih koheren dibandingkan diskriminator visual saja.

Dalam konteks restorasi dokumen, potensi pendekatan multimodal menjadi relevan karena tujuan akhir bukan hanya kualitas visual, tetapi keterbacaan teks untuk sistem HTR. Namun, validasi empiris diperlukan untuk mengonfirmasi keuntungan ini pada domain dokumen historis spesifik. Kemajuan dalam domain *vision-language models* seperti CLIP dan GPT-4V menunjukkan bahwa integrasi modalitas visual-tekstual dapat menghasilkan representasi yang lebih kaya dan semantis dibandingkan pendekatan unimodal.

Ringkasan Seksi 2.6: Pembelajaran multimodal mengintegrasikan informasi visual dan tekstual yang saling melengkapi. Diskriminator dual modal yang mengevaluasi koherensi visual-tekstual secara simultan berpotensi memberikan supervisi yang lebih kaya dibanding diskriminator visual saja. Strategi fusi (awal/akhir/hibrida)

dan evidensi dari domain terkait (*image captioning*) menunjukkan keuntungan stabilitas dan koherensi keluaran.

II.7 Sintesis Fungsi *Loss* dan Optimasi Multiobjektif

Setelah mengkaji pembelajaran multimodal yang mengintegrasikan informasi visual dan tekstual, pertanyaan fundamental muncul: bagaimana mengoptimasi model secara efektif ketika terdapat berbagai tujuan yang harus diseimbangkan? Integrasi diskriminator dual modal dan supervisi HTR menciptakan skenario optimasi multiobjektif yang kompleks dengan tujuan yang berbeda (kualitas visual, realisme adversarial, keterbacaan teks) yang dapat saling berkonflik. Bagian ini menganalisis secara mendalam keterbatasan pelatihan dengan fungsi *loss* tunggal, kemudian mengembangkan kerangka konseptual untuk fungsi *loss* multikomponen dengan strategi pembobotan yang memungkinkan kontrol kompromi antar objektif. Analisis ini esensial untuk merancang fungsi optimasi yang mencapai keseimbangan optimal antara kualitas perseptual dan keterbacaan fungsional.

II.7.1 Keterbatasan Pelatihan *Loss* Tunggal

Melatih jaringan saraf dalam dengan fungsi *loss* tunggal sering kali tidak mencukupi untuk tugas kompleks yang memerlukan penyeimbangan berbagai tujuan seperti restorasi dokumen. Keterbatasan fundamental dari pendekatan *loss* tunggal dapat diamati dari berbagai perspektif.

Pelatihan dengan *loss* adversarial murni tanpa komponen rekonstruksi cenderung menyebabkan keruntuhan modus dan ketidakstabilan yang signifikan. Dalam kondisi ini, generator dapat mempelajari strategi untuk menghasilkan keluaran yang mampu menipu diskriminator, namun sepenuhnya mengabaikan kondisi masukan yang diberikan. Untuk tugas generasi bersyarat seperti restorasi dokumen, fenomena ini mengakibatkan kegagalan fundamental karena kehilangan korespondensi antara citra masukan yang mengalami degradasi dengan citra keluaran yang direstorasi.

Sebaliknya, pelatihan dengan *loss* rekonstruksi murni menggunakan norma L1 atau L2 menghasilkan permasalahan yang berbeda namun tidak kalah serius. Fungsi *loss* berbasis jarak piksel ini cenderung merata-ratakan semua kemungkinan keluaran yang valid, menghasilkan citra yang kabur dan kekurangan detail frekuensi tinggi.

Pada kasus-kasus ambigu dengan rekonstruksi jamak yang masuk akal (*multiple*

plausible reconstructions), model cenderung mempelajari strategi aman dengan menghasilkan rata-rata statistik yang meminimalkan jarak piksel terhadap *ground truth*. Strategi ini, meskipun optimal dari perspektif *loss* numerik, menghasilkan keluaran yang secara visual tidak realistis dan kehilangan ketajaman detail seperti goresan karakter.

Keterbatasan-keterbatasan ini memotivasi kebutuhan akan fungsi *loss* multikomponen yang mampu mengoptimalkan berbagai tujuan secara simultan. Pendekatan multiobjektif ini memungkinkan model untuk menyeimbangkan *trade-off* antara realisme visual yang didorong oleh komponen adversarial dengan kesetiaan konten yang dijaga oleh komponen rekonstruksi. Tantangan kunci yang muncul dalam pendekatan ini adalah penentuan bobot relatif yang optimal untuk setiap komponen *loss*, yang memerlukan eksplorasi empiris dan pemahaman mendalam tentang kontribusi masing-masing komponen terhadap tujuan akhir.

II.7.2 Kerangka Konseptual Fungsi *Loss* Multikomponen

Berdasarkan analisis keterbatasan di atas, kerangka fungsi *loss* multikomponen untuk restorasi dokumen berorientasi HTR dapat dikonseptualisasikan secara umum sebagai kombinasi berbobot dari tujuan ganda:

$$\mathcal{L}_{total} = \sum_i \lambda_i \mathcal{L}_i \quad (\text{II.6})$$

dengan setiap $\mathcal{L}_i$ merepresentasikan objektif spesifik dan λ_i adalah bobot yang mengontrol kontribusi relatif.

1. Komponen Umum dalam Restorasi Dokumen

a. *Adversarial Loss* ($\mathcal{L}_{adversarial}$)

Komponen adversarial standar dalam GAN bersyarat untuk mendorong realisme visual keluaran. Mengikuti formulasi Goodfellow **and others** (2014) dan Isola **and others** (2017), *loss* ini memberikan sinyal untuk menghasilkan citra yang tidak dapat dibedakan dari citra nyata oleh diskriminator.

b. *Reconstruction Loss* ($\mathcal{L}_{reconstruction}$)

Komponen rekonstruksi untuk menjaga kesetiaan konten terhadap *ground truth*. Dapat menggunakan L1, L2, atau kombinasi keduanya. Isola **and others** (2017) menunjukkan bahwa L1 cenderung menghasilkan keluaran yang lebih tajam dibandingkan L2 dalam konteks translasi citra-ke-citra.

c. *Perceptual Loss* ($\mathcal{L}_{perceptual}$) - Opsional

Johnson **and others** (2016) memperkenalkan *perceptual loss* yang mengukur kesamaan pada ruang fitur jaringan praterlatih (seperti VGG). Ini berpotensi menangkap kemiripan semantik yang tidak tertangkap oleh *loss* tingkat piksel.

d. *Loss* Berorientasi HTR ($\mathcal{L}_{HTR}$) - Kesenjangan yang Teridentifikasi

Berdasarkan analisis literatur, komponen yang mengintegrasikan supervisi langsung dari model HTR masih terbatas eksplorasinya. Potensi pendekatan mencakup penggunaan *loss* CTC atau *loss* berbasis atensi dari model pengenalan untuk memberikan gradien yang berorientasi pada keterbacaan, bukan hanya kualitas visual.

2. *Trade-off Frozen vs Joint Training*

Dalam konteks integrasi model HTR dengan generator restorasi, terdapat dua paradigma yang dapat dieksplorasi:

- a. *Frozen Recognizer* Model HTR praterlatih dibekukan dan digunakan hanya untuk menghitung gradien tanpa mengubah bobotnya. Keuntungan teoretis mencakup stabilitas gradien dan konsistensi evaluasi. *Loss* potensial adalah kurangnya adaptasi terhadap karakteristik keluaran generator.
- b. *Pelatihan Bersama* Model HTR dan generator dilatih bersama secara *end-to-end*. Keuntungan teoretis adalah kemampuan koadaptasi. *Loss* potensial adalah ketidakstabilan optimisasi karena kompetisi gradien antara dua tujuan yang berbeda.

Souibgui **and others** (2021a) mengeksplorasi *joint training* pada ERB-MultiTask dengan hasil yang menjanjikan, namun melaporkan tantangan dalam stabilitas konvergensi. Eksplorasi lebih lanjut diperlukan untuk membandingkan kedua paradigma pada konteks dokumen historis spesifik.

II.7.3 Tantangan Penyeimbangan Multiobjektif

Penentuan bobot optimal untuk setiap komponen *loss* dalam kerangka multiobjektif merupakan tantangan penelitian yang terbuka. Kompleksitas ini diperparah oleh fakta bahwa komponen *loss* yang berbeda dapat memiliki skala, dinamika konvergensi, dan sensitivitas parameter yang sangat berbeda. Beberapa pertimbangan teoretis mencakup analisis empiris tentang interaksi antar komponen dan dampaknya terhadap kualitas akhir restorasi.

1. Perbedaan Skala Magnitudo

Komponen *loss* yang berbeda dapat memiliki rentang nilai yang sangat berbeda. *Adversarial loss* biasanya dalam rentang probabilitas log, *reconstruction loss* bergantung pada rentang nilai piksel, dan *loss* HTR bergantung pada panjang sekuens dan ukuran kosakata. Tanpa normalisasi atau pembobotan yang tepat, komponen dengan magnitudo lebih besar akan mendominasi optimisasi.

2. Strategi yang Dapat Dieksplorasi

Beberapa strategi untuk penyeimbangan yang telah diusulkan dalam literatur:

- a. Penalaan Manual: Pendekatan *grid search* atau *random search* dengan evaluasi empiris pada himpunan validasi. Sederhana tetapi memerlukan banyak eksperimen.
- b. *Adaptive Weighting*: Chen **and others** (2018) mengusulkan *GradNorm* yang secara dinamis menyesuaikan bobot berdasarkan magnitudo relatif gradien dari setiap *loss*. Berpotensi mencapai keseimbangan otomatis.
- c. Optimisasi Pareto: Pendekatan optimisasi multiobjektif yang mencari solusi pada *Pareto frontier* yang tidak ada objektif yang dapat ditingkatkan tanpa mengorbankan objektif lainnya.

Validasi empiris diperlukan untuk menentukan strategi yang paling efektif untuk konteks restorasi dokumen historis.

Ringkasan Seksi 2.7: Fungsi *loss* multikomponen esensial untuk restorasi dokumen yang menyeimbangkan kualitas visual dan keterbacaan teks. Komponen umum meliputi *adversarial loss* (realisme), *reconstruction loss* (kesetiaan konten), *perceptual loss* (kesamaan semantik), dan *loss* berorientasi HTR (keterbacaan). *Trade-off frozen vs joint training recognizer* dan strategi pembobotan (manual *grid search*, *adaptive GradNorm*, atau optimisasi Pareto) memerlukan validasi empiris sistematis.

II.8 Kesenjangan Penelitian dan Positioning

II.8.1 Sintesis Keterbatasan Metode yang Ada

Berdasarkan tinjauan komprehensif terhadap evolusi metode restorasi dokumen dari era klasik hingga pendekatan modern berbasis pembelajaran mendalam, analisis sistematis mengungkapkan pola konsisten dalam keterbatasan yang belum teratasi. Sintesis ini disajikan melalui dua perspektif komplementer yang saling melengkapi: evaluasi kuantitatif performa dan analisis karakteristik arsitektural.

Tabel ?? menyajikan evaluasi kuantitatif komprehensif dari sembilan metode representatif yang mencakup rentang temporal 1979-2022. Analisis metrik mengungkapkan pola evolusi yang jelas: peningkatan progresif dalam PSNR dari metode klasik (Otsu, Sauvola) yang tidak menghasilkan metrik kuantitatif hingga pendekatan transformer modern (DocEnTr: 35,2 dB). Namun, kolom evaluasi HTR mengungkapkan kesenjangan kritis—hanya 22% metode (ERB-MultiTask dan DE-GAN) yang melaporkan CER, dan evaluasi tersebut dilakukan pasca-pelatihan, bukan terintegrasi dalam siklus optimisasi.

Tabel II.6 Perbandingan metode terkini dalam restorasi dokumen (Bagian 1: Metrik Performa)

Metode	PSNR	SSIM	CER	Evaluasi HTR
Otsu Otsu (1979)	T/A	T/A	–	×
Sauvola Sauvola and Pietikäinen (2000)	T/A	0,68	–	×
U-Net Ronneberger and others (2015)	T/A	T/A	–	×
Pix2Pix Isola and others (2017)	T/A	T/A	–	×
ERB-MultiTask Souibgui and others (2021a)	15,7 dB	0,87	27,03 / 24,33%	✓ ^{1,2}
DE-GAN Souibgui and Kessentini (2021)	15,5 dB	0,86	28,2%	✓ ^{1,2}
Text-DIAE Souibgui, Kessentini and others (2022b)	28,5 dB	0,88	–	×
DocEnTr Souibgui, Kessentini and others (2022a)	35,2 dB	0,92	–	×
CycleGAN Zhu and others (2017)	30,2 dB	0,90	–	×

Analisis mendalam terhadap Tabel ?? mengungkapkan pola divergensi yang signifikan: peningkatan dramatis metrik visual (PSNR dari tidak terdefinisi pada era klasik mencapai 35,2 dB pada DocEnTr) tidak diikuti dengan evaluasi keterbacaan yang setara. Dari sembilan metode yang dianalisis, hanya dua (22%) yang melaporkan CER, yaitu ERB-MultiTask dengan penurunan CER dari 30,34% menjadi 24,33% dan DE-GAN dengan CER 28,2%. Fenomena ini mengonfirmasi bias sistematis dalam paradigma penelitian yang mengutamakan optimisasi visual

tanpa validasi dampaknya terhadap keterbacaan fungsional untuk sistem HTR.

Dimensi arsitektural dalam Tabel ?? melengkapi analisis performa dengan mengungkapkan pola evolusi teknologi yang sejalan: transisi dari pendekatan deterministik (Otsu, Sauvola) menuju arsitektur pembelajaran mendalam yang semakin kompleks hingga pendekatan *Transformer-only* (DocEnTr), serta peningkatan bertahap dalam kompleksitas fungsi *loss* dari *threshold* sederhana hingga kombinasi multikomponen (Adversarial + Reconstruction + Recognition pada ERB-MultiTask). Namun, kolom diskriminator mengungkapkan kesenjangan fundamental: semua metode berbasis GAN menggunakan diskriminator visual saja, tanpa mekanisme untuk mengevaluasi koherensi tekstual atau keterbacaan struktur karakter.

Tabel II.7 Perbandingan metode terkini dalam restorasi dokumen (Bagian 2: Karakteristik Arsitektur)

Metode	Diskriminator	Arsitektur	Tipe Loss
Otsu Otsu (1979)	T/A	N/A	<i>Threshold</i>
Sauvola Sauvola and Pietikäinen (2000)	T/A	N/A	Adaptif
U-Net Ronneberger and others (2015)	T/A	CNN <i>Encoder-Decoder</i>	L2 (MSE)
Pix2Pix Isola and others (2017)	Visual saja	CNN U-Net + PatchGAN	Adv + L1
ERB-MultiTask Souibgui and others (2021a)	Visual saja	FCN + CRNN	Adv + CRNN
DE-GAN Souibgui and Kessentini (2021)	Visual saja	CNN U-Net	Adv + BCE
Text-DIAE Souibgui, Kessentini and others (2022b)	T/A	ViT <i>Autoencoder</i>	Rekonstruksi
DocEnTr Souibgui, Kessentini and others (2022a)	T/A	<i>Transformer Only</i>	MSE
CycleGAN Zhu and others (2017)	Visual saja	CNN <i>Encoder-Decoder</i>	Cycle + Adv

¹DE-GAN dan ERB-MultiTask: Evaluasi pasca-pelatihan dengan pengenalan yang telah dilatih sebelumnya, bukan pelatihan terintegrasi. Data PSNR/CER direvisi berdasarkan sumber asli Souibgui **and others** (2021b) **and** Souibgui **and others** (2022). ²U-Net dan Pix2Pix: Data T/A karena tidak ada evaluasi spesifik untuk *handwritten document restoration* pada sumber yang tersedia.

Sintesis komprehensif dari kedua tabel mengungkapkan tiga kesenjangan fundamental yang konsisten muncul lintas periode penelitian. **Pertama**, diskrepansi antara optimisasi visual dan keterbacaan fungsional: metode dengan PSNR tertinggi (DocEnTr: 35,2 dB, Text-DIAE: 28,5 dB) tidak melaporkan evaluasi HTR, sementara metode yang melaporkan CER (ERB-MultiTask, DE-GAN) memiliki PSNR relatif rendah (15,5-15,7 dB). Korelasi negatif ini mengindikasikan bahwa optimisasi metrik visual tidak menjamin peningkatan keterbacaan teks, bahkan berpotensi menurunkan performa HTR jika tidak disertai supervisi eksplisit. **Kedua**, ketiadaan diskriminator dual modal: semua arsitektur GAN yang dianalisis menggunakan evaluasi visual saja tanpa supervisi keterbacaan tekstual. Diskriminator hanya mengevaluasi realisme visual tingkat piksel dan tekstur, tanpa kemampuan menilai koherensi struktur karakter atau keterbacaan sekuensial. **Ketiga**, evaluasi HTR yang tidak terintegrasi: pada metode yang melaporkan CER (ERB-MultiTask dan DE-GAN), evaluasi dilakukan pasca-pelatihan dengan pengenalan terpisah (catatan ¹), bukan sebagai komponen integral dalam fungsi objektif optimisasi. Hal ini menyebabkan generator tidak menerima gradien yang berorientasi pada keterbacaan selama pelatihan.

Temuan ini memvalidasi kesenjangan penelitian yang signifikan dan memotivasi pengembangan metodologi yang mengintegrasikan evaluasi keterbacaan secara eksplisit dalam siklus pelatihan melalui diskriminator dual modal dan strategi *frozen recognizer*. Pola yang teridentifikasi menunjukkan bahwa paradigma penelitian perlu bergeser dari optimisasi visual murni menuju optimisasi holistik yang menyeimbangkan kualitas perseptual dan keterbacaan fungsional. Lebih jauh, analisis temporal menunjukkan bahwa meskipun kompleksitas arsitektural meningkat dari era klasik (1979-2010) hingga era adversarial modern (2017-sekarang), kesenjangan antara metrik visual dan evaluasi fungsional justru semakin melebar, mengindikasikan perlunya intervensi metodologis yang fundamental.

1. Pertanyaan Penelitian dan Hipotesis

Berdasarkan sintesis kesenjangan dari perbandingan komprehensif di atas dan identifikasi pola sistematis dalam keterbatasan metode terkini, penelitian ini merumuskan pertanyaan penelitian sebagai berikut:

Pertanyaan Penelitian Utama:

Bagaimana mengembangkan kerangka kerja restorasi dokumen berbasis GAN dengan diskriminator dual modal dan strategi *frozen recognizer* yang secara eksplisit mengintegrasikan evaluasi keterbacaan teks ke dalam proses pelatihan

untuk mengatasi kesenjangan antara optimasi visual dan performa HTR?

Pertanyaan Penelitian Spesifik:

1. *Arsitektur Diskriminator Dual Modal:*

Bagaimana merancang dan mengevaluasi arsitektur diskriminator dual modal dengan cabang visual (CNN) dan cabang tekstual (LSTM) yang mengevaluasi koherensi visual-tekstual secara simultan, serta bagaimana mengukur kontribusinya terhadap kualitas umpan balik generator dibandingkan diskriminator visual saja?

2. *Frozen Recognizer dengan Integrasi CTC Loss:*

Bagaimana strategi *frozen recognizer* dengan integrasi *CTC loss* dibandingkan dengan pendekatan pelatihan bersama dalam hal: (a) stabilitas gradien selama pelatihan, (b) performa keterbacaan teks yang dihasilkan, dan (c) efisiensi komputasi dalam proses optimisasi?

3. *Strategi Curriculum Learning:*

Bagaimana merancang strategi temporal *curriculum learning* untuk *CTC loss annealing* yang memastikan konvergensi stabil dengan beberapa komponen *loss* (*adversarial*, *reconstruction*, *recognition*) pada fase awal hingga akhir pelatihan?

4. *Optimasi Multiobjektif:*

Bagaimana menentukan konfigurasi bobot akhir yang optimal untuk *adversarial*, *reconstruction*, dan *recognition loss* guna mencapai keseimbangan terbaik antara kualitas visual (PSNR/SSIM) dan keterbacaan teks (CER/WER) pada hasil restorasi?

Hipotesis:

Penggunaan diskriminator dual modal dan strategi *frozen recognizer* dengan *curriculum learning* dan optimasi *loss function* multiobjektif dapat mengatasi kesenjangan antara optimasi visual dan keterbacaan teks, sehingga menghasilkan restorasi yang secara signifikan lebih baik dalam aspek keterbacaan teks sambil mempertahankan kualitas visual dibandingkan metode *state-of-the-art*.

II.8.2 Posisi dan Kontribusi Penelitian Ini

Pertanyaan penelitian dan hipotesis yang telah dirumuskan mengarahkan pada kebutuhan untuk mengembangkan metodologi baru yang secara sistematis mengatasi kesenjangan yang teridentifikasi. Penelitian ini diposisikan sebagai solusi inovatif yang mengintegrasikan tiga dimensi metodologis: arsitektur

diskriminator dual modal, strategi *frozen recognizer*, dan optimasi *loss function* multikomponen. Pendekatan ini berbeda secara fundamental dari metode yang ada sebelumnya yang cenderung fokus pada satu aspek saja atau menggunakan integrasi yang tidak stabil. Berdasarkan analisis komprehensif tersebut, penelitian ini diposisikan sebagai penelitian inovatif yang mengusulkan pendekatan baru dalam restorasi dokumen berorientasi HTR. Berbeda dari metode yang ada sebelumnya yang menggunakan pelatihan gabungan (*joint training*) antara *generator* dan *recognizer*, penelitian ini memperkenalkan paradigma *frozen recognizer* yang memberikan stabilitas pelatihan dan gradien sadar teks yang konsisten.

Secara spesifik, posisi dan kontribusi penelitian ini dapat dirumuskan sebagai berikut:

1. Posisi Penelitian: Berbeda dari pendekatan terdahulu yang hanya fokus pada satu aspek (visual saja atau pelatihan gabungan dengan risiko ketidakstabilan), penelitian ini menyajikan solusi terintegrasi yang mengatasi tantangan fundamental optimisasi multiobjektif dalam restorasi dokumen. Penelitian ini mengisi celah penting antara metode restorasi visual murni (seperti GAN standar) dan metode *joint training* yang kompleks namun tidak stabil.
2. Kontribusi Utama: Penelitian ini menawarkan tiga dimensi inovasi:
 - Integrasi HTR dengan *Frozen Recognizer*: Strategi yang memecahkan masalah ketidakstabilan *joint training* sambil memberikan gradien peka HTR yang konsisten.
 - *Curriculum Learning* untuk Stabilitas Pelatihan: Penerapan strategi *CTC loss annealing* untuk mencegah dominasi satu komponen *loss* pada fase awal.
 - Optimisasi *Loss Function* Multikomponen: Formulasi bobot optimal yang divalidasi secara empiris untuk menyeimbangkan kualitas visual dan keterbacaan teks.

II.9 Sintesis Tinjauan Pustaka

Bab ini telah menyajikan analisis komprehensif dari lanskap penelitian restorasi dokumen, dari metode tradisional hingga pendekatan pembelajaran mendalam modern. Berdasarkan tinjauan sistematis terhadap 9 metode terkini dan metaanalisis kuantitatif, analisis ini mengidentifikasi kesenjangan fundamental yang masih memerlukan eksplorasi lebih lanjut dalam bidang restorasi dokumen historis.

1. Sintesis Temuan Kunci

a. Kesenjangan Signifikan Optimisasi Visual-Fungsional

Metaanalisis kuantitatif mengungkapkan korelasi Spearman hanya 0,60-0,70 antara peningkatan PSNR dan penurunan CER Jadhav **and** Raghuwanshi (2022), membuktikan bahwa optimisasi visual tidak otomatis menjamin optimisasi keterbacaan. Hanya 2 dari 9 metode (22%) melaporkan evaluasi HTR, mencerminkan kesenjangan evaluasi yang sistematis. Studi lintas domain dalam peningkatan ucapan Weninger **and others** (2023) menunjukkan bahwa supervisi eksplisit dari model pengenalan secara signifikan meningkatkan keterbacaan dibandingkan optimisasi metrik akustik saja, memberikan indikasi teoretis untuk pendekatan serupa dalam restorasi dokumen. Lebih lanjut, *benchmark* standar seperti seri DIBCO hanya menyediakan *ground truth* visual tanpa metrik HTR (CER/WER), memperpanjang pemisahan antara penelitian restorasi dan aplikasi praktis.

b. Ketiadaan *Loss Function* Peka HTR dalam *Training Loop*

Pelatihan GAN dengan kombinasi *adversarial loss*, *reconstruction loss*, dan *recognition loss* (CTC) menghadapi tantangan stabilitas karena perbedaan skala dan dinamika konvergensi masing-masing komponen. Belum ada penelitian yang mengevaluasi strategi *curriculum learning* untuk *CTC loss annealing* guna mencegah dominasi satu komponen pada fase awal pelatihan. ERB-MultiTask menggunakan pembobotan *loss* manual ($\lambda = 1$ optimal) namun tanpa mekanisme adaptif. Karakterisasi *trade-off* antara kualitas visual (PSNR/SSIM) dan keterbacaan teks (CER/WER) dalam konteks optimisasi fungsi *loss* multikomponen masih memerlukan investigasi sistematis melalui studi ablasi yang komprehensif.

c. Temuan Metaanalisis

Analisis kuantitatif mengidentifikasi tren dalam perkembangan metode restorasi dokumen. Dari era tradisional hingga pendekatan GAN modern, terdapat peningkatan signifikan dalam metrik visual, namun evaluasi fungsional (HTR) masih terbatas. Hanya minoritas metode yang melaporkan evaluasi HTR, mengindikasikan kesenjangan dalam protokol evaluasi yang komprehensif.

2. Implikasi untuk Penelitian

Tiga kesenjangan fundamental yang teridentifikasi—(1) optimisasi visual-fungsional yang terpisah, (2) ketiadaan fungsi *loss* yang peka terhadap HTR dengan strategi *frozen recognizer*, dan (3) ketidakstabilan pelatihan multiobjektif tanpa *curriculum learning*—memberikan landasan untuk pengembangan

metodologi penelitian. Penelitian ini akan mengatasi kesenjangan tersebut melalui: integrasi *CTC loss* dengan *frozen HTR recognizer* untuk gradien yang stabil dan peka HTR, strategi *curriculum learning* untuk *CTC loss annealing* guna mencegah ketidakstabilan pelatihan, dan optimisasi pembobotan *loss* melalui studi ablasi sistematis untuk mencapai keseimbangan optimal antara kualitas visual dan keterbacaan teks pada dokumen historis autentik.