

Bab IV Perancangan Sistem

Bab ini menyajikan perancangan teknis kerangka kerja restorasi dokumen berbasis GAN. Fokus utama perancangan adalah mengatasi kesenjangan antara pemulihan kualitas visual dan keterbacaan mesin. Pembahasan diorganisasi ke dalam empat bagian: (1) Arsitektur dan Komponen Utama, (2) Pengembangan Dataset, (3) Strategi dan Protokol Pelatihan, dan (4) Konfigurasi Evaluasi.

IV.1 Arsitektur dan Komponen Utama


Kerangka kerja GAN-HTR dirancang untuk mengatasi kesenjangan metode restorasi konvensional yang telah diidentifikasi pada Bab II.8. Berbeda dari pendekatan sebelumnya yang mengabaikan aspek keterbacaan oleh mesin atau mengalami ketidakstabilan pada *joint training*, kerangka kerja ini mengintegrasikan evaluasi keterbacaan teks secara eksplisit dalam siklus pelatihan melalui strategi *frozen recognizer*.

Kerangka kerja yang diusulkan beroperasi pada citra baris dokumen tulisan tangan yang terdegradasi dan menghasilkan keluaran bersih yang dioptimalkan untuk kualitas visual serta kinerja HTR. Arsitektur terdiri dari empat komponen utama yang berinteraksi dalam kerangka pelatihan *adversarial*:

1. Generator (G): Arsitektur U-Net *Enhanced* yang memetakan citra terdegradasi I_{deg} ke citra terestorasi I_{gen} . Dilengkapi dengan *Residual Dense Blocks* (RDB) dan *Attention Gates* untuk preservasi detail teks halus sekaligus menghilangkan derau latar belakang.
2. Diskriminator *Dual-Modal* (D): Diskriminator dengan jalur paralel CNN dan BiLSTM yang menilai kualitas visual dan koherensi teks secara bersamaan. Mekanisme *bilateral cross-attention fusion* memvalidasi konsistensi visual-tekstual.
3. *Frozen Recognizer* (R): Pengenal berbasis *Transformer* praterlatih dengan bobot tetap yang menyediakan gradien sadar-HTR tanpa risiko *catastrophic forgetting*.
4. Fungsi Loss Multikomponen: Menyeimbangkan kualitas visual ($L1 + \text{perceptual} + \text{adversarial}$) dan keterbacaan teks (*CTC loss*).

Keempat komponen ini divalidasi secara empiris melalui studi ablasi pada Bab V. Gambar ?? memvisualisasikan arsitektur keseluruhan dan interaksi antarkomponen dalam siklus pelatihan *adversarial*: Generator menghasilkan citra restorasi dari input terdegradasi, *frozen recognizer* mengevaluasi keterbacaan melalui *CTC loss*,

dan diskriminator menilai koherensi visual-tekstual. Strategi pelatihan dan protokol optimisasi diuraikan pada Bagian ??.




Gambar IV.1 Kerangka kerja GAN-HTR dengan diskriminator *dual-modal* dan *frozen* HTR recognizer. Komponen utama: (1) Generator U-Net *Enhanced*, (2) Diskriminator *Dual-Modal* (CNN+BiLSTM), (3) *Frozen* HTR Recognizer untuk CTC loss.

Subbagian berikut menguraikan arsitektur detail setiap komponen.

IV.1.1 Arsitektur Generator

Penelitian ini mengadopsi arsitektur U-Net Enhanced yang terdiri dari tiga komponen utama: *encoder*, *bottleneck*, dan *decoder*. Berbeda dari U-Net konvensional [ronneberger2015unet](#) yang menggunakan blok konvolusi standar, arsitektur *Enhanced* mengintegrasikan empat teknik tambahan: *Residual Dense Blocks* (RDB) [zhang2018residual](#), *Convolutional Block Attention Module* (CBAM) [woo2018cbam](#), *Multi-Scale Feature Pyramid* (MSFP) [lin2017fpn](#), dan *Attention Gates* [oktay2018attention](#). Spesifikasi detail arsitektur (21,8M parameter, *memory footprint* ~ 87 MB) tersedia pada Lampiran A, sementara Gambar ?? memvisualisasikan struktur keseluruhan.



Gambar IV.2 Generator U-Net Enhanced: arsitektur *encoder-decoder* simetris dengan *RDB+CBAM*, *bottleneck* MSFP 512 kanal, *attention gates*, dan *skip connections*.

IV.1.1.1 Encoder

Encoder mengekstrak fitur hierarkis melalui *downsampling* progresif dalam lima tahap, mengurangi resolusi spasial dari 1024×128 hingga 32×4 (lebar $\times$ tinggi) sambil meningkatkan kedalaman kanal. Setiap blok *encoder* terdiri dari:

- Residual Dense Block* (RDB): Tiga lapisan konvolusi *densely-connected* (*kernel* 3×3 , *growth rate* 32) yang memungkinkan setiap lapisan mengakses fitur dari semua lapisan sebelumnya.
- CBAM*: Atensi kanal (rasio reduksi 8) dan atensi spasial (*kernel* 7×7) untuk rekalisasi fitur adaptif.
- Batch normalization* (*momentum* = 0,9) dan aktivasi *LeakyReLU* ($\alpha = 0,2$).
- Koneksi *residual* untuk propagasi gradien efektif.

IV.1.1.2 Bottleneck

Bottleneck pada resolusi terendah ($32 \times 4 \times 512$) menangkap konteks global multi-skala melalui *Multi-Scale Feature Pyramid* (MSFP) dengan tiga skala konvolusi terdilasi (*dilation rates* 1, 2, 4) chen2017deeplab. Komponen ini memungkinkan arsitektur 'melihat' degradasi pada berbagai skala—dari derau titik hingga noda besar—sebelum proses rekonstruksi. *RDB* dan *CBAM* diterapkan untuk penyempurnaan fitur global.

IV.1.1.3 Decoder

Decoder merekonstruksi citra bersih melalui *upsampling* progresif dalam lima tahap, mencerminkan struktur *encoder*. Fitur penting *decoder* adalah *Attention Gates* oktay2018attention pada setiap *skip connection* yang menyaring fitur dari *encoder*:

$$\alpha = \sigma(W_g^T g + W_x^T x + b) \quad (\text{IV.1})$$

dengan g adalah fitur *decoder* (sinyal *gating*), x adalah fitur *skip connection* dari *encoder*, dan σ adalah aktivasi *sigmoid*. Koefisien atensi $\alpha \in [0, 1]$ ini kemudian diterapkan pada fitur: $\hat{x} = \alpha \odot x$, menekan fitur latar belakang sambil memperkuat wilayah pembawa teks.

Detail arsitektur lengkap (21,8M parameter) dengan spesifikasi setiap tahap tersedia pada Lampiran A (Tabel A.1).


IV.1.2 Arsitektur Diskriminator

Arsitektur diskriminator *dual-modal* dirancang untuk mengatasi keterbatasan diskriminator *single-modal* yang hanya mengevaluasi kualitas visual—contohnya adalah *PatchGAN* pada DE-GAN dan ERB-MultiTask. Berbeda dengan pendekatan konvensional tersebut, arsitektur ini mengevaluasi citra dari dua perspektif yang saling melengkapi:

- (1) Perspektif spasial (visual) melalui jalur CNN yang menilai kualitas goresan, tekstur, dan struktur spasial.
- (2) Perspektif sekuensial (teks) melalui jalur BiLSTM yang menilai koherensi dan kelayakan urutan karakter.

Integrasi kedua modalitas melalui mekanisme *bilateral cross-modal attention* memungkinkan diskriminator memberikan sinyal *adversarial* yang lebih kaya informasi. Gradien visual mendorong pelestarian detail goresan halus, sementara gradien tekstual mendorong konsistensi struktur karakter. Hipotesis desain ini divalidasi melalui studi ablasi pada Bagian ??.

Secara teknis, diskriminator menerima citra masukan dan sekuens teks (panjang maksimal 128 karakter), kemudian memprosesnya melalui dua jalur paralel seperti ditunjukkan pada Gambar ?. Detail arsitektur lengkap (17,4M parameter) tersedia pada Lampiran B (Tabel B.1).



Gambar IV.3 Arsitektur Diskriminator Dual-Modal Enhanced dengan dua cabang pemrosesan paralel (CNN untuk fitur visual, BiLSTM untuk fitur tekstual) dan mekanisme fusi *bilateral cross-modal attention*.

Gambar ?? memvisualisasikan alur pemrosesan arsitektur. Cabang CNN (kiri) memproses citra melalui 4 *DownBlocks* dengan *spatial attention*. Cabang BiLSTM (kanan) memproses sekuens teks melalui *embedding* dan *self-attention*. Kedua representasi 512-D bertemu pada modul fusi bilateral sebelum klasifikasi akhir. Bagian berikut menguraikan spesifikasi teknis masing-masing komponen.

IV.1.2.1 Cabang Citra (CNN dengan Atensi Spasial)

Cabang ini mengekstrak fitur visual spasial melalui arsitektur berbasis *ResNet*. Masukan citra $I \in \mathbb{R}^{1024 \times 128 \times 1}$ diproses melalui lapisan konvolusi awal (64 kanal) dengan *batch normalization* dan aktivasi *LeakyReLU* ($\alpha = 0,2$). Empat blok *downsampling residual* secara progresif mengurangi resolusi spasial sambil meningkatkan kedalaman kanal:

$$\begin{aligned} 1024 \times 128 \times 64 &\rightarrow 512 \times 64 \times 64 \rightarrow 256 \times 32 \times 128 \\ &\rightarrow 128 \times 16 \times 256 \rightarrow 64 \times 8 \times 512 \end{aligned} \quad (\text{IV.2})$$

Mekanisme atensi spasial dengan kernel 3×3 diterapkan pada fitur 512 kanal untuk fokus pada wilayah pembawa teks:

$$\alpha_{\text{spatial}} = \sigma(\text{Conv}_{3 \times 3}(F_{\text{img}})) \quad (\text{IV.3})$$

dengan σ adalah fungsi *sigmoid* dan F_{img} adalah peta fitur berdimensi $64 \times 8 \times 512$. Setelah atensi spasial, blok *residual* tambahan dengan 512 kanal (*ResBlock-512*) memproses fitur lebih lanjut tanpa mengubah dimensi spasial. Selanjutnya, *global average pooling* mengagregasi fitur spasial menjadi vektor representasi $F_{\text{img}}^{\text{global}} \in \mathbb{R}^{512}$.

IV.1.2.2 Cabang Teks (BiLSTM dengan Atensi-Mandiri)

Cabang ini menangkap koherensi sekuensial teks. Sekuens karakter masukan $S \in \mathbb{N}^L$ (panjang $L \leq 128$) diproyeksikan ke ruang *embedding* $E \in \mathbb{R}^{L \times 128}$. BiLSTM memproses sekuens dalam kedua arah untuk menangkap ketergantungan kontekstual:

$$h_t = [\vec{h}_t; \overleftarrow{h}_t] = [\text{LSTM}_{\text{fwd}}(E_t); \text{LSTM}_{\text{bwd}}(E_t)] \quad (\text{IV.4})$$

menghasilkan *hidden states* $H \in \mathbb{R}^{L \times 512}$. Mekanisme atensi-mandiri *multi-head scaled dot-product* diterapkan:

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V \quad (\text{IV.5})$$

dengan Q, K, V adalah proyeksi linear dari H . *Global average pooling* menghasilkan vektor teks $F_{\text{text}}^{\text{global}} \in \mathbb{R}^{512}$.

IV.1.2.3 Fusi Cross-Modal

Kedua vektor fitur $F_{\text{img}}^{\text{global}} \in \mathbb{R}^{512}$ dan $F_{\text{text}}^{\text{global}} \in \mathbb{R}^{512}$ diproses melalui mekanisme atensi *cross-modal* bilateral untuk memungkinkan interaksi dua arah antarmodalitas. Pendekatan bilateral memiliki dua alasan: pertama, citra perlu memvalidasi koherensi teks yang diprediksi pengenalan HTR; kedua, teks perlu memverifikasi kualitas visual goresan yang menghasilkan karakter tersebut. Dengan demikian, kedua modalitas saling memberikan konteks untuk deteksi anomali yang lebih *robust*. Setiap modalitas memproyeksikan fiturnya ke ruang bersama berdimensi rendah $d = 128$ melalui enam matriks proyeksi terpisah:

Atensi Citra→Teks: Citra sebagai *query*, teks sebagai *key/value*:

$$\begin{aligned} Q_{\text{img}} &= W_{\text{img}}^Q F_{\text{img}}^{\text{global}} \\ K_{\text{text}} &= W_{\text{text}}^K F_{\text{text}}^{\text{global}} \\ V_{\text{text}} &= W_{\text{text}}^V F_{\text{text}}^{\text{global}} \end{aligned} \quad (\text{IV.6})$$

$$F_{\text{img}}^{\text{att}} = \text{softmax} \left(\frac{Q_{\text{img}} K_{\text{text}}^T}{\sqrt{d}} \right) V_{\text{text}} \quad (\text{IV.7})$$

dengan $W_{\text{img}}^Q, W_{\text{text}}^K, W_{\text{text}}^V \in \mathbb{R}^{512 \times 128}$ adalah matriks proyeksi yang dipelajari.

Atensi Teks→Citra: Teks sebagai *query*, citra sebagai *key/value*:

$$\begin{aligned} Q_{\text{text}} &= W_{\text{text}}^Q F_{\text{text}}^{\text{global}} \\ K_{\text{img}} &= W_{\text{img}}^K F_{\text{img}}^{\text{global}} \\ V_{\text{img}} &= W_{\text{img}}^V F_{\text{img}}^{\text{global}} \end{aligned} \quad (\text{IV.8})$$

$$F_{\text{text}}^{\text{att}} = \text{softmax} \left(\frac{Q_{\text{text}} K_{\text{img}}^T}{\sqrt{d}} \right) V_{\text{img}} \quad (\text{IV.9})$$

dengan $W_{\text{text}}^Q, W_{\text{img}}^K, W_{\text{img}}^V \in \mathbb{R}^{512 \times 128}$ adalah matriks proyeksi simetris.

Kedua fitur yang telah mengalami atensi bilateral ($F_{\text{img}}^{\text{att}}, F_{\text{text}}^{\text{att}} \in \mathbb{R}^{128}$) digabungkan menjadi vektor fusi: $F_{\text{fused}} = [F_{\text{img}}^{\text{att}}; F_{\text{text}}^{\text{att}}] \in \mathbb{R}^{256}$.

Kepala klasifikasi terdiri dari dua lapisan padat ($512 \rightarrow 256$ neuron) dengan *dropout* dan aktivasi *LeakyReLU*. Lapisan keluaran menggunakan aktivasi *sigmoid* yang

menghasilkan nilai validitas $D(I, S) \in [0, 1]$ untuk membedakan pasangan citra-teks asli dari pasangan palsu yang dihasilkan generator.

IV.1.2.4 Kemampuan Deteksi

Dengan kombinasi analisis spasial CNN dan pemrosesan sekuens BiLSTM, diskriminator dapat mendeteksi:


- a. Goresan yang rusak atau terputus yang mengganggu alur teks (melalui deteksi anomali sekuens BiLSTM)
- b. Pola derau, artefak, dan tembus-balik (melalui fitur spasial CNN)
- c. Lebar goresan yang tidak konsisten (melalui mekanisme atensi spasial)
- d. Celah atau koneksi yang tidak wajar antar karakter (melalui analisis fusi cross-modal)

IV.1.2.5 Mode Input Teks

Diskriminator dual-modal dapat beroperasi dalam dua mode input teks: (1) *Ground Truth Mode* menggunakan label teks yang sudah dianotasi, memberikan sinyal pembelajaran yang bersih namun kurang realistis untuk *deployment*, dan (2) *Predicted Mode* menggunakan prediksi dari *frozen recognizer*, lebih realistis namun rentan terhadap *error propagation*. Perbandingan empiris kedua mode dan justifikasi pemilihan mode untuk pelatihan diuraikan pada Bab V.

IV.1.3 Arsitektur HTR

Komponen *Recognizer* (R) dalam kerangka kerja ini merupakan model HTR hibrida CNN-Transformer praterlatih dengan total 27,86M parameter. Arsitektur terdiri dari tiga bagian utama yang diuraikan berikut ini dan divisualisasikan pada Gambar ???. Model ini dilatih pada dokumen ANRI era kolonial abad 16–18 sebelum diintegrasikan ke dalam kerangka kerja GAN dengan strategi pembekuan bobot.



Gambar IV.4 Arsitektur HTR Recognizer: model hibrida CNN-Transformer dengan CNN Backbone 4 tahap (64→512 kanal), Transformer Encoder 6 lapisan (8 heads, dimensi 512), dan CTC Output Layer (96 kelas). Total 27,86M parameter dibekukan selama pelatihan GAN.

IV.1.3.1 CNN Backbone

CNN Backbone berfungsi untuk mengekstrak fitur visual dari citra baris dokumen. Arsitektur terdiri dari 8 lapisan konvolusi yang diorganisasi dalam 4 tahap dengan peningkatan kedalaman kanal progresif: $64 \rightarrow 128 \rightarrow 256 \rightarrow 512$. Setiap tahap menerapkan *max pooling* untuk reduksi dimensi spasial sambil mempertahankan informasi diskriminatif. Output berupa peta fitur spasial yang menjadi input bagi Transformer Encoder.

IV.1.3.2 Transformer Encoder

Transformer Encoder memodelkan ketergantungan kontekstual antar posisi karakter dalam sekuens. Arsitektur terdiri dari 6 lapisan encoder dengan konfigurasi: 8 attention heads dan dimensi representasi 512. Mekanisme *self-attention* memungkinkan setiap posisi mengakses informasi dari seluruh sekuens, penting untuk menangani variasi jarak antar karakter pada dokumen tulisan tangan. Output berupa representasi kontekstual untuk prediksi karakter.

IV.1.3.3 CTC Output Layer

CTC Output Layer memetakan representasi kontekstual ke distribusi probabilitas karakter. Lapisan ini menghasilkan prediksi untuk 95 kelas karakter (termasuk

blank token untuk penyelarasan CTC). *Connectionist Temporal Classification* (CTC) dipilih karena kemampuannya menangani sekuens dengan panjang variabel tanpa memerlukan penyelarasan karakter-per-karakter secara eksplisit—ideal untuk dokumen tulisan tangan dengan variasi spasial tinggi.

IV.1.3.4 Ekstraksi Fitur

Selain prediksi teks, *Recognizer* juga menghasilkan fitur perantara untuk kalkulasi *Recognition Feature Loss*. Fitur diekstrak dari lapisan proyeksi sebelum *Transformer Encoder*:

$$\mathcal{F}_{\text{rec}}(I) = R_{\text{encoder}}(I) \quad (\text{IV.10})$$

dengan R_{encoder} adalah bagian *encoder* yang dibekukan. Output berupa peta fitur dengan dimensi (batch, 128, 512) yang menangkap karakteristik relevan dengan teks: pola goresan, bentuk karakter, dan pengaturan spasial. Lapisan ini dipilih karena mengandung fitur tingkat urutan sebelum pengodean kontekstual, memberikan gradien yang stabil untuk Generator.

IV.1.3.5 Strategi Integrasi

Berbeda dengan pendekatan *joint training* pada ERB-MultiTask erb2021, penelitian ini mengadopsi strategi pembekuan bobot (*frozen recognizer*). Strategi ini dipilih berdasarkan tiga pertimbangan utama: (1) efisiensi komputasional—pengenal 27,86M parameter tidak memerlukan komputasi gradien, (2) stabilitas pelatihan—mengeliminasi konflik gradien destruktif antara tujuan rekonstruksi dan pengenalan souibgui2022,kang2021pay, dan (3) pelestarian kinerja—mencegah *catastrophic forgetting* kirkpatrick2017overcoming pada pengenal praterlatih.

Komponen *Recognizer* beku berfungsi sebagai evaluator objektif yang menghasilkan: (1) input teks bagi Diskriminator *dual-modal* untuk menilai koherensi visual-tekstual, dan (2) kalkulasi *CTC Loss* dan *Recognition Feature Loss* untuk mengukur keterbacaan hasil restorasi. Tabel ?? merangkum perbandingan strategi integrasi yang dipertimbangkan.

Tabel IV.1 Analisis komparatif strategi integrasi pengenalan HTR.

Strategi	Keuntungan	Keterbatasan
Pelatihan bersama	Optimasi <i>end-to-end</i> , adaptasi spesifik-tugas	Biaya komputasi tinggi, konflik gradien, risiko <i>catastrophic forgetting</i>
Beku*	Konvergensi stabil, efisiensi komputasional, pelestarian kinerja	Adaptasi spesifik-tugas terbatas
Dua tahap	Optimasi seimbang, stabilitas sekuensial	Waktu pelatihan berlipat, penjadwalan kompleks
Tanpa <i>Recognizer</i>	Arsitektur sederhana	Tidak ada optimasi sadar-HTR
*Strategi yang dipilih dalam penelitian ini		

Validasi empiris strategi pembekuan melalui studi ablasi diuraikan pada Bab V.6.3. Hasil menunjukkan bahwa strategi *frozen recognizer* mempertahankan kinerja pengenalan lebih baik dibandingkan *joint training* yang mengalami degradasi akibat *catastrophic forgetting*.

IV.1.4 Fungsi Loss Multikomponen

Generator dilatih dengan kombinasi lima komponen loss yang dikalibrasi melalui penyetelan empiris berdasarkan analisis *inverse scaling* terhadap distribusi magnitudo loss dan divalidasi secara *post-hoc* menggunakan pencarian kisi sistematis (27 konfigurasi dengan metode *orthogonal array sampling*) yang mengonfirmasi optimalitas konfigurasi yang dipilih. Fungsi loss total menggabungkan komponen-komponen tersebut secara terbobot untuk mengoptimalkan kualitas visual dan keterbacaan teks secara simultan:

$$\mathcal{L}_{\text{total}} = \lambda_{\text{adv}} \mathcal{L}_{\text{adv}} + \lambda_{\text{pixel}} \mathcal{L}_{\text{pixel}} + \lambda_{\text{perc}} \mathcal{L}_{\text{perc}} + \lambda_{\text{ctc}} \mathcal{L}_{\text{ctc}} + \lambda_{\text{rec-feat}} \mathcal{L}_{\text{rec-feat}} \quad (\text{IV.11})$$

Konfigurasi bobot loss untuk setiap komponen ditunjukkan dalam Tabel ?? . Studi ablasi sistematis (Bab V) mengidentifikasi konfigurasi optimal 4-komponen (tanpa $\mathcal{L}_{\text{rec-feat}}$) sebagai keseimbangan *Pareto* antara kualitas visual dan keterbacaan HTR.

IV.1.4.1 Adversarial Loss

Adversarial loss standar GAN mendorong pembuatan citra yang realistis dengan melatih generator untuk menipu diskriminator:

$$\mathcal{L}_{\text{adv}} = -\log D(I_{\text{deg}}, I_{\text{gen}}) \quad (\text{IV.12})$$

dengan $D(I_{\text{deg}}, I_{\text{gen}})$ adalah probabilitas diskriminator menganggap pasangan citra terdegradasi masukan I_{deg} dan citra hasil restorasi I_{gen} sebagai pasangan autentik. Diskriminator dilatih untuk memaksimalkan kemampuan membedakan:

$$\begin{aligned} \mathcal{L}_D = -[& \log D(I_{\text{deg}}, I_{\text{gt}}) \\ & + \log(1 - D(I_{\text{deg}}, I_{\text{gen}}))] \end{aligned} \quad (\text{IV.13})$$

dengan pasangan $(I_{\text{deg}}, I_{\text{gt}})$ merupakan pasangan nyata (citra terdegradasi dengan *ground truth* bersih), sedangkan $(I_{\text{deg}}, I_{\text{gen}})$ merupakan pasangan palsu hasil generator. Mekanisme *adversarial* ini mendorong generator menghasilkan citra dengan distribusi tekstur dan karakteristik visual yang tidak dapat dibedakan dari dokumen bersih autentik.

IV.1.4.2 Pixel Reconstruction Loss

Pixel reconstruction loss menggunakan norma L1 untuk memastikan kesamaan piksel-demi-piksel dengan *ground truth*:

$$\mathcal{L}_{\text{pixel}} = \|I_{\text{gen}} - I_{\text{gt}}\|_1 \quad (\text{IV.14})$$

Norma L1 dipilih karena menghasilkan hasil yang lebih tajam dibandingkan norma L2 dan lebih tangguh terhadap nilai pencilan. Berbeda dengan L2 yang memberikan penalti kuadratik (cenderung menghasilkan citra kabur), L1 memberikan penalti linear yang mempertahankan ketajaman tepi dan detail goresan halus yang penting untuk keterbacaan HTR.

IV.1.4.3 Perceptual Loss

Perceptual loss johnson2016 membandingkan fitur tingkat tinggi dari jaringan VGG-19 yang telah dilatih pada *ImageNet*:

$$\mathcal{L}_{\text{perc}} = \sum_{l \in L} \|\phi_l(I_{\text{gen}}) - \phi_l(I_{\text{gt}})\|_2 \quad (\text{IV.15})$$

dengan ϕ_l menunjukkan fitur dari lapisan l dari jaringan VGG-19 praterlatih, dan L adalah himpunan lapisan konvolusi yang dipilih untuk ekstraksi fitur. Fitur diekstrak dari beberapa lapisan konvolusi untuk perbandingan perseptual multiskala. Pendekatan ini memastikan pelestarian karakteristik visual dari detail tingkat rendah (tepi, tekstur) hingga fitur semantik tingkat tinggi (pola goresan, bentuk karakter), menghasilkan citra yang lebih koheren secara perseptual meskipun terdapat perbedaan piksel minor.

IV.1.4.4 CTC Loss

CTC loss memberikan gradien sadar-tekst langsung dari *frozen recognizer* untuk mengoptimalkan keterbacaan HTR secara eksplisit. *Connectionist Temporal Classification* (CTC) graves2006 dipilih karena kemampuannya menangani sekuens dengan panjang variabel tanpa memerlukan *alignment* eksplisit antara input citra dan output teks, ideal untuk dokumen tulisan tangan dengan variasi spasial karakter yang tinggi.

Formulasi matematis CTC dan mekanisme penyelarasan otomatis telah dijelaskan secara rinci pada Bab II Subbab ???. Komponen ini merupakan karakteristik penting kerangka kerja yang membedakannya dari metode restorasi dokumen konvensional yang hanya mengoptimalkan kualitas visual tanpa mempertimbangkan keterbacaan mesin.

Analisis kontribusi menunjukkan CTC loss berkontribusi 67,5% terhadap total generator loss (meskipun bobot $\lambda_{\text{ctc}} = 0,15$ relatif kecil) karena magnitudo *natural* CTC ($\sim 100\text{--}300$) jauh lebih besar dibanding komponen visual ($\sim 0,1\text{--}5,0$), memvalidasi peran dominan komponen HTR dalam optimasi.

Strategi *clipping* dengan batas maksimal 400,0 diterapkan untuk mencegah gradien ekstrem pada kasus degradasi berat yang dapat mengganggu stabilitas pelatihan adversarial.

IV.1.4.5 Recognition Feature Loss

Komponen *recognition feature loss* ($\mathcal{L}_{\text{rec-feat}}$) dirancang untuk mendorong kesamaan fitur tingkat menengah antara citra restorasi dan *ground truth* pada ruang representasi *recognizer*:

$$\mathcal{L}_{\text{rec-feat}} = \|\mathcal{F}_{\text{rec}}(I_{\text{gen}}) - \mathcal{F}_{\text{rec}}(I_{\text{gt}})\|_2^2 \quad (\text{IV.16})$$

dengan $\mathcal{F}_{\text{rec}}$ adalah ekstraksi fitur dari *Recognizer* (Persamaan ??). Namun, studi ablasi sistematis (Bab V.6.2) menunjukkan bahwa komponen ini tidak memberikan kontribusi signifikan ($p > 0,05$) dan memiliki pola korelasi tinggi dengan *CTC loss*—mengindikasikan objektif yang tumpang tindih. Berdasarkan prinsip *parsimony*, konfigurasi produksi menonaktifkan komponen ini ($\lambda_{\text{rec-feat}} = 0$) dan menggunakan *CTC loss* sebagai komponen HTR tunggal.

Tabel IV.2 Konfigurasi bobot *loss* optimal: *inverse scaling* empiris divalidasi dengan *grid search* (27 konfigurasi).

Komponen Loss	Bobot (λ)	Justifikasi
<i>adversarial</i> ($\mathcal{L}_{\text{adv}}$)	3,0	Realisme tekstur dan distribusi visual yang ditingkatkan tanpa mengorbankan stabilitas pelatihan
Piksel L1 ($\mathcal{L}_{\text{pixel}}$)	50,0	Pelestarian struktur piksel yang seimbang; bobot tinggi memastikan kesetiaan rekonstruksi dasar
<i>Perceptual</i> ($\mathcal{L}_{\text{perc}}$)	1,0	Pelestarian topologi dan koherensi fitur semantik tingkat tinggi
Recognition Feature loss ($\mathcal{L}_{\text{rec-feat}}$)	8,0	Panduan karakteristik ramah HTR yang kuat (dinonaktifkan produksi: $\lambda = 0$)
CTC loss ($\mathcal{L}_{\text{ctc}}$)	0,15	Pemantauan keterbacaan HTR dengan <i>clipping</i> numerik untuk stabilitas gradien

Pemilihan bobot *loss* (Tabel ??) dilakukan berdasarkan prinsip *inverse scaling* empiris dari analisis distribusi magnitudo *loss*, dengan pertimbangan bahwa komponen dengan magnitudo natural lebih besar memerlukan bobot lebih kecil untuk mencegah dominasi berlebihan dalam total generator *loss*. Konfigurasi yang dipilih (pixel=50,0, adversarial=3,0, perceptual=1,0, CTC=0,15, recognition feature=8,0) kemudian divalidasi melalui dua mekanisme: (1) validasi *post-hoc* menggunakan pencarian kisi sistematis dengan 27 konfigurasi (pixel $\in \{25, 50, 100\}$, adversarial $\in \{1, 5, 3, 0, 6, 0\}$, perceptual $\in \{0, 5, 1, 0, 2, 0\}$, CTC $\in$

$\{0,075,0,15,0,30\}$, recognition feature $\in \{0,8,16\}$) yang menggunakan metode *orthogonal array sampling*, menunjukkan bahwa konfigurasi production berada dalam rentang optimal dan tidak ada konfigurasi alternatif yang memberikan peningkatan signifikan pada fase awal konvergensi (3 epoch); (2) validasi *GradNorm* selama pelatihan production (50 epoch) menunjukkan variasi bobot 0%, mengonfirmasi konfigurasi sudah berada pada titik keseimbangan optimal untuk konvergensi jangka panjang.

IV.1.4.6 Optimasi Berorientasi HTR

Istilah optimasi fungsi loss berorientasi HTR pada penelitian ini mengacu pada strategi kalibrasi yang menempatkan komponen HTR sebagai faktor dominan dalam pemilihan bobot, bukan sekadar komponen tambahan pada fungsi loss visual. Pendekatan ini berbeda dari metode restorasi dokumen konvensional dalam dua aspek:

- **Dominasi CTC Loss:** Meskipun bobot nominal rendah ($\lambda_{\text{ctc}} = 0,15$), magnitudo *natural* yang besar ($\sim 100\text{--}400$) menghasilkan kontribusi efektif 67,5% terhadap total *generator loss*—dibandingkan 32,4% untuk komponen visual (*pixel + adversarial + perceptual*).
- **Orientasi Keterbacaan:** Generator dioptimalkan secara eksplisit untuk keterbacaan HTR, memastikan hasil restorasi tidak hanya berkualitas visual tinggi tetapi juga dapat dibaca oleh sistem pengenalan teks.

Analisis *trade-off* multi-objektif antara kualitas visual (PSNR, SSIM) dan keterbacaan teks (CER, WER), termasuk validasi *Pareto front* dan sensitivitas komponen loss, diuraikan secara detail pada Bab V.

IV.2 Pengembangan Dataset

Pelatihan dan evaluasi kerangka kerja GAN-HTR memerlukan konstruksi dataset khusus yang tidak tersedia secara publik. Bagian ini menjelaskan proses pengembangan empat komponen dataset: (1) *ground truth* untuk pelatihan model GAN, (2) *ground truth* untuk pelatihan model *recognizer*, (3) dataset evaluasi kuantitatif, dan (4) dataset evaluasi kualitatif. Seluruh data bersumber dari koleksi arsip ANRI untuk memastikan karakteristik paleografi yang representatif. Gambar ?? memvisualisasikan alur pembuatan *ground truth* secara keseluruhan.

IV.2.1 Pembuatan *Ground Truth* untuk GAN

Model GAN memerlukan pasangan citra terdegradasi-bersih (*paired images*) dengan keselarasan tingkat piksel yang sempurna. Karena dokumen historis nyata yang rusak tidak dapat dipulihkan ke kondisi aslinya secara fisik, dataset semi-sintetis dikonstruksi melalui dua tahap.

IV.2.1.1 Tahap Satu: Ekstraksi Citra Bersih

Citra *ground truth* (bersih) diperoleh dari dokumen arsip ANRI abad ke-16 hingga ke-18 yang memiliki kondisi fisik prima (minim degradasi). Proses ekstraksi meliputi:


- Seleksi manual halaman dengan keterbacaan tinggi dari koleksi ANRI.
- Ekstraksi baris teks menggunakan koordinat *baseline* dari anotasi Transkribus.
- Normalisasi geometri ke dimensi 1024×128 piksel.

IV.2.1.2 Tahap Dua: Sintesis Degradasi


Citra bersih kemudian diproses melalui *pipeline* degradasi sintetis berlapis untuk menghasilkan pasangan citra terdegradasi. Lima jenis degradasi diterapkan secara stokastik:

- a. *Overlay Latar Belakang & Fading*: Penggabungan dengan tekstur kertas tua ANRI, disertai reduksi kontras ($\gamma \in [0, 5, 0, 8]$).
- b. *Bleed-through* (30% prob.): *Alpha blending* ($\alpha \in [0, 3, 0, 7]$) mensimulasikan tembus tinta dari halaman belakang.
- c. *Stains & Foxing* (25% prob.): Tekstur noda organik menggunakan *Perlin noise* dan bintik kecoklatan.
- d. *Gaussian blur* (20% prob.): Kernel $\sigma \in [0, 5, 2, 0]$ mensimulasikan ketidakfokusan optik.
- e. Kerusakan Fisik & *Noise* (10% prob.): Simulasi robekan, lipatan, dan *salt & pepper noise*.

Degradasi diterapkan secara independen dan dapat saling tumpang tindih. Validasi PSNR > 20 dB memastikan struktur karakter tetap terbaca. Proses ini menghasilkan *dataset triplet* ($I_{\text{deg}}, I_{\text{clean}}, \text{transcription}$) sebanyak 4.739 pasangan.



Gambar IV.5 Alur pembuatan *ground truth* untuk GAN-HTR. Proses mengintegrasikan tiga sumber: (1) dokumen ANRI kondisi prima untuk citra bersih, (2) PageXML Transkribus untuk koordinat *baseline* dan transkripsi, serta (3) dokumen ANRI rusak untuk tekstur *background* autentik. Hasil akhir adalah dataset triplet (I_{clean} , I_{degraded} , transcription) sebanyak 4.739 pasangan.



Gambar IV.6 Pasangan dataset semi-sintetis realistis. (Atas) Citra *ground truth* bersih dari dokumen ANRI abad ke-16–18. (Bawah) Citra terdegradasi hasil sintesis degradasi berlapis.

IV.2.2 Pembuatan *Ground Truth* untuk *Recognizer*

Model *recognizer* (HTR) yang digunakan sebagai komponen *frozen* dalam arsitektur memerlukan dataset terpisah untuk pelatihannya. Dataset ini dikonstruksi

dari sumber yang sama (dokumen ANRI bersih) namun dengan pemrosesan yang berbeda.

IV.2.2.1 Proses Konstruksi

- Segmentasi Baris: Ekstraksi baris teks menggunakan koordinat *baseline* dari anotasi Transkribus.
- Pra-pemrosesan: Normalisasi ke rentang $[0, 1]$, *resize bilinear* ke 1024×128 piksel, dan binarisasi menggunakan DE-GAN untuk meningkatkan kontras goresan-latar.
- Validasi Kualitas: Setiap *patch* harus memiliki transkripsi valid (panjang > 3 karakter, tanpa karakter *out-of-vocabulary*).
- Pembagian Data: Rasio 80/10/10 (pelatihan/validasi/uji) dengan *stratified sampling* berdasarkan panjang teks.

Dataset ini disimpan dalam format TFRecord dan digunakan untuk melatih model *recognizer* sebelum di-*freeze* untuk integrasi ke dalam arsitektur GAN.

IV.2.3 Dataset Evaluasi Kuantitatif

Evaluasi kuantitatif menggunakan subset dari dataset semi-sintetis yang telah dikonstruksi. Dataset dibagi dengan rasio 70/15/15 menggunakan *seed* deterministik untuk menjamin reproduktibilitas:

- Pelatihan: 3.317 pasangan citra (70%)
- Validasi: 710 pasangan citra (15%)
- Pengujian: 712 pasangan citra (15%)

Keselarasan piksel sempurna antara citra terdegradasi dan *ground truth* memungkinkan perhitungan metrik objektif (PSNR, SSIM) yang akurat. Transkripsi yang menyertai setiap pasangan memungkinkan evaluasi CER terhadap prediksi HTR.

IV.2.4 Dataset Evaluasi Kualitatif

Untuk menguji kemampuan generalisasi model pada kondisi dunia nyata, sejumlah dokumen representatif dari koleksi ANRI digunakan sebagai set evaluasi kualitatif. Sebanyak 15 dokumen halaman penuh dari era VOC dan Hindia Belanda (1650–1800) dipilih secara manual berdasarkan kriteria:

- a. Variasi Degradasi: Mencakup spektrum kerusakan dari ringan hingga parah.
- b. Jenis Kerusakan: Meliputi penuaan kertas, noda organik, *foxing*, tinta luntur, *bleed-through*, dan kerusakan fisik.
- c. Karakteristik Paleografi: Merepresentasikan berbagai gaya tulisan tangan dan tingkat kompleksitas ligatur.

Karena tidak memiliki *ground truth* visual (citra bersih), evaluasi pada dataset ini dilakukan secara kualitatif melalui inspeksi visual dan validasi keterbacaan oleh ahli paleografi. Pendekatan ini memvalidasi kemampuan generalisasi model terhadap degradasi autentik yang tidak dapat sepenuhnya direplikasi melalui sintesis komputasional.

IV.3 Strategi dan Protokol Pelatihan

Pelatihan kerangka kerja GAN-HTR menghadapi tantangan unik yang tidak dijumpai pada pelatihan GAN konvensional. Kombinasi lima komponen *loss* dengan magnitudo berbeda, integrasi *frozen recognizer* untuk gradien sadar-HTR, serta arsitektur diskriminator *dual-modal* memerlukan strategi pelatihan yang dirancang secara khusus untuk menjamin stabilitas konvergensi. Bagian ini menguraikan protokol pelatihan yang dikembangkan untuk mengatasi tantangan-tantangan tersebut.

Pembahasan dimulai dengan strategi *curriculum learning* tiga fase yang memperkenalkan komponen *loss* secara bertahap untuk mencegah *mode collapse* dini (??). Selanjutnya, dibahas mekanisme regularisasi dan analisis stabilitas yang memvalidasi efektivitas protokol pelatihan (??). Bagian ini ditutup dengan spesifikasi teknis implementasi, termasuk kebijakan presisi numerik dan konfigurasi mode diskriminator.

IV.3.1 Curriculum Learning dan Protokol Optimisasi

Strategi pelatihan GAN-HTR terdiri atas dua dimensi yang saling melengkapi: (1) *curriculum learning* yang mengatur evolusi bobot *loss* antar-epoch, dan (2) prosedur pelatihan *adversarial* yang mengatur pembaruan model dalam setiap iterasi. Kedua dimensi ini bekerja secara simultan untuk menjamin stabilitas konvergensi.

IV.3.1.1 Dimensi Temporal: Tiga Fase *Curriculum Learning*

Pelatihan menggunakan pendekatan *curriculum learning* bengio2009 tiga fase yang memperkenalkan komponen *loss* secara bertahap. Strategi ini mencegah *mode collapse* dan memungkinkan generator membangun kapabilitas secara inkremental:

- Fase *Warmup* Visual (epoch 1–10): Pelatihan eksklusif pada kualitas visual tanpa supervisi teks, memungkinkan generator membangun kemampuan rekonstruksi dasar. Fase ini mencegah *mode collapse* dini yang dapat terjadi jika *loss* CTC diperkenalkan terlalu awal. Pada fase ini, hanya komponen *loss* visual yang diaktifkan: $\mathcal{L}_{\text{pixel}}$, $\mathcal{L}_{\text{adv}}$, dan $\mathcal{L}_{\text{perc}}$ dengan bobot penuh sesuai Tabel ??, sementara $\lambda_{\text{ctc}} = 0$ untuk stabilitas awal.
- Fase Peningkatan Bertahap CTC (epoch 11–30): Peningkatan bertahap bobot CTC dari nol ke bobot penuh secara linear. Integrasi halus ini memungkinkan generator beradaptasi dengan gradien HTR tanpa mengganggu kestabilan pelatihan *adversarial* yang sudah terbentuk. Bobot CTC ditingkatkan secara linear: $\lambda_{\text{ctc}}(e) = 0,15 \times \frac{e-10}{20}$ untuk epoch $e \in [11, 30]$, mencapai nilai maksimal 0,15 pada epoch 30.
- Fase Pelatihan Penuh (epoch 31–50): Pelatihan dengan semua komponen *loss* aktif pada bobot optimal (Tabel ??), disertai penyeimbangan adaptif untuk menjaga keseimbangan dinamis antara *loss* visual dan tekstual. Mekanisme penyeimbangan memantau rasio kontribusi setiap komponen dan melakukan penyesuaian minor ($\pm 5\%$) jika terjadi dominasi berlebihan dari satu komponen.

Tabel ?? merangkum konfigurasi ketiga fase beserta fokus optimasi masing-masing.

Tabel IV.3 Protokol *curriculum learning* tiga fase: warmup visual, peningkatan bertahap CTC, pelatihan penuh.

Fase	Epoch	λ_{CTC}	Fokus
Warmup Visual	1–10	0,0	Struktur visual dasar, stabilitas adversarial
Peningkatan Bertahap	11–30	$0 \rightarrow 0,15$	Adaptasi gradien HTR secara halus
Pelatihan Penuh	31–50	0,15	Optimasi penuh semua komponen

IV.3.1.2 Penyeimbangan Bobot Adaptif

Pada fase pelatihan penuh (epoch 31–50), sistem mengaktifkan mekanisme *adaptive loss balancing* yang secara otomatis menyesuaikan bobot setiap komponen *loss* berdasarkan magnitudo relatifnya. Mekanisme ini bertujuan menjaga

keseimbangan antara komponen visual dan HTR dengan target rasio CTC 40% dan visual 60%. Algoritma penyeimbangan memantau kontribusi relatif setiap komponen *loss* pada setiap iterasi dan melakukan penyesuaian halus dengan *adaptation rate* 0,08 untuk mencegah dominasi berlebihan dari satu komponen yang dapat merusak optimasi multiobjektif.

IV.3.1.3 Dimensi Iterasi: Prosedur Pelatihan *Adversarial* Bergantian

Dalam setiap fase *curriculum* di atas, pembaruan model dilakukan melalui prosedur pelatihan *adversarial* bergantian. Prosedur ini menentukan bagaimana generator dan diskriminator diperbarui secara bergantian pada setiap iterasi (*batch*):

- a. Langkah Diskriminator: Perbarui D untuk memaksimalkan kemampuan membedakan pasangan nyata (I_{gt}, teks_{gt}) dari pasangan palsu ($I_{gen}, \text{teks}_{pred}$) dengan supervisi simultan pada domain visual dan tekstual. Diskriminator dilatih dengan *loss binary cross-entropy* yang mengoptimalkan deteksi autentisitas pada kedua modalitas secara bersamaan.
- b. Langkah Generator: Perbarui G untuk meminimalkan $\mathcal{L}_{total}$ (kombinasi lima komponen *loss*, Persamaan ??), menghasilkan citra yang secara simultan menipu diskriminator dan mengoptimalkan keterbacaan HTR. Generator menerima gradien dari diskriminator (untuk realisme visual), pengenalan beku (untuk keterbacaan teks), dan *loss* rekonstruksi langsung.

Pembaruan dilakukan dengan rasio seimbang 1:1, memastikan stabilitas pelatihan *adversarial*. Setiap iterasi pelatihan melakukan satu pembaruan diskriminator diikuti satu pembaruan generator untuk mencegah ketidakseimbangan yang dapat menyebabkan *mode collapse* atau dominasi salah satu komponen.

IV.3.1.4 Konfigurasi Hyperparameter Pelatihan

Konfigurasi pelatihan didasarkan pada penyetelan empiris untuk stabilitas GAN dan konvergensi optimal:

- a. Optimisasi: Generator menggunakan algoritma Adam dengan parameter momentum disesuaikan ($\beta_1 = 0,5$, $\beta_2 = 0,999$) untuk stabilitas GAN, sementara diskriminator menggunakan SGD dengan momentum = 0,9 untuk mencegah *mode collapse* dan memastikan konvergensi stabil. Kedua model menerapkan *gradient clipping* dengan norma global = 1,0 untuk mencegah ledakan gradien.

- b. Laju Pembelajaran: Kedua model menggunakan laju pembelajaran awal yang sama ($\alpha_{\text{init}} = 2 \times 10^{-4}$) dengan penjadwalan *cosine annealing* untuk konvergensi halus tanpa penurunan tajam. Laju pembelajaran menurun secara halus mengikuti fungsi *cosine* dari nilai awal ke nilai minimum ($\alpha_{\text{min}} = 1 \times 10^{-6}$) selama pelatihan.
- c. Ukuran *Batch* dan Dimensi: Ukuran batch kecil (2 sampel per GPU) dengan dimensi citra lebar ($1024 \times 128 \times 1$ piksel) yang mempertahankan detail goresan halus pada teks baris tunggal paleografi. Dimensi lebar diperlukan untuk menangkap konteks sekuensial teks baris lengkap.
- d. Penghentian Dini: Diterapkan dengan mekanisme *patience* 25 epoch yang mempertimbangkan fase *curriculum*, memulihkan bobot terbaik berdasarkan metrik gabungan PSNR-CER dengan pembobotan yang memprioritaskan kualitas visual. Kriteria: $\text{Score} = \text{PSNR} - 0,5 \times \text{CER}$ untuk keseimbangan optimal.

IV.3.2 Mekanisme Regularisasi dan Konfigurasi Teknis

Selain strategi *curriculum learning* dan protokol optimasi yang telah diuraikan sebelumnya, keberhasilan pelatihan GAN-HTR bergantung pada mekanisme regularisasi untuk mencegah *overfitting* dan spesifikasi implementasi teknis untuk menjamin reproduktibilitas. Pelatihan arsitektur *deep learning* pada dataset terbatas rentan terhadap risiko *overfitting*. Untuk memitigasi risiko ini, serangkaian teknik regularisasi diterapkan secara strategis:

- a. *Batch Normalization*: Diterapkan di semua lapisan konvolusional dengan momentum = 0,9 dan $\epsilon = 10^{-5}$ untuk stabilitas pelatihan dan mempercepat konvergensi.
- b. *Label Smoothing* Asimetris: Hanya diterapkan pada label nyata ($\epsilon_{\text{smooth}} = 0,1$) untuk mengurangi kepercayaan berlebihan diskriminator.
- c. Koneksi Residual: Diterapkan di diskriminator untuk aliran gradien yang lebih baik, mengatasi masalah *vanishing gradient*.
- d. *Dropout*: Diterapkan pada *classification head* diskriminator ($\text{rate} = 0,1$) dan *embedding layer* teks ($\text{rate} = 0,2$).

Untuk menjamin reproduktibilitas eksperimen, dibawah ini merupakan parameter pelatihan yang digunakan, dijelaskan pada Tabel ??.

Tabel IV.4 Spesifikasi implementasi teknis eksperimen pelatihan GAN-HTR.

Parameter	Nilai/Konfigurasi
<i>Optimizer</i> Diskriminator	SGD, momentum = 0,9, $\alpha_{\text{init}} = 2 \times 10^{-4}$
<i>Optimizer</i> Generator	Adam, $\beta_1 = 0,5$, $\beta_2 = 0,999$, $\alpha_{\text{init}} = 2 \times 10^{-4}$
Ukuran <i>Batch</i>	2 sampel/GPU
Dimensi Citra	$1024 \times 128 \times 1$ piksel (<i>width</i> $\times$ <i>height</i> $\times$ <i>channel</i>)
Presisi Numerik	<i>Pure</i> FP32 (tanpa <i>mixed precision</i>)
<i>Early Stopping</i>	<i>Patience</i> = 25 epoch, <i>min delta</i> = 0,05
<i>Gradient Clipping</i>	Norma global = 1,0 (kedua model)
<i>CTC Loss Clipping</i>	Nilai maksimum = 400,0
<i>Seed</i> Reproductibilitas	42

Model terbaik dipilih berdasarkan metrik gabungan PSNR-CER pada epoch 44. Pelatihan dilanjutkan hingga epoch 50 untuk memverifikasi konvergensi stabil. Terkait mode masukan diskriminator *dual-modal*, penelitian ini mengimplementasikan *Predicted Mode* yang menggunakan prediksi dari *frozen recognizer* sebagai masukan cabang teks. Mode ini dipilih karena lebih realistis untuk skenario penerapan (*deployment*) ketika *ground truth* tidak tersedia, serta memberikan gradien yang lebih konsisten dengan kondisi inferensi aktual. Kebijakan presisi *pure* FP32 diimplementasikan untuk stabilitas kalkulasi *loss* CTC yang sensitif terhadap *underflow*, dengan *trade-off* waktu pelatihan $\sim 28\%$ lebih lambat dibanding FP16.

Validasi empiris terhadap stabilitas pelatihan dan konvergensi dibahas pada Bab V Subbab ??.

IV.4 Konfigurasi Evaluasi

Evaluasi *framework* GAN-HTR dilakukan melalui tiga pendekatan: (1) perbandingan dengan metode *baseline* klasik, (2) studi ablasi untuk validasi komponen, dan (3) pengukuran metrik multi-objektif untuk kualitas visual dan keterbacaan teks.

IV.4.1 Metode Klasik untuk Perbandingan Kuantitatif

Metode klasik dipilih sebagai *baseline* kuantitatif karena dapat diimplementasi ulang pada dataset identik tanpa memerlukan pelatihan ulang, sehingga memungkinkan perbandingan yang adil dan reproduktibel. Tabel ?? merangkum

tiga metode *baseline* yang digunakan beserta konfigurasinya.

Tabel IV.5 Ringkasan metode *baseline* klasik untuk perbandingan kuantitatif.

Metode	Implementasi	Konfigurasi
Tanpa Perbaikan	Input langsung	Normalisasi [0,1], citra <i>grayscale</i> 1024×128 px
Otsu <i>Thresholding</i>	OpenCV 4.8.1	Gaussian blur 5×5 , threshold otomatis
Sauvola Adaptive	scikit-image 0.21.0	Window $w = 51$ px (optimasi grid search), $k = 0,2$

Tanpa Perbaikan (*Degraded Input*) berfungsi sebagai *upper bound* degradasi untuk mengukur dampak maksimal kerusakan dokumen terhadap kinerja HTR. Otsu *Thresholding* menerapkan binarisasi global berbasis histogram yang umum digunakan untuk pembersihan dokumen sederhana. Sauvola Adaptive *Thresholding* menggunakan binarisasi lokal yang lebih sesuai untuk dokumen dengan pencahayaan tidak seragam; parameter *window* dioptimalkan melalui pencarian kisi pada subset validasi ($n = 100$).

Metode klasik dipilih karena: (1) reproduktibilitas dengan library standar, (2) waktu eksekusi cepat (<1 detik per citra), dan (3) mewakili pendekatan tradisional yang umum digunakan praktisi arsip.

IV.4.2 Studi Ablasi sebagai Validasi Komponen

Untuk memvalidasi kontribusi setiap komponen arsitektur secara sistematis, studi ablasi inkremental dilakukan dengan menambahkan komponen *loss* secara bertahap (hasil evaluasi disajikan pada Bagian ??):

1. Eksperimen 01 (Hanya Piksel): Setara dengan U-Net standar untuk restorasi citra
2. Eksperimen 02 (+*Adversarial*): Setara dengan GAN standar tanpa komponen HTR
3. Eksperimen 03 (+Perseptual): Peningkatan dengan loss perseptual berbasis VGG
4. Eksperimen 04 (+CTC): Konfigurasi optimal dengan integrasi HTR
5. Eksperimen 05 (+Fitur Pengenal): Konfigurasi lengkap untuk validasi redundansi komponen

Pendekatan ablasi ini memberikan pemahaman tentang kontribusi relatif setiap komponen dan memvalidasi keputusan desain arsitektural secara empiris.

Perbandingan kuantitatif langsung dengan metode *deep learning* terkini (U-Net, DE-GAN, ERB-MultiTask, DocEnTr) tidak dilakukan karena perbedaan dataset pelatihan dan ketiadaan implementasi resmi yang dapat direproduksi, metode tersebut berfungsi sebagai konteks penelitian untuk memposisikan kontribusi yang diusulkan sebagaimana telah dibahas pada Bab II.

IV.4.3 Metrik Evaluasi

Evaluasi multi-objektif memerlukan metrik untuk mengukur kualitas visual dan keterbacaan teks secara simultan. Tabel ?? memetakan metrik dengan komponen arsitektur yang divalidasi, sedangkan Tabel ?? menyajikan spesifikasi implementasi teknis.

Tabel IV.6 Pemetaan metrik evaluasi dengan komponen arsitektur dan kebutuhan sistem.

Metrik	Aspek Diukur	Komponen Terkait	Kebutuhan
PSNR	Akurasi piksel	Generator ($\mathcal{L}_{\text{pixel}}$)	NFR-1
SSIM	Struktur perseptual	Generator ($\mathcal{L}_{\text{perc}}$)	NFR-1
CER	Keterbacaan karakter	<i>Frozen Recognizer</i> + $\mathcal{L}_{\text{CTC}}$	FR-3, NFR-2
WER	Keterbacaan kata	<i>Frozen Recognizer</i> + $\mathcal{L}_{\text{CTC}}$	FR-3, NFR-2

Tabel IV.7 Spesifikasi implementasi teknis metrik evaluasi.

Metrik	Library	Algoritma	Pra-pemrosesan
PSNR	scikit-image 0.21.0	$10\log_{10}(\text{MAX}^2/\text{MSE})$	<i>float32</i> [0, 1]
SSIM	scikit-image 0.21.0	<i>Gaussian weighted</i>	<i>grayscale</i> [0, 1]
CER	editdistance 0.6.2	<i>Levenshtein distance</i>	<i>CTC greedy, lowercase</i>
WER	editdistance 0.6.2	<i>Levenshtein distance</i>	Tokenisasi kata

IV.4.4 Formula Matematika

Metrik kualitas visual PSNR (*Peak Signal-to-Noise Ratio*) mengukur rasio antara nilai maksimum sinyal dan derau rekonstruksi:

$$\text{PSNR} = 10\log_{10}\left(\frac{\text{MAX}^2}{\text{MSE}}\right) \quad (\text{IV.17})$$

dengan $\text{MAX} = 1,0$ untuk citra ternormalisasi [0, 1], dan MSE merupakan *Mean Squared Error*.

Metrik SSIM (*Structural Similarity Index*) mengukur kesamaan struktural antara

dua citra berdasarkan luminansi, kontras, dan struktur:

$$\text{SSIM}(I_1, I_2) = \frac{(2\mu_1\mu_2 + C_1)(2\sigma_{12} + C_2)}{(\mu_1^2 + \mu_2^2 + C_1)(\sigma_1^2 + \sigma_2^2 + C_2)} \quad (\text{IV.18})$$

dengan μ_1 , μ_2 adalah rata-rata lokal; σ_1 , σ_2 adalah variansi lokal; σ_{12} adalah kovariansi; dan C_1 , C_2 adalah konstanta stabilisasi.

Metrik keterbacaan CER (*Character Error Rate*) dan WER (*Word Error Rate*) mengukur tingkat kesalahan pengenalan teks menggunakan algoritma *Levenshtein distance*:

$$\text{CER} = \frac{\text{EditDistance}(t_{\text{gt}}, t_{\text{pred}})}{|t_{\text{gt}}|} \times 100\% \quad (\text{IV.19})$$

$$\text{WER} = \frac{\text{EditDistance}(w_{\text{gt}}, w_{\text{pred}})}{|w_{\text{gt}}|} \times 100\% \quad (\text{IV.20})$$

dengan t_{gt} , w_{gt} adalah teks/kata *ground truth*, t_{pred} , w_{pred} adalah hasil prediksi, dan $|\cdot|$ menunjukkan panjang karakter atau jumlah kata.

IV.4.5 Metrik Peningkatan Relatif

Selain metrik absolut, penelitian ini menggunakan metrik peningkatan relatif untuk mengukur efektivitas restorasi secara ternormalisasi terhadap kondisi awal dokumen terdegradasi:

$$\text{Improvement} = \frac{M_{\text{degraded}} - M_{\text{restored}}}{M_{\text{degraded}}} \times 100\% \quad (\text{IV.21})$$

dengan M_{degraded} adalah nilai metrik (CER/WER) pada citra terdegradasi dan M_{restored} adalah nilai pada citra hasil restorasi. Nilai positif menunjukkan penurunan tingkat kesalahan, dengan nilai lebih tinggi mengindikasikan efektivitas restorasi yang lebih besar.