

Bab V Hasil dan Pembahasan

V.1 Pendahuluan

Bab ini menyajikan hasil evaluasi kerangka kerja restorasi dokumen berbasis GAN dengan diskriminator dual-modal dan strategi *frozen recognizer* yang dirancang dan diimplementasikan pada bab sebelumnya. Evaluasi dilakukan untuk menjawab pertanyaan penelitian yang dirumuskan pada Bab I, khususnya terkait dengan kemampuan kerangka kerja yang diusulkan dalam mengatasi kesenjangan antara optimasi visual dan keterbacaan teks.

Pembahasan dalam bab ini diorganisasikan sebagai berikut. Pertama, hasil kuantitatif yang menyajikan pengukuran kinerja model menggunakan metrik standar untuk kualitas visual (PSNR dan SSIM) serta metrik keterbacaan teks (CER dan WER). Kedua, evaluasi kualitatif pada dokumen historis nyata yang memperkuat temuan kuantitatif melalui visualisasi dan penilaian ahli. Ketiga, studi ablasi yang mengisolasi dan mengukur kontribusi dari setiap komponen yang diusulkan (diskriminator dual-modal, *frozen recognizer*, *curriculum learning*, dan konfigurasi fungsi *loss*). Keempat, pengujian hipotesis untuk memvalidasi signifikansi hasil secara formal. Kelima, posisi penelitian terhadap pustaka terkini untuk mengontekstualisasikan temuan dalam lanskap penelitian yang lebih luas. Terakhir, pembahasan yang menginterpretasikan temuan utama dan mengidentifikasi keterbatasan penelitian.

Organisasi pembahasan ini dirancang untuk memberikan pemahaman menyeluruh mengenai efektivitas kerangka kerja yang diusulkan, mulai dari bukti empiris kuantitatif, validasi visual, hingga identifikasi kontribusi spesifik dari setiap komponen yang diajukan dalam penelitian ini.

V.2 Hasil Kuantitatif pada Set Uji Semi-Sintetis Realistis

Bagian ini menyajikan hasil evaluasi kuantitatif model restorasi pada *set* uji semi-sintetis realistis. Pembahasan dibagi menjadi tiga subbagian yang saling melengkapi. Pertama, performa model pada *set* uji menyajikan metrik akhir restorasi (PSNR, SSIM, CER, WER) dan membandingkannya dengan metode *baseline*. Kedua, perkembangan metrik pelatihan menjelaskan bagaimana model mencapai performa tersebut melalui analisis dinamika metrik selama 50 *epoch*. Ketiga, analisis korelasi tingkat degradasi mengkuantifikasi hubungan antara kondisi citra masukan dan efektivitas restorasi.

V.2.1 Performa Model pada Set Uji

Tabel ?? menyajikan hasil kuantitatif dari evaluasi model pada *set* uji yang sama ($n=712$). Evaluasi mencakup lima metrik utama: PSNR untuk kualitas visual piksel,

SSIM untuk kesamaan struktural, *F-measure* untuk akurasi binarisasi, serta CER dan WER untuk keterbacaan teks.

Tabel V.1 Hasil Kuantitatif pada Set Uji Semi-Sintetis Realistic

Metode	PSNR (dB) ↑	SSIM ↑	<i>F-measure</i> ↑	CER (%)	WER (%)
Tanpa Perbaikan	7,91±1,01	0,340±0,077	- ^a	83,4±18,5 ↓	98,7±7,3 ↓
Otsu <i>Thresholding</i>	4,75±2,00	0,261±0,099	0,748±0,085	85,7±56,7 ↓	112,9±69,5 ↓
Sauvola Adaptif	9,92±1,99	0,437±0,149	0,933±0,030	109,5±179,5 ↓	171,5±172,2 ↓
Yang Diusulkan	30,74±5,09	0,987±0,014	0,921±0,067	34,9±21,8 ↓	82,4±26,1 ↓
Batas Atas (<i>GT Bersih</i>)	-	-	-	34,1±22,7	82,1±27,3

^a*F-measure* tidak dapat diterapkan pada citra terdegradasi tanpa binarisasi.


Metode klasik menggunakan implementasi OpenCV standar dengan parameter global tetap ($k = 0.34, R = 128$).

Varians tinggi pada metode klasik mencerminkan sensitivitas terhadap parameter pada *dataset* heterogen.


WER > 100% disebabkan oleh tingginya *insertion error* akibat derau latar belakang yang terdeteksi sebagai karakter.

Hasil kuantitatif pada Tabel ?? menunjukkan keunggulan signifikan metode yang diusulkan dalam menangani variabilitas degradasi. Metode usulan mencapai PSNR 30,74±5,09 dB dan CER 34,9±21,8%, mendekati batas atas teoretis citra bersih.

Sebaliknya, metode klasik menunjukkan keterbatasan signifikan dalam skenario parameter tunggal untuk seluruh sampel. Varians yang sangat tinggi pada Sauvola (CER $\sigma=179,5$) dan nilai WER yang melebihi 100% (171,5%) mengindikasikan terjadinya kegagalan total pada sebagian sampel; pada kondisi tersebut, sistem HTR mengenali derau latar belakang (*foxing*, *bleed-through*) sebagai teks tambahan (*insertion errors*). Hal ini bukan berarti metode klasik tidak valid, melainkan menegaskan bahwa metode berbasis aturan sangat sensitif terhadap penyetelan parameter. Tanpa penyetelan manual per-citra (yang tidak praktis untuk volume arsip besar), metode klasik gagal beradaptasi dengan heterogenitas degradasi dokumen paleografi. Metode pembelajaran mendalam yang diusulkan, di sisi lain, menunjukkan kehandalan yang jauh lebih baik ($\sigma=21,8$) karena kemampuannya mempelajari fitur degradasi secara adaptif. Gambar ?? memvisualisasikan distribusi keempat metrik, sedangkan Gambar ?? mengkuantifikasi besaran peningkatan relatif. Gambar ?? memvisualisasikan perbandingan kualitatif pada dua sampel terbaik, menunjukkan tiga keunggulan metode yang diusulkan: (1) menjaga kelancaran goresan, yaitu kontinuitas karakter tetap utuh tanpa fragmentasi yang terlihat pada metode binarisasi (CER rata-rata 13,2% berbanding Otsu/Sauvola 63,2–64,7%); (2) pembersihan selektif, yaitu eliminasi *foxing* dan noda penuaan tanpa merusak detail teks; (3) keselarasan antara kualitas visual dan keterbacaan, yaitu SSIM tinggi (0,990) berkorelasi dengan CER rendah, memvalidasi efektivitas optimasi dual-objektif. Metode klasik dengan parameter tetap kurang efektif karena ambang adaptif global sulit mengakomodasi variasi degradasi lokal yang ekstrem pada dokumen paleografi.



Gambar V.1 Distribusi metrik restorasi pada *set* uji dengan interval kepercayaan 95%: (a) PSNR, (b) SSIM, (c) CER, (d) WER. Metode usulan mencapai performa mendekati performa HTR pada citra bersih tanpa degradasi.



Gambar V.2 Peningkatan metrik dari kondisi terdegradasi ke hasil restorasi: (a) peningkatan absolut, (b) peningkatan relatif (%). CER menunjukkan pengurangan 58,2% (83,4% → 34,9%).

Untuk memberikan gambaran yang jelas mengenai berbagai nilai CER yang digunakan dalam penelitian ini, Tabel ?? merangkum tiga kategori *baseline*: (1) performa *recognizer* pada citra bersih, (2) *input* terdegradasi tanpa restorasi, dan (3) hasil setelah restorasi.

Perbedaan CER antara *set* validasi dan uji ($\Delta=7,53$ poin persentase pada citra bersih,



Gambar V.3 Evaluasi kualitatif pada sampel optimal (PSNR > 30 dB, CER < 15%): (1) citra terdegradasi, (2) Otsu, (3) Sauvola, (4) metode usulan, (5) *ground truth*. Metode usulan mempertahankan detail goresan dan ligatur paleografi.

Tabel V.2 Ringkasan metrik CER pada berbagai kondisi: *baseline recognizer*, *input terdegradasi*, dan hasil restorasi.

Kondisi	Dataset	<i>n</i>	CER (%)
<i>Baseline Recognizer pada Citra Bersih (Ground Truth)</i>			
CER _{pretrain}	ANRI validasi awal	948	33,72
CER _{val-GT}	Validasi GT penelitian	710	26,57
CER _{test-GT}	Uji GT penelitian	712	34,1
<i>Input Terdegradasi (Tanpa Restorasi)</i>			
CER _{degraded}	Validasi & Uji	1422	83,4
<i>Hasil Restorasi Metode Usulan</i>			
CER _{val-restored}	Validasi	710	27,11
CER _{test-restored}	Uji	712	34,9
<i>Peningkatan Relatif</i>			
Validasi	83,4% → 27,11%	—	67,5%
Uji	83,4% → 34,9%	—	58,2%


$\Delta=7,79$ poin persentase pada hasil restorasi) mencerminkan variasi kompleksitas paleografi antardataset (bukan *overfitting*), yang dikonfirmasi oleh konsistensi rasio

peningkatan (67,5% berbanding 58,2%).

V.2.2 Perkembangan Metrik Pelatihan

Subbagian sebelumnya menyajikan hasil akhir restorasi pada *set* uji. Subbagian ini menjelaskan *bagaimana* model mencapai performa tersebut dengan menganalisis perkembangan metrik validasi selama 50 *epoch* pelatihan. Analisis ini penting untuk memastikan dua hal: (1) konvergensi berjalan stabil tanpa osilasi berlebihan, dan (2) model tidak mengalami *overfitting* pada data pelatihan.

Gambar ?? menyajikan perkembangan empat metrik validasi (PSNR, SSIM, CER, dan WER) dengan interval kepercayaan 95% yang menunjukkan keandalan statistik pengukuran.



Gambar V.4 Perkembangan metrik validasi selama 50 *epoch* dengan interval kepercayaan 95%: (a) PSNR, (b) SSIM, (c) CER, (d) WER. Model terbaik dipilih pada *epoch* 44 (bintang merah) berdasarkan kriteria gabungan PSNR-CER.

Terkait konvergensi metrik visual, proses pelatihan mengikuti strategi *curriculum learning* tiga fase yang dirancang pada Bab III.

Fase pertama (*epoch* 1–10) memfokuskan model pada rekonstruksi visual dasar tanpa penalti HTR, menghasilkan peningkatan PSNR yang cepat dari nilai awal. Fase kedua (*epoch* 11–30) secara bertahap mengaktifkan komponen CTC *loss* untuk menyelaraskan optimasi visual dengan keterbacaan teks. Pada fase ini, target kualitas visual tercapai: SSIM melampaui 0,95 pada *epoch* 22 dan PSNR mencapai 30,0

dB pada *epoch* 38. Fase ketiga (*epoch* 31–50) mempertahankan bobot penuh untuk konvergensi akhir.

Dari sisi stabilitas pelatihan, interval kepercayaan yang sempit ($\pm 0,42$ dB untuk PSNR dan $\pm 0,001$ untuk SSIM pada model terbaik) menunjukkan bahwa model mempelajari pola restorasi yang konsisten. Stabilitas ini penting untuk aplikasi praktis karena menjamin konsistensi performa.

Untuk pemilihan model terbaik, model optimal dipilih pada *epoch* 44 (bukan *epoch* terakhir) berdasarkan kriteria gabungan PSNR-CER. Protokol *early stopping* dengan toleransi 25 *epoch* tanpa perbaikan diterapkan untuk mencegah *overfitting* yang mungkin terjadi pada fase akhir pelatihan.

Secara keseluruhan, analisis perkembangan metrik mengonfirmasi keberhasilan desain strategi pelatihan: konvergensi bertahap melalui tiga fase memfasilitasi optimasi yang stabil, dan mekanisme *early stopping* mencegah degradasi performa.

V.2.3 Analisis Korelasi Tingkat Degradasi

Untuk memahami hubungan antara tingkat degradasi dokumen dan efektivitas restorasi, dilakukan analisis korelasi menggunakan set validasi ($n=710$ sampel). Analisis ini menjawab pertanyaan penelitian kunci: “Apakah restorasi lebih efektif untuk dokumen dengan degradasi berat atau ringan?” Gambar ?? menyajikan empat panel korelasi yang memvisualisasikan hubungan ini.

Berikut adalah temuan korelasi dari analisis tersebut:


1. SNR terhadap Peningkatan CER (Panel a)

- Korelasi negatif sangat kuat: Pearson’s $r = -0,963$, $R^2 = 0,927$, $p < 0,001$
- Interpretasi: dokumen dengan SNR rendah (degradasi berat) mengalami penurunan CER yang lebih besar dibanding dokumen dengan SNR tinggi (degradasi ringan)
- Implikasi praktis: model menunjukkan efektivitas lebih tinggi untuk dokumen historis yang sangat terdegradasi
- Validasi empiris: korelasi kuat ($R^2 > 0,9$) mengonfirmasi bahwa tingkat degradasi awal merupakan prediktor signifikan untuk manfaat restorasi

2. PSNR terhadap CER Terestorasi (Panel b)

- Korelasi lemah: Pearson’s r mendekati nol
- Interpretasi: setelah restorasi, PSNR tidak berkorelasi kuat dengan CER, mengindikasikan bahwa peningkatan kualitas visual tidak secara otomatis menjamin peningkatan akurasi pengenalan teks

**Comprehensive Degradation Severity vs Restoration Quality Analysis
(Production V3 Best Model - Epoch 44)**



Gambar V.5 Analisis korelasi pada *set* validasi: (a) SNR berbanding peningkatan CER ($r = -0,963$), (b) PSNR berbanding CER pasca-restorasi, (c) SSIM berbanding CER, (d) korelasi CER sebelum-sesudah.

c) Implikasi praktis: model menyeragamkan performa HTR terlepas dari tingkat degradasi awal

3. SSIM terhadap CER (Panel c)

- Korelasi lemah teramati antara SSIM dan CER, mengindikasikan SSIM saja tidak cukup untuk memprediksi akurasi HTR
- Implikasi: justifikasi untuk evaluasi multimetrik (PSNR + SSIM + CER) daripada mengandalkan metrik tunggal

4. CER Sebelum berbanding Sesudah (Panel d)

- Mayoritas sampel terletak di bawah garis diagonal ($y=x$), mengonfirmasi bahwa restorasi umumnya meningkatkan atau mempertahankan akurasi HTR
- Distribusi poin menunjukkan manfaat konsisten pada spektrum tingkat degradasi

Terkait implikasi untuk digitalisasi, berdasarkan analisis korelasi: (1) arsip dapat memprioritaskan dokumen dengan degradasi berat untuk restorasi karena peningkatan akurasi lebih besar; (2) restorasi tetap bermanfaat untuk normalisasi kualitas pada degradasi ringan; (3) PSNR/SSIM berguna untuk pemantauan visual,

tetapi CER/WER esensial untuk validasi efektivitas berorientasi HTR.

V.3 Hasil Kualitatif pada Dokumen Historis Nyata

Bagian sebelumnya mengevaluasi model pada data semi-sintetis dengan *ground truth* yang tersedia. Bagian ini melengkapi evaluasi tersebut dengan menguji model pada dokumen ANRI autentik, yaitu dokumen historis nyata tanpa *ground truth*, untuk memvalidasi kemampuan generalisasi ke kondisi degradasi di luar distribusi pelatihan.

Pembahasan diorganisasikan dalam subbagian berikut: (1) karakteristik *dataset* dan prosedur inferensi menjelaskan dokumen uji; (2) hasil kualitatif dan observasi menyajikan temuan visual berdasarkan tingkat kontras; (3) evaluasi oleh ahli paleografi memberikan validasi independen dari pakar domain; (4) analisis kesenjangan domain dan keterbatasan evaluasi mengidentifikasi perbedaan antara data pelatihan dan dokumen nyata serta keterbatasan yang perlu dicatat; dan (5) kesimpulan evaluasi kualitatif merangkum temuan keseluruhan.

V.3.1 Dataset dan Protokol Evaluasi Kualitatif

Dataset evaluasi kualitatif terdiri dari 15 dokumen halaman penuh dari koleksi ANRI. Tabel ?? merangkum karakteristik teknis dan jenis degradasi yang terdapat pada dokumen uji.

Tabel V.3 Karakteristik *dataset* evaluasi kualitatif ANRI

Aspek	Deskripsi
Jumlah dokumen	15 halaman penuh
Periode	1650–1800 (era VOC dan Hindia Belanda)
Resolusi	300 DPI (hasil pemindaian arsip)
Orientasi	Potret
<i>Jenis Degradasi Autentik</i>	
Penuaan kertas	Diskolorasi kuning/coklat intensitas tinggi
<i>Foxing</i>	Bercak kecoklatan dari <i>fungi</i> dan oksidasi selulosa
<i>Bleed-through</i>	Transparansi tinta dari halaman <i>verso</i>
Korosi tinta	Artefak <i>iron gall</i> dengan halo gelap
<i>Distribusi Kondisi</i>	
Degradasi parah	2 dokumen (13,3%)
Degradasi sedang	8 dokumen (53,3%)
Degradasi ringan-sedang	5 dokumen (33,3%)

1. Protokol Inferensi

Setiap dokumen diproses menggunakan *checkpoint* model dengan performa validasi terbaik. Mengingat dokumen ANRI memiliki orientasi potret dengan rasio aspek $< 1,5$, diterapkan strategi *adaptive tiling* bertingkat sebagai berikut:

- a. Segmentasi vertikal: Dokumen potret dibagi menjadi 2–3 kolom vertikal dengan *overlap* 25% untuk menghindari artefak batas.
- b. Segmentasi horizontal: Setiap kolom dipotong menjadi strip horizontal dengan target rasio aspek 6:1 (mendekati rasio pelatihan 8:1) dan *overlap* 15%.
- c. Pemrosesan *tile*: Setiap strip dinormalisasi ke rentang $[-1, 1]$ sesuai *pipeline* pelatihan, diproses melalui generator, lalu dikonversi kembali ke $[0, 255]$.
- d. *Blending* Gaussian: Strip hasil restorasi digabungkan menggunakan *windowing* Gaussian untuk transisi mulus antar-*tile*.
- e. *Post-processing* (opsional): Tahap ini bersifat tidak mandatori dan dapat diterapkan sesuai kebutuhan, mencakup CLAHE (*Contrast Limited Adaptive Histogram Equalization*), operasi morfologi penutupan untuk konektivitas goresan, dan *unsharp masking* untuk ketajaman tepi.

2. Protokol Evaluasi Visual

Keluaran disimpan dalam format TIFF tanpa kompresi sesuai standar preservasi arsip digital. Evaluasi visual dilakukan melalui perbandingan langsung *side-by-side* antara citra masukan terdegradasi dan keluaran terestorasi berdasarkan lima kriteria:

- a. Pembersihan latar : Efektivitas penghapusan artefak degradasi tanpa merusak area teks.
- b. Kejelasan teks: Tingkat keterbacaan karakter setelah restorasi.
- c. Keberadaan artefak: Kemunculan artefak baru akibat proses restorasi (*hallucination*, *ringing*).
- d. Pelestarian goresan: Keutuhan karakteristik paleografi (ketebalan, kemiringan, ornamen).
- e. Kegunaan keseluruhan: Penilaian holistik kesiapan dokumen untuk transkripsi manual atau HTR.

V.3.2 Hasil Kualitatif dan Observasi

Subbagian ini menyajikan hasil restorasi pada dokumen ANRI autentik secara visual, diikuti dengan observasi sistematis berdasarkan kategori tingkat kontras. Penilaian dilakukan melalui perbandingan langsung antara citra masukan terdegradasi dan keluaran terestorasi untuk mengidentifikasi pola kekuatan dan keterbatasan model. Gambar ?? menampilkan enam contoh representatif dari 15 dokumen yang diuji. Analisis visual mengungkapkan pola performa yang konsisten dengan karakteristik degradasi pada citra masukan.

Analisis visual 15 dokumen ANRI menunjukkan tiga pola performa utama berdasarkan tingkat kontras citra masukan (detail distribusi pada Tabel ??):



Gambar V.6 Hasil restorasi pada dokumen ANRI autentik: (kiri) masukan terdegradasi, (kanan) keluaran terestorasi. Baris 1 (a–b): sukses optimal pada kontras tinggi. Baris 2 (c–d): sukses tinggi hingga parsial pada kontras sedang. Baris 3 (e–f): kegagalan pada kontras sangat rendah dengan degradasi ekstrem.

1. Tinggi (≥ 60): pembersihan latar optimal dengan eliminasi *foxing* dan noda penuaan secara efektif, pelestarian morfologi karakter tanpa artefak, dan penghilangan *bleed-through* dengan preservasi teks *recto* yang baik.
2. Sedang (30–60): sukses parsial dengan reduksi derau substansial namun artefak residual pada wilayah *bleed-through* berat; peningkatan keterbacaan lebih konservatif untuk menghindari pembuatan teks palsu.
3. Rendah (< 30): peningkatan terbatas dengan strategi konservatif menghindari pembangkitan artefak palsu, mempertahankan autentisitas paleografi meskipun peningkatan visual minimal.

Meskipun model menunjukkan performa baik pada mayoritas dokumen ANRI, beberapa keterbatasan teridentifikasi:

1. Pemudaran ekstrem: dokumen dengan kontras <20 (1/15, 6,7%) mendapat peningkatan minimal karena distribusi kontras *dataset* pelatihan semi-sintetis berbeda.
2. Variansi *bleed-through*: pola *bleed-through* dunia nyata dengan tata letak halaman *verso* kompleks lebih sulit ditangani dibanding augmentasi semi-sintetis, menghasilkan sukses parsial pada 4/15 kasus (26,7%).
3. Artefak tinta *iron gall*: degradasi kimiawi historis tidak sepenuhnya tercakup dalam pelatihan, menyebabkan *over-suppression* pada 2/15 dokumen (13,3%).

Hasil evaluasi dokumen riil ANRI memberikan indikasi awal bahwa model dapat menggeneralisasi ke dokumen historis nyata dengan karakteristik degradasi yang tumpang tindih dengan distribusi pelatihan (kontras ≥ 30 , penuaan sedang hingga berat). Untuk kasus ekstrem di luar domain pelatihan, strategi konservatif model menghindari kegagalan katastrofik seperti halusinasi; pendekatan ini sesuai dengan prinsip preservasi arsip.

V.3.3 Evaluasi Ahli Paleografi

Untuk melengkapi analisis visual sebelumnya, penelitian ini melakukan evaluasi independen oleh ahli paleografi. Evaluasi ini bertujuan mendapatkan perspektif praktisi lapangan mengenai kualitas restorasi dan kesesuaiannya untuk alur kerja digitisasi arsip. Pembahasan mencakup tiga aspek: (1) prosedur penilaian ahli, (2) hasil dan analisis penilaian, serta (3) kesimpulan evaluasi ahli.

1. Prosedur Penilaian Ahli

Evaluasi ahli melibatkan dua evaluator independen. Penting untuk dicatat bahwa evaluasi bersifat pendahuluan dengan ukuran sampel terbatas ($n = 15$) dan tidak dimaksudkan sebagai validasi statistik konklusif. Tabel ?? merangkum prosedur yang digunakan.

2. Hasil dan Analisis Penilaian

Tabel ?? menyajikan hasil penilaian kuantitatif dari dua ahli independen. Skor keseluruhan mencapai 3,42/4,0 dengan reliabilitas antarpemilai yang substansial (Cohen's $\kappa=0,78$), mengindikasikan konsistensi penilaian meskipun ukuran sampel terbatas.

Analisis berdasarkan kategori kontras menunjukkan korelasi kuat antara tingkat kontras dan skor penilaian ahli (lihat Tabel ??). Pada kategori kontras tinggi, preservasi detail mikroskopis (goresan halus, modulasi tekanan pena) dinilai sangat

Tabel V.4 Prosedur evaluasi oleh ahli paleografi

Aspek	Deskripsi
<i>Panel Evaluator</i>	
Penilai 1	Ahli paleografi, skrip Belanda abad 16–18, 16 tahun pengalaman
Penilai 2	Ahli restorasi arsip, digitisasi koleksi Hindia Belanda
<i>Protokol Asesmen</i>	
Jenis asesmen Sampel	Tertutup (<i>blind</i>), evaluasi independen 15 pasangan dokumen (terdegradasi–terestorasi)
Skala Reliabilitas	Likert 4 poin (1=Buruk, 4=Sangat Baik) Cohen’s κ untuk konsistensi antarpemilai
<i>Kriteria Evaluasi</i>	
Keterbacaan Teks	Kemudahan membaca karakter dan ligatur khas
Autentisitas	Preservasi <i>ductus</i> , tekanan pena, ketebalan goresan
Minimasi Artefak	Tingkat gangguan artefak (skor tinggi = minimal)
Kegunaan	Kesesuaian untuk digitisasi dan transkripsi

Tabel V.5 Penilaian kualitatif ahli paleografi pada dokumen ANRI: skor keterbacaan, preservasi struktur, dan kelayakan transkripsi

Kriteria	Penilai 1	Penilai 2	Rerata
Keterbacaan Teks	3,47	3,33	3,40
Autentisitas Paleografi	3,60	3,53	3,57
Minimasi Artefak (inv.)	3,27	3,13	3,20
Kegunaan Transkripsi	3,53	3,47	3,50
Skor Keseluruhan	3,47	3,37	3,42

Cohen’s kappa (antarpemilai): $\kappa = 0,78$ (kesepakatan substansial pada sampel ini)

Skala: 1=Buruk, 2=Cukup, 3=Baik, 4=Sangat Baik

95% CI untuk rerata keseluruhan: [3,28, 3,56]

penting untuk analisis paleografi komparatif. Kategori kontras sedang memperoleh evaluasi positif meskipun terdapat catatan sedikit penghalusan berlebih pada region *bleed-through* berat. Sementara itu, kategori kontras rendah mendapat apresiasi khusus untuk pendekatan konservatif yang menghindari rekonstruksi semu.

Berikut adalah umpan balik kualitatif dari para ahli:

- a) *Penilai 1 (ahli paleografi)*: “Restorasi menunjukkan pemahaman implisit terhadap karakteristik skrip Belanda abad ke-17, khususnya preservasi *aspect*

Tabel V.6 Performa restorasi pada dokumen ANRI berdasarkan tingkat kontras dan skor penilaian ahli paleografi

Kategori Kontras	n	% Total	Efektivitas Teramati	Skor Ahli ^d
Tinggi (≥ 60)	5	33,3%	Baik Sekali ^a	3,75/4,0
Sedang (30–60)	8	53,3%	Baik ^b	3,38/4,0
Rendah (< 30)	2	13,3%	Terbatas ^c	2,63/4,0

^aBaik Sekali: pembersihan latar $> 80\%$, artefak minimal

^bBaik: perbaikan substansial, derau residual minor

^cTerbatas: peningkatan konservatif, tanpa halusinasi

^dSkor Ahli: rerata penilaian 2 ahli paleografi independen

ratio huruf-huruf *Gothic minuscule* dan ligatur khas seperti ‘st’, ‘ct’, dan ‘ck’. Pada dokumen kontras tinggi, pembersihan *foxing* sangat efektif tanpa mengorbankan detail superfisial seperti *pen lift marks* yang penting untuk analisis autentisitas. Catatan kritik: pada 2–3 kasus sedang, terdapat *slight blur* pada region dengan tinta *iron gall* terkorosi, namun ini tidak mengurangi utilitas untuk transkripsi semantik.”

- b) *Penilai 2 (ahli restorasi arsip)*: “Dari perspektif arsip digital, keluaran model sangat sesuai untuk digitisasi massal dengan koreksi manual minimal. Reduksi derau latar pada mayoritas dokumen sangat membantu proses OCR/HTR selanjutnya. Apresiasi khusus untuk pendekatan konservatif pada dokumen memudar ekstrem; model tidak melakukan *creative reconstruction* yang dapat menyesatkan interpretasi historis. Untuk alur kerja ANRI, disarankan penggunaan untuk praproses *batch* dengan verifikasi ahli pada kasus kontras < 30 .”
- c) *Kesepakatan antarpenilai*: Ketidaksepakatan terbesar terjadi pada kriteria *Minimasi Artefak* untuk dokumen kontras sedang; Penilai 1 lebih toleran terhadap derau residual dibanding Penilai 2 yang memprioritaskan kebersihan untuk otomasi OCR. Namun, kedua penilai sepakat pada urutan relatif dokumen (Spearman’s $\rho = 0,91$, $p < 0,001$).

3. Kesimpulan Evaluasi Ahli

Kesimpulannya, evaluasi awal oleh ahli paleografi (Cohen’s $\kappa = 0,78$, skor keseluruhan 3,42/4,0) memberikan indikasi positif bahwa model memiliki potensi untuk aplikasi digitisasi arsip, dengan catatan keterbatasan generalisasi akibat ukuran sampel kecil. Aspek yang dinilai menjanjikan meliputi: (1) preservasi arsip digital, yaitu autentisitas fitur paleografi terjaga (3,57/4,0) memungkinkan

Tabel V.7 Perbandingan distribusi karakteristik: data pelatihan semi-sintetis berbanding dokumen riil. Analisis kesenjangan domain menjelaskan perbedaan performa kuantitatif dan kualitatif.

Aspek	Semi-Sintetis	Dokumen Riil
Degradasi	<i>Pipeline</i> terkontrol 6 tahap	Penuaan alami 250–450 tahun
Keseragaman	Relatif seragam	Sangat bervariasi
Keparahan	Sedang (15–25 dB)	Ekstrem (<10 dB)
Latar belakang	Tekstur sampel	Kimia kertas menua
Jenis tinta	Simulasi modular	Korosi <i>iron gall</i>
<i>Ground truth</i>	Data berpasangan	Tanpa referensi

analisis komparatif skrip dan identifikasi juru tulis; (2) kemudahan akses publik, yaitu peningkatan keterbacaan (3,40/4,0) mengurangi hambatan peneliti nonspesialis; (3) alur kerja semiotomatis, yaitu kegunaan transkripsi (3,50/4,0) mendukung integrasi *pipeline* HTR dengan supervisi minimal. Hasil evaluasi dokumen riil secara keseluruhan memberikan indikasi awal potensi generalisasi model ke dokumen historis nyata dalam rentang distribusi pelatihan, dengan strategi konservatif yang menjaga integritas arsip pada kasus kontras rendah ekstrem.

V.3.4 Analisis Kesenjangan Domain dan Keterbatasan Evaluasi

Performa yang konsisten pada dokumen riil menunjukkan bahwa *pipeline* degradasi semi-sintetis realistis berhasil mereplikasi karakteristik degradasi historis yang relevan. Tabel ?? merangkum perbedaan karakteristik antara data pelatihan dan dokumen nyata.

Beberapa efek kesenjangan domain teramati pada evaluasi:

1. Bias restorasi konservatif: model cenderung melakukan peningkatan kurang optimal pada degradasi ekstrem (PSNR <10 dB) karena distribusi pelatihan tidak mencakup tingkat keparahan setara; namun ini merupakan kompromi yang dapat diterima untuk menghindari halusinasi.
2. Sensitivitas pola latar belakang: dokumen nyata dengan margin dekoratif kompleks atau tepi ornamental terkadang terhapus sebagian karena kebingungan

dengan derau (frekuensi: 2/15 dokumen).

3. Variansi kimia tinta *iron gall*: pola korosi kimia berbeda dengan degradasi yang disimulasikan sehingga restorasi hanya parsial; data pelatihan perlu diaugmentasi dengan model degradasi spesifik korosi.

Selain kesenjangan domain, evaluasi pada dokumen riil juga memiliki keterbatasan metodologis inheren:

1. Tidak ada metrik HTR kuantitatif: dokumen riil berusia 250–450 tahun tidak memiliki transkripsi *ground truth* yang andal, sehingga CER/WER tidak dapat diukur secara objektif.
2. Ukuran sampel terbatas: evaluasi dilakukan pada 15 dokumen halaman penuh yang dipilih secara representatif, sehingga bias sampel mungkin ada.
3. Tidak ada pengukuran PSNR/SSIM: dokumen riil tanpa citra referensi bersih menyebabkan penilaian kualitas visual sepenuhnya bergantung pada evaluasi subjektif ahli.

Keterbatasan-keterbatasan ini memperkuat pentingnya menggunakan metrik semi-sintetis pada Bagian ?? sebagai ukuran pengganti kuantitatif, sambil tetap mengacu pada penilaian ahli sebagai validasi praktis.

V.3.5 Kesimpulan Evaluasi Kualitatif

Meskipun dilatih secara eksklusif pada data berpasangan semi-sintetis, model menunjukkan generalisasi yang wajar ke pola degradasi dunia nyata. Dari 15 dokumen ANRI: 10 dokumen (66,7%) menunjukkan peningkatan signifikan dengan pembersihan latar >70% dan artefak minimal; 3 dokumen (20,0%) menunjukkan peningkatan moderat dengan derau residual yang dapat diterima; dan 2 dokumen (13,3%) dengan degradasi ekstrem (kontras <20) mendapat peningkatan terbatas karena berada di luar domain pelatihan. Secara keseluruhan, 13 dari 15 dokumen (86,7%) mendapat manfaat berguna untuk alur kerja transkripsi.

Penilaian ahli paleografi (skor 3,42/4,0, Cohen's $\kappa=0,78$) memberikan validasi independen terhadap potensi restorasi untuk alur kerja digitisasi arsip. Kesimpulannya, kesenjangan domain sintetis-ke-nyata dapat diatasi melalui desain *pipeline* degradasi yang hati-hati, dan bukti kualitatif ini memberikan dasar yang cukup untuk eksplorasi lebih lanjut dalam aplikasi arsip praktis.

V.4 Studi Ablasi

Bagian sebelumnya telah menunjukkan bahwa kerangka kerja yang diusulkan mencapai keseimbangan antara kualitas visual (PSNR 30,33 dB, SSIM 0,9537) dan keterbacaan teks (CER 27,41%). Namun, kerangka kerja ini terdiri dari beberapa komponen yang saling berinteraksi: fungsi *loss* multikomponen, strategi

frozen recognizer, diskriminator *dual-modal*, dan *curriculum learning*. Pertanyaan mendasar yang muncul adalah: seberapa besar kontribusi masing-masing komponen terhadap performa keseluruhan?

Studi ablasi pada bagian ini dirancang untuk menjawab pertanyaan tersebut melalui serangkaian eksperimen terkontrol yang mengisolasi dan mengukur dampak setiap komponen secara independen. Sebagaimana telah dirancang pada Bab IV Subbab ??, pendekatan ablasi menggunakan metode inkremental, yaitu menambahkan komponen *loss* secara bertahap dari *baseline* hingga konfigurasi lengkap, untuk memahami kontribusi relatif setiap komponen.

Pembahasan diorganisasikan sebagai berikut: (1) ablasi komponen fungsi *loss* mengukur kontribusi inkremental lima komponen (piksel $\rightarrow$ *adversarial* $\rightarrow$ perseptual $\rightarrow$ CTC $\rightarrow$ fitur pengenalan); (2) ablasi strategi *frozen recognizer* membandingkan parameter beku dengan pelatihan bersama; (3) ablasi diskriminator *dual-modal* mengevaluasi arsitektur diskriminator hibrida; (4) ablasi *curriculum learning* menganalisis efek penjadwalan fase pelatihan; dan (5) analisis bobot fungsi *loss* menyajikan distribusi kontribusi efektif dan validasi sensitivitas konfigurasi.

V.4.1 Ablasi Komponen Fungsi Loss

Tabel ?? menyajikan hasil dari studi ablasi inkremental lima komponen fungsi *loss*. Hasil ini mengukur kontribusi setiap komponen terhadap kualitas restorasi dokumen pada pelatihan 15 *epoch*.

Tabel V.8 Kontribusi inkremental komponen *loss* terhadap kualitas restorasi (15 *epoch*): (1) L1 piksel, (2) +*adversarial*, (3) +perseptual, (4) +CTC, (5) +fitur pengenalan. Komponen CTC memberikan peningkatan CER paling signifikan.

No.	Komponen <i>Loss</i>	PSNR (dB)	SSIM	CER (%)	Δ PSNR
1	$\mathcal{L}_{\text{pixel}}$ (L1)	$24,59 \pm 4,10$	$0,9614 \pm 0,0278$	N/A [†]	(acuan)
2	$\mathcal{L}_{\text{pixel}} + \mathcal{L}_{\text{adv}}$	$24,86^* \pm 4,21$	$0,9626 \pm 0,0279$	N/A [†]	+0,27
3	+ $\mathcal{L}_{\text{perc}}$ (VGG)	$24,55 \pm 4,69$	$0,9630^* \pm 0,0273$	N/A [†]	-0,04
4	+ $\mathcal{L}_{\text{ctc}}$	$24,76 \pm 4,71$	$0,9627 \pm 0,0294$	29,66*	+0,17
5	+ $\mathcal{L}_{\text{rec-feat}}$	$24,75 \pm 4,60$	$0,9629 \pm 0,0312$	30,16	+0,16
[†] CER tidak tersedia karena <i>recognizer</i> tidak diaktifkan					
*Nilai tertinggi untuk metrik ini: PSNR (Eks 2), SSIM (Eks 3), CER (Eks 4)					

Berikut adalah analisis kontribusi per komponen:

1. Piksel L1 (*Baseline*)

Eksperimen pertama menggunakan hanya *loss* L1 sebagai *baseline*, mencapai PSNR 24,59 dB dan SSIM 0,9614. Konfigurasi ini setara dengan U-Net standar tanpa mekanisme *adversarial* dan tanpa kepekaan teks. Nilai ini menjadi acuan untuk mengukur kontribusi inkremental setiap komponen tambahan.

2. *Adversarial Loss*

Memberikan peningkatan PSNR terbesar (+0,27 dB dari *baseline*), mencapai 24,86 dB. Komponen ini meningkatkan realisme tekstur melalui mekanisme pelatihan *adversarial* tanpa mengorbankan stabilitas konvergensi. SSIM juga meningkat (+0,0012), mengindikasikan perbaikan kesamaan struktural.

3. *Perceptual Loss*

Mengoptimalkan kesamaan struktural dengan SSIM tinggi (0,9630), namun dengan sedikit penurunan PSNR sebagai konsekuensi (-0,04 dB menjadi 24,55 dB). Penurunan metrik berbasis piksel ini merupakan konsekuensi yang diharapkan dari optimisasi berbasis fitur (VGG-19); dalam hal ini, ketajaman visual dan konsistensi perseptual diprioritaskan di atas akurasi piksel absolut.

4. *CTC Loss*

Mengaktifkan kapabilitas kepekaan HTR, mencapai CER 29,66% sambil mempertahankan kualitas visual yang kompetitif (PSNR 24,76 dB, hanya -0,10 dB dari maksimum). Dalam konteks ablasi 15 *epoch*, ini adalah konfigurasi yang sesuai untuk evaluasi cepat, mencapai keseimbangan *Pareto* antara kualitas visual dan keterbacaan teks tanpa beban komputasi komponen kelima.

5. *Recognition Feature Loss*

Menunjukkan kontribusi marginal dalam ablasi singkat, dengan penurunan performa CER sebesar 0,50% (menjadi 30,16%) tanpa adanya peningkatan visual yang signifikan. Temuan ini mengindikasikan bahwa pada fase awal pelatihan, komponen ini bersifat *redundan* dibandingkan dengan sinyal kepekaan teks yang sudah disediakan oleh *CTC Loss*.

Temuan penting - perbandingan dengan pelatihan produksi:

Studi ablasi 15 *epoch* mencapai PSNR maksimal 24,86 dB (Eksperimen 02), jauh di bawah model produksi (30,91). Kesenjangan ini (6,05 dB) mengonfirmasi bahwa:

- a) Pelatihan diperluas (≥ 40 *epoch*) diperlukan untuk konvergensi penuh dan mencapai batas kinerja absolut
- b) Studi ablasi 15 *epoch* efektif untuk mengukur kontribusi relatif setiap komponen,

bukan performa absolut

- c) Kontribusi komponen dapat berbeda antara fase awal (ablasi singkat) dan fase konvergensi penuh.

Rekomendasi konfigurasi berdasarkan konteks pelatihan:

- a) *Ablasi cepat/evaluasi awal (<20 epoch)*: Eksperimen 04 (4-komponen: Piksel + *Adversarial* + *Perceptual* + CTC, CER 29,66%) memberikan hasil terbaik tanpa beban komputasi RecFeat yang belum berkontribusi di fase awal
- b) Pelatihan produksi (*>40 epoch*), direkomendasikan: Konfigurasi lengkap 5-komponen (Eksperimen 05) dengan RecFeat=8,0 untuk stabilitas konvergensi jangka panjang, mencapai PSNR 30,91 dB
- c) *Kualitas visual prioritas tanpa HTR*: Eksperimen 02 (Piksel + *Adversarial*, PSNR 24,86 dB) untuk aplikasi tampilan visual semata

V.4.2 Ablasi Strategi *Frozen Recognizer*

Bagian ini mengevaluasi efektivitas strategi *Frozen Recognizer* dalam mengatasi ketidakstabilan gradien dan *catastrophic forgetting* pada sistem *end-to-end*. Eksperimen komparatif dilakukan antara metode usulan (bobot pengenalan teks dibekukan) dibandingkan dengan metode konvensional *Joint Training* (semua bobot dilatih) pada dataset ANRI paleografi. Analisis difokuskan pada validasi hipotesis bahwa pembekuan bobot dapat mempertahankan kemampuan pengenalan teks sekaligus mempercepat konvergensi restorasi visual. Temuan utama disajikan dalam empat aspek berikut:


1. Stabilitas Gradien

Tabel V.9 Perbandingan stabilitas trajektori *loss*: *frozen recognizer* berbanding *joint training* (20 epoch)

Pendekatan	G Loss	D Loss	R Loss	Rentang G	Status
<i>Frozen (Baseline)</i>	$2,84 \pm 0,45$	$1,37 \pm 0,31$	$96,23 \pm 12,3$	2,15–3,62	Stabil
<i>Joint Training</i>	$89,09 \pm 7,45$	$0,037 \pm 0,067$	$30,45 \pm 1,59$	75,16–103,41	Tidak Stabil

Dalam aspek stabilitas trajektori *loss*, hasil eksperimen menunjukkan perbedaan substansial dalam stabilitas pelatihan. Pendekatan *frozen recognizer* menunjukkan trajektori *loss* yang halus dengan standar deviasi rendah (G *loss*: $\pm 0,45$), sementara *joint training* mengalami nilai tinggi yang konsisten (G *loss*: $89,09 \pm 7,45$). Rentang G *loss* pada *joint training* (75,16–103,41) mengindikasikan *magnitude loss* yang signifikan lebih tinggi dibandingkan dengan *frozen* (2,15–3,62), dengan rasio $26\times$ pada nilai minimum.

Lebih lanjut, analisis *loss* diskriminator mengungkapkan fenomena *mode*



Gambar V.7 Trajektori *loss* selama 20 *epoch*: (a) Generator, (b) Diskriminator, (c) CTC. Strategi *frozen* menunjukkan konvergensi stabil, sedangkan *joint training* mengalami osilasi ekstrem dan *mode collapse*.

collapse yang signifikan pada *joint training* dengan D *loss* mendekati nol ($0,037 \pm 0,067$), mengindikasikan bahwa diskriminator terlalu dominan dan generator tidak dapat belajar secara optimal. Sebaliknya, *frozen recognizer* mempertahankan keseimbangan yang sehat antara generator dan diskriminator (D *loss*: $1,37 \pm 0,31$).

Stabilitas *frozen recognizer* yang teramati konsisten dengan mekanisme pembekuan bobot yang dirancang untuk mencegah kompetisi gradien (Bab IV.1.4), terbukti berhasil mengeliminasi konflik antara optimasi generator dan preservasi kemampuan *recognizer*. Gambar ?? mengonfirmasi *mode collapse* pada *joint training* (D *loss* $\rightarrow 0$) dan fluktuasi besar *frozen* ($\sigma=136,6$) sebagai efek *curriculum learning*, bukan instabilitas yang merusak.

2. Performa Keterbacaan Teks Evaluasi performa keterbacaan teks dilakukan menggunakan metrik CER dan WER pada data validasi. Tabel ?? menyajikan perbandingan antara kedua pendekatan.


Secara spesifik, *Joint training* menyebabkan *catastrophic forgetting* dengan pola berikut:

Tabel V.10 Perbandingan metrik keterbacaan: *frozen recognizer* (CER 31,63%) berbanding *joint training* (CER 42,85%)

Pendekatan	CER (%)	Δ CER (%)	PSNR (dB)	SSIM
Acuan (Praterlatih)	33,72	-	-	-
<i>Frozen Recognizer</i>	31,63	-2,09	23,09 $\pm$ 3,88	0,9538 $\pm$ 0,0306
<i>Joint Training (Epoch 5)</i>	69,06	+35,34	9,36 $\pm$ N/A	0,623 $\pm$ N/A
<i>Joint Training (Epoch 20)</i>	42,85	+9,13	10,71 $\pm$ N/A	0,742 $\pm$ N/A
Degradasi <i>Joint</i> (Puncak)	-	+35,34	-13,73	-0,33
Degradasi <i>Joint</i> (Akhir)	-	+11,22	-12,38	-0,21


- Epoch 5 (Degradasi Puncak): CER melonjak dari *baseline* 33,72% menjadi 69,06% (degradasi +35,34%), mengindikasikan ketidaksesuaian untuk domain paleografi kompleks
- Epoch 20 (Pemulihan Parsial): Pemulihan parsial hingga 42,85%, namun degradasi final tetap signifikan (+9,13% dari *baseline*)

Berbanding terbalik dengan kondisi tersebut, *frozen recognizer* justru meningkatkan performa menjadi 31,63% (perbaikan -2,09%), dengan keluaran yang tetap berkorelasi dengan masukan. Gambar ?? menunjukkan perkembangan CER selama eksperimen.



Gambar V.8 Trajektori CER selama 20 *epoch*: *frozen* mencapai 31,63% (-2,09% dari *baseline*), *joint* mengalami *catastrophic forgetting* (puncak 69,06%) dan hanya pulih ke 42,85% (+9,13%).

Gambar ?? menunjukkan ketidakstabilan *joint training* berdampak pada kualitas visual yang sangat rendah (*derau*/distorsi tinggi). *Frozen* unggul 12,38 dB (23,09 dB berbanding 10,71 dB, $p < 0,001$), atau peningkatan 115% dalam kualitas visual. Meskipun belum mencapai performa produksi (30,91 dB, 50 *epoch*),



Gambar V.9 Kualitas visual: *frozen* mencapai $23,09 \pm 3,88$ dB, sedangkan *joint* hanya 10,71 dB (*epoch* 20). Selisih 12,38 dB ($p < 0,001$) menunjukkan degradasi berat pada *joint training*.

frozen menunjukkan keunggulan yang jelas.

Catatan: Fluktuasi *loss* pada *frozen* lebih terkendali (Rentang *G loss* 2,15–3,62) dibandingkan dengan *joint* (75,16–103,41). Metrik akhir membuktikan: *frozen* CER 31,63% (perbaikan -2,09%) berbanding *joint* 42,85% *epoch* 20 (degradasi +9,13%); stabilitas numerik *loss* berkorelasi dengan stabilitas kemampuan HTR.

3. Efisiensi Komputasi


Perbandingan efisiensi komputasi dilakukan dengan mengukur waktu pelatihan, penggunaan memori GPU, dan jumlah parameter yang dioptimasi. Tabel ?? merangkum hasil analisis efisiensi.

Tabel V.11 Perbandingan efisiensi: *frozen* $7,4 \times$ lebih cepat (85s berbanding 630s per *epoch*) dengan parameter *trainable* 61,6% lebih sedikit

Metrik Efisiensi	<i>Frozen</i>	<i>Joint</i>
Waktu per <i>Epoch</i> (detik)	$85,0 \pm 2,1$	$630,5 \pm 5,3$
Durasi Total 20 <i>Epoch</i>	28,3 menit	210,2 menit
Penggunaan Memori GPU (GB)	13,6	$\sim 13,6$
Parameter Dapat Dilatih (M)	17,4	$\sim 45,3$
Parameter Tidak Dapat Dilatih (M)	27,9	–
<i>Steps</i> per <i>Epoch</i>	100	100
Stabilitas <i>Training</i>	Tinggi	Rendah

Data *joint training* dari log eksperimen 20 *epoch*. *Joint* $7,4 \times$ lebih lambat per *epoch* (630s berbanding 85s) karena beban tambahan *backpropagation* melalui *recognizer* yang dilatih (45,3M parameter berbanding 17,4M *frozen*), meskipun

melakukan validasi setiap 5 *epoch*. Efisiensi komputasi menunjukkan perbedaan substansial: *frozen recognizer* $7,4\times$ lebih cepat per *epoch* (85 detik berbanding 630 detik), dengan total durasi pelatihan 20 *epoch* hanya 28,3 menit dibanding 210,2 menit untuk *joint training*. Penggunaan memori GPU sebanding ($\sim 13,6$ GB) karena *batch size* identik. Perbedaan kecepatan disebabkan oleh beban tambahan *backpropagation* melalui 45,3M parameter yang dapat dilatih pada *joint* (*generator* + diskriminator + *recognizer*) berbanding 17,4M pada *frozen* (*generator* + diskriminator saja, *recognizer* yang tidak dapat dilatih 27,9M tidak mengonsumsi gradien). Gambar ?? menyajikan perbandingan efisiensi secara visual. Keunggulan ganda *frozen*: (1) Efisiensi komputasi $7,4\times$ lebih tinggi, (2) Pelestarian kemampuan HTR yang lebih baik (CER 31,63% dengan perbaikan -2,09% berbanding *joint* 42,85% dengan degradasi +9,13%).



Gambar V.10 Analisis efisiensi: (a) waktu per *epoch*, (b) penggunaan memori GPU, (c) jumlah parameter dapat dilatih. Strategi *frozen* mengurangi beban komputasi $7,4\times$ tanpa mengorbankan akurasi.

4. Sintesis dan Kesimpulan Perbandingan

Sintesis hasil eksperimen mengonfirmasi superioritas strategi *frozen recognizer* dibandingkan *joint training* di seluruh dimensi evaluasi. Tabel ?? merangkum temuan kuantitatif, menunjukkan bahwa pendekatan *frozen* tidak hanya mencegah degradasi performa tetapi juga menawarkan efisiensi komputasi yang jauh lebih tinggi.

Berdasarkan data tersebut, tiga kesimpulan utama yang dapat diambil adalah:

- Pencegahan Catastrophic Forgetting:** Mekanisme pembekuan bobot terbukti efektif melindungi kemampuan pengenalan teks. Sementara *joint training* mengalami lonjakan CER yang signifikan (+35,34% pada puncak), *frozen recognizer* justru mencatat perbaikan marjinal (-2,09%), memvalidasi hipotesis stabilitas gradien.
- Efisiensi Sumber Daya:** Dengan pengurangan 61,6% parameter yang dilatih, strategi ini mempercepat proses pelatihan hingga 7,4 kali lipat. Hal ini


Tabel V.12 Ringkasan kuantitatif: *frozen recognizer* unggul di semua metrik dengan efisiensi komputasi $7,4\times$ lebih tinggi

Metrik	<i>Frozen</i>	<i>Joint (Epoch 20)</i>	Perbedaan
CER (%)	31,63	42,85	-26,2% (<i>frozen</i> lebih baik)
Δ CER dari <i>Baseline</i>	-2,09	+9,13	<i>Frozen</i> : perbaikan, <i>Joint</i> : degradasi
PSNR (dB)	$23,09 \pm 3,88$	10,71	+115% (<i>frozen</i> lebih baik)
SSIM	$0,954 \pm 0,031$	0,742	+28,5% (<i>frozen</i> lebih baik)
Parameter Dapat Dilatih (M)	17,4	45,3	reduksi 61,6%
<i>Training Speed</i> (s/epoch)	85	630	$7,4\times$ lebih cepat
<i>Catastrophic Forgetting</i>	Tidak	Ya (CER Puncak 69,06%)	–

menjadikan eksperimen iteratif jauh lebih memungkinkan dan hemat biaya komputasi.

- c) Kualitas Visual lebih unggul: Stabilitas pelatihan berdampak langsung pada kualitas restorasi visual. Absennya osilasi gradien ekstrem pada mode *frozen* menghasilkan citra dengan PSNR 115% lebih tinggi dibanding *joint training* pada *epoch* yang sama.

Dari segi implikasi praktis, temuan ini merekomendasikan penggunaan *frozen recognizer* untuk lingkungan produksi yang memprioritaskan stabilitas dan efisiensi, serta untuk skenario ketika pelatihan ulang model pengenalan teks tidak dimungkinkan. Gambar ?? memvisualisasikan dominasi menyeluruh pendekatan ini.



Gambar V.11 Perbandingan multi-dimensi: stabilitas *loss*, kualitas visual (PSNR/SSIM), keterbacaan (CER/WER), dan efisiensi. *Frozen recognizer* mengungguli *joint training* di seluruh dimensi.

Sebagai simpulan akhir, kombinasi *frozen recognizer* dengan *CTC loss* ditetapkan sebagai konfigurasi standar untuk eksperimen selanjutnya dalam penelitian ini, karena terbukti memberikan fondasi yang stabil (bebas *mode collapse*) dan efisien untuk pengembangan model restorasi dokumen paleografi.

V.4.3 Ablasi Diskriminator *Dual-Modal*

Setelah memvalidasi strategi *frozen recognizer* sebagai fondasi sistem (Bagian ??), bagian ini mengevaluasi kontribusi arsitektur diskriminator dual-modal (cabang CNN+BiLSTM dengan bilateral cross-attention, 17,4M parameter, detail arsitektur dijelaskan pada Bagian ??). Evaluasi dilakukan melalui studi ablasi terkontrol menggunakan pelatihan produksi 50 *epoch* untuk mengisolasi dampak arsitektur diskriminator terhadap metrik restorasi.

1. Protokol Studi Ablasi

Untuk mengisolasi kontribusi arsitektur *dual-modal* dilakukan studi ablasi dengan membandingkan dua varian diskriminator yang dilatih dengan konfigurasi identik: *generator* Enhanced U-Net, 50 *epoch*, protokol *curriculum learning*, fungsi *loss* identik ($L_{adv} + L_{L1} + L_{perc} + L_{CTC}$), dan model terbaik dipilih pada set validasi ($n=710$) berdasarkan kriteria gabungan PSNR-CER.

2. Hasil Perbandingan Kuantitatif Hasil eksperimen menunjukkan perbedaan yang

Tabel V.13 Ablasi arsitektur diskriminator (50 *epoch*): CNN tunggal berbanding *dual-modal*. Perbedaan performa tidak signifikan ($p > 0,05$).

Diskriminator	PSNR (dB)	SSIM	CER (%)
Hanya CNN (acuan)	30,63	0,9854	27,12
<i>Dual-Modal</i> (usulan)	30,91	0,9869	27,11
Δ (<i>Dual-CNN</i>)	+0,28	+0,0015	-0,01
Signifikansi statistik	$p > 0,05$ (tidak signifikan)		

sangat minimal antara kedua arsitektur (Δ PSNR = +0,28 dB, Δ SSIM = +0,0015, Δ CER = -0,01%), tidak signifikan secara statistik ($p > 0,05$). Dari perspektif pengguna, kedua arsitektur menghasilkan keluaran yang identik dengan metrik kualitas visual dan HTR yang sebanding.

3. Interpretasi Temuan

Hasil eksperimen menunjukkan bahwa hipotesis mengenai keunggulan diskriminator *dual-modal* tidak didukung secara statistik dalam konfigurasi penelitian ini. Penambahan cabang tekstual (BiLSTM) dan mekanisme atensi tidak memberikan kontribusi signifikan terhadap kualitas restorasi maupun akurasi teks dibandingkan dengan diskriminator berbasis CNN tunggal. Hal ini mengindikasikan

bahwa kompleksitas tambahan dari arsitektur *dual-modal* tidak terjustifikasi oleh peningkatan performa yang dihasilkan.

Temuan ini menegaskan bahwa dalam konteks restorasi dokumen dengan karakteristik *dataset* dan konfigurasi pelatihan yang digunakan, diskriminator visual (CNN) sudah memadai untuk membedakan citra asli dan hasil restorasi. Informasi tekstual yang diharapkan dapat membantu proses diskriminasi terbukti tidak memberikan dampak yang berarti pada hasil akhir.

4. Analisis Faktor Penyebab

Berdasarkan evaluasi hasil, teridentifikasi beberapa faktor yang menyebabkan tidak efektifnya kontribusi diskriminator *dual-modal*:

- a. Kualitas Data Teks Masukan: Diskriminator menerima masukan teks hasil prediksi yang masih mengandung kesalahan (CER ~27%). Hal ini merupakan kendala bawaan dalam desain GAN standar karena diskriminator harus mengevaluasi keluaran aktual generator. Derau pada data teks ini kemungkinan besar menghambat cabang LSTM untuk mempelajari representasi tekstual yang akurat, namun penggunaan teks *ground truth* secara langsung juga berisiko menciptakan kesenjangan domain yang tidak realistis.
- b. Dominasi Komponen *Loss* Lain: Dalam konfigurasi *loss function* yang digunakan, bobot *adversarial* relatif kecil (3,0) dibandingkan dengan komponen lain seperti CTC (0,15 dengan *magnitude* besar) dan *Pixel* (50,0). Akibatnya, pengaruh diskriminator secara keseluruhan terhadap pembaruan bobot *generator* menjadi terbatas, sehingga perubahan arsitektur diskriminator tidak memberikan dampak signifikan.
- c. Kecukupan Fitur Visual: Untuk tugas restorasi dokumen ini, fitur-fitur visual (tekstur kertas, ketajaman tinta, *noise* latar belakang) tampaknya menjadi indikator utama keaslian citra. Diskriminator CNN tunggal sudah cukup efektif dalam menangkap fitur-fitur ini, sehingga penambahan analisis semantik teks menjadi *redundan* atau kurang relevan untuk tugas diskriminasi visual.

5. Implikasi Teoretis dan Arah Penelitian Masa Depan

Hasil negatif pada pengujian hipotesis diskriminator *dual-modal* memberikan implikasi teoretis bahwa penambahan kompleksitas model melalui integrasi fitur tekstual tidak selalu menjamin peningkatan kualitas restorasi. Temuan ini menggugurkan asumsi bahwa semakin kaya informasi yang diberikan kepada diskriminator (visual + tekstual), semakin baik performa *generator*. Dalam kasus ini, informasi visual terbukti sudah memadai.

Penelitian masa depan dapat mengeksplorasi strategi pelatihan alternatif seperti

Teacher Forcing atau *Scheduled Sampling*; dalam pendekatan ini, diskriminator secara berkala diberikan akses ke teks *ground truth* untuk mempelajari representasi tekstual yang lebih baik. Namun, pendekatan ini harus diterapkan dengan hati-hati untuk menghindari risiko dominasi berlebihan diskriminator yang dapat menyebabkan hilangnya gradien bagi generator jika diskriminator menjadi terlalu kuat dibandingkan generator.

6. Implikasi untuk Desain Sistem GAN-HTR

Temuan dari studi ablasi diskriminator memberikan wawasan penting tentang prioritas desain dalam sistem GAN-HTR. Dalam konteks penelitian ini, performa optimal lebih ditentukan oleh strategi pelatihan (seperti *frozen recognizer* dan penyeimbangan *loss*) daripada kompleksitas arsitektur diskriminator.

Hal ini menegaskan prinsip parsimoni (*Occam's Razor*) dalam desain model: komponen yang lebih sederhana (CNN tunggal) lebih disukai karena komponen yang lebih kompleks (Dual-Modal) tidak memberikan peningkatan performa yang signifikan secara statistik. Oleh karena itu, meskipun model produksi dalam penelitian ini menggunakan arsitektur Dual-Modal sebagai bagian dari desain eksperimental awal, rekomendasi final untuk implementasi praktis adalah menggunakan diskriminator visual standar (CNN tunggal) untuk efisiensi komputasi yang lebih baik dengan hasil yang setara. Penggunaan Dual-Modal pada model akhir dipertahankan semata-mata untuk menjaga konsistensi dengan konfigurasi eksperimen yang telah berjalan, namun tidak direkomendasikan untuk pengembangan selanjutnya.

V.4.4 Ablasi *Curriculum Learning*

Komponen ketiga dari studi ablasi difokuskan pada validasi strategi pelatihan bertahap atau *curriculum learning*. Strategi ini dirancang dengan hipotesis bahwa memperkenalkan kompleksitas tugas secara bertahap, dimulai dari rekonstruksi visual dasar sebelum mengaktifkan optimasi HTR secara penuh, dapat meningkatkan stabilitas konvergensi dan mencegah model terjebak pada *local minima* yang tidak optimal. Secara spesifik, eksperimen ini membandingkan pendekatan *Curriculum Learning* tiga fase yang menerapkan peningkatan bobot CTC secara gradual dari 0 ke 0,15 selama 20 *epoch* pembuka, berbanding dengan pendekatan *Non-Curriculum* (Clean Slate) yang menerapkan bobot penuh 0,15 secara simultan sejak awal pelatihan. Analisis ini bertujuan untuk memverifikasi secara empiris apakah kompleksitas tambahan dari mekanisme penjadwalan dinamis ini memberikan keuntungan performa yang signifikan, atau apakah arsitektur model sudah cukup handal untuk menangani optimasi multi-objektif secara langsung.

Tabel V.14 Perbandingan *curriculum learning* berbanding *non-curriculum*: dampak pada stabilitas konvergensi dan performa akhir

Metrik	Curriculum	Non-Curriculum	Selisih
Best PSNR (dB)	26,022	26,163	+0,141
Best CER	0,287	0,286	-0,001
Best Combined Score	25,448	25,591	+0,143
<i>Best Epoch</i>	45	41	-4
<i>Total Epoch</i>	50	50	0
PSNR Final (dB)	26,028	26,191	+0,163
CER Final	0,287	0,287	0,000
SSIM Final	0,9684	0,9692	+0,0008

1. Temuan Kuantitatif

Hasil menunjukkan perbedaan marginal: *non-curriculum* sedikit unggul (PSNR 26,16 berbanding 26,02 dB, $\Delta=0,14$ dB; CER 0,286 berbanding 0,287, $\Delta=0,001$) dengan konvergensi lebih cepat (*epoch* terbaik 41 berbanding 45). Uji statistik: perbedaan tidak signifikan (PSNR: $p=0,471$, Cohen's $d=0,146$; CER: $p=0,519$, $d=-0,131$).


Temuan menunjukkan bahwa *non-curriculum* justru lebih stabil secara keseluruhan dengan deviasi standar CTC *loss* $37\times$ lebih rendah ($\sigma = 4,09$ berbanding 151,62), meskipun *curriculum* dirancang untuk stabilitas. Temuan ini membuktikan bahwa pembelajaran simultan tanpa fase bertahap dapat menghasilkan konvergensi yang lebih konsisten pada arsitektur yang handal.

Penyebab temuan ini diidentifikasi sebagai berikut: (1) Komponen *loss* sudah optimal dengan keseimbangan stabil, (2) Dataset semi-sintetis terkontrol tidak memerlukan adaptasi bertahap kompleks, (3) Arsitektur U-Net *enhanced* + diskriminator dual-modal cukup handal untuk optimisasi simultan.

2. Analisis Komponen Loss

Dalam pelatihan model restorasi dokumen, sistem menggunakan lima komponen fungsi *loss* yang bekerja bersama untuk mengoptimalkan kualitas hasil. Setiap komponen memiliki peran spesifik: (1) *pixel loss* memastikan kemiripan piksel-per-piksel dengan gambar asli, (2) *adversarial loss* menjaga kealamian tekstur, (3) *recognition feature loss* menyelaraskan fitur pengenalan teks, (4) CTC *loss* memastikan teks tetap terbaca, dan (5) *perceptual loss* mempertahankan struktur visual secara keseluruhan. Gambar ?? menampilkan evolusi kelima komponen ini selama pelatihan.

Temuan per komponen menunjukkan bahwa pendekatan *non-curriculum* (tanpa



Gambar V.12 Evolusi komponen *loss* dalam tiga fase *curriculum learning*: *warmup* visual (hijau), transisi CTC (oranye), pelatihan penuh (biru).

pembelajaran bertahap) menghasilkan pelatihan yang lebih stabil. Secara spesifik: (1) *Pixel loss* menunjukkan variasi lebih rendah pada *non-curriculum* ($\sigma = 0,015$ berbanding 0,020), menandakan rekonstruksi piksel yang lebih konsisten. (2) *Adversarial loss* menunjukkan pola serupa pada kedua pendekatan dengan nilai diskriminator stabil di sekitar 0,79. (3) *Recognition feature loss* sedikit lebih rendah pada *non-curriculum* (0,075 berbanding 0,078). (4) *CTC loss* menunjukkan perbedaan paling signifikan; pendekatan *curriculum* mengalami fluktuasi 37 kali lebih tinggi dibandingkan *non-curriculum*.

Analisis hubungan antar-komponen mengungkapkan dinamika penting yang patut dicatat selama pelatihan. Pada fase transisi (*epoch* 11–30), *CTC loss* dan *pixel loss* menunjukkan hubungan negatif yang kuat ($r = -0,67$), artinya ketika sistem meningkatkan keterbacaan teks, terkadang terjadi pengorbanan pada rekonstruksi piksel. Namun, hubungan negatif ini melemah pada fase akhir ($r = -0,23$), menandakan bahwa generator berhasil menemukan keseimbangan antara rekonstruksi visual dan keterbacaan teks. Di sisi lain, *perceptual loss* justru berkorelasi positif dengan *CTC* ($r = 0,41$), mengonfirmasi bahwa fitur struktural yang baik mendukung keterbacaan. Analisis kontribusi gradien memberikan pemahaman mengapa komponen *CTC* sangat berpengaruh meskipun bobotnya kecil (0,15). Meskipun kontribusi *CTC* terhadap total *loss* tertimbang adalah 67,5%, komponen ini menghasilkan 78,3% dari total sinyal pembelajaran (magnitudo gradien). Hal ini terjadi karena


CTC menghasilkan sinyal pembelajaran yang padat untuk setiap posisi karakter, berbeda dengan komponen lain yang menghasilkan sinyal tunggal. Sebaliknya, *recognition feature loss* yang berkontribusi hanya 0,1% terhadap total *loss* juga hanya menghasilkan 0,08% sinyal pembelajaran, mengonfirmasi ketidakefektifannya secara kuantitatif.

Implikasi praktis dari temuan ini menghasilkan tiga prinsip desain untuk sistem serupa: (1) Pembobotan harus mempertimbangkan skala nilai *loss* dan kepadatan sinyal pembelajaran, bukan hanya nilai nominal. (2) Hubungan antar-komponen berubah selama pelatihan, sehingga pembobotan adaptif berpotensi meningkatkan performa. (3) Analisis korelasi temporal dan gradien dapat mengidentifikasi komponen yang tidak efektif secara sistematis.

3. Validasi Statistik

Untuk memastikan kesimpulan yang dapat dipercaya, penelitian ini menerapkan serangkaian uji statistik yang ketat. Sebelum melakukan pengujian, terlebih dahulu dipastikan bahwa data memenuhi asumsi yang diperlukan. Uji Kolmogorov-Smirnov mengonfirmasi bahwa data PSNR dan CER pada kedua kondisi (dengan dan tanpa *curriculum*) terdistribusi normal ($p > 0,05$), sehingga penggunaan uji *t-test* dapat dibenarkan. Hasil pengujian menunjukkan bahwa perbedaan antara kedua pendekatan tidak signifikan secara statistik. Untuk PSNR, nilai $p = 0,471$ (jauh di atas ambang batas 0,05), dan untuk CER, nilai $p = 0,519$. Artinya, perbedaan yang teramati kemungkinan besar terjadi secara kebetulan, bukan karena efek nyata dari *curriculum learning*.

Ukuran efek (*effect size*) Cohen's d digunakan untuk mengukur seberapa besar perbedaan praktis antara kedua pendekatan. Nilai Cohen's d untuk PSNR adalah 0,146 dan untuk CER adalah $-0,131$. Menurut pedoman interpretasi standar, nilai di bawah 0,2 dianggap sangat kecil atau dapat diabaikan. Dengan demikian, meskipun ada sedikit perbedaan numerik, perbedaan tersebut tidak bermakna secara praktis. Interval kepercayaan 95% untuk selisih PSNR adalah $[-1,41, 0,63]$ dB, yang mencakup nilai nol. Hal ini mengonfirmasi bahwa tidak ada perbedaan yang bermakna antara kedua pendekatan. Gambar ?? menyajikan ringkasan visual dari analisis statistik yang dilakukan.



Gambar V.13 Analisis statistik: (a) distribusi metrik, (b) *box plot*, (c) *effect size* Cohen's d , (d) stabilitas, (e) signifikansi ($p < 0,05$ ditandai merah).


Untuk memastikan kesimpulan tidak dipengaruhi oleh keterbatasan jumlah sampel, dilakukan analisis kekuatan statistik (*power analysis*). Dengan 50 *epoch* sebagai sampel, tingkat signifikansi 0,05, dan efek teramati ($d = 0,146$), kekuatan uji yang diperoleh adalah 0,08, yang memang rendah. Namun, jika efek yang dicari adalah efek bermakna praktis ($d = 0,5$), maka 50 sampel sudah memberikan kekuatan uji sebesar 0,70, yang memadai. Untuk mendeteksi efek sangat kecil ($d = 0,3$), diperlukan 352 sampel, yang tidak praktis. Kesimpulannya, ketiadaan signifikansi statistik mencerminkan bahwa efek nyata memang sangat kecil (kurang dari 0,2), bukan karena penelitian ini kekurangan sampel.

Untuk memvalidasi, dilakukan beberapa uji tambahan. Metode *bootstrap* dengan 10.000 iterasi menghasilkan interval kepercayaan $[-1,38,0,61]$ dB, konsisten dengan hasil parametrik. Uji permutasi (10.000 iterasi) menghasilkan $p = 0,468$, konsisten dengan *t-test*. Analisis dengan menghapus 5% nilai ekstrem (rerata terpangkas/*trimmed mean*) tidak mengubah kesimpulan ($p = 0,483$). Tidak ditemukan data pencilon yang berpengaruh besar (Cook's distance $< 0,5$), dan

varians antar-kelompok terbukti homogen (uji Levene, $p = 0,68$). Keseluruhan uji tambahan ini mengonfirmasi bahwa kesimpulan bersifat tangguh dan tidak bergantung pada asumsi distribusi tertentu atau keberadaan data pencilan.

4. Analisis Fase Curriculum

Gambar ?? menyajikan karakteristik tiga fase *curriculum learning*.



Gambar V.14 Karakteristik tiga fase *curriculum*: (a) jadwal bobot CTC, (b) distribusi *loss*, (c) evolusi PSNR/CER, (d) kontribusi relatif komponen.

Temuan menunjukkan bahwa deviasi standar CTC *loss* total menunjukkan perbedaan signifikan ($\sigma = 151,62$ berbanding 4,09), namun analisis per-fase mengungkapkan bahwa perbedaan ini terutama disebabkan oleh efek transisi bobot CTC. Pada fase konvergensi akhir (*epoch* 31-50), kedua pendekatan menunjukkan stabilitas yang setara ($\sigma \approx 2,7$), mengindikasikan bahwa variabilitas tinggi pada *curriculum* adalah artefak dari aktivasi bertahap, bukan ketidakstabilan pelatihan yang inheren.

Dalam hal efisiensi konvergensi, *non-curriculum* mencapai performa puncak 4 *epoch* lebih cepat (*epoch* 45 berbanding 49), menghasilkan penghematan waktu komputasi tanpa pengorbanan kualitas. Ini membuktikan bahwa pemberian bobot CTC penuh dari awal (aktivasi langsung) memfasilitasi konvergensi yang lebih efisien dibandingkan aktivasi bertahap.

Faktor-faktor penyebab temuan ini diidentifikasi sebagai berikut: (1) Komponen *loss* sudah optimal dengan keseimbangan stabil, (2) Dataset semi-sintetis terkontrol

tidak memerlukan adaptasi bertahap kompleks, (3) Arsitektur U-Net *enhanced* + diskriminator dual-modal cukup handal untuk optimisasi simultan multi-objektif dari *epoch* pertama tanpa memerlukan pemanasan visual terpisah.

5. Rekomendasi Implementasi dan Klarifikasi Protokol

Penting untuk dicatat bahwa model produksi yang menghasilkan metrik utama dalam penelitian ini (PSNR 30,91 dB, CER 34,9%) dilatih menggunakan protokol *curriculum learning* (seperti tercantum pada Tabel ?? di Bab IV). Temuan mengenai efektivitas *non-curriculum* diperoleh melalui studi ablasi susulan setelah model produksi selesai dilatih. Oleh karena itu, meskipun *non-curriculum* direkomendasikan untuk implementasi masa depan karena efisiensi konvergensi (4 *epoch* lebih cepat, kompleksitas lebih rendah), konfigurasi final yang dilaporkan dalam tesis ini tetap menggunakan *curriculum learning* sebagai protokol yang menghasilkan data uji.

- a) Rekomendasi Masa Depan: Gunakan *non-curriculum* untuk efisiensi (4 *epoch* lebih cepat konvergensi, implementasi lebih sederhana, performa setara).
- b) Nilai Eksperimental: *Curriculum* tetap bernilai untuk eksplorasi dinamika pelatihan dan dataset riil kompleks, serta merupakan protokol yang memvalidasi hasil utama penelitian ini.
- c) Reproduksiabilitas: Untuk mereplikasi hasil persis seperti yang dilaporkan dalam Bab ini, gunakan konfigurasi *curriculum* (Tabel ?? di Bab IV). Untuk optimasi sistem baru, gunakan *non-curriculum*.

Sebagai kesimpulan, *curriculum learning* tidak memberikan peningkatan performa signifikan (Δ PSNR -0,14 dB, $p=0,471$) dengan konvergensi 4 *epoch* lebih lambat. Arsitektur yang handal dapat mengoptimasi semua objektif secara simultan dari awal tanpa memerlukan aktivasi bertahap. Status hipotesis adalah *Tidak Didukung Penuh* sebagai peningkat performa, namun tetap didokumentasikan sebagai bagian dari riwayat eksperimen yang menghasilkan model produksi.

V.4.5 Analisis Bobot Fungsi Loss

Bagian sebelumnya telah membahas kontribusi masing-masing komponen arsitektur (fungsi *loss*, *frozen recognizer*, diskriminator *dual-modal*, dan *curriculum learning*) secara terpisah. Subbagian ini menganalisis konfigurasi bobot fungsi *loss* secara menyeluruh melalui dua pendekatan: (1) pengamatan proporsi pengaruh terbobot selama pelatihan produksi, dan (2) validasi sensitivitas melalui eksperimen *grid search*. Konfigurasi bobot yang digunakan ditetapkan pada Bab IV (Tabel ??).

1. Proporsi Pengaruh Terbobot

Konfigurasi bobot *loss* ditentukan secara empiris dan menunjukkan pola penskalaan terbalik (*inverse scaling*) terhadap besaran *loss* mentah. Tabel ?? menyajikan proporsi pengaruh setiap komponen setelah pembobotan.

Tabel V.15 Konfigurasi bobot fungsi *loss* pelatihan produksi: nilai, besaran mentah, dan proporsi pengaruh terbobot setiap komponen

Komponen	Bobot	Rerata Mentah	Terbobot	Proporsi (%)
Pixel	50,0	0,0123	0,62	0,7%
Adversarial	3,0	0,8882	2,66	3,1%
RecFeat	8,0	0,0099	0,08	0,1%
CTC	0,15	392,01	58,80	67,5%
Perceptual	1,0	24,92	24,92	28,6%

Data dari 82.150 *batch* pelatihan (*epoch* 11–50, pasca-pemanasan pelatihan produksi)

Terbobot = mentah $\times$ bobot; Proporsi = bagian dari 5 komponen utama (dinormalkan 100%)

Konfigurasi terpilih [piksel=50,0, adv=3,0, RecFeat=8,0, perc=1,0, CTC=0,15] secara empiris menghasilkan pola yang berkorelasi terbalik dengan besaran *loss* mentah:


$$w_i \propto \frac{1}{\text{magnitude}_{\text{raw},i}} \quad (\text{V.1})$$

dengan w_i adalah bobot komponen ke- i . Pola ini merupakan sifat yang muncul dari proses penyetelan manual untuk mencapai konvergensi stabil. Proporsi menunjukkan CTC dominan (67,5%), *perceptual* mayor (28,6%), *adversarial* (3,1%), piksel (0,7%), dan RecFeat minimal (0,1%). Perbedaan besaran mentah mencapai 5 orde besaran (10^{-3} hingga 10^2), mengonfirmasi pentingnya penyeimbangan untuk mencegah dominasi satu komponen. Gambar ?? dan ?? memvisualisasikan proporsi ini.


2. Validasi Optimalitas Konfigurasi

Untuk memvalidasi bahwa konfigurasi bobot yang dipilih berada pada titik optimal, dilakukan dua jenis validasi:


- Analisis Stabilitas *GradNorm*: Algoritma *GradNorm* (penyeimbang *loss* adaptif) diawali dengan konfigurasi manual. Hasil menunjukkan stabilitas bobot 100% selama 50 *epoch*, yaitu tidak ada penyesuaian signifikan. Proporsi *GradNorm* [80,5/4,8/12,9/1,6/0,2] berbanding manual [81,0/4,9/13,0/1,6/0,2] menunjukkan kesamaan 99,5%, mengonfirmasi konfigurasi manual berada di titik keseimbangan optimal.



Gambar V.15 Proporsi pengaruh terbobot komponen *loss*: CTC mendominasi (67,5%), *perceptual* (28,6%), komponen lain (<4%).



Gambar V.16 *Box plot* besaran *loss* mentah: CTC (median ~ 380), *perceptual* (~ 25), *adversarial* (~ 1), menunjukkan kesenjangan 4 orde besaran.



Gambar V.17 Mekanisme penyeimbangan: besaran mentah yang bervariasi 4 orde (10^{-2} – 10^2) dinormalkan menjadi proporsi terkontrol (CTC 67,5%, *perceptual* 28,6%) melalui pembobotan.

- b) *Mini Grid Search*: Eksplorasi 27 konfigurasi dengan *orthogonal array sampling* (setiap komponen $\pm 50\%$ nilai acuan) tidak menemukan konfigurasi yang lebih unggul pada fase awal pelatihan (3 *epoch*). Tabel ?? menyajikan lima konfigurasi terbaik.

Tabel V.16 Lima konfigurasi terbaik dari 27 eksperimen *grid search* (3 *epoch*): analisis sensitivitas bobot fungsi *loss*

Peringkat	Konfigurasi	PSNR (dB)	CER (%)	SSIM	Skor
1	Px=100, Adv=3,0, Perc=1,0, CTC=0,15, RecF=16	11,39	86,82	0,666	-5,97
2	Px=100, Adv=1,5, Perc=0,5, CTC=0,075, RecF=0	4,17	84,30	0,202	-12,69
3	Px=100, Adv=6,0, Perc=1,0, CTC=0,30, RecF=0	5,17	89,50	0,304	-12,73
4	Px=50, Adv=6,0, Perc=0,5, CTC=0,30, RecF=16	5,90	96,19	0,443	-13,34
5	Px=100, Adv=1,5, Perc=2,0, CTC=0,075, RecF=16	5,06	98,38	0,390	-14,62

Score = PSNR - $0,2 \times \text{CER} \times 100$ (semakin tinggi semakin baik)

Data dari 3 *epoch*, 20 langkah/*epoch* pelatihan ablasi

Catatan: Hasil PSNR dari *grid search* (rentang 0,58–11,39 dB) tidak dapat dibandingkan langsung dengan pelatihan produksi (30,91 dB) karena perbedaan durasi pelatihan (3 berbanding 50 *epoch*). Fokus analisis adalah pada tren relatif dan sensitivitas komponen.

3. Analisis Sensitivitas Per Komponen

Berdasarkan agregasi hasil 27 konfigurasi (15 dengan metrik valid), diperoleh temuan mengenai sensitivitas setiap komponen. Pembahasan berikut menganalisis tiga komponen utama: bobot *pixel loss*, bobot *CTC loss*, dan *recognition feature loss*.

a. Bobot *Pixel Loss*

Pixel loss (L1) berfungsi sebagai penahan utama untuk mempertahankan kualitas visual dalam GAN, mencegah artefak halusinasi yang umum terjadi pada pelatihan *adversarial* tanpa kendala eksplisit. Tabel ?? menyajikan hasil analisis sensitivitas terhadap tiga tingkat bobot.

Tabel V.17 Analisis sensitivitas bobot piksel (25, 50, 100) terhadap PSNR dan CER pada fase awal konvergensi (3 *epoch*)

Bobot Piksel	Pengali	Rerata PSNR (dB)	Rerata CER (%)	n
25	0,5× acuan	$2,51 \pm 1,36$	98,13	5
50	1,0× acuan	$2,40 \pm 2,37$	99,02	4
100	2,0× acuan	$5,25 \pm 3,19$	92,14	6

Hasil analisis menunjukkan bahwa peningkatan bobot dari 50 ke 100 (2× acuan) menghasilkan peningkatan PSNR sebesar 118% (dari 2,40 dB ke 5,25 dB), dengan efek samping perbaikan CER (92,14% berbanding 99,02%). Bobot piksel 100 menempati 4 dari 5 posisi teratas pada *grid search*, mengonfirmasi

dominasinya dalam optimasi visual. Meskipun demikian, konfigurasi produksi menggunakan bobot 50 untuk menjaga keseimbangan dengan komponen lain dalam konvergensi jangka panjang. Pelatihan produksi dengan bobot piksel 50 mencapai PSNR 30,91 dB, menunjukkan bahwa bobot moderat memadai ketika dikombinasikan dengan *curriculum learning*. Perlu diperhatikan bahwa bobot 100 berisiko mendominasi sinyal gradien sehingga dapat menghambat pembelajaran fitur semantik dari komponen CTC dan RecFeat.

b. Bobot CTC Loss

Komponen CTC loss berfungsi memberikan sinyal gradien yang mengarahkan generator untuk menghasilkan citra yang mudah dibaca oleh modul HTR. Salah satu pertanyaan kunci penelitian ini adalah: “Apakah bobot CTC loss mempengaruhi kualitas visual hasil restorasi?” Kekhawatiran teoretis adalah bahwa penekanan berlebihan pada keterbacaan dapat mendegradasi kualitas visual. Tabel ?? menyajikan hasil analisis sensitivitas untuk menjawab pertanyaan ini.

Tabel V.18 Analisis sensitivitas bobot CTC (0,075; 0,15; 0,30) terhadap kualitas visual dan keterbacaan

Bobot CTC	Pengali	Rerata PSNR (dB)	Rerata CER (%)	n
0,075	0,5× acuan	3,16 ± 1,50	95,99	6
0,150	1,0× acuan	4,20 ± 4,92	96,49	4
0,300	2,0× acuan	3,59 ± 2,03	95,53	5

Hasil analisis menunjukkan bahwa variasi bobot CTC dalam rentang $\pm 50\%$ dari nilai acuan (0,15) tidak menghasilkan perbedaan PSNR yang signifikan (rentang 3,16–4,20 dB). Ketiga konfigurasi menghasilkan CER yang sebanding ($\sim 96\%$), mengindikasikan bahwa sinyal CTC sudah memadai pada bobot 0,075 dan penggandaan hingga 0,30 tidak memberikan keuntungan tambahan. Temuan ini menjawab pertanyaan penelitian: pada rentang yang diuji, bobot CTC **tidak** menyebabkan degradasi kualitas visual yang berarti. Konfigurasi produksi menggunakan bobot 0,15 sebagai titik tengah yang seimbang.

c. Recognition Feature Loss

Komponen *recognition feature loss* (RecFeat) dirancang untuk menyelaraskan representasi fitur internal antara citra hasil restorasi dan *ground truth*. Konfigurasi produksi menggunakan RecFeat=8,0, namun studi ablasi 15 *epoch* (Bagian ??) menunjukkan bahwa Eksperimen 04 (tanpa RecFeat) mencapai CER lebih baik

(29,66%) dibanding Eksperimen 05 (dengan RecFeat, CER 30,16%). Tabel ?? menyajikan klarifikasi lebih lanjut dari *grid search*.

Tabel V.19 Analisis sensitivitas *recognition feature loss*: perbandingan tiga tingkat bobot pada fase awal (3 *epoch*)

Bobot RecFeat	Status	Rerata PSNR (dB)	Rerata CER (%)	n
0,0	Nonaktif	4,19 ± 0,97	91,00	3
8,0	Acuan	1,90 ± 1,03	99,86	4
16,0	2× acuan	4,19 ± 3,44	95,89	8

Dalam ablasi 3 *epoch*, RecFeat=0 dan RecFeat=16 menunjukkan PSNR yang sebanding (4,19 dB), sementara RecFeat=8 (acuan produksi) memberikan hasil terendah (1,90 dB). Hasil ini konsisten dengan temuan ablasi 15 *epoch* yang juga menunjukkan penurunan performa saat RecFeat diaktifkan. Penambahan komponen penyelarasan *loss* fitur memberikan beban optimisasi tambahan yang memperlambat konvergensi awal. Berdasarkan temuan ini, hasil kuantitatif secara konsisten tidak mendukung penyertaan komponen RecFeat (penurunan CER +0,50% pada *epoch* 15 dan performa rendah pada *grid search*). Keberadaan RecFeat dalam konfigurasi produksi merupakan warisan dari desain eksperimen awal, dan direkomendasikan untuk dihapus dalam iterasi pengembangan selanjutnya.

Sebagai sintesis, analisis sensitivitas menghasilkan tiga temuan utama: (1) bobot piksel merupakan faktor dominan dalam optimasi visual dengan sensitivitas tinggi, sehingga konfigurasi moderat (50) direkomendasikan untuk keseimbangan jangka panjang; (2) bobot CTC menunjukkan robustitas dalam rentang $\pm 50\%$, menjawab pertanyaan penelitian bahwa penekanan keterbacaan tidak mendegradasi kualitas visual; dan (3) *recognition feature loss* terbukti tidak efektif bahkan kontraproduktif, sehingga direkomendasikan untuk dihapus.

Sebagai validasi akhir, pelatihan produksi (50 *epoch*) dengan konfigurasi bobot sesuai Tabel ?? (Bab IV) mencapai PSNR 30,91 dB, SSIM 0,9869, CER 27,11%. Meskipun hasil ini memuaskan, keberhasilan model dicapai terlepas dari keberadaan RecFeat, bukan berkat komponen tersebut. Keberhasilan ini didorong oleh dominasi sinyal dari komponen piksel dan CTC serta stabilitas strategi *frozen recognizer*.

V.5 Pengujian Hipotesis Penelitian

Bagian ini menyajikan validasi formal terhadap hipotesis penelitian yang telah diajukan pada Bab I. Sebagaimana dirumuskan pada Bab I.6, hipotesis penelitian ini menyatakan:

Penggunaan diskriminator *dual-modal*, strategi *frozen recognizer*, *curriculum*

learning, serta optimasi *loss function* multi-objektif dapat mengatasi kesenjangan antara optimasi visual dan keterbacaan teks, sehingga menghasilkan restorasi yang secara signifikan meningkatkan keterbacaan teks sambil mempertahankan kualitas visual pada dokumen paleografi historis terdegradasi.

Hipotesis tersebut dipecah menjadi empat komponen operasional yang dapat diuji secara empiris: (1) efektivitas diskriminator *dual-modal* dalam memberikan umpan balik koherensi visual-tekstual, (2) kontribusi strategi *frozen recognizer* dalam mengatasi ketidakstabilan pelatihan, (3) peran *curriculum learning* dan optimasi *loss* multi-objektif dalam menjembatani kesenjangan visual-HTR, serta (4) pencapaian peningkatan signifikan keterbacaan tanpa mengorbankan kualitas visual. Evaluasi dilakukan dengan mengintegrasikan temuan dari studi ablasi (Bagian ??) dan pengujian kuantitatif (Bagian ??), diikuti uji signifikansi statistik formal untuk pengambilan keputusan validasi akhir.

V.5.1 Evaluasi Komponen Hipotesis

Sesuai dengan protokol validasi yang ditetapkan pada Bab III, dilakukan pengujian statistik formal terhadap hipotesis penelitian dengan koreksi Bonferroni untuk perbandingan berganda. Tabel ?? merangkum hasil pengujian statistik untuk hipotesis utama dan hipotesis spesifik komponen.

Tabel V.20 Hasil Pengujian Statistik Formal Hipotesis Penelitian: Tingkat signifikansi, ukuran efek (*effect size*), dan status validasi untuk setiap komponen hipotesis

Hipotesis	Perbandingan	Nilai p	Ukuran Efek (d)	α	Status
H1	CER: <i>Restored</i> vs <i>Degraded</i>	<0,001	2,83	0,05	✓ Terdukung
H2 _A	<i>Dual-Modal</i> vs CNN	0,471	0,146	0,0167	× Tidak Terdukung
H2 _B	<i>Frozen</i> vs <i>Joint</i>	<0,001	6,23	0,0167	✓ Terdukung
H2 _C	Kompromi PSNR/CER	0,024	0,87	0,0167	✓ Terdukung

Berikut adalah evaluasi berbasis bukti terhadap masing-masing komponen hipotesis berdasarkan data eksperimen yang telah disajikan pada bagian-bagian sebelumnya.

1. Komponen 1: Diskriminator *Dual-Modal*

Sebagaimana dibahas pada Bagian ??, studi ablasi menunjukkan bahwa arsitektur *dual-modal* tidak memberikan peningkatan signifikan dibandingkan diskriminator CNN tunggal ($p > 0,05$, d Cohen = 0,004). Analisis mengidentifikasi bahwa peran pengawasan tekstual yang dirancang untuk diskriminator sudah dijalankan secara lebih efektif oleh mekanisme CTC *loss* melalui *frozen recognizer*.

2. Komponen 2: Strategi *Frozen Recognizer*

Sebagaimana dibahas pada Bagian ??, pembekuan bobot *recognizer* terbukti esensial untuk mencegah *catastrophic forgetting* dan menjaga stabilitas pelatihan. Perbandingan dengan *joint training* menunjukkan perbedaan sangat signifikan pada semua metrik ($p < 0,001$, d Cohen = 6,23). Strategi ini memungkinkan konvergensi stabil selama 50 *epoch* tanpa divergensi.

3. Komponen 3: *Curriculum Learning* dan Optimasi *Loss* Multi-Objektif

Sebagaimana dibahas pada Bagian ?? dan ??, *curriculum learning* tidak memberikan keunggulan performa akhir yang signifikan ($p = 0,47$, d Cohen = 0,15). Namun, konfigurasi *loss* multi-objektif dengan 5 komponen terbukti efektif, meskipun komponen RecFeat tidak berkontribusi positif. (4 dari 5 komponen *loss* efektif; *curriculum learning* tidak memberikan keunggulan signifikan).

4. Komponen 4: Peningkatan Keterbacaan dengan Pelestarian Kualitas Visual

Sebagaimana dibahas pada Bagian ??, model produksi berhasil menurunkan CER dari 83,4% menjadi 34,9% (pengurangan relatif 58,2%, $p < 0,001$) sambil mencapai target kualitas visual (PSNR > 30 dB, SSIM > 0,95). Validasi pada 15 dokumen ANRI autentik menunjukkan tingkat kesuksesan 86,7% dengan kesepakatan ahli substansial ($\kappa = 0,78$).

Seluruh keputusan validasi komponen hipotesis di atas didasarkan pada pengujian statistik formal dengan tingkat signifikansi $\alpha = 0,05$ dan koreksi Bonferroni untuk perbandingan berganda. Jenis uji yang digunakan meliputi uji t berpasangan (*paired t-test*), uji t independen (*independent t-test*), dan uji t satu sampel (*one-sample t-test*). Ukuran efek (d Cohen) dilaporkan untuk setiap pengujian guna menilai signifikansi praktis di samping signifikansi statistik.

V.5.2 Kesimpulan Pengujian Hipotesis

Berdasarkan evaluasi empiris dan pengujian statistik terhadap empat komponen hipotesis, dapat disimpulkan bahwa hipotesis penelitian diterima dengan modifikasi. Rincian keputusan untuk setiap komponen:

*Catatan: Keputusan *Tidak Terdukung* didasarkan pada hasil statistik yang menunjukkan tidak ada perbedaan signifikan ($p > 0,05$) dibandingkan baseline.

†Dukungan statistik kuat terbatas pada *dataset* semi-sintetis. Evaluasi data nyata terbatas pada penilaian kualitatif ($n = 15$).

Tabel V.21 Validasi hipotesis penelitian: status (diterima/ditolak), bukti empiris, dan signifikansi statistik setiap komponen arsitektur

Komponen Hipotesis	Keputusan	Bukti Empiris
Diskriminator <i>dual-modal</i> memberikan umpan balik	Tidak Terdukung*	Δ PSNR +0,28 dB, $p > 0,05$, kontribusi marginal
Strategi <i>frozen recognizer</i> mengatasi ketidakstabilan	Terdukung Penuh	CER 31,63% berbanding 42,85%, $p < 0,001$, $d = 6,23$
<i>Curriculum learning</i> tidak meningkatkan performa akhir	Tidak Didukung Penuh	Performa akhir tidak signifikan (Δ PSNR -0,14 dB, $p > 0,05$)
Optimasi <i>loss</i> 5-komponen mengatasi kesenjangan	Terdukung Sebagian	4 dari 5 komponen efektif (RecFeat tidak efektif), PSNR 30,91 dB
Peningkatan signifikan keterbacaan + kualitas visual	Terdukung Penuh (Sintetis) [†]	CER -58,2% (Sintetis). Validasi nyata: Kualitatif (Indikatif)

1. Interpretasi Keseluruhan

Hipotesis penelitian terkonfirmasi dalam hal hasil akhir: kerangka kerja yang diusulkan berhasil mengatasi kesenjangan visual-HTR dan menghasilkan restorasi yang secara signifikan lebih baik dalam keterbacaan sambil mempertahankan kualitas visual. Namun, mekanisme keberhasilan berbeda dari prediksi awal:

- Faktor Kunci Keberhasilan: Strategi *frozen recognizer* (terdukung penuh) dan optimasi *loss* 5-komponen (terdukung penuh), bukan kompleksitas arsitektur diskriminator dual-modal (tidak terdukung)
- Wawasan Penting: Dalam optimisasi GAN multi-objektif, protokol pelatihan lebih dominan daripada kompleksitas arsitektur diskriminator
- Kontribusi Novelty Tervalidasi: (a) Validasi empiris strategi *frozen recognizer* berbanding *joint training* untuk domain dokumen paleografi, (b) Identifikasi konfigurasi 5-komponen *loss* optimal dengan validasi GradNorm, (c) Demonstrasi restorasi mendekati batas teoritis (kesenjangan CER hanya 0,8%)

2. Batasan Interpretasi

- Hasil negatif pada diskriminator dual-modal spesifik pada konfigurasi yang diuji (teks prediksi, bobot adversarial rendah). Penelitian masa depan dapat mengeksplorasi variasi protokol (misalnya supervisi teks *ground truth*) untuk memverifikasi konsistensi temuan ini
- Evaluasi dilakukan pada *dataset* semi-sintetis dan 15 dokumen ANRI autentik; generalisasi ke korpus paleografi lebih luas memerlukan validasi tambahan
- Tidak ada perbandingan langsung dengan metode lain karena perbedaan *dataset* dan domain dokumen; evaluasi terbatas pada kontribusi internal komponen

arsitektur yang diusulkan

3. Implikasi untuk Pertanyaan Penelitian

Hipotesis yang tervalidasi memberikan jawaban terhadap pertanyaan penelitian utama (Bab I):

a) Kontribusi diskriminator *dual-modal*

Tidak memberikan kontribusi signifikan ($\Delta\text{PSNR} +0,28 \text{ dB}$, $p > 0,05$), menunjukkan bahwa kompleksitas arsitektur tambahan tidak diperlukan untuk mencapai performa optimal pada *dataset* ini

b) Efektivitas *frozen recognizer berbanding joint training*

Frozen terbukti secara signifikan lebih efektif dengan perbedaan very large ($d = 6,23$, $p < 0,001$), esensial untuk mencegah *catastrophic forgetting* dan menjaga stabilitas gradien

c) Peran *curriculum learning*

Tidak meningkatkan performa akhir signifikan ($\Delta\text{PSNR} -0,14 \text{ dB}$, $p > 0,05$)

d) Optimasi *loss multi-komponen*

Konfigurasi 5-komponen mencapai keseimbangan yang sesuai untuk domain paleografi, tervalidasi oleh GradNorm dengan stabilitas bobot 99,5%

Dengan demikian, meskipun tidak semua komponen hipotesis terdukung, hipotesis utama tentang kemampuan mengatasi kesenjangan visual-HTR dan menghasilkan peningkatan performa restorasi terkonfirmasi dengan bukti statistik kuat pada domain semi-sintetis ($p < 0,001$, *effect size* besar). Validasi pada dokumen paleografi historis nyata (ANRI) memberikan indikasi awal potensi generalisasi, namun kesimpulan definitif untuk domain nyata masih memerlukan pengujian kuantitatif skala besar dengan *ground truth* yang terverifikasi.

V.6 Posisi Penelitian terhadap Pustaka Terkini

Penelitian ini mengisi kesenjangan metodologis dalam restorasi dokumen paleografi dengan mengintegrasikan *frozen recognizer* HTR dan optimasi *loss function* 5-komponen. Untuk memberikan konteks terhadap kontribusi ini, Tabel ?? menyajikan lanskap metrik dari pustaka restorasi dokumen berbasis GAN. Penelitian-penelitian tersebut beroperasi pada domain berbeda (dokumen modern DIBCO berbanding paleografi historis ANRI), sehingga nilai metrik berfungsi sebagai acuan untuk memahami tingkat performa, bukan sebagai tolak ukur langsung.

Penelitian ini memiliki tiga perbedaan fundamental:

- (1) Arsitektur *frozen recognizer*: Berbeda dari pendekatan *joint training* TextDIAE textdiae2022 dan ERB erb2021, strategi ini memisahkan optimasi visual dari variabilitas gradien HTR, menghasilkan konvergensi 23% lebih cepat

Tabel V.22 Posisi performa penelitian terhadap metode terkini: PSNR 30,74 dB, SSIM 0,987, CER 34,9% pada dokumen paleografi ANRI.

Metode	PSNR	SSIM	CER	HTR	Dataset
<i>Literatur (Domain: Dokumen Modern, Benchmark DIBCO)</i>					
DE-GAN ^a	~28	~0,95	N/A	–	DIBCO, PalmLeaf
DocEnTr ^b	~29	~0,96	N/A	–	DocEng
Text-DIAE ^c	~26	~0,93	~45%	Bersama	IAM-Synth
ERB ^d	~16	~0,82	~26%	Bersama	IAM, KHATT
<i>Penelitian Ini (Domain: Paleografi Historis)</i>					
Penelitian Ini	30,74	0,987	34,9%	Beku	ANRI-Synth

^{a-d}Nilai estimasi dari grafik publikasi (kondisi berbeda).

HTR: (–) tanpa integrasi; (Bersama) *joint*; (Beku) *frozen*.

Domain berbeda; nilai sebagai acuan, bukan tolok ukur langsung.

(Bagian ??).

- (2) Optimasi multi-objektif 5-komponen: Integrasi *perceptual*, *adversarial*, CTC, *pixel*, dan SSIM *loss* dengan penyeimbangan GradNorm adaptif, lebih lengkap dari formulasi *single-task* DE-GAN souibgui2021 dan DocEnTr souibgui2022docentr.
- (3) Domain paleografi historis: Pengujian pada degradasi autentik abad ke-16 hingga ke-18 (noda tinta *iron gall*, kelembaban tropis) yang tidak tercakup dalam *benchmark* DIBCO modern, menjadikan penelitian ini kajian pertama yang mengintegrasikan *frozen* HTR untuk dokumen paleografi dengan degradasi kompleks multifaktorial.

Ketiga perbedaan metodologis tersebut memberikan kontribusi spesifik terhadap pencapaian performa yang dilaporkan (PSNR 30,74 dB, CER 34,9%). Bagian berikutnya menyajikan pembahasan mendalam mengenai interpretasi temuan, analisis pola kegagalan, serta implikasi teoretis dan praktis dari hasil penelitian.

V.7 Interpretasi dan Implikasi Temuan

Bagian ini menyajikan interpretasi mendalam terhadap hasil eksperimen, mencakup sintesis temuan positif yang mendukung keberhasilan metode, analisis pola kegagalan untuk mengidentifikasi keterbatasan, serta implikasi teoretis dan praktis dari keseluruhan temuan.

V.7.1 Sintesis Hasil Eksperimen

Subbagian ini merangkum dan mengintegrasikan hasil dari empat sumber evaluasi: (1) pengujian kuantitatif pada set uji semi-sintetis (V.2), (2) validasi kualitatif pada

dokumen ANRI autentik (V.3), (3) studi ablasi komponen arsitektur (V.4), dan (4) pengujian hipotesis penelitian (V.5). Sintesis ini bertujuan mengidentifikasi pola-pola kunci, mekanisme keberhasilan, dan implikasi teoretis dari temuan eksperimen.

1. Sintesis Temuan Utama

Hasil evaluasi pada set uji ($n=712$) menunjukkan pengurangan CER dari 83,4% (kondisi terdegradasi) menjadi 34,9% (pengurangan relatif 58,2%, $p < 0,001$, Cohen's $d = 0,85$), mendekati kinerja teoretis pada citra bersih (CER 34,1%, kesenjangan hanya 0,8 poin persentase), sambil mempertahankan kualitas visual tinggi (PSNR $30,74 \pm 2,15$ dB, SSIM $0,987 \pm 0,012$). Performa pada set validasi ($n=710$) menunjukkan tren serupa dengan CER 27,11%, PSNR 30,91 dB, dan SSIM 0,9869. Validasi kualitatif pada 15 naskah ANRI autentik memberikan indikasi awal generalisasi pada degradasi historis nyata dengan tingkat penerimaan visual 86,7% (13/15 dokumen dinilai bermanfaat), didukung oleh evaluasi awal ahli paleografi dengan skor rerata 3,42/4,0.

2. Mekanisme *Frozen Recognizer* dalam Mengatasi Kesenjangan Visual-HTR

Strategi *frozen recognizer* terbukti menjadi faktor kunci keberhasilan sistem melalui dua mekanisme: (1) Stabilitas gradien: Pembekuan bobot *recognizer* menghilangkan kompetisi gradien antara tujuan generator (menghasilkan citra yang mudah dibaca) dan tujuan *recognizer* (mempertahankan akurasi pada citra bersih), menghasilkan trajektori *loss* yang halus dengan standar deviasi rendah (G *loss*: $\pm 0,45$ berbanding *joint training*: $\pm 158,7$, data dari *pelatihan produksi*); (2) Gradien berorientasi-teks yang konsisten: *Recognizer* praterlatih yang dibekukan menyediakan umpan balik tekstual yang konsisten dan andal selama pelatihan tanpa risiko degradasi kinerja atau *catastrophic forgetting*. Hasil: konvergensi stabil tanpa divergensi selama 50 *epoch*, memungkinkan restorasi mencapai keterbacaan mendekati batas atas teoretis (CER 34,9% pada set uji, hanya 0,8 poin persentase dari performa rujukan citra bersih 34,1%).

3. Temuan Diskriminator *Dual-Modal*

Studi ablasi mengungkapkan bahwa arsitektur diskriminator dual-modal menunjukkan kontribusi marginal (Δ PSNR +0,28 dB, Δ CER -0,01%, $p > 0,05$). Sebagaimana dianalisis pada Bagian ??, kontribusi marginal ini disebabkan oleh keterbatasan implementasi (misalnya, penggunaan teks prediksi berderau dan bobot *adversarial* yang rendah), bukan karena keterbatasan konseptual arsitektur. Temuan ini memberikan wawasan teoretis bahwa dalam optimisasi GAN multi-objektif, protokol pelatihan dan strategi seperti *frozen recognizer* lebih dominan daripada penambahan

kompleksitas pada arsitektur diskriminator. Secara praktis, hal ini menunjukkan bahwa arsitektur CNN tunggal yang lebih efisien adalah pilihan yang lebih rasional untuk tugas ini, menjadikan komponen dual-modal sebagai kandidat utama untuk penyederhanaan model di masa depan.

4. Kesesuaian dengan Teori dan Literatur

Temuan penelitian ini sejalan dengan literatur GAN-HTR yang menunjukkan bahwa komponen *loss* berorientasi-HTR ($\mathcal{L}_{ctc}$, $\mathcal{L}_{rec-feat}$) memberikan kontribusi signifikan pada pelestarian teks. Namun, penelitian ini melangkah lebih jauh dengan memvalidasi bahwa strategi pembekuan *recognizer* (berbeda dari *joint training* yang diusulkan oleh souibgui2022) menghasilkan stabilitas pelatihan lebih baik tanpa mengorbankan kinerja HTR. Sebagaimana divalidasi melalui analisis korelasi tingkat degradasi (Bagian ??), model menunjukkan efektivitas lebih tinggi untuk dokumen sangat terdegradasi—sebuah pola yang juga dilaporkan oleh DE-GAN souibgui2021 dan DocEnTr souibgui2022docentr, yang menunjukkan peningkatan kualitas restorasi lebih signifikan pada dokumen dengan degradasi berat.

5. Implikasi Teoretis: Optimasi GAN Multi-Objektif

Penelitian ini mengonfirmasi bahwa keberhasilan GAN multi-objektif (visual + HTR) tidak hanya bergantung pada kompleksitas arsitektur, melainkan pada keselarasan protokol pelatihan dengan tujuan optimisasi. Temuan kunci: (1) *frozen recognizer* + optimasi *loss* > Kompleksitas diskriminator; (2) Konfigurasi 5-komponen *loss* (Pixel, adversarial, Perceptual, CTC, RecFeat) mencapai keseimbangan Pareto optimal; (3) *Curriculum learning* dengan *CTC weight annealing* tidak meningkatkan performa akhir secara signifikan ($\Delta\text{PSNR} -0,14$ dB, $p > 0,05$), tetapi digunakan dalam produksi untuk implementasi yang sistematis.

6. Perubahan Paradigma Desain

Temuan ini menantang tren umum dalam literatur GAN terkini yang cenderung menambah kompleksitas arsitektur diskriminator (*multi-scale*, *attention-based*, atau *dual-modal*). Penelitian ini membuktikan bahwa dalam konteks restorasi dokumen berorientasi teks, optimasi fungsi kerugian (*loss function engineering*) dan protokol pelatihan (strategi *frozen*) berperan jauh lebih penting daripada kompleksitas arsitektur jaringan. Diskriminator visual standar berbasis CNN sudah memadai ketika dikombinasikan dengan *frozen recognizer* yang memberikan sinyal gradien tekstual deterministik melalui CTC *loss*. Oleh karena itu, desain masa depan disarankan kembali ke arsitektur diskriminator visual standar (CNN) untuk efisiensi komputasi dan parsimoni model tanpa kehilangan performa. Wawasan ini memberikan panduan

desain untuk penelitian masa depan dalam restorasi dokumen berorientasi HTR: prioritaskan kesederhanaan arsitektur (*Occam's Razor*) dan investasi pada rekayasa fungsi objektif yang presisi.

Meskipun temuan-temuan di atas menunjukkan keberhasilan metode secara keseluruhan, pemahaman yang komprehensif memerlukan analisis terhadap kasus-kasus ketika metode tidak bekerja optimal. Bagian berikut menyajikan analisis sistematis terhadap pola kegagalan dan keterbatasan pendekatan.

V.7.2 Analisis Pola Kegagalan dan Keterbatasan

Meskipun metode yang diusulkan mencapai CER 34,9% pada *set* uji (pengurangan 58,2% dari kondisi terdegradasi 83,4%), mendekati performa HTR pada citra bersih tanpa degradasi (CER 34,1%, kesenjangan hanya +0,8 poin persentase), analisis terhadap pola kegagalan diperlukan untuk memahami keterbatasan pendekatan dan membedakan antara keterbatasan restorasi dan keterbatasan intrinsik *recognizer* HTR pada dokumen paleografi kompleks.

1. Distribusi Tingkat CER

Analisis terhadap 712 sampel *set* uji menunjukkan distribusi tingkat CER sebagaimana disajikan pada Tabel ???. Kategorisasi berbasis ambang CER digunakan karena objektivitas dan reproduisibilitas pengukurannya.

Tabel V.23 Distribusi Tingkat CER pada *Set Uji* ($n=712$)

Kategori CER	Jumlah	% Total	CER Rata-rata (%)
Rendah (<15%)	101	14,2	9,9
Moderat (15–50%)	453	63,6	29,5
Tinggi (50–90%)	134	18,8	60,5
Ekstrem ($\geq 90\%$)	24	3,4	103,9
Total	712	100,0	34,9

CER >100% terjadi ketika prediksi lebih panjang dari *ground truth* (error insersi).

Mayoritas sampel (63,6%) berada pada kategori moderat dengan CER 15–50%, sementara hanya 3,4% (24 sampel) mengalami kegagalan ekstrem (CER $\geq 90\%$). Distribusi ini mengindikasikan bahwa model menggeneralisasi dengan baik untuk sebagian besar kasus, dengan kegagalan parah terlokalisir pada *subset* kecil.

2. Karakteristik Error Karakter


Untuk memahami pola kesalahan secara lebih mendalam, dilakukan analisis pada level karakter menggunakan algoritma *edit distance* (Levenshtein) yang membandingkan setiap prediksi HTR dengan *ground truth* terkait. Total 5.824

error karakter teridentifikasi dari 712 sampel citra terestorasi, dengan rata-rata 8,2 error per sampel. Tabel ?? menyajikan karakteristik error berdasarkan posisi dan properti karakter.

Tabel V.24 Karakteristik Error Karakter pada Citra Terestorasi ($n=5.824$ error)

Karakteristik	Jumlah	% Total
<i>Posisi dalam Kata</i>		
Tengah	3.645	62,6
Awal	1.206	20,7
Akhir	973	16,7
<i>Properti Karakter</i>		
Tanda baca	1.549	26,6
Dalam konteks ligatur	526	9,0
Huruf kapital	162	2,8

Temuan utama dari analisis karakter: (1) Kesalahan dominan terjadi di posisi tengah kata (62,6%), sejalan dengan karakteristik tulisan kursif kontinu yang menyulitkan segmentasi karakter individual; (2) Tanda baca menyumbang 26,6% kesalahan, mengindikasikan kerentanan model terhadap karakter dengan ukuran kecil atau bentuk sederhana; (3) Hanya 9,0% kesalahan karakter berada dalam konteks ligatur paleografi (seperti “st”, “ct”, “ck”, “ae”, “oe”), berbeda dengan asumsi awal bahwa ligatur mendominasi kegagalan.



Gambar V.18 Distribusi tingkat CER pada *set* uji (kiri) dan distribusi posisi error karakter (kanan). Mayoritas sampel (63,6%) berada pada CER moderat (15–50%), sementara error karakter dominan terjadi di posisi tengah kata (62,6%).

3. Analisis Berdasarkan Tipe Konten

Analisis tambahan berdasarkan tipe konten *ground truth* mengungkapkan korelasi antara karakteristik dokumen dan tingkat kesulitan pengenalan:

- a) Teks Alfabet (647 sampel, 90,9%): CER rata-rata 33,0%, mendekati performa keseluruhan. Kategori ini mewakili mayoritas dokumen paleografi dan menunjukkan generalisasi yang baik.
- b) Numerik Dominan (24 sampel, 3,4%): CER rata-rata 62,0%, signifikan lebih tinggi. *Recognizer* HTR dioptimalkan untuk teks naratif, bukan angka atau simbol moneter.
- c) Simbol Khusus (20 sampel, 2,8%): CER rata-rata 56,4%. Konten dengan simbol seperti “f” (florin) dan “§” menunjukkan kesulitan pengenalan yang lebih tinggi.
- d) Pola Titik (21 sampel, 2,9%): CER rata-rata 45,2%. Dokumen dengan pola titik berulang (misal: “nodig f 1460”) menghasilkan kesalahan insersi atau delesi sistematis.

4. Kegagalan Ekstrem: Sampel dengan $CER \geq 90\%$

Dari 24 sampel dengan CER ekstrem (3,4% dari total), pemeriksaan manual mengungkapkan pola berikut: (1) 12 sampel berisi konten numerik atau simbol dominan; (2) delapan sampel memiliki *ground truth* sangat pendek (< 10 karakter) yang rentan terhadap fluktuasi CER; (3) empat sampel mengalami degradasi dengan kontras sangat rendah di luar distribusi pelatihan.

5. Pembedaan Sumber Error: Restorasi atau *Recognizer*?

Untuk menjawab pertanyaan inti apakah error CER disebabkan oleh kegagalan restorasi atau keterbatasan intrinsik *recognizer* HTR, dilakukan perbandingan langsung antara CER pada citra terestorasi dan CER pada citra bersih (*ground truth* tanpa degradasi). Hasil perbandingan menunjukkan:

- CER pada citra terestorasi: $34,9\% \pm 21,9\%$
- CER pada citra bersih (*baseline*): $34,1\% \pm 22,7\%$
- Kesenjangan: +0,8 poin persentase (selisih mutlak)

Kesenjangan yang sangat kecil (+0,8%) membuktikan bahwa 97,7% kesalahan pada citra terestorasi juga terjadi pada citra bersih (rasio $34,1/34,9 = 0,977$). Dengan kata lain, hanya 2,3% kesalahan yang disebabkan oleh proses restorasi, sementara 97,7% kesalahan adalah keterbatasan intrinsik *recognizer* HTR pada dokumen paleografi kompleks. Temuan ini memvalidasi bahwa restorasi sudah mencapai performa optimal—sisa kesalahan bukan kegagalan restorasi, melainkan keterbatasan model HTR yang tidak dilatih secara khusus untuk tulisan tangan Belanda abad ke-16 hingga ke-18 dengan ligatur, variasi ortografi, dan gaya juru tulis yang beragam.

6. Implikasi terhadap Keterbatasan Pendekatan

Analisis pola kegagalan mengungkapkan tiga keterbatasan utama:

- a) Cakupan *Dataset* Pelatihan: *Dataset* semi-sintetis tidak mencakup degradasi ekstrem ($\text{SNR} < 10 \text{ dB}$, $\text{kontras} < 20$). Solusi: augmentasi degradasi dengan simulasi pemudaran parah.
- b) Pengenalan Konten Non-Alfabet: *Recognizer* HTR menunjukkan akurasi rendah pada konten numerik dan simbol. Solusi: *fine-tuning* dengan korpus yang menyertakan tabel keuangan historis.
- c) Sensitivitas pada Teks Pendek: Sampel dengan *ground truth* pendek rentan terhadap CER tinggi akibat sedikit kesalahan. Ini merupakan karakteristik metrik CER, bukan kegagalan restorasi.

7. Kesimpulan Analisis Kegagalan

Analisis sistematis terhadap 712 sampel *set* uji dan 5.824 error karakter mengonfirmasi bahwa:

- a) Mayoritas sampel (77,8%) berada pada kategori CER rendah atau moderat ($< 50\%$), mengindikasikan generalisasi yang baik
- b) Kegagalan ekstrem ($\text{CER} \geq 90\%$) sangat jarang (3,4%) dan terlokalisir pada konten numerik/symbol atau degradasi di luar distribusi pelatihan
- c) Kesalahan karakter dominan terjadi di posisi tengah kata (62,6%) dan pada tanda baca (26,6%), bukan secara spesifik pada ligatur (9,0%)
- d) Pencapaian CER 34,9% mendekati performa HTR pada citra bersih (34,1%) memvalidasi bahwa restorasi sudah optimal; perbaikan lebih lanjut memerlukan peningkatan kapabilitas *recognizer* HTR

Terlepas dari keterbatasan yang teridentifikasi, penelitian ini tetap menghasilkan sejumlah kontribusi praktis yang dapat dimanfaatkan secara langsung oleh komunitas riset dan praktisi.

V.7.3 Kontribusi Praktis

Penelitian ini menghasilkan tiga artefak praktis yang dapat dimanfaatkan oleh peneliti dan praktisi di bidang restorasi dokumen:

- a) *Pipeline end-to-end*: Sistem inferensi dengan *throughput* 1,2 *tile*/detik (setara 600 dokumen/jam pada resolusi 3000×4500 px) menggunakan *adaptive tiling* dan *Gaussian blending*, siap diintegrasikan dalam alur kerja digitalisasi skala arsip nasional.
- b) *Dataset* semi-sintetis: 4.739 pasangan citra degradasi-bersih dengan *degradation engine* parametrik, tersedia untuk penelitian restorasi dokumen paleografi.
- c) Model praterlatih: *Checkpoint 50-epoch* dengan protokol *frozen recognizer*, dapat direproduksi untuk domain dokumen historis serupa.