

BAB V. Hasil dan Pembahasan

V.1 Pendahuluan

Bab ini menyajikan hasil evaluasi kerangka kerja restorasi dokumen berbasis GAN dengan diskriminator dual-modal dan strategi *frozen recognizer* yang dirancang dan diimplementasikan pada bab sebelumnya. Evaluasi dilakukan untuk menjawab pertanyaan penelitian yang dirumuskan pada Bab I, khususnya terkait dengan kemampuan kerangka kerja yang diusulkan dalam mengatasi kesenjangan antara optimasi visual dan keterbacaan teks.

Pembahasan dalam bab ini diorganisasikan dalam empat bagian utama. Pertama, analisis kuantitatif yang menyajikan hasil pengukuran kinerja model menggunakan metrik standar untuk kualitas visual (PSNR dan SSIM) serta metrik keterbacaan teks (CER dan WER). Kedua, analisis kualitatif yang memperkuat temuan kuantitatif melalui visualisasi hasil restorasi untuk memahami karakteristik visual dari keluaran model. Ketiga, studi ablasi yang mengisolasi dan mengukur kontribusi dari setiap komponen yang diusulkan (diskriminator dual-modal, *frozen recognizer*, *curriculum learning*, dan konfigurasi fungsi *loss*). Keempat, pengujian hipotesis statistik untuk memvalidasi signifikansi hasil secara formal.

Organisasi pembahasan ini dirancang untuk memberikan pemahaman menyeluruh mengenai efektivitas kerangka kerja yang diusulkan, mulai dari bukti empiris kuantitatif, validasi visual, hingga identifikasi kontribusi spesifik dari setiap komponen yang diajukan dalam penelitian ini.

V.2 Hasil Kuantitatif pada Set Uji Semi-Sintetis Realistis

Bagian ini menyajikan hasil kuantitatif perbandingan metode yang diusulkan dengan metode klasik pada set uji semi-sintetis realistis.^a Evaluasi difokuskan pada metode baseline klasik (*thresholding* Otsu dan Sauvola adaptif) sebagai representasi standar pemrosesan citra konvensional yang umum digunakan di institusi arsip. Perlu dicatat bahwa perbandingan ini menyoroti perbedaan fundamental antara pendekatan berbasis aturan dengan parameter tetap versus pendekatan berbasis pembelajaran berbasis aturan, khususnya dalam konteks pemrosesan otomatis skala besar di mana penyediaan parameter manual per-citra tidak dimungkinkan.

V.2.1 Performa Model pada Set Uji

Tabel V.1 menyajikan hasil kuantitatif dari evaluasi model pada set uji yang sama ($n=712$). Evaluasi mencakup lima metrik utama: PSNR untuk kualitas visual piksel, SSIM untuk kesamaan struktural, *F-measure* untuk akurasi binarisasi, serta CER dan WER untuk keterbacaan teks.

Tabel V.1 Hasil Kuantitatif pada Set Uji Semi-Sintetis Realistis ($n=712$)

Metode	PSNR (dB) $\uparrow$	SSIM $\uparrow$	<i>F-measure</i> $\uparrow$	CER (%)	WER (%)
Tanpa Perbaikan	7.91 ± 1.01	0.340 ± 0.077	- ^a	$83.4 \pm 18.5 \downarrow$	$98.7 \pm 7.3 \downarrow$
Otsu <i>Thresholding</i>	4.75 ± 2.00	0.261 ± 0.099	0.748 ± 0.085	$85.7 \pm 56.7 \downarrow$	$112.9 \pm 69.5 \downarrow$
Sauvola Adaptif	9.92 ± 1.99	0.437 ± 0.149	0.933 ± 0.030	$109.5 \pm 179.5 \downarrow$	$171.5 \pm 172.2 \downarrow$
Yang Diusulkan	30.74 ± 5.09	0.987 ± 0.014	0.921 ± 0.067	$34.9 \pm 21.8 \downarrow$	$82.4 \pm 26.1 \downarrow$
Batas Atas (<i>GT Bersih</i>)	-	-	-	34.1 ± 22.7	82.1 ± 27.3

^a*F-measure* tidak dapat diterapkan pada citra terdegradasi tanpa binarisasi.


Metode klasik menggunakan implementasi OpenCV standar dengan parameter global tetap ($k = 0.34, R = 128$).

Varians tinggi pada metode klasik mencerminkan sensitivitas terhadap parameter pada dataset heterogen.


WER > 100% disebabkan oleh tingginya *insertion error* akibat derau latar belakang yang terdeteksi sebagai karakter.

Hasil kuantitatif pada Tabel V.1 menunjukkan keunggulan signifikan metode yang diusulkan dalam menangani variabilitas degradasi. Metode usulan mencapai PSNR 30.74 ± 5.09 dB dan CER $34.9 \pm 21.8\%$, mendekati batas atas teoretis citra bersih. Sebaliknya, metode klasik menunjukkan keterbatasan signifikan dalam skenario “satu parameter untuk semua”. Varians yang sangat tinggi pada Sauvola (CER $\sigma=179.5$) dan nilai WER yang melebihi 100% (171.5%) mengindikasikan terjadinya kegagalan katastrofik pada sebagian sampel, di mana derau latar belakang (*foxing*, *bleed-through*) diinterpretasikan sebagai teks tambahan (*insertion errors*) oleh sistem HTR. Hal ini bukan berarti metode klasik tidak valid, melainkan menegaskan bahwa metode berbasis aturan sangat sensitif terhadap penyetelan parameter. Tanpa penyetelan manual per-citra—yang tidak praktis untuk volume arsip besar—metode klasik gagal beradaptasi dengan heterogenitas degradasi dokumen paleografi. Metode pembelajaran mendalam yang diusulkan, di sisi lain, menunjukkan robustitas yang jauh lebih baik ($\sigma=21.8$) karena kemampuannya mempelajari fitur degradasi secara adaptif.

Gambar V.3 memvisualisasikan perbandingan kualitatif pada dua sampel terbaik, mendemonstrasikan tiga keunggulan metode yang diusulkan: (1) Pelestarian goresan—kontinuitas karakter terjaga tanpa fragmentasi yang terlihat pada metode binarisasi (CER rata-rata 13.2% vs Otsu/Sauvola 63.2–64.7%); (2) Pembersihan selektif—eliminasi *foxing* dan noda penuaan tanpa merusak detail teks; (3) Koherensi visual-HTR—SSIM tinggi (0.990) berkorelasi dengan CER rendah, memvalidasi keselarasan optimasi dual-objektif. Metode klasik dengan parameter tetap kurang efektif karena ambang adaptif global sulit mengakomodasi variasi degradasi lokal yang ekstrem pada dokumen paleografi.



Gambar V.1 Distribusi metrik kuantitatif pada set uji ($n=712$) menunjukkan peningkatan signifikan dari kondisi terdegradasi ke hasil restorasi, mendekati batas atas *ground truth* bersih. *Error bars* menunjukkan interval kepercayaan 95%. Panel (a-b): metrik visual; (c-d): metrik keterbacaan teks. Detail numerik tersedia di Tabel V.1.



Gambar V.2 Kuantifikasi peningkatan metrik dari kondisi terdegradasi ke hasil restorasi ($n=712$). Panel (a): peningkatan absolut; (b): peningkatan relatif (%). Visualisasi mengonfirmasi kesenjangan substansial antara kondisi baseline dengan performa restorasi yang mendekati batas teoretis.

V.2.2 Trajektori Pelatihan dan Konvergensi

Analisis trajektori metrik validasi pada Gambar ?? mengungkapkan tiga temuan kunci. Pertama konvergensi bertahap yang efektif, di mana target PSNR tercapai

Degraded	CER: 58.8%	CER: 67.6%
Otsu	CER: 70.6%	CER: 55.9%
Sauvola	CER: 70.6%	CER: 58.8%
Proposed	CER: 8.8%	CER: 17.6%
GT	Sampel 1 heijd welk wij herhaald hebben in 't...	Sampel 2 jongst verleden jar zal mogen vol,...

Gambar V.3 Evaluasi kualitatif empat metode pada sampel optimal set uji. Kolom: (1) *Degraded*, (2) *Otsu*, (3) *Sauvola*, (4) *Proposed*, (5) *Ground Truth* dengan transkripsi. Sampel dipilih berdasarkan performa terbaik metode usulan ($PSNR > 30$ dB, $CER < 15\%$) untuk demonstrasi kemampuan optimal sistem.

pada epoch 38 (30.0 dB) dan SSIM pada epoch 22 (0.95), memvalidasi efektivitas *curriculum learning* tiga fase (*warmup* visual epoch 1–10, peningkatan CTC bertahap epoch 11–30, optimasi penuh epoch 31–50). Kedua, stabilitas tinggi yang ditunjukkan oleh interval kepercayaan 95% yang sempit ($PSNR \pm 0.42$ dB, $SSIM \pm 0.001$ pada epoch 44), mengonfirmasi varians rendah dan prediktabilitas performa untuk aplikasi praktis.

(3) Pemilihan optimal—model terpilih pada epoch 44 berdasarkan kriteria gabungan PSNR-CER dengan protokol early stopping ($patience=25$), mencegah overfitting dan memastikan keseimbangan visual-HTR. Performa pada set uji konsisten dengan tren validasi (Tabel V.1), mengonfirmasi generalisasi efektif tanpa overfitting. Perbedaan CER validasi-uji ($\Delta=7.79\%$) konsisten dengan delta performa rujukan citra bersih ($\Delta=7.53\%$), mengindikasikan bahwa kesenjangan disebabkan kompleksitas intrinsik teks, bukan degradasi performa model.

V.3 Posisi Penelitian terhadap Pustaka Terkini

Penelitian ini mengisi kesenjangan metodologis dalam restorasi dokumen paleografi dengan mengintegrasikan *frozen recognizer* HTR dan optimasi *loss function* 5-komponen. Untuk mengontekstualisasikan kontribusi ini, Tabel V.2 menyajikan lanskap metrik dari pustaka restorasi dokumen berbasis GAN. Penelitian-penelitian tersebut beroperasi pada domain berbeda (dokumen modern DIBCO vs paleografi historis ANRI), sehingga nilai metrik berfungsi sebagai rentang acuan untuk memahami magnitude performa, bukan sebagai tolak ukur langsung.

V.3.1 Lanskap Metrik Penelitian Terdahulu

Tabel V.2 menunjukkan *state-of-the-art* metrik dari empat pendekatan berbasis GAN yang representatif. Penelitian ini mengilustrasikan posisi metodologis yang berbeda, bukan untuk perbandingan numerik langsung.

Tabel V.2 Posisi Metrik Penelitian dalam Landscape Pustaka Terkini

Metode	PSNR	SSIM	CER	HTR	Dataset
Literatur (Domain: Dokumen Modern, Benchmark DIBCO)					
DE-GAN [?] ^a	~28	~0.95	N/A	–	DIBCO, Palm Leaf
DocEnTr [?] ^b	~29	~0.96	N/A	–	DocEng
Text-DIAE [?] ^c	~26	~0.93	~45%	Bersama	IAM-Synth
ERB [?] ^d	~16	~0.82	~26%	Bersama	IAM, KHATT
Untuk Referensi: Penelitian Ini					
Penelitian Ini	30.74	0.987	34.9%	Beku	ANRI Semi-Synth

^{a,b,c,d}Nilai estimasi dari grafik publikasi (kondisi eksperimental berbeda).

HTR: (–) tanpa integrasi; (Bersama) *joint training*; (Beku) *frozen recognizer* (kontribusi penelitian ini).

Domain berbeda (DIBCO modern vs paleografi ANRI)—nilai sebagai rentang acuan, bukan tolak ukur langsung.

Penelitian ini memiliki tiga perbedaan:: (1) Arsitektur *frozen recognizer*—berbeda dari pendekatan *joint training* Text-DIAE [?] dan ERB [?], strategi ini mengisolasi optimasi visual dari variabilitas gradien HTR, menghasilkan konvergensi 23% lebih cepat (Bagian ??); (2) Optimasi *multi-objective* 5-komponen—integrasi perceptual, adversarial, CTC, pixel, dan SSIM loss dengan penyeimbangan GradNorm adaptif, melampaui formulasi single-task DE-GAN [?] dan DocEnTr [?]; (3) Domain paleografi historis—pengujian pada degradasi autentik abad 16–18 (noda tinta besi-empedu, kelembaban tropis) yang tidak tercakup dalam benchmark DIBCO modern, menjadikan ini kajian pertama yang mengintegrasikan frozen HTR untuk dokumen paleografi dengan degradasi kompleks multifaktorial.

Untuk memvalidasi kontribusi spesifik dari ketiga inovasi di atas dan mengidentifika-

si sumber performa yang terukur (PSNR 30.74 dB, CER 34.9%), bagian berikutnya menyajikan studi eliminasi sistematis yang mengisolasi efek setiap komponen arsitektural.

V.4 Studi Ablasi

V.4.1 Desain Eksperimen Eliminasi

Untuk memvalidasi kontribusi setiap komponen arsitektur secara ilmiah, penelitian ini merancang serangkaian eksperimen ablasi terkontrol mengikuti konfigurasi dasar Bab IV dan Tabel V.15.

Prinsip desain ablasi:

a) **Isolasi komponen**

Setiap eksperimen mengisolasi *satu* komponen (contoh: diskriminator dual-modal vs tunggal), sementara komponen lain tetap pada konfigurasi baseline

b) **Konsistensi eksperimental**

Dataset split identik (70%/15%/15%), *fixed seed* (42) untuk *reproducibility*, durasi 15–20 epoch untuk efisiensi komputasi

c) **Evaluasi himpunan validasi**

Menghindari *overfitting* pada himpunan uji yang direservasi untuk evaluasi final

d) **Signifikansi statistik**

Uji-t berpasangan dengan $\alpha = 0.05$, Cohen's d untuk *effect size*

V.4.2 Hasil Ablasi Komponen Loss Function

Tabel V.3 menyajikan hasil dari studi ablasi inkremental lima komponen fungsi *loss*. Hasil ini mengukur kontribusi setiap komponen terhadap kualitas restorasi dokumen pada pelatihan 15 epoch.

Tabel V.3 Studi Eliminasi Inkremental Komponen Fungsi *Loss*: kontribusi setiap komponen terhadap kualitas restorasi. Lima konfigurasi dengan penambahan inkremental: (1) baseline L1, (2) +adversarial, (3) +perseptual VGG-19, (4) +CTC untuk kepekaan HTR, (5) +fitur pengenalan. Evaluasi pada himpunan validasi ($n=710$) setelah 15 epoch.

Eks	Komponen Loss	PSNR (dB)	SSIM	CER (%)	Δ PSNR
1	$\mathcal{L}_{\text{pixel}}$ (L1)	24.59 ± 4.10	0.9614 ± 0.0278	N/A [†]	baseline
2	$\mathcal{L}_{\text{pixel}} + \mathcal{L}_{\text{adv}}$	$24.86^* \pm 4.21$	0.9626 ± 0.0279	N/A [†]	+0.27
3	+ $\mathcal{L}_{\text{perc}}$ (VGG)	24.55 ± 4.69	$0.9630^* \pm 0.0273$	N/A [†]	-0.04
4	+ $\mathcal{L}_{\text{ctc}}$	24.76 ± 4.71	0.9627 ± 0.0294	29.66*	+0.17
5	+ $\mathcal{L}_{\text{rec-feat}}$	24.75 ± 4.60	0.9629 ± 0.0312	30.16	+0.16
[†] CER tidak tersedia karena <i>recognizer</i> tidak diaktifkan					
*Nilai tertinggi untuk metrik ini: PSNR (Eks 2), SSIM (Eks 3), CER (Eks 4)					

Analisis kontribusi per komponen:

Adversarial Loss: Memberikan peningkatan PSNR terbesar (+0.27 dB dari baseline), mencapai 24.86 dB. Komponen ini meningkatkan realisme tekstur melalui mekanisme pelatihan adversarial tanpa mengorbankan stabilitas konvergensi. SSIM juga meningkat (+0.0012), mengindikasikan perbaikan kesamaan struktural.

Perceptual Loss: Mengoptimalkan kesamaan struktural dengan SSIM tinggi (0.9630), namun dengan trade-off penurunan PSNR minor (-0.04 dB menjadi 24.55 dB). Penurunan metrik berbasis piksel ini merupakan konsekuensi yang diharapkan dari optimisasi berbasis fitur (VGG-19), di mana ketajaman visual dan konsistensi perseptual diprioritaskan di atas akurasi piksel absolut.

CTC Loss: Mengaktifkan kapabilitas kepekaan HTR, mencapai CER 29.66% sambil mempertahankan kualitas visual yang kompetitif (PSNR 24.76 dB, hanya -0.10 dB dari maksimum). Dalam konteks ablasi 15 epoch, ini adalah konfigurasi yang sesuai untuk evaluasi cepat, mencapai keseimbangan Pareto antara kualitas visual dan keterbacaan teks tanpa overhead komponen kelima.

Recognition Feature Loss: Menunjukkan kontribusi marginal dalam ablasi singkat, dengan penurunan performa CER sebesar 0.50% (menjadi 30.16%) tanpa adanya peningkatan visual yang signifikan. Temuan ini mengindikasikan bahwa pada fase awal pelatihan, komponen ini bersifat redundan jika dibandingkan dengan sinyal kepekaan teks yang sudah disediakan oleh CTC Loss.

Temuan penting - perbandingan dengan pelatihan produksi:

Studi ablasi 15 epoch mencapai PSNR maksimal 24.86 dB (Eksperimen 02), jauh di bawah model produksi (30.91). Kesenjangan ini (6.05 dB) mengonfirmasi bahwa:

- Pelatihan diperluas (≥ 40 epoch) diperlukan untuk konvergensi penuh dan mencapai batas kinerja absolut
- Studi ablasi 15 epoch efektif untuk mengukur kontribusi relatif setiap komponen, bukan performa absolut
- Kontribusi komponen dapat berbeda antara fase awal (ablasi singkat) dan fase konvergensi penuh.

Rekomendasi konfigurasi berdasarkan konteks pelatihan:

- Ablasi cepat/evaluasi awal (< 20 epoch)*: Eksperimen 04 (4-komponen: Piksel + Adversarial + Perceptual + CTC, CER 29.66%) memberikan hasil terbaik tanpa *overhead* RecFeat yang belum berkontribusi di fase awal
- Pelatihan produksi (> 40 epoch), direkomendasikan: Konfigurasi lengkap 5-komponen (Eksperimen 05) dengan RecFeat=8.0 untuk stabilitas konvergensi jangka panjang, mencapai PSNR 30.91 dB pada epoch 44
- Kualitas visual prioritas tanpa HTR*: Eksperimen 02 (Piksel + Adversarial, PSNR 24.86 dB) untuk aplikasi tampilan visual semata

V.4.3 Kontribusi Frozen Recognizer dengan Integrasi CTC Loss

Eksperimen ablasi membandingkan *frozen recognizer* (Bab IV.1.4) versus *joint training* pada dataset ANRI paleografi (20 epoch, 100 steps/epoch).

1. Stabilitas Gradien

Tabel V.4 menunjukkan perbandingan dinamika *loss* antara kedua pendekatan.


Pendekatan	G Loss	D Loss	R Loss	Rentang G	Status
Frozen (Baseline)	2.84 ± 0.45	1.37 ± 0.31	96.23 ± 12.3	2.15–3.62	Stabil
Joint Training	89.09 ± 7.45	0.037 ± 0.067	30.45 ± 1.59	75.16–103.41	Tidak Stabil

Tabel V.4 Perbandingan Trajektori *Loss* antara *Frozen Recognizer* dan *Joint Training*

Hasil eksperimen menunjukkan perbedaan mencolok dalam stabilitas pelatihan. Pendekatan *frozen recognizer* menunjukkan trajektori *loss* yang halus dengan standar deviasi rendah (G *loss*: ± 0.45), sementara *joint training* mengalami nilai tinggi yang konsisten (G *loss*: 89.09 ± 7.45). Rentang G *loss* pada *joint training* (75.16–103.41) mengindikasikan magnitude *loss* yang signifikan lebih tinggi dibanding *frozen* (2.15–3.62), dengan rasio $26\times$ pada nilai minimum.

Analisis *loss* diskriminator menunjukkan fenomena *mode collapse* parah pada *joint training*, di mana *D loss* mendekati nol (0.037 ± 0.067), mengindikasikan bahwa diskriminator terlalu dominan dan generator tidak dapat belajar secara optimal. Sebaliknya, *frozen recognizer* mempertahankan keseimbangan yang sehat antara generator dan diskriminator (*D loss*: 1.37 ± 0.31).

Stabilitas *frozen recognizer* yang teramati konsisten dengan mekanisme pembekuan bobot yang dirancang untuk mencegah kompetisi gradien (Bab IV.1.4), terbukti berhasil mengeliminasi konflik antara optimasi generator dan preservasi kemampuan *recognizer*.



Gambar V.4 Trajektori *loss* selama 20 epoch. (a) Generator: fluktuasi *frozen* akibat *curriculum learning* vs osilasi ekstrem *joint*. (b) Discriminator: keseimbangan *frozen* vs *mode collapse* pada *joint*. (c) CTC: pembelajaran adaptif *frozen* vs ketidakstabilan *joint*.

Gambar V.4 mengonfirmasi *mode collapse* pada *joint training* ($D \text{ loss} \rightarrow 0$) dan fluktuasi besar *frozen* ($\sigma=136.6$) sebagai efek *curriculum learning*, bukan instabilitas merusak.


2. Performa Keterbacaan Teks

Evaluasi performa keterbacaan teks dilakukan menggunakan metrik CER dan WER pada data validasi. Tabel V.5 menyajikan perbandingan antara kedua pendekatan.


Tabel V.5 Perbandingan Metrik Keterbacaan Teks antara *Frozen Recognizer* dan *Joint Training*

Pendekatan	CER (%)	Δ CER (%)	PSNR (dB)	SSIM
Baseline (Pre-trained)	33.72	-	-	-
Frozen Recognizer	31.63	-2.09	23.09 ± 3.88	0.9538 ± 0.0306
Joint Training (Epoch 5)	69.06	+35.34	$9.36 \pm \text{N/A}$	$0.623 \pm \text{N/A}$
Joint Training (Epoch 20)	42.85	+9.13	$10.71 \pm \text{N/A}$	$0.742 \pm \text{N/A}$
Degradasi Joint (Peak)	-	+35.34	-13.73	-0.33
Degradasi Joint (Final)	-	+11.22	-12.38	-0.21

Joint training menyebabkan *kelupaan katastropik*: CER melonjak dari baseline 33.72% menjadi 69.06% pada epoch 5 (degradasi +35.34%), membuktikan ketidakcocokan untuk domain paleografi kompleks. Meskipun terjadi pemulihan parsial hingga 42.85% pada epoch 20, degradasi final tetap signifikan (+9.13% dari baseline). Sebaliknya, *frozen recognizer* justru meningkatkan performa menjadi 31.63% (perbaikan -2.09%), dengan *output* yang tetap berkorelasi dengan *input*.



Gambar V.5 Trajektori CER: *frozen* stabil dengan perbaikan (31.63%, -2.09% dari baseline) vs *joint* mengalami *catastrophic forgetting* (69.06% epoch 5) dengan pemulihan parsial (42.85% epoch 20, zona merah: degradasi +9.13% dari baseline).



Gambar V.6 Kualitas visual: *frozen* 23.09 ± 3.88 dB vs *joint* 10.71 dB epoch 20 ($\Delta=12.38$ dB, $p < 0.001$), menunjukkan degradasi parah pada *joint training* dengan PSNR awal 9.36 dB (epoch 5).

Gambar V.6 menunjukkan ketidakstabilan *joint training* berdampak pada kualitas visual yang sangat rendah (*derau/distorsi tinggi*). *Frozen* unggul 12.38

dB (23.09 dB vs 10.71 dB, $p < 0.001$), setara dengan peningkatan 115% dalam kualitas visual. Meskipun belum mencapai performa produksi (30.91 dB, 50 epoch), *frozen* menunjukkan keunggulan yang jelas.

Catatan: Fluktuasi *loss* pada *frozen* lebih terkendali (G loss range 2.15–3.62) dibanding *joint* (75.16–103.41). Metrik akhir membuktikan: *frozen* CER 31.63% (perbaikan -2.09%) vs *joint* 42.85% epoch 20 (degradasi +9.13%)—*stabilitas numerik loss berkorelasi dengan stabilitas kemampuan HTR*.

3. Efisiensi Komputasi

Perbandingan efisiensi komputasi dilakukan dengan mengukur waktu pelatihan, penggunaan memori GPU, dan jumlah parameter yang dioptimasi. Tabel V.6 merangkum hasil analisis efisiensi.


Tabel V.6 Perbandingan Efisiensi Komputasi antara *Frozen Recognizer* dan *Joint Training*

Metrik Efisiensi	Frozen	Joint
Waktu per <i>Epoch</i> (detik)	85.0 ± 2.1	630.5 ± 5.3
Durasi Total 20 <i>Epoch</i>	28.3 menit	210.2 menit
Penggunaan Memori GPU (GB)	13.6	~13.6
Parameter <i>Trainable</i> (M)	17.4	~45.3
Parameter <i>Non-Trainable</i> (M)	27.9	—
<i>Steps</i> per <i>Epoch</i>	100	100
Stabilitas <i>Training</i>	Tinggi	Rendah

Data *joint training* dari log eksperimen 20 epoch. *Joint* $7.4\times$ lebih lambat per epoch (630s vs 85s) karena overhead backpropagation melalui recognizer trainable (45.3M parameter vs 17.4M frozen), meskipun melakukan validasi setiap 5 epoch.

Efisiensi komputasi menunjukkan perbedaan dramatis: *frozen recognizer* $7.4\times$ lebih cepat per epoch (85 detik vs 630 detik), dengan total durasi pelatihan 20 epoch hanya 28.3 menit dibanding 210.2 menit untuk *joint training*. Penggunaan memori GPU sebanding (~13.6 GB) karena batch size identik. Perbedaan kecepatan disebabkan oleh overhead backpropagation melalui 45.3M parameter trainable pada *joint* (generator + diskriminator + recognizer) versus 17.4M pada *frozen* (generator + diskriminator saja, recognizer non-trainable 27.9M tidak mengonsumsi gradien). Keunggulan ganda *frozen*: (1) Efisiensi komputasi

$7.4\times$ lebih tinggi, (2) Pelestarian kemampuan HTR yang lebih baik (CER 31.63% dengan perbaikan -2.09% vs *joint* 42.85% dengan degradasi +9.13%).



Gambar V.7 Efisiensi komputasi: (a) *Frozen* $7.4\times$ lebih cepat (85s vs 630s per epoch). (b) Memori identik (13.6 GB). (c) Pengurangan parameter trainable 61.6% (17.4M vs 45.3M) berkontribusi pada kecepatan DAN stabilitas.

V.4.4 Ringkasan Eksperimen: Frozen vs Joint Training

Penelitian ini membandingkan dua strategi integrasi HTR dalam sistem restorasi dokumen paleografi. Pendekatan *frozen recognizer* menunjukkan keunggulan yang signifikan dalam pelestarian kemampuan HTR dengan CER 31,63% dibandingkan 42,85% pada *joint training* ($p < 0,001$, Cohen's $d = 6,23$). Metode ini mencapai keseimbangan optimal antara stabilitas pelatihan dan performa restorasi, dengan PSNR $23,09 \pm 3,88$ dB dan efisiensi komputasi yang sebanding.

Tabel V.7 Ringkasan Kuantitatif Perbandingan Frozen vs Joint Training

Metrik	Frozen	Joint (Epoch 20)	Perbedaan
CER (%)	31.63	42.85	-26.2% (frozen lebih baik)
ΔCER dari Baseline	-2.09	+9.13	Frozen: perbaikan, Joint: degradasi
PSNR (dB)	23.09 ± 3.88	10.71	+115% (frozen lebih baik)
SSIM	0.954 ± 0.031	0.742	+28.5% (frozen lebih baik)
Trainable Params (M)	17.4	45.3	61.6% reduction
Training Speed (s/epoch)	85	630	$7.4\times$ lebih cepat
Catastrophic Forgetting	Tidak	Ya (Peak CER 69.06%)	—


Validasi Teknis.

1. Pencegahan *Catastrophic Forgetting*: Pendekatan *frozen recognizer* mengurangi parameter yang dapat dilatih sebesar 61,6% sambil meningkatkan performa HTR (CER 31.63%, perbaikan -2.09% dari baseline 33.72%). Sebaliknya, *joint training* mengalami *catastrophic forgetting* parah dengan CER puncak

69.06% (epoch 5, +35.34% dari baseline) dan pemulihan parsial ke 42.85% (epoch 20, masih +9.13% dari baseline), divalidasi dengan signifikansi statistik ($p < 0,001$, Cohen's $d = 6.23$).

2. Efisiensi Komputasi: *Frozen recognizer* $7,4 \times$ lebih cepat per epoch (85 detik vs 630 detik) dengan penggunaan memori yang sebanding (13,6 GB). Total durasi pelatihan 20 epoch: 28,3 menit (frozen) vs 210,2 menit (joint), menunjukkan keunggulan signifikan dalam produktivitas penelitian dan biaya komputasi.
3. Pelestarian Kualitas: Pendekatan *frozen recognizer* mempertahankan kualitas visual tinggi (PSNR 23,09 dB, SSIM $0,954 \pm 0,031$) dibandingkan *joint training* yang mengalami penurunan kualitas parah (PSNR 10,71 dB epoch 20, SSIM 0,742)—perbedaan 115% pada PSNR dan 28,5% pada SSIM.

Implikasi Praktis. Pendekatan *frozen recognizer* menunjukkan tiga keunggulan utama: (1) tidak memerlukan pelatihan ulang untuk model *recognizer* yang sudah ada, (2) memberikan hasil yang dapat diprediksi dan konsisten untuk penerapan di lingkungan produksi, (3) kompatibilitas dengan infrastruktur HTR berbasis paleografi yang ada. Metode ini secara khusus direkomendasikan untuk sistem dengan batasan pelatihan ulang atau lingkungan produksi yang membutuhkan stabilitas.



Gambar V.8 Perbandingan multi-dimensi frozen vs joint training. Frozen menunjukkan konsistensi yang unggul di seluruh metrik evaluasi.

Kesimpulan. Penelitian ini memvalidasi bahwa kombinasi strategi *frozen recognizer* dan CTC *loss* merupakan strategi yang optimal untuk domain paleografi yang kompleks. *Frozen recognizer* menunjukkan keunggulan komprehensif: (1) Kualitas HTR yang lebih baik (CER 31,63% dengan perbaikan -2,09% vs joint 42,85% dengan degradasi +9,13%), (2) Kualitas visual lebih tinggi (PSNR 23,09 dB vs 10,71 dB, +115%), (3) Efisiensi komputasi $7,4\times$ lebih cepat. Meskipun performa PSNR (23,09 dB, 20 epoch) belum mencapai tolok ukur model produksi (30,91 dB, 50 epoch), keunggulan yang konsisten di semua metrik membuktikan efektivitas pendekatan ini untuk mencegah *catastrophic forgetting* yang dialami *joint training*.

V.4.5 Kontribusi Diskriminator Dual-Modal

Setelah memvalidasi strategi *frozen recognizer* sebagai fondasi sistem (Bagian V.4.3), bagian ini mengevaluasi kontribusi arsitektur diskriminator dual-modal (cabang CNN+BiLSTM dengan bilateral cross-attention, 17.4M parameter, detail arsitektur dijelaskan pada Bab IV.1.5). Evaluasi dilakukan melalui studi ablasi terkontrol menggunakan pelatihan produksi 50 *epoch* untuk mengisolasi dampak arsitektur diskriminator terhadap metrik restorasi.

1. Protokol Studi Ablasi

Untuk mengisolasi kontribusi arsitektur dual-modal dilakukan studi ablasi dengan membandingkan dua varian diskriminator yang dilatih dengan konfigurasi identik: generator Enhanced U-Net, 50 epoch, protokol curriculum learning, fungsi loss identik ($L_{adv} + L_{L1} + L_{perc} + L_{CTC}$), dan model terbaik (epoch 44) dipilih pada set validasi ($n=710$) berdasarkan kriteria gabungan PSNR-CER.

2. Hasil Perbandingan Kuantitatif

Tabel V.8 Studi Ablasi Arsitektur Diskriminator: Perbandingan CNN Tunggal vs Dual-Modal pada Set Validasi

Diskriminator	PSNR (dB)	SSIM	CER (%)
Hanya CNN (baseline)	30.63	0.9854	27.12
Dual-Modal (usulan)	30.91	0.9869	27.11
Δ (Dual-CNN)	+0.28	+0.0015	-0.01
Signifikansi statistik	$p > 0.05$ (tidak signifikan)		

Hasil eksperimen menunjukkan perbedaan yang sangat minimal antara kedua arsitektur (Δ PSNR = +0.28 dB, Δ SSIM = +0.0015, Δ CER = -0.01%), tidak

signifikan secara statistik ($p > 0.05$). Dari perspektif pengguna, kedua arsitektur menghasilkan keluaran yang identik dengan metrik kualitas visual dan HTR yang sebanding.

3. Interpretasi Temuan

Hasil eksperimen menunjukkan bahwa hipotesis mengenai keunggulan diskriminator dual-modal **tidak terdukung** secara statistik dalam konfigurasi penelitian ini. Penambahan cabang tekstual (BiLSTM) dan mekanisme atensi tidak memberikan kontribusi signifikan terhadap kualitas restorasi maupun akurasi teks dibandingkan dengan diskriminator berbasis CNN tunggal. Hal ini mengindikasikan bahwa kompleksitas tambahan dari arsitektur dual-modal tidak terjustifikasi oleh peningkatan performa yang dihasilkan.

Temuan ini menegaskan bahwa dalam konteks restorasi dokumen dengan karakteristik dataset dan konfigurasi pelatihan yang digunakan, diskriminator visual (CNN) sudah memadai untuk membedakan citra asli dan hasil restorasi. Informasi tekstual yang diharapkan dapat membantu proses diskriminasi ternyata tidak memberikan dampak yang berarti pada hasil akhir.

4. Analisis Faktor Penyebab

Berdasarkan evaluasi hasil, teridentifikasi beberapa faktor yang menyebabkan tidak efektifnya kontribusi diskriminator dual-modal:

- (a) **Kualitas Masukan Tekstual:** Diskriminator menerima masukan teks hasil prediksi yang masih mengandung kesalahan (CER $\sim 27\%$). Hal ini merupakan kendala inherent dalam desain GAN standar di mana diskriminator harus mengevaluasi keluaran aktual generator. Derau pada data teks ini kemungkinan besar menghambat cabang LSTM untuk mempelajari representasi tekstual yang akurat, namun penggunaan teks *ground truth* secara langsung juga berisiko menciptakan kesenjangan domain yang tidak realistis.
- (b) **Dominasi Komponen Loss Lain:** Dalam konfigurasi *loss function* yang digunakan, bobot *adversarial* relatif kecil (3.0) dibandingkan dengan komponen lain seperti CTC (0.15 dengan magnitudo besar) dan Pixel (50.0). Akibatnya, pengaruh diskriminator secara keseluruhan terhadap pembaruan bobot generator menjadi terbatas, sehingga perubahan arsitektur diskriminator tidak memberikan dampak signifikan.
- (c) **Kecukupan Fitur Visual:** Untuk tugas restorasi dokumen ini, fitur-fitur visual (tekstur kertas, ketajaman tinta, noise latar belakang) tampaknya menjadi indikator utama keaslian citra. Diskriminator CNN tunggal sudah

cukup efektif dalam menangkap fitur-fitur ini, sehingga penambahan analisis semantik teks menjadi redundan atau kurang relevan untuk tugas diskriminasi visual.

5. Implikasi Teoretis dan Arah Penelitian Masa Depan

Hasil negatif pada pengujian hipotesis diskriminator dual-modal memberikan implikasi teoretis bahwa penambahan kompleksitas model melalui integrasi fitur tekstual tidak secara otomatis menjamin peningkatan kualitas restorasi. Temuan ini menantang asumsi bahwa semakin kaya informasi yang diberikan kepada diskriminator (visual + tekstual), semakin baik performa generator. Dalam kasus ini, informasi visual ternyata sudah memadai.

Penelitian masa depan dapat mengeksplorasi strategi pelatihan alternatif seperti *Teacher Forcing* atau *Scheduled Sampling*, di mana diskriminator secara berkala diberikan akses ke teks *ground truth* untuk mempelajari representasi tekstual yang lebih baik. Namun, pendekatan ini harus diterapkan dengan hati-hati untuk menghindari risiko *overpowering* diskriminator yang dapat menyebabkan hilangnya gradien bagi generator jika diskriminator menjadi terlalu kuat dibandingkan generator.

6. Implikasi untuk Desain Sistem GAN-HTR

Temuan dari studi ablasi diskriminator memberikan wawasan penting tentang prioritas desain dalam sistem GAN-HTR. Dalam konteks penelitian ini, performa optimal lebih ditentukan oleh strategi pelatihan (seperti *frozen recognizer* dan penyeimbangan *loss*) daripada kompleksitas arsitektur diskriminator.

Hal ini menggarisbawahi prinsip parsimoni (*Occam's Razor*) dalam desain model: komponen yang lebih sederhana (CNN tunggal) lebih disukai karena komponen yang lebih kompleks (Dual-Modal) tidak memberikan peningkatan performa yang signifikan secara statistik. Oleh karena itu, meskipun model produksi dalam penelitian ini menggunakan arsitektur Dual-Modal sebagai bagian dari desain eksperimental awal, rekomendasi final untuk implementasi praktis adalah menggunakan diskriminator visual standar (CNN tunggal) untuk efisiensi komputasi yang lebih baik dengan hasil yang setara. Penggunaan Dual-Modal pada model akhir dipertahankan semata-mata untuk menjaga konsistensi dengan konfigurasi eksperimen yang telah berjalan, namun tidak direkomendasikan untuk pengembangan selanjutnya.

V.4.6 Kontribusi Curriculum Learning

Eksperimen komparatif evaluasi strategi *curriculum learning* tiga fase (penurunan bobot CTC 0→0.15 dalam 20 epoch) versus *non-curriculum* (bobot konstan 0.15 dari awal).

Tabel V.9 Perbandingan Performa Curriculum Learning vs Non-Curriculum Learning

Metrik	Curriculum	Non-Curriculum	Selisih
Best PSNR (dB)	26.022	26.163	+0.141
Best CER	0.287	0.286	-0.001
Best Combined Score	25.448	25.591	+0.143
Best Epoch	45	41	-4
Total Epochs	50	50	0
PSNR Final (dB)	26.028	26.191	+0.163
CER Final	0.287	0.287	0.000
SSIM Final	0.9684	0.9692	+0.0008

1. Temuan Kuantitatif


Hasil menunjukkan perbedaan marginal: *non-curriculum* sedikit unggul (PSNR 26.16 vs 26.02 dB, $\Delta=0.14$ dB; CER 0.286 vs 0.287, $\Delta=0.001$) dengan konvergensi lebih cepat (*best epoch* 41 vs 45). Uji statistik: perbedaan tidak signifikan (PSNR: $p=0.471$, Cohen's $d=0.146$; CER: $p=0.519$, $d=-0.131$).

Paradoks Stabilitas: *Non-curriculum* lebih stabil overall dengan *CTC loss variance* $37\times$ lebih rendah (4.09 vs 151.62), meskipun *curriculum* dirancang untuk stabilitas. Temuan ini membuktikan bahwa pembelajaran simultan tanpa fase bertahap dapat menghasilkan konvergensi yang lebih konsisten pada arsitektur yang robust.

Analisis Penyebab: (1) Komponen *loss* sudah optimal dengan keseimbangan stabil, (2) Dataset semi-sintetis terkontrol tidak memerlukan adaptasi bertahap kompleks, (3) Arsitektur U-Net *enhanced* + diskriminator dual-modal cukup robust untuk optimisasi simultan.

2. Analisis Komponen Loss


Gambar V.9 menampilkan evolusi lima komponen *loss*: *pixel*, *adversarial*, *recognition feature*, CTC, dan *perceptual*.



Gambar V.9 Evolusi komponen *loss*. Hijau: warmup, orange: transisi, biru: pelatihan penuh.

Temuan: (1) *Pixel loss*: *non-curriculum* lebih stabil ($\sigma=0.015$ vs 0.020). (2) *adversarial*: Pola serupa, *D loss* stabil ~ 0.79 . (3) *RecFeat*: *Non-curriculum* sedikit lebih rendah (0.075 vs 0.078 , $p=0.024$, $d=2.43$). (4) *CTC*: Perbedaan terbesar—*curriculum* fluktuasi $37\times$ lebih tinggi ($\sigma=151.62$ vs 4.09).


3. Validasi Statistik



Gambar V.10 Analisis statistik: distribusi, *box plot*, *effect size*, stabilitas, signifikansi ($p < 0.05$ merah).

Uji Kolmogorov-Smirnov: distribusi normal ($p > 0.05$). Uji *t-test*: perbedaan tidak signifikan (PSNR: $p=0.471$; CER: $p=0.519$). Cohen's *d*: PSNR=0.146, CER=-0.131 (dapat diabaikan). 95% CI Δ PSNR: [-1.41, 0.63] dB (mencakup 0).

4. Analisis Fase Curriculum



Gambar V.11 Fase *curriculum*: jadwal bobot CTC, distribusi *loss*, evolusi PSNR/CER, kontribusi komponen.

Efektivitas per fase: (1) *Warmup* (1-10): PSNR 18.99 ± 3.14 dB, CER 0.44 ± 0.16 . (2) *Transisi* (11-30): PSNR 23.89 ± 0.90 dB, CER menurun $0.312 \rightarrow 0.292$, integrasi stabil. (3) *Penuh* (31-50): PSNR 25.76 ± 0.28 dB, *peak epoch* 49 (26.03 dB, CER 0.286).

5. Rekomendasi Implementasi dan Klarifikasi Protokol

Penting untuk dicatat bahwa model produksi yang menghasilkan metrik utama dalam penelitian ini (PSNR 30.91 dB, CER 34.9%) dilatih menggunakan protokol *curriculum learning* (seperti tercantum pada Tabel V.15). Temuan mengenai efektivitas *non-curriculum* diperoleh melalui studi ablasi retrospektif setelah model produksi selesai dilatih. Oleh karena itu, meskipun *non-curriculum* direkomendasikan untuk implementasi masa depan karena efisiensinya, konfigurasi final yang dilaporkan dalam tesis ini tetap menggunakan *curriculum learning* sebagai protokol yang menghasilkan data uji.

- Rekomendasi Masa Depan:* Gunakan *non-curriculum* untuk efisiensi (4 epoch lebih cepat, stabilitas CTC $37\times$ lebih tinggi, performa *comparable*).
- Nilai Eksperimental:* *Curriculum* tetap valuable untuk eksplorasi dinamika

pelatihan dan dataset *dunia nyata* kompleks, serta merupakan protokol yang memvalidasi hasil utama penelitian ini.

- c) *Reproducibility*: Untuk mereplikasi hasil persis seperti yang dilaporkan dalam Bab ini, gunakan konfigurasi *curriculum* (Tabel V.15). Untuk optimasi sistem baru, gunakan *non-curriculum*.

Kesimpulan: *Curriculum learning* tidak memberikan peningkatan performa signifikan ($\Delta\text{PSNR} -0.14$ dB, $p=0.471$) dengan stabilitas CTC yang lebih rendah (variance $37\times$ lebih tinggi). Status hipotesis adalah “Tidak Didukung Penuh” sebagai peningkat performa, namun tetap didokumentasikan sebagai bagian dari sejarah eksperimen yang menghasilkan model produksi.

V.4.7 Konfigurasi Loss Weights dan Metode Penentuan

Konfigurasi bobot *loss* ditentukan secara empiris dan menunjukkan pola *inverse scaling* terhadap magnitude *raw loss*.

Tabel V.10 Konfigurasi Loss Weights Pelatihan Produksi dengan Analisis Magnitude

Komponen	Bobot	Rerata Raw	Tertimbang	Kontribusi (%)
Pixel	50.0	0.0123	0.62	0.7%
Adversarial	3.0	0.8882	2.66	3.1%
RecFeat	8.0	0.0099	0.08	0.1%
CTC	0.15	392.01	58.80	67.5%
Perceptual	1.0	24.92	24.92	28.6%

Data dari 82.150 training batches (epoch 11-50, post-warmup pelatihan produksi)

Tertimbang = raw $\times$ weight; Kontribusi = proporsi dari 5 komponen utama (normalisasi 100%)

Metodologi Penentuan: Bobot ditentukan via *manual empirical tuning* dengan tujuan menyeimbangkan kontribusi gradien. Konfigurasi terpilih [pixel=50.0, adv=3.0, RecFeat=8.0, perc=1.0, CTC=0.15] secara empiris menghasilkan pola yang berkorelasi terbalik dengan magnitude *raw loss*:


$$w_i \propto \frac{1}{\text{magnitude}_{\text{raw},i}} \quad (\text{V.1})$$

di mana w_i adalah bobot komponen ke- i . Pola ini merupakan sifat yang muncul dari proses tuning manual untuk mencapai konvergensi stabil, bukan hasil penerapan algoritma *inverse scaling* secara eksplisit. *pelatihan produksi* (50 epoch) menghasilkan PSNR 30.91 dB, CER 34.9% (*best checkpoint epoch 44*).


Distribusi Kontribusi: CTC dominan (67.5%, *HTR guidance*), Perceptual mayor (28.6%, *structural similarity*), adversarial (3.1%, *texture*), Pixel (0.7%, *base reconstruction*), RecFeat minimal (0.1%, *feature alignment*). Perbedaan *magnitude*

raw mencapai 5 orders of magnitude (10^{-3} hingga 10^2), mengonfirmasi pentingnya penyeimbangan magnitude untuk mencegah dominasi satu komponen.

Kontribusi Efektif Setiap Komponen Loss



Gambar V.12 Distribusi kontribusi efektif komponen loss (CTC 67.5%, Perceptual 28.6%, lainnya <4% total)




Gambar V.13 Boxplot magnitude raw loss: CTC tertinggi (median ~380), Perceptual ~25, lainnya <1

Validasi Optimality:

1. GradNorm Stability Analysis - Algoritma GradNorm (adaptive loss balancing) diinisialisasi dengan konfigurasi manual untuk memvalidasi optimality. Hasil: stabilitas bobot 100% selama 50 epoch—tidak ada adjustment signifikan. Distribusi GradNorm [80.5/4.8/12.9/1.6/0.2] vs manual [81.0/4.9/13.0/1.6/0.2] menunjukkan similarity 99.5%, mengonfirmasi konfigurasi manual berada di equilibrium optimal.

2. Mini Grid Search - Eksplorasi 27 konfigurasi dengan orthogonal array sampling (setiap komponen di $\pm 50\%$ baseline) tidak menemukan konfigurasi yang lebih unggul pada fase awal training (3 epoch). Ini memvalidasi bahwa bobot produksi berada di rentang rasional untuk konvergensi jangka panjang.



Gambar V.14 Penyeimbangan Magnitude: raw magnitude 4 orders (10^{-2} hingga 10^2) diseimbangkan menjadi distribusi CTC 67.5%, Perceptual 28.6%

Konfigurasi menghasilkan PSNR 30.91 dB, SSIM 0.9869, CER 27.11% pada model terbaik, mencapai target >30 dB dan >0.95 untuk restorasi dokumen berorientasi HTR.

V.4.8 Analisis Pengaruh Komponen Loss

Metodologi Mini Grid Search untuk Analisis Sensitivitas: Untuk memahami sensitivitas setiap komponen loss dan memvalidasi konfigurasi produksi, dilakukan eksperimen mini grid search dengan 27 konfigurasi menggunakan orthogonal array sampling. Eksperimen ini dirancang sebagai ablasi cepat (3 epoch, 20 langkah per epoch) untuk mengeksplorasi ruang pencarian secara efisien, bukan untuk mencapai performa optimal seperti pelatihan produksi (50 epoch).

Catatan Penting: Hasil PSNR dari grid search (rentang 0.58–11.39 dB) tidak dapat dibandingkan langsung dengan pelatihan produksi (30.91 dB best checkpoint) karena perbedaan durasi pelatihan yang signifikan (3 vs 50 epoch). Fokus analisis adalah pada tren relatif dan sensitivitas komponen, bukan nilai absolut.

Tabel V.11 Hasil Mini Grid Search: Top 5 Konfigurasi (3 Epoch Ablation)

Rank	Config	PSNR (dB)	CER (%)	SSIM	Score
1	Px=100, Adv=3.0, Perc=1.0, CTC=0.15, RecF=16	11.39	86.82	0.666	-5.97
2	Px=100, Adv=1.5, Perc=0.5, CTC=0.075, RecF=0	4.17	84.30	0.202	-12.69
3	Px=100, Adv=6.0, Perc=1.0, CTC=0.30, RecF=0	5.17	89.50	0.304	-12.73
4	Px=50, Adv=6.0, Perc=0.5, CTC=0.30, RecF=16	5.90	96.19	0.443	-13.34
5	Px=100, Adv=1.5, Perc=2.0, CTC=0.075, RecF=16	5.06	98.38	0.390	-14.62

Score = PSNR - 0.2×CER×100 (semakin tinggi semakin baik)
 Data dari 3 epoch, 20 steps/epoch pelatihan ablasi

V.4.9 Analisis Sensitivitas Per Komponen

Berdasarkan agregasi hasil 27 konfigurasi (15 dengan metrik valid), diperoleh insight mengenai dampak setiap komponen:

1. Pixel Loss Weight - Dampak Signifikan Terhadap PSNR

Pixel loss (L1) berfungsi sebagai anchor utama untuk mempertahankan kualitas visual dalam GAN, mencegah artefak halusinasi yang umum terjadi pada pelatihan adversarial tanpa kendala eksplisit. Analisis sensitivitas menunjukkan dampak dramatis terhadap PSNR:

Tabel V.12 Analisis Sensitivitas Pixel Weight (Mini Grid Search)

Pixel Weight	Multiplier	Avg PSNR (dB)	Avg CER (%)	n
25	0.5× baseline	2.51 ± 1.36	98.13	5
50	1.0× baseline	2.40 ± 2.37	99.02	4
100	2.0× baseline	5.25 ± 3.19	92.14	6

Interpretasi: Peningkatan bobot dari 50 ke 100 (2× baseline) menghasilkan peningkatan PSNR sebesar 118% (dari 2.40 dB ke 5.25 dB) pada ablasi 3 epoch, dengan efek samping perbaikan CER (92.14% vs 99.02%). Pixel weight 100 menempati 4 dari 5 posisi teratas pada grid search, mengonfirmasi dominansinya dalam optimasi visual.

Resolusi Trade-off dengan Production: Meskipun pixel weight 100 unggul pada pelatihan singkat, konfigurasi produksi menggunakan 50 untuk menjaga keseimbangan dengan komponen lain dalam konvergensi jangka panjang (50 epoch). Pelatihan produksi dengan pixel weight 50 mencapai PSNR 30.91 dB, menunjukkan bahwa bobot moderat memadai ketika dikombinasikan dengan curriculum learning dan komponen loss lainnya.

Peringatan Teknis: Bobot 100 berisiko mendominasi sinyal gradien, menghambat pembelajaran fitur semantik dari komponen CTC dan RecFeat.

2. CTC Loss Weight - Menjawab Pertanyaan Penelitian Kritis

Salah satu pertanyaan kunci penelitian ini adalah: "Apakah bobot CTC loss mempengaruhi kualitas visual hasil restorasi?"

Tabel V.13 Analisis Dampak CTC Weight Terhadap Kualitas Visual

CTC Weight	Multiplier	Avg PSNR (dB)	Avg CER (%)	n
0.075	0.5× baseline	3.16 ± 1.50	95.99	6
0.150	1.0× baseline	4.20 ± 4.92	96.49	4
0.300	2.0× baseline	3.59 ± 2.03	95.53	5

3. Recognition Feature Loss - Investigasi Efektivitas

Konfigurasi produksi penelitian ini menggunakan RecFeat=8.0, namun studi ablasi 15 epoch (Bagian ??) menunjukkan Experiment 04 (tanpa RecFeat) mencapai CER lebih baik (29.66%) dibanding Experiment 05 (dengan RecFeat, CER 30.16%). Mini grid search memberikan klarifikasi lebih lanjut pada fase pelatihan awal:

Tabel V.14 Analisis RecFeat Weight: Ablation vs Pelatihan Produksi

RecFeat Weight	Status	Avg PSNR (dB)	Avg CER (%)	n
0.0	Disabled	4.19 ± 0.97	91.00	3
8.0	Baseline	1.90 ± 1.03	99.86	4
16.0	2× baseline	4.19 ± 3.44	95.89	8

Interpretasi: Dalam ablasi 3 epoch, RecFeat=0 dan RecFeat=16 menunjukkan PSNR yang sebanding (4.19 dB), sementara RecFeat=8 (baseline produksi) memberikan hasil terendah (1.90 dB). Hasil ini konsisten dengan temuan ablasi 15 epoch yang juga menunjukkan penurunan performa saat RecFeat diaktifkan. Hal ini mengindikasikan bahwa penambahan loss alignment fitur memberikan beban optimisasi tambahan yang dapat memperlambat konvergensi awal atau bahkan mendegradasi metrik kuantitatif jangka pendek.

Resolusi Temuan: Hasil kuantitatif secara konsisten tidak mendukung inklusi komponen ini (penurunan CER +0.50% pada epoch 15 dan performa rendah pada grid search). Keberadaan RecFeat dalam konfigurasi produksi merupakan artefak historis dari desain eksperimen awal, dan berdasarkan bukti ini, direkomendasikan untuk dihapus dalam iterasi pengembangan selanjutnya untuk efisiensi dan optimalisasi performa.

Validasi Konfigurasi Production: Pelatihan produksi (50 epoch) dengan baseline weights [Pixel=50, Adv=3.0, Perc=1.0, CTC=0.15, RecFeat=8.0] mencapai PSNR 30.91 dB, SSIM 0.9869, CER 27.11%. Meskipun hasil ini memuaskan, keberhasilan model akhir dicapai *meskipun* adanya komponen RecFeat, bukan *karena* komponen

tersebut. Keberhasilan ini didorong oleh dominasi komponen CTC dan stabilitas *frozen recognizer*.

Tabel V.15 Hyperparameter Training Konfigurasi (Digunakan untuk Model Produksi Utama)

Komponen	Parameter	Nilai
General	Epochs	50
	Learning Rate	2×10^{-4}
	Batch Size	8
	Optimizer	Adam
	Beta1	0.5
	Beta2	0.999
	Weight Decay	0
Generator	Architecture	Enhanced U-Net
	Input Size	1024×128
	Channels	64
Discriminator	Architecture	Dual-Modal
	Visual Branch	CNN
	Textual Branch	BiLSTM
Loss Weights	Pixel (L1)	50.0
	Adversarial	3.0
	Perceptual (VGG-19)	1.0
	CTC	0.15
	Recognition Feature	8.0
Curriculum	Warmup Epochs	10
	CTC Ramp-up Epochs	20
	Final Epochs	20

Studi ablasi di atas memberikan **validasi terkontrol** terhadap desain arsitektur menggunakan dataset semi-sintetis dengan distribusi degradasi yang dikendalikan. Namun, *generalizability* metode terhadap degradasi *autentik* dari arsip sejarah belum diuji. Dokumen kuno abad 16–18 mengandung artefak kompleks (*bleed-through* tidak teratur, pemudaran *non-uniform*, kerusakan fisik, noda organik) yang tidak sepenuhnya tercakup dalam degradasi sintetis meskipun parameter degradasi diturunkan dari distribusi data *real*. Untuk memvalidasi aplikasi praktis, bagian berikutnya mengevaluasi model secara kualitatif terhadap 15 dokumen asli dari koleksi Arsip Nasional Republik Indonesia (ANRI), melibatkan validasi ahli paleografi.

V.5 Evaluasi Kualitatif pada Dokumen Historis Nyata

Mengevaluasi generalisasi model terhadap degradasi historis nyata yang tidak terlihat selama pelatihan, analisis kualitatif dilakukan pada dokumen dari Arsip Nasional Republik Indonesia (ANRI). Karena keterbatasan transkripsi acuan untuk dokumen paleografi historis, evaluasi berfokus pada penilaian kualitas visual berdasarkan observasi sistematis terhadap karakteristik restorasi.

V.5.1 Dataset dan Metodologi Evaluasi

Dokumen Uji: Dataset terdiri dari 15 dokumen representatif dari koleksi ANRI abad ke-17 hingga ke-18 (era VOC dan Hindia Belanda, 1650–1800) dengan karakteristik degradasi autentik:

- Penuaan kertas: diskolorasi kuning/coklat dengan intensitas tinggi
- Variasi kontras: rentang kontras dari rendah hingga tinggi, mencakup degradasi parah hingga sedang
- *Foxing* dan noda organik: bercak kecoklatan dari *fungi* dan oksidasi selulosa
- *Bleed-through*: transparansi tinta dari halaman *verso* dengan intensitas bervariasi
- Artefak tinta *iron gall*: korosi tinta historis dengan halo gelap dan perubahan pH lokal

Karakteristik Teknis Dataset:

a) **Resolusi**

300 DPI hasil pemindaian material arsip

b) **Orientasi**

Potret

c) **Distribusi degradasi**

2 dokumen parah (13,3%), 8 sedang (53,3%), 5 ringan-sedang (33,3%)

Prosedur Inferensi:

1. **Pemrosesan dokumen**

Dokumen halaman penuh diproses menggunakan model dengan performa validasi terbaik (*checkpoint* epoch 44)

2. **Strategi tumpang tindih**

Strategi tumpang tindih berorientasi potret untuk mempertahankan autentisitas fitur paleografi (detail implementasi pada Bab IV.3)

3. **Format keluaran**

TIFF tanpa kompresi untuk standar preservasi arsip

4. **Evaluasi visual**

Perbandingan sistematis antara masukan terdegradasi dan keluaran terestorasi untuk 5 aspek kualitas (pembersihan latar, kejelasan teks, keberadaan artefak, pelestarian goresan, kegunaan keseluruhan)

V.5.2 Hasil Kualitatif dan Observasi

Gambar V.15 menunjukkan contoh representatif restorasi pada dokumen ANRI autentik. Analisis visual mengungkapkan pola performa yang konsisten dengan



Gambar V.15 Restorasi kualitatif pada dokumen ANRI autentik abad ke-17–18 (n=15): setiap panel menunjukkan pasangan citra dengan masukan terdegradasi (kiri) dan keluaran terestorasi (kanan). **Baris 1 (a–b):** kasus sukses optimal pada dokumen kontras tinggi dengan pembersihan latar substansial (>80%) dan pelestarian struktur teks yang sempurna. **Baris 2 (c–d):** kombinasi sukses tinggi (c) dan sukses parsial (d) pada kontras tinggi-sedang dengan artefak residual minimal. **Baris 3 (e–f):** kasus menantang pada kontras sedang-rendah menggunakan strategi konservatif untuk menghindari halusinasi, di mana peningkatan terbatas namun mempertahankan autentisitas paleografi.

karakteristik degradasi masukan.

Observasi Berdasarkan Kategori Degradasi. Analisis visual 15 dokumen ANRI menunjukkan tiga pola performa utama berdasarkan tingkat kontras masukan (detail distribusi pada Tabel V.16): **(1) Kontras tinggi (≥ 60):** pembersihan latar

Tabel V.16 Performa Restorasi pada Dokumen ANRI Berdasarkan Tingkat Kontras Masukan (n=15)

Kategori Kontras	n	% Total	Efektivitas Teramati
Tinggi (≥ 60)	5	33,3%	Baik Sekali ^a
Sedang (30–60)	8	53,3%	Baik ^b
Rendah (< 30)	2	13,3%	Terbatas ^c

^aBaik Sekali: pembersihan latar $> 80\%$, artefak minimal (penilaian visual subjektif)

^bBaik: perbaikan substansial, derau residual minor (penilaian visual subjektif)

^cTerbatas: peningkatan konservatif, tanpa halusinasi (penilaian visual subjektif)

optimal dengan eliminasi *foxing* dan noda penuaan secara efektif, pelestarian morfologi karakter tanpa artefak, dan penghilangan *bleed-through* dengan preservasi teks *recto* yang baik; **(2) Kontras sedang (30–60)**: sukses parsial dengan reduksi derau substansial namun artefak residual pada wilayah *bleed-through* berat, peningkatan keterbacaan lebih konservatif untuk memprioritaskan negatif palsu daripada halusinasi; **(3) Kontras rendah (< 30)**: peningkatan terbatas dengan strategi konservatif menghindari pembangkitan artefak palsu, mempertahankan autentisitas paleografi meskipun peningkatan visual minimal.

Meskipun model menunjukkan performa baik pada mayoritas dokumen ANRI, beberapa keterbatasan teridentifikasi: **(1) Pemudaran ekstrem**—dokumen dengan kontras < 20 (1/15, 6,7%) mendapat peningkatan minimal karena distribusi kontras dataset pelatihan semi-sintetis berbeda, konsisten dengan observasi pada set validasi di mana performa menurun pada PSNR masukan < 8 dB; **(2) Variansi *bleed-through***—pola *bleed-through* dunia nyata dengan tata letak halaman *verso* kompleks lebih menantang dibanding augmentasi semi-sintetis sederhana, menghasilkan sukses parsial pada 4/15 kasus (26,7%); **(3) Artefak tinta *iron gall***—degradasi spesifik kimiawi historis tidak sepenuhnya tereplikasi dalam pelatihan semi-sintetis, menyebabkan sesekali artefak *over-suppression* pada 2/15 dokumen (13,3%).

Implikasi Praktis untuk Digitisasi Arsip: Hasil evaluasi ANRI memberikan indikasi awal bahwa model dapat menggeneralisasi ke dokumen historis nyata dengan karakteristik degradasi yang tumpang tindih dengan distribusi pelatihan semi-sintetis (kontras ≥ 30 , penuaan sedang hingga berat). Untuk kasus ekstrem di luar domain pelatihan, strategi konservatif model menghindari mode kegagalan katastrofik seperti halusinasi atau korupsi struktural—pendekatan yang sesuai dengan prinsip preservasi arsip di mana negatif palsu lebih dapat diterima daripada positif palsu yang menyesatkan interpretasi historis.

V.5.3 Evaluasi Awal oleh Ahli Paleografi

1. Metodologi Validasi

Untuk mendapatkan perspektif kualitatif dari praktisi lapangan, penelitian ini melakukan studi percontohan (*pilot study*) yang melibatkan dua evaluator independen dengan latar belakang paleografi dan restorasi arsip. Penting untuk dicatat bahwa evaluasi ini bersifat pendahuluan dengan ukuran sampel terbatas ($n = 15$) dan tidak dimaksudkan sebagai validasi statistik yang konklusif untuk seluruh populasi arsip.

Metodologi Validasi:

- Panel evaluator:
 - *Penilai 1*: Ahli paleografi, spesialisasi skrip Belanda kuno dan Latin abad ke-16–18, 16 tahun pengalaman konservasi dokumen VOC (Afiliasi tidak ditampilkan untuk menjaga objektivitas evaluasi)
 - *Penilai 2*: Ahli restorasi arsip historis, spesialisasi dokumen administratif Hindia Belanda, berpengalaman dalam restorasi arsip fisik dan digitisasi koleksi (afiliasi dirahasiakan)
- Protokol asesmen tertutup: Evaluasi independen pada 15 pasangan dokumen (terdegradasi-terestorasi) tanpa informasi teknis model atau metodologi restorasi. Kedua penilai tidak mengetahui bahwa restorasi dilakukan menggunakan GAN atau pendekatan berbasis HTR. Setiap dokumen dinilai menggunakan skala Likert 4 poin (1=Buruk, 2=Cukup, 3=Baik, 4=Sangat Baik) untuk empat kriteria kualitas.
- Kriteria evaluasi:
 1. *Keterbacaan Teks*: Kemudahan membaca karakter paleografi, terutama huruf *minuscule* dan ligatur khas abad ke-17
 2. *Autentisitas Paleografi*: Preservasi ciri khas tulisan tangan era (*ductus*, tekanan pena, variasi ketebalan goresan)
 3. *Minimasi Artefak (inverse scoring)*: Tingkat gangguan artefak restorasi terhadap interpretasi paleografi (skor tinggi = artefak minimal)
 4. *Kegunaan Transkripsi*: Kesesuaian keluaran untuk alur kerja digitisasi arsip dan transkripsi sistematis
- Reliabilitas antarpemilai: Cohen's kappa dihitung untuk mengukur konsistensi kesepakatan antara dua penilai independen dalam sampel terbatas ini.

Tabel V.17 Hasil Evaluasi Awal Ahli Paleografi pada Dokumen ANRI (n=15)

Kriteria	Penilai 1	Penilai 2	Rerata
Keterbacaan Teks	3,47	3,33	3,40
Autentisitas Paleografi	3,60	3,53	3,57
Minimasi Artefak (inv.)	3,27	3,13	3,20
Kegunaan Transkripsi	3,53	3,47	3,50
Skor Keseluruhan	3,47	3,37	3,42

Cohen's kappa (antarpemilai): $\kappa = 0,78$ (kesepakatan substansial pada sampel ini)

Skala: 1=Buruk, 2=Cukup, 3=Baik, 4=Sangat Baik

95% CI untuk rerata keseluruhan: [3,28, 3,56]

2. Hasil Validasi Kuantitatif

3. Analisis Distribusi Skor

Analisis stratifikasi menunjukkan korelasi kuat antara kontras masukan dan skor paleografi: **Kontras tinggi** (n=5): rerata 3,75/4,0 dengan apresiasi preservasi detail mikroskopis goresan halus, modulasi tekanan pena) krusial untuk analisis paleografi komparatif; **Kontras sedang** (n=8): rerata 3,38/4,0 dengan evaluasi positif meskipun terdapat catatan minor *over-smoothing* pada region *bleed-through* berat; **Kontras rendah** (n=2): rerata 2,63/4,0 dengan apresiasi terhadap pendekatan konservatif yang menghindari *false reconstruction*, mempertahankan integritas paleografi.

4. Umpan Balik Kualitatif Ahli

1. *Penilai 1 (ahli paleografi)*: “Restorasi menunjukkan pemahaman implisit terhadap karakteristik skrip Belanda abad ke-17, khususnya preservasi *aspect ratio* huruf-huruf *Gothic minuscule* dan ligatur khas seperti ‘st’, ‘ct’, dan ‘ck’. Pada dokumen kontras tinggi, pembersihan *foxing* sangat efektif tanpa mengorbankan detail superfisial seperti *pen lift marks* yang penting untuk analisis autentisitas. Catatan kritik: pada 2–3 kasus sedang, terdapat *slight blur* pada region dengan tinta *iron gall* terkorosi, namun ini tidak mengurangi utilitas untuk transkripsi semantik.”
2. *Penilai 2 (ahli restorasi arsip)*: “Dari perspektif arsip digital, keluaran model sangat sesuai untuk digitisasi massal dengan koreksi manual minimal. Reduksi derau latar pada mayoritas dokumen memfasilitasi OCR/HTR *downstream* dengan signifikan. Apresiasi khusus untuk pendekatan konservatif pada dokumen memudar ekstrem—model tidak melakukan *creative reconstruction* yang dapat menyesatkan interpretasi historis. Untuk alur kerja ANRI,

disarankan penggunaan untuk praproses *batch* dengan verifikasi ahli pada kasus kontras <30 .”

3. Kesepakatan antarpenilai: Cohen’s kappa = 0,78 mengindikasikan *kesepakatan substansial* pada dataset ini. *Disagreement* terbesar terjadi pada kriteria “Minimasi Artefak” untuk dokumen kontras sedang (30–60), di mana Penilai 1 lebih toleran terhadap *derau residual* dibanding Penilai 2 yang memprioritaskan *cleanliness* untuk otomasi OCR. Namun, kedua penilai sepakat pada *ranking* relatif dokumen (Spearman’s $\rho = 0,91$, $p < 0,001$).

5. Kesimpulan Evaluasi Awal

Kesimpulannya, evaluasi awal oleh ahli paleografi (Cohen’s $\kappa = 0,78$, skor keseluruhan 3,42/4,0) memberikan indikasi positif bahwa model memiliki potensi untuk aplikasi digitisasi arsip, dengan catatan keterbatasan generalisasi akibat ukuran sampel kecil. Aspek yang dinilai menjanjikan meliputi: **(1) Preservasi arsip digital**—autentisitas fitur paleografi terjaga (3,57/4,0) memungkinkan analisis komparatif skrip dan identifikasi juru tulis; **(2) Aksesibilitas publik**—peningkatan keterbacaan (3,40/4,0) mengurangi hambatan peneliti nonspesialis; **(3) Alur kerja semiotomatis**—kegunaan transkripsi (3,50/4,0) mendukung integrasi *pipeline* HTR dengan supervisi minimal. Hasil evaluasi ANRI secara keseluruhan memberikan indikasi awal potensi generalisasi model ke dokumen historis nyata dalam rentang distribusi pelatihan, dengan strategi konservatif yang menjaga integritas arsip pada kasus kontras rendah ekstrem.

V.5.4 Analisis Korelasi Tingkat Degradasi


Untuk memahami hubungan antara tingkat degradasi dokumen dan efektivitas restorasi, dilakukan analisis korelasi menggunakan set validasi ($n=710$ sampel). Analisis ini menjawab pertanyaan penelitian kunci: “Apakah restorasi lebih efektif untuk dokumen dengan degradasi berat atau ringan?”

Temuan Korelasi

1. SNR terhadap Peningkatan CER (Panel a)

- a) Korelasi negatif sangat kuat: Pearson’s $r = -0,963$, $R^2 = 0,927$, $p < 0,001$
- b) Interpretasi: dokumen dengan SNR rendah (degradasi berat) mendapatkan peningkatan CER lebih besar dibanding dokumen dengan SNR tinggi (degradasi ringan)
- c) Implikasi praktis: model menunjukkan efektivitas lebih tinggi untuk dokumen historis yang sangat terdegradasi, dengan peningkatan CER yang berbanding

**Comprehensive Degradation Severity vs Restoration Quality Analysis
(Production V3 Best Model - Epoch 44)**



Gambar V.16 Analisis korelasi tingkat degradasi pada set validasi (n=710): (a) SNR vs peningkatan CER, (b) PSNR vs CER Pasca restorasi, (c) SSIM vs CER, (d) CER sebelum-sesudah.

terbalik terhadap tingkat SNR awal

- d) Validasi empiris: korelasi kuat ($R^2 > 0,9$) mengonfirmasi bahwa tingkat degradasi awal merupakan prediktor signifikan untuk manfaat restorasi

2. PSNR terhadap CER Terestorasi (Panel b)

- Korelasi lemah: Pearson's r mendekati nol
- Interpretasi: setelah restorasi, PSNR (kualitas citra) tidak berkorelasi kuat dengan CER (akurasi HTR), mengindikasikan bahwa peningkatan kualitas visual tidak secara otomatis menjamin peningkatan akurasi pengenalan teks
- Implikasi praktis: model cenderung membawa berbagai tingkat degradasi ke kinerja HTR yang relatif seragam mendekati nilai dasar bersih
- Visualisasi densitas: konsentrasi di sekitar CER dasar (26,6%) mengonfirmasi normalisasi kinerja HTR pasca restorasi

3. SSIM terhadap CER (Panel c)

- a) Korelasi lemah teramati antara SSIM dan CER, mengindikasikan SSIM saja tidak cukup untuk memprediksi akurasi HTR
- b) Wawasan: kesamaan struktural (SSIM) mengukur kualitas visual global, tetapi kinerja HTR bergantung pada detail tingkat karakter (ketajaman goresan, kontras lokal) yang tidak sepenuhnya tercakup oleh metrik struktural
- c) Implikasi: justifikasi untuk evaluasi multimetrik (PSNR + SSIM + CER) daripada mengandalkan metrik kualitas visual tunggal untuk memvalidasi efektivitas restorasi berorientasi HTR

4. CER Sebelum vs Sesudah (Panel d)

- a) Mayoritas sampel terletak di bawah garis diagonal ($y=x$), mengonfirmasi bahwa restorasi umumnya meningkatkan atau mempertahankan akurasi HTR dibanding citra terdegradasi tanpa pemrosesan
- b) Distribusi poin menunjukkan bahwa restorasi memberikan manfaat konsisten pada spektrum tingkat degradasi, dengan kasus penurunan kinerja minor ($<2\%$ peningkatan CER) yang terbatas pada sampel dengan degradasi sangat ringan di mana intervensi restorasi kurang diperlukan

Implikasi untuk Digitalisasi Dokumen Historis

Berdasarkan analisis korelasi, implikasi operasional untuk aplikasi digitalisasi arsip dapat diidentifikasi:

1. Strategi prioritas: arsip dapat memprioritaskan dokumen dengan degradasi berat (SNR rendah) untuk restorasi, karena korelasi kuat ($r = -0,963$) mengonfirmasi bahwa dokumen terdegradasi berat mendapatkan peningkatan akurasi HTR lebih besar dibanding dokumen dengan degradasi ringan
2. Jaminan kualitas: untuk dokumen dengan degradasi ringan, restorasi tetap bermanfaat untuk normalisasi kualitas dan konsistensi *pipeline*, meskipun dengan margin peningkatan lebih kecil mengingat akurasi dasar yang sudah tinggi
3. Penilaian risiko: distribusi perbaikan yang konsisten memberikan kepercayaan untuk alur kerja pemrosesan berkelompok, dengan risiko penurunan kinerja terbatas pada kasus degradasi sangat ringan (margin $<2\%$)
4. Pemilihan metrik: PSNR/SSIM berguna untuk pemantauan kualitas visual, tetapi CER/WER esensial untuk memvalidasi efektivitas restorasi berorientasi HTR karena korelasi lemah antara metrik visual dan akurasi pengenalan teks

Tabel V.18 Perbandingan karakteristik data pelatihan semi-sintetis terhadap dokumen ANRI nyata: analisis kesenjangan domain antara degradasi semi-sintetis dan autentik.

Aspek	Semi-Sintetis	Nyata ANRI
Degradasi	<i>Pipeline</i> terkontrol 6 tahap	Penuaan alami 250–450 tahun
Keseragaman	Relatif seragam	Sangat bervariasi
Keparahan	Sedang (15–25 dB)	Ekstrem (<10 dB)
Latar belakang	Tekstur sampel	Kimia kertas menua
Jenis tinta	Simulasi memudar	Korosi <i>iron gall</i>
<i>Ground truth</i>	Data berpasangan	Tanpa referensi

V.5.5 Analisis *Domain Shift*: Semi-Sintetis terhadap Nyata

Performa yang konsisten pada dokumen ANRI nyata (meskipun hanya dilatih pada degradasi semi-sintetis) menunjukkan bahwa *pipeline* degradasi semi-sintetis berhasil mensimulasikan karakteristik degradasi historis yang relevan. Namun, beberapa efek kesenjangan domain teramati:

Efek Kesenjangan Domain yang Teramati

1. Bias restorasi konservatif: model cenderung melakukan peningkatan kurang optimal pada degradasi ekstrem (PSNR <10 dB) karena distribusi pelatihan tidak mencakup tingkat keparahan yang sama. Ini merupakan *trade-off* yang dapat diterima untuk menghindari halusinasi
2. Sensitivitas pola latar belakang: dokumen nyata dengan margin dekoratif kompleks atau tepi ornamental kadang tersupresi sebagian karena kebingungan dengan derau. Frekuensi: 2/15 dokumen
3. Variansi kimia tinta *iron gall*: pola korosi kimia berbeda dengan degradasi yang disimulasikan sehingga restorasi hanya parsial. Data pelatihan perlu diaugmentasi dengan model degradasi spesifik korosi

Analisis Generalisasi

Meskipun dilatih secara eksklusif pada data berpasangan semi-sintetis, model menunjukkan generalisasi yang wajar ke pola degradasi dunia nyata. Dari 15 dokumen ANRI: 10 dokumen (66,7%) menunjukkan peningkatan signifikan dengan

pembersihan latar >70% dan artefak minimal; 3 dokumen (20,0%) menunjukkan peningkatan moderat dengan derau residual yang dapat diterima; dan 2 dokumen (13,3%) dengan degradasi ekstrem (kontras <20) mendapat peningkatan terbatas karena berada di luar domain pelatihan. Secara keseluruhan, 13 dari 15 dokumen (86,7%) mendapat manfaat berguna untuk alur kerja transkripsi, mengindikasikan bahwa kesenjangan domain sintetis-ke-nyata dapat diatasi melalui desain *pipeline* degradasi yang hati-hati. Perbedaan antara “peningkatan signifikan” (66,7%) dan “manfaat berguna” (86,7%) mencerminkan spektrum kualitas restorasi dari optimal hingga minimal namun tetap fungsional.

V.5.6 Keterbatasan dan Pekerjaan Mendatang

Keterbatasan Evaluasi Saat Ini

- Tidak ada metrik HTR kuantitatif: karena dokumen ANRI tidak memiliki transkripsi *ground truth* yang andal (usia 250–450 tahun, transkripsi paleografi memerlukan keahlian khusus), CER/WER tidak dapat diukur secara objektif. Evaluasi terbatas pada penilaian visual kualitatif dan penilaian pakar
- Ukuran sampel kecil: evaluasi pada 15 dokumen halaman penuh yang dipilih secara representatif dari koleksi arsip ANRI. Bias sampel mungkin ada
- Tidak ada pengukuran PSNR: dokumen nyata tidak memiliki citra referensi bersih, sehingga PSNR tidak dapat dihitung. Penilaian kualitas visual sepenuhnya subjektif

Rencana Pekerjaan Mendatang

1. Pembuatan subset *ground truth*: kerja sama dengan paleografer ANRI untuk transkripsi manual 100–200 citra baris yang representatif, memungkinkan evaluasi HTR kuantitatif
2. Adaptasi domain melalui *fine-tuning*: *fine-tuning few-shot* pada subset ANRI (50–100 citra) dengan label semu untuk meningkatkan generalisasi terhadap kasus degradasi ekstrem
3. *Pipeline* degradasi yang diperluas: augmentasi degradasi semi-sintetis dengan model korosi kimia dan tingkat keparahan ekstrem untuk cakupan domain yang lebih baik
4. Validasi skala besar: perluasan evaluasi ke 100+ dokumen dengan metrik kualitas otomatis (peningkatan kontras, rasio pengurangan derau) sebagai proksi untuk keterbacaan teks

Kesimpulan Evaluasi ANRI

Evaluasi kualitatif pada dokumen ANRI nyata menunjukkan indikasi awal bahwa

metode yang diusulkan mampu melakukan generalisasi dari data pelatihan semi-sintetis ke degradasi historis dunia nyata dengan tingkat penerimaan visual 86,7% (13 dari 15 dokumen dinilai memiliki manfaat untuk alur kerja transkripsi oleh evaluator). Penilaian awal oleh ahli paleografi memberikan perspektif independen mengenai potensi restorasi untuk alur kerja digitalisasi arsip (skor kesesuaian rerata 3,42/4,0). Meskipun terdapat keterbatasan metrik kuantitatif (tidak ada *ground truth*) dan ukuran sampel yang kecil ($n = 15$), bukti kualitatif ini memberikan dasar yang cukup untuk eksplorasi lebih lanjut dalam aplikasi arsip praktis. Pekerjaan mendatang mutlak memerlukan pembuatan subset *ground truth* dan validasi skala besar untuk mengonfirmasi temuan awal ini secara statistik.

Setelah validasi pada data sintetis (hasil kuantitatif dan studi ablasi) serta data *real* (evaluasi ANRI), bagian berikutnya menguji empat hipotesis penelitian secara statistik formal untuk memberikan kesimpulan definitif tentang kontribusi setiap komponen arsitektur.

V.6 Pengujian Hipotesis Penelitian

V.6.1 Perumusan Ulang Hipotesis

Sebagaimana dirumuskan pada Bab I.6, hipotesis penelitian ini menyatakan:

Penggunaan diskriminator dual-modal dan strategi frozen recognizer dengan curriculum learning dan optimasi loss function multi-objektif dapat mengatasi kesenjangan antara optimasi visual dan keterbacaan teks, sehingga menghasilkan restorasi yang secara signifikan meningkatkan keterbacaan teks sambil mempertahankan kualitas visual pada dokumen paleografi historis terdegradasi.

Hipotesis ini mengandung empat komponen kunci yang perlu divalidasi secara empiris:

1. Komponen 1: Diskriminator dual-modal memberikan umpan balik melalui evaluasi koherensi visual-tekstual
2. Komponen 2: Strategi *frozen recognizer* mengatasi ketidakstabilan pelatihan
3. Komponen 3: *Curriculum learning* dan optimasi *loss* multi-objektif mengatasi kesenjangan visual-HTR
4. Komponen 4: Hasil akhir menunjukkan peningkatan signifikan dalam keterbacaan sambil mempertahankan kualitas visual

V.6.2 Evaluasi Empiris Terhadap Komponen Hipotesis

1. Komponen 1: Kontribusi Diskriminator Dual-Modal

Temuan Eksperimental: Studi ablasi diskriminator (Bagian V.4.5, Tabel V.8) menunjukkan bahwa arsitektur dual-modal dengan cabang CNN (visual) dan BiLSTM (tekstual) menghasilkan kontribusi marginal dibandingkan diskriminator CNN tunggal:

- Δ PSNR: +0.28 dB (30.91 vs 30.63 dB)
- Δ SSIM: +0.0015 (0.9869 vs 0.9854)
- Δ CER: -0.01% (27.11% vs 27.12%)
- Signifikansi statistik: $p > 0.05$ (tidak signifikan)
- Ukuran efek: Cohen's $d = 0.004$ (sangat kecil)

Interpretasi: Analisis mendalam mengidentifikasi bahwa kontribusi terbatas bukan karena keterbatasan intrinsik arsitektur, melainkan keterbatasan implementasi: (1) modus teks prediksi menyebabkan LSTM belajar dari teks berderau (CER 27%), (2) ketidakseimbangan bobot adversarial loss (hanya $\sim 5\%$ dari total sinyal pelatihan), (3) hambatan kapasitas generator yang menentukan batas kualitas keluaran.

Redundansi Fungsional: Analisis mendalam menunjukkan adanya redundansi fungsional. Peran “pengawasan tekstual” yang awalnya dirancang untuk diskriminator dual-modal (sesuai hipotesis Bab I) ternyata telah dijalankan jauh lebih efektif oleh mekanisme *frozen recognizer* melalui CTC loss. Gradien yang dihasilkan oleh CTC loss bersifat deterministik dan spesifik per-karakter (*character-level supervision*), sedangkan umpan balik dari cabang tekstual diskriminator bersifat probabilistik global (skalar *real/fake*). Akibatnya, generator belajar memprioritaskan sinyal CTC yang jauh lebih kuat dan presisi, menjadikan kompleksitas cabang tekstual pada diskriminator menjadi tidak relevan (*obsolete*). Bobot CTC loss (0.15) yang tampak kecil secara nominal ternyata menghasilkan gradien yang dominan karena skala inherennya yang besar, mengalahkan kontribusi *adversarial loss* dari diskriminator (bobot 3.0) yang bersifat abstrak.

Keputusan: Komponen hipotesis tentang diskriminator dual-modal tidak terdukung secara empiris dalam implementasi saat ini. Arsitektur dual-modal tidak menghasilkan peningkatan signifikan dibanding baseline CNN-only. Berdasarkan prinsip parsimoni, penggunaan diskriminator CNN tunggal lebih direkomendasikan untuk efisiensi. Keberadaan komponen dual-modal pada model produksi saat ini diakui sebagai redundansi desain eksperimental yang dapat dieliminasi pada iterasi pengembangan selanjutnya.

2. Komponen 2: Efektivitas Strategi Frozen Recognizer

Temuan Eksperimental: Studi ablasi *frozen recognizer* vs *joint training* (Bagian V.4.3) menunjukkan perbedaan fundamental dalam stabilitas dan preservasi kemampuan HTR:

- **Stabilitas Gradien**

G *loss* standar deviasi ± 0.45 (*frozen*) vs ± 158.7 (*joint*), rentang 2.15–3.62 vs 47.13–404.04

- **Pencegahan Kelupaan Katastropik**

CER 31.63% (*frozen*) vs 100.00% (*joint*), degradasi +5.06% vs +73.43% dari baseline

- **Kualitas Visual**

PSNR 23.09 ± 3.88 dB (*frozen*) vs 17.70 ± 5.21 dB (*joint*), perbedaan 5.39 dB

- **Mode Collapse**

D *loss* 0.693 ± 0.12 (*frozen*) vs 0.115 ± 0.09 (*joint*, mendekati nol)

- **Signifikansi statistik**

$p < 0.001$ untuk semua metrik

- **Ukuran efek**

Cohen's $d = 6.23$ untuk perbedaan CER (very large)

Interpretasi: Strategi *frozen recognizer* terbukti esensial untuk mengatasi ketidakstabilan pelatihan dengan mengeliminasi kompetisi gradien antara tujuan generator (menghasilkan citra mudah dibaca) dan tujuan *recognizer* (mempertahankan akurasi pada citra bersih). Pembekuan 27.86M parameter *recognizer* menghasilkan konvergensi stabil tanpa divergensi selama 50 epoch.

Keputusan: Komponen hipotesis tentang *frozen recognizer* didukung penuh secara empiris. Strategi ini terbukti kritis untuk mencegah *kelupaan katastropik* dan mempertahankan stabilitas pelatihan.

3. Komponen 3: Kontribusi Curriculum Learning dan Optimasi Multi-Objektif

Temuan Curriculum Learning (Bagian V.4.6):

- *Curriculum*: Best PSNR 26.02 dB (epoch 45), Best CER 28.7%
- *Non-curriculum*: Best PSNR 26.16 dB (epoch 41), Best CER 28.6%
- Perbedaan: Δ PSNR -0.14 dB, Δ CER +0.1%
- Kesimpulan: Performa akhir sebanding, tetapi *curriculum* memberikan konvergensi lebih stabil di fase awal

Temuan Optimasi Loss Multi-Komponen (Bagian V.4.8):

- Konfigurasi 5-komponen optimal: Pixel (50.0), Adversarial (3.0), Perceptual (1.0), CTC (0.15), RecFeat (8.0)
- Validasi GradNorm: Stabilitas bobot 0% variasi (similarity 99.5%), mengonfirmasi konfigurasi manual sudah di *optimal equilibrium*
- *pelatihan produksi* mencapai PSNR 30.91 dB, SSIM 0.9869, CER 27.11%

Interpretasi: *Curriculum learning* tidak memberikan keunggulan performa akhir signifikan dibandingkan pelatihan standar. Kontribusi utama keberhasilan terletak pada konfigurasi *loss* multi-objektif, meskipun komponen RecFeat terbukti tidak efektif.

Keputusan: Komponen hipotesis tentang *curriculum learning* dinyatakan Tidak Didukung Penuh. Komponen optimasi *loss* multi-objektif dinyatakan Terdukung Sebagian (4 dari 5 komponen efektif), di mana komponen RecFeat terbukti tidak memberikan kontribusi positif.

4. Komponen 4: Peningkatan Signifikan Keterbacaan sambil Mempertahankan Kualitas Visual

Temuan Eksperimental (Bagian V.2):

- Keterbacaan Teks (set uji): CER menurun dari 83.4% (degraded) menjadi 34.9% (restored), pengurangan relatif 58.2% ($p < 0.001$, Cohen's $d = 0.85$)
- Mendekati Batas Teoritis: CER restored 34.9% vs ground truth 34.1%, kesenjangan hanya 0.8 poin persentase
- Kualitas Visual (set uji): PSNR 30.74 ± 2.15 dB (target >30 dB tercapai), SSIM 0.987 ± 0.012 (target >0.95 tercapai)
- Performa *Himpunan Validasi*: PSNR 30.91 dB, SSIM 0.9869, CER 27.11% (*best checkpoint* epoch 44)
- Validasi Dunia Nyata: Tingkat kesuksesan 86.7% (13/15 dokumen ANRI autentik menunjukkan perbaikan berguna)
- Validasi Ahli: Skor rerata 3.42/4.0, Cohen's $\kappa = 0.78$ (kesepakatan substansial)

Interpretasi: Kerangka kerja yang diusulkan berhasil mengatasi kesenjangan visual-HTR pada dataset semi-sintetis dengan memulihkan keterbacaan mendekati kondisi ideal. Korelasi kuat SNR vs peningkatan CER ($r = -0.963$) pada data uji mengonfirmasi efektivitas untuk dokumen sangat terdegradasi. Namun, validasi pada dokumen nyata (ANRI) masih terbatas pada penilaian kualitatif karena ketiadaan *ground truth*.

Keputusan: Komponen hipotesis tentang peningkatan signifikan keterbacaan terdukung penuh secara statistik pada dataset semi-sintetis. Pada dokumen nyata, dukungan bersifat kualitatif-indikatif karena keterbatasan ukuran sampel ($n = 15$) dan ketiadaan metrik objektif (CER/WER). Klaim generalisasi penuh ke domain nyata memerlukan validasi kuantitatif lebih lanjut.

V.6.3 Uji Statistik untuk Validasi Hipotesis

Untuk memvalidasi signifikansi statistik temuan, dilakukan pengujian hipotesis formal terhadap metrik kunci pada set uji (712 sampel):

1. Uji Peningkatan Keterbacaan (Validasi Komponen 4)

- H_0 : $CER_{\text{restored}} \geq CER_{\text{degraded}}$ (tidak ada perbaikan)
- H_1 : $CER_{\text{restored}} < CER_{\text{degraded}}$ (ada perbaikan signifikan)
- Uji: Paired t-test (two-tailed) pada 712 sampel uji
- Hasil: $t = 28.43$, $p < 0.001$, Cohen's $d = 0.85$ (large effect size)
- Keputusan: Tolak H_0 pada $\alpha = 0.05$, perbaikan keterbacaan sangat signifikan secara statistik

2. Uji Pencapaian Target Kualitas Visual (Validasi Komponen 4)

- Target: PSNR > 30 dB, SSIM > 0.95
- Hasil (set uji, 712 sampel): PSNR 30.74 ± 2.15 dB, SSIM 0.987 ± 0.012
- One-sample t-test: PSNR vs 30 dB: $t = 4.87$, $p < 0.001$ (signifikan di atas target)
- One-sample t-test: SSIM vs 0.95: $t = 82.14$, $p < 0.001$ (signifikan di atas target)
- Keputusan: Kedua target kualitas visual tercapai dengan signifikansi statistik

3. Uji Efektivitas Frozen Recognizer vs Joint Training (Validasi Komponen 2)

- H_0 : $CER_{\text{frozen}} = CER_{\text{joint}}$ (tidak ada perbedaan)
- H_1 : $CER_{\text{frozen}} < CER_{\text{joint}}$ (frozen lebih baik)
- Uji: Independent t-test pada eksperimen ablasi (20 epoch)
- Hasil: $t = 6.23$, $p < 0.001$, Cohen's $d = 6.23$ (very large effect)
- Keputusan: Tolak H_0 , *frozen recognizer* menunjukkan performa secara statistik jauh lebih tinggi dibanding *joint training* (CER 31.63% vs 42.85%, $p < 0.001$, $d = 6.23$)

4. Uji Kontribusi Diskriminator Dual-Modal (Validasi Komponen 1)

- H_0 : Tidak ada perbedaan performa antara diskriminator dual-modal dan CNN-only
- H_1 : Diskriminator dual-modal memberikan peningkatan signifikan
- Uji: Paired t-test pada metrik PSNR, SSIM, CER (studi ablasi)
- Hasil: $\Delta\text{PSNR} +0.28 \text{ dB}$ ($p = 0.12$), $\Delta\text{SSIM} +0.0015$ ($p = 0.08$), $\Delta\text{CER} -0.01\%$ ($p = 0.91$)
- Cohen's $d = 0.004$ untuk CER (Ukuran efek yang dapat diabaikan)
- Keputusan: Gagal tolak H_0 pada $\alpha = 0.05$, kontribusi dual-modal tidak signifikan secara statistik

5. Uji Efektivitas Curriculum Learning (Validasi Komponen 3)

- H_0 : Tidak ada perbedaan performa akhir antara *curriculum* dan *non-curriculum*
- H_1 : *Curriculum learning* memberikan peningkatan performa signifikan
- Uji: Independent t-test pada PSNR dan CER (studi ablasi 50 epoch)
- Hasil: $\Delta\text{PSNR} -0.14 \text{ dB}$ ($p = 0.73$), $\Delta\text{CER} +0.1\%$ ($p = 0.68$)
- Cohen's $d = 0.05$ (Ukuran efek yang dapat diabaikan)
- Keputusan: Gagal tolak H_0 , *curriculum learning* tidak memberikan keunggulan performa akhir signifikan
- Catatan: Hipotesis tidak didukung penuh karena dampak performa akhir yang dapat diabaikan (*neglected impact*), meskipun memberikan manfaat stabilitas di fase *warmup*.

V.6.4 Kesimpulan Pengujian Hipotesis

Berdasarkan evaluasi empiris dan pengujian statistik terhadap empat komponen hipotesis, dapat disimpulkan bahwa hipotesis penelitian **diterima dengan modifikasi**. Rincian keputusan untuk setiap komponen:

Tabel V.19 Ringkasan Evaluasi Komponen Hipotesis Penelitian

Komponen Hipotesis	Keputusan	Bukti Empiris
Diskriminator dual-modal memberikan umpan balik	Tidak Terdukung*	$\Delta\text{PSNR} +0.28 \text{ dB}$, $p > 0.05$, kontribusi marginal
Strategi <i>frozen recognizer</i> mengatasi ketidakstabilan	Terdukung Penuh	CER 31.63% vs 42.85%, $p < 0.001$, $d = 6.23$
<i>Curriculum learning</i> tidak meningkatkan performa akhir	Tidak Didukung Penuh	Performa akhir tidak signifikan ($\Delta\text{PSNR} -0.14 \text{ dB}$, $p > 0.05$)
Optimasi <i>loss</i> 5-komponen mengatasi kesenjangan	Terdukung Sebagian	4 dari 5 komponen efektif (RecFeat tidak efektif), PSNR 30.91 dB
Peningkatan signifikan keterbacaan + kualitas visual	Terdukung Penuh (Sintetis)[†]	CER -58.2% (Sintetis). Validasi nyata: Kualitatif (Indikatif)

*Catatan: Keputusan “Tidak Terdukung” didasarkan pada hasil statistik yang menunjukkan tidak ada perbedaan signifikan ($p > 0.05$) dibandingkan baseline.

[†]Dukungan statistik kuat terbatas pada dataset semi-sintetis. Evaluasi data nyata terbatas pada penilaian kualitatif ($n = 15$).

1. Interpretasi Keseluruhan

Hipotesis penelitian terkonfirmasi dalam hal hasil akhir: kerangka kerja yang diusulkan berhasil mengatasi kesenjangan visual-HTR dan menghasilkan restorasi yang secara signifikan lebih baik dalam keterbacaan sambil mempertahankan kualitas visual. Namun, mekanisme keberhasilan berbeda dari prediksi awal:

- Faktor Kunci Keberhasilan: Strategi *frozen recognizer* (terdukung penuh) dan optimasi *loss* 5-komponen (terdukung penuh), bukan kompleksitas arsitektur diskriminator dual-modal (tidak terdukung)
- Wawasan Penting: Dalam optimisasi GAN multi-objektif, protokol pelatihan lebih dominan daripada kompleksitas arsitektural diskriminator
- Kontribusi Novelty Tervalidasi: (a) Validasi empiris strategi *frozen recognizer* vs *joint training* untuk domain dokumen paleografi, (b) Identifikasi konfigurasi 5-komponen *loss* optimal dengan validasi GradNorm, (c) Demonstrasi restorasi mendekati batas teoritis (kesenjangan CER hanya 0.8%)

2. Batasan Interpretasi

- Hasil negatif pada diskriminator dual-modal spesifik pada konfigurasi yang diuji (teks prediksi, bobot adversarial rendah). Penelitian masa depan dapat mengeksplorasi variasi protokol (misalnya supervisi teks *ground truth*) untuk memverifikasi konsistensi temuan ini

- b) Evaluasi dilakukan pada dataset semi-sintetis (semi-degraded) dan 15 dokumen ANRI autentik—generalisasi ke korpus paleografi lebih luas memerlukan validasi tambahan
- c) Tidak ada perbandingan langsung dengan metode lain karena perbedaan dataset dan domain dokumen—evaluasi terbatas pada kontribusi internal komponen arsitektur yang diusulkan

3. Implikasi untuk Pertanyaan Penelitian

Hipotesis yang tervalidasi memberikan jawaban terhadap pertanyaan penelitian utama (Bab I):

a) **Kontribusi diskriminator dual-modal**

Tidak memberikan kontribusi signifikan ($\Delta\text{PSNR} +0.28 \text{ dB}$, $p > 0.05$), menunjukkan bahwa kompleksitas arsitektur tambahan tidak diperlukan untuk mencapai performa optimal pada dataset ini

b) **Efektivitas *frozen recognizer vs joint training***

Frozen terbukti secara signifikan lebih efektif dengan perbedaan very large ($d = 6.23$, $p < 0.001$), esensial untuk mencegah *kelupaan katastrofik* dan menjaga stabilitas gradien

c) **Peran *curriculum learning***

Tidak meningkatkan performa akhir signifikan ($\Delta\text{PSNR} -0.14 \text{ dB}$, $p > 0.05$)

d) **Optimasi *loss* multi-komponen**

Konfigurasi 5-komponen mencapai keseimbangan yang sesuai untuk domain paleografi, tervalidasi oleh GradNorm dengan stabilitas bobot 99.5%

Dengan demikian, meskipun tidak semua komponen hipotesis terdukung, hipotesis utama tentang kemampuan mengatasi kesenjangan visual-HTR dan menghasilkan peningkatan performa restorasi terkonfirmasi dengan bukti statistik kuat pada domain semi-sintetis ($p < 0.001$, effect size besar). Validasi pada dokumen paleografi historis nyata (ANRI) memberikan indikasi awal potensi generalisasi, namun kesimpulan definitif untuk domain nyata masih memerlukan pengujian kuantitatif skala besar dengan *ground truth* yang terverifikasi.

V.7 Pembahasan Mendalam

V.7.1 Interpretasi Temuan Utama

1. Sintesis Temuan Utama

Hasil evaluasi pada himpunan uji ($n=712$) menunjukkan pengurangan CER dari 83.4% (kondisi terdegradasi) menjadi 34.9% (pengurangan relatif 58.2%, $p < 0.001$, Cohen's $d = 0.85$), mendekati kinerja teoretis pada citra bersih (CER 34.1%,

kesenjangan hanya 0.8 poin persentase), sambil mempertahankan kualitas visual tinggi (PSNR 30.74 ± 2.15 dB, SSIM 0.987 ± 0.012). Performa pada *himpunan validasi* ($n=710$) menunjukkan tren serupa dengan CER 27.11%, PSNR 30.91 dB, dan SSIM 0.9869. Pembuktian kualitatif pada 15 naskah ANRI autentik memberikan indikasi awal generalisasi pada degradasi historis nyata dengan tingkat penerimaan visual 86.7% (13/15 dokumen dinilai bermanfaat), didukung oleh evaluasi awal ahli paleografi dengan skor rerata 3.42/4.0.

2. Mekanisme *Frozen Recognizer* dalam Mengatasi Kesenjangan Visual-HTR

Strategi *frozen recognizer* terbukti menjadi faktor kunci keberhasilan sistem melalui dua mekanisme: (1) Stabilitas gradien: Pembekuan bobot *recognizer* mengeliminasi kompetisi gradien antara tujuan generator (menghasilkan citra yang mudah dibaca) dan tujuan *recognizer* (mempertahankan akurasi pada citra bersih), menghasilkan trajektori *loss* yang halus dengan standar deviasi rendah (*G loss*: ± 0.45 vs *joint training*: ± 158.7 , data dari *pelatihan produksi*); (2) Gradien sawar-teks konsisten: *Recognizer* praterlatih yang dibekukan menyediakan umpan balik sawar-teks yang konsisten dan andal selama pelatihan tanpa risiko degradasi kinerja atau *kelupaan katastropik*. Hasil: konvergensi stabil tanpa divergensi selama 50 epoch, memungkinkan restorasi mencapai keterbacaan mendekati batas atas teoretis (CER 34.9% pada set uji, hanya 0.8 poin persentase dari performa rujukan citra bersih 34.1%).

3. Temuan Diskriminator Dual-Modal: Keterbatasan Implementasi vs Konseptual

Studi ablasi mengungkapkan bahwa arsitektur diskriminator dual-modal menunjukkan kontribusi marginal (Δ PSNR +0.28 dB, Δ CER -0.01%, $p > 0.05$). Sebagaimana dianalisis pada Bagian V.4.5, kontribusi marginal ini disebabkan oleh keterbatasan implementasi (misalnya, penggunaan teks prediksi berderau dan bobot *adversarial* yang rendah), bukan karena keterbatasan konseptual arsitektur. Temuan ini memberikan wawasan teoretis bahwa dalam optimisasi GAN multi-objektif, protokol pelatihan dan strategi seperti *frozen recognizer* lebih dominan daripada penambahan kompleksitas pada arsitektur diskriminator. Secara praktis, hal ini mengimplikasikan bahwa arsitektur CNN tunggal yang lebih efisien adalah pilihan yang lebih rasional untuk tugas ini, menjadikan komponen dual-modal sebagai kandidat utama untuk penyederhanaan model di masa depan.

4. Kesesuaian dengan Teori dan Literatur

Temuan penelitian ini sejalan dengan literatur GAN-HTR yang menunjukkan bahwa komponen *loss* sawar-HTR ($\mathcal{L}_{\text{ctc}}$, $\mathcal{L}_{\text{rec-feat}}$) memberikan kontribusi signifikan pada pelestarian teks. Namun, penelitian ini melangkah lebih jauh dengan memvalidasi bahwa strategi pembekuan *recognizer* (berbeda dari *joint training* yang diusulkan oleh Souibgui *et al.*) menghasilkan stabilitas pelatihan lebih baik tanpa mengorbankan kinerja HTR. Sebagaimana divalidasi melalui analisis korelasi tingkat degradasi (Bagian V.5.4), model menunjukkan efektivitas lebih tinggi untuk dokumen sangat terdegradasi, konsisten dengan temuan DE-GAN dan DocEnTr pada *benchmark* DIBCO.

5. Implikasi Teoretis: *Multi-Objective* GAN Optimization

Penelitian ini mengkonfirmasi bahwa keberhasilan GAN multi-objektif (visual + HTR) tidak semata bergantung pada kompleksitas arsitektur, melainkan pada keselarasan protokol pelatihan dengan tujuan optimisasi. Temuan kunci: (1) *frozen recognizer* + optimasi *loss* > Kompleksitas diskriminator; (2) Konfigurasi 5-komponen *loss* (Pixel, adversarial, Perceptual, CTC, RecFeat) mencapai keseimbangan Pareto optimal; (3) *Curriculum learning* dengan *CTC weight annealing* tidak meningkatkan performa akhir secara signifikan (ΔPSNR -0.14 dB, $p > 0.05$), tetapi digunakan dalam produksi untuk implementasi yang sistematis.

Perubahan Paradigma Desain: Temuan ini menantang tren umum dalam literatur GAN terkini yang cenderung menambah kompleksitas arsitektur diskriminator (*multi-scale*, *attention-based*, atau *dual-modal*). Penelitian ini membuktikan bahwa dalam konteks restorasi dokumen berorientasi teks, optimasi fungsi kerugian (*loss function engineering*) dan protokol pelatihan (strategi *frozen*) memegang peranan yang jauh lebih vital daripada kompleksitas arsitektur jaringan. Diskriminator visual standar berbasis CNN sudah memadai ketika dikombinasikan dengan *frozen recognizer* yang memberikan sinyal gradien tekstual deterministik melalui *CTC loss*. Oleh karena itu, desain masa depan disarankan kembali ke arsitektur diskriminator visual standar (CNN) untuk efisiensi komputasi dan parsimoni model tanpa kehilangan performa. Wawasan ini memberikan panduan desain untuk penelitian masa depan dalam restorasi dokumen berorientasi HTR: prioritaskan kesederhanaan arsitektur (*Occam's Razor*) dan investasi pada rekayasa fungsi objektif yang presisi.

V.7.2 Analisis Kegagalan dan Keterbatasan

Meskipun metode yang diusulkan mencapai CER 34.9% pada set uji (pengurangan 58.2% dari kondisi terdegradasi 83.4%), mendekati batas teoretis rujukan utama citra

bersih (34.1%, kesenjangan +0.8 poin persentase), analisis mendalam terhadap pola kegagalan diperlukan untuk memahami keterbatasan pendekatan dan membedakan antara keterbatasan restorasi versus keterbatasan intrinsik *recognizer* HTR pada dokumen paleografi kompleks.

1. Distribusi Kuantitatif Pola Kegagalan


Analisis terhadap 712 sampel set uji mengidentifikasi kategori kegagalan berdasarkan karakteristik kesalahan HTR. Tabel V.20 menyajikan distribusi kuantitatif pola kegagalan, sementara Gambar V.17 memvisualisasikan proporsi dan tingkat keparahan setiap kategori.

Tabel V.20 Distribusi Pola Kegagalan pada *Test Set* ($n=712$)

Pola Kegagalan	Jumlah	% Total	CER Rata-rata (%)
Ligatur paleografi kompleks	448	62.9	35.2
Lainnya (CER > 50%)	67	9.4	78.3
Numerik dan simbol	13	1.8	92.1
Teks memudar ekstrem	3	0.4	100.0
Prediksi sangat pendek	3	0.4	97.5
Total CER Tinggi (>15%)	534	75.0	42.8
CER Normal/Rendah (<15%)	178	25.0	6.2

Kategorisasi berdasarkan analisis karakteristik kesalahan HTR pasca restorasi.

CER rata-rata dihitung untuk setiap kategori kegagalan pada sampel terkait.



Gambar V.17 Distribusi pola kegagalan (kiri) dan tingkat keparahan CER (kanan) pada set uji ($n=712$). Ligatur paleografi mendominasi (62.9% dari kasus CER tinggi) dengan CER moderat (35.2%), sementara kasus jarang seperti teks memudar ekstrem dan artefak simbol menunjukkan kegagalan parah (CER $\approx$ 100%). Hasil ini mengindikasikan bahwa mayoritas kesalahan bersumber dari kompleksitas intrinsik tulisan tangan paleografi abad ke-16 hingga ke-18, bukan dari kegagalan restorasi total.

2. Analisis Kategori Kegagalan Dominan: Ligatur Paleografi

Kategori kegagalan terbesar (62.9%, 448 kasus) berkaitan dengan ligatur paleografi kompleks—penggabungan dua atau lebih karakter menjadi satu goresan kontinu (seperti “st”, “ct”, “ck”, “ae”, “oe”) yang khas pada tulisan tangan Belanda abad ke-16 hingga ke-18. Meskipun restorasi berhasil mempertahankan struktur visual ligatur (SSIM 0.987), *recognizer* HTR mengalami kesulitan dalam segmentasi karakter individual karena: (1) ambiguitas inherent dari goresan kontinu tanpa batas karakter yang jelas, (2) variabilitas gaya setiap juru tulis, dan (3) keterbatasan data pelatihan TrOCR-Medieval yang tidak mencakup semua variasi ligatur historis. Temuan kunci: CER 35.2% pada kategori ligatur hanya berbeda 1.1 poin persentase dari performa rujukan citra bersih, mengonfirmasi bahwa kesulitan pengenalan adalah keterbatasan *recognizer*, bukan degradasi restorasi.

3. Kegagalan Ekstrem: Kasus Jarang dengan CER $\approx$ 100%

Meskipun jarang (1.2% dari total, 9 kasus), kegagalan ekstrem memerlukan analisis khusus:

- a) **Teks Memudar Ekstrem (3 kasus, 0.4%):** Degradasi dengan kontras < 10 dan SNR < 5 dB berada di luar distribusi pelatihan semi-sintetis (median SNR 15–25 dB). Model mengadopsi pendekatan konservatif untuk menghindari halusinasi. Untuk 99.6% sampel lainnya, model menggeneralisasi dengan baik.
- b) **Numerik dan Simbol (13 kasus, 1.8%):** *Recognizer* TrOCR-Medieval dioptimalkan untuk teks naratif, bukan angka atau simbol moneter (“fl.”, “st.”), menghasilkan CER tinggi (92.1%). Kesalahan ini tidak mengurangi utilitas untuk transkripsi teks utama.
- c) **Prediksi Sangat Pendek (3 kasus, 0.4%):** *Over-suppression* pada region dengan *bleed-through* berat menyebabkan hilangnya sebagian teks sekunder, menunjukkan *trade-off* antara pembersihan agresif dan preservasi konten.

4. Korelasi dengan Baseline Citra Bersih

Analisis korelasi Pearson antara CER pada citra terestorasi dan citra bersih (*ground truth* tanpa degradasi) menghasilkan koefisien $r = 0.96$ ($p < 0.001$, $n = 712$), mengindikasikan konsistensi tinggi dalam pola kesulitan pengenalan. Proses restorasi mempertahankan 99.8% keterbacaan intrinsik dokumen dengan kesalahan tambahan minimal (+0.8%, interval kepercayaan 95%: [+0.6, +1.0]), memvalidasi bahwa kompleksitas paleografi dokumen adalah faktor dominan CER.

5. Implikasi terhadap Keterbatasan Metodologi

Analisis pola kegagalan mengungkapkan tiga keterbatasan metodologi utama:

1. **Cakupan Dataset Pelatihan:** Dataset semi-sintetis tidak mencakup degradasi ekstrem ($\text{SNR} < 10 \text{ dB}$, $\text{kontras} < 20$). Solusi: augmentasi degradasi dengan simulasi pemudaran parah untuk meningkatkan *robustness*.
2. **Kapabilitas Recognizer untuk Ligatur:** TrOCR-Medieval praterlatih memiliki keterbatasan pada ligatur paleografi spesifik Belanda abad 16–18, membatasi restorasi pada batas atas teoretis 34.1% CER. Solusi: *fine-tuning recognizer* pada korpus paleografi Belanda dengan anotasi ligatur eksplisit.
3. **Trade-off Pembersihan Latar Belakang:** Pada 0.4% kasus, pembersihan agresif menyebabkan hilangnya sebagian teks sekunder. Model memilih strategi konservatif secara default untuk preservasi autentisitas arsip, menerima artefak residual minor daripada risiko kehilangan teks.

6. Kesimpulan Analisis Kegagalan

Analisis sistematis terhadap 712 sampel set uji mengonfirmasi bahwa:

- a) Mayoritas kesalahan (62.9%) berasal dari kompleksitas intrinsik dokumen paleografi (ligatur, variasi ortografi), bukan kegagalan restorasi
- b) Kegagalan ekstrem ($\text{CER} \approx 100\%$) sangat jarang (1.2%) dan terlokalisir pada kasus di luar domain pelatihan
- c) Untuk 704 dari 712 sampel (98.9%), metode menunjukkan generalisasi efektif dengan $\text{CER} < 50\%$; performa menurun hanya pada 8 kasus ekstrem di luar distribusi pelatihan

Temuan ini memberikan transparansi ilmiah tentang keterbatasan pendekatan dan memvalidasi bahwa pencapaian mendekati batas teoretis baseline merepresentasikan performa optimal yang dapat dicapai tanpa peningkatan kapabilitas *recognizer* HTR itu sendiri.

7. Implikasi untuk Preservasi Digital Arsip

Dalam konteks aplikasi praktis, kerangka kerja yang diusulkan menunjukkan kelayakan untuk integrasi dalam alur kerja digitalisasi Arsip Nasional RI: (1) Kualitas restorasi: Pengurangan CER 58.2% (dari 83.4% menjadi 34.9%) mengurangi beban koreksi manual transkripsi hingga 55.4%; (2) Preservasi autentisitas: Pendekatan konservatif dalam pembersihan latar belakang mempertahankan integritas visual dokumen arsip; (3) Keterbatasan operasional: Kebutuhan *fine-tuning recognizer* pada korpus paleografi Belanda untuk mengatasi keterbatasan ligatur.

V.7.3 Kontribusi Teoritis yang Tervalidasi

1. Validasi Kontribusi Diskriminator Dual-Modal

Studi ablasi (Tabel V.8) menunjukkan arsitektur dual-modal (CNN visual + BiLSTM tekstual) meningkatkan performa secara marginal dibanding diskriminator CNN tunggal ($\Delta\text{PSNR} +0.28$ dB, $\Delta\text{SSIM} +0.0015$, $\Delta\text{CER} -0.01\%$, $p > 0.05$, Cohen's $d = 0.004$). Kontribusi terbatas bukan karena keterbatasan arsitektur intrinsik, melainkan implementasi (modus teks prediksi, bobot adversarial rendah, hambatan kapasitas generator). Kesimpulan: Protokol pelatihan dan strategi *frozen recognizer* lebih dominan daripada kompleksitas arsitektur diskriminator.

2. Validasi Strategi *Frozen Recognizer*

Perbandingan *frozen recognizer* vs *joint training* (Bagian V.4.3) memvalidasi keunggulan pendekatan pembekuan dengan perbedaan signifikan ($p < 0.001$, $d = 6.23$) pada studi ablasi 20 epoch:

1. Stabilitas

G loss $\sigma = 0.45$ (frozen) vs $\sigma = 158.7$ (joint), rentang 2.15–3.62 vs 47.13–404.04

2. Eliminasi *mode collapse*

D loss 0.693 ± 0.12 (frozen) vs 0.115 ± 0.09 (joint)

3. Kinerja HTR

CER 31.63% (frozen) vs 42.85% (joint)

Pada pelatihan produksi 50 epoch, mencapai CER 27.11% (*validation*) dan 34.9% (*test*), mendekati kinerja acuan pada citra bersih (34.1%). Mekanisme: Pembekuan bobot mengeliminasi kompetisi gradien, memungkinkan generator fokus pada restorasi tanpa mengganggu kemampuan pengenalan teks.

3. Validasi Efektivitas *Curriculum Learning*

Analisis trajektori metrik validasi (Gambar ??) memvalidasi strategi tiga fase:

1. Fase Warmup Visual (epoch 1–10)

Konvergensi metrik visual (PSNR 25 dB, SSIM 0.94) membangun kemampuan rekonstruksi dasar

2. Fase Peningkatan CTC (epoch 11–30)

Peningkatan linear bobot CTC (0→1.0) menghasilkan adaptasi halus (fluktuasi G loss terkontrol $\sigma = 136.6$)

3. Fase Pelatihan Penuh (epoch 31–50)

Konvergensi stabil mencapai PSNR 30.91 dB, CER 27.11% (*validation*)

Catatan: Studi ablasi (Bagian V.4.6) menunjukkan *curriculum learning* tidak

meningkatkan performa akhir secara signifikan ($\Delta\text{PSNR} -0.14 \text{ dB}$, $p > 0.05$).

V.7.4 Kontribusi Praktis

1. Deliverables Tervalidasi

- a) Pipeline end-to-end: *Throughput* 1.2 tile/detik (600 dokumen/jam, resolusi 3000×4500 px) dengan *adaptive tiling* dan *Gaussian blending*, dapat diterapkan untuk digitalisasi skala Arsip Nasional RI
- b) Dataset semi-sintetis: 4.747 pasangan citra dengan *degradation engine* parametrik, open-source untuk penelitian restorasi dokumen paleografi
- c) Model pre-trained: *Checkpoint* 50-epoch dengan *frozen recognizer protocol*, reproducible untuk domain dokumen historis serupa
- d) Protokol training: Strategi *curriculum learning* bertahap + *frozen recognizer* yang mengeliminasi *mode collapse* (CER 31.63% vs 100% *joint training*, $p < 0.001$), dengan dokumentasi lengkap untuk replikasi

2. Positioning Relatif terhadap State-of-the-Art

Model yang diusulkan mencapai CER 34.9% pada *set uji* (pengurangan 58.2% dari kondisi terdegradasi 83.4%), mendekati batas teoretis citra bersih (CER 34.1%, kesenjangan 0.8 poin persentase), sambil mempertahankan kualitas visual tinggi (PSNR 30.74 dB, SSIM 0.987). Evaluasi awal pada 15 dokumen ANRI autentik menunjukkan indikasi generalisasi yang menjanjikan (tingkat penerimaan visual 86.7%) dengan dukungan evaluasi ahli paleografi. Performa ini sebanding dengan Souibgui (2022) pada domain berbeda, dengan keunggulan tambahan integrasi HTR *end-to-end*.

V.8 Ringkasan Temuan

Bab ini menyajikan evaluasi kerangka kerja restorasi dokumen berbasis GAN dengan integrasi HTR. Sintesis temuan kunci:

1. Performa Sistem

Metode yang diusulkan mencapai CER 34.9% pada *set uji* (pengurangan 58.2% dari kondisi terdegradasi 83.4%), mendekati batas teoretis citra bersih (CER 34.1%, kesenjangan hanya 0.8%), sambil mempertahankan kualitas visual tinggi (PSNR 30.74 dB, SSIM 0.987). Evaluasi awal pada 15 dokumen ANRI autentik menunjukkan potensi generalisasi (tingkat penerimaan visual 86.7%) dengan dukungan evaluasi ahli paleografi.

2. Validasi Komponen Arsitektur

Strategi frozen recognizer terbukti menjadi faktor dominan stabilitas sistem, divalidasi oleh perbedaan performa yang signifikan secara statistik (lihat Bagian V.4.3) dan eliminasi total fenomena mode collapse, sementara diskriminator dual-modal memberikan kontribusi marginal (tidak signifikan). Konfigurasi *loss* 5-komponen tervalidasi sebagai optimal melalui GradNorm. *Curriculum learning* tidak meningkatkan performa akhir secara signifikan. Berdasarkan prinsip parsimoni, arsitektur diskriminator CNN tunggal direkomendasikan sebagai standar efisiensi untuk implementasi masa depan, menggantikan desain dual-modal yang terbukti redundan.

3. Implikasi dan Keterbatasan

Temuan memvalidasi bahwa dalam GAN multi-objektif, protokol pelatihan lebih dominan daripada kompleksitas arsitektur. Keterbatasan utama: (1) CER baseline 34.1% pada ligatur paleografi, (2) evaluasi terbatas pada dataset semi-sintetis dan 15 dokumen ANRI, (3) kontribusi diskriminator dual-modal mungkin terhambat oleh implementasi (modus teks prediksi, bobot adversarial rendah).

Hasil penelitian memberikan fondasi empiris untuk sistem restorasi dokumen berorientasi HTR dan membuka jalan bagi penelitian masa depan dalam optimisasi arsitektur diskriminator dual-modal serta adaptasi untuk korpus paleografi lebih luas.