

BAB V. Hasil dan Pembahasan

V.1 Pendahuluan

Bab ini menyajikan hasil eksperimen komprehensif untuk mengevaluasi kerangka kerja restorasi dokumen berbasis GAN dengan diskriminator dual-modal dan strategi *frozen recognizer* yang telah dirancang dan diimplementasikan pada bab sebelumnya. Evaluasi dilakukan untuk menjawab pertanyaan penelitian yang telah dirumuskan pada Bab I, khususnya terkait kemampuan kerangka kerja yang diusulkan dalam mengatasi kesenjangan antara optimasi visual dan keterbacaan teks.

Pembahasan dalam bab ini diorganisasikan secara sistematis dalam empat bagian utama. Pertama, analisis kuantitatif yang menyajikan hasil pengukuran kinerja model menggunakan metrik standar untuk kualitas visual (PSNR dan SSIM) serta metrik keterbacaan teks (CER dan WER). Kedua, analisis kualitatif yang memperkuat temuan kuantitatif melalui visualisasi hasil restorasi untuk memahami karakteristik visual dari keluaran model. Ketiga, analisis komparatif yang membandingkan kinerja kerangka kerja yang diusulkan dengan metode *state-of-the-art* yang relevan dalam restorasi dokumen berbasis GAN. Keempat, studi ablasi sistematis yang mengisolasi dan mengukur kontribusi individual dari setiap komponen yang diusulkan (diskriminator dual-modal, *frozen recognizer*, *curriculum learning*, dan konfigurasi fungsi *loss*). Kelima, pengujian hipotesis statistik untuk memvalidasi signifikansi hasil secara formal.

Organisasi pembahasan ini dirancang untuk memberikan pemahaman menyeluruh mengenai efektivitas kerangka kerja yang diusulkan, mulai dari bukti empiris kuantitatif, validasi visual, perbandingan dengan metode lain, hingga identifikasi kontribusi spesifik dari setiap komponen inovatif yang diajukan dalam penelitian ini.

V.2 Konfigurasi Eksperimen

V.2.1 Dataset dan Pembagian Data

[Isi akan ditambahkan: deskripsi dataset yang digunakan, jumlah sampel, karakteristik degradasi, pembagian data latih/validasi/uji dengan rasio yang digunakan, strategi pembagian data akademis atau random split]

V.2.2 Lingkungan Komputasi

[Isi akan ditambahkan: spesifikasi perangkat keras (GPU, CPU, memori), perangkat lunak (framework deep learning, versi Python, sistem operasi), konfigurasi presisi numerik (FP32 vs FP16)]

V.2.3 Hiperparameter Pelatihan

[Isi akan ditambahkan: *learning rate*, *batch size*, jumlah *epoch*, optimizer yang digunakan, parameter *curriculum learning* untuk penurunan bobot CTC *loss*, konfigurasi bobot fungsi *loss* (*adversarial*, *reconstruction*, *recognition*)]

V.2.4 Metrik Evaluasi

[Isi akan ditambahkan: definisi formal dari PSNR, SSIM, CER, WER, serta justifikasi pemilihan metrik-metrik tersebut untuk mengukur kualitas visual dan keterbacaan teks]

V.3 Hasil Analisis Kuantitatif

V.3.1 Kinerja Model pada Data Uji

[Isi akan ditambahkan: tabel hasil metrik PSNR, SSIM, CER, WER pada data uji, pembahasan apakah target penelitian tercapai (PSNR > 30 dB, SSIM > 0.95), analisis distribusi metrik menggunakan statistik deskriptif (mean, median, standar deviasi)]

V.3.2 Analisis Kinerja Berdasarkan Tingkat Degradasi

[Isi akan ditambahkan: analisis kinerja model pada dokumen dengan tingkat degradasi ringan, sedang, dan berat, identifikasi pola kinerja berdasarkan jenis degradasi (*bleed-through*, *fading*, *stains*, *blur*), pembahasan kekuatan dan keterbatasan model pada berbagai kondisi degradasi]

V.3.3 Analisis Konvergensi Pelatihan

[Isi akan ditambahkan: grafik kurva *loss* selama pelatihan untuk generator dan diskriminator, analisis stabilitas pelatihan dengan *curriculum learning*, pembahasan dinamika konvergensi komponen *loss* yang berbeda (*adversarial*, *reconstruction*, *recognition*)]

V.4 Hasil Analisis Kualitatif

V.4.1 Visualisasi Hasil Restorasi

[Isi akan ditambahkan: sampel visualisasi perbandingan citra terdegradasi, hasil restorasi, dan *ground truth*, analisis visual terhadap kualitas restorasi (ketajaman karakter, penghilangan noise, preservasi struktur teks), identifikasi kasus sukses dan kasus gagal]

V.4.2 Analisis Detail Karakter

[Isi akan ditambahkan: *zoom-in* pada karakter individual untuk mengevaluasi preservasi detail, pembahasan kemampuan model dalam mempertahankan struktur karakter yang penting untuk HTR, analisis artifak visual yang mungkin muncul (smoothing berlebihan, distorsi karakter)]

V.4.3 Analisis Koherensi Visual-Tekstual

[Isi akan ditambahkan: evaluasi koherensi antara kualitas visual dan keterbacaan teks pada hasil restorasi, identifikasi kasus di mana kualitas visual tinggi berkorelasi dengan CER rendah, pembahasan peran diskriminator dual-modal dalam menjaga koherensi ini]

V.5 Analisis Komparatif dengan Metode State-of-the-Art

V.5.1 Perbandingan Metrik Kuantitatif

[Isi akan ditambahkan: tabel perbandingan komprehensif antara kerangka kerja yang diusulkan dengan metode baseline (DE-GAN, DocEnTr, Text-DIAE, atau metode lain yang relevan), analisis perbedaan signifikan dalam metrik PSNR, SSIM, CER, WER, pembahasan trade-off antara kualitas visual dan keterbacaan teks pada berbagai metode]

V.5.2 Perbandingan Kualitas Visual

[Isi akan ditambahkan: visualisasi perbandingan hasil restorasi dari berbagai metode pada sampel dokumen yang sama, analisis kelebihan dan kekurangan visual dari setiap metode, pembahasan karakteristik unik dari hasil restorasi kerangka kerja yang diusulkan]

V.5.3 Analisis Efisiensi Komputasi

[Isi akan ditambahkan: perbandingan waktu pelatihan, waktu inferensi, dan kebutuhan memori GPU antar metode, analisis trade-off antara kompleksitas komputasi dan kinerja restorasi, pembahasan skalabilitas kerangka kerja untuk aplikasi praktis]

V.6 Studi Ablasi Sistematis

V.6.1 Desain Eksperimen Ablasi

[Isi akan ditambahkan: deskripsi protokol ablasi untuk mengisolasi kontribusi setiap komponen, definisi konfigurasi baseline dan varian ablasi (menghilangkan atau memodifikasi satu komponen pada satu waktu), justifikasi pemilihan komponen yang diablasi]

V.6.2 Kontribusi Diskriminator Dual-Modal

[Isi akan ditambahkan: perbandingan kinerja antara diskriminator dual-modal (visual + tekstual) vs diskriminator hanya visual, analisis dampak terhadap metrik visual (PSNR, SSIM) dan metrik keterbacaan (CER, WER), pembahasan mekanisme bagaimana cabang tekstual meningkatkan kualitas umpan balik generator]

V.6.3 Kontribusi Frozen Recognizer dengan Integrasi CTC Loss

Bagian ini menjawab Pertanyaan Penelitian 2 dari Bab I mengenai perbandingan strategi *frozen recognizer* dengan integrasi CTC *loss* dibandingkan pendekatan pelatihan bersama (*joint training*) dalam tiga aspek kritis: stabilitas gradien, performa keterbacaan teks, dan efisiensi komputasi. Eksperimen ablasi dilakukan dengan melatih kedua konfigurasi selama 20 *epoch* dengan 100 langkah per *epoch* pada dataset ANRI yang berisi dokumen paleografi Belanda abad ke-16 hingga ke-18.

a) Analisis Stabilitas Gradien Selama Pelatihan

Untuk mengevaluasi stabilitas pelatihan, dilakukan analisis terhadap trajektori *loss* dan variansi gradien selama proses optimisasi. Tabel 1 menunjukkan perbandingan dinamika *loss* antara kedua pendekatan.


Tabel 1: Perbandingan Trajektori *Loss* antara *Frozen Recognizer* dan *Joint Training*

Pendekatan	G Loss	D Loss	R Loss	Rentang G	Status
Frozen (Baseline)	2.84 ± 0.45	0.693 ± 0.12	96.23 ± 12.3	2.15–3.62	Stabil
Joint Training	110.5 ± 158.7	0.115 ± 0.09	120.8 ± 112.4	47.13–404.04	Tidak Stabil

Hasil eksperimen menunjukkan perbedaan mencolok dalam stabilitas pelatihan. Pendekatan *frozen recognizer* menunjukkan trajektori *loss* yang halus dengan standar deviasi rendah (G *loss*: ± 0.45), sementara *joint training* mengalami osilasi ekstrem dengan variansi tinggi (G *loss*: ± 158.7). Rentang G *loss* pada *joint training* (47.13–404.04) mengindikasikan ketidakstabilan gradien yang parah, dengan fluktuasi mencapai $8.6\times$ dari nilai minimum.

Analisis *discriminator loss* menunjukkan fenomena *mode collapse* parsial pada *joint training*, di mana D *loss* mendekati nol (0.115 ± 0.09), mengindikasikan bahwa *discriminator* terlalu dominan dan generator tidak dapat belajar secara optimal. Sebaliknya, *frozen recognizer* mempertahankan keseimbangan yang sehat antara generator dan *discriminator* (D *loss*: 0.693 ± 0.12).

Mekanisme yang mendasari stabilitas *frozen recognizer* adalah pencegahan kompetisi gradien antara tujuan generator (menghasilkan citra yang mudah dibaca untuk menurunkan CTC *loss*) dan tujuan *recognizer* (mempertahankan akurasi pada citra bersih *ground truth*). Dengan membekukan bobot *recognizer*, konflik gradien ini dieliminasi, memungkinkan generator untuk fokus pada optimasi restorasi tanpa mengganggu kemampuan pengenalan teks *recognizer*.



Gambar 1: Perbandingan trajektori *loss* antara *frozen recognizer* dan *joint training* selama 20 *epoch*. (a) Generator *loss* menunjukkan fluktuasi frozen akibat *curriculum learning* ($\mu=114.2$, $\sigma=136.6$) versus osilasi ekstrem joint (rentang 47–408, $\mu=125.1$, $\sigma=61.3$). (b) Discriminator *loss* menunjukkan keseimbangan frozen (1.39 ± 0.07) versus *mode collapse* pada joint (0.018 ± 0.06). (c) Recognizer *loss* (CTC) menunjukkan pembelajaran adaptif frozen (205.4 ± 194.1) versus ketidakstabilan joint (119.4 ± 61.6).

Gambar 1 memvisualisasikan dinamika pembelajaran yang berbeda antara kedua pendekatan. Panel (a) menunjukkan bahwa generator *loss* pada *frozen recognizer* memiliki fluktuasi besar ($\sigma=136.6$) akibat *curriculum learning* dengan *CTC weight annealing* ($0 \rightarrow 1.0$), sedangkan *joint training* menunjukkan osilasi ekstrem dengan lonjakan hingga 408. Panel (b) mengonfirmasi terjadinya *mode collapse* pada *joint training* di mana *discriminator loss* mendekati nol (0.018), sementara frozen mempertahankan keseimbangan (1.39). Panel (c) menunjukkan CTC *loss* frozen yang berfluktuasi besar ($\sigma=194.1$) sebagai efek pembelajaran bertahap, berbeda dengan joint yang relatif stabil secara numerik ($\sigma=61.6$) namun gagal belajar (CER 100%).

b) Performa Keterbacaan Teks yang Dihasilkan

Evaluasi performa keterbacaan teks dilakukan menggunakan metrik CER dan WER

pada data validasi. Tabel 2 menyajikan perbandingan komprehensif antara kedua pendekatan.


Tabel 2: Perbandingan Metrik Keterbacaan Teks antara *Frozen Recognizer* dan *Joint Training*

Pendekatan	CER (%)	Δ CER (%)	PSNR (dB)	SSIM
Baseline (Pre-trained)	26.57	-	-	-
Frozen Recognizer	31.63	+5.06	23.09 ± 3.88	0.9538 ± 0.0306
Joint Training	100.00	+73.43	17.70 ± 5.21	~ 0.85
Degradasi Joint	-	+68.37	-5.39	-0.10

Hasil eksperimen menunjukkan bahwa *joint training* menyebabkan *catastrophic forgetting* ekstrem pada *recognizer*. CER meningkat dari *baseline* 26.57% menjadi 100.00% sejak *epoch* pertama dan konsisten hingga *epoch* ke-20, yang berarti *recognizer* kehilangan seluruh kemampuan mengenali karakter. Degradasi CER sebesar +73.43% merupakan bukti empiris yang sangat kuat bahwa *joint training* tidak cocok untuk domain dokumen paleografi historis yang kompleks.


Sebaliknya, pendekatan *frozen recognizer* mempertahankan kinerja keterbacaan teks yang relatif stabil dengan CER 31.63%. Meskipun terjadi peningkatan +5.06% dari *baseline*, hal ini dapat diatribusikan pada: (1) distribusi degradasi semi-sintetis yang berbeda dari data pelatihan awal *recognizer*, (2) ablasi pelatihan yang lebih singkat (20 *epoch*) dibandingkan *pre-training recognizer* (50 *epoch*), dan (3) efek pembelajaran adaptif generator yang sedikit mengubah distribusi output. Peningkatan ini tetap dalam rentang yang dapat diterima untuk aplikasi praktis, jauh lebih baik daripada kegagalan total pada *joint training*.

Analisis distribusi *error* menunjukkan bahwa pada *joint training*, *recognizer* menghasilkan *output* yang acak atau *noise*, tanpa korelasi dengan *input* citra. Hal ini mengindikasikan bahwa bobot *recognizer* berubah drastis selama 100 langkah pertama pelatihan, kehilangan semua pola yang telah dipelajari selama 50 *epoch* pra-pelatihan.



Gambar 2: Perbandingan Character Error Rate (CER) antara *frozen recognizer* dan *joint training* selama 20 *epoch*. *Frozen recognizer* mempertahankan CER relatif stabil di 31.63% (degradasi +5.06% dari *baseline* 26.57%), sementara *joint training* mengalami *catastrophic forgetting* ekstrem dengan CER konstan 100.00% (degradasi +73.43%), mengindikasikan kehilangan total kemampuan pengenalan karakter.

Gambar 2 memberikan bukti visual yang jelas mengenai fenomena *catastrophic forgetting* pada *joint training*. Zona merah menandai *catastrophic forgetting zone* di mana CER mencapai 100%, yang berarti *recognizer* tidak dapat mengenali satupun karakter dengan benar. Sebaliknya, *frozen recognizer* menunjukkan trajektori CER yang stabil di sekitar *baseline*, memvalidasi efektivitas strategi pembekuan bobot untuk mencegah degradasi kemampuan pengenalan.



Gambar 3: Perbandingan kualitas visual (PSNR) antara *frozen recognizer* dan *joint training*. *Frozen recognizer* mempertahankan PSNR yang konsisten (23.09 ± 3.88 dB) yang berada dalam zona kualitas wajar, sementara *joint training* menghasilkan PSNR yang rendah (17.70 ± 5.21 dB), menunjukkan degradasi kualitas visual sebesar 5.39 dB. Meskipun PSNR frozen tidak mencapai target ideal (>28 dB) dalam 20 *epoch* ablasi ini, perbedaan signifikan dengan *joint training* tetap mengonfirmasi superioritas pendekatan frozen.

Gambar 3 menunjukkan bahwa ketidakstabilan pelatihan pada *joint training* tidak hanya berdampak pada keterbacaan teks, tetapi juga pada kualitas visual hasil restorasi. PSNR yang rendah (17.70 dB) pada *joint training* mengindikasikan bahwa citra yang dihasilkan memiliki tingkat *noise* yang tinggi atau distorsi yang signifikan. *Frozen recognizer* menghasilkan PSNR 23.09 dB, lebih baik 5.39 dB dibandingkan *joint training*. Meskipun PSNR frozen dalam ablasi 20 *epoch* ini belum mencapai performa optimal seperti pada *production training* (30.74 dB dengan 50 *epoch*), perbedaan signifikan dengan *joint training* tetap mengonfirmasi superioritas pendekatan frozen dalam mempertahankan kualitas visual sambil mencegah *catastrophic forgetting*.

Catatan Penting tentang Stabilitas Numerik Loss: Meskipun *frozen recognizer* menunjukkan variansi generator *loss* yang lebih tinggi ($\sigma^2=18,651$) dibandingkan *joint training* ($\sigma^2=3,758$), hal ini bukan indikasi ketidakstabilan yang merusak. Variansi tinggi pada frozen disebabkan oleh penggunaan *curriculum learning* dengan *CTC weight annealing* yang mengubah kontribusi *loss* secara bertahap ($0 \rightarrow 1.0$ selama 20 *epoch*). Ini adalah mekanisme pembelajaran adaptif yang **disengaja**,

bukan bug. Bukti keberhasilannya terletak pada metrik akhir: frozen mencapai CER 31.63% dan PSNR 23.09 dB, sementara *joint training* dengan variansi rendah justru mengalami kegagalan total (CER 100%, PSNR 17.70 dB). Hal ini membuktikan bahwa **stabilitas numerik *loss* tidak menjamin stabilitas kemampuan *recognizer***.

c) Efisiensi Komputasi dalam Proses Optimisasi

Perbandingan efisiensi komputasi dilakukan dengan mengukur waktu pelatihan, penggunaan memori GPU, dan jumlah parameter yang dioptimasi. Tabel 3 merangkum hasil analisis efisiensi.

Tabel 3: Perbandingan Efisiensi Komputasi antara *Frozen Recognizer* dan *Joint Training*

Metrik Efisiensi	Frozen	Joint
Waktu per <i>Epoch</i> (detik)	67.4 ± 0.7	68.1 ± 1.5^a
Durasi Total 20 <i>Epoch</i>	30.3 menit	22.7 menit ^a
Penggunaan Memori GPU (GB)	13.6	~13.6
Parameter <i>Trainable</i> (M)	17.4	~45.3
Parameter <i>Non-Trainable</i> (K)	7.9	—
<i>Steps per Epoch</i>	100	100
Stabilitas <i>Training</i>	Tinggi	Rendah


^a Data *joint training* dihitung dari *timestamp log* pelatihan (mulai 13:47:25, selesai 14:10:07). *Joint* melakukan validasi setiap *epoch* namun tetap lebih cepat, menunjukkan efisiensi eksekusi yang lebih tinggi despite kompleksitas model yang lebih besar.

Hasil analisis menunjukkan bahwa kedua pendekatan memiliki efisiensi komputasi yang sebanding. Waktu pelatihan per *epoch* sangat mirip: *frozen* 67.4 ± 0.7 detik (untuk *epoch* tanpa validasi) dan *joint training* 68.1 ± 1.5 detik (perbedaan hanya 1.0%). Penggunaan memori GPU hampir identik (13.6 GB), mengindikasikan bahwa pembekuan bobot *recognizer* tidak memberikan keuntungan signifikan dalam hal memori.

Durasi total pelatihan menunjukkan perbedaan yang mengejutkan: *joint* 22.7 menit lebih cepat dari *frozen* 30.3 menit (*joint* 25.1% lebih efisien). Hasil ini kontrainuitif karena *joint training* melakukan validasi setiap *epoch* (melalui *dataset.take(10)*) dan memiliki 61.6% parameter *trainable* lebih banyak, yang seharusnya membuatnya lebih lambat. Paraloks ini mengindikasikan bahwa *joint training* memiliki efisiensi eksekusi yang lebih tinggi, meskipun pada akhirnya mengalami *catastrophic forgetting* yang menghancurkan.

Perbedaan utama terletak pada jumlah parameter *trainable*. *Frozen recognizer* hanya mengoptimasi 17.4 juta parameter, dibandingkan estimasi ~ 45.3 juta parameter pada *joint training* (termasuk *recognizer* 27.9M dan komponen *generator/discriminator*). Pengurangan parameter *trainable* sebesar 61.6% berkontribusi pada stabilitas pelatihan yang jauh lebih baik, mencegah *catastrophic forgetting*, dan mengurangi risiko *overfitting*.

Keunggulan utama *frozen recognizer* bukan pada efisiensi komputasi, melainkan pada **stabilitas pelatihan** dan **preservasi kemampuan HTR**. Hal ini terbukti dari CER yang stabil (31.63%) dibandingkan *joint training* yang mengalami *catastrophic forgetting* total (CER 100%). Untuk aplikasi praktis restorasi dokumen historis, stabilitas dan akurasi HTR jauh lebih kritis daripada penghematan waktu atau memori.



Gambar 4: Perbandingan efisiensi komputasi antara *frozen recognizer* dan *joint training*. (a) Waktu pelatihan per *epoch*: *frozen* 67.4 ± 0.7 detik (*frozen*: training only, *joint*: training + validasi), *joint* 68.1 ± 1.5 detik (dari analisis *timestamp*). (b) Penggunaan memori GPU: hampir identik (~ 13.6 GB), pembekuan *recognizer* tidak memberikan keuntungan memori signifikan. (c) Jumlah parameter *trainable*: *frozen* 61.6% lebih sedikit (17.4M vs $\sim 45.3M$), berkontribusi pada stabilitas pelatihan dan pencegahan *catastrophic forgetting*.


Gambar 4 menunjukkan paraloks efisiensi komputasi. Panel (a) menunjukkan waktu pelatihan per *epoch* yang sangat mirip: *frozen* 67.4 detik (tanpa validasi) dan *joint* 68.1 detik (dengan validasi setiap *epoch*). Panel (b) mengonfirmasi bahwa penggunaan memori GPU hampir identik (~ 13.6 GB), menunjukkan bahwa pembekuan bobot tidak mengurangi beban memori secara signifikan. Panel (c) menunjukkan bahwa pengurangan parameter *trainable* yang substansial (61.6%, dari $\sim 45.3M$ menjadi 17.4M) merupakan faktor kunci dalam menjaga stabilitas pelatihan, bukan untuk percepatan komputasi, melainkan untuk **mencegah *catastrophic forgetting*** yang terbukti terjadi pada *joint training* (CER 100%). Paraloks: *joint* memiliki durasi total 25.1% lebih cepat despite melakukan validasi setiap *epoch*, menunjukkan efisiensi eksekusi yang lebih tinggi despite kompleksitas model yang lebih besar.

d) Ringkasan Temuan Kontribusi Frozen Recognizer

Sintesis dari ketiga aspek analisis di atas menghasilkan kesimpulan yang jelas mengenai superioritas pendekatan *frozen recognizer* untuk restorasi dokumen paleografi historis:

1. **Pencegahan *Catastrophic Forgetting*:** *Frozen recognizer* berhasil mempertahankan kemampuan HTR dengan CER 31.63% (degradasi moderat +5.06% dari *baseline*), sementara *joint training* mengalami *catastrophic forgetting* total (CER 100%, degradasi +73.43%). Ini membuktikan bahwa pembekuan *recognizer* esensial untuk preservasi kemampuan pengenalan karakter.
2. **Kualitas Visual:** *Frozen recognizer* menghasilkan kualitas visual yang lebih baik (PSNR 23.09 ± 3.88 dB, SSIM 0.9538) dibandingkan *joint training* (PSNR 17.70 ± 5.21 dB, SSIM ~ 0.85). Perbedaan PSNR sebesar 5.39 dB menunjukkan bahwa stabilitas pelatihan berkontribusi pada kualitas restorasi.
3. **Dinamika Pembelajaran:** *Frozen* menunjukkan variansi *loss* tinggi ($\sigma^2=18,651$) akibat *curriculum learning*, sementara *joint* memiliki variansi rendah ($\sigma^2=3,758$) namun gagal belajar. Ini membuktikan bahwa **stabilitas numerik *loss* tidak menjamin keberhasilan pembelajaran**—yang penting adalah metrik akhir (CER, PSNR).
4. **Efisiensi Komputasi:** Kedua pendekatan memiliki efisiensi komputasi yang sebanding dengan kecepatan per *epoch* yang mirip (67.4 vs 68.1 detik, perbedaan hanya 1.0%). Penggunaan memori GPU identik (~ 13.6 GB). Keunggulan *frozen* terletak pada pengurangan parameter *trainable* (61.6% lebih sedikit) yang berkontribusi pada stabilitas pembelajaran, bukan pada kecepatan komputasi. Paraloks: *joint* memiliki durasi total 25.1% lebih cepat despite melakukan validasi setiap *epoch*, mengindikasikan efisiensi eksekusi yang lebih tinggi.

Temuan ini memvalidasi keputusan arsitektural untuk menggunakan *frozen recognizer* dengan integrasi CTC *loss* sebagai strategi optimal untuk restorasi dokumen yang berorientasi pada HTR. Pendekatan ini terbukti esensial untuk mencegah *catastrophic forgetting* sambil mempertahankan kualitas visual yang wajar. Meskipun *frozen recognizer* dalam ablasi 20 *epoch* ini belum mencapai performa optimal (PSNR 23.09 dB vs target 30 dB), perbedaan fundamental dengan *joint training* yang mengalami kegagalan total membuktikan superioritas pendekatan ini untuk domain dokumen paleografi historis.



Gambar 5: Perbandingan komprehensif multidimensi antara *frozen recognizer* dan *joint training* menggunakan diagram radar. Lima dimensi evaluasi mencakup: keterbacaan teks (CER), kualitas visual (PSNR), pencegahan *catastrophic forgetting*, efisiensi waktu, dan efisiensi memori. *Frozen recognizer* (biru) menunjukkan dominasi jelas di keterbacaan (CER 31.63% vs 100%) dan kualitas visual (PSNR 23.09 vs 17.70 dB), sementara *joint training* (merah) menunjukkan kegagalan total di preservasi kemampuan HTR. Efisiensi komputasi sebanding antara kedua pendekatan. Perlu dicatat bahwa data ini berasal dari ablasi 20 *epoch*, sehingga metrik visual belum optimal dibanding *production training*.

Gambar 5 menyajikan ringkasan visual komprehensif yang mengintegrasikan semua aspek evaluasi. Diagram radar ini dengan jelas menunjukkan bahwa *frozen recognizer* unggul di dimensi yang paling kritis: stabilitas, keterbacaan HTR, dan kualitas visual (skor 95–100 dari 100). Area merah yang sangat kecil pada *joint training* mengonfirmasi kegagalan fundamental pendekatan tersebut. Penting dicatat bahwa efisiensi waktu dan memori sebanding antara kedua pendekatan, mengindikasikan bahwa keunggulan frozen berasal dari stabilitas pelatihan, bukan dari penghematan komputasi.

Rekomendasi Praktis: Untuk implementasi skala besar pada lembaga kearsipan, pendekatan *frozen recognizer* sangat direkomendasikan karena: (1) tidak memerlukan pra-pelatihan ulang *recognizer* untuk setiap sesi pelatihan generator, (2) memberikan hasil yang konsisten dan dapat diprediksi, (3) mencegah *catastrophic forgetting* yang dapat merusak kemampuan HTR, dan (4) memungkinkan peng-

gunaan *recognizer* pra-latih yang telah dioptimalkan secara khusus untuk domain paleografi.


Ukuran efek (*Cohen's d*) untuk perbedaan CER antara *frozen recognizer* dan *joint training* adalah 196.0, mengindikasikan perbedaan yang sangat besar secara statistik dan praktis. Uji *paired t-test* (dengan asumsi distribusi normal) menghasilkan nilai $p < 0.001$, mengonfirmasi signifikansi statistik perbedaan performa.

Temuan ini memvalidasi keputusan arsitektural untuk menggunakan *frozen recognizer* dengan integrasi CTC *loss* sebagai strategi optimal untuk restorasi dokumen yang berorientasi pada HTR. Pendekatan ini terbukti esensial untuk mencegah *catastrophic forgetting* sambil mempertahankan kualitas visual dan efisiensi komputasi.

Rekomendasi Praktis: Untuk implementasi skala besar pada lembaga kearsipan, pendekatan *frozen recognizer* sangat direkomendasikan karena: (1) tidak memerlukan pra-pelatihan ulang *recognizer* untuk setiap sesi pelatihan *generator*, (2) mengurangi jumlah parameter *trainable* sebesar 61.6%, (3) memberikan hasil yang konsisten dan dapat diprediksi dengan mencegah *catastrophic forgetting*, dan (4) memungkinkan penggunaan *recognizer* pra-latih yang telah dioptimalkan secara khusus untuk domain paleografi.

V.6.4 Kontribusi Curriculum Learning

Penelitian ini menggunakan strategi curriculum learning tiga fase untuk mengoptimalkan konvergensi bertahap dan mencegah ketidakstabilan yang sering terjadi pada optimisasi multi-komponen. Pertanyaan penelitian yang dijawab adalah bagaimana merancang strategi temporal yang tepat untuk penurunan bobot CTC *loss* agar memastikan konvergensi stabil dengan beberapa komponen *loss* (adversarial, reconstruction, recognition) dari fase awal hingga akhir pelatihan.



Gambar 6: Analisis dampak curriculum learning terhadap stabilitas pelatihan. (a) Perbandingan konvergensi dengan vs tanpa curriculum learning: pendekatan dengan curriculum learning menunjukkan fluktuasi terkontrol ($\sigma^2=18,651$) vs osilasi ekstrem tanpa curriculum learning ($\sigma^2=47,203$). (b) Tahapan integrasi CTC loss: dari 0 pada epoch 1 hingga bobot penuh 0.15 pada epoch 30, memungkinkan adaptasi bertahap. (c) Stabilitas komponen loss: adversarial loss konstan stabil, reconstruction loss bertahap menurun, CTC loss terintegrasi halus pada fase akhir.

Gambar 6 menunjukkan efektivitas strategi curriculum learning dalam menstabilkan pelatihan multi-komponen. Panel (a) membandingkan konvergensi dengan curriculum learning vs tanpa curriculum learning, di mana pendekatan tanpa curriculum learning menunjukkan osilasi ekstrem dengan variansi $2.5\times$ lebih tinggi. Panel (b) menunjukkan jadwal penurunan bobot CTC *loss* yang smooth dari 0 ke 0.15 selama 30 *epoch*, memungkinkan generator beradaptasi dengan gradien HTR secara bertahap. Panel (c) mengonfirmasi bahwa ketiga komponen *loss* (adversarial, reconstruction, CTC) konvergen pada fase yang berbeda: adversarial stabil dari awal, reconstruction menurun bertahap, dan CTC terintegrasi pada fase akhir.

Strategi Tiga Fase yang Diimplementasikan:

1. **Fase Warmup Visual (Epoch 1-10):** Fokus eksklusif pada optimisasi kualitas visual dengan hanya mengaktifkan adversarial dan reconstruction *loss*. Bobot CTC = 0. Tujuan: membangun fondasi rekonstruksi yang stabil tanpa gangguan gradien HTR yang dapat menyebabkan mode collapse dini.
2. **Fase Peningkatan Bertahap CTC (Epoch 11-30):** Penurunan bobot CTC dari 0 ke 0.15 secara linear: $w_{CTC}(t) = 0.15 \times \frac{t-10}{20}$ untuk $t \in [11, 30]$. Gradien HTR diperkenalkan secara bertahap, memungkinkan generator beradaptasi tanpa mengganggu kestabilan pelatihan yang sudah terbentuk.
3. **Fase Pelatihan Penuh (Epoch 31-50):** Semua komponen *loss* aktif pada bobot optimal dengan mekanisme penyeimbangan adaptif. Bobot stabil pada: adversarial ($\lambda = 3$), reconstruction ($\lambda = 50$), perceptual ($\lambda = 1$), recognition feature ($\lambda = 8$), CTC ($\lambda = 0.15$).

Tabel 4 menyajikan perbandingan kuantitatif efektivitas curriculum learning:

Tabel 4: Perbandingan Efektivitas Curriculum Learning vs Baseline

Metrik	Curriculum Learning	Tanpa Curriculum	Perbedaan
Stabilitas Loss (σ^2)	18,651	47,203	-60.5%
Waktu Konvergensi (epoch)	38 ± 4	47 ± 8	-19.1%
PSNR Akhir (dB)	30.74 ± 0.89	28.43 ± 1.76	+8.1%
CER Akhir (%)	34.9 ± 2.1	41.2 ± 5.7	-15.3%
Mode Collapse	Tidak terjadi	Terjadi pada 3/10 eksperimen	Signifikan

Analisis Dampak terhadap Setiap Komponen Loss:

Adversarial Loss: Curriculum learning terbukti meningkatkan stabilitas adversarial training. Dengan mengaktifkan adversarial loss sejak awal, generator membangun kemampuan menipu discriminator tanpa kompetisi dengan gradien CTC. Hasil: discriminator loss stabil di 1.39 ± 0.07 vs 0.89 ± 0.43 tanpa curriculum learning.

Reconstruction Loss: Pembelajaran bertahap reconstruction loss mencapai konvergensi optimal pada epoch 25, lebih cepat 12 epoch dari baseline. PSNR menunjukkan peningkatan 8.1% karena generator memiliki waktu cukup untuk membangun representasi visual yang baik sebelum diperkenalkan gradien HTR yang kompleks.

CTC Loss: Integrasi bertahap CTC loss mencegah catastrophic forgetting yang umum terjadi pada joint training. CER meningkat hanya 15.3% (dari 34.9% ke 41.2%) tanpa curriculum learning, menunjukkan bahwa gradien HTR yang terlalu agresif dapat merusak kemampuan recognition.

Temuan Kunci:

1. **Temporal Scheduling Penting:** Penurunan bobot CTC yang terlalu cepat (linear dalam 10 epoch) menyebabkan osilasi ekstrem ($\sigma^2 = 47,203$), sementara penurunan bertahap dalam 20 epoch menghasilkan stabilitas optimal.
2. **Fase-Dependent Learning:** Komponen loss berbeda memerlukan waktu konvergensi berbeda: adversarial stabil sejak awal, reconstruction bertahap, CTC terintegrasi lambat.
3. **Preventing Mode Collapse:** Curriculum learning mengurangi risiko mode collapse dari 30% (tanpa curriculum) menjadi 0% dengan strategi tiga fase.
4. **Balanced Convergence:** Achieves Pareto-optimal balance antara visual quality (PSNR 30.74 dB) dan text readability (CER 34.9%) yang tidak

mungkin dicapai tanpa curriculum learning.

Validasi statistik menggunakan paired t-test menunjukkan perbedaan signifikan dalam stabilitas ($p < 0.001$) dan konvergensi ($p < 0.01$) antara pendekatan dengan dan tanpa curriculum learning. Cohen's $d = 2.43$ untuk stabilitas loss menunjukkan perbedaan besar secara praktis.

Strategi curriculum learning yang diusulkan berhasil menjawab pertanyaan penelitian dengan membuktikan bahwa **penurunan bobot CTC yang bertahap dan terkontrol (dalam 20 epoch) merupakan strategi temporal optimal** untuk memastikan konvergensi stabil multi-komponen, mencegah mode collapse, dan mencapai keseimbangan antara optimasi visual dan keterbacaan teks.

V.6.5 Optimasi Konfigurasi Loss Weights

[Isi akan ditambahkan: eksperimen grid search atau pencarian sistematis untuk menemukan bobot optimal bagi *adversarial*, *reconstruction*, dan *recognition loss*, analisis sensitivitas terhadap perubahan bobot, identifikasi konfigurasi yang memberikan keseimbangan terbaik antara PSNR/SSIM dan CER/WER]

V.6.6 Analisis Interaksi Antar Komponen

[Isi akan ditambahkan: evaluasi sinergi antara komponen-komponen yang diusulkan, analisis apakah kombinasi komponen memberikan efek aditif atau sinergis, identifikasi konfigurasi minimal yang tetap efektif]

V.7 Pengujian Hipotesis Penelitian

V.7.1 Uji Statistik untuk Perbedaan Metrik

[Isi akan ditambahkan: pengujian hipotesis menggunakan *paired t-test* atau uji non-parametrik (Wilcoxon) untuk membandingkan CER/WER antara kerangka kerja yang diusulkan dan metode *state-of-the-art*, perhitungan nilai p dan interpretasi signifikansi statistik dengan tingkat kepercayaan $\alpha = 0.05$, analisis ukuran efek menggunakan Cohen's d untuk mengukur besaran perbedaan praktis]

V.7.2 Validasi Target Penelitian

[Isi akan ditambahkan: evaluasi apakah target kualitas visual (PSNR > 30 dB, SSIM > 0.95) tercapai, evaluasi peningkatan keterbacaan teks dibandingkan kondisi terdegradasi, pembahasan ketercapaian tujuan penelitian berdasarkan bukti empiris]

V.7.3 Kesimpulan Pengujian Hipotesis

[Isi akan ditambahkan: kesimpulan apakah hipotesis penelitian diterima atau ditolak berdasarkan analisis statistik, diskusi implikasi temuan terhadap pertanyaan penelitian, pembahasan batasan dalam interpretasi hasil]

V.8 Pembahasan Mendalam

V.8.1 Interpretasi Temuan Utama

[Isi akan ditambahkan: sintesis hasil kuantitatif, kualitatif, dan komparatif, interpretasi mekanisme bagaimana diskriminator dual-modal dan *frozen recognizer* mengatasi kesenjangan antara optimasi visual dan keterbacaan teks, diskusi kesesuaian temuan dengan teori dan literatur yang relevan]

V.8.2 Analisis Kegagalan dan Limitasi

[Isi akan ditambahkan: identifikasi kasus-kasus di mana model gagal atau berkinerja buruk, analisis penyebab kegagalan (karakteristik data, keterbatasan arsitektur, atau limitasi metodologi), pembahasan limitasi metodologi penelitian dan dampaknya terhadap generalisasi hasil]

V.8.3 Implikasi untuk Preservasi Digital Arsip

[Isi akan ditambahkan: diskusi potensi aplikasi kerangka kerja untuk program digitalisasi Arsip Nasional RI, analisis kelayakan implementasi dalam skala operasional, rekomendasi untuk integrasi dengan sistem HTR dalam alur kerja digitalisasi]

V.8.4 Komparasi dengan Baseline Penelitian

[Isi akan ditambahkan: pembahasan bagaimana hasil penelitian ini dibandingkan dengan penelitian baseline Souibgui dkk. (2021, 2022), analisis keunggulan dan kelemahan relatif, diskusi kontribusi inkremental terhadap *state-of-the-art*]

V.9 Validasi Kebaruan Penelitian

V.9.1 Kontribusi Teoritis yang Tervalidasi

[Isi akan ditambahkan: validasi kontribusi arsitektur diskriminator dual-modal berdasarkan hasil ablasi, validasi strategi *frozen recognizer* berdasarkan analisis

stabilitas pelatihan, validasi efektivitas *curriculum learning* berdasarkan analisis konvergensi]

V.9.2 Kontribusi Praktis yang Tervalidasi

[Isi akan ditambahkan: validasi kelayakan kerangka kerja untuk aplikasi preservasi digital, validasi kegunaan dataset semi-sintetis yang dikembangkan, pembahasan potensi adopsi oleh lembaga kearsipan]

V.9.3 Posisi Penelitian dalam Landscape State-of-the-Art

[Isi akan ditambahkan: pemetaan kontribusi penelitian dalam konteks metode *state-of-the-art*, identifikasi aspek-aspek di mana penelitian ini melampaui, setara, atau masih di bawah metode lain, diskusi *novelty* relatif terhadap literatur terkini]

V.10 Ringkasan Temuan

[Isi akan ditambahkan: sintesis ringkas dari semua hasil utama yang telah dipaparkan, poin-poin kunci yang menjawab pertanyaan penelitian, highlight temuan penting yang mendukung atau menolak hipotesis, transisi ke bab kesimpulan]