

**RESTORASI DOKUMEN TERDEGRADASI MENGGUNAKAN
GENERATIVE ADVERSARIAL NETWORK DENGAN
DISKRIMINATOR DUAL-MODAL DAN OPTIMASI
LOSS FUNCTION BERORIENTASI HTR**

TESIS

Karya tulis sebagai salah satu syarat
untuk memperoleh gelar Magister dari
Institut Teknologi Bandung

Oleh

JATNIKO NUR MUTAQIN

NIM: 23523314

(Program Studi Magister Informatika)



INSTITUT TEKNOLOGI BANDUNG

Desember 2025

ABSTRAK

RESTORASI DOKUMEN TERDEGRADASI MENGGUNAKAN *GENERATIVE ADVERSARIAL NETWORK* DENGAN DISKRIMINATOR *DUAL-MODAL* DAN OPTIMASI *LOSS FUNCTION* BERORIENTASI HTR

Oleh

JATNIKO NUR MUTAQIN

NIM: 23523314

(Program Studi Magister Informatika)

Arsip Nasional Republik Indonesia (ANRI) menyimpan ribuan koleksi dokumen paleografi dari abad ke-16 hingga ke-18 yang memiliki nilai sejarah krusial. Namun, sebagian besar dokumen tersebut mengalami degradasi fisik yang parah akibat faktor usia, kelembapan tropis, dan korosi tinta *iron gall*. Kondisi ini memunculkan tantangan ganda: dokumen sulit dibaca secara visual oleh manusia dan hampir mustahil diproses oleh mesin. Pendekatan restorasi konvensional selama ini cenderung menitikberatkan pada perbaikan visual semata (estetika), seperti penghilangan noda dan peningkatan kontras. Sayangnya, peningkatan kualitas visual tersebut tidak selalu berbanding lurus dengan peningkatan keterbacaan mesin, yang menjadi syarat mutlak bagi upaya digitalisasi dan pengindeksan arsip secara massal. Kesenjangan antara kualitas visual dan fungsional inilah yang menjadi fokus utama penelitian ini. Penelitian ini bertujuan mengembangkan kerangka kerja restorasi dokumen berbasis *Generative Adversarial Network* (GAN) yang secara eksplisit mengintegrasikan umpan balik semantik guna meningkatkan kinerja *Handwritten Text Recognition* (HTR). Kebaruan penelitian ini terletak pada penerapan strategi *frozen recognizer* yang dikombinasikan dengan fungsi kerugian multiobjektif lima komponen, serta evaluasi kritis terhadap arsitektur diskriminator *dual-modal*. Metode yang digunakan melibatkan pelatihan generator *U-Net* yang dimodifikasi, yang belajar tidak hanya dari perbedaan piksel citra, tetapi juga dari umpan balik gradien model pengenalan teks yang bobotnya dibekukan. Pendekatan ini dirancang untuk menjaga stabilitas pelatihan yang sering kali menjadi masalah pada arsitektur GAN konvensional. Evaluasi dilakukan secara komprehensif menggunakan 712 citra uji semisintetis yang merepresentasikan karakteristik degradasi dokumen historis. Hasil penelitian menunjukkan bahwa model yang diusulkan mampu menurunkan *Character Error Rate* (CER) secara signifikan dari rata-rata 83,4% pada dokumen terdegradasi menjadi 34,9% pada dokumen hasil restorasi ($p < 0,001$). Capaian CER 34,9% ini hampir setara dengan CER 34,1% yang diperoleh ketika model pengenalan memproses citra bersih tanpa degradasi—batas bawah teoretis yang mencerminkan keterbatasan inheren model pengenalan itu sendiri. Selain keunggulan fungsional, model juga mempertahankan kualitas visual yang tinggi dengan skor *Peak Signal-to-Noise Ratio* (PSNR) mencapai 30,74 dB dan *Structural Similarity Index*

(SSIM) sebesar 0,987. Dibandingkan dengan penelitian sejenis yang menggunakan arsitektur *joint-training*, pendekatan *frozen recognizer* terbukti lebih unggul dalam mencegah fenomena *mode collapse* dan ketidakstabilan gradien. Melalui studi ablatasi, penelitian ini mengungkap temuan empiris yang menantang asumsi umum dalam literatur *deep learning* terkini. Studi ini menemukan bahwa penambahan kompleksitas arsitektur melalui diskriminator *dual-modal* (visual-tekstual) hanya memberikan kontribusi peningkatan kinerja yang marginal dan tidak signifikan secara statistik. Sebaliknya, protokol pelatihan yang disiplin menggunakan strategi *frozen recognizer* dan penyeimbangan fungsi *loss* terbukti menjadi faktor determinan utama keberhasilan restorasi. Hal ini mengindikasikan bahwa stabilitas sinyal pembelajaran jauh lebih vital daripada kompleksitas arsitektur jaringan itu sendiri. Secara teoretis, penelitian ini menyumbangkan wawasan baru mengenai prinsip parsimoni dalam perancangan jaringan saraf tiruan untuk restorasi dokumen, yakni arsitektur yang lebih efisien dapat mengungguli arsitektur kompleks apabila dilatih dengan strategi berobjektif ganda yang tepat. Secara praktis, kerangka kerja ini menawarkan solusi konkret bagi lembaga kearsipan untuk mempercepat proses transkripsi otomatis dokumen historis yang sebelumnya tidak terbaca, membuka peluang baru bagi pelestarian warisan budaya bangsa di era digital.

Kata kunci: Restorasi Dokumen, *Generative Adversarial Networks* (GAN), *Handwritten Text Recognition* (HTR), *Frozen Recognizer*, Dokumen Paleografi

ABSTRACT

DEGRADED DOCUMENT RESTORATION USING GENERATIVE ADVERSARIAL NETWORK WITH DUAL-MODAL DISCRIMINATOR AND HTR-ORIENTED LOSS FUNCTION OPTIMIZATION

By

JATNIKO NUR MUTAQIN

NIM: 23523314

(Master's Program in Informatics)

The National Archives of the Republic of Indonesia (ANRI) houses thousands of paleographic document collections from the 16th to the 18th century, possessing crucial historical value. However, the majority of these documents suffer from severe physical degradation due to aging, tropical humidity, and iron gall ink corrosion. This condition poses a dual challenge: the documents are difficult for humans to decipher visually and nearly impossible for machines to process. Conventional restoration approaches have predominantly focused on visual enhancement (aesthetics), such as stain removal and contrast adjustment. Unfortunately, such visual quality improvements do not necessarily correlate with improved machine legibility—a prerequisite for mass archival digitization and indexing. This discrepancy between visual and functional quality constitutes the primary focus of this research. This study aims to develop a Generative Adversarial Network (GAN)-based document restoration framework that explicitly integrates semantic feedback to enhance Handwritten Text Recognition (HTR) performance. The novelty of this research lies in the implementation of a frozen recognizer strategy combined with a multi-objective loss function comprising five components, alongside a critical evaluation of the dual-modal discriminator architecture. The methodology involves training a modified U-Net generator that learns not only from pixel-level differences but also from gradient feedback provided by a pre-trained HTR model with frozen weights. This approach is designed to maintain training stability, a frequent issue in conventional GAN architectures. Comprehensive evaluation was conducted using 712 semi-synthetic test images representing the degradation characteristics of historical documents. The results demonstrate that the proposed model significantly reduced the Character Error Rate (CER) from an average of 83.4% in degraded documents to 34.9% in restored documents ($p < 0.001$). This CER of 34.9% is nearly equivalent to the 34.1% CER obtained when the recognizer processes clean images without degradation—the theoretical lower bound reflecting the inherent limitations of the recognizer model itself. Beyond functional superiority, the model maintains high visual quality, achieving a Peak Signal-to-Noise Ratio (PSNR) of 30.74 dB and a Structural Similarity Index (SSIM) of 0.987. Compared to similar studies utilizing joint-training architectures, the frozen recognizer approach

proved superior in preventing mode collapse and gradient instability. Through systematic ablation studies, this research reveals empirical findings that challenge prevailing assumptions in recent deep learning literature. The study found that increasing architectural complexity via a dual-modal discriminator (visual-textual) yielded only marginal performance contributions that were statistically insignificant. Conversely, a disciplined training protocol employing the frozen recognizer strategy and precise loss balancing proved to be the determinant factors for restoration success. This indicates that the stability of the learning signal is far more vital than the complexity of the network architecture itself. Theoretically, this study contributes new insights regarding the principle of parsimony in neural network design for document restoration, demonstrating that a more efficient architecture can outperform complex ones when trained with an appropriate dual-objective strategy. Practically, this framework offers a concrete solution for archival institutions to accelerate the automatic transcription of previously illegible historical documents, opening new avenues for cultural heritage preservation in the digital era.

Keywords: *Document Restoration, Generative Adversarial Networks (GAN), Handwritten Text Recognition (HTR), Frozen Recognizer, Paleographic Documents.*

**RESTORASI DOKUMEN TERDEGRADASI MENGGUNAKAN
GENERATIVE ADVERSARIAL NETWORK DENGAN
DISKRIMINATOR DUAL-MODAL DAN OPTIMASI
LOSS FUNCTION BERORIENTASI HTR**

Oleh

Jatniko Nur Mutaqin

NIM: 23523314

(Program Studi Magister Informatika)

Institut Teknologi Bandung

Menyetujui

Tim Pembimbing

Tanggal

Ketua

(Ir. I Gusti Bagus Baskara Nugraha, ST, MT, Ph.D)

*Dipersembahkan kepada orang tua, istri, anak,
adik kakak, mertua serta keluarga besarku tercinta
yang senantiasa mendukung lahir dan batin.*

KATA PENGANTAR

Puji dan syukur penulis panjatkan ke hadirat Tuhan Yang Maha Esa, karena atas berkat, rahmat, dan karunia-Nya, penulis dapat menyelesaikan tesis yang berjudul Restorasi Dokumen Terdegradasi Menggunakan Generative Adversarial Network dengan Diskriminator Dual-Modal dan Optimasi Loss Function Berorientasi HTR.

Penulisan tesis ini dilakukan dalam rangka memenuhi salah satu syarat untuk mencapai gelar Magister pada Program Smart-X Sekolah Teknik Elektro dan Informatika (STIE) Institut Teknologi Bandung.

Penelitian ini dilatarbelakangi oleh kepedulian penulis terhadap tantangan preservasi digital warisan sejarah bangsa, khususnya koleksi dokumen paleografi abad ke-16 hingga ke-18 yang tersimpan di Arsip Nasional Republik Indonesia (ANRI). Penulis menyadari bahwa restorasi dokumen tidak hanya tentang perbaikan visual semata, tetapi juga bagaimana menjembatani kualitas visual tersebut dengan keterbacaan mesin, untuk mendukung digitalisasi arsip dan diperolehnya fakta sejarah baru dari koleksi arsip yang berhasil di rekognisi. Melalui pengembangan kerangka kerja GAN dengan strategi Frozen Recognizer, penelitian ini diharapkan dapat memberikan sumbangsih teknis bagi kemajuan teknologi restorasi dokumen dan pengenalan teks tulisan tangan (HTR) pada dokumen historis

Penulis menyadari bahwa penyelesaian tesis ini tidak terlepas dari bantuan, bimbingan, dan dukungan dari berbagai pihak. Oleh karena itu, pada kesempatan ini, penulis ingin menyampaikan rasa terima kasih dan penghargaan yang setinggi-tingginya kepada:

1. Bapak Ir. I Gusti Bagus Baskara Nugraha, ST, MT, Ph.D , selaku pembimbing utama, yang telah meluangkan waktu, tenaga, dan pikiran untuk memberikan arahan strategis, diskusi mendalam mengenai topik penelitian, serta motivasi tanpa henti hingga penelitian ini dapat diselesaikan.
2. Kementerian Komunikasi dan Digital Republik Indonesia (KOMDIGI) yang telah memberikan beasiswa pasca sarjana, program magister multidisiplin Smart System (Smart-X).
3. Arsip Nasional Republik Indonesia (ANRI), yang telah memfasilitasi akses terhadap dataset dokumen historis dan seluruh sumber daya komputasi untuk mendukung penelitian ini.
4. Segenap Dosen dan Staf Pengajar di Program Pascasarjana STIE ITB yang telah memberikan bekal ilmu pengetahuan yang sangat bermanfaat selama masa

perkuliahan.

5. Seluruh Keluarga, atas doa yang tidak pernah putus, kasih sayang, serta dukungan moral dan material yang menjadi sumber kekuatan penulis dalam melewati berbagai tantangan selama penelitian.
6. Rekan-rekan seperjuangan program Smart-X, terima kasih atas diskusi produktif, dan berbagi pengetahuan, serta kebersamaan yang menyenangkan.

Penulis menyadari bahwa tesis ini masih jauh dari kesempurnaan, mengingat kompleksitas tantangan dalam restorasi dokumen kuno. Oleh karena itu, penulis sangat mengharapkan kritik dan saran yang membangun demi penyempurnaan penelitian ini di masa mendatang.

Akhir kata, penulis berharap semoga tesis ini dapat memberikan manfaat bagi pengembangan ilmu pengetahuan, khususnya di bidang kecerdasan artifisial dan preservasi digital, serta dapat diaplikasikan untuk pelestarian sejarah bangsa.

Bandung, Desember 2025

Jatniko Nur Mutaqin

DAFTAR ISI

ABSTRAK	i
ABSTRACT	iii
LEMBAR PENGESAHAN	v
HALAMAN PERUNTUKAN	vi
KATA PENGANTAR	vii
DAFTAR LAMPIRAN	xii
DAFTAR GAMBAR DAN ILUSTRASI	xiii
DAFTAR TABEL	xiv
DAFTAR LAMBANG DAN SINGKATAN	xv
Bab I Pendahuluan	1
I.1 Latar Belakang	1
I.2 Rumusan Masalah	4
I.3 Pertanyaan Penelitian	4
I.4 Tujuan Penelitian	5
I.5 Ruang Lingkup	6
I.6 Hipotesis Penelitian	7
I.7 Kebaruan Penelitian	7
I.8 Sistematika Penulisan	7
Bab II Tinjauan Pustaka	11
II.1 Degradasi Dokumen Historis	11
II.1.1 Karakteristik Degradasi Dokumen Historis	12
II.2 Evolusi Metode Restorasi Dokumen	17
II.2.1 Pendekatan Tradisional dan Keterbatasannya	17
II.2.2 Transisi ke Pembelajaran Mendalam	19
II.3 Generative Adversarial Networks	21
II.3.1 Arsitektur dan Mekanisme GAN	21
II.3.2 Pix2Pix dan Evolusi untuk Keluaran Terstruktur	22
II.4 Kajian Terkini dalam Restorasi Dokumen	23
II.4.1 ERB-MultiTask: Integrasi Pionir GAN dan Pengenal HTR	24
II.4.2 DE-GAN: Peningkatan Dokumen dengan Pendekatan Adversarial	28
II.4.3 Analisis Komparatif: ERB-MultiTask vs DE-GAN	29
II.4.4 Text-DIAE: Autoenkoder Invarian Degradasi Mandiri	31
II.4.5 DocEnTr: Transformer untuk Peningkatan Dokumen	33
II.4.6 Debat: Transformer vs GAN	36
II.4.7 CycleGAN dan Pembelajaran Tak Berpasangan untuk Peningkatan Dokumen	37
II.4.8 Refleksi Komprehensif terhadap Bias Metodologis dalam Literatur	38
II.5 Pengenalan Teks Tulisan Tangan: Arsitektur dan Tantangan	40
II.5.1 Evolusi Arsitektur HTR	40
II.5.2 Loss CTC: Mekanisme dan Implikasi untuk Restorasi	42

II.5.3	Paradigma Transformer: Dari Pengenalan hingga Peningkatan Dokumen	43
II.5.4	Pembelajaran Mandiri: Revolusi dalam Pemrosesan Dokumen	44
II.5.5	Kompromi antara Pembelajaran Terawasi dan Mandiri	45
II.5.6	Arsitektur CNN+Transformer dan Justifikasi untuk Kasus Paleografi	45
II.5.7	Analisis Komparatif: CNN+ <i>Transformer</i> vs HTR Konvensional	46
II.6	Pembelajaran Multimodal dan Diskriminator Dual Modal	48
II.6.1	Landasan Teoretis dan Kemajuan Arsitektur Multimodal	48
II.6.2	Aplikasi Multimodal untuk Restorasi Dokumen	49
II.6.3	Konsep Diskriminator Multimodal	50
II.7	Sintesis Fungsi <i>Loss</i> dan Optimasi Multiobjektif	51
II.7.1	Keterbatasan Pelatihan <i>Loss</i> Tunggal	51
II.7.2	Kerangka Konseptual Fungsi <i>Loss</i> Multikomponen	52
II.7.3	Tantangan Penyeimbangan Multiobjektif	53
II.8	Kesenjangan Penelitian dan Positioning	54
II.8.1	Sintesis Keterbatasan Metode yang Ada	54
II.8.2	Posisi dan Kontribusi Penelitian Ini	58
II.9	Sintesis Tinjauan Pustaka	59
Bab III	Metodologi Penelitian	62
III.1	Kerangka Teori Metodologi Penelitian	62
III.1.1	Design Science Research Methodology (DSRM)	62
III.1.2	Siklus Iteratif Berbasis Bukti Empiris	64
III.2	Tahapan Penelitian	65
III.2.1	Identifikasi Masalah dan Motivasi (Tahap 1)	65
III.2.2	Definisi Tujuan Solusi (Tahap 2)	67
III.2.3	Spesifikasi Kebutuhan Sistem	67
III.2.4	Lingkungan Eksperimen dan Spesifikasi Komputasi	70
III.2.5	Desain dan Pengembangan Artefak (Tahap 3)	71
III.2.6	Demonstrasi (Tahap 4)	73
III.2.7	Evaluasi (Tahap 5)	74
III.2.8	Komunikasi (Tahap 6)	75
Bab IV	Perancangan Sistem	77
IV.1	Arsitektur dan Komponen Utama	77
IV.1.1	Arsitektur Generator	78
IV.1.2	Arsitektur Diskriminator	80
IV.1.3	Arsitektur HTR	84
IV.1.4	Fungsi Loss Multikomponen	86
IV.2	Pengembangan Dataset	90
IV.2.1	Pembuatan <i>Ground Truth</i> untuk GAN	90
IV.2.2	Pembuatan <i>Ground Truth</i> untuk <i>Recognizer</i>	92
IV.2.3	Dataset Evaluasi Kuantitatif	92
IV.2.4	Dataset Evaluasi Kualitatif	93
IV.3	Strategi dan Protokol Pelatihan	93
IV.3.1	<i>Curriculum Learning</i> dan Protokol Optimisasi	93
IV.3.2	Mekanisme Regularisasi dan Konfigurasi Teknis	96

IV.4 Konfigurasi Evaluasi	97
IV.4.1 Metode Klasik untuk Perbandingan Kuantitatif	97
IV.4.2 Studi Ablasi sebagai Validasi Komponen	98
IV.4.3 Metrik Evaluasi	98
Bab V Hasil dan Pembahasan	102
V.1 Pendahuluan	102
V.2 Hasil Kuantitatif pada Set Uji Semi-Sintetis Realistik	102
V.2.1 Performa Model pada Set Uji	102
V.2.2 Perkembangan Metrik Pelatihan	106
V.2.3 Analisis Korelasi Tingkat Degradasi	107
V.3 Hasil Kualitatif pada Dokumen Historis Nyata	108
V.3.1 <i>Dataset</i> dan Protokol Evaluasi Kualitatif	109
V.3.2 Hasil Kualitatif dan Observasi	110
V.3.3 Evaluasi Ahli Paleografi	112
V.3.4 Analisis Kesenjangan Domain dan Keterbatasan Evaluasi	115
V.3.5 Kesimpulan Evaluasi Kualitatif	116
V.4 Studi Ablasi	116
V.4.1 Ablasi Komponen Fungsi <i>Loss</i>	117
V.4.2 Ablasi Strategi <i>Frozen Recognizer</i>	119
V.4.3 Ablasi Diskriminator <i>Dual-Modal</i>	124
V.4.4 Ablasi <i>Curriculum Learning</i>	127
V.4.5 Analisis Bobot Fungsi <i>Loss</i>	133
V.5 Pengujian Hipotesis Penelitian	138
V.5.1 Evaluasi Komponen Hipotesis	138
V.5.2 Kesimpulan Pengujian Hipotesis	140
V.6 Posisi Penelitian terhadap Pustaka Terkini	141
V.7 Interpretasi dan Implikasi Temuan	143
V.7.1 Sintesis Hasil Eksperimen	143
V.7.2 Analisis Pola Kegagalan dan Keterbatasan	145
V.7.3 Kontribusi Praktis	149
Bab VI Kesimpulan dan Saran	151
VI.1 Kesimpulan	151
VI.2 Keterbatasan	152
VI.3 Saran	152
VI.3.1 Saran untuk Penelitian Lanjutan	153
VI.3.2 Saran untuk Implementasi Praktis	153
VI.4 Penutup	154
DAFTAR PUSTAKA	155
LAMPIRAN	160

DAFTAR LAMPIRAN

Lampiran A. Arsitektur Generator U-Net Enhanced	161
Lampiran B. Arsitektur Diskriminator Dual-Modal Enhanced	162
Lampiran C. Formulir Penilaian Ahli Paleografi	163

DAFTAR GAMBAR DAN ILUSTRASI

Gambar II.1.	Struktur Bab II: Tinjauan Pustaka	11
Gambar II.2.	Contoh Degradasi Dokumen ANRI Abad 16-18	12
Gambar II.3.	Arsitektur U-Net dengan Koneksi Pintas	20
Gambar II.4.	Kerangka Kerja Pelatihan Adversarial pada GAN	21
Gambar II.5.	Arsitektur CRNN untuk Ekstraksi Fitur Visual	41
Gambar II.6.	Mekanisme CTC untuk Penyelarasan Otomatis	42
Gambar III.1.	Kerangka DSRM dengan Siklus Iteratif	63
Gambar III.2.	Alur Pengembangan Kerangka Kerja	72
Gambar IV.1.	Kerangka kerja GAN-HTR dengan diskriminator <i>dual-modal</i>	78
Gambar IV.2.	Arsitektur Generator U-Net <i>Enhanced</i>	79
Gambar IV.3.	Arsitektur Diskriminator <i>Dual-Modal Enhanced</i>	81
Gambar IV.4.	Arsitektur HTR Recognizer	84
Gambar IV.5.	Alur pembuatan <i>ground truth</i> untuk GAN-HTR	91
Gambar IV.6.	Pasangan dataset semi-sintetis realistis	92
Gambar V.1.	Perbandingan metrik kuantitatif	104
Gambar V.2.	Analisis peningkatan metrik	104
Gambar V.3.	Perbandingan visual metode restorasi	105
Gambar V.4.	Perkembangan metrik validasi	106
Gambar V.5.	Korelasi degradasi dan performa	107
Gambar V.6.	Restorasi dokumen ANRI autentik	111
Gambar V.7.	Trajektori <i>loss frozen</i> berbanding <i>joint</i>	120
Gambar V.8.	Trajektori CER frozen berbanding <i>joint</i>	121
Gambar V.9.	PSNR frozen berbanding <i>joint</i>	121
Gambar V.10.	Efisiensi komputasi frozen berbanding <i>joint</i>	123
Gambar V.11.	Radar chart performa frozen berbanding <i>joint</i>	124
Gambar V.12.	Evolusi komponen <i>loss curriculum</i>	128
Gambar V.13.	Analisis statistik curriculum learning	130
Gambar V.14.	Analisis tiga fase <i>curriculum</i>	132
Gambar V.15.	Proporsi pengaruh <i>loss</i>	134
Gambar V.16.	Variabilitas besaran <i>loss</i>	134
Gambar V.17.	Mekanisme penyeimbangan besaran	135
Gambar V.18.	Distribusi tingkat CER dan posisi kesalahan	147

DAFTAR TABEL

Tabel II.1.	Pengaruh Jenis Degradasi terhadap Kinerja HTR	16
Tabel II.2.	Perbandingan Paradigma Metode Restorasi	17
Tabel II.3.	Hasil Kuantitatif ERB-MultiTask	26
Tabel II.4.	Perbandingan ERB-MultiTask dan DE-GAN	29
Tabel II.5.	Perbandingan Pendekatan Terawasi vs Mandiri	45
Tabel II.6.	Perbandingan Metode Restorasi (Metrik Performa)	55
Tabel II.7.	Perbandingan Metode Restorasi (Karakteristik Arsitektur)	56
Tabel III.1.	Target Metrik Kuantitatif Penelitian	67
Tabel III.2.	Spesifikasi Kebutuhan Fungsional Kerangka Kerja Restorasi	68
Tabel III.3.	Spesifikasi Kebutuhan Non-Fungsional Kerangka Kerja Restorasi	69
Tabel III.4.	Matriks Pelacakan: Kebutuhan Sistem vs Rumusan Masalah	69
Tabel III.5.	Lingkungan eksperimen	70
Tabel IV.1.	Analisis komparatif strategi integrasi pengenalan HTR	86
Tabel IV.2.	Konfigurasi bobot <i>loss</i> optimal	89
Tabel IV.3.	Protokol <i>curriculum learning</i> tiga fase	94
Tabel IV.4.	Spesifikasi implementasi teknis pelatihan	96
Tabel IV.5.	Ringkasan metode <i>baseline</i> klasik	97
Tabel IV.6.	Pemetaan metrik evaluasi dengan komponen arsitektur	98
Tabel IV.7.	Spesifikasi implementasi metrik evaluasi	99
Tabel V.1.	Hasil kuantitatif pada set uji semi-sintetis	103
Tabel V.2.	Ringkasan metrik CER <i>baseline</i>	105
Tabel V.3.	Karakteristik dataset ANRI	109
Tabel V.4.	Prosedur evaluasi ahli	113
Tabel V.5.	Evaluasi ahli paleografi	113
Tabel V.6.	Performa restorasi ANRI	114
Tabel V.7.	Kesenjangan domain pelatihan-riil	115
Tabel V.8.	Studi ablasi komponen <i>loss</i>	117
Tabel V.9.	Perbandingan <i>loss frozen</i> berbanding <i>joint</i>	119
Tabel V.10.	Metrik keterbacaan frozen berbanding <i>joint</i>	120
Tabel V.11.	Efisiensi komputasi frozen berbanding <i>joint</i>	122
Tabel V.12.	Temuan kunci frozen berbanding <i>joint</i>	123
Tabel V.13.	Ablasi diskriminator dual-modal berbanding CNN	125
Tabel V.14.	Performa <i>curriculum</i> berbanding non- <i>curriculum</i>	127
Tabel V.15.	Konfigurasi bobot <i>loss</i> produksi	133
Tabel V.16.	Lima konfigurasi terbaik <i>grid search</i>	135
Tabel V.17.	Sensitivitas bobot piksel	136
Tabel V.18.	Sensitivitas bobot CTC	136
Tabel V.19.	Sensitivitas bobot RecFeat	137
Tabel V.20.	Hasil pengujian statistik formal hipotesis penelitian	139
Tabel V.21.	Evaluasi hipotesis penelitian	140
Tabel V.22.	Perbandingan dengan pustaka	142
Tabel V.23.	Distribusi Tingkat CER	146
Tabel V.24.	Karakteristik Kesalahan Karakter	146

DAFTAR SINGKATAN DAN LAMBANG

SINGKATAN	Nama	Hal.
AI	<i>Artificial Intelligence</i>	2
ANRI	<i>Arsip Nasional Republik Indonesia</i>	1
API	<i>Application Programming Interface</i>	85
BCE	<i>Binary Cross-Entropy</i>	30
BiGRU	<i>Bidirectional Gated Recurrent Unit</i>	25
BiLSTM	<i>Bidirectional Long Short-Term Memory</i>	25
CBAM	<i>Convolutional Block Attention Module</i>	35
CER	<i>Character Error Rate</i>	5
cGAN	<i>Conditional Generative Adversarial Network</i>	20
CLI	<i>Command-Line Interface</i>	90
CNN	<i>Convolutional Neural Network</i>	15
CRNN	<i>Convolutional Recurrent Neural Network</i>	20
CTC	<i>Connectionist Temporal Classification</i>	25
CUDA	<i>Compute Unified Device Architecture</i>	90
cuDNN	<i>CUDA Deep Neural Network library</i>	90
CWV	<i>Core Web Vitals</i>	95
DE-GAN	<i>Document Enhancement GAN</i>	18
DIBCO	<i>Document Image Binarization Contest</i>	22
DocEnTr	<i>Document Enhancement Transformer</i>	19
DRD	<i>Distance Reciprocal Distortion</i>	22
DSRM	<i>Design Science Research Methodology</i>	50
ERB	<i>Enhance to Read Better</i>	18
FCN	<i>Fully Convolutional Network</i>	16
FM	<i>F-measure</i>	22
Fps	<i>pseudo-F-measure</i>	22
FR	<i>Functional Requirement</i>	60
GAN	<i>Generative Adversarial Network</i>	2
GPU	<i>Graphics Processing Unit</i>	85
GT	<i>Ground Truth (Kebenaran Dasar)</i>	55
H-DIBCO	<i>Handwritten Document Image Binarization Contest</i>	22
HMM	<i>Hidden Markov Model</i>	25
HTR	<i>Handwritten Text Recognition</i>	3
IAM	<i>IAM Handwriting Database</i>	27
ICDAR	<i>International Conference on Document Analysis and Recognition</i>	22
IIIT5K	<i>IIIT 5K-word dataset</i>	27
KHATT	<i>Arabic Handwritten Text Database</i>	27
LSTM	<i>Long Short-Term Memory</i>	25
MAE	<i>Mean Absolute Error</i>	30

ML	<i>Machine Learning</i>	2
MLflow	<i>Machine Learning Flow</i>	90
MSE	<i>Mean Squared Error</i>	30
MSFP	<i>Multi-Scale Feature Pyramid</i>	35
NFR	<i>Non-Functional Requirement</i>	65
OCR	<i>Optical Character Recognition</i>	3
PALM	<i>Presentation Attack Liveness Detection in Mobile scenarios</i>	27
Pix2Pix	<i>Image-to-Image Translation with Conditional Adversarial Networks</i>	19
PSNR	<i>Peak Signal-to-Noise Ratio</i>	5
RDB	<i>Residual Dense Block</i>	35
RMSProp	<i>Root Mean Square Propagation</i>	85
RNN	<i>Recurrent Neural Network</i>	25
SDM	<i>Sumber Daya Manusia</i>	60
SGD	<i>Stochastic Gradient Descent</i>	85
SNR	<i>Signal-to-Noise Ratio</i>	30
SOP	<i>Standard Operating Procedure</i>	65
SOTA	<i>State-of-the-Art</i>	5
SSIM	<i>Structural Similarity Index Measure</i>	5
UNESCO	<i>United Nations Educational, Scientific and Cultural Organization</i>	1
U-Net	<i>U-shaped Convolutional Network</i>	16
VGG	<i>Visual Geometry Group</i>	17
ViT	<i>Vision Transformer</i>	19
VOC	<i>Visual Object Classes</i>	27
WER	<i>Word Error Rate</i>	28

LAMBANG	NAMA	Hal.
α	Koefisien bobot untuk <i>loss function</i> , tingkat signifikansi statistik	75
β	Koefisien bobot untuk <i>Binary Cross-Entropy loss</i>	75
λ	Koefisien bobot untuk <i>CTC loss</i> , parameter regularisasi	75
θ	Parameter model <i>neural network</i>	75
σ	Deviasi standar	75
μ	Rata-rata (<i>mean</i>)	75
ε	<i>Token blank</i> /kosong dalam <i>CTC</i> , konstanta kecil untuk stabilitas numerik	75
Δ	Delta (selisih/perubahan nilai)	75
π	<i>Alignment path</i> dalam <i>CTC</i>	75
π_t	<i>Token</i> pada <i>timestep t</i> dalam <i>alignment path</i>	76
∇ atau ∂	Operator gradien atau turunan parsial	75
Σ	Operator penjumlahan	75
Π	Operator perkalian	75
$\int$	Operator integral	75
argmax	Argumen yang memaksimalkan fungsi	76
$\sim$	Terdistribusi menurut	75
$\rightarrow$	Menuju atau konvergen ke	75
$\mathcal{L}$	Fungsi <i>loss</i> (kerugian)	75
$\mathcal{L}_{total}$	Total <i>loss function</i>	75
$\mathcal{L}_{adversarial}$ atau $\mathcal{L}_{adv}$	<i>Adversarial loss</i>	75
$\mathcal{L}_{reconstruction}$	<i>Reconstruction loss</i>	75
$\mathcal{L}_{L1}$	<i>L1 loss (Mean Absolute Error)</i>	75
$\mathcal{L}_{L2}$	<i>L2 loss (Mean Squared Error)</i>	75
$\mathcal{L}_{CTC}$	<i>CTC (Connectionist Temporal Classification) loss</i>	75
$\mathcal{L}_{perceptual}$	<i>Perceptual loss</i>	75
$\mathcal{L}_{pixel}$	<i>Pixel-wise loss</i>	75
$\mathcal{L}_{BCE}$	<i>Binary Cross-Entropy loss</i>	75
$\mathcal{L}_{GAN}$	<i>GAN loss</i>	75
$\mathcal{L}_{cycle}$	<i>Cycle consistency loss</i>	75
G	<i>Generator</i> dalam GAN	75
D	<i>Discriminator</i> dalam GAN	75
$G(z)$	<i>Output</i> dari <i>generator</i> dengan <i>input z</i>	75
$D(x)$	<i>Output</i> dari <i>discriminator</i> dengan <i>input x</i>	75
$G_{A \rightarrow B}$	<i>Generator</i> dari domain <i>A</i> ke <i>B</i>	75
$G_{B \rightarrow A}$	<i>Generator</i> dari domain <i>B</i> ke <i>A</i>	75
$V(D, G)$	Fungsi nilai (<i>value function</i>) dalam GAN	75

x	Sampel data asli, <i>input</i> citra	75
y	Label atau <i>ground truth</i> , kondisi dalam <i>conditional GAN</i>	75
z	<i>Noise vector</i> atau representasi laten	
$\mathbb{E}$	Ekspektasi atau nilai harapan	75
p_{data}	Distribusi data asli	75
p_z	Distribusi <i>prior (noise)</i>	75
$p(y x)$	Probabilitas bersyarat <i>output y given input x</i>	75
$p_t(\pi_t x)$	Probabilitas <i>token</i> pada <i>timestep t</i>	
$\mathcal{B}$	Fungsi penciutan (<i>collapse function</i>) dalam CTC	75
$\mathcal{B}^{-1}$	Fungsi invers penciutan dalam CTC	75
T	Jumlah <i>timestep</i> atau panjang <i>sequence</i>	
$ x - G(y) _1$	L1 <i>distance</i> antara <i>ground truth</i> dan <i>generated image</i>	75
$ x - G(y) _2$	L2 <i>distance</i> antara <i>ground truth</i> dan <i>generated image</i>	75
$N \times N$	Ukuran <i>patch</i> dalam PatchGAN	
d	Cohen's d (<i>effect size</i>)	75
n	Jumlah sampel	75
p	p -value (nilai probabilitas statistik)	75
r	Koefisien korelasi	75
R^2	Koefisien determinasi	
$O(n)$	Notasi Big-O untuk kompleksitas linear	75
$O(n^2)$	Notasi Big-O untuk kompleksitas kuadratik	75

Bab I Pendahuluan

I.1 Latar Belakang

Arsip Nasional Republik Indonesia menyimpan berbagai koleksi arsip bersejarah yang sangat bernilai dan diakui oleh UNESCO sebagai Daftar Ingatan Dunia (*Memory of the World Register*). Koleksi ini mencakup dokumen tulisan tangan bersejarah dari abad ke-16 hingga ke-18 yang merepresentasikan jati diri bangsa dan merupakan aset budaya penting. Namun, dokumen-dokumen ini mengalami degradasi fisik yang disebabkan oleh berbagai faktor seperti kondisi lingkungan, usia dokumen, dan proses penyimpanan yang tidak optimal sepanjang waktu.

Degradasi yang terjadi mencakup berbagai bentuk kerusakan dengan karakteristik unik. Rembesan tinta merupakan tembusan tinta dari halaman lain yang menciptakan efek bayangan karakter terbalik dengan intensitas bervariasi. Pemudaran terjadi sebagai hilangnya warna tinta, khususnya pada *iron gall ink* yang mengubah warna dari hitam menjadi coklat keabu-abuan. Tinta jenis ini juga dapat memicu korosi, sebuah proses kimiawi yang merusak serat kertas hingga membuatnya rapuh atau berlubang. Kerusakan lainnya adalah noda yang muncul dari kelembaban atau jamur, muncul secara tidak teratur, dan dapat menutupi sebagian atau seluruh karakter. Kondisi degradasi ini tidak hanya mengganggu keutuhan visual dokumen, tetapi juga mengancam keutuhan dan keaslian informasi yang terkandung di dalamnya. Hal ini menimbulkan tantangan serius dalam upaya pelestarian digital, sebagaimana yang diamanatkan oleh Undang-Undang Nomor 43 Tahun 2009 tentang Kearsipan.

Secara khusus, degradasi fisik dokumen menjadi penghambat utama dalam implementasi sistem Pengenalan Teks Tulisan Tangan (HTR) yang sangat penting untuk transkripsi otomatis dokumen tulisan tangan. Penelitian menunjukkan bahwa sistem HTR mengalami penurunan akurasi yang signifikan ketika diaplikasikan pada dokumen terdegradasi Gatos dkk. (2006). Tingkat kesalahan pengenalan karakter (CER) dapat meningkat hingga 15% atau lebih pada dokumen dengan degradasi berat, sehingga menyulitkan proses digitalisasi dan ekstraksi informasi secara otomatis Jadhav dan Raghuwanshi (2022). Kondisi ini berdampak langsung pada efisiensi operasional lembaga kearsipan dan aksesibilitas informasi bagi peneliti serta masyarakat luas.

Pendekatan untuk mengatasi masalah degradasi dokumen telah berkembang dari teknik tradisional hingga metode berbasis pembelajaran mendalam. Metode tradisional seperti penentuan ambang adaptif Sauvola dan Pietikäinen (2000) dan Otsu (1979) dan segmentasi berbasis ruang warna terbukti efektif untuk kasus degradasi sederhana, seperti noda ringan atau perubahan warna minor. Namun, metode ini memiliki keterbatasan signifikan dalam menangani degradasi kompleks

seperti tembus tinta yang parah atau variasi intensitas latar belakang yang tidak merata M. A. Souibgui dan Kessentini (2021b). Sebagai alternatif, pendekatan berbasis Jaringan Adversarial Generatif (GAN) menawarkan solusi yang lebih adaptif dan andal untuk restorasi dokumen Goodfellow dkk. (2014).

GAN memanfaatkan dua jaringan saraf yang saling berkompetisi: generator (pembuat) yang mencoba menghasilkan citra dokumen yang lebih bersih, dan diskriminator (pembeda) yang menilai keaslian citra tersebut. Proses kompetitif ini memungkinkan GAN untuk mempelajari pola degradasi yang kompleks dan menghasilkan hasil restorasi yang lebih baik secara visual. Namun, evaluasi mendalam terhadap berbagai arsitektur GAN mengungkap pola yang menarik.

Penelitian terkini menunjukkan bahwa performa metode-metode tersebut sangat bergantung pada bagaimana keterbacaan teks dievaluasi. DE-GAN, misalnya, melaporkan penurunan CER yang signifikan dari 0.37 menjadi 0.01 pada eksperimen tertentu, namun evaluasi keterbacaan ini dilakukan setelah pelatihan selesai, bukan sebagai bagian dari fungsi objektif M. A. Souibgui dan Kessentini (2021b). Sebaliknya, DocEnTr mencapai PSNR tertinggi (22.29 dB) dengan arsitektur transformer saja, namun pendekatan ini tanpa komponen kompetitif cenderung menghasilkan keluaran yang terlalu halus yang dapat menghilangkan detail tekstur penting M. Souibgui, Kessentini, dkk. (2022a).

Pola ini mengindikasikan adanya kompromi mendasar antara optimasi visual dan keterbacaan teks. Metode yang difokuskan pada metrik visual seperti PSNR seringkali mengabaikan karakteristik spesifik yang penting untuk HTR. Diskriminator pada arsitektur GAN umumnya dirancang untuk evaluasi visual semata, tidak mempertimbangkan apakah struktur karakter masih dapat dibaca oleh sistem HTR. Akibatnya, peningkatan kualitas visual tidak selalu berbanding lurus dengan peningkatan akurasi pengenalan teks.

Temuan ini menunjukkan bahwa citra yang terlihat bersih secara visual belum tentu optimal untuk sistem HTR. Metrik visual seperti PSNR dan SSIM mengukur kemiripan piksel secara keseluruhan, namun tidak sensitif terhadap distorsi halus pada struktur karakter yang krusial untuk pengenalan teks. Oleh karena itu, diperlukan pendekatan yang secara eksplisit mengintegrasikan evaluasi keterbacaan ke dalam proses restorasi dokumen.

Kesenjangan antara optimasi visual dan optimasi keterbacaan ini menjadi fokus utama penelitian ini. Untuk mengatasi keterbatasan tersebut, penelitian ini mengusulkan kerangka kerja GAN yang mengintegrasikan empat komponen inovatif dalam dua kontribusi utama. Pertama, arsitektur kerangka kerja dengan Diskriminator Dual-Modal yang memiliki cabang visual (CNN) dan cabang tekstual

(LSTM) untuk mengevaluasi koherensi gambar-teks secara simultan, serta strategi *Frozen Recognizer* yang mengintegrasikan CTC loss dari model HTR pralatih tanpa mengubah bobotnya untuk memberikan gradien sadar teks yang stabil. Kedua, strategi pelatihan multi-objektif dengan *Curriculum Learning* untuk penurunan bobot CTC loss yang mencegah ketidakstabilan pelatihan akibat perbedaan skala komponen loss ganda, dilengkapi dengan studi ablasi sistematis untuk validasi empiris kontribusi setiap komponen terhadap keseimbangan optimal antara kualitas visual (PSNR/SSIM) dan keterbacaan teks (CER/WER). Kerangka kerja ini mengoptimalkan fungsi loss 5-komponen yang terdiri dari: piksel, adversarial, perseptual, CTC, dan fitur rekognisi.

Diskriminator *Dual-Modal* dirancang dengan arsitektur dua cabang paralel. Cabang visual menggunakan jaringan konvolusional untuk mengekstrak fitur spasial dari gambar. Sementara itu, cabang tekstual menggunakan pemodelan urutan (LSTM/*Transformer*) untuk memproses representasi teks dari model HTR. Kedua cabang ini kemudian difusikan melalui lapisan konkatenasi dan *dense layers* untuk menghasilkan skor validitas koherensi gambar-teks.

Pendekatan ini sejalan dengan penelitian terkini yang menunjukkan bahwa arsitektur multi-modal dapat meningkatkan stabilitas pelatihan dan kualitas keluaran GAN Baltrušaitis dkk. (2019). Sementara itu, integrasi CTC Loss memungkinkan generator untuk belajar secara langsung dari umpan balik sistem HTR, sehingga restorasi yang dihasilkan tidak hanya terlihat bersih, tetapi juga memaksimalkan keterbacaan teks Graves dkk. (2006).

Kebaruan penelitian ini terletak pada kombinasi empat inovasi tersebut dalam satu kerangka kerja terpadu. Berbeda dengan DE-GAN yang menggunakan diskriminator berbasis visual tanpa integrasi HTR, atau ERB-MultiTask yang menggunakan diskriminator visual dengan pelatihan bersama *recognizer* (berpotensi tidak stabil), penelitian ini mengembangkan diskriminator *dual-modal* yang secara langsung mengevaluasi koherensi visual-tekstual sambil menggunakan *frozen recognizer* untuk stabilitas gradien. Berbeda dengan DocEnTr atau Text-DIAE yang fokus pada berbasis *transformer* tanpa komponen *adversarial*, kerangka kerja yang diusulkan mengkombinasikan keunggulan pelatihan adversarial dengan evaluasi *dual-modal* dan *curriculum learning* untuk penurunan bobot CTC loss. Dengan demikian, penelitian ini tidak hanya berkontribusi pada pengembangan arsitektur diskriminator yang lebih komprehensif dan strategi pelatihan yang lebih stabil, tetapi juga memberikan solusi praktis untuk mendukung preservasi digital dan aksesibilitas arsip nasional.

Penelitian ini dilandasi oleh premis bahwa diskriminator dual-modal yang

menggabungkan evaluasi visual dan tekstual dapat memberikan umpan balik yang lebih komprehensif kepada generator, dan kombinasi dengan strategi *frozen recognizer* serta *curriculum learning* dapat mengatasi ketidakstabilan pelatihan dalam optimisasi multi-objektif.

I.2 Rumusan Masalah

Berdasarkan analisis latar belakang, penelitian ini mengidentifikasi empat masalah fundamental dalam restorasi dokumen historis terdegradasi:

1. Kesenjangan antara Optimasi Visual dan Keterbacaan Teks

Metode *state-of-the-art* (DE-GAN, DocEnTr, Text-DIAE) mengoptimalkan metrik visual (PSNR/SSIM) tanpa integrasi eksplisit dengan evaluasi HTR. Peningkatan kualitas visual tidak berkorelasi langsung dengan penurunan CER, karena metrik piksel tidak sensitif terhadap distorsi struktur karakter yang sangat penting untuk pengenalan teks.

2. Keterbatasan Arsitektur Diskriminator Berbasis Visual

Metode berbasis GAN yang ada menggunakan diskriminator yang hanya mengevaluasi realisme visual tanpa mempertimbangkan koherensi tekstual. Diskriminator tidak dapat menilai apakah struktur karakter yang dihasilkan tetap dapat dibaca oleh sistem HTR, sehingga generator mungkin menghasilkan citra yang terlihat bersih secara visual namun kehilangan detail karakter penting untuk pengenalan teks.

3. Ketiadaan Fungsi Loss Berorientasi HTR dengan Strategi Frozen Recognizer

Meskipun ERB-MultiTask mengintegrasikan *CTC loss*, pendekatan pelatihan bersama yang digunakan (melatih generator, diskriminator, dan *recognizer* secara bersamaan) berpotensi tidak stabil karena kompetisi gradien. Strategi *frozen recognizer* yang dapat memberikan gradien berorientasi HTR secara konsisten tanpa mengganggu bobot model pengenalan belum dieksplorasi secara sistematis untuk restorasi dokumen.

4. Ketidakstabilan Pelatihan dengan Komponen Loss Ganda

Pelatihan GAN dengan *adversarial*, *reconstruction*, dan *recognition loss* secara simultan mengalami ketidakstabilan karena perbedaan skala dan dinamika konvergensi. Belum ada penelitian yang mengevaluasi *curriculum learning* untuk penurunan bobot *CTC loss* guna mencegah dominasi satu komponen pada fase awal pelatihan dan memastikan konvergensi yang stabil.

I.3 Pertanyaan Penelitian

Berdasarkan identifikasi masalah di atas, penelitian ini merumuskan pertanyaan penelitian sebagai berikut:

Pertanyaan Penelitian Utama:

Bagaimana mengembangkan kerangka kerja restorasi dokumen berbasis GAN dengan diskriminator dual-modal dan strategi frozen recognizer yang secara eksplisit mengintegrasikan evaluasi keterbacaan teks ke dalam proses pelatihan untuk mengatasi kesenjangan antara optimasi visual dan performa HTR?

Pertanyaan Penelitian Spesifik:

1. Arsitektur Diskriminator Dual-Modal:

Bagaimana merancang dan mengevaluasi arsitektur diskriminator dual-modal dengan cabang visual (CNN) dan cabang tekstual (LSTM) yang mengevaluasi koherensi visual-tekstual secara simultan, serta bagaimana mengukur kontribusinya terhadap kualitas umpan balik generator dibandingkan diskriminator hanya visual?

2. Frozen Recognizer dengan Integrasi CTC Loss:

Bagaimana strategi *frozen recognizer* dengan integrasi *CTC loss* dibandingkan dengan pendekatan pelatihan bersama dalam hal: (a) stabilitas gradien selama pelatihan, (b) performa keterbacaan teks yang dihasilkan, dan (c) efisiensi komputasi dalam proses optimisasi?

3. Strategi Curriculum Learning:

Bagaimana merancang strategi temporal *curriculum learning* untuk penurunan bobot *CTC loss* yang memastikan konvergensi stabil dengan beberapa komponen loss (*adversarial*, *reconstruction*, *recognition*) pada fase awal hingga akhir pelatihan?

4. Optimasi Multi-Objektif:

Bagaimana menentukan konfigurasi bobot akhir yang optimal untuk *adversarial*, *reconstruction*, dan *recognition loss* guna mencapai keseimbangan terbaik antara kualitas visual (PSNR/SSIM) dan keterbacaan teks (CER/WER) pada hasil restorasi?

I.4 Tujuan Penelitian

Tujuan Umum:

Mengembangkan kerangka kerja restorasi dokumen berbasis GAN dengan diskriminator dual-modal dan strategi *frozen recognizer* yang mengatasi kesenjangan antara optimasi visual dan keterbacaan teks, dengan target: (1) kualitas visual PSNR > 30 dB dan SSIM > 0.95, serta (2) peningkatan signifikan keterbacaan teks dibandingkan kondisi terdegradasi.

Tujuan Khusus:

a. Merancang dan Mengevaluasi Arsitektur Diskriminator Dual-Modal:

Mengembangkan diskriminator dengan cabang visual dan tekstual untuk

- mengevaluasi koherensi gambar-tekst. Melakukan evaluasi komparatif terhadap diskriminator hanya visual untuk mengukur kontribusinya pada kualitas restorasi.
- b. Mengintegrasikan CTC Loss dengan Strategi Frozen Recognizer:
Membangun mekanisme integrasi *CTC loss* dari model HTR pralatih ke dalam fungsi objektif generator. Pendekatan ini mempertahankan stabilitas pelatihan dan mencegah *catastrophic forgetting* dibandingkan pendekatan pelatihan bersama yang tidak stabil.
 - c. Mengoptimalkan Fungsi Loss Multi-Objektif:
Merancang fungsi *loss* gabungan yang mengintegrasikan *adversarial*, *reconstruction*, dan *recognition loss* dengan bobot terkalibrasi. Mengimplementasikan strategi *curriculum learning* untuk mengatasi ketidakstabilan pelatihan dan memastikan konvergensi yang stabil.
 - d. Melakukan Studi Ablasi untuk Validasi Kontribusi Komponen:
Mengidentifikasi dan mengukur kontribusi masing-masing komponen utama (diskriminator *dual-modal*, *frozen recognizer*, dan *curriculum learning*) serta mengidentifikasi konfigurasi optimal untuk mencapai keseimbangan terbaik antara kualitas visual dan keterbacaan teks.

I.5 Ruang Lingkup

Untuk memastikan fokus dan ketercapaian tujuan penelitian, ditetapkan ruang lingkup dan batasan sebagai berikut:

1. Ruang Lingkup:
Penelitian ini dibatasi pada dokumen tulisan tangan berbahasa Belanda dari era kolonial abad ke-16 hingga ke-18 (Arsip Nasional RI) dengan pemrosesan tingkat baris teks. Fokus pada empat jenis degradasi utama: *bleed-through*, *fading*, *stains*, dan *blur*.
2. Batasan Metodologi:
Mengevaluasi arsitektur dual-modal dengan strategi *frozen recognizer* dan fungsi *loss* multi-objektif (*adversarial*, *reconstruction*, *recognition*). Data pelatihan berupa kombinasi data semi-sintetis dan data riil dalam jumlah terbatas. Data semi-sintetis digunakan untuk menyediakan *ground truth* berpasangan, sedangkan data riil digunakan untuk validasi generalisasi.
3. Batasan Teknis:
Evaluasi menggunakan metrik visual (PSNR, SSIM) dan metrik keterbacaan teks (CER, WER).
4. Asumsi Penelitian:
Degradasi semi-sintetis dapat mewakili kondisi dokumen riil dalam batas tertentu untuk keperluan pelatihan, model HTR pralatih memiliki performa yang

baik pada data bersih, dan peningkatan metrik CER/WER berkorelasi dengan keterbacaan teks praktis.

I.6 Hipotesis Penelitian

Berdasarkan analisis masalah dan kajian literatur yang menunjukkan bahwa diskriminator dual-modal dapat memberikan umpan balik yang lebih komprehensif melalui evaluasi koherensi visual-tekstual secara simultan, dan kombinasi dengan strategi *frozen recognizer* serta *curriculum learning* dapat mengatasi ketidakstabilan pelatihan dalam optimisasi multi-objektif, penelitian ini merumuskan hipotesis sebagai berikut:

Penggunaan diskriminator dual-modal dan strategi *frozen recognizer* dengan *curriculum learning* dan optimasi *loss function* multi-objektif dapat mengatasi kesenjangan antara optimasi visual dan keterbacaan teks, sehingga menghasilkan restorasi yang secara signifikan lebih baik dalam aspek keterbacaan teks sambil mempertahankan kualitas visual dibandingkan metode acuan.

I.7 Kebaruan Penelitian

Kebaruan penelitian ini terletak pada pengembangan kerangka kerja restorasi dokumen berbasis GAN yang mengintegrasikan arsitektur diskriminator *dual-modal* (dengan cabang pemrosesan visual dan tekstual), strategi *frozen recognizer* untuk supervisi HTR yang stabil, serta protokol pelatihan *curriculum learning* untuk penjadwalan bobot *loss* secara bertahap. Kerangka kerja ini dievaluasi melalui studi ablasi sistematis untuk mengidentifikasi kontribusi setiap komponen arsitektur. Selain itu, penelitian ini menghasilkan kumpulan data dokumen terdegradasi semi-sintetis dengan *ground truth* yang dapat digunakan sebagai sumber daya penelitian lanjutan.

I.8 Sistematika Penulisan

Tesis ini disusun dalam enam bab dengan struktur sebagai berikut:

Bab I: Pendahuluan

Bab ini menyajikan pendahuluan yang menjadi landasan bagi keseluruhan penelitian. Pembahasan diawali dengan latar belakang tentang urgensi pelestarian dokumen historis dan tantangan degradasi yang dihadapi, serta menjelaskan keterbatasan metode restorasi yang ada saat ini. Berdasarkan permasalahan tersebut, dirumuskan masalah dan pertanyaan penelitian yang spesifik, yang menjadi acuan dalam penetapan tujuan dan ruang lingkup penelitian. Untuk menjawab tantangan tersebut, diajukan sebuah hipotesis yang akan diuji, serta diuraikan kebaruan dan kontribusi yang diharapkan dari penelitian ini. Di akhir bab, dijelaskan sistematika penulisan yang akan digunakan pada tesis ini.

Bab II: Tinjauan Pustaka

Bab ini menyajikan landasan teoretis dan tinjauan pustaka untuk membangun justifikasi penelitian. Kajian diawali dengan pembahasan teori fundamental (GAN, U-Net, HTR), kemudian membahas perkembangan metode restorasi dokumen. Dari analisis terhadap metode-metode tersebut beserta metrik evaluasinya, diidentifikasi celah penelitian, yaitu: belum adanya mekanisme restorasi yang secara eksplisit mempertahankan keterbacaan teks melalui diskriminator sadar teks.

Bab III: Metodologi Penelitian

Bab ini menguraikan metodologi penelitian yang digunakan sebagai panduan sistematis dalam pelaksanaan penelitian. Penelitian ini mengadopsi kerangka kerja *Design Science Research Methodology* (DSRM) yang terdiri dari enam tahapan: (1) identifikasi masalah dan motivasi, (2) definisi tujuan solusi, (3) desain dan pengembangan artefak, (4) demonstrasi, (5) evaluasi, dan (6) komunikasi. Di dalam tahapan-tahapan tersebut, akan dibahas secara rinci mengenai kerangka pengembangan GAN dengan diskriminator dual-modal, strategi *frozen recognizer*, dan *curriculum learning*, serta lingkungan eksperimen (perangkat keras dan lunak).

Bab IV: Perancangan Sistem

Bab ini menyajikan perancangan teknis dari kerangka kerja yang diusulkan. Pembahasan mencakup arsitektur sistem yang meliputi generator berbasis U-Net dan diskriminator dual-modal dengan *frozen recognizer*. Untuk mengoptimalkan performa, dirancang pula fungsi *loss* gabungan yang mengintegrasikan *adversarial*, *reconstruction*, dan *recognition loss*, serta alur kerja untuk penyiapan data semi-sintetis. Bab ini ditutup dengan konfigurasi pelatihan dan strategi *curriculum learning* yang diterapkan.

Bab V: Hasil dan Pembahasan

Setelah kerangka kerja dirancang dan diimplementasikan pada bab sebelumnya, bab ini berfokus pada evaluasi eksperimental untuk mengukur kinerja dan efektivitasnya. Kinerja model dievaluasi secara komprehensif, diawali dengan analisis kuantitatif menggunakan metrik standar (PSNR, SSIM, CER, WER) yang kemudian diperkuat oleh analisis kualitatif melalui visualisasi hasil restorasi. Untuk membuktikan keunggulan kerangka kerja ini, dilakukan analisis komparatif terhadap metode restorasi dokumen berbasis GAN yang relevan. Studi ablasi sistematis dilakukan untuk mengisolasi dan mengukur kontribusi individual dari setiap komponen yang diusulkan (diskriminator *dual-modal*, *frozen recognizer*, *curriculum learning*, dan konfigurasi *loss*), sehingga dapat diidentifikasi komponen mana yang memberikan dampak signifikan terhadap kinerja sistem. Sebagai penutup, dilakukan pengujian hipotesis statistik untuk menjawab rumusan masalah penelitian secara formal

berdasarkan data hasil eksperimen.


Bab VI: Kesimpulan dan Saran

Bab ini merupakan bagian penutup yang menyajikan sintesis dan evaluasi atas keseluruhan rangkaian penelitian yang telah dilaksanakan. Pembahasan akan diawali dengan merangkum temuan-temuan utama yang diperoleh dari hasil analisis dan evaluasi. Berdasarkan temuan tersebut, akan dilakukan penilaian terhadap ketercapaian tujuan penelitian dan pengujian hipotesis yang telah dirumuskan. Selanjutnya, akan diidentifikasi kontribusi signifikan dari penelitian ini, baik pada aspek teoretis (ilmiah) maupun implikasi praktisnya. Sebagai penutup, bab ini menyajikan rekomendasi bagi pengembangan penelitian di masa depan serta saran untuk penerapan praktis.

Bab II Tinjauan Pustaka

Bab ini menyajikan kajian mengenai perkembangan metode restorasi dokumen yang berfokus pada analisis kekuatan dan keterbatasan pendekatan yang telah ada. Pembahasan mencakup evolusi dari metode tradisional hingga pendekatan pembelajaran mendalam terkini, teori dan aplikasi *Generative Adversarial Networks* (GAN), integrasi sistem HTR, pembelajaran multi-modal, serta optimasi fungsi *loss*. Tinjauan pustaka ini mengadopsi pendekatan meta-analisis kuantitatif untuk mengidentifikasi tren perkembangan performa metode restorasi, serta menekankan korelasi antara metrik kualitas visual dan keterbacaan fungsional. Analisis terhadap sembilan metode terkini periode 2006-2024 mengungkapkan pola perkembangan yang jelas, yaitu peralihan dari optimisasi visual murni (berfokus pada PSNR) menuju optimisasi holistik yang mengintegrasikan metrik kinerja HTR.

Analisis ini bertujuan mengidentifikasi kesenjangan penelitian yang memerlukan eksplorasi lebih lanjut dalam konteks restorasi dokumen historis berorientasi keterbacaan teks. Fokus khusus diberikan pada pendekatan pembelajaran dual-modal yang mampu mengoptimalkan kualitas visual dan keterbacaan fungsional secara simultan.



Gambar II.1 Struktur Bab II: Alur kajian dari degradasi dokumen hingga metodologi penelitian, dengan fondasi teoretis GAN, HTR, multi-modal, dan fungsi *loss* sebagai dukungan.

Struktur kajian pada Gambar II.1 menunjukkan alur logis pembahasan yang dimulai dari karakteristik degradasi dokumen historis sebagai landasan pemahaman masalah, dilanjutkan dengan evolusi metodologis, dan diakhiri dengan identifikasi kesenjangan penelitian yang menjadi dasar pengembangan metodologi baru.

II.1 Degradasi Dokumen Historis

Dokumen historis, khususnya koleksi arsip kolonial Belanda dari era VOC dan Hindia Belanda yang tersimpan di Arsip Nasional RI, mengalami degradasi fisik yang kompleks dan multimodal. Pemahaman mendalam tentang karakteristik degradasi ini sangat penting untuk merancang strategi restorasi yang efektif.

II.1.1 Karakteristik Degradasi Dokumen Historis

Berdasarkan analisis literatur dan observasi empiris pada koleksi Arsip Nasional, degradasi dokumen dapat dikategorikan menjadi enam tipe utama yang masing-masing memiliki karakteristik visual dan dampak terhadap keterbacaan yang berbeda:



Gambar II.2 Contoh degradasi pada dokumen ANRI abad ke-16 hingga ke-18: (a) tinta tembus, (b) korosi tinta besi galat, (c) penuaan kertas, (d) kerusakan fisik, (e) pemudaran tinta, (f) degradasi gabungan. Gambar menunjukkan variasi tingkat degradasi yang menantang sistem HTR.

1. Tembusan Tinta (*Bleed-Through*)

Fenomena ini terjadi ketika tinta dari halaman sebaliknya menembus medium kertas dan tampak pada halaman yang sedang diamati. Tembusan tinta disebabkan oleh kombinasi faktor: kualitas kertas yang berpori, tinta berbasis air yang digunakan pada era kolonial, dan degradasi serat selulosa yang meningkatkan permeabilitas kertas seiring waktu. Secara visual, tembusan tinta menciptakan efek bayangan berupa karakter terbalik atau terputus yang tumpang tindih dengan teks utama.

Dampak terhadap HTR sangat signifikan karena model kesulitan membedakan antara teks latar depan (teks asli) dan derau latar belakang (tembusan). Penelitian Gatos dkk. (2006) menunjukkan bahwa tembusan tinta dapat meningkatkan CER hingga 40 persen pada model HTR yang tidak dilatih dengan degradasi serupa.

Karakteristik spasial tembusan tinta adalah lapisan semi-transparan dengan intensitas yang bervariasi bergantung pada ketebalan kertas dan densitas tinta.

2. Korosi Tinta Besi Galat (*Iron Gall Ink*)

Korosi tinta *iron gall* merupakan proses degradasi kimia spesifik yang terjadi pada dokumen berusia ratusan tahun akibat reaksi oksidatif tinta berbasis *ferrous sulfate* yang digunakan secara luas pada era kolonial Belanda. Proses ini melibatkan: (1) oksidasi *ferrous sulfate* menjadi *ferric sulfate* yang lebih reaktif, (2) reaksi dengan asam organik dan air yang terbentuk dari degradasi kertas, menghasilkan asam sulfat yang mempercepat korosi, (3) perubahan warna tinta dari hitam menjadi cokelat keabu-abuan atau kuning kecokelatan (Neevel, 1995; Krekel, 1999). Karakteristik visual korosi tinta adalah perubahan warna progresif, disertai dengan penggelapan tepi goresan dan pelemahan kontras visual.

Dampak terhadap HTR signifikan karena kombinasi penurunan kontras dan degradasi material tinta: (1) tinta yang terkorosi memiliki intensitas lebih rendah dibandingkan dengan tinta baru, mengurangi rasio sinyal-derau, (2) korosi dapat menyebabkan fragmentasi halus pada goresan tinta yang tebal, (3) reaksi kimia berlanjut dalam penyimpanan arsip modern, menyebabkan degradasi progresif. Penelitian menunjukkan bahwa korosi tinta besi galat dapat meningkatkan CER sebesar 35-45 persen, sebanding dengan efek pemudaran tinta secara umum.

3. Penuaan Kertas dan Penguningan

Penuaan kertas merupakan proses degradasi fisikokimia fundamental yang terjadi selama berabad-abad penyimpanan dokumen. Karakteristik utama penuaan kertas meliputi: (1) penguningan progresif (*yellowing*) akibat oksidasi selulosa dan lignin dengan paparan cahaya dan udara (Reilly, 1993), (2) kerusakan serat selulosa yang mengurangi fleksibilitas dan kekuatan kertas (Porck, 2000), (3) peningkatan keasaman kertas melalui pembentukan asam organik dari degradasi komponen kertas dan lignin (Neevel, 1995). Penguningan menyebabkan perubahan karakteristik optik: latar belakang kertas berubah dari putih menjadi kuning, krem, atau cokelat, secara signifikan mengurangi kontras visual dengan tinta.

Dampak terhadap HTR sangat signifikan karena penuaan kertas mengurangi rasio sinyal-derau secara dramatis: (1) penurunan kontras antara tinta dan latar belakang menghambat ekstraksi fitur pada lapisan CNN awal, (2) penguningan heterogen menciptakan latar belakang tidak seragam yang menambah kompleksitas, (3) kerusakan serat dapat menyebabkan tekstur permukaan kertas yang tidak rata. Penelitian Gatos dkk. (2006) menunjukkan bahwa penuaan kertas moderat dapat meningkatkan CER hingga 40-50 persen. Pada koleksi ANRI, hampir semua

dokumen berusia 300+ tahun menunjukkan tanda penuaan kertas yang nyata.

4. Kerusakan Fisik (Robekan, Lipatan, Sobekan)

Kerusakan fisik merupakan artefak mekanis yang terjadi akibat penanganan, penyimpanan, atau pemindaian dokumen yang kurang hati-hati. Jenis kerusakan fisik meliputi: (1) robekan dan sobekan yang menyebabkan hilangnya material kertas, (2) lipatan permanen yang mengakibatkan perubahan topologi lokal, (3) kerutan yang menciptakan bayangan dan distorsi tekstur, (4) distorsi lengkungan halaman. Karakteristik visual kerusakan fisik adalah perubahan topografi lokal yang signifikan, penutupan parsial karakter pada wilayah kerusakan, dan perubahan drastis intensitas piksel di sepanjang garis robekan.

Dampak terhadap HTR sangat signifikan karena kerusakan fisik menyebabkan penutupan atau distorsi goresan: (1) robekan dapat menutupi sebagian atau seluruh karakter, menciptakan penutupan yang sulit dipulihkan tanpa informasi kontekstual, (2) lipatan menghasilkan bayangan kompleks yang membingungkan model segmentasi, (3) kelengkungan halaman pada pemindaian menyebabkan distorsi perspektif yang mengubah bentuk karakter. Penelitian menunjukkan bahwa kerusakan fisik yang menutupi lebih dari 20 persen area karakter menyebabkan peningkatan CER hingga 60-70 persen, mengingat hilangnya informasi goresan yang tidak dapat dipulihkan.

5. Pemudaran dan Degradasi Tinta

Pemudaran tinta merupakan proses degradasi kimia yang menyebabkan pigmen tinta kehilangan intensitas dan saturasi warna akibat oksidasi, paparan cahaya UV, atau reaksi dengan kontaminan atmosfer. Pada dokumen berusia ratusan tahun, pemudaran tinta terjadi secara progresif, menghasilkan: (1) penurunan intensitas warna dari hitam pekat menjadi abu-abu atau coklat terang, (2) penurunan kontras yang signifikan antara tinta dan latar belakang, (3) homogenisasi dan pengaburan goresan tinta yang semula tajam, sehingga detail halus seperti *serif* atau diakritik menjadi kabur Pratikakis dkk. (2013). Tingkat pemudaran bervariasi bergantung pada paparan cahaya selama penyimpanan.

Dampak terhadap HTR sangat signifikan karena pemudaran mengurangi rasio sinyal-derau dan fitur pembeda visual: (1) penurunan kontras menghambat ekstraksi fitur deteksi tepi (*edge-detection*) pada lapisan CNN awal, (2) hilangnya ketajaman goresan mengurangi daya pembeda antar karakter, (3) derau latar belakang menjadi lebih terlihat relatif terhadap tinta yang memudar. Studi Pratikakis dkk. (2013) pada dataset DIBCO menunjukkan bahwa pemudaran moderat dapat meningkatkan CER dari 8 persen menjadi 25 persen. Pada dokumen ANRI, mayoritas mengalami

pemudaran tinta dalam tingkat sedang hingga berat.

6. Degradasi Gabungan dan Interaksi Kompleks

Dalam praktik, dokumen historis jarang mengalami degradasi tunggal murni. Lebih umum ditemukan kombinasi dari dua atau lebih jenis degradasi yang berinteraksi secara kompleks. Contoh umum pada dokumen ANRI abad ke-16 hingga 18 meliputi: (1) tinta tembus + penuaan kertas (menciptakan kontras rendah dengan bayangan berganda), (2) korosi tinta besi galat + kerusakan fisik (tinta coklat teroksidasi dengan celah robekan), (3) pemudaran + noda organik (kedua-duanya mengurangi kontras dan membuat segmentasi karakter sulit), (4) penuaan kertas + kekaburan (*blur*) + noda (kombinasi ini menciptakan skenario paling menantang untuk HTR).

Degradasi gabungan menciptakan sinergi negatif yang dampaknya terhadap keterbacaan HTR jauh lebih besar daripada akumulasi dampak individual. Misalnya, tembusan tinta yang ringan sendiri mungkin dapat ditangani model HTR, namun ketika dikombinasikan dengan pemudaran yang mengakibatkan kontras rendah secara keseluruhan, efeknya menjadi sangat fatal. Fenomena ini menyebabkan pendekatan tradisional berbasis aturan atau penalaan parameter manual menjadi tidak efektif dan sulit diterapkan dalam skala besar. Setiap kombinasi degradasi memerlukan parameter berbeda, dan tidak ada formulasi umum yang dapat menangani variasi ini.

Kompleksitas tersebut menjadi motivasi utama transisi ke pendekatan berbasis pembelajaran mendalam. Penelitian M. A. Souibgui, Kessentini, Fornés, dkk. (2022) menunjukkan bahwa kombinasi tiga atau lebih jenis degradasi dapat meningkatkan CER hingga 85-90 persen. Arsitektur seperti U-Net (Ronneberger dkk. (2015a)) dan GAN (Goodfellow dkk. (2014)) terbukti mampu menangani variabilitas ini melalui pembelajaran representasi hierarkis dari data berpasangan, tanpa memerlukan formulasi eksplisit untuk setiap kombinasi degradasi. Namun, tantangan tetap ada dalam memastikan restorasi menjaga keterbacaan teks secara fungsional, sebuah kesenjangan yang akan dibahas lebih lanjut dalam Bagian II.8.

Kompleksitas dan variabilitas degradasi yang telah dijelaskan di atas menciptakan tantangan fundamental bagi pendekatan restorasi berbasis aturan yang dirancang manual. Untuk memberikan gambaran kuantitatif yang lebih konkret tentang dampak setiap jenis degradasi terhadap sistem HTR, Tabel II.1 menyajikan analisis komparatif berdasarkan data eksperimental dari berbagai penelitian.

Tabel II.1 Pengaruh Jenis Degradasi terhadap Kinerja HTR

Jenis Degradasi	Tingkat	Peningkatan CER	Penurunan Keyakinan	Referensi
(A) Tinta Tembus	Sedang	+40%	-60%	Gatos dkk. (2006)
(B) Korosi Tinta Besi Galat	Sedang	+35%	-50%	Neevel (1995) dan Krekel (1999)
(C) Penuaan Kertas / Penguningan	Sedang	+40%	-55%	Reilly dkk. (1993) dan Porck dan Teßelaar (2000)
(D) Kerusakan Fisik (Robek, Lipatan)	Berat	+60%	-70%	Gatos dkk. (2006)
(E) Pemudaran Tinta	Sedang	+25%	-45%	Pratikakis dkk. (2013)
(F) Degradasi Gabungan	Berat	+85%	-80%	M. A. Souibgui, Kessentini, Fornés, dkk. (2022)

Data pada Tabel II.1 menunjukkan bahwa degradasi gabungan memiliki dampak paling destruktif terhadap kinerja HTR, dengan peningkatan CER hingga 85% dan penurunan keyakinan mencapai 80%. Fenomena ini membuktikan bahwa interaksi antar jenis degradasi bersifat sinergis negatif, bukan hanya akumulatif linear. Sulitnya merumuskan model eksplisit untuk setiap kombinasi degradasi memotivasi transisi ke pendekatan pembelajaran mendalam yang dapat mempelajari representasi optimal secara otomatis dari data. Bagian berikutnya menelusuri evolusi metode restorasi dokumen dari paradigma tradisional menuju arsitektur pembelajaran mendalam modern, dengan fokus pada analisis mendalam terhadap keterbatasan fundamental setiap paradigma.

Ringkasan Seksi 2.1: Dokumen historis ANRI mengalami enam tipe degradasi utama yang masing-masing meningkatkan CER hingga 40-70%, dengan degradasi gabungan mencapai 85-90%. Kompleksitas interaksi antar degradasi memerlukan pendekatan pembelajaran mendalam yang dapat mempelajari representasi tangguh tanpa formulasi eksplisit setiap kombinasi.

II.2 Evolusi Metode Restorasi Dokumen

Metode restorasi dokumen telah mengalami transformasi signifikan dari pendekatan tradisional berbasis aturan menuju paradigma pembelajaran mendalam modern. Evolusi ini dapat dikategorisasikan ke dalam tiga paradigma utama yang masing-masing memiliki karakteristik dan keterbatasan yang berbeda, sebagaimana dirangkum dalam Tabel II.2.

Tabel II.2 Perbandingan Paradigma Metode Restorasi Dokumen

Paradigma	Periode	Karakteristik Utama	Keterbatasan Mendasar
Berbasis Aturan	1979-2010	Ambang batas adaptif, fitur manual	Tidak dapat menangani degradasi kompleks
Pembelajaran Mendalam Awal	2015-2018	<i>Autoencoder</i> , U-Net, MSE <i>loss</i>	<i>Output</i> kabur, fokus visual
Adversarial Modern	2017-sekarang	GAN, multi-modal, integrasi HTR	Kesenjangan visual-fungsional masih ada

Analisis temporal pada Tabel II.2 mengungkapkan pergeseran paradigmatik yang jelas: dari periode berbasis aturan (1979-2010) yang mengandalkan formulasi eksplisit menuju era adversarial modern (2017-sekarang) yang menggunakan pembelajaran representasi otomatis. Meskipun paradigma adversarial modern telah berhasil mengatasi keterbatasan metode tradisional, kesenjangan visual-fungsional masih menjadi tantangan yang belum sepenuhnya teratasi. Evolusi ini didorong oleh keterbatasan mendasar metode konvensional dalam menangani kompleksitas degradasi dokumen historis. Bagian ini menelusuri perkembangan historis metode restorasi, menganalisis kekuatan dan kelemahan setiap paradigma, serta mengidentifikasi momen transisi menuju pendekatan berbasis pembelajaran yang lebih terstruktur. Pemahaman tentang evolusi ini penting untuk menghargai inovasi dalam metode pembelajaran mendalam kontemporer dan memposisikan kontribusi penelitian ini dalam rangkaian perkembangan ilmu restorasi dokumen.

II.2.1 Pendekatan Tradisional dan Keterbatasannya

Metode restorasi tradisional dapat dikategorikan menjadi tiga paradigma utama: berbasis ambang batas, berbasis energi, dan berbasis model statistik. Evaluasi

terhadap ketiga paradigma ini mengungkapkan keterbatasan fundamental yang memotivasi transisi ke pendekatan pembelajaran mendalam.

1. Paradigma 1: Metode Berbasis Ambang Batas

Metode ini mengasumsikan bahwa teks dan latar belakang dapat dipisahkan berdasarkan ambang batas intensitas yang optimal. Algoritma klasik yang diusulkan oleh Otsu (1979) menggunakan maksimisasi varians antar-kelas untuk menemukan ambang batas yang memisahkan histogram intensitas menjadi dua distribusi. Selanjutnya, Sauvola dan Pietikäinen (2000) mengembangkan ambang batas adaptif yang menghitung ambang batas lokal berdasarkan rata-rata dan deviasi standar dalam jendela ketetanggaan.

Analisis keterbatasan menunjukkan bahwa pendekatan ini gagal pada dokumen dengan tembusan tinta (*bleed-through*) karena asumsi distribusi bimodal tidak terpenuhi. Ketika intensitas tinta tembus tumpang tindih dengan teks asli, tidak ada ambang batas tunggal ataupun lokal yang dapat memisahkan keduanya. Analisis komprehensif Pratikakis dkk. (2013) terhadap himpunan data DIBCO 2009-2019 menunjukkan bahwa metode Sauvola hanya mencapai rata-rata *F-measure* 68 persen pada dokumen dengan degradasi berat, jauh di bawah performa metode pembelajaran mendalam yang mencapai 85 persen pada tolok ukur yang sama.

Secara lebih mendasar, metode berbasis ambang batas bersifat deterministik dan tidak memiliki mekanisme untuk belajar dari data. Setiap jenis dokumen yang memiliki karakteristik degradasi berbeda memerlukan penyetelan parameter manual, yang tidak praktis untuk proyek digitalisasi skala besar.

2. Paradigma 2: Metode Berbasis Energi

Metode ini memformulasikan restorasi sebagai masalah optimisasi yang bertujuan meminimalkan fungsi energi dengan menggabungkan suku kesetiaan data (*data fidelity*) dan suku regularisasi. Gatos dkk. (2006) mengusulkan fungsi energi yang memaksimalkan pemisahan latar depan (tinta) dan meminimalkan degradasi latar belakang menggunakan operasi morfologis serta analisis komponen terhubung.

Analisis keterbatasan menunjukkan bahwa metode berbasis energi memerlukan definisi eksplisit mengenai asumsi awal karakteristik teks dan degradasi. Sebagai contoh, asumsi bahwa teks memiliki kontinuitas goresan atau komponen terhubung dengan rasio aspek tertentu sering kali tidak terpenuhi pada dokumen nyata yang memiliki goresan terputus akibat pemudaran atau tertutup noda.

Selain itu, proses optimisasi untuk fungsi energi non-cembung memerlukan biaya komputasi tinggi dan sering terjebak pada minimum lokal. Kualitas hasil sangat sensitif terhadap kondisi awal dan parameter regularisasi, yang kembali memerlukan

penyesuaian manual oleh ahli.

3. Paradigma 3: Metode Berbasis Model Statistik

Pendekatan ini memodelkan degradasi sebagai proses statistik dan menggunakan inferensi Bayes atau *Markov Random Fields* untuk pemulihan. Metode ini berupaya memodelkan proses pembentukan degradasi secara eksplisit untuk kemudian melakukan operasi invers.

Analisis keterbatasan menunjukkan bahwa kompleksitas proses degradasi nyata menyebabkan pemodelan statistik eksplisit sulit dipecahkan secara komputasi (*intractable*). Estimasi parameter untuk model yang kompleks memerlukan data referensi dalam jumlah besar yang sering kali tidak tersedia untuk dokumen historis. Lebih penting lagi, model statistik tidak mampu menangkap informasi semantik tingkat tinggi mengenai struktur teks yang krusial untuk menjaga keterbacaan.

Keterbatasan mendasar metode tradisional adalah ketidakmampuan mempelajari representasi hierarkis data serta ketergantungan pada fitur rekayasa manual atau model eksplisit yang sulit digeneralisasi. Hal ini memotivasi transisi menuju pendekatan pembelajaran mendalam yang mampu mempelajari representasi optimal dari data secara otomatis.

II.2.2 Transisi ke Pembelajaran Mendalam

Munculnya pembelajaran mendalam menandai perubahan paradigma dalam visi komputer dan pemrosesan citra dokumen. Kemampuan Jaringan Saraf Tiruan Konvolusional (CNN) untuk pembelajaran representasi fitur secara hierarkis dari piksel mentah membuka kemungkinan baru untuk restorasi dokumen.

1. Autoencoder untuk Translasi Citra-ke-Citra


Arsitektur *Autoencoder* yang terdiri atas Enkoder untuk ekstraksi fitur dan Dekoder untuk rekonstruksi pertama kali diaplikasikan untuk penghilangan derau dokumen oleh Zhao dkk. (2019). Enkoder melakukan pengurangan sampel (*downsampling*) bertahap dengan lapisan konvolusional untuk mengekstrak fitur tingkat tinggi, sementara Dekoder melakukan peningkatan sampel (*upsampling*) untuk merekonstruksi citra bersih.

Kontribusi utama pendekatan ini adalah kemampuan *Autoencoder* untuk mempelajari model implisit dari proses degradasi dan restorasi tanpa memerlukan formulasi eksplisit. Pelatihan dengan data berpasangan (mengalami degradasi dan bersih) memungkinkan model untuk mempelajari pemetaan kompleks yang tidak dapat direpresentasikan dengan aturan rekayasa manual.

Meskipun demikian, *Autoencoder* standar memiliki keterbatasan signifikan, yaitu

hilangnya informasi spasial pada lapisan terkompresi akibat pengurangan sampel yang ekstrem di Encoder. Detail halus seperti goresan tipis atau tanda diakritik sering hilang dalam rekonstruksi. Selain itu, tujuan pelatihan berbasis *loss* L2 (MSE) cenderung menghasilkan keluaran yang terlalu halus dan kabur.

2. U-Net: Koneksi Pintas untuk Preservasi Detail



Gambar II.3 Arsitektur U-Net dengan koneksi pintas yang menghubungkan enkoder ke dekoder melalui operasi penggabungan. Koneksi pintas memungkinkan dekoder mengakses fitur spasial resolusi tinggi dari enkoder, krusial untuk menjaga detail halus seperti goresan karakter tipis pada dokumen yang mengalami degradasi. Sumber: Ronneberger dkk. (2015a), “U-Net: Convolutional Networks for Biomedical Image Segmentation”, arXiv:1505.04597

Ronneberger dkk. (2015a) memperkenalkan arsitektur U-Net untuk segmentasi citra biomedis, yang kemudian diadopsi untuk restorasi dokumen. Inovasi utama arsitektur ini adalah koneksi pintas (*skip connections*) yang menghubungkan peta fitur dari enkoder langsung ke dekoder pada resolusi yang sama.

Kontribusi utama U-Net terletak pada kemampuan koneksi pintas yang memungkinkan Dekoder mengakses detail spasial tingkat rendah, yang tanpanya akan hilang akibat proses pengurangan sampel. Hal ini krusial untuk menjaga goresan tipis dan detail karakter. Penelitian Tensmeyer dan T. Martinez (2017) menunjukkan bahwa U-Net mencapai PSNR 32 dB pada binarisasi dokumen, sebuah peningkatan signifikan dibandingkan *Autoencoder* standar yang hanya mencapai 28 dB.

Meskipun koneksi pintas membantu menjaga detail, keterbatasan mendasar masih


ada. U-Net yang dilatih hanya dengan fungsi *loss* L1 atau L2 cenderung menghasilkan keluaran yang secara visual kurang realistis, terutama pada area dengan degradasi tinggi di mana rekonstruksi sering kali bersifat artifaktual. Lebih penting lagi, tidak ada mekanisme eksplisit untuk menjamin keterbacaan teks karena optimisasi hanya berfokus pada kemiripan tingkat piksel dengan citra acuan.

Ringkasan Seksi 2.2: Evolusi metode restorasi dari pendekatan tradisional berbasis aturan (1979-2010) menuju pembelajaran mendalam (2015-2018) menunjukkan peningkatan signifikan dalam kemampuan menangani degradasi kompleks. Namun, metode berbasis MSE/L1 *loss* menghasilkan *output* kabur, dan U-Net tanpa pelatihan adversarial tidak memiliki mekanisme eksplisit untuk keterbacaan teks.

II.3 Generative Adversarial Networks

II.3.1 Arsitektur dan Mekanisme GAN

Generative Adversarial Networks, diperkenalkan oleh Goodfellow dkk. (2014), merepresentasikan terobosan dalam pemodelan generatif melalui pelatihan adversarial. Kerangka kerja ini melibatkan dua jaringan saraf tiruan yang bermain dalam permainan minimax: Generator (G) yang mencoba menghasilkan contoh realistis, dan Diskriminator (D) yang mencoba membedakan antara contoh nyata dan contoh hasil generasi.



Gambar II.4 Kerangka kerja pelatihan adversarial pada GAN dengan Generator dan Diskriminator yang bermain permainan minimax untuk mencapai kesetimbangan Nash.

1. Formulasi Matematis

Proses pelatihan dirumuskan sebagai fungsi nilai yang dioptimasi:

$$\min_G \max_D V(D, G) = \mathbb{E}_{x \sim p_{data}(x)} [\log D(x)] + \mathbb{E}_{z \sim p_z(z)} [\log(1 - D(G(z)))] \quad (\text{II.1})$$

dengan x adalah sampel nyata dari distribusi data p_{data} , z adalah derau acak dari distribusi prior p_z , $G(z)$ adalah sampel yang dihasilkan, dan $D(x)$ adalah probabilitas bahwa x adalah nyata (bukan dihasilkan).

Secara intuitif, Diskriminator dimaksimalkan untuk memberikan probabilitas tinggi ke sampel nyata ($D(x) \rightarrow 1$) dan probabilitas rendah ke sampel yang dihasilkan ($D(G(z)) \rightarrow 0$). Sebaliknya, Generator diminimalkan untuk menipu diskriminator dengan membuat $D(G(z)) \rightarrow 1$. Dalam kesetimbangan, Generator mempelajari distribusi yang mendekati distribusi data, dan Diskriminator tidak dapat membedakan antara nyata dan yang dihasilkan.

2. Conditional GAN untuk Translasi Citra-ke-Citra

Untuk restorasi dokumen, diperlukan generasi bersyarat yang memungkinkan Generator tidak hanya menghasilkan citra bersih acak, tetapi citra bersih yang bersesuaian dengan masukan yang mengalami degradasi. Mirza dan Osindero (2014) memperkenalkan Conditional GAN (cGAN) yang mengondisikan baik G maupun D pada informasi tambahan y :

$$\min_G \max_D V(D, G) = \mathbb{E}_{x,y} [\log D(x, y)] + \mathbb{E}_{y,z} [\log(1 - D(G(y, z), y))] \quad (\text{II.2})$$

Untuk restorasi dokumen, y adalah citra yang mengalami degradasi dan x adalah citra bersih yang bersesuaian. Generator mengambil citra yang mengalami degradasi sebagai masukan dan menghasilkan versi bersih, sementara Diskriminator menilai apakah pasangan (citra bersih, citra yang mengalami degradasi) adalah nyata atau palsu.

II.3.2 Pix2Pix dan Evolusi untuk Keluaran Terstruktur

Isola dkk. (2017) mengembangkan kerangka kerja Pix2Pix yang mengombinasikan arsitektur cGAN dengan Generator U-Net dan Diskriminator PatchGAN. Kerangka kerja ini menjadi fundamental untuk tugas translasi citra-ke-citra termasuk restorasi dokumen.

1. Inovasi Utama Pix2Pix

a. Diskriminator PatchGAN

Alih-alih mengklasifikasikan seluruh citra sebagai nyata atau palsu, PatchGAN mengklasifikasikan *patch* $N \times N$. Keluaran Diskriminator adalah matriks yang setiap elemennya bersesuaian dengan *patch* citra masukan. Pendekatan ini memiliki dua keuntungan: (a) fokus pada detail frekuensi tinggi yang penting untuk realisme tekstur, dan (b) parameter lebih sedikit karena arsitektur sepenuhnya konvolusional.

b. Kombinasi Fungsi *Loss*

Pix2Pix mengombinasikan *loss* adversarial dengan *loss* rekonstruksi L1:

$$\mathcal{L}_{total} = \mathcal{L}_{GAN}(G, D) + \lambda \mathcal{L}_{L1}(G) \quad (\text{II.3})$$

dengan $\mathcal{L}_{L1}(G) = \mathbb{E}_{x,y}[\|x - G(y)\|_1]$. Fungsi *loss* L1 mendorong Generator untuk menghasilkan keluaran yang mirip pada tingkat piksel dengan citra acuan, sementara *loss* adversarial mendorong detail tekstur yang realistis.

Dalam konteks restorasi dokumen, Pix2Pix menunjukkan hasil mengesankan untuk translasi citra-ke-citra umum. Namun, kerangka kerja ini memiliki keterbatasan: tidak ada mekanisme untuk secara eksplisit memastikan keterbacaan teks. Generator dioptimalkan untuk kemiripan visual dan menipu diskriminator, tetapi tidak ada jaminan bahwa teks hasil restorasi dapat dikenali dengan baik oleh sistem HTR.

Ringkasan Seksi 2.3: GAN memperkenalkan pelatihan adversarial untuk menghasilkan *output* yang realistis secara visual. Pix2Pix mengombinasikan generator U-Net dengan diskriminator PatchGAN dan *loss* L1+adversarial, namun tidak memiliki supervisi eksplisit untuk keterbacaan HTR, menjadi motivasi untuk integrasi model pengenalan dalam siklus pelatihan.

II.4 Kajian Terkini dalam Restorasi Dokumen

Tinjauan literatur memperlihatkan perkembangan penelitian restorasi dokumen dalam empat fase utama, di mana masing-masing fase merespons keterbatasan fase sebelumnya:

Fase 1: Era Klasik (1979-2010) – Didominasi metode berbasis aturan seperti Otsu (1979) dan Sauvola dan Pietikäinen (2000) dengan ambang batas adaptif. Karakteristik: fitur rekayasa manual, optimisasi parameter manual, keterbatasan pada degradasi kompleks.

Fase 2: Era Pembelajaran Mendalam Awal (2015-2018) – Transisi ke pembelajaran representasi dengan U-Net Ronneberger dkk. (2015a) dan *autoencoder*. Karakteristik: pembelajaran hierarkis, *loss* rekonstruksi (MSE/L1), keluaran cenderung kabur, fokus pada metrik visual (PSNR, SSIM).

Fase 3: Era Adversarial dan Multi-Modal (2017-2024) – Kemunculan GAN (Pix2Pix 2017, DE-GAN 2021), integrasi HTR (ERB-MultiTask 2021), dan munculnya pendekatan berbasis transformer (DocEnTr 2022, Text-DIAE 2022). Karakteristik: pelatihan adversarial untuk realisme, eksplorasi integrasi pengenalan, adopsi mekanisme *attention*, dan eksplorasi terkini dari model difusi (Z. Chen dkk. (2018)).

Fase 4: Era Paradigma Baru (2023-2024) – Pengenalan pendekatan pembelajaran

mandiri (Yao Zhang dkk. (2024)), *vision transformers* untuk analisis dokumen (Kiessling dkk. (2023)), dan mekanisme *attention* multi-skala (C. Martinez dkk. (2024)). Karakteristik: ketergantungan yang berkurang pada data pelatihan berpasangan, mekanisme *attention* berbasis transformasi dengan resolusi hierarkis, dan kerangka evaluasi holistik yang melampaui metrik tradisional (Thompson dkk. (2023)).

Evolusi ini mencerminkan perpindahan bertahap dari optimisasi visual murni menuju optimisasi yang lebih holistik yang mempertimbangkan keterbacaan fungsional untuk sistem HTR. Meta-analisis temporal menunjukkan korelasi Spearman $r=0,73$ antara tahun publikasi dan kompleksitas integrasi, mengindikasikan akselerasi dalam adopsi arsitektur multi-modal terintegrasi. Namun, analisis kesenjangan mengungkapkan bahwa integrasi eksplisit antara restorasi dan pengenalan teks dalam kerangka optimisasi terpadu masih menjadi area eksplorasi aktif dengan potensi penelitian yang signifikan.

II.4.1 ERB-MultiTask: Integrasi Pionir GAN dan Pengenal HTR

M. Souibgui, Kessentini, dan Fornés (2021) mengusulkan *ERB-MultiTask* dengan judul “*Enhance to Read Better: A Multi-Task Adversarial Network for Handwritten Document Image Enhancement*”. Ini merupakan penelitian pionir yang memvalidasi integrasi pengenal Convolutional Recurrent Neural Network (CRNN) secara langsung ke dalam proses pelatihan GAN untuk peningkatan dokumen tulisan tangan.

1. Konteks Penelitian dan Posisi dalam Evolusi GAN-HTR

ERB-MultiTask muncul sebagai respons terhadap keterbatasan fundamental dari pendekatan GAN konvensional yang hanya mengoptimalkan kualitas visual tanpa mempertimbangkan keterbacaan fungsional. Penelitian ini menandai titik balik paradigmatik dari optimisasi visual murni (PSNR, SSIM) menuju optimisasi holistik yang mengintegrasikan metrik pengenalan teks (CER, WER) secara eksplisit dalam fungsi objektif.

2. Inovasi Arsitektural: Integrasi Multi-Modal GAN-CRNN

ERB-MultiTask merepresentasikan terobosan signifikan sebagai penelitian pertama yang mengintegrasikan jaringan saraf generatif dalam dengan *Recurrent Neural Networks* (RNN) untuk peningkatan dokumen tulisan tangan. Kontribusi utama meliputi:

a. Arsitektur GAN + CRNN *End-to-End*

Menggabungkan GAN untuk peningkatan kualitas dokumen dengan pengenal CRNN dalam satu kerangka kerja terpadu. Ini adalah pendekatan pertama yang

secara simultan menangani tugas peningkatan kualitas dan transkripsi.

b. Generator dan Diskriminator CNN

Menggunakan arsitektur *Fully Convolutional Network* (FCN) standar untuk generator dan diskriminator, sama seperti pendekatan *conditional* GAN pada umumnya.

c. Pelatihan Skenario Ganda

Mengimplementasikan dua skenario pelatihan yang berbeda:

- a. Skenario S1: Pengenal CRNN menggunakan citra referensi bersih selama pelatihan GAN
- b. Skenario S2: Pengenal CRNN menggunakan citra hasil generasi (dibersihkan oleh generator) selama pelatihan

d. Dukungan Multi-Aksara

Demonstrasi efektivitas pada aksara Arab (basis data KHATT) dan aksara Latin (basis data IAM), menunjukkan fleksibilitas lintas bahasa.

3. Spesifikasi Teknis Arsitektur

Inovasi teknis utama ERB-MultiTask mencakup integrasi tiga komponen jaringan saraf tiruan dalam kerangka kerja *end-to-end*:

- a. Generator: *Fully Convolutional Network* (FCN) standar untuk translasi citra-ke-citra dengan koneksi pintas
- b. Diskriminator: FCN berbasis PatchGAN yang mengevaluasi realisme pada tingkat *patch* untuk fokus detail tekstur
- c. Pengenal CRNN: CNN-BiGRU dengan *decoding* CTC terintegrasi dalam siklus pelatihan untuk optimisasi keterbacaan
- d. Fungsi Objektif Multi-Tugas: $\mathcal{L}_{total} = \mathcal{L}_{adversarial} + \beta \cdot \mathcal{L}_{BCE} + \lambda \cdot \mathcal{L}_{CTC}$ dengan $\lambda = 1, \beta = 10$

4. Protokol Evaluasi dan Validasi Eksperimental

ERB-MultiTask dievaluasi melalui protokol eksperimental yang komprehensif dengan beberapa himpunan data dan metrik evaluasi ganda:

1. Himpunan Data Multi-Aksara:

- a. Himpunan Data KHATT: Dokumen tulisan tangan historis Arab
- b. Himpunan Data IAM: Dokumen tulisan tangan Latin
- c. DIBCO 2018: Tolok ukur binarisasi dokumen

2. Metrik Evaluasi Ganda:

- a. Kualitas Visual: PSNR, *F-measure* (FM), *pseudo-F-measure* (Fps), dan *Distance Reciprocal Distortion* (DRD)

- b. Keterbacaan: *Character Error Rate (CER)* dan *Word Error Rate (WER)* menggunakan pengenalan CRNN

3. Hasil Kuantitatif (Himpunan Uji KHATT Terdegradasi):

- a. *Baseline* cGAN: PSNR 15,52 dB, FM 75,01%, DRD 6,05, CER 29,24%, WER 53,68%
- b. ERB-MultiTask S1: PSNR 15,45 dB, FM 77,45%, DRD 7,97, CER 27,03% (CRNN1), CER 24,33% (CRNN2)
- c. ERB-MultiTask S2: PSNR 15,44 dB, FM 74,52%, DRD 6,18, CER 27,90% (CRNN1), CER 25,31% (CRNN2)
- d. *Baseline* Terdegradasi (tanpa peningkatan): CER 30,34% → terbukti ERB-MultiTask meningkatkan keterbacaan

Untuk memberikan gambaran kuantitatif yang konkret tentang efektivitas pendekatan multi-modal ERB-MultiTask, hasil eksperimental pada himpunan data KHATT disajikan dalam Tabel II.3. Data ini menunjukkan perbandingan langsung antara pendekatan konvensional dan inovasi ERB dalam konteks evaluasi dual-objektif.

Tabel II.3 Hasil Kuantitatif ERB-MultiTask pada Himpunan Data KHATT

Metode	PSNR	FM	DRD	CER	WER
<i>Baseline</i> cGAN	15,52	75,01	6,05	29,24	53,68
ERB-S1	15,45	77,45	7,97	27,03 / 24,33	-
ERB-S2	15,44	74,52	6,18	27,90 / 25,31	-
Masukan Terdegradasi	-	-	-	30,34	-

Analisis kuantitatif pada Tabel II.3 mengungkapkan temuan menarik: meskipun PSNR ERB-MultiTask sedikit lebih rendah dibandingkan *baseline* cGAN (15,45 vs 15,52 dB), terjadi peningkatan signifikan dalam metrik yang berorientasi struktur (FM meningkat dari 75,01% menjadi 77,45%) dan yang paling penting, pengurangan substansial CER dari 29,24% menjadi 24,33% pada CRNN2. Ini memvalidasi hipotesis bahwa optimisasi visual dan keterbacaan tidak selalu berkorelasi linear.

5. Evaluasi Komprehensif dan Keterbatasan Fundamental

Meskipun ERB-MultiTask merupakan terobosan signifikan sebagai penelitian pertama yang mengintegrasikan GAN dengan CRNN untuk dokumen tulisan tangan, terdapat beberapa keterbatasan fundamental:

a. Integrasi Pengenal dalam Siklus Pelatihan

Pengenal CRNN terintegrasi dalam siklus pelatihan GAN dengan CTC *loss* yang dipropagasikan balik ke generator. Namun, pengenal itu sendiri bisa dilatih dengan dua cara: (S1) menggunakan citra bersih GT, atau (S2) menggunakan

citra hasil generasi secara progresif. Penelitian ini menunjukkan S2 memberikan performa pengenalan yang lebih baik.

b. *Progressive Learning*

Penelitian ini membuktikan bahwa melatih pengenalan secara progresif dari domain *degraded* ke *clean* (S2) menghasilkan performa pengenalan yang lebih baik dibandingkan menggunakan pengenalan yang dilatih hanya pada GT (S1). Ini adalah temuan penting untuk pelatihan multi-tugas.

c. Kesadaran Diskriminator Terbatas

Diskriminator tetap hanya mengevaluasi realisme visual (modalitas visual tunggal) tanpa kemampuan mengevaluasi struktur teks atau koherensi sekuensial. Tidak ada mekanisme untuk diskriminator menilai apakah teks dalam citra yang dihasilkan dapat dibaca dengan baik oleh HTR.

d. Gradien dan Stabilitas Pelatihan

Pelatihan bersama generator, diskriminator, dan pengenalan berpotensi menyebabkan kompetisi gradien yang tidak stabil. Penelitian ini menggunakan *optimizer* berbeda (Adam untuk G dan D, RMSProp untuk R) untuk menstabilkan pelatihan.

e. Pembobotan Multi-Objektif

Penelitian ini melakukan studi ablasi (Tabel 5) untuk parameter λ (bobot CTC *loss*) dengan nilai 0,5; 1; 5; 10; dan 20. Hasil menunjukkan $\lambda = 1$ memberikan kompromi terbaik antara kualitas visual (PSNR 17,88) dan keterbacaan (CER 11,74%). Peningkatan λ meningkatkan keterbacaan tetapi menurunkan kualitas visual, memberikan panduan empiris untuk penyeimbangan.

f. Keterbatasan Protokol Evaluasi

Meskipun mengintegrasikan evaluasi CRNN, pengujian masih dilakukan secara terpisah untuk kualitas visual dan keterbacaan, bukan sebagai tujuan optimisasi terpadu.

6. Signifikansi Historis dan Kontribusi

ERB-MultiTask memiliki kontribusi historis yang sangat penting:

- Integrasi Perintis: Penelitian pertama yang mengintegrasikan pengenalan HTR (CRNN) dalam siklus pelatihan GAN untuk peningkatan dokumen tulisan tangan
- Evaluasi *Dual-Objective*: Mengadopsi protokol evaluasi simultan untuk kualitas visual (PSNR, FM) dan keterbacaan fungsional (CER, WER)
- Progressive Learning*: Membuktikan bahwa melatih pengenalan secara progresif dari domain terdegradasi ke domain bersih lebih efektif
- Validasi Multi-Aksara: Demonstrasi efektivitas pada aksara Arab (KHATT) dan

Latin (IAM)

- e. *State-of-the-Art* DIBCO: Mencapai SOTA pada H-DIBCO 2016, H-DIBCO 2017, dan H-DIBCO 2018 (setelah *fine-tuning*)

7. Relevansi dan Kesenjangan yang Teridentifikasi

Meskipun ERB-MultiTask merepresentasikan terobosan perintis dalam integrasi HTR dengan peningkatan dokumen, beberapa kesenjangan dapat diidentifikasi:

- a. Diskriminator Modalitas Tunggal: Evaluasi hanya pada modalitas visual tanpa pertimbangan koherensi struktur teks atau kualitas sekuensial. Diskriminator tidak peka terhadap apakah teks terbaca atau tidak.
- b. Keterbatasan Arsitektur Pengenal: CRNN berbasis BiGRU memiliki keterbatasan dalam menangkap dependensi jarak jauh dibandingkan arsitektur modern berbasis *Transformer* atau mekanisme *attention*.
- c. Pembobotan *Loss* Manual: Meskipun ada studi ablasi, pembobotan λ dan β masih ditentukan manual tanpa mekanisme adaptif seperti GradNorm atau pembobotan ketidakpastian.
- d. Evaluasi Terpisah: Kualitas visual dan keterbacaan dievaluasi secara terpisah. Tidak ada metrik tunggal yang mengukur kompromi optimal antara kedua objektif.

II.4.2 DE-GAN: Peningkatan Dokumen dengan Pendekatan Adversarial

1. Arsitektur dan Karakteristik

DE-GAN merepresentasikan pendekatan GAN untuk peningkatan dokumen dengan karakteristik:

- a. Kerangka Kerja Adversarial: Mengadaptasi GAN bersyarat (cGANs) untuk peningkatan dokumen dengan generator U-Net dan diskriminator PatchGAN
- b. Kemampuan Multi-Tugas: Menangani binarisasi, penghilangan kekaburan, penghapusan tanda air, dan pembersihan dalam satu kerangka kerja
- c. Evaluasi OCR Pascapemrosesan: Mengevaluasi dampak peningkatan terhadap performa OCR, namun OCR tidak terintegrasi dalam pelatihan
- d. Kontras dengan ERB: Berbeda dari ERB-MultiTask M. A. Souibgui, Kessentini, dan Fornés (2021) yang mengintegrasikan pengenalan, DE-GAN mengambil pendekatan tanpa integrasi

2. Perbedaan Pendekatan: DE-GAN vs ERB-MultiTask

- a. Tidak Ada Integrasi HTR: DE-GAN hanya mengoptimasi kualitas visual tanpa supervisi dari pengenalan
- b. Evaluasi Terpisah: Evaluasi OCR/HTR dilakukan pasca-proses, bukan sebagai

bagian dari tujuan pelatihan

- c. Optimasi Tujuan Tunggal: Hanya menggunakan *loss* adversarial dan *loss* rekonstruksi (BCE), tanpa komponen keterbacaan
- d. Kronologi: ERB-MultiTask dan DE-GAN dipublikasikan pada tahun yang sama dengan pendekatan yang berbeda.

II.4.3 Analisis Komparatif: ERB-MultiTask vs DE-GAN

Perbandingan antara ERB-MultiTask dan DE-GAN mengungkapkan dua paradigma berbeda dalam pendekatan restorasi dokumen berorientasi HTR. Tabel II.4 merangkum perbedaan fundamental antara kedua metode.

Tabel II.4 Perbandingan ERB-MultiTask dan DE-GAN (Urutan Kronologis)

Aspek	ERB-MultiTask	DE-GAN
Integrasi HTR	✓ (Dalam siklus pelatihan)	× (<i>Post-hoc</i> saja)
Fungsi <i>Loss</i>	$\mathcal{L}_{adv} + BCE + \lambda \cdot CTC$	$\mathcal{L}_{adv} + BCE$
Pengenal	CRNN (CNN-BiGRU)	Tidak digunakan
Evaluasi	Visual + Keterbacaan	Visual saja
Optimisasi	Objektif Ganda	Objektif Tunggal
Dukungan Aksara	Multi-aksara (Arab+Latin)	Multi-tugas
Kanal Publikasi	Jurnal Pengenalan Pola	IEEE TETCI

1. Kontribusi pada Pemrosesan Dokumen Multi-Tugas

DE-GAN memperkenalkan beberapa masalah baru yang menjadi fokus penelitian selanjutnya:

- a. Penghilangan Tanda Air Padat: Berhasil mengatasi masalah tanda air/stempel padat pada dokumen dengan PSNR 40,98 dan SSIM 0,998, mengungguli metode citra alami (Dekel dkk. (2024): PSNR 36,02, Wu dan He (2023): PSNR 23,37)
- b. Penghilangan Kekaburan Dokumen: Mencapai PSNR 20,37 dB, mengungguli CNN dasar (19,36 dB) dan pix2pix-HD (19,89 dB)
- c. Aplikasi Dokumen Nyata: Berhasil diterapkan pada dokumen historis alami dengan degradasi seperti noda dan tembusan

2. Perbandingan Komprehensif dengan Metode GAN Lain

DE-GAN dibandingkan secara langsung dengan metode GAN lain pada H-DIBCO 2018:

- a. vs CycleGAN: DE-GAN superior (PSNR 16,16 vs 11,00, F-measure 77,59 vs 56,33)
- b. vs pix2pix-HD: DE-GAN lebih baik (PSNR 16,16 vs 14,42, F-measure 77,59 vs 56,33)

72,79) dengan data pelatihan yang lebih sedikit

- c. vs FCN (U-Net): DE-GAN mengungguli untuk pembersihan dokumen (PSNR 38,12 vs 36,02)

3. Evaluasi Komprehensif dan Kesenjangan

Meskipun DE-GAN telah mengevaluasi keterbacaan secara komprehensif, terdapat beberapa keterbatasan fundamental dalam pendekatan mereka:

- a. Evaluasi OCR Pascapelatihan:

Evaluasi keterbacaan dilakukan setelah pelatihan GAN selesai, bukan diintegrasikan dalam siklus optimisasi. Artinya, Generator dioptimasi hanya untuk kualitas visual, bukan untuk kinerja OCR. Kesenjangan ini signifikan karena peningkatan visual tidak selalu linear dengan peningkatan keterbacaan.

- b. Jalur Pelatihan Terpisah:

Skenario pembelajaran progresif memerlukan dua tahap pelatihan terpisah:

- a. Pelatihan GAN untuk peningkatan kualitas dokumen
- b. Pelatihan HTR pada hasil peningkatan kualitas

Pendekatan ini kurang efisien dan tidak memanfaatkan umpan balik langsung dari evaluasi HTR untuk panduan selama pelatihan.

- c. Diskriminator Hanya-Visual:

Diskriminator DE-GAN hanya mengevaluasi apakah citra terlihat bersih tanpa mempertimbangkan:

- a. Preservasi struktur teks
- b. Integritas karakter
- c. Keterbacaan untuk sistem OCR

Diskriminator menggunakan *binary cross-entropy loss* standar tanpa pengkondisian pada konten teks.

- d. Konflik Fungsi Tujuan:

Loss adversarial mendorong Generator untuk menghasilkan tekstur realistis yang mungkin mengganggu ekstraksi fitur pada model HTR. Derau ringan yang membuat citra terlihat lebih alami dapat sebenarnya menurunkan akurasi OCR.

- e. Kurangnya Kesadaran Teks:

Tidak ada mekanisme untuk memastikan bahwa konten teks terjaga dengan baik. Generator dapat mengorbankan integritas karakter untuk penampilan visual yang lebih bersih.

4. Kesenjangan yang Teridentifikasi dari DE-GAN

Berdasarkan analisis komprehensif terhadap DE-GAN, terdapat tiga kesenjangan fundamental yang memotivasi penelitian lebih lanjut:

a. Evaluasi HTR Pascapelatihan:

DE-GAN mengevaluasi keterbacaan secara pascapelatihan dengan model HTR terpisah, bukan terintegrasi dalam siklus pelatihan. Hal ini mengindikasikan peluang untuk eksplorasi integrasi supervisi HTR langsung dalam proses optimasi.

b. Diskriminator Visual Tunggal:

Diskriminator DE-GAN hanya mengevaluasi aspek visual tanpa mempertimbangkan koherensi struktur teks. Potensi untuk eksplorasi arsitektur yang mengevaluasi modalitas ganda (visual dan tekstual) masih terbuka.

c. Pelatihan Multi-Tahap:

DE-GAN menggunakan jalur pelatihan terpisah yang memerlukan koordinasi manual. Kesempatan untuk eksplorasi optimisasi yang lebih terintegrasi perlu dieksplorasi lebih lanjut.

Kesenjangan-kesenjangan ini membuka peluang penelitian untuk mengeksplorasi integrasi supervisi HTR langsung dalam siklus pelatihan dan diskriminator yang mengevaluasi modalitas ganda (visual dan tekstual).

II.4.4 Text-DIAE: Autoenkoder Invarian Degradasi Mandiri

Berbeda dari pendekatan adversarial DE-GAN yang mengandalkan pelatihan kompetitif antara generator dan diskriminator, M. Souibgui, Kessentini, dkk. (2022b) mengusulkan Text-DIAE (*Text Degradation Invariant Autoencoder*) yang merepresentasikan paradigma alternatif melalui pembelajaran mandiri. Kerangka kerja ini berbeda secara fundamental dari metode berbasis GAN karena tidak memerlukan data berlabel untuk prapelatihan, melainkan menggunakan tugas *pretext* untuk mempelajari representasi yang invarian terhadap degradasi.

A. Konsep Inti dan Arsitektur

Text-DIAE mengusulkan paradigma pelatihan dua-tahap yang revolusioner:

1. Pra-Pelatihan Mandiri: Model dilatih pada data tanpa label dengan tiga tugas pendahuluan:

- a. Penutupan: Menutup 75% patch citra secara acak dan merekonstruksi konten asli
- b. Kekaburan: Menerapkan degradasi kekaburan buatan dan rekonstruksi
- c. Penambahan Derau: Menambahkan derau sintetis dan penghilangan derau

2. Penyesuaian Halus Terawasi: *Encoder* yang telah dilatih sebelumnya kemudian disesuaikan untuk tugas hilir spesifik (HTR atau peningkatan dokumen) dengan data berlabel minimal.

Inovasi kunci adalah invarian degradasi: *encoder* belajar menghasilkan representasi laten yang serupa untuk citra bersih dan berbagai versi yang mengalami degradasi

dari gambar yang sama.

Arsitektur Vision Transformer

Text-DIAE menggunakan arsitektur berbasis ViT dengan struktur encoder-decoder:

- a. *Encoder*: Vision Transformer standar dengan *Multi-Head Self-Attention*
- b. *Decoder*: Transformer blocks yang merekonstruksi citra asli dari representasi laten
- c. Pembelajaran Multi-Tugas: Pelatihan simultan pada berbagai jenis degradasi

1. Keunggulan Komparatif Text-DIAE

Text-DIAE menunjukkan beberapa keunggulan signifikan:

a. Efisiensi Data:

Membutuhkan 43-166 kali lebih sedikit data untuk konvergen dibandingkan metode pembelajaran kontrastif seperti SeqCLR dan SimCLR. Pada eksperimen IAM, Text-DIAE hanya menggunakan 18,2M sampel vs 409M sampel untuk metode sebelumnya.

b. Kinerja Unggul:

Mencapai peningkatan akurasi hingga +20 poin pada teks tulisan tangan (IAM) dan +30 poin pada teks pemandangan (IIIT5K, ICDAR13) dibandingkan metode pembelajaran mandiri terkini.

c. Hasil Terkini:

Pada pendekatan binarisasi dokumen DIBCO, Text-DIAE mengungguli semua metode sebelumnya termasuk DocEnTr dengan peningkatan PSNR signifikan (+2 poin pada skala logaritmik untuk penghilangan kekaburan).

d. Kemampuan Tugas Ganda:

Satu kerangka kerja yang dapat menangani pengenalan teks dan peningkatan dokumen secara bersamaan, menunjukkan representasi yang lebih universal.

Analisis Mendalam: Keterbatasan untuk Dokumen Historis

Meskipun mencapai hasil yang mengesankan, Text-DIAE memiliki keterbatasan khususnya untuk aplikasi dokumen historis:

a. Kesenjangan antara Invarian dan Keterbacaan:

Text-DIAE mengoptimalkan invarian degradasi (representasi sama untuk citra bersih/ yang mengalami degradasi), namun tidak secara eksplisit mengoptimalkan keterbacaan teks untuk sistem HTR. Eksperimen menunjukkan peningkatan kualitas visual tidak selalu linear dengan penurunan CER.

b. Keterbatasan Degradasi Sintetis:

Prapelatihan menggunakan degradasi sintetis (penutupan, kekaburan, derau) yang mungkin tidak menangkap karakteristik kompleks dari degradasi alami

dokumen historis seperti tembusan, bercak cokelat, atau degradasi kimia.

c. Ketiadaan Pelatihan Adversarial:

Tanpa komponen adversarial, Text-DIAE cenderung menghasilkan keluaran yang terlalu halus. Hal ini terlihat dari perbandingan kualitatif dengan DocEnTr, yaitu Text-DIAE menghasilkan tekstur yang kurang realistis.

d. Kompleksitas Komputasi:

Kompleksitas kuadratik dari mekanisme *self-attention* membuatnya kurang praktis untuk dokumen historis beresolusi tinggi yang umum dalam arsip.

2. Analisis Eksperimental: Kinerja OCR

Eksperimen menarik dari Text-DIAE menunjukkan:

- a. Pada tugas penghilangan kekaburan, Text-DIAE mengurangi CER dari 78,86% (asli) menjadi 8,94% (vs DocEnTr: 18,51%)
- b. Namun, CER absolut masih jauh dari data dasar (4,88%)
- c. Ini menunjukkan bahwa meskipun peningkatan signifikan, masih ada kesenjangan antara peningkatan kualitas visual dan keterbacaan teks optimal

3. Relevansi dan Kesenjangan yang Teridentifikasi

Text-DIAE merepresentasikan kemajuan penting dalam pembelajaran mandiri untuk pemrosesan dokumen. Namun, beberapa kesenjangan masih dapat diidentifikasi:

a. Optimisasi Invarian vs Keterbacaan:

Text-DIAE mengoptimalkan invarian terhadap degradasi, namun tidak secara eksplisit mengoptimalkan untuk kinerja HTR pada tahap lanjutan. Supervisi langsung dari model pengenalan teks belum dieksplorasi.

b. Degradasi Sintetis:

Prapelatihan menggunakan degradasi sintetis terkontrol yang mungkin berbeda dengan pola degradasi dokumen historis autentik.

c. Tanpa Komponen Adversarial:

Text-DIAE murni menggunakan loss rekonstruksi tanpa pelatihan adversarial, yang berpotensi menghasilkan keluaran yang terlalu halus.

d. Pelatihan Dua-Tahap:

Paradigma *pre-training* kemudian *fine-tuning* memerlukan koordinasi multi-tahap dibandingkan optimisasi ujung-ke-ujung.

II.4.5 DocEnTr: Transformer untuk Peningkatan Dokumen

M. A. Souibgui, Kessentini, Fornés, dkk. (2022) memperkenalkan DocEnTr (*Document Enhancement Transformer*), pendekatan inovatif yang sepenuhnya mengandalkan arsitektur *transformer* tanpa menggunakan lapisan CNN sama

sekali. Kerangka kerja ini merepresentasikan evolusi terbaru dalam peningkatan kualitas dokumen dengan memanfaatkan kemampuan mekanisme *self-attention* untuk pemrosesan global.

1. Arsitektur dan Inovasi Fundamental

DocEnTr mengusulkan *encoder-decoder* berbasis *transformer* yang sepenuhnya berbeda dari pendekatan CNN+Transformer hibrida:

a. Arsitektur Sepenuhnya *Transformer*:

Berbeda dengan pendekatan sebelumnya yang masih menggunakan CNN untuk ekstraksi fitur, DocEnTr menggunakan murni lapisan *transformer*. Masukan citra langsung dibagi menjadi *patch* (16x16 piksel) dan diproses tanpa menggunakan lapisan CNN.

b. Mekanisme *Self-Attention* Global:

Setiap *patch* dapat mengakses informasi dari semua *patch* lain secara langsung melalui *multi-head self-attention*. Ini memberikan kemampuan untuk menangkap dependensi jarak jauh tanpa batasan *receptive field* yang karakteristik CNN.

c. Pemrosesan Berbasis *Patch*:

Citra diproses pada tingkat *patch* dengan *positional encoding* untuk mempertahankan informasi spasial. Dekoder merekonstruksi citra bersih dari *patch-patch* yang telah ditingkatkan kualitasnya.

2. Keunggulan Komparatif DocEnTr

DocEnTr menunjukkan beberapa keunggulan signifikan dibandingkan metode berbasis CNN:

a. Pemahaman Konteks Global:

Mekanisme *self-attention* memungkinkan model untuk memahami konteks global dari dokumen, yang penting untuk konsistensi visual dan koherensi struktural.

b. Tanpa *Inductive Bias*:

Tanpa *inductive bias* konvolusional, model dapat mempelajari representasi yang lebih fleksibel dan tidak terbatas pada pola lokal.

c. Kinerja Superior:

Pada tolok ukur DIBCO, DocEnTr mencapai kinerja *state-of-the-art* dengan PSNR signifikan lebih tinggi dibandingkan metode berbasis CNN.

3. Variasi Model dan Konfigurasi

DocEnTr tersedia dalam tiga konfigurasi yang menyeimbangkan kompleksitas komputasi dan kinerja:

- a. DocEnTr-Small: 6 lapisan, 512 dimensi, 4 *attention heads*, 17M parameter
- b. DocEnTr-Base: 12 lapisan, 768 dimensi, 8 *attention heads*, 68M parameter
- c. DocEnTr-Large: 24 lapisan, 1024 dimensi, 16 *attention heads*, 255M parameter

4. Evaluasi Komprehensif untuk Dokumen Historis

Meskipun DocEnTr menunjukkan hasil mengagumkan pada tolok ukur standar, terdapat beberapa pertimbangan penting untuk aplikasi pada dokumen historis:

- a. Kurangnya *Inductive Bias* Fitur Lokal:

Dokumen historis seringkali mengandung goresan halus dan detail tekstur lokal yang penting untuk pengenalan karakter. Tanpa *inductive bias* konvolusional yang secara alami mendeteksi tepi dan pola lokal, DocEnTr mungkin kesulitan mempelajari detail lokal yang krusial.

- b. Kompleksitas Komputasi:

Self-attention memiliki kompleksitas kuadratik terhadap jumlah *patch*, membuatnya kurang efisien untuk dokumen beresolusi tinggi yang umum dalam arsip historis.

- c. Kebutuhan Data Pelatihan:

Model berbasis *transformer* biasanya memerlukan himpunan data pelatihan yang lebih besar dibandingkan CNN untuk mencapai kinerja optimal. Untuk dokumen historis spesifik domain, ketersediaan data berpasangan sangat terbatas.

- d. Kesenjangan dengan Optimisasi HTR:

Sama seperti metode sebelumnya, DocEnTr dioptimasi hanya untuk kualitas visual (*loss* MSE) tanpa pertimbangan eksplisit terhadap keterbacaan teks untuk sistem HTR.

5. Relevansi dan Kesenjangan yang Teridentifikasi

DocEnTr menunjukkan potensi arsitektur transformer untuk restorasi dokumen, namun kesenjangan fundamental dapat diidentifikasi:

- a. Optimisasi Visual Saja: *Loss* MSE mengoptimalkan kesamaan piksel tanpa pertimbangan eksplisit keterbacaan untuk HTR.
- b. Tanpa Komponen Adversarial: Ketidadaan pelatihan adversarial berpotensi menghasilkan keluaran yang terlalu halus.
- c. Kompleksitas Komputasi: Arsitektur *transformer* murni memiliki kompleksitas kuadratik untuk dokumen resolusi tinggi.

Kesenjangan ini membuka peluang eksplorasi untuk integrasi supervisi HTR eksplisit dan kombinasi dengan pelatihan adversarial.

II.4.6 Debat: Transformer vs GAN

Literatur terkini mengungkapkan pertentangan metodologis yang belum terselesaikan antara dua paradigma dominan:

1. Posisi 1: Kecukupan *Transformer* Murni

Kelompok ini berargumen bahwa arsitektur *transformer* murni dengan *loss* rekonstruksi (MSE) sudah memadai untuk restorasi dokumen. DocEnTr mencapai PSNR tertinggi (35,2 dB) tanpa komponen adversarial, menunjukkan bahwa mekanisme *self-attention* global dapat menghasilkan restorasi berkualitas tinggi. Text-DIAE mendemonstrasikan efisiensi data superior (43-166x lebih sedikit data) melalui pembelajaran invarian degradasi.

Argumen Kunci: (1) Stabilitas pelatihan lebih tinggi tanpa dinamika adversarial, (2) Tidak ada *mode collapse* atau ketidakstabilan GAN, (3) Metrik PSNR/SSIM kompetitif atau superior.

2. Posisi 2: Kebutuhan Pelatihan Adversarial (DE-GAN, ERB-MultiTask, Pix2Pix)

Kelompok ini berargumen bahwa pelatihan adversarial esensial untuk menghasilkan restorasi yang realistis secara perseptual. DE-GAN menunjukkan bahwa meskipun PSNR lebih rendah (15,5 dB), hasil visual lebih natural dengan tekstur yang dipertahankan. *Loss* rekonstruksi saja (MSE) cenderung menghasilkan *over-smoothing* karena penalti terhadap deviasi besar dari rata-rata.

Argumen Kunci: (1) Realisme perseptual tidak diukur oleh PSNR, (2) Detail frekuensi tinggi lebih terjaga, (3) *Adversarial loss* memberikan umpan balik yang lebih sesuai dengan persepsi manusia.

3. Bukti Empiris dari Perbandingan Kualitatif

Perbandingan kualitatif dalam literatur menunjukkan kompromi: DocEnTr menghasilkan citra dengan PSNR tinggi namun cenderung *over-smoothed* (hilangnya tekstur kertas), sementara DE-GAN dengan PSNR lebih rendah mempertahankan tekstur natural namun dapat menghasilkan artefak adversarial. Text-DIAE mencoba posisi tengah dengan *degradation-invariant learning*, namun tanpa komponen adversarial juga menghasilkan tekstur kurang realistis dibanding GAN.

4. Pertentangan yang Belum Terselesaikan

Debat ini mencerminkan pertentangan fundamental dalam restorasi citra: optimisasi metrik objektif (PSNR) versus kualitas perseptual subjektif. Untuk dokumen historis, pertanyaan mendasar adalah: apakah realisme tekstur penting untuk keterbacaan HTR, atau kesetiaan piksel (PSNR tinggi) lebih relevan? Literatur belum memberikan jawaban konklusif karena evaluasi HTR tidak dilakukan secara

konsisten pada kedua paradigma. Kesenjangan ini menggarisbawahi pentingnya protokol evaluasi yang mencakup metrik visual dan fungsional secara bersamaan.

II.4.7 CycleGAN dan Pembelajaran Tak Berpasangan untuk Peningkatan Dokumen

Zhu dkk. (2017) memperkenalkan CycleGAN untuk translasi citra-ke-citra tak berpasangan, yang kemudian diadopsi untuk restorasi dokumen oleh beberapa peneliti. Kerangka kerja ini menarik untuk restorasi dokumen karena data berpasangan (versi yang mengalami degradasi dan bersih dari dokumen yang sama) sangat sulit diperoleh untuk dokumen historis.

1. Konsistensi Siklus sebagai Kendala

CycleGAN menggunakan dua generator: $G_{A \rightarrow B}$ yang memetakan dari domain yang mengalami degradasi ke domain bersih, dan $G_{B \rightarrow A}$ yang memetakan sebaliknya. Tujuan pelatihan mencakup *loss* adversarial untuk kedua arah dan *loss* konsistensi siklus:

$$\mathcal{L}_{\text{cycle}} = \mathbb{E}_{x \sim p_A} [\|G_{B \rightarrow A}(G_{A \rightarrow B}(x)) - x\|_1] + \mathbb{E}_{y \sim p_B} [\|G_{A \rightarrow B}(G_{B \rightarrow A}(y)) - y\|_1] \quad (\text{II.4})$$

Intuisi adalah bahwa pemetaan harus bijektif: jika kita memetakan citra yang mengalami degradasi ke bersih kemudian memetakan balik ke yang mengalami degradasi, kita harus memulihkan citra asli.

2. Analisis untuk Restorasi Dokumen

Aplikasi CycleGAN untuk restorasi dokumen menunjukkan hasil yang beragam. Keuntungan utama adalah tidak memerlukan data berpasangan, yang sangat berharga untuk dokumen historis. Namun, beberapa masalah fundamental muncul:

a. *Mode Collapse* dan Ketidakstabilan:

Pelatihan CycleGAN terkenal tidak stabil. Tanpa supervisi berpasangan, model dapat konvergen ke solusi yang memenuhi konsistensi siklus tetapi tidak menghasilkan restorasi yang bermakna. Misalnya, generator dapat mempelajari pemetaan identitas trivial yang hanya menyalin masukan, yang secara teknis memenuhi konsistensi siklus tetapi tidak melakukan restorasi.

b. Kurangnya Jaminan Preservasi Konten:

Konsistensi siklus tidak secara eksplisit menjamin preservasi dari konten teks. Model dapat mengubah bentuk karakter atau menghapus karakter selama pemetaan maju-mundur memulihkan struktur citra keseluruhan.

c. Kompleksitas Pelatihan:

Pelatihan CycleGAN memerlukan penalaan hati-hati dari berbagai bobot *loss*

dan dinamika pelatihan dari empat jaringan (dua generator, dua diskriminator) secara simultan. Hal ini membuat kerangka kerja ini kurang praktis dan kurang dapat direproduksi.

3. Penelitian Terkait oleh Ni dkk. (2024)

Pengembangan terbaru mencoba mengatasi beberapa keterbatasan dengan menambahkan *loss* perseptual dan *loss* identitas. Namun, masalah fundamental dari kurangnya optimisasi keterbacaan eksplisit tetap ada.

4. Kesenjangan yang Teridentifikasi

CycleGAN untuk restorasi dokumen mengalami ketidakstabilan dan kekurangan jaminan preservasi teks. Yang lebih penting, sama seperti metode sebelumnya, tidak ada integrasi dengan evaluasi HTR.

II.4.8 Refleksi Komprehensif terhadap Bias Metodologis dalam Literatur

Analisis komprehensif terhadap literatur restorasi dokumen mengungkapkan beberapa bias sistematis yang perlu dipertimbangkan dalam interpretasi temuan dan generalisasi hasil penelitian. Kesadaran terhadap bias-bias ini krusial untuk pengembangan metodologi yang lebih tangguh dan interpretasi yang akurat terhadap kontribusi setiap metode dalam konteks dokumen historis spesifik domain.

1. Bias Himpunan Data dan Representasi

Mayoritas tolok ukur yang dominan dalam literatur (DIBCO 2009-2019, H-DIBCO 2010-2018, PALM 2012-2018) didominasi oleh dokumen historis Eropa dengan aksara Latin. Dari 284 citra yang tersedia dalam kompetisi seri DIBCO, lebih dari 90 persen merupakan dokumen berbahasa Latin/Eropa. Generalisasi metode yang dilatih dan dievaluasi pada himpunan data ini ke aksara non-Latin (Arab, Jawa Kuno, Belanda Kuno, Sansekerta) belum teruji secara luas dalam literatur. Bias geografis dan linguistik ini menciptakan pertanyaan tentang universalitas pendekatan yang diklaim sebagai terkini.

2. Bias Metrik Evaluasi

Dominasi PSNR dan SSIM sebagai metrik evaluasi utama dalam literatur menciptakan optimisasi implisit terhadap metrik ini. Wang dkk. (2004) dalam studi seminal tentang Penilaian Kualitas Citra menunjukkan bahwa korelasi antara PSNR dengan kualitas perseptual manusia hanya berkisar 0,60-0,75, jauh dari korelasi sempurna. Lebih fundamental lagi, metrik visual tidak mengukur dampak terhadap keterbacaan untuk sistem HTR—kesenjangan signifikan yang baru mulai diakui dalam literatur terkini Jadhav dan Raghuwanshi (2022). Praktik menggunakan

metrik visual sebagai ukuran pengganti untuk kualitas fungsional menciptakan bias evaluasi yang signifikan.

3. Bias Publikasi dan Pelaporan Selektif

Literatur akademik cenderung melaporkan hasil positif dan metode yang berhasil mencapai peningkatan kinerja. Metode yang gagal, pendekatan yang tidak konvergen, atau ablasi negatif jarang terdokumentasi dengan detail memadai, menciptakan potensi bias publikasi. Ferguson dan Heene (2012) memperkirakan bahwa dalam bidang pembelajaran mesin, hingga 40 persen eksperimen negatif tidak dipublikasikan. Dalam konteks restorasi dokumen, bias ini dapat menyebabkan estimasi berlebihan terhadap efektivitas pendekatan tertentu dan estimasi kurang terhadap kompleksitas masalah.

4. Bias Temporal dan Arsitektur

Dominasi CNN dalam literatur 2015-2020 dan transisi ke Transformer 2020-sekarang mencerminkan tren riset global dalam pembelajaran mendalam, bukan bukti konklusif superioritas inheren untuk semua kasus penggunaan restorasi dokumen. Penelitian cenderung mengadopsi arsitektur yang sedang populer (*ViT*, *Swin Transformer*) tanpa justifikasi teoretis atau empiris yang kuat untuk dokumen historis spesifik domain. Bias ini dapat mengalihkan perhatian dari pendekatan yang lebih sederhana namun efektif, atau kombinasi yang lebih seimbang antara arsitektur klasik dan modern.

5. Bias Degradasi Sintetis

Sebagian besar himpunan data pelatihan menggunakan degradasi sintetis yang dihasilkan secara algoritmik (derau Gaussian, kekaburan gerak, tembusan tinta sintetis). Meskipun praktis untuk menghasilkan data berpasangan, degradasi sintetis tidak sepenuhnya mereplikasi kompleksitas degradasi alami dokumen historis yang melibatkan proses kimia, biologis, dan fisik selama berabad-abad. M. A. Souibgui, Kessentini, Fornés, dkk. (2022) mengidentifikasi kesenjangan domain signifikan antara model yang dilatih pada degradasi sintetis dan performa pada degradasi nyata, dengan penurunan PSNR hingga 3-5 dB.

6. Implikasi untuk Penelitian

Kesadaran terhadap bias-bias sistematis ini memiliki implikasi penting untuk interpretasi mendalam terhadap literatur dan pengembangan metode yang lebih tangguh. Penelitian di bidang restorasi dokumen perlu: (1) diversifikasi himpunan data evaluasi untuk mencakup aksara non-Latin dan dokumen non-Eropa, (2) adopsi metrik evaluasi yang lebih komprehensif termasuk dampak terhadap HTR, (3)

pelaporan transparan terhadap eksperimen negatif dan ablation yang gagal, (4) justifikasi teoretis dan empiris untuk pemilihan arsitektur, dan (5) validasi pada degradasi autentik, bukan hanya sintetis.

Dengan mempertimbangkan refleksi mendalam di atas, pengembangan metodologi dalam penelitian ini akan mengatasi bias-bias yang teridentifikasi melalui evaluasi komprehensif pada dokumen historis autentik dengan metrik ganda (visual dan fungsional).

Ringkasan Seksi 2.4: Analisis 9 metode terkini (ERB-MultiTask, DE-GAN, Text-DIAE, DocEnTr, CycleGAN) mengungkapkan evolusi dari 4 fase (Classical 1979-2010, DL Awal 2015-2018, Adversarial 2017-2024, New Paradigm 2023-2024). Hanya 22% metode melaporkan evaluasi HTR, dengan korelasi PSNR-CER hanya $r=0.60-0.70$, menunjukkan kesenjangan optimisasi visual-fungsional yang signifikan.

II.5 Pengenalan Teks Tulisan Tangan: Arsitektur dan Tantangan

Analisis mendalam terhadap metode restorasi dokumen pada bagian sebelumnya mengungkapkan kesenjangan signifikan: optimasi kualitas visual tidak otomatis menjamin peningkatan keterbacaan teks untuk sistem HTR. Untuk memahami mengapa integrasi supervisi berorientasi HTR menjadi esensial, diperlukan pemahaman tentang karakteristik, mekanisme, dan tantangan sistem Handwritten Text Recognition itu sendiri. Bagian ini mengkaji evolusi arsitektur HTR dari pendekatan tradisional hingga sistem berbasis pembelajaran mendalam modern, dengan fokus pada mekanisme yang menentukan sensitivitas HTR terhadap kualitas citra masukan. Pemahaman ini menjadi fondasi untuk merancang strategi restorasi yang tidak hanya menghasilkan citra dengan kualitas visual tinggi, tetapi juga secara eksplisit dioptimasi untuk performa pengenalan teks.

II.5.1 Evolusi Arsitektur HTR

Pengenalan Teks Tulisan Tangan telah berkembang dari pendekatan pencocokan templat tradisional ke sistem berbasis pembelajaran mendalam modern. Memahami evolusi ini penting untuk menghargai mengapa optimisasi berorientasi HTR sangat penting untuk restorasi dokumen.


1. Pendekatan Tradisional: HMM dan Rekayasa Fitur

Sistem HTR awal menggunakan Model Markov Tersembunyi (*Hidden Markov Models* - HMM) dengan fitur yang dirancang manual seperti fitur arah, histogram gradien, atau fitur struktural. Pendekatan ini memerlukan segmentasi hati-hati dari baris teks ke karakter individual, diikuti oleh pengenalan tingkat karakter.

Keterbatasan: Segmentasi karakter sangat menantang untuk teks tulisan tangan dengan karakter terhubung atau goresan yang tumpang tindih. Rekayasa fitur

memerlukan keahlian domain dan fitur tidak dapat digeneralisasi di berbagai gaya tulisan atau bahasa.

2. Era Pembelajaran Mendalam: Arsitektur CRNN



Gambar II.5 Arsitektur CRNN yang mengombinasikan CNN untuk ekstraksi fitur visual dengan RNN untuk pemodelan konteks dan CTC untuk transkripsi tanpa segmentasi.

Shi dkk. (2016) memperkenalkan CRNN (Jaringan Saraf Rekuren Konvolusional) yang menjadi terobosan untuk pengenalan urutan-ke-urutan tanpa segmentasi eksplisit. Arsitektur terdiri atas:

a. Lapisan CNN

Mengekstrak fitur visual dari citra masukan dalam bentuk urutan fitur. Lapisan konvolusional dengan *pooling* mengurangi dimensi spasial secara vertikal tetapi mempertahankan urutan horizontal.

b. Lapisan Rekuren

LSTM dua arah memproses urutan fitur untuk menangkap dependensi konteks. LSTM maju menangkap konteks kiri, LSTM mundur menangkap konteks kanan, memungkinkan model untuk bernalar tentang karakter dalam konteks dari karakter di sekitarnya.

c. Lapisan Transkripsi


Klasifikasi Temporal Koneksionis (*Connectionist Temporal Classification* - CTC) *loss* memungkinkan pelatihan tanpa memerlukan label yang selaras. CTC memungkinkan model untuk mempelajari penyelarasan secara implisit.

Kontribusi: CRNN menghilangkan kebutuhan untuk segmentasi karakter dan mencapai hasil *state-of-the-art* pada berbagai tolok ukur. Arsitektur ini menjadi standar *de facto* untuk HTR tingkat baris.

II.5.2 Loss CTC: Mekanisme dan Implikasi untuk Restorasi

Loss CTC, diperkenalkan oleh Graves dkk. (2006), adalah komponen krusial yang memungkinkan pelatihan model HTR tanpa penyelarasan eksplisit antara fitur masukan dan karakter keluaran.

1. Penyelarasan CTC dan Token Kosong



Gambar II.6 Mekanisme CTC (Klasifikasi Temporal Koneksionis) untuk penyelarasan otomatis antara fitur masukan dan karakter keluaran tanpa memerlukan segmentasi eksplisit.

CTC memperkenalkan token kosong khusus (ϵ) yang merepresentasikan tidak ada karakter pada langkah waktu tertentu. Model bebas untuk mengeluarkan token kosong atau mengulangi karakter, dan CTC secara otomatis menciutkan karakter berulang dan menghapus token kosong untuk menghasilkan transkripsi akhir.

Secara formal, probabilitas CTC untuk urutan keluaran y diberikan masukan x adalah:

$$p(y|x) = \sum_{\pi \in \mathcal{B}^{-1}(y)} \prod_{t=1}^T p_t(\pi_t|x) \quad (\text{II.5})$$

dengan $\mathcal{B}$ adalah fungsi penciutan yang memetakan urutan dengan pengulangan dan token kosong ke keluaran akhir, dan $p_t(\pi_t|x)$ adalah probabilitas dari token π_t pada langkah waktu t .

2. Implikasi untuk Restorasi Dokumen

Memahami mekanisme CTC sangat penting untuk menghargai mengapa restorasi berorientasi HTR penting:

a. Sensitivitas terhadap Kualitas Fitur

CTC bergantung pada fitur diskriminatif yang jelas untuk setiap langkah waktu. Degradasi yang mengaburkan batas atau menciptakan fitur ambigu akan berdampak signifikan pada kepercayaan dan akurasi CTC.

b. Pentingnya Kontinuitas Goresan

Goresan terputus akibat pemudaran dapat menyebabkan emisi token kosong yang keliru atau pemisahan karakter. generator yang menjaga kontinuitas goresan akan secara langsung meningkatkan kualitas penyaluran CTC.

c. Propagasi Kesalahan dalam Lapisan Rekuren

Lapisan LSTM meneruskan informasi lintas langkah waktu. Kesalahan atau ketidakpastian di langkah waktu awal dapat bertambah dan memengaruhi prediksi selanjutnya. Restorasi yang meningkatkan pengenalan karakter awal akan memiliki manfaat yang berantai.

3. Motivasi untuk Integrasi

Fakta bahwa *loss* CTC secara langsung mengukur akurasi pengenalan teks menjadikannya tujuan yang ideal untuk memandu generator dalam proses restorasi. Dengan meminimalkan *loss* CTC pada citra yang direstorasi, generator secara eksplisit dioptimisasi untuk menghasilkan citra yang dapat dibaca oleh sistem HTR.

II.5.3 Paradigma Transformer: Dari Pengenalan hingga Peningkatan Dokumen

Meskipun arsitektur CRNN dengan mekanisme CTC telah menjadi standar *de facto* untuk HTR, perkembangan terkini menunjukkan transisi paradigmatis menuju arsitektur berbasis *Transformer*. Keterbatasan inheren dari LSTM—khususnya kesulitan menangkap dependensi jarak jauh dan sifat sekuensial yang membatasi paralelisasi—memotivasi eksplorasi mekanisme perhatian-diri (*self-attention*) yang dapat mengakses informasi dari seluruh sekuens secara langsung. Transisi ini memiliki implikasi signifikan untuk restorasi dokumen berorientasi HTR, karena pemilihan arsitektur pengenalan yang tepat dapat memengaruhi stabilitas gradien dan kualitas supervisi dalam siklus pelatihan integrasi.

Perkembangan terbaru dalam HTR telah mengadopsi arsitektur *Transformer*, menggantikan lapisan rekuren dengan mekanisme *self-attention*. Diaz dkk. (2021) menunjukkan bahwa HTR berbasis *Transformer* dapat mencapai kinerja superior dengan paralelisasi yang lebih baik.

1. Aplikasi pada Peningkatan Dokumen

Evolusi terbaru dalam peningkatan dokumen ditandai oleh kemunculan DocEnTr dan Text-DIAE, yang menggunakan arsitektur *Transformer* penuh dengan pendekatan yang berbeda:

a. DocEnTr

Sepenuhnya *Transformer* dengan pembelajaran terawasi, mengoptimalkan *loss* MSE untuk peningkatan kualitas visual.

b. Text-DIAE

Prapelatihan mandiri dengan invarian degradasi, diikuti penalaan halus terawasi.

II.5.4 Pembelajaran Mandiri: Revolusi dalam Pemrosesan Dokumen

Text-DIAE merepresentasikan paradigma baru dalam pemrosesan dokumen: pembelajaran mandiri yang mengurangi ketergantungan pada data berlabel. Ini sangat relevan untuk domain dokumen historis yang data berlabelnya sangat terbatas.

1. Kontribusi Utama Pembelajaran Mandiri

- a. Efisiensi Data: Mengurangi kebutuhan data berlabel hingga 166 kali
- b. Generalisasi: Representasi yang lebih universal untuk berbagai tugas
- c. Skalabilitas: Memanfaatkan sejumlah besar dokumen historis tidak berlabel

2. Perbedaan Fundamental dengan Pembelajaran Terawasi

- a. Fungsi Tujuan: Pembelajaran mandiri menggunakan tujuan rekonstruksi (MSE), terawasi menggunakan *loss* spesifik tugas (CTC, entropi silang)
- b. Strategi Pelatihan: Dua tahap (prapelatihan + penalaan halus) vs *end-to-end*
- c. Kebutuhan Data: Data tidak berlabel untuk prapelatihan vs data berlabel untuk terawasi

3. Keterbatasan Pembelajaran Mandiri untuk Optimisasi Keterbacaan

Meskipun *Text-DIAE* menunjukkan efisiensi data yang mengesankan, pendekatan ini memiliki keterbatasan fundamental untuk optimisasi keterbacaan:

a. Ketidaksesuaian Tujuan

Tujuan prapelatihan (penutupan, kekaburan, rekonstruksi derau) tidak secara eksplisit mengoptimalkan keterbacaan teks. Kesenjangan antara invarian degradasi dan kinerja HTR tetap ada.

b. Degradasi Sintetis vs Nyata

Tugas *pretext* menggunakan degradasi sintetis yang mungkin tidak representatif untuk pola degradasi dokumen historis nyata.

c. Keterbatasan Dua Tahap

Tahap penalaan halus masih terpisah dari evaluasi HTR. Tidak ada integrasi *end-to-end* antara peningkatan kualitas dan pengenalan.

II.5.5 Kompromi antara Pembelajaran Terawasi dan Mandiri

Evolusi paradigma pembelajaran dalam restorasi dokumen menimbulkan pertanyaan fundamental tentang *trade-off* antara efisiensi data dan kualitas hasil. Tabel II.5 merangkum analisis komparatif antara paradigma pembelajaran terawasi dan mandiri. Analisis ini menyoroti *trade-off* fundamental antara efisiensi penggunaan data, kedalaman integrasi HTR, dan realisme visual hasil restorasi.

Tabel II.5 Perbandingan pendekatan Terawasi vs Mandiri untuk Peningkatan Kualitas Dokumen

Pendekatan	Efisiensi Data	Integrasi HTR	Realisme
Terawasi (DE-GAN)	Rendah	<i>Post-hoc</i>	Tinggi
Mandiri (Text-DIAE)	Sangat Tinggi	Tidak Ada	Sedang
Terawasi (DocEnTr)	Rendah	Tidak Ada	Sedang
Metode Usulan	Sedang	<i>End-to-End</i>	Tinggi

Berdasarkan perbandingan di atas, penelitian ini mengadopsi pendekatan hibrida yang strategis. Meskipun pembelajaran mandiri menawarkan efisiensi data, kebutuhan akan realisme visual tinggi dan akurasi teks pada dokumen historis menuntut penggunaan paradigma terawasi. Untuk memitigasi inefisiensi data dan ketidakstabilan yang umum pada metode terawasi murni, penelitian ini mengusulkan strategi *frozen recognizer*. Pendekatan ini memungkinkan integrasi HTR *end-to-end* yang stabil (seperti pada pembelajaran terawasi) namun dengan efisiensi komputasi yang lebih baik, menyeimbangkan kebutuhan akan kualitas visual (Realisme: Tinggi) dan keterbacaan fungsional (Integrasi HTR: *End-to-End*).

II.5.6 Arsitektur CNN+Transformer dan Justifikasi untuk Kasus Paleografi

1. Arsitektur Dasar HTR Transformer

HTR *Transformer* umumnya menggunakan *backbone* CNN untuk ekstraksi fitur yang diikuti oleh enkoder *Transformer* untuk pemodelan sekuens. Mekanisme *self-attention* memungkinkan model untuk memperhatikan posisi mana pun dalam sekuens, menangkap dependensi jarak jauh secara lebih efektif dibandingkan LSTM.

2. Justifikasi Pemilihan Arsitektur untuk Dokumen Paleografi

Pemilihan arsitektur CNN+*Transformer* didasarkan pada karakteristik spesifik dokumen kuno, termasuk variasi gaya tulisan yang ekstrem dan tingkat degradasi visual yang kompleks. Dokumen paleografi memiliki tantangan unik yang

membutuhkan pendekatan arsitektur yang komprehensif:

- a. Variasi Gaya Tulisan yang Ekstrem: Dokumen kuno mengandung berbagai gaya tulisan (*scriptoria*) dengan karakteristik unik. Arsitektur CNN dengan ekstraksi fitur progresif dapat menangkap hierarki fitur visual, mulai dari goresan dasar hingga kompleksitas karakter, melalui 4 tahap yang dirancang secara adaptif.
- b. Dependensi Jarak Jauh dalam Karakter: Tulisan tangan historis seringkali memiliki struktur yang bagian awal karakternya memengaruhi bagian akhir. Mekanisme 8 *Multi-Head Attention* pada *Transformer* memungkinkan model menangkap dependensi jarak jauh ini, yang penting untuk membedakan karakter yang mirip secara visual tetapi berbeda secara struktural.
- c. Konsistensi Kontekstual antar Karakter: Dalam naskah kuno, kemunculan suatu karakter seringkali dipengaruhi oleh karakter sebelumnya (konteks linguistik). Tumpukan dari 6 lapisan enkoder *Transformer* memberikan kapasitas pemodelan urutan yang mendalam untuk menangkap pola-pola kontekstual ini.
- d. Ketangguhan terhadap Degradasi: Dokumen kuno umumnya mengalami berbagai bentuk degradasi (pemudaran, noda, sobekan). Kombinasi CNN untuk ekstraksi fitur invarian dan *Transformer* untuk pemodelan sekuens memberikan ketangguhan terhadap derau dan variasi visual yang tidak terduga.
- e. Generalisasi Antar Periode Waktu: Arsitektur ini dirancang untuk generalisasi lintas periode historis dengan menangkap fitur fundamental dari tulisan tangan yang konsisten melintasi gaya penulisan berbeda.

II.5.7 Analisis Komparatif: CNN+*Transformer* vs HTR Konvensional

1. Perbedaan Arsitektur Fundamental

Arsitektur yang diusulkan berbeda secara fundamental dari HTR konvensional yang umumnya menggunakan CRNN atau LSTM. Perbedaan utamanya terletak pada penggunaan *Transformer* untuk meningkatkan kapasitas representasi dalam menangani kompleksitas dokumen kuno, seperti variasi gaya tulisan ekstrem dan dependensi karakter yang kompleks, yang sulit ditangani oleh model sekuensial biasa.

2. Keunggulan Komparatif dalam Konteks Dokumen Paleografi

Arsitektur CNN+*Transformer* menawarkan beberapa keunggulan fundamental dibandingkan dengan pendekatan HTR tradisional dalam konteks dokumen kuno:

- a. Kapasitas Representasi yang Lebih Tinggi: Tumpukan 6 enkoder *Transformer* dengan 8 *Multi-Head Attention* memberikan matriks konektivitas $O(n^2)$, memungkinkan setiap posisi dalam sekuens untuk berinteraksi langsung dengan semua posisi lain. Ini lebih unggul dibandingkan LSTM yang hanya memiliki

dependensi sekuensial $O(n)$. Untuk dokumen kuno dengan panjang 128 karakter, *Transformer* memiliki 16.384 kemungkinan koneksi antar posisi, sementara LSTM hanya memiliki 127 koneksi sekuensial.

- b. Kemampuan Pemrosesan Paralel: Arsitektur *Transformer* memungkinkan pemrosesan paralel seluruh sekuens, berbeda dengan LSTM yang sifatnya sekuensial. Ini memberikan keuntungan komputasi signifikan untuk dokumen panjang. Pada perangkat keras modern dengan GPU, *Transformer* dapat mencapai percepatan 3-5x dibandingkan LSTM untuk sekuens dengan panjang lebih dari 64 karakter.
- c. Ekstraksi Fitur Adaptif: *Multi-Head Attention* memungkinkan model secara adaptif memfokuskan perhatian pada bagian gambar yang paling relevan untuk setiap karakter, sementara CNN dengan ekstraksi progresif menangkap fitur multi-skala dari goresan hingga kata. Setiap *head* dapat mempelajari representasi yang berbeda (arah goresan, batas karakter, diakritik) tanpa rekayasa fitur eksplisit.
- d. Penanganan Dependensi Jarak Jauh: Untuk dokumen kuno dengan karakter kompleks yang dapat memiliki komponen terpisah secara spasial (seperti ligatur Arab atau diakritik Latin), kemampuan menangkap dependensi jarak jauh menjadi krusial. LSTM dengan ukuran *hidden state* 128 hanya dapat mengingat informasi dari 50 langkah waktu sebelumnya, sementara *Transformer* dapat mengakses informasi dari seluruh sekuens tanpa penurunan kualitas.
- e. Reduksi Masalah *Vanishing Gradient*: Dengan koneksi residual dalam *Transformer* dan koneksi langsung dalam CNN bergaya U-Net, arsitektur ini lebih tangguh terhadap *vanishing gradients*, memungkinkan pelatihan yang lebih stabil untuk model yang dalam. Aliran gradien dalam *Transformer* lebih efisien karena pemrosesan paralel dan jalur komputasi yang lebih pendek antara masukan dan keluaran.
- f. Skalabilitas untuk Kosakata Besar: Arsitektur *Transformer* lebih skalabel untuk kosakata yang besar (100+ karakter) karena mekanisme *attention* tidak terikat pada pemrosesan sekuensial. Ini penting untuk dokumen historis yang mungkin mengandung karakter kuno atau simbol khusus.

Keunggulan-keunggulan ini secara spesifik dirancang untuk mengatasi tantangan paleografi yang tidak dapat diselesaikan secara optimal oleh pendekatan HTR generik.

3. Relevansi untuk Eksplorasi Arsitektur HTR

Dalam konteks restorasi dokumen berorientasi HTR, pemilihan arsitektur pengenalan yang tepat menjadi pertimbangan penting. Eksplorasi penggunaan HTR berbasis

Transformer sebagai komponen *frozen recognizer* dimotivasi oleh:

- a. Kinerja Mutakhir: HTR *Transformer* mencapai CER yang lebih rendah dibandingkan CRNN pada banyak tolok ukur, memberikan dasar yang lebih baik untuk evaluasi.
- b. Gradien Stabil: Mekanisme *self-attention* menghasilkan gradien yang lebih stabil dibandingkan LSTM, yang penting saat *backpropagation* melalui pengenalan untuk pelatihan generator.
- c. Visualisasi *Attention* Eksplisit: Bobot *attention* dapat divisualisasikan untuk memahami bagian mana dari citra yang direstorasi paling penting untuk pengenalan, memberikan interpretabilitas.

Ringkasan Seksi 2.5: Evolusi HTR dari HMM tradisional menuju CRNN (CNN+LSTM+CTC) dan Transformer-based HTR menunjukkan peningkatan signifikan dalam menangani variasi paleografi. *Transformer* dengan mekanisme *self-attention* global memberikan keunggulan dalam kapasitas representasi ($O(n^2)$ vs $O(n)$), pemrosesan paralel, dan penanganan dependensi jarak jauh yang krusial untuk dokumen kuno kompleks.

II.6 Pembelajaran Multimodal dan Diskriminator Dual Modal

Mengintegrasikan informasi dari berbagai modalitas telah terbukti meningkatkan kinerja sistem kecerdasan buatan dalam berbagai domain aplikasi. Dalam konteks restorasi dokumen, pendekatan tradisional yang hanya mengandalkan informasi visual sering kali gagal menangkap struktur semantik teks yang penting untuk mempertahankan keterbacaan. Bagian ini menyajikan kajian komprehensif tentang pembelajaran multimodal, dengan fokus pada pengembangan diskriminator dual modal yang secara simultan mengevaluasi aspek visual dan tekstual dari citra yang direstorasi. Pembahasan mencakup landasan teoretis, hipotesis informasi komplementer, kemajuan terkini dalam arsitektur multimodal, serta aplikasi spesifik dalam kerangka kerja restorasi dokumen berorientasi pengenalan teks.

II.6.1 Landasan Teoretis dan Kemajuan Arsitektur Multimodal

Pembelajaran multimodal mengacu pada pembelajaran dari data yang mengandung berbagai modalitas (misalnya, visual, teks, audio). Dalam konteks restorasi dokumen, dua modalitas yang relevan adalah informasi visual (intensitas piksel, tekstur) dan informasi tekstual (urutan karakter, struktur linguistik). Hipotesis inti adalah bahwa modalitas yang berbeda memberikan informasi yang saling melengkapi: modalitas visual mendeteksi fitur tingkat rendah seperti tepi dan tekstur, sementara modalitas tekstual memberikan batasan semantik tingkat tinggi. Baltrušaitis dkk. (2019) dalam survei komprehensif tentang pembelajaran multimodal mengidentifikasi tiga

tantangan kunci: (1) pembelajaran representasi untuk menggabungkan modalitas yang berbeda, (2) translasi antara modalitas, dan (3) penyelarasan antara elemen yang berkorespondensi dari modalitas yang berbeda.

1. Kemajuan Terkini dalam Arsitektur Multimodal

Penelitian terkini dalam pembelajaran multimodal telah menunjukkan kemajuan signifikan:

- a. Pendekatan Berbasis CLIP: Radford dkk. (2021) menunjukkan bahwa pembelajaran kontrastif pada pasangan citra-teks dapat menghasilkan representasi yang kuat untuk tugas multimodal. Meskipun CLIP belum diterapkan secara luas dalam restorasi dokumen, konsep pembelajaran kontrastif dapat diadaptasi untuk pasangan dokumen-teks.
- b. Mekanisme *Cross-Attention*: Vaswani dkk. (2017) mengembangkan arsitektur *cross-attention* yang secara efektif dapat mengintegrasikan informasi dari berbagai modalitas dengan bobot perhatian yang dipelajari. Pendekatan ini sangat relevan untuk restorasi dokumen yang informasi visual dan tekstualnya harus dinormalisasi.
- c. Kerangka Kerja Pembelajaran Multitugas: Raffel dkk. (2020) menunjukkan bahwa pembelajaran multitugas dapat meningkatkan generalisasi dan ketangguhan dalam pengaturan multimodal. Dalam konteks restorasi dokumen, pembelajaran multitugas dapat menggabungkan tugas peningkatan kualitas, binarisasi, dan pengenalan.

2. Strategi Fusi Multimodal

Fusi multimodal dapat dilakukan pada berbagai tingkatan: (1) Fusi Awal—menggabungkan fitur mentah dari modalitas yang berbeda di tahap awal jaringan, memungkinkan interaksi tingkat rendah tetapi meningkatkan dimensionalitas; (2) Fusi Akhir—memproses setiap modalitas secara independen hingga representasi tingkat tinggi kemudian menggabungkan prediksi, lebih sederhana tetapi kehilangan interaksi tingkat rendah; (3) Fusi Hibrida—menggabungkan fusi awal dan akhir, menawarkan keseimbangan antara ekspresivitas dan efisiensi komputasi.

II.6.2 Aplikasi Multimodal untuk Restorasi Dokumen

Dalam konteks restorasi dokumen, pembelajaran multimodal berpotensi mengintegrasikan informasi visual (karakteristik piksel, tekstur, struktur spasial) dengan informasi tekstual (urutan karakter, koherensi linguistik) untuk supervisi yang lebih kaya.

II.6.3 Konsep Diskriminator Multimodal

Dalam restorasi dokumen, diskriminator konvensional hanya mengevaluasi modalitas visual—apakah citra hasil restorasi terlihat bersih secara visual. Pendekatan multimodal yang berpotensi dieksplorasi adalah diskriminator yang mengevaluasi dua modalitas secara bersamaan:

- a. Modalitas Visual: Evaluasi karakteristik spasial dan tekstur citra melalui jaringan konvolusional, mengikuti paradigma *PatchGAN* Isola dkk. (2017) yang menilai keaslian pada tingkat *patch* lokal.
- b. Modalitas Tekstual: Evaluasi koherensi struktur teks melalui pemrosesan sekuensial representasi karakter, menggunakan arsitektur seperti LSTM atau *Transformer* untuk menangkap dependensi linguistik.
- c. Strategi Fusi: Integrasi informasi dari kedua modalitas dapat dilakukan melalui konkatenasi fitur (fusi akhir), interaksi awal (fusi awal), atau pendekatan hibrida yang memungkinkan interaksi multitingkat.

1. Potensi Keuntungan Teoretis

- a. Supervisi Multidimensi: Evaluasi simultan terhadap modalitas visual dan tekstual berpotensi memberikan sinyal gradien yang lebih kaya dibandingkan evaluasi visual saja. Diskriminator dapat mendeteksi inkonsistensi yang tidak terlihat dari perspektif visual murni, seperti karakter yang secara visual terlihat wajar tetapi tidak koheren dalam konteks sekuens.
- b. Sejalan dengan Tujuan Akhir: Untuk restorasi dokumen yang ditujukan untuk HTR, supervisi tekstual berpotensi lebih selaras dengan tujuan akhir pemrosesan dibandingkan supervisi visual saja. Hal ini sejalan dengan prinsip optimisasi berorientasi tugas.
- c. Regularisasi Implisit: Batasan dari modalitas ganda dapat berfungsi sebagai regularisasi, berpotensi mengurangi risiko keruntuhan modus karena generator harus memenuhi kriteria dari kedua modalitas secara bersamaan.

2. Bukti dari Domain Sejenis

Wei dkk. (2022) menunjukkan bahwa diskriminator multimodal pada tugas *image captioning* meningkatkan stabilitas pelatihan dan koherensi keluaran. Eksperimen mendemonstrasikan bahwa evaluasi visual-tekstual gabungan menghasilkan *caption* yang lebih koheren dibandingkan diskriminator visual saja.

Dalam konteks restorasi dokumen, potensi pendekatan multimodal menjadi relevan karena tujuan akhir bukan hanya kualitas visual, tetapi keterbacaan teks untuk sistem HTR. Namun, validasi empiris diperlukan untuk mengonfirmasi keuntungan ini pada domain dokumen historis spesifik. Kemajuan dalam domain *vision-language models*

seperti CLIP dan GPT-4V menunjukkan bahwa integrasi modalitas visual-tekstual dapat menghasilkan representasi yang lebih kaya dan semantis dibandingkan pendekatan unimodal.

Ringkasan Seksi 2.6: Pembelajaran multimodal mengintegrasikan informasi visual dan tekstual yang saling melengkapi. Diskriminator dual modal yang mengevaluasi koherensi visual-tekstual secara simultan berpotensi memberikan supervisi yang lebih kaya dibanding diskriminator visual saja. Strategi fusi (awal/akhir/hibrida) dan evidensi dari domain terkait (*image captioning*) menunjukkan keuntungan stabilitas dan koherensi keluaran.

II.7 Sintesis Fungsi Loss dan Optimasi Multiobjektif

Setelah mengkaji pembelajaran multimodal yang mengintegrasikan informasi visual dan tekstual, pertanyaan fundamental muncul: bagaimana mengoptimasi model secara efektif ketika terdapat berbagai tujuan yang harus diseimbangkan? Integrasi diskriminator dual modal dan supervisi HTR menciptakan skenario optimasi multiobjektif yang kompleks dengan tujuan yang berbeda (kualitas visual, realisme adversarial, keterbacaan teks) yang dapat saling berkonflik. Bagian ini menganalisis secara mendalam keterbatasan pelatihan dengan fungsi *loss* tunggal, kemudian mengembangkan kerangka konseptual untuk fungsi *loss* multikomponen dengan strategi pembobotan yang memungkinkan kontrol kompromi antar objektif. Analisis ini esensial untuk merancang fungsi optimasi yang mencapai keseimbangan optimal antara kualitas perseptual dan keterbacaan fungsional.

II.7.1 Keterbatasan Pelatihan Loss Tunggal

Melatih jaringan saraf dalam dengan fungsi *loss* tunggal sering kali tidak mencukupi untuk tugas kompleks yang memerlukan penyeimbangan berbagai tujuan seperti restorasi dokumen. Keterbatasan fundamental dari pendekatan *loss* tunggal dapat diamati dari berbagai perspektif.

Pelatihan dengan *loss* adversarial murni tanpa komponen rekonstruksi cenderung menyebabkan keruntuhan modus dan ketidakstabilan yang signifikan. Dalam kondisi ini, generator dapat mempelajari strategi untuk menghasilkan keluaran yang mampu menipu diskriminator, namun sepenuhnya mengabaikan kondisi masukan yang diberikan. Untuk tugas generasi bersyarat seperti restorasi dokumen, fenomena ini mengakibatkan kegagalan fundamental karena kehilangan korespondensi antara citra masukan yang mengalami degradasi dengan citra keluaran yang direstorasi.

Sebaliknya, pelatihan dengan *loss* rekonstruksi murni menggunakan norma L1 atau L2 menghasilkan permasalahan yang berbeda namun tidak kalah serius. Fungsi *loss* berbasis jarak piksel ini cenderung merata-ratakan semua kemungkinan keluaran

yang valid, menghasilkan citra yang kabur dan kekurangan detail frekuensi tinggi. Pada kasus-kasus ambigu dengan rekonstruksi jamak yang masuk akal (*multiple plausible reconstructions*), model cenderung mempelajari strategi aman dengan menghasilkan rata-rata statistik yang meminimalkan jarak piksel terhadap *ground truth*. Strategi ini, meskipun optimal dari perspektif *loss* numerik, menghasilkan keluaran yang secara visual tidak realistis dan kehilangan ketajaman detail seperti goresan karakter.

Keterbatasan-keterbatasan ini memotivasi kebutuhan akan fungsi *loss* multikomponen yang mampu mengoptimalkan berbagai tujuan secara simultan. Pendekatan multiobjektif ini memungkinkan model untuk menyeimbangkan *trade-off* antara realisme visual yang didorong oleh komponen adversarial dengan kesetiaan konten yang dijaga oleh komponen rekonstruksi. Tantangan kunci yang muncul dalam pendekatan ini adalah penentuan bobot relatif yang optimal untuk setiap komponen *loss*, yang memerlukan eksplorasi empiris dan pemahaman mendalam tentang kontribusi masing-masing komponen terhadap tujuan akhir.

II.7.2 Kerangka Konseptual Fungsi *Loss* Multikomponen

Berdasarkan analisis keterbatasan di atas, kerangka fungsi *loss* multikomponen untuk restorasi dokumen berorientasi HTR dapat dikonseptualisasikan secara umum sebagai kombinasi berbobot dari tujuan ganda:

$$\mathcal{L}_{total} = \sum_i \lambda_i \mathcal{L}_i \quad (\text{II.6})$$

dengan setiap $\mathcal{L}_i$ merepresentasikan objektif spesifik dan λ_i adalah bobot yang mengontrol kontribusi relatif.

1. Komponen Umum dalam Restorasi Dokumen

a. *Adversarial Loss* ($\mathcal{L}_{adversarial}$)

Komponen adversarial standar dalam GAN bersyarat untuk mendorong realisme visual keluaran. Mengikuti formulasi Goodfellow dkk. (2014) dan Isola dkk. (2017), *loss* ini memberikan sinyal untuk menghasilkan citra yang tidak dapat dibedakan dari citra nyata oleh diskriminator.

b. *Reconstruction Loss* ($\mathcal{L}_{reconstruction}$)

Komponen rekonstruksi untuk menjaga kesetiaan konten terhadap *ground truth*. Dapat menggunakan L1, L2, atau kombinasi keduanya. Isola dkk. (2017) menunjukkan bahwa L1 cenderung menghasilkan keluaran yang lebih tajam dibandingkan L2 dalam konteks translasi citra-ke-citra.

c. *Perceptual Loss* ($\mathcal{L}_{perceptual}$) - Opsional

Johnson dkk. (2016) memperkenalkan *perceptual loss* yang mengukur kesamaan pada ruang fitur jaringan praterlatih (seperti VGG). Ini berpotensi menangkap kemiripan semantik yang tidak tertangkap oleh *loss* tingkat piksel.

d. *Loss* Berorientasi HTR ($\mathcal{L}_{HTR}$) - Kesenjangan yang Teridentifikasi

Berdasarkan analisis literatur, komponen yang mengintegrasikan supervisi langsung dari model HTR masih terbatas eksplorasinya. Potensi pendekatan mencakup penggunaan *loss* CTC atau *loss* berbasis atensi dari model pengenalan untuk memberikan gradien yang berorientasi pada keterbacaan, bukan hanya kualitas visual.

2. *Trade-off Frozen vs Joint Training*

Dalam konteks integrasi model HTR dengan generator restorasi, terdapat dua paradigma yang dapat dieksplorasi:

- a. *Frozen Recognizer* Model HTR praterlatih dibekukan dan digunakan hanya untuk menghitung gradien tanpa mengubah bobotnya. Keuntungan teoretis mencakup stabilitas gradien dan konsistensi evaluasi. *Loss* potensial adalah kurangnya adaptasi terhadap karakteristik keluaran generator.
- b. *Pelatihan Bersama* Model HTR dan generator dilatih bersama secara *end-to-end*. Keuntungan teoretis adalah kemampuan koadaptasi. *Loss* potensial adalah ketidakstabilan optimisasi karena kompetisi gradien antara dua tujuan yang berbeda.

M. Souibgui, Kessentini, dan Fornés (2021) mengeksplorasi *joint training* pada ERB-MultiTask dengan hasil yang menjanjikan, namun melaporkan tantangan dalam stabilitas konvergensi. Eksplorasi lebih lanjut diperlukan untuk membandingkan kedua paradigma pada konteks dokumen historis spesifik.

II.7.3 Tantangan Penyeimbangan Multiobjektif

Penentuan bobot optimal untuk setiap komponen *loss* dalam kerangka multiobjektif merupakan tantangan penelitian yang terbuka. Kompleksitas ini diperparah oleh fakta bahwa komponen *loss* yang berbeda dapat memiliki skala, dinamika konvergensi, dan sensitivitas parameter yang sangat berbeda. Beberapa pertimbangan teoretis mencakup analisis empiris tentang interaksi antar komponen dan dampaknya terhadap kualitas akhir restorasi.

1. Perbedaan Skala Magnitudo

Komponen *loss* yang berbeda dapat memiliki rentang nilai yang sangat berbeda. *Adversarial loss* biasanya dalam rentang probabilitas log, *reconstruction loss* bergantung pada rentang nilai piksel, dan *loss* HTR bergantung pada panjang sekuens

dan ukuran kosakata. Tanpa normalisasi atau pembobotan yang tepat, komponen dengan magnitudo lebih besar akan mendominasi optimisasi.

2. Strategi yang Dapat Dieksplorasi

Beberapa strategi untuk penyeimbangan yang telah diusulkan dalam literatur:

- a. Penalaan Manual: Pendekatan *grid search* atau *random search* dengan evaluasi empiris pada himpunan validasi. Sederhana tetapi memerlukan banyak eksperimen.
- b. *Adaptive Weighting*: Z. Chen dkk. (2018) mengusulkan *GradNorm* yang secara dinamis menyesuaikan bobot berdasarkan magnitudo relatif gradien dari setiap *loss*. Berpotensi mencapai keseimbangan otomatis.
- c. Optimisasi Pareto: Pendekatan optimisasi multiobjektif yang mencari solusi pada *Pareto frontier* yang tidak ada objektif yang dapat ditingkatkan tanpa mengorbankan objektif lainnya.

Validasi empiris diperlukan untuk menentukan strategi yang paling efektif untuk konteks restorasi dokumen historis.

Ringkasan Seksi 2.7: Fungsi *loss* multikomponen esensial untuk restorasi dokumen yang menyeimbangkan kualitas visual dan keterbacaan teks. Komponen umum meliputi *adversarial loss* (realisme), *reconstruction loss* (kesetiaan konten), *perceptual loss* (kesamaan semantik), dan *loss* berorientasi HTR (keterbacaan). *Trade-off frozen vs joint training recognizer* dan strategi pembobotan (manual *grid search*, *adaptive GradNorm*, atau optimisasi Pareto) memerlukan validasi empiris sistematis.

II.8 Kesenjangan Penelitian dan Positioning

II.8.1 Sintesis Keterbatasan Metode yang Ada

Berdasarkan tinjauan komprehensif terhadap evolusi metode restorasi dokumen dari era klasik hingga pendekatan modern berbasis pembelajaran mendalam, analisis sistematis mengungkapkan pola konsisten dalam keterbatasan yang belum teratasi. Sintesis ini disajikan melalui dua perspektif komplementer yang saling melengkapi: evaluasi kuantitatif performa dan analisis karakteristik arsitektural.

Tabel II.6 menyajikan evaluasi kuantitatif komprehensif dari sembilan metode representatif yang mencakup rentang temporal 1979-2022. Analisis metrik mengungkapkan pola evolusi yang jelas: peningkatan progresif dalam PSNR dari metode klasik (Otsu, Sauvola) yang tidak menghasilkan metrik kuantitatif hingga pendekatan transformer modern (DocEnTr: 35,2 dB). Namun, kolom evaluasi HTR mengungkapkan kesenjangan kritis—hanya 22% metode (ERB-MultiTask dan DE-GAN) yang melaporkan CER, dan evaluasi tersebut dilakukan pasca-pelatihan,

bukan terintegrasi dalam siklus optimisasi.

Tabel II.6 Perbandingan metode terkini dalam restorasi dokumen (Bagian 1: Metrik Performa)

Metode	PSNR	SSIM	CER	Evaluasi HTR
Otsu Otsu (1979)	T/A	T/A	–	×
Sauvola Sauvola dan Pietikäinen (2000)	T/A	0,68	–	×
U-Net Ronneberger dkk. (2015a)	T/A	T/A	–	× ²
Pix2Pix Isola dkk. (2017)	T/A	T/A	–	× ²
ERB-MultiTask M. Souibgui, Kessentini, dan Fornés (2021)	15,7 dB	0,87	27,03 / 24,33%	√ ^{1,2}
DE-GAN M. A. Souibgui dan Kessentini (2021a)	15,5 dB	0,86	28,2%	√ ^{1,2}
Text-DIAE M. Souibgui, Kessentini, dkk. (2022b)	28,5 dB	0,88	–	×
DocEnTr M. Souibgui, Kessentini, dkk. (2022a)	35,2 dB	0,92	–	×
CycleGAN Zhu dkk. (2017)	30,2 dB	0,90	–	×

Analisis mendalam terhadap Tabel II.6 mengungkapkan pola divergensi yang signifikan: peningkatan dramatis metrik visual (PSNR dari tidak terdefinisi pada era klasik mencapai 35,2 dB pada DocEnTr) tidak diikuti dengan evaluasi keterbacaan yang setara. Dari sembilan metode yang dianalisis, hanya dua (22%) yang melaporkan CER, yaitu ERB-MultiTask dengan penurunan CER dari 30,34% menjadi 24,33% dan DE-GAN dengan CER 28,2%. Fenomena ini mengonfirmasi bias sistematis dalam paradigma penelitian yang mengutamakan optimisasi visual tanpa validasi dampaknya terhadap keterbacaan fungsional untuk sistem HTR.

Dimensi arsitektural dalam Tabel II.7 melengkapi analisis performa dengan mengungkapkan pola evolusi teknologi yang sejalan: transisi dari pendekatan deterministik (Otsu, Sauvola) menuju arsitektur pembelajaran mendalam yang semakin kompleks hingga pendekatan *Transformer-only* (DocEnTr), serta peningkatan bertahap dalam kompleksitas fungsi *loss* dari *threshold* sederhana

hingga kombinasi multikomponen (Adversarial + Reconstruction + Recognition pada ERB-MultiTask). Namun, kolom diskriminator mengungkapkan kesenjangan fundamental: semua metode berbasis GAN menggunakan diskriminator visual saja, tanpa mekanisme untuk mengevaluasi koherensi tekstual atau keterbacaan struktur karakter.

Tabel II.7 Perbandingan metode terkini dalam restorasi dokumen (Bagian 2: Karakteristik Arsitektur)

Metode	Diskriminator	Arsitektur	Tipe Loss
Otsu Otsu (1979)	T/A	N/A	<i>Threshold</i>
Sauvola Sauvola dan Pietikäinen (2000)	T/A	N/A	Adaptif
U-Net Ronneberger dkk. (2015a)	T/A	CNN <i>Encoder-Decoder</i>	L2 (MSE)
Pix2Pix Isola dkk. (2017)	Visual saja	CNN U-Net + PatchGAN	Adv + L1
ERB-MultiTask M. Souibgui, Kessentini, dan Fornés (2021)	Visual saja	FCN + CRNN	Adv + CRNN
DE-GAN M. A. Souibgui dan Kessentini (2021a)	Visual saja	CNN U-Net	Adv + BCE
Text-DIAE M. Souibgui, Kessentini, dkk. (2022b)	T/A	ViT <i>Autoencoder</i>	Rekonstruksi
DocEnTr M. Souibgui, Kessentini, dkk. (2022a)	T/A	<i>Transformer Only</i>	MSE
CycleGAN Zhu dkk. (2017)	Visual saja	CNN <i>Encoder-Decoder</i>	Cycle + Adv

¹DE-GAN dan ERB-MultiTask: Evaluasi pasca-pelatihan dengan pengenalan yang telah dilatih sebelumnya, bukan pelatihan terintegrasi. Data PSNR/CER direvisi berdasarkan sumber asli M. A. Souibgui, Kessentini, dan Fornés (2021) dan M. A. Souibgui, Kessentini, Fornés, dkk. (2022).

²U-Net dan Pix2Pix: Data T/A karena tidak ada evaluasi spesifik untuk *handwritten document restoration* pada sumber yang tersedia.

Sintesis komprehensif dari kedua tabel mengungkapkan tiga kesenjangan fundamental yang konsisten muncul lintas periode penelitian. **Pertama**, diskrepansi antara optimisasi visual dan keterbacaan fungsional: metode dengan PSNR tertinggi (DocEnTr: 35,2 dB, Text-DIAE: 28,5 dB) tidak melaporkan evaluasi HTR, sementara metode yang melaporkan CER (ERB-MultiTask, DE-GAN) memiliki PSNR relatif

rendah (15,5-15,7 dB). Korelasi negatif ini mengindikasikan bahwa optimisasi metrik visual tidak menjamin peningkatan keterbacaan teks, bahkan berpotensi menurunkan performa HTR jika tidak disertai supervisi eksplisit. **Kedua**, ketiadaan diskriminator dual modal: semua arsitektur GAN yang dianalisis menggunakan evaluasi visual saja tanpa supervisi keterbacaan tekstual. Diskriminator hanya mengevaluasi realisme visual tingkat piksel dan tekstur, tanpa kemampuan menilai koherensi struktur karakter atau keterbacaan sekuensial. **Ketiga**, evaluasi HTR yang tidak terintegrasi: pada metode yang melaporkan CER (ERB-MultiTask dan DE-GAN), evaluasi dilakukan pasca-pelatihan dengan pengenalan terpisah (catatan¹), bukan sebagai komponen integral dalam fungsi objektif optimisasi. Hal ini menyebabkan generator tidak menerima gradien yang berorientasi pada keterbacaan selama pelatihan.

Temuan ini memvalidasi kesenjangan penelitian yang signifikan dan memotivasi pengembangan metodologi yang mengintegrasikan evaluasi keterbacaan secara eksplisit dalam siklus pelatihan melalui diskriminator dual modal dan strategi *frozen recognizer*. Pola yang teridentifikasi menunjukkan bahwa paradigma penelitian perlu bergeser dari optimisasi visual murni menuju optimisasi holistik yang menyeimbangkan kualitas perseptual dan keterbacaan fungsional. Lebih jauh, analisis temporal menunjukkan bahwa meskipun kompleksitas arsitektural meningkat dari era klasik (1979-2010) hingga era adversarial modern (2017-sekarang), kesenjangan antara metrik visual dan evaluasi fungsional justru semakin melebar, mengindikasikan perlunya intervensi metodologis yang fundamental.

1. Pertanyaan Penelitian dan Hipotesis

Berdasarkan sintesis kesenjangan dari perbandingan komprehensif di atas dan identifikasi pola sistematis dalam keterbatasan metode terkini, penelitian ini merumuskan pertanyaan penelitian sebagai berikut:

Pertanyaan Penelitian Utama:

Bagaimana mengembangkan kerangka kerja restorasi dokumen berbasis GAN dengan diskriminator dual modal dan strategi *frozen recognizer* yang secara eksplisit mengintegrasikan evaluasi keterbacaan teks ke dalam proses pelatihan untuk mengatasi kesenjangan antara optimasi visual dan performa HTR?

Pertanyaan Penelitian Spesifik:

1. Arsitektur Diskriminator Dual Modal:

Bagaimana merancang dan mengevaluasi arsitektur diskriminator dual modal dengan cabang visual (CNN) dan cabang tekstual (LSTM) yang mengevaluasi koherensi visual-tekstual secara simultan, serta bagaimana mengukur kontribusinya terhadap kualitas umpan balik generator dibandingkan

diskriminator visual saja?

2. *Frozen Recognizer* dengan Integrasi *CTC Loss*:

Bagaimana strategi *frozen recognizer* dengan integrasi *CTC loss* dibandingkan dengan pendekatan pelatihan bersama dalam hal: (a) stabilitas gradien selama pelatihan, (b) performa keterbacaan teks yang dihasilkan, dan (c) efisiensi komputasi dalam proses optimisasi?

3. Strategi *Curriculum Learning*:

Bagaimana merancang strategi temporal *curriculum learning* untuk *CTC loss annealing* yang memastikan konvergensi stabil dengan beberapa komponen *loss* (*adversarial, reconstruction, recognition*) pada fase awal hingga akhir pelatihan?

4. Optimasi Multiobjektif:

Bagaimana menentukan konfigurasi bobot akhir yang optimal untuk *adversarial, reconstruction, dan recognition loss* guna mencapai keseimbangan terbaik antara kualitas visual (PSNR/SSIM) dan keterbacaan teks (CER/WER) pada hasil restorasi?

Hipotesis:

Penggunaan diskriminator dual modal dan strategi *frozen recognizer* dengan *curriculum learning* dan optimasi *loss function* multiobjektif dapat mengatasi kesenjangan antara optimasi visual dan keterbacaan teks, sehingga menghasilkan restorasi yang secara signifikan lebih baik dalam aspek keterbacaan teks sambil mempertahankan kualitas visual dibandingkan metode *state-of-the-art*.

II.8.2 Posisi dan Kontribusi Penelitian Ini

Pertanyaan penelitian dan hipotesis yang telah dirumuskan mengarahkan pada kebutuhan untuk mengembangkan metodologi baru yang secara sistematis mengatasi kesenjangan yang teridentifikasi. Penelitian ini diposisikan sebagai solusi inovatif yang mengintegrasikan tiga dimensi metodologis: arsitektur diskriminator dual modal, strategi *frozen recognizer*, dan optimasi *loss function* multikomponen. Pendekatan ini berbeda secara fundamental dari metode yang ada sebelumnya yang cenderung fokus pada satu aspek saja atau menggunakan integrasi yang tidak stabil. Berdasarkan analisis komprehensif tersebut, penelitian ini diposisikan sebagai penelitian inovatif yang mengusulkan pendekatan baru dalam restorasi dokumen berorientasi HTR. Berbeda dari metode yang ada sebelumnya yang menggunakan pelatihan gabungan (*joint training*) antara *generator* dan *recognizer*, penelitian ini memperkenalkan paradigma *frozen recognizer* yang memberikan stabilitas pelatihan dan gradien sadar teks yang konsisten.

Secara spesifik, posisi dan kontribusi penelitian ini dapat dirumuskan sebagai berikut:

1. Posisi Penelitian: Berbeda dari pendekatan terdahulu yang hanya fokus pada

satu aspek (visual saja atau pelatihan gabungan dengan risiko ketidakstabilan), penelitian ini menyajikan solusi terintegrasi yang mengatasi tantangan fundamental optimisasi multiobjektif dalam restorasi dokumen. Penelitian ini mengisi celah penting antara metode restorasi visual murni (seperti GAN standar) dan metode *joint training* yang kompleks namun tidak stabil.

2. Kontribusi Utama: Penelitian ini menawarkan tiga dimensi inovasi:

- Integrasi HTR dengan *Frozen Recognizer*: Strategi yang memecahkan masalah ketidakstabilan *joint training* sambil memberikan gradien peka HTR yang konsisten.
- *Curriculum Learning* untuk Stabilitas Pelatihan: Penerapan strategi *CTC loss annealing* untuk mencegah dominasi satu komponen *loss* pada fase awal.
- Optimisasi *Loss Function* Multikomponen: Formulasi bobot optimal yang divalidasi secara empiris untuk menyeimbangkan kualitas visual dan keterbacaan teks.

II.9 Sintesis Tinjauan Pustaka

Bab ini telah menyajikan analisis komprehensif dari lanskap penelitian restorasi dokumen, dari metode tradisional hingga pendekatan pembelajaran mendalam modern. Berdasarkan tinjauan sistematis terhadap 9 metode terkini dan metaanalisis kuantitatif, analisis ini mengidentifikasi kesenjangan fundamental yang masih memerlukan eksplorasi lebih lanjut dalam bidang restorasi dokumen historis.

1. Sintesis Temuan Kunci

a. Kesenjangan Signifikan Optimisasi Visual-Fungsional

Metaanalisis kuantitatif mengungkapkan korelasi Spearman hanya 0,60-0,70 antara peningkatan PSNR dan penurunan CER Jadhav dan Raghuwanshi (2022), membuktikan bahwa optimisasi visual tidak otomatis menjamin optimisasi keterbacaan. Hanya 2 dari 9 metode (22%) melaporkan evaluasi HTR, mencerminkan kesenjangan evaluasi yang sistematis. Studi lintas domain dalam peningkatan ucapan Weninger dkk. (2023) menunjukkan bahwa supervisi eksplisit dari model pengenalan secara signifikan meningkatkan keterbacaan dibandingkan optimisasi metrik akustik saja, memberikan indikasi teoretis untuk pendekatan serupa dalam restorasi dokumen. Lebih lanjut, *benchmark* standar seperti seri DIBCO hanya menyediakan *ground truth* visual tanpa metrik HTR (CER/WER), memperpanjang pemisahan antara penelitian restorasi dan aplikasi praktis.

b. Ketiadaan *Loss Function* Peka HTR dalam *Training Loop*

Pelatihan GAN dengan kombinasi *adversarial loss*, *reconstruction loss*, dan

recognition loss (CTC) menghadapi tantangan stabilitas karena perbedaan skala dan dinamika konvergensi masing-masing komponen. Belum ada penelitian yang mengevaluasi strategi *curriculum learning* untuk *CTC loss annealing* guna mencegah dominasi satu komponen pada fase awal pelatihan. ERB-MultiTask menggunakan pembobotan *loss* manual ($\lambda = 1$ optimal) namun tanpa mekanisme adaptif. Karakterisasi *trade-off* antara kualitas visual (PSNR/SSIM) dan keterbacaan teks (CER/WER) dalam konteks optimisasi fungsi *loss* multikomponen masih memerlukan investigasi sistematis melalui studi ablasi yang komprehensif.

c. Temuan Metaanalisis

Analisis kuantitatif mengidentifikasi tren dalam perkembangan metode restorasi dokumen. Dari era tradisional hingga pendekatan GAN modern, terdapat peningkatan signifikan dalam metrik visual, namun evaluasi fungsional (HTR) masih terbatas. Hanya minoritas metode yang melaporkan evaluasi HTR, mengindikasikan kesenjangan dalam protokol evaluasi yang komprehensif.

2. Implikasi untuk Penelitian

Tiga kesenjangan fundamental yang teridentifikasi—(1) optimisasi visual-fungsional yang terpisah, (2) ketiadaan fungsi *loss* yang peka terhadap HTR dengan strategi *frozen recognizer*, dan (3) ketidakstabilan pelatihan multiobjektif tanpa *curriculum learning*—memberikan landasan untuk pengembangan metodologi penelitian. Penelitian ini akan mengatasi kesenjangan tersebut melalui: integrasi *CTC loss* dengan *frozen HTR recognizer* untuk gradien yang stabil dan peka HTR, strategi *curriculum learning* untuk *CTC loss annealing* guna mencegah ketidakstabilan pelatihan, dan optimisasi pembobotan *loss* melalui studi ablasi sistematis untuk mencapai keseimbangan optimal antara kualitas visual dan keterbacaan teks pada dokumen historis autentik.

Bab III Metodologi Penelitian

Bab ini menguraikan pendekatan penelitian yang mengadopsi *Design Science Research Methodology* (DSRM) sebagai kerangka kerja sistematis untuk pengembangan dan evaluasi artefak teknologi informasi. Metodologi DSRM dipilih karena tiga alasan utama: (1) kesesuaiannya untuk merancang artefak inovatif yang menyelesaikan masalah praktis, (2) pendekatan evaluasi berbasis bukti empiris yang mengutamakan validasi kuantitatif, dan (3) siklus iteratif yang mengakomodasi penyempurnaan berkelanjutan berdasarkan umpan balik evaluasi—karakteristik yang sangat relevan untuk pengembangan sistem *deep learning*. Artefak yang dikembangkan dalam penelitian ini adalah kerangka kerja restorasi dokumen berbasis GAN dengan tiga komponen inovatif: (1) *recognizer* HTR yang dibekukan (*frozen*) sebagai evaluator objektif keterbacaan teks, (2) optimasi fungsi *loss* multikomponen yang menyeimbangkan kualitas visual dan performa HTR, dan (3) eksplorasi diskriminator *dual-modal* sebagai hipotesis penelitian untuk evaluasi bilateral visual-tekstual, yang kontribusi empirisnya divalidasi melalui studi ablasi terkawal (lihat Bab V, Bagian 5.3.2.3). Implementasi teknis mengikuti siklus *deep learning* yang iteratif, di mana setiap iterasi eksperimen didasarkan pada bukti empiris dari iterasi sebelumnya dan didokumentasikan secara sistematis menggunakan MLflow untuk mencapai tujuan penelitian dengan transparansi dan reproduktibilitas.


III.1 Kerangka Teori Metodologi Penelitian

Bagian ini menetapkan landasan teoretis yang menjadi fondasi metodologis penelitian, yaitu kerangka kerja *Design Science Research Methodology* (DSRM) dan siklus iteratif berbasis bukti empiris. Kedua komponen ini memastikan setiap keputusan desain dan evaluasi didasarkan pada prinsip-prinsip ilmiah yang sistematis dan terukur.

III.1.1 Design Science Research Methodology (DSRM)

Dalam penelitian sistem informasi dan teknologi, pemilihan metodologi yang tepat sangat menentukan kualitas dan validitas hasil penelitian. Penelitian ini mengadopsi *Design Science Research Methodology* (DSRM) sebagai kerangka kerja utama karena karakteristiknya yang sesuai dengan tujuan pengembangan artefak teknologi inovatif. Berbeda dengan metodologi penelitian *behavioral* yang berfokus pada pemahaman fenomena yang sudah ada, DSRM berorientasi pada penciptaan solusi baru untuk masalah yang diidentifikasi—dalam hal ini, pengembangan sistem restorasi dokumen yang mengintegrasikan optimisasi visual dan keterbacaan teks secara simultan.

Gambar III.1 mengilustrasikan siklus iteratif DSRM yang menjadi karakteristik



Gambar III.1 Kerangka Kerja *Design Science Research Methodology* dengan siklus iteratif antara evaluasi dan desain untuk penyempurnaan artefak.

fundamental metodologi ini. *Design Science Research Methodology* (DSRM), yang diperkenalkan oleh Peffers dkk. (2007), merupakan kerangka penelitian yang dirancang khusus untuk pengembangan dan evaluasi artefak teknologi informasi. DSRM terdiri dari enam tahapan fundamental yang saling terkait dan bersifat iteratif: (1) identifikasi masalah dan motivasi, (2) definisi tujuan solusi, (3) desain dan pengembangan, (4) demonstrasi, (5) evaluasi, dan (6) komunikasi. Dalam setiap tahapan, hasil evaluasi memberikan umpan balik untuk penyempurnaan, menciptakan siklus perbaikan berkelanjutan.

Karakteristik utama DSRM yang relevan dengan penelitian ini adalah:

1. Berorientasi Solusi: DSRM berfokus pada penciptaan artefak inovatif untuk menyelesaikan masalah praktis yang sudah diidentifikasi. Dalam penelitian ini, artefak yang dikembangkan berupa kerangka kerja restorasi dokumen berbasis GAN dengan integrasi *recognizer* HTR yang dibekukan dan optimasi fungsi *loss* multikomponen. Kerangka kerja ini secara eksplisit dioptimalkan untuk meningkatkan keterbacaan dokumen oleh sistem HTR (bukan hanya kualitas visual), dan merupakan kontribusi konkret yang dapat diimplementasikan pada sistem digitalisasi arsip historis.
2. Evaluasi Berbasis Bukti: Setiap iterasi desain dievaluasi secara kuantitatif menggunakan metrik yang terukur—kualitas visual (PSNR, SSIM) untuk validasi pelestarian struktur dokumen, dan metrik keterbacaan HTR (CER, WER) untuk

validasi peningkatan performa pengenalan teks. Pendekatan evaluasi ganda ini memastikan bahwa penyempurnaan didasarkan pada data empiris dari dua dimensi objektif (visual dan tekstual), bukan asumsi subjektif atau observasi visual semata.

3. Siklus Iteratif: Kerangka kerja DSRM memfasilitasi perbaikan berkelanjutan melalui putaran umpan balik antara tahap evaluasi dan desain. Karakteristik ini sangat sesuai untuk pengembangan model *deep learning* yang memerlukan eksperimen terkawal, analisis konvergensi, penyetelan *hyperparameter*, dan studi ablasi berulang. Setiap siklus iterasi menghasilkan wawasan yang menjadi dasar penyempurnaan arsitektur atau konfigurasi pelatihan pada iterasi berikutnya.
4. Komunikasi dan Diseminasi: DSRM menekankan pentingnya mendokumentasikan dan mengomunikasikan hasil penelitian kepada komunitas ilmiah untuk validasi eksternal dan kemajuan kolektif. Penelitian ini mengadopsi prinsip transparansi melalui: (a) publikasi akademis dengan detail arsitektur dan hasil eksperimen, (b) dokumentasi metodologi pelatihan dan evaluasi yang komprehensif, (c) rencana berbagi kode sumber untuk reproduktibilitas dan verifikasi independen oleh peneliti lain.

III.1.2 Siklus Iteratif Berbasis Bukti Empiris

Penelitian ini menerapkan prinsip iterasi DSRM melalui pendekatan berbasis bukti empiris (*evidence-based*). Pendekatan ini bertujuan untuk menjamin bahwa setiap keputusan desain, mulai dari modifikasi arsitektur hingga penyesuaian *hyperparameter*, memiliki landasan data kuantitatif yang valid dan dapat diverifikasi. Mekanisme iterasi dilaksanakan melalui empat tahapan berulang sebagai berikut:

1. Eksperimen Terkawal: Setiap modifikasi (misalnya, perubahan bobot fungsi *loss*) dijalankan dengan konfigurasi terkunci dan dicatat menggunakan identitas unik (*run ID*) pada sistem pelacakan MLflow.
2. Evaluasi Terstandar: Kinerja model diukur menggunakan metrik kuantitatif (PSNR, SSIM, CER, WER) pada *set* validasi yang konsisten untuk menjamin keterbandingan.
3. Analisis Komparatif: Hasil evaluasi dibandingkan dengan eksperimen sebelumnya untuk mengidentifikasi pola peningkatan atau penurunan performa.
4. Penyempurnaan Terarah: Revisi desain atau konfigurasi hanya diterapkan apabila didukung oleh peningkatan metrik yang signifikan atau landasan teoretis yang kuat.

Prinsip *evidence-based decision making*: Pendekatan ini meminimalkan subjektivitas dan bias konfirmasi dengan mengharuskan setiap perubahan desain divalidasi secara objektif melalui metrik kuantitatif. Temuan negatif (misalnya, kontribusi marginal

diskriminator *dual-modal*, $p > 0.05$) didokumentasikan secara transparan untuk meningkatkan validitas ilmiah dan memberikan panduan kepada peneliti lain yang mengeksplorasi arah serupa. Siklus ini dijalankan secara berulang terutama pada Tahap 3 (Desain dan Pengembangan) dan Tahap 5 (Evaluasi) dari kerangka DSRM untuk penyempurnaan artefak berkelanjutan.

III.2 Tahapan Penelitian

Penelitian ini mengikuti enam tahapan DSRM yang telah diadaptasi untuk pengembangan *framework* restorasi dokumen berbasis *deep learning*. Setiap tahapan dijelaskan secara rinci berikut dengan metode, perangkat lunak, dan dokumentasi yang digunakan.

III.2.1 Identifikasi Masalah dan Motivasi (Tahap 1)

Tahap pertama berfokus pada analisis mendalam terhadap tantangan yang ada dalam restorasi dokumen historis dan identifikasi kesenjangan penelitian yang menjadi motivasi pengembangan *framework* baru.

1. Studi Literatur Sistematis

Dilakukan kajian komprehensif terhadap penelitian terkait restorasi dokumen, GAN, dan HTR untuk mengidentifikasi keterbatasan metode yang ada. Analisis terhadap metode *state-of-the-art* seperti DE-GAN, TEXT-DIAE, dan CycleGAN mengungkapkan beberapa keterbatasan fundamental: (1) mayoritas metode menggunakan diskriminator *single-modal* yang hanya mengevaluasi kualitas visual tanpa mempertimbangkan koherensi tekstual, (2) pendekatan *joint training* antara generator dan *recognizer* dapat menyebabkan ketidakstabilan optimisasi, dan (3) tidak ada eksplorasi sistematis terhadap konfigurasi optimal fungsi *loss* multikomponen untuk menyeimbangkan kualitas visual dan keterbacaan HTR. Kajian lengkap disajikan pada Bab II bagian Tinjauan Literatur.

2. Analisis Kebutuhan Praktis

Dilakukan analisis terhadap kebutuhan nyata lembaga kearsipan, khususnya ANRI, di mana restorasi digital harus mendukung transkripsi otomatis untuk aksesibilitas dan analisis data historis. Identifikasi pada koleksi dokumen kolonial Belanda abad ke-16 hingga ke-18 menunjukkan pola degradasi kompleks yang khas, meliputi: tinta tembus (*bleed-through*) dari halaman balik, korosi tinta *iron gall* yang menyebabkan lubang mikro pada kertas, penuaan kertas dengan bercak kecokelatan (*foxing*), kerusakan fisik berupa robek dan keriput, degradasi tinta yang memudar (*ink fading*), dan kabur optik (*optical blur*) dari proses pemindaian. Kesenjangan Penelitian yang Diidentifikasi:

Berdasarkan studi literatur dan analisis kebutuhan praktis, ditemukan tiga

kesenjangan fundamental dalam penelitian restorasi dokumen yang ada:

- (a) Kesenjangan Metodologis—Ketidakstabilan Pelatihan Bersama: Metode yang ada menggunakan *joint training* antara generator dan *recognizer*, yang berpotensi menyebabkan ketidakstabilan optimisasi. Belum ada eksplorasi sistematis terhadap strategi *frozen recognizer* sebagai evaluator objektif yang stabil.
- (b) Kesenjangan Arsitektural—Evaluasi *Single-Modal*: Diskriminator yang ada hanya mengevaluasi kualitas visual (*single-modal* CNN), tanpa eksplorasi arsitektur *dual-modal* yang dapat menangkap koherensi tekstual melalui jalur sekuensial (LSTM). Meskipun kontribusi empirisnya perlu divalidasi, eksplorasi ini penting untuk melengkapi pemahaman teoretis tentang evaluasi bilateral visual-tekstual dalam konteks GAN berorientasi HTR.
- (c) Kesenjangan Evaluasi—Optimasi *Loss Function*: Tidak ada studi ablatasi sistematis yang mengidentifikasi konfigurasi optimal untuk menyeimbangkan komponen fungsi *loss* (piksel, *adversarial*, perseptual, CTC) guna mencapai keseimbangan Pareto antara kualitas visual dan keterbacaan HTR.

3. Perumusan Masalah Penelitian

Berdasarkan analisis literatur dan kebutuhan praktis, dirumuskan masalah utama penelitian: “Bagaimana merancang arsitektur GAN yang secara eksplisit dioptimalkan untuk meningkatkan keterbacaan teks oleh sistem HTR, bukan hanya kualitas visual, pada dokumen historis dengan degradasi kompleks?”

Masalah ini diformulasikan menjadi empat pertanyaan penelitian spesifik:

- RQ1: Bagaimana merancang arsitektur generator dan diskriminator GAN yang secara eksplisit dioptimalkan untuk meningkatkan keterbacaan HTR pada dokumen historis terdegradasi?
- RQ2: Bagaimana mengintegrasikan model HTR *recognizer* ke dalam *framework* GAN untuk memberikan sinyal gradien sadar-teks yang stabil tanpa ketidakstabilan pelatihan bersama?
- RQ3: Bagaimana mengoptimalkan konfigurasi fungsi *loss* multikomponen untuk mencapai keseimbangan optimal antara kualitas visual (PSNR, SSIM) dan keterbacaan teks (CER, WER)?
- RQ4: Seberapa efektif *framework* yang diusulkan dalam meningkatkan akurasi HTR pada dokumen paleografi ANRI abad ke-16 hingga ke-18 dibandingkan dengan kondisi terdegradasi *baseline*?

III.2.2 Definisi Tujuan Solusi (Tahap 2)

Berdasarkan masalah yang sudah diidentifikasi, tujuan artefak yang akan dibangun didefinisikan secara kuantitatif dan kualitatif dengan target yang terukur.

1. Tujuan Kuantitatif:

Penelitian ini menetapkan target performa yang dapat diukur dan diverifikasi:

Tabel III.1 Target metrik kuantitatif penelitian (direvisi berdasarkan karakteristik dataset historis)

Kategori	Metrik	Target
Kualitas Visual	PSNR	$> 30 \text{ dB}^1$
	SSIM	> 0.95
Keterbacaan Teks	Reduksi CER	$\geq 50\%$ dari <i>degraded</i> ²
	Reduksi WER	Penurunan signifikan vs <i>baseline</i>
Efisiensi Komputasi	<i>Inference Time</i>	< 1 detik per <i>line image</i>

Sebagai kriteria keberhasilan metodologi pelatihan, stabilitas konvergensi dipantau melalui: (a) tidak terjadi *mode collapse* (divergensi *loss* Generator), (b) konvergensi gradual metrik validasi, dan (c) akurasi diskriminator stabil di rentang 60–80% (*Nash equilibrium*) tanpa dominasi satu pihak.

2. Tujuan Kualitatif:

Artefak yang dikembangkan adalah kerangka kerja restorasi dokumen berbasis GAN dengan tiga fitur utama: (1) arsitektur diskriminator *dual-modal*, (2) strategi *frozen recognizer*, dan (3) *curriculum learning* untuk optimasi multiobjektif. Efektivitas kombinasi komponen ini divalidasi melalui studi ablasi sistematis dan evaluasi komparatif dengan metode *baseline*.

III.2.3 Spesifikasi Kebutuhan Sistem

Setelah mengidentifikasi masalah dan mendefinisikan tujuan solusi pada tahap sebelumnya, langkah selanjutnya dalam kerangka DSRM adalah menurunkan tujuan tersebut menjadi spesifikasi kebutuhan sistem yang konkret dan terukur. Analisis kebutuhan ini menjadi jembatan antara tujuan penelitian dan perancangan arsitektur, serta tolok ukur evaluasi akhir.

Kebutuhan sistem diklasifikasikan menjadi dua kategori utama: (1) Kebutuhan Fungsional yang mendefinisikan fungsi spesifik yang harus dimiliki sistem, dan

¹Target PSNR disesuaikan dari 35 dB menjadi >30 dB berdasarkan kompleksitas degradasi historis dokumen paleografi abad 16–18 dan keterbatasan inheren *dataset* semi-sintetis.

²Target utama adalah pengurangan relatif CER dari kondisi terdegradasi, dengan target mendekati performa *recognizer* pada dokumen bersih *ground truth*.

(2) Kebutuhan Non-Fungsional yang mendefinisikan kriteria kualitas dan batasan performa sistem. Spesifikasi kebutuhan ini disusun untuk memastikan bahwa solusi yang dikembangkan tidak hanya secara teknis mampu mengatasi masalah restorasi dokumen, tetapi juga praktis untuk digunakan dalam lingkungan produksi dan dapat diintegrasikan dengan sistem lain.

1. Kebutuhan Fungsional

Kebutuhan fungsional mendefinisikan 8 fungsi utama *framework* restorasi, dikelompokkan dalam 3 kategori:

- (a) Inti ML: restorasi visual & HTR (FR-1–3)
- (b) Pemrosesan: batch & dataset sintetis (FR-4–5)
- (c) Integrasi: I/O & antarmuka (FR-6–8)

Detail lengkap di Tabel III.2.

Tabel III.2 Spesifikasi Kebutuhan Fungsional Kerangka Kerja Restorasi

Kode	Nama	Deskripsi
FR-1	Restorasi Gambar	Menerima input gambar terdegradasi dan menghasilkan output restorasi dengan preservasi struktur karakter.
FR-2	Penanganan Degradasi	Menangani 4 jenis degradasi: <i>bleed-through</i> , <i>fading</i> , <i>stains</i> , dan <i>blur</i> .
FR-3	Integrasi HTR	Output restorasi dapat diproses HTR dengan akurasi lebih tinggi dari gambar terdegradasi.
FR-4	Pemrosesan Batch	Memproses <i>batch</i> dengan output: gambar restorasi, transkripsi (.txt), metadata (.json).
FR-5	Dataset Sintetis	Alur otomatis pembuatan <i>dataset</i> sintetis dengan kontrol parameter degradasi.
FR-6	Output Terdefinisi	Format output: citra (PNG/TIFF 300 DPI), teks (UTF-8), metrik (PSNR/SSIM).
FR-7	Input Fleksibel	Menangani format JPG, PNG, TIFF, PDF dengan validasi dan pra-pemrosesan otomatis.
FR-8	Integrasi Sistem	Antarmuka CLI dan Python API dengan konfigurasi YAML/JSON.

2. Kebutuhan Non-Fungsional

Kebutuhan non-fungsional mendefinisikan kriteria kualitas dan batasan performa *framework* restorasi. Empat kebutuhan non-fungsional yang ditetapkan mengukur aspek kualitatif dan kuantitatif performa sistem:

- 1. NFR-1: Kualitas Visual mengukur kesamaan gambar hasil restorasi dengan *ground truth* menggunakan metrik PSNR dan SSIM,

2. NFR-2: Keterbacaan Teks sebagai metrik utama keberhasilan sistem melalui penurunan CER,
3. NFR-3: Efisiensi Waktu untuk memastikan kepraktisan penggunaan dalam skenario produksi,
4. NFR-4: Reprodusibilitas untuk menjamin konsistensi dan keandalan hasil eksperimen.

Spesifikasi lengkap disajikan pada Tabel III.3.

Tabel III.3 Spesifikasi Kebutuhan Non-Fungsional Kerangka Kerja Restorasi

Kode	Nama	Target Performa
NFR-1	Kualitas Visual	PSNR > 30 dB, SSIM $\geq$ 0.90.
NFR-2	Keterbacaan Teks	Penurunan CER $\geq$ 25% dari terdegradasi.
NFR-3	Waktu Inferensi	< 15 detik/gambar (GPU RTX A4000).
NFR-4	Reproduktibilitas	Melalui Poetry dan Docker.

3. Matriks Pelacakan

Tabel III.4 memetakan kebutuhan sistem ke rumusan masalah dan evaluasi.

Tabel III.4 Matriks Pelacakan: Kebutuhan Sistem vs Rumusan Masalah

Kode	Kebutuhan	Terkait	Evaluasi
FR-1	Restorasi Gambar	RM-1, T1	V.2 (Visual)
FR-2	Penanganan Degradasi	RM-1, T1	V.2 (Kuantitatif)
FR-3	Integrasi HTR	RM-1, T2	V.2 (CER/WER)
FR-4	<i>Batch Processing</i>	T4	V.2 (Set Uji)
FR-5	<i>Dataset</i> Sintetis	Fase 3	V.2 (Data)
FR-6-8	<i>Output & Integrasi</i>	T4	Bab IV
NFR-1	Kualitas Visual	RM-1, T1	V.2 (PSNR/SSIM)
NFR-2	Keterbacaan	RM-1, RM-3, T2	V.2 (CER/WER)
NFR-3	Waktu	Praktis	V.2 ¹
NFR-4	Reproduktibilitas	DSRM	MLflow

Simpulan Analisis Kebutuhan: Berdasarkan analisis di atas, kerangka kerja yang akan dikembangkan harus memenuhi total 12 kebutuhan (8 fungsional dan 4 non-fungsional) yang mencakup aspek visual, tekstual, performa, dan integrasi sistem. Spesifikasi kebutuhan ini menjadi acuan untuk: (1) Perancangan Arsitektur

¹Validasi memenuhi target <15 detik/gambar (GPU RTX A4000).

(Bab IV): Setiap komponen arsitektur (Generator, Recognizer, Discriminator, *Loss Function*) dirancang untuk memenuhi kebutuhan spesifik yang telah ditetapkan, (2) Implementasi Sistem (Bab IV): Detail implementasi seperti alur data, *training loop*, dan *inference workflow* didesain untuk memenuhi kebutuhan fungsional FR-4 hingga FR-8, (3) Evaluasi dan Validasi (Bab V): Metrik evaluasi dan protokol eksperimen dirancang untuk mengukur pencapaian kebutuhan non-fungsional NFR-1 hingga NFR-4. Dengan demikian, analisis kebutuhan ini memberikan dasar yang kuat untuk tahapan selanjutnya dalam kerangka DSRM, yaitu perancangan dan pengembangan solusi (DSRM Tahap 3: Desain dan Pengembangan) yang akan diuraikan pada tahap berikutnya.

III.2.4 Lingkungan Eksperimen dan Spesifikasi Komputasi

Implementasi menggunakan *workstation* dengan spesifikasi pada Tabel III.5. Sistem ini mendukung komputasi paralel GPU untuk melatih arsitektur GAN yang kompleks, termasuk komponen *dual-modal* dan *frozen recognizer*.

Tabel III.5 Spesifikasi perangkat keras dan perangkat lunak yang digunakan dalam eksperimen.

Komponen	Spesifikasi
GPU	2 × NVIDIA RTX A4000 (16 GB GDDR6 per GPU)
CPU	AMD Ryzen Threadripper PRO 3955WX (16-core/32-thread)
RAM	128 GB DDR4-3200
Penyimpanan	1 TB NVMe SSD (Samsung 980 PRO)
Sistem Operasi	Ubuntu 22.04.5 LTS
Kerangka Kerja	TensorFlow 2.16.1 + CUDA 12.8 + cuDNN 8.9.7

1. Dependensi Perangkat Lunak

Sistem menggunakan *software stack* terintegrasi berikut:

- Python 3.10.12 sebagai bahasa pemrograman utama.
- TensorFlow 2.16.1 dengan CUDA 12.8 dan cuDNN 8.9 untuk komputasi GPU.
- Poetry 1.7.1 untuk pengelolaan dependensi secara deterministik melalui `poetry.lock`.
- TensorFlow Text 2.16 untuk operasi CTC *loss*.
- MLflow 2.14.1 untuk pelacakan eksperimen dengan pencatatan otomatis *hyperparameter* dan metrik.

Pemilihan TensorFlow didasarkan pada stabilitas CTC *loss* dan kematangan ekosistem *tooling* pada domain HTR.

2. Protokol Reprodutibilitas

Reprodutibilitas dijamin melalui empat mekanisme deterministik:

1. *Seed* acak tetap ($seed=42$) untuk NumPy, TensorFlow, dan Python random.
2. Mode deterministik TensorFlow dan cuDNN ($TF_DETERMINISTIC_OPS=1$).
3. Konfigurasi GPU *single-device* (GPU:0) untuk menghindari variasi hasil akibat paralelisme.
4. Pelacakan eksperimen MLflow untuk audit penuh.

Model disimpan setiap 5 *epoch*, ditambah penyimpanan *best model* berdasarkan metrik gabungan PSNR-CER pada set validasi.

3. Konfigurasi Numerik dan Kinerja

Implementasi menggunakan presisi float32 untuk menjaga stabilitas numerik CTC *loss*. Presisi float16 dengan *mixed precision* tidak digunakan karena rentan terhadap *numerical underflow* pada probabilitas karakter kecil.

Infrastruktur komputasi ($2 \times$ RTX A4000, 128 GB RAM) memungkinkan *batch size* 2 per GPU untuk citra beresolusi 1024×128 piksel. Waktu pelatihan total adalah 17,82 jam GPU untuk 50 *epoch*.

III.2.5 Desain dan Pengembangan Artefak (Tahap 3)


Tahap ini merupakan inti penelitian di mana artefak *framework* restorasi dirancang, diimplementasikan, dan disempurnakan melalui siklus iteratif berbasis eksperimen. Tahap ini mengikuti metodologi pengembangan *deep learning* yang terdokumentasi dan mencakup pengembangan *framework* modular.

1. Fase 1: Persiapan Dataset HTR

Dataset bersih disiapkan untuk melatih model *Recognizer* dengan struktur pasangan citra-transkripsi. Dataset ini merupakan ekstraksi baris teks dari koleksi dokumen tulisan tangan paleografi Belanda abad ke-16 hingga ke-18 yang berasal dari Arsip Nasional Republik Indonesia (ANRI), yang telah didigitalisasi dan dianotasi dengan transkripsi *ground truth* oleh ahli paleografi.

2. Fase 2: Pelatihan dan Pembekuan Recognizer

Model *Recognizer* HTR dilatih menggunakan arsitektur hibrida CNN-Transformer dengan dataset ANRI paleografi Belanda. Setelah pelatihan mencapai konvergensi, bobot model dibekukan untuk memastikan konsistensi evaluasi selama pelatihan GAN dan mencegah *catastrophic forgetting*. Model beku ini diintegrasikan ke kerangka kerja untuk perhitungan CTC *loss* yang dipropagasi balik ke Generator.



Gambar III.2 Alur pengembangan kerangka kerja restorasi dokumen dengan lima fase utama yang dilakukan secara sekuensial dengan iterasi pada fase 4 dan 5.

3. Fase 3: Alur Degradasi Sintetis

Mengingat keterbatasan ketersediaan data berpasangan untuk dokumen historis, dikembangkan alur degradasi sintetis yang realistis untuk menghasilkan pasangan pelatihan dari dokumen bersih. Alur ini mensimulasikan berbagai jenis degradasi karakteristik dokumen historis seperti *bleed-through*, *ink fading*, noda, dan *noise* untuk menghasilkan citra terdegradasi yang merepresentasikan kondisi dokumen arsip autentik.

4. Fase 4: Implementasi dan Training GAN

Kerangka kerja GAN dengan komponen Generator, Diskriminator *Dual-Modal*, dan *frozen recognizer* (Fase 2) diimplementasikan dengan fungsi *loss* multikomponen. Dataset yang digunakan merupakan pasangan citra terdegradasi-bersih dari dokumen ANRI dengan alur degradasi semi-sintetis (Fase 3), dengan pembagian *train-validation-test split*.

Prosedur pelatihan mengikuti strategi *curriculum learning* tiga fase untuk stabilitas konvergensi: (1) *Visual Warmup* dengan *CTC loss disabled* untuk fokus rekonstruksi visual dasar, (2) *CTC Introduction* dengan aktivasi penuh untuk optimasi keterbacaan teks, dan (3) *Full Optimization* untuk keseimbangan Pareto antara kualitas visual dan keterbacaan HTR.¹ Pendekatan bertahap ini mencegah ketidakstabilan gradien

¹Studi ablasi susulan (Bab V, Bagian 5.3.2.4) menunjukkan bahwa untuk arsitektur yang handal

akibat optimasi simultan komponen *loss* dengan skala berbeda sejak awal pelatihan. Penelitian ini menerapkan tiga mekanisme metodologis untuk stabilitas dan efisiensi pelatihan: (1) penghentian dini berbasis kurikulum yang diaktifkan setelah fase *curriculum learning* selesai untuk mencegah penghentian dini selama fase pembelajaran kritis, (2) penyeimbangan *loss* adaptif berbasis GradNorm untuk menyeimbangkan kontribusi CTC *loss* dan *loss* visual secara dinamis, mencegah dominasi satu komponen yang dapat menyebabkan degradasi aspek lain, dan (3) konfigurasi *optimizer* dan regularisasi yang dioptimalkan melalui pencarian empiris bertahap, mencakup pemilihan algoritma *optimizer*, *learning rate*, dan bobot fungsi *loss* multi-komponen.

5. Fase 5: Studi Ablasi dan Optimasi Konfigurasi

Validasi kontribusi komponen dan identifikasi konfigurasi optimal dilakukan melalui eksperimen terkawal yang didokumentasikan menggunakan MLflow. Eksperimen mencakup: (1) studi ablasi sistematis untuk evaluasi kontribusi setiap komponen fungsi *loss* dengan pelatihan eksplorasi cepat (15–20 epoch) untuk efisiensi komputasi,² (2) eksplorasi diskriminator *dual-modal* vs *single-modal* dengan generator identik, (3) validasi strategi *frozen recognizer* versus *joint training* untuk mengevaluasi stabilitas pelatihan dan preservasi kemampuan HTR (menjawab RQ2), (4) eksperimen *curriculum learning* tiga fase versus pelatihan simultan untuk mengukur dampak terhadap stabilitas konvergensi, dan (5) optimasi *hyperparameter* melalui penyetelan manual empiris yang divalidasi dengan analisis stabilitas GradNorm dan pencarian kisi mini pada ruang *hyperparameter* terbatas. Detail protokol evaluasi dan hasil studi ablasi disajikan lengkap pada Tahap 5 (Section 3.2.5).

III.2.6 Demonstrasi (Tahap 4)

Efektivitas artefak yang dikembangkan divalidasi melalui serangkaian eksperimen pada *set* uji. Tahap ini bertujuan membuktikan kemampuan sistem dalam memulihkan dokumen terdegradasi sekaligus meningkatkan keterbacaan teks oleh mesin (HTR), sesuai dengan tujuan solusi yang telah didefinisikan.

Protokol Demonstrasi: Untuk memverifikasi kemampuan generalisasi model final, demonstrasi dilakukan melalui tiga mekanisme utama:

(1) Evaluasi Kualitatif Visual: Perbandingan visual secara berdampingan

dan dataset terkontrol, pendekatan *non-curriculum* dapat menghasilkan stabilitas yang sebanding dengan konvergensi lebih cepat. Namun, protokol *curriculum* tetap digunakan dalam pelatihan produksi untuk eksplorasi dinamika pembelajaran bertahap dan konsistensi dengan desain eksperimen awal.

²Pelatihan produksi (50 epoch) diperlukan untuk konvergensi penuh; ablasi cepat fokus pada kontribusi relatif, bukan performa absolut.

(*side-by-side*) pada sampel representatif yang mencakup berbagai jenis degradasi. Perbandingan ini menampilkan citra input terdegradasi, hasil restorasi dari metode *baseline*, hasil restorasi metode usulan, dan citra *ground truth* sebagai referensi ideal.

- (2) Evaluasi Fungsional HTR: Pengujian dampak restorasi terhadap akurasi pengenalan teks. Citra hasil restorasi diproses menggunakan HTR untuk menghasilkan transkripsi, yang kemudian dibandingkan dengan transkripsi manual untuk menghitung metrik kesalahan karakter (CER) dan kata (WER).
- (3) Evaluasi pada Dokumen Autentik: Pengujian model pada dokumen ANRI asli tanpa *ground truth* untuk memvalidasi kemampuan generalisasi ke kondisi degradasi di luar distribusi pelatihan. Hasil restorasi dievaluasi oleh ahli paleografi untuk memberikan validasi independen dari perspektif pakar domain.

III.2.7 Evaluasi (Tahap 5)

Tahap evaluasi bertujuan untuk mengukur kinerja artefak secara objektif dan memvalidasi hipotesis penelitian melalui empat mekanisme utama.

1. Evaluasi Kuantitatif

Pengukuran kinerja menggunakan dua kategori metrik:

- Kualitas visual: PSNR untuk fidelitas sinyal (target > 30 dB) dan SSIM untuk kesamaan struktural (target $> 0,95$).
- Keterbacaan teks: CER dan WER yang dihitung menggunakan *frozen recognizer* untuk mengukur penurunan tingkat kesalahan pengenalan.

2. Studi Ablasi Sistematis

Serangkaian eksperimen untuk memvalidasi kontribusi setiap komponen:

- Ablasi fungsi *loss*: lima eksperimen bertahap dari *pixel loss* tunggal hingga kombinasi lengkap (*pixel + adversarial + perceptual + CTC + feature loss*).
- Ablasi arsitektur: perbandingan diskriminator *single-modal* (CNN) dan *dual-modal* (CNN+BiLSTM).

3. Evaluasi Komparatif

Perbandingan kinerja metode usulan terhadap metode konvensional (*Otsu thresholding* dan *Sauvola adaptive thresholding*) serta kondisi tanpa perbaikan (*baseline*) pada *set uji* yang sama ($n = 712$).

4. Validasi Hipotesis

Pengujian signifikansi statistik menggunakan *independent samples t-test* ($\alpha = 0,05$) untuk hipotesis utama (H1) dan koreksi Bonferroni ($\alpha = 0,0167$) untuk hipotesis spesifik (H2_A, H2_B, H2_C). Ukuran efek (*effect size*) dihitung menggunakan Cohen's *d* untuk memastikan perbedaan memiliki makna praktis.

III.2.8 Komunikasi (Tahap 6)

Hasil penelitian disebarluaskan ke komunitas ilmiah dan praktisi untuk mendorong validasi eksternal, reproduisibilitas, dan penerapan praktis. Komunikasi dilakukan melalui tiga saluran utama:

- (1) **Diseminasi Akademik:** Hasil penelitian didokumentasikan dalam tesis dan dipublikasikan melalui konferensi internasional bereputasi sebagai tahap *peer review* awal, serta jurnal internasional Q2/Q3 di bidang analisis dokumen atau pengenalan pola untuk diseminasi. Publikasi mencakup kontribusi arsitektur *dual-modal*, strategi *frozen recognizer*, *curriculum learning*, dan validasi pada dokumen historis.
- (2) **Reproduisibilitas dan *Open Science*:** Untuk memastikan transparansi dan reproduisibilitas, seluruh artefak penelitian (kode sumber, model terlatih, konfigurasi eksperimen, dan *dataset* semi-sintetis) dipublikasikan dalam repositori *open-source* dengan dokumentasi lengkap dan *Digital Object Identifier* (DOI) untuk sitasi permanen.
- (3) **Transfer Pengetahuan kepada Praktisi:** Kerja sama dengan ANRI diwujudkan dalam bentuk bimbingan teknis, dokumentasi praktis, dan peluang riset lanjutan untuk mendukung penerapan *framework* dalam alur kerja preservasi digital dan digitalisasi dokumen historis.

Bab IV Perancangan Sistem

Bab ini menyajikan perancangan teknis kerangka kerja restorasi dokumen berbasis GAN. Fokus utama perancangan adalah mengatasi kesenjangan antara pemulihan kualitas visual dan keterbacaan mesin. Pembahasan diorganisasi ke dalam empat bagian: (1) Arsitektur dan Komponen Utama, (2) Pengembangan Dataset, (3) Strategi dan Protokol Pelatihan, dan (4) Konfigurasi Evaluasi.


IV.1 Arsitektur dan Komponen Utama

Kerangka kerja GAN-HTR dirancang untuk mengatasi kesenjangan metode restorasi konvensional yang telah diidentifikasi pada Bab II.8. Berbeda dari pendekatan sebelumnya yang mengabaikan aspek keterbacaan oleh mesin atau mengalami ketidakstabilan pada *joint training*, kerangka kerja ini mengintegrasikan evaluasi keterbacaan teks secara eksplisit dalam siklus pelatihan melalui strategi *frozen recognizer*.

Kerangka kerja yang diusulkan beroperasi pada citra baris dokumen tulisan tangan yang terdegradasi dan menghasilkan keluaran bersih yang dioptimalkan untuk kualitas visual serta kinerja HTR. Arsitektur terdiri dari empat komponen utama yang berinteraksi dalam kerangka pelatihan *adversarial*:

1. Generator (G): Arsitektur U-Net *Enhanced* yang memetakan citra terdegradasi I_{deg} ke citra terestorasi I_{gen} . Dilengkapi dengan *Residual Dense Blocks* (RDB) dan *Attention Gates* untuk preservasi detail teks halus sekaligus menghilangkan derau latar belakang.
2. Diskriminator *Dual-Modal* (D): Diskriminator dengan jalur paralel CNN dan BiLSTM yang menilai kualitas visual dan koherensi teks secara bersamaan. Mekanisme *bilateral cross-attention fusion* memvalidasi konsistensi visual-tekstual.
3. *Frozen Recognizer* (R): Pengenal berbasis *Transformer* praterlatih dengan bobot tetap yang menyediakan gradien sadar-HTR tanpa risiko *catastrophic forgetting*.
4. Fungsi Loss Multikomponen: Menyeimbangkan kualitas visual ($L1 + perceptual$ + *adversarial*) dan keterbacaan teks (*CTC loss*).

Keempat komponen ini divalidasi secara empiris melalui studi ablasi pada Bab V. Gambar IV.1 memvisualisasikan arsitektur keseluruhan dan interaksi antarkomponen dalam siklus pelatihan *adversarial*: Generator menghasilkan citra restorasi dari input terdegradasi, *frozen recognizer* mengevaluasi keterbacaan melalui *CTC loss*, dan diskriminator menilai koherensi visual-tekstual. Strategi pelatihan dan protokol optimisasi diuraikan pada Bagian IV.3.



Gambar IV.1 Kerangka kerja GAN-HTR dengan diskriminator *dual-modal* dan *frozen* HTR recognizer. Komponen utama: (1) Generator U-Net Enhanced, (2) Diskriminator Dual-Modal (CNN+BiLSTM), (3) Frozen HTR Recognizer untuk CTC loss.

Subbagian berikut menguraikan arsitektur detail setiap komponen.


IV.1.1 Arsitektur Generator

Penelitian ini mengadopsi arsitektur U-Net Enhanced yang terdiri dari tiga komponen utama: *encoder*, *bottleneck*, dan *decoder*. Berbeda dari U-Net konvensional Ronneberger dkk. (2015b) yang menggunakan blok konvolusi standar, arsitektur *Enhanced* mengintegrasikan empat teknik tambahan: *Residual Dense Blocks* (RDB) Yulun Zhang dkk. (2018), *Convolutional Block Attention Module* (CBAM) Woo dkk. (2018), *Multi-Scale Feature Pyramid* (MSFP) Lin dkk. (2017), dan *Attention Gates* Oktay dkk. (2018). Spesifikasi detail arsitektur (21,8M parameter, *memory footprint* ~ 87 MB) tersedia pada Lampiran A, sementara Gambar IV.2 memvisualisasikan struktur keseluruhan.

1. Encoder

Encoder mengekstrak fitur hierarkis melalui *downsampling* progresif dalam lima tahap, mengurangi resolusi spasial dari 1024×128 hingga 32×4 (lebar $\times$ tinggi) sambil meningkatkan kedalaman kanal. Setiap blok *encoder* terdiri dari:

- Residual Dense Block* (RDB): Tiga lapisan konvolusi *densely-connected* (kernel 3×3 , *growth rate* 32) yang memungkinkan setiap lapisan mengakses fitur dari semua lapisan sebelumnya.



Gambar IV.2 Generator U-Net Enhanced: arsitektur *encoder-decoder* simetris dengan *RDB+CBAM*, *bottleneck* MSFP 512 kanal, *attention gates*, dan *skip connections*.

- b. *CBAM*: Atensi kanal (rasio reduksi 8) dan atensi spasial (*kernel* 7×7) untuk rekalisasi fitur adaptif.
- c. *Batch normalization* (*momentum* = 0,9) dan aktivasi *LeakyReLU* ($\alpha = 0,2$).
- d. Koneksi *residual* untuk propagasi gradien efektif.

2. Bottleneck

Bottleneck pada resolusi terendah ($32 \times 4 \times 512$) menangkap konteks global multi-skala melalui *Multi-Scale Feature Pyramid* (MSFP) dengan tiga skala konvolusi terdilasi (*dilation rates* 1, 2, 4) L.-C. Chen dkk. (2017). Komponen ini memungkinkan arsitektur 'melihat' degradasi pada berbagai skala—dari derau titik hingga noda besar—sebelum proses rekonstruksi. *RDB* dan *CBAM* diterapkan untuk penyempurnaan fitur global.

3. Decoder

Decoder merekonstruksi citra bersih melalui *upsampling* progresif dalam lima tahap, mencerminkan struktur *encoder*. Fitur penting *decoder* adalah *Attention Gates* Oktay dkk. (2018) pada setiap *skip connection* yang menyaring fitur dari *encoder*:

$$\alpha = \sigma(W_g^T g + W_x^T x + b) \quad (\text{IV.7})$$

dengan g adalah fitur *decoder* (sinyal *gating*), x adalah fitur *skip connection* dari *encoder*, dan σ adalah aktivasi *sigmoid*. Koefisien atensi $\alpha \in [0, 1]$ ini kemudian diterapkan pada fitur: $\hat{x} = \alpha \odot x$, menekan fitur latar belakang sambil memperkuat wilayah pembawa teks.

Detail arsitektur lengkap (21,8M parameter) dengan spesifikasi setiap tahap tersedia pada Lampiran A (Tabel A.1).

IV.1.2 Arsitektur Diskriminator


Arsitektur diskriminator *dual-modal* dirancang untuk mengatasi keterbatasan diskriminator *single-modal* yang hanya mengevaluasi kualitas visual—contohnya adalah *PatchGAN* pada DE-GAN dan ERB-MultiTask. Berbeda dengan pendekatan konvensional tersebut, arsitektur ini mengevaluasi citra dari dua perspektif yang saling melengkapi:

- (1) Perspektif spasial (visual) melalui jalur CNN yang menilai kualitas goresan, tekstur, dan struktur spasial.
- (2) Perspektif sekuensial (teks) melalui jalur BiLSTM yang menilai koherensi dan kelayakan urutan karakter.

Integrasi kedua modalitas melalui mekanisme *bilateral cross-modal attention* memungkinkan diskriminator memberikan sinyal *adversarial* yang lebih kaya informasi. Gradien visual mendorong pelestarian detail goresan halus, sementara gradien tekstual mendorong konsistensi struktur karakter. Hipotesis desain ini divalidasi melalui studi ablasi pada Bagian V.4.3.

Secara teknis, diskriminator menerima citra masukan dan sekuens teks (panjang maksimal 128 karakter), kemudian memprosesnya melalui dua jalur paralel seperti ditunjukkan pada Gambar IV.3. Detail arsitektur lengkap (17,4M parameter) tersedia pada Lampiran B (Tabel B.1).

Gambar IV.3 memvisualisasikan alur pemrosesan arsitektur. Cabang CNN (kiri) memproses citra melalui 4 *DownBlocks* dengan *spatial attention*. Cabang BiLSTM (kanan) memproses sekuens teks melalui *embedding* dan *self-attention*. Kedua representasi 512-D bertemu pada modul fusi bilateral sebelum klasifikasi akhir. Bagian berikut menguraikan spesifikasi teknis masing-masing komponen.



Gambar IV.3 Arsitektur Diskriminator Dual-Modal Enhanced dengan dua cabang pemrosesan paralel (CNN untuk fitur visual, BiLSTM untuk fitur tekstual) dan mekanisme fusi *bilateral cross-modal attention*.

1. Cabang Citra (CNN dengan Atensi Spasial)

Cabang ini mengekstrak fitur visual spasial melalui arsitektur berbasis *ResNet*. Masukan citra $I \in \mathbb{R}^{1024 \times 128 \times 1}$ diproses melalui lapisan konvolusi awal (64 kanal) dengan *batch normalization* dan aktivasi *LeakyReLU* ($\alpha = 0,2$). Empat blok *downsampling residual* secara progresif mengurangi resolusi spasial sambil meningkatkan kedalaman kanal:

$$\begin{aligned} 1024 \times 128 \times 64 &\rightarrow 512 \times 64 \times 64 \rightarrow 256 \times 32 \times 128 \\ &\rightarrow 128 \times 16 \times 256 \rightarrow 64 \times 8 \times 512 \end{aligned} \quad (\text{IV.8})$$

Mekanisme atensi spasial dengan kernel 3×3 diterapkan pada fitur 512 kanal untuk fokus pada wilayah pembawa teks:

$$\alpha_{\text{spatial}} = \sigma(\text{Conv}_{3 \times 3}(F_{\text{img}})) \quad (\text{IV.9})$$

dengan σ adalah fungsi *sigmoid* dan F_{img} adalah peta fitur berdimensi $64 \times 8 \times 512$. Setelah atensi spasial, blok *residual* tambahan dengan 512 kanal (*ResBlock-512*) memproses fitur lebih lanjut tanpa mengubah dimensi spasial. Selanjutnya, *global average pooling* mengagregasi fitur spasial menjadi vektor representasi $F_{\text{img}}^{\text{global}} \in \mathbb{R}^{512}$.

2. Cabang Teks (BiLSTM dengan Atensi-Mandiri)

Cabang ini menangkap koherensi sekuensial teks. Sekuens karakter masukan $S \in \mathbb{N}^L$ (panjang $L \leq 128$) diproyeksikan ke ruang *embedding* $E \in \mathbb{R}^{L \times 128}$. BiLSTM memproses sekuens dalam kedua arah untuk menangkap ketergantungan kontekstual:

$$h_t = [\vec{h}_t; \overleftarrow{h}_t] = [\text{LSTM}_{\text{fwd}}(E_t); \text{LSTM}_{\text{bwd}}(E_t)] \quad (\text{IV.10})$$

menghasilkan *hidden states* $H \in \mathbb{R}^{L \times 512}$. Mekanisme atensi-mandiri *multi-head scaled dot-product* diterapkan:

$$\text{Attention}(Q, K, V) = \text{softmax} \left(\frac{QK^T}{\sqrt{d_k}} \right) V \quad (\text{IV.11})$$

dengan Q, K, V adalah proyeksi linear dari H . *Global average pooling* menghasilkan vektor teks $F_{\text{text}}^{\text{global}} \in \mathbb{R}^{512}$.

3. Fusi Cross-Modal

Kedua vektor fitur $F_{\text{img}}^{\text{global}} \in \mathbb{R}^{512}$ dan $F_{\text{text}}^{\text{global}} \in \mathbb{R}^{512}$ diproses melalui mekanisme atensi *cross-modal* bilateral untuk memungkinkan interaksi dua arah antarmodalitas. Pendekatan bilateral memiliki dua alasan: pertama, citra perlu memvalidasi koherensi teks yang diprediksi pengenalan HTR; kedua, teks perlu memverifikasi kualitas visual goresan yang menghasilkan karakter tersebut. Dengan demikian, kedua modalitas saling memberikan konteks untuk deteksi anomali yang lebih *robust*. Setiap modalitas memproyeksikan fiturnya ke ruang bersama berdimensi rendah $d = 128$ melalui enam matriks proyeksi terpisah:

Atensi Citra→Teks: Citra sebagai *query*, teks sebagai *key/value*:

$$\begin{aligned} Q_{\text{img}} &= W_{\text{img}}^Q F_{\text{img}}^{\text{global}} \\ K_{\text{text}} &= W_{\text{text}}^K F_{\text{text}}^{\text{global}} \\ V_{\text{text}} &= W_{\text{text}}^V F_{\text{text}}^{\text{global}} \end{aligned} \quad (\text{IV.12})$$

$$F_{\text{img}}^{\text{att}} = \text{softmax} \left(\frac{Q_{\text{img}} K_{\text{text}}^T}{\sqrt{d}} \right) V_{\text{text}} \quad (\text{IV.13})$$

dengan $W_{\text{img}}^Q, W_{\text{text}}^K, W_{\text{text}}^V \in \mathbb{R}^{512 \times 128}$ adalah matriks proyeksi yang dipelajari.

Atensi Teks→Citra: Teks sebagai *query*, citra sebagai *key/value*:

$$\begin{aligned} Q_{\text{text}} &= W_{\text{text}}^Q F_{\text{text}}^{\text{global}} \\ K_{\text{img}} &= W_{\text{img}}^K F_{\text{img}}^{\text{global}} \\ V_{\text{img}} &= W_{\text{img}}^V F_{\text{img}}^{\text{global}} \end{aligned} \quad (\text{IV.14})$$

$$F_{\text{text}}^{\text{att}} = \text{softmax} \left(\frac{Q_{\text{text}} K_{\text{img}}^T}{\sqrt{d}} \right) V_{\text{img}} \quad (\text{IV.15})$$

dengan $W_{\text{text}}^Q, W_{\text{img}}^K, W_{\text{img}}^V \in \mathbb{R}^{512 \times 128}$ adalah matriks proyeksi simetris.

Kedua fitur yang telah mengalami atensi bilateral ($F_{\text{img}}^{\text{att}}, F_{\text{text}}^{\text{att}} \in \mathbb{R}^{128}$) digabungkan menjadi vektor fusi: $F_{\text{fused}} = [F_{\text{img}}^{\text{att}}, F_{\text{text}}^{\text{att}}] \in \mathbb{R}^{256}$.

Kepala klasifikasi terdiri dari dua lapisan padat ($512 \rightarrow 256$ neuron) dengan *dropout* dan aktivasi *LeakyReLU*. Lapisan keluaran menggunakan aktivasi *sigmoid* yang menghasilkan nilai validitas $D(I, S) \in [0, 1]$ untuk membedakan pasangan citra-teks asli dari pasangan palsu yang dihasilkan generator.

4. Kemampuan Deteksi

Dengan kombinasi analisis spasial CNN dan pemrosesan sekuens BiLSTM, diskriminator dapat mendeteksi:

- Goresan yang rusak atau terputus yang mengganggu alur teks (melalui deteksi anomali sekuens BiLSTM)
- Pola derau, artefak, dan tembus-balik (melalui fitur spasial CNN)
- Lebar goresan yang tidak konsisten (melalui mekanisme atensi spasial)
- Celah atau koneksi yang tidak wajar antar karakter (melalui analisis fusi cross-modal)


5. Mode Input Teks

Diskriminator dual-modal dapat beroperasi dalam dua mode input teks: (1) *Ground Truth Mode* menggunakan label teks yang sudah dianotasi, memberikan sinyal pembelajaran yang bersih namun kurang realistis untuk *deployment*, dan (2) *Predicted Mode* menggunakan prediksi dari *frozen recognizer*, lebih realistis namun rentan terhadap *error propagation*. Perbandingan empiris kedua mode dan justifikasi pemilihan mode untuk pelatihan diuraikan pada Bab V.

IV.1.3 Arsitektur HTR

Komponen *Recognizer* (R) dalam kerangka kerja ini merupakan model HTR hibrida CNN-Transformer praterlatih dengan total 27,86M parameter. Arsitektur terdiri dari tiga bagian utama yang diuraikan berikut ini dan divisualisasikan pada

Gambar IV.4. Model ini dilatih pada dokumen ANRI era kolonial abad 16–18 sebelum diintegrasikan ke dalam kerangka kerja GAN dengan strategi pembekuan bobot.



Gambar IV.4 Arsitektur HTR *Recognizer*: model hibrida CNN-Transformer dengan CNN *Backbone* 4 tahap (64 $\rightarrow$ 512 kanal), *Transformer Encoder* 6 lapisan (8 *heads*, dimensi 512), dan *CTC Output Layer* (96 kelas). Total 27,86M parameter dibekukan selama pelatihan GAN.

1. CNN Backbone

CNN *Backbone* berfungsi untuk mengekstrak fitur visual dari citra baris dokumen. Arsitektur terdiri dari 8 lapisan konvolusi yang diorganisasi dalam 4 tahap dengan peningkatan kedalaman kanal progresif: $64 \rightarrow 128 \rightarrow 256 \rightarrow 512$. Setiap tahap menerapkan *max pooling* untuk reduksi dimensi spasial sambil mempertahankan informasi diskriminatif. Output berupa peta fitur spasial yang menjadi input bagi *Transformer Encoder*.

2. Transformer Encoder

Transformer Encoder memodelkan ketergantungan kontekstual antar posisi karakter dalam sekuens. Arsitektur terdiri dari 6 lapisan *encoder* dengan konfigurasi: 8 *attention heads* dan dimensi representasi 512. Mekanisme *self-attention* memungkinkan setiap posisi mengakses informasi dari seluruh sekuens, penting untuk menangani variasi jarak antar karakter pada dokumen tulisan tangan. Output berupa representasi kontekstual untuk prediksi karakter.

3. CTC Output Layer

CTC Output Layer memetakan representasi kontekstual ke distribusi probabilitas karakter. Lapisan ini menghasilkan prediksi untuk 95 kelas karakter (termasuk *blank token* untuk penyelarasan CTC). *Connectionist Temporal Classification*

(CTC) dipilih karena kemampuannya menangani sekuens dengan panjang variabel tanpa memerlukan penyelarasan karakter-per-karakter secara eksplisit—ideal untuk dokumen tulisan tangan dengan variasi spasial tinggi.

4. Ekstraksi Fitur

Selain prediksi teks, *Recognizer* juga menghasilkan fitur perantara untuk kalkulasi *Recognition Feature Loss*. Fitur diekstrak dari lapisan proyeksi sebelum *Transformer Encoder*:

$$\mathcal{F}_{\text{rec}}(I) = R_{\text{encoder}}(I) \quad (\text{IV.16})$$

dengan R_{encoder} adalah bagian *encoder* yang dibekukan. Output berupa peta fitur dengan dimensi (batch, 128, 512) yang menangkap karakteristik relevan dengan teks: pola goresan, bentuk karakter, dan pengaturan spasial. Lapisan ini dipilih karena mengandung fitur tingkat urutan sebelum pengodean kontekstual, memberikan gradien yang stabil untuk Generator.

5. Strategi Integrasi

Berbeda dengan pendekatan *joint training* pada ERB-MultiTask M. Souibgui, Kessentini, dan Fornés (2021), penelitian ini mengadopsi strategi pembekuan bobot (*frozen recognizer*). Strategi ini dipilih berdasarkan tiga pertimbangan utama: (1) efisiensi komputasional—pengenal 27,86M parameter tidak memerlukan komputasi gradien, (2) stabilitas pelatihan—mengeliminasi konflik gradien destruktif antara tujuan rekonstruksi dan pengenalan M. Souibgui, Kessentini, dan Fornés (2022) dan Kang dkk. (2021), dan (3) pelestarian kinerja—mencegah *catastrophic forgetting* Kirkpatrick dkk. (2017) pada pengenalan praterlatih.

Komponen *Recognizer* beku berfungsi sebagai evaluator objektif yang menghasilkan: (1) input teks bagi Diskriminator *dual-modal* untuk menilai koherensi visual-tekstual, dan (2) kalkulasi *CTC Loss* dan *Recognition Feature Loss* untuk mengukur keterbacaan hasil restorasi. Tabel IV.1 merangkum perbandingan strategi integrasi yang dipertimbangkan.

Tabel IV.1 Analisis komparatif strategi integrasi pengenalan HTR.

Strategi	Keuntungan	Keterbatasan
Pelatihan bersama	Optimasi <i>end-to-end</i> , adaptasi spesifik-tugas	Biaya komputasi tinggi, konflik gradien, risiko <i>catastrophic forgetting</i>
Beku*	Konvergensi stabil, efisiensi komputasional, pelestarian kinerja	Adaptasi spesifik-tugas terbatas
Dua tahap	Optimasi seimbang, stabilitas sekuensial	Waktu pelatihan berlipat, penjadwalan kompleks
Tanpa <i>Recognizer</i>	Arsitektur sederhana	Tidak ada optimasi sadar-HTR
*Strategi yang dipilih dalam penelitian ini		

Validasi empiris strategi pembekuan melalui studi ablasi diuraikan pada Bab V.6.3. Hasil menunjukkan bahwa strategi *frozen recognizer* mempertahankan kinerja pengenalan lebih baik dibandingkan *joint training* yang mengalami degradasi akibat *catastrophic forgetting*.

IV.1.4 Fungsi Loss Multikomponen

Generator dilatih dengan kombinasi lima komponen loss yang dikalibrasi melalui penyetelan empiris berdasarkan analisis *inverse scaling* terhadap distribusi magnitudo loss dan divalidasi secara *post-hoc* menggunakan pencarian kisi sistematis (27 konfigurasi dengan metode *orthogonal array sampling*) yang mengonfirmasi optimalitas konfigurasi yang dipilih. Fungsi loss total menggabungkan komponen-komponen tersebut secara terbobot untuk mengoptimalkan kualitas visual dan keterbacaan teks secara simultan:

$$\begin{aligned} \mathcal{L}_{\text{total}} = & \lambda_{\text{adv}} \mathcal{L}_{\text{adv}} + \lambda_{\text{pixel}} \mathcal{L}_{\text{pixel}} + \lambda_{\text{perc}} \mathcal{L}_{\text{perc}} \\ & + \lambda_{\text{ctc}} \mathcal{L}_{\text{ctc}} + \lambda_{\text{rec-feat}} \mathcal{L}_{\text{rec-feat}} \end{aligned} \quad (\text{IV.17})$$

Konfigurasi bobot loss untuk setiap komponen ditunjukkan dalam Tabel IV.2. Studi ablasi sistematis (Bab V) mengidentifikasi konfigurasi optimal 4-komponen (tanpa $\mathcal{L}_{\text{rec-feat}}$) sebagai keseimbangan *Pareto* antara kualitas visual dan keterbacaan HTR.

1. Adversarial Loss

Adversarial loss standar GAN mendorong pembuatan citra yang realistis dengan melatih generator untuk menipu diskriminator:

$$\mathcal{L}_{\text{adv}} = -\log D(I_{\text{deg}}, I_{\text{gen}}) \quad (\text{IV.18})$$

dengan $D(I_{\text{deg}}, I_{\text{gen}})$ adalah probabilitas diskriminator menganggap pasangan citra terdegradasi masukan I_{deg} dan citra hasil restorasi I_{gen} sebagai pasangan autentik. Diskriminator dilatih untuk memaksimalkan kemampuan membedakan:

$$\begin{aligned} \mathcal{L}_D = -[& \log D(I_{\text{deg}}, I_{\text{gt}}) \\ & + \log(1 - D(I_{\text{deg}}, I_{\text{gen}}))] \end{aligned} \quad (\text{IV.19})$$

dengan pasangan $(I_{\text{deg}}, I_{\text{gt}})$ merupakan pasangan nyata (citra terdegradasi dengan *ground truth* bersih), sedangkan $(I_{\text{deg}}, I_{\text{gen}})$ merupakan pasangan palsu hasil generator. Mekanisme *adversarial* ini mendorong generator menghasilkan citra dengan distribusi tekstur dan karakteristik visual yang tidak dapat dibedakan dari dokumen bersih autentik.

2. Pixel Reconstruction Loss

Pixel reconstruction loss menggunakan norma L1 untuk memastikan kesamaan piksel-demi-piksel dengan *ground truth*:

$$\mathcal{L}_{\text{pixel}} = \|I_{\text{gen}} - I_{\text{gt}}\|_1 \quad (\text{IV.20})$$

Norma L1 dipilih karena menghasilkan hasil yang lebih tajam dibandingkan norma L2 dan lebih tangguh terhadap nilai pencilan. Berbeda dengan L2 yang memberikan penalti kuadratik (cenderung menghasilkan citra kabur), L1 memberikan penalti linear yang mempertahankan ketajaman tepi dan detail goresan halus yang penting untuk keterbacaan HTR.

3. Perceptual Loss

Perceptual loss Johnson dkk. (2016) membandingkan fitur tingkat tinggi dari jaringan VGG-19 yang telah dilatih pada *ImageNet*:

$$\mathcal{L}_{\text{perc}} = \sum_{l \in L} \|\phi_l(I_{\text{gen}}) - \phi_l(I_{\text{gt}})\|_2 \quad (\text{IV.21})$$

dengan ϕ_l menunjukkan fitur dari lapisan l dari jaringan VGG-19 praterlatih, dan L adalah himpunan lapisan konvolusi yang dipilih untuk ekstraksi fitur. Fitur diekstrak dari beberapa lapisan konvolusi untuk perbandingan perseptual multiskala. Pendekatan ini memastikan pelestarian karakteristik visual dari detail tingkat rendah (tepi, tekstur) hingga fitur semantik tingkat tinggi (pola goresan, bentuk

karakter), menghasilkan citra yang lebih koheren secara perseptual meskipun terdapat perbedaan piksel minor.

4. CTC Loss

CTC loss memberikan gradien sadar-teks langsung dari *frozen recognizer* untuk mengoptimalkan keterbacaan HTR secara eksplisit. *Connectionist Temporal Classification* (CTC) Graves dkk. (2006) dipilih karena kemampuannya menangani sekuens dengan panjang variabel tanpa memerlukan *alignment* eksplisit antara input citra dan output teks, ideal untuk dokumen tulisan tangan dengan variasi spasial karakter yang tinggi.

Formulasi matematis CTC dan mekanisme penyalarsan otomatis telah dijelaskan secara rinci pada Bab II Subbab II.5.2. Komponen ini merupakan karakteristik penting kerangka kerja yang membedakannya dari metode restorasi dokumen konvensional yang hanya mengoptimalkan kualitas visual tanpa mempertimbangkan keterbacaan mesin.

Analisis kontribusi menunjukkan CTC loss berkontribusi 67,5% terhadap total generator loss (meskipun bobot $\lambda_{ctc} = 0,15$ relatif kecil) karena magnitudo *natural* CTC ($\sim 100\text{--}300$) jauh lebih besar dibanding komponen visual ($\sim 0,1\text{--}5,0$), memvalidasi peran dominan komponen HTR dalam optimasi.

Strategi *clipping* dengan batas maksimal 400,0 diterapkan untuk mencegah gradien ekstrem pada kasus degradasi berat yang dapat mengganggu stabilitas pelatihan adversarial.

5. Recognition Feature Loss

Komponen *recognition feature loss* ($\mathcal{L}_{\text{rec-feat}}$) dirancang untuk mendorong kesamaan fitur tingkat menengah antara citra restorasi dan *ground truth* pada ruang representasi *recognizer*:

$$\mathcal{L}_{\text{rec-feat}} = \|\mathcal{F}_{\text{rec}}(I_{\text{gen}}) - \mathcal{F}_{\text{rec}}(I_{\text{gt}})\|_2^2 \quad (\text{IV.22})$$

dengan $\mathcal{F}_{\text{rec}}$ adalah ekstraksi fitur dari *Recognizer* (Persamaan IV.16). Namun, studi ablasi sistematis (Bab V.6.2) menunjukkan bahwa komponen ini tidak memberikan kontribusi signifikan ($p > 0,05$) dan memiliki pola korelasi tinggi dengan *CTC loss*—mengindikasikan objektif yang tumpang tindih. Berdasarkan prinsip *parsimony*, konfigurasi produksi menonaktifkan komponen ini ($\lambda_{\text{rec-feat}} = 0$) dan menggunakan *CTC loss* sebagai komponen HTR tunggal.

Tabel IV.2 Konfigurasi bobot *loss* optimal: *inverse scaling* empiris divalidasi dengan *grid search* (27 konfigurasi).

Komponen Loss	Bobot (λ)	Justifikasi
<i>adversarial</i> ($\mathcal{L}_{adv}$)	3,0	Realisme tekstur dan distribusi visual yang ditingkatkan tanpa mengorbankan stabilitas pelatihan
Piksel L1 ($\mathcal{L}_{pixel}$)	50,0	Pelestarian struktur piksel yang seimbang; bobot tinggi memastikan kesetiaan rekonstruksi dasar
<i>Perceptual</i> ($\mathcal{L}_{perc}$)	1,0	Pelestarian topologi dan koherensi fitur semantik tingkat tinggi
Recognition Feature loss ($\mathcal{L}_{rec-feat}$)	8,0	Panduan karakteristik ramah HTR yang kuat (dinonaktifkan produksi: $\lambda = 0$)
CTC loss ($\mathcal{L}_{ctc}$)	0,15	Pemantauan keterbacaan HTR dengan <i>clipping</i> numerik untuk stabilitas gradien

Pemilihan bobot *loss* (Tabel IV.2) dilakukan berdasarkan prinsip *inverse scaling* empiris dari analisis distribusi magnitudo *loss*, dengan pertimbangan bahwa komponen dengan magnitudo natural lebih besar memerlukan bobot lebih kecil untuk mencegah dominasi berlebihan dalam total generator *loss*. Konfigurasi yang dipilih (pixel=50,0, adversarial=3,0, perceptual=1,0, CTC=0,15, recognition feature=8,0) kemudian divalidasi melalui dua mekanisme: (1) validasi *post-hoc* menggunakan pencarian kisi sistematis dengan 27 konfigurasi (pixel $\in \{25, 50, 100\}$, adversarial $\in \{1, 5, 3, 0, 6, 0\}$, perceptual $\in \{0, 5, 1, 0, 2, 0\}$, CTC $\in \{0, 075, 0, 15, 0, 30\}$, recognition feature $\in \{0, 8, 16\}$) yang menggunakan metode *orthogonal array sampling*, menunjukkan bahwa konfigurasi production berada dalam rentang optimal dan tidak ada konfigurasi alternatif yang memberikan peningkatan signifikan pada fase awal konvergensi (3 epoch); (2) validasi *GradNorm* selama pelatihan production (50 epoch) menunjukkan variasi bobot 0%, mengonfirmasi konfigurasi sudah berada pada titik keseimbangan optimal untuk konvergensi jangka panjang.

6. Optimasi Berorientasi HTR

Istilah optimasi fungsi *loss* berorientasi HTR pada penelitian ini mengacu pada strategi kalibrasi yang menempatkan komponen HTR sebagai faktor dominan dalam pemilihan bobot, bukan sekadar komponen tambahan pada fungsi *loss* visual. Pendekatan ini berbeda dari metode restorasi dokumen konvensional dalam dua

aspek:

- Dominasi *CTC Loss*: Meskipun bobot nominal rendah ($\lambda_{ctc} = 0,15$), magnitudo *natural* yang besar ($\sim 100\text{--}400$) menghasilkan kontribusi efektif 67,5% terhadap total *generator loss*—dibandingkan 32,4% untuk komponen visual (*pixel + adversarial + perceptual*).
- Orientasi Keterbacaan: Generator dioptimalkan secara eksplisit untuk keterbacaan HTR, memastikan hasil restorasi tidak hanya berkualitas visual tinggi tetapi juga dapat dibaca oleh sistem pengenalan teks.

Analisis *trade-off* multi-objektif antara kualitas visual (PSNR, SSIM) dan keterbacaan teks (CER, WER), termasuk validasi *Pareto front* dan sensitivitas komponen loss, diuraikan secara detail pada Bab V.

IV.2 Pengembangan Dataset

Pelatihan dan evaluasi kerangka kerja GAN-HTR memerlukan konstruksi dataset khusus yang tidak tersedia secara publik. Bagian ini menjelaskan proses pengembangan empat komponen dataset: (1) *ground truth* untuk pelatihan model GAN, (2) *ground truth* untuk pelatihan model *recognizer*, (3) dataset evaluasi kuantitatif, dan (4) dataset evaluasi kualitatif. Seluruh data bersumber dari koleksi arsip ANRI untuk memastikan karakteristik paleografi yang representatif. Gambar IV.5 memvisualisasikan alur pembuatan *ground truth* secara keseluruhan.

IV.2.1 Pembuatan *Ground Truth* untuk GAN

Model GAN memerlukan pasangan citra terdegradasi-bersih (*paired images*) dengan keselarasan tingkat piksel yang sempurna. Karena dokumen historis nyata yang rusak tidak dapat dipulihkan ke kondisi aslinya secara fisik, dataset semi-sintetis dikonstruksi melalui dua tahap.


1. Tahap Satu: Ekstraksi Citra Bersih

Citra *ground truth* (bersih) diperoleh dari dokumen arsip ANRI abad ke-16 hingga ke-18 yang memiliki kondisi fisik prima (minim degradasi). Proses ekstraksi meliputi:

- Seleksi manual halaman dengan keterbacaan tinggi dari koleksi ANRI.
- Ekstraksi baris teks menggunakan koordinat *baseline* dari anotasi Transkribus.
- Normalisasi geometri ke dimensi 1024×128 piksel.

2. Tahap Dua: Sintesis Degradasi


Citra bersih kemudian diproses melalui *pipeline* degradasi sintetis berlapis untuk menghasilkan pasangan citra terdegradasi. Lima jenis degradasi diterapkan secara stokastik:



Gambar IV.5 Alur pembuatan *ground truth* untuk GAN-HTR. Proses mengintegrasikan tiga sumber: (1) dokumen ANRI kondisi prima untuk citra bersih, (2) PageXML Transkribus untuk koordinat *baseline* dan transkripsi, serta (3) dokumen ANRI rusak untuk tekstur *background* autentik. Hasil akhir adalah dataset triplet (I_{clean} , I_{degraded} , transcription) sebanyak 4.739 pasangan.

- Overlay Latar Belakang & Fading*: Penggabungan dengan tekstur kertas tua ANRI, disertai reduksi kontras ($\gamma \in [0, 5, 0, 8]$).
- Bleed-through* (30% prob.): *Alpha blending* ($\alpha \in [0, 3, 0, 7]$) mensimulasikan tembus tinta dari halaman belakang.
- Stains & Foxing* (25% prob.): Tekstur noda organik menggunakan *Perlin noise* dan bintik kecoklatan.
- Gaussian blur* (20% prob.): Kernel $\sigma \in [0, 5, 2, 0]$ mensimulasikan ketidakfokusan optik.
- Kerusakan Fisik & Noise (10% prob.): Simulasi robekan, lipatan, dan *salt & pepper noise*.

Degradasi diterapkan secara independen dan dapat saling tumpang tindih. Validasi PSNR > 20 dB memastikan struktur karakter tetap terbaca. Proses ini menghasilkan *dataset triplet* (I_{deg} , I_{clean} , transcription) sebanyak 4.739 pasangan.



Gambar IV.6 Pasangan dataset semi-sintetis realistis. (Atas) Citra *ground truth* bersih dari dokumen ANRI abad ke-16–18. (Bawah) Citra terdegradasi hasil sintesis degradasi berlapis.

IV.2.2 Pembuatan *Ground Truth* untuk *Recognizer*

Model *recognizer* (HTR) yang digunakan sebagai komponen *frozen* dalam arsitektur memerlukan dataset terpisah untuk pelatihannya. Dataset ini dikonstruksi dari sumber yang sama (dokumen ANRI bersih) namun dengan pemrosesan yang berbeda.

1. Proses Konstruksi

- Segmentasi Baris: Ekstraksi baris teks menggunakan koordinat *baseline* dari anotasi Transkribus.
- Pra-pemrosesan: Normalisasi ke rentang $[0, 1]$, *resize bilinear* ke 1024×128 piksel, dan binarisasi menggunakan DE-GAN untuk meningkatkan kontras goresan-latar.
- Validasi Kualitas: Setiap *patch* harus memiliki transkripsi valid (panjang > 3 karakter, tanpa karakter *out-of-vocabulary*).
- Pembagian Data: Rasio 80/10/10 (pelatihan/validasi/uji) dengan *stratified sampling* berdasarkan panjang teks.

Dataset ini disimpan dalam format TFRecord dan digunakan untuk melatih model *recognizer* sebelum di-*freeze* untuk integrasi ke dalam arsitektur GAN.

IV.2.3 Dataset Evaluasi Kuantitatif

Evaluasi kuantitatif menggunakan subset dari dataset semi-sintetis yang telah dikonstruksi. Dataset dibagi dengan rasio 70/15/15 menggunakan *seed* deterministik untuk menjamin reproduktibilitas:

- Pelatihan: 3.317 pasangan citra (70%)
- Validasi: 710 pasangan citra (15%)
- Pengujian: 712 pasangan citra (15%)

Keselarasan piksel sempurna antara citra terdegradasi dan *ground truth* memungkinkan perhitungan metrik objektif (PSNR, SSIM) yang akurat. Transkripsi yang menyertai setiap pasangan memungkinkan evaluasi CER terhadap prediksi HTR.

IV.2.4 Dataset Evaluasi Kualitatif

Untuk menguji kemampuan generalisasi model pada kondisi dunia nyata, sejumlah dokumen representatif dari koleksi ANRI digunakan sebagai set evaluasi kualitatif. Sebanyak 15 dokumen halaman penuh dari era VOC dan Hindia Belanda (1650–1800) dipilih secara manual berdasarkan kriteria:

- a. Variasi Degradasi: Mencakup spektrum kerusakan dari ringan hingga parah.
- b. Jenis Kerusakan: Meliputi penuaan kertas, noda organik, *foxing*, tinta luntur, *bleed-through*, dan kerusakan fisik.
- c. Karakteristik Paleografi: Merepresentasikan berbagai gaya tulisan tangan dan tingkat kompleksitas ligatur.

Karena tidak memiliki *ground truth* visual (citra bersih), evaluasi pada dataset ini dilakukan secara kualitatif melalui inspeksi visual dan validasi keterbacaan oleh ahli paleografi. Pendekatan ini memvalidasi kemampuan generalisasi model terhadap degradasi autentik yang tidak dapat sepenuhnya direplikasi melalui sintesis komputasional.

IV.3 Strategi dan Protokol Pelatihan

Pelatihan kerangka kerja GAN-HTR menghadapi tantangan unik yang tidak dijumpai pada pelatihan GAN konvensional. Kombinasi lima komponen *loss* dengan magnitudo berbeda, integrasi *frozen recognizer* untuk gradien sadar-HTR, serta arsitektur diskriminator *dual-modal* memerlukan strategi pelatihan yang dirancang secara khusus untuk menjamin stabilitas konvergensi. Bagian ini menguraikan protokol pelatihan yang dikembangkan untuk mengatasi tantangan-tantangan tersebut.

Pembahasan dimulai dengan strategi *curriculum learning* tiga fase yang memperkenalkan komponen *loss* secara bertahap untuk mencegah *mode collapse* dini (IV.3.1). Selanjutnya, dibahas mekanisme regularisasi dan analisis stabilitas yang memvalidasi efektivitas protokol pelatihan (IV.3.2). Bagian ini ditutup dengan spesifikasi teknis implementasi, termasuk kebijakan presisi numerik dan konfigurasi mode diskriminator.

IV.3.1 Curriculum Learning dan Protokol Optimisasi

Strategi pelatihan GAN-HTR terdiri atas dua dimensi yang saling melengkapi: (1) *curriculum learning* yang mengatur evolusi bobot *loss* antar-epoch, dan (2) prosedur pelatihan *adversarial* yang mengatur pembaruan model dalam setiap iterasi. Kedua dimensi ini bekerja secara simultan untuk menjamin stabilitas konvergensi.

1. Dimensi Temporal: Tiga Fase *Curriculum Learning*

Pelatihan menggunakan pendekatan *curriculum learning* Bengio dkk. (2009) tiga fase yang memperkenalkan komponen *loss* secara bertahap. Strategi ini mencegah *mode collapse* dan memungkinkan generator membangun kapabilitas secara inkremental:

- Fase *Warmup* Visual (epoch 1–10): Pelatihan eksklusif pada kualitas visual tanpa supervisi teks, memungkinkan generator membangun kemampuan rekonstruksi dasar. Fase ini mencegah *mode collapse* dini yang dapat terjadi jika *loss* CTC diperkenalkan terlalu awal. Pada fase ini, hanya komponen *loss* visual yang diaktifkan: $\mathcal{L}_{\text{pixel}}$, $\mathcal{L}_{\text{adv}}$, dan $\mathcal{L}_{\text{perc}}$ dengan bobot penuh sesuai Tabel IV.2, sementara $\lambda_{\text{ctc}} = 0$ untuk stabilitas awal.
- Fase Peningkatan Bertahap CTC (epoch 11–30): Peningkatan bertahap bobot CTC dari nol ke bobot penuh secara linear. Integrasi halus ini memungkinkan generator beradaptasi dengan gradien HTR tanpa mengganggu kestabilan pelatihan *adversarial* yang sudah terbentuk. Bobot CTC ditingkatkan secara linear: $\lambda_{\text{ctc}}(e) = 0,15 \times \frac{e-10}{20}$ untuk epoch $e \in [11, 30]$, mencapai nilai maksimal 0,15 pada epoch 30.
- Fase Pelatihan Penuh (epoch 31–50): Pelatihan dengan semua komponen *loss* aktif pada bobot optimal (Tabel IV.2), disertai penyeimbangan adaptif untuk menjaga keseimbangan dinamis antara *loss* visual dan tekstual. Mekanisme penyeimbangan memantau rasio kontribusi setiap komponen dan melakukan penyesuaian minor ($\pm 5\%$) jika terjadi dominasi berlebihan dari satu komponen.

Tabel IV.3 merangkum konfigurasi ketiga fase beserta fokus optimasi masing-masing.

Tabel IV.3 Protokol *curriculum learning* tiga fase: warmup visual, peningkatan bertahap CTC, pelatihan penuh.

Fase	Epoch	λ_{CTC}	Fokus
<i>Warmup</i> Visual	1–10	0,0	Struktur visual dasar, stabilitas adversarial
Peningkatan Bertahap	11–30	$0 \rightarrow 0,15$	Adaptasi gradien HTR secara halus
Pelatihan Penuh	31–50	0,15	Optimasi penuh semua komponen

2. Penyeimbangan Bobot Adaptif

Pada fase pelatihan penuh (epoch 31–50), sistem mengaktifkan mekanisme *adaptive loss balancing* yang secara otomatis menyesuaikan bobot setiap komponen *loss* berdasarkan magnitudo relatifnya. Mekanisme ini bertujuan menjaga keseimbangan antara komponen visual dan HTR dengan target rasio CTC 40% dan visual 60%. Algoritma penyeimbangan memantau kontribusi relatif setiap komponen *loss* pada

setiap iterasi dan melakukan penyesuaian halus dengan *adaptation rate* 0,08 untuk mencegah dominasi berlebihan dari satu komponen yang dapat merusak optimasi multiobjektif.

3. Dimensi Iterasi: Prosedur Pelatihan *Adversarial* Bergantian

Dalam setiap fase *curriculum* di atas, pembaruan model dilakukan melalui prosedur pelatihan *adversarial* bergantian. Prosedur ini menentukan bagaimana generator dan diskriminator diperbarui secara bergantian pada setiap iterasi (*batch*):

- a. Langkah Diskriminator: Perbarui D untuk memaksimalkan kemampuan membedakan pasangan nyata (I_{gt}, teks_{gt}) dari pasangan palsu ($I_{gen}, \text{teks}_{pred}$) dengan supervisi simultan pada domain visual dan tekstual. Diskriminator dilatih dengan *loss binary cross-entropy* yang mengoptimalkan deteksi autentisitas pada kedua modalitas secara bersamaan.
- b. Langkah Generator: Perbarui G untuk meminimalkan $\mathcal{L}_{total}$ (kombinasi lima komponen *loss*, Persamaan IV.17), menghasilkan citra yang secara simultan menipu diskriminator dan mengoptimalkan keterbacaan HTR. Generator menerima gradien dari diskriminator (untuk realisme visual), pengenalan beku (untuk keterbacaan teks), dan *loss* rekonstruksi langsung.

Pembaruan dilakukan dengan rasio seimbang 1:1, memastikan stabilitas pelatihan *adversarial*. Setiap iterasi pelatihan melakukan satu pembaruan diskriminator diikuti satu pembaruan generator untuk mencegah ketidakseimbangan yang dapat menyebabkan *mode collapse* atau dominasi salah satu komponen.

4. Konfigurasi Hyperparameter Pelatihan

Konfigurasi pelatihan didasarkan pada penyetelan empiris untuk stabilitas GAN dan konvergensi optimal:

- a. Optimisasi: Generator menggunakan algoritma Adam dengan parameter momentum disesuaikan ($\beta_1 = 0,5, \beta_2 = 0,999$) untuk stabilitas GAN, sementara diskriminator menggunakan SGD dengan momentum = 0,9 untuk mencegah *mode collapse* dan memastikan konvergensi stabil. Kedua model menerapkan *gradient clipping* dengan norma global = 1,0 untuk mencegah ledakan gradien.
- b. Laju Pembelajaran: Kedua model menggunakan laju pembelajaran awal yang sama ($\alpha_{init} = 2 \times 10^{-4}$) dengan penjadwalan *cosine annealing* untuk konvergensi halus tanpa penurunan tajam. Laju pembelajaran menurun secara halus mengikuti fungsi *cosine* dari nilai awal ke nilai minimum ($\alpha_{min} = 1 \times 10^{-6}$) selama pelatihan.
- c. Ukuran *Batch* dan Dimensi: Ukuran batch kecil (2 sampel per GPU) dengan dimensi citra lebar ($1024 \times 128 \times 1$ piksel) yang mempertahankan detail goresan

halus pada teks baris tunggal paleografi. Dimensi lebar diperlukan untuk menangkap konteks sekuensial teks baris lengkap.

- d. Penghentian Dini: Diterapkan dengan mekanisme *patience* 25 epoch yang mempertimbangkan fase *curriculum*, memulihkan bobot terbaik berdasarkan metrik gabungan PSNR-CER dengan pembobotan yang memprioritaskan kualitas visual. Kriteria: $\text{Score} = \text{PSNR} - 0,5 \times \text{CER}$ untuk keseimbangan optimal.

IV.3.2 Mekanisme Regularisasi dan Konfigurasi Teknis

Selain strategi *curriculum learning* dan protokol optimasi yang telah diuraikan sebelumnya, keberhasilan pelatihan GAN-HTR bergantung pada mekanisme regularisasi untuk mencegah *overfitting* dan spesifikasi implementasi teknis untuk menjamin reproduktibilitas. Pelatihan arsitektur *deep learning* pada dataset terbatas rentan terhadap risiko *overfitting*. Untuk memitigasi risiko ini, serangkaian teknik regularisasi diterapkan secara strategis:

- a. *Batch Normalization*: Diterapkan di semua lapisan konvolusional dengan momentum = 0,9 dan $\epsilon = 10^{-5}$ untuk stabilitas pelatihan dan mempercepat konvergensi.
- b. *Label Smoothing* Asimetris: Hanya diterapkan pada label nyata ($\epsilon_{\text{smooth}} = 0,1$) untuk mengurangi kepercayaan berlebihan diskriminator.
- c. Koneksi Residual: Diterapkan di diskriminator untuk aliran gradien yang lebih baik, mengatasi masalah *vanishing gradient*.
- d. *Dropout*: Diterapkan pada *classification head* diskriminator ($\text{rate} = 0,1$) dan *embedding layer* teks ($\text{rate} = 0,2$).

Untuk menjamin reproduktibilitas eksperimen, dibawah ini merupakan parameter pelatihan yang digunakan, dijelaskan pada Tabel IV.4.

Tabel IV.4 Spesifikasi implementasi teknis eksperimen pelatihan GAN-HTR.

Parameter	Nilai/Konfigurasi
Optimizer Diskriminator	SGD, momentum = 0,9, $\alpha_{\text{init}} = 2 \times 10^{-4}$
Optimizer Generator	Adam, $\beta_1 = 0,5$, $\beta_2 = 0,999$, $\alpha_{\text{init}} = 2 \times 10^{-4}$
Ukuran Batch	2 sampel/GPU
Dimensi Citra	$1024 \times 128 \times 1$ piksel (<i>width</i> $\times$ <i>height</i> $\times$ <i>channel</i>)
Presisi Numerik	Pure FP32 (tanpa <i>mixed precision</i>)
Early Stopping	<i>Patience</i> = 25 epoch, <i>min delta</i> = 0,05
Gradient Clipping	Norma global = 1,0 (kedua model)
CTC Loss Clipping	Nilai maksimum = 400,0
Seed Reprodutibilitas	42

Model terbaik dipilih berdasarkan metrik gabungan PSNR-CER pada epoch

44. Pelatihan dilanjutkan hingga epoch 50 untuk memverifikasi konvergensi stabil. Terkait mode masukan diskriminator *dual-modal*, penelitian ini mengimplementasikan *Predicted Mode* yang menggunakan prediksi dari *frozen recognizer* sebagai masukan cabang teks. Mode ini dipilih karena lebih realistis untuk skenario penerapan (*deployment*) ketika *ground truth* tidak tersedia, serta memberikan gradien yang lebih konsisten dengan kondisi inferensi aktual. Kebijakan presisi *pure FP32* diimplementasikan untuk stabilitas kalkulasi *loss* CTC yang sensitif terhadap *underflow*, dengan *trade-off* waktu pelatihan $\sim 28\%$ lebih lambat dibanding FP16.

Validasi empiris terhadap stabilitas pelatihan dan konvergensi dibahas pada Bab V Subbab V.2.2.

IV.4 Konfigurasi Evaluasi

Evaluasi *framework* GAN-HTR dilakukan melalui tiga pendekatan: (1) perbandingan dengan metode *baseline* klasik, (2) studi ablasi untuk validasi komponen, dan (3) pengukuran metrik multi-objektif untuk kualitas visual dan keterbacaan teks.

IV.4.1 Metode Klasik untuk Perbandingan Kuantitatif

Metode klasik dipilih sebagai *baseline* kuantitatif karena dapat diimplementasi ulang pada dataset identik tanpa memerlukan pelatihan ulang, sehingga memungkinkan perbandingan yang adil dan reproduktibel. Tabel IV.5 merangkum tiga metode *baseline* yang digunakan beserta konfigurasinya.

Tabel IV.5 Ringkasan metode *baseline* klasik untuk perbandingan kuantitatif.

Metode	Implementasi	Konfigurasi
Tanpa Perbaikan	Input langsung	Normalisasi $[0,1]$, citra <i>grayscale</i> 1024×128 px
Otsu <i>Thresholding</i>	OpenCV 4.8.1	Gaussian blur 5×5 , threshold otomatis
Sauvola Adaptive	scikit-image 0.21.0	Window $w = 51$ px (optimasi grid search), $k = 0,2$

Tanpa Perbaikan (*Degraded Input*) berfungsi sebagai *upper bound* degradasi untuk mengukur dampak maksimal kerusakan dokumen terhadap kinerja HTR. Otsu *Thresholding* menerapkan binarisasi global berbasis histogram yang umum digunakan untuk pembersihan dokumen sederhana. Sauvola Adaptive *Thresholding* menggunakan binarisasi lokal yang lebih sesuai untuk dokumen dengan pencahayaan tidak seragam; parameter *window* dioptimalkan melalui pencarian kisi pada subset validasi ($n = 100$).

Metode klasik dipilih karena: (1) reproduktibilitas dengan library standar, (2) waktu eksekusi cepat (<1 detik per citra), dan (3) mewakili pendekatan tradisional yang umum digunakan praktisi arsip.

IV.4.2 Studi Ablasi sebagai Validasi Komponen

Untuk memvalidasi kontribusi setiap komponen arsitektur secara sistematis, studi ablasi inkremental dilakukan dengan menambahkan komponen *loss* secara bertahap (hasil evaluasi disajikan pada Bagian V.4.1):

1. Eksperimen 01 (Hanya Piksel): Setara dengan U-Net standar untuk restorasi citra
2. Eksperimen 02 (+*Adversarial*): Setara dengan GAN standar tanpa komponen HTR
3. Eksperimen 03 (+Perseptual): Peningkatan dengan *loss* perseptual berbasis VGG
4. Eksperimen 04 (+CTC): Konfigurasi optimal dengan integrasi HTR
5. Eksperimen 05 (+Fitur Pengenal): Konfigurasi lengkap untuk validasi redundansi komponen

Pendekatan ablasi ini memberikan pemahaman tentang kontribusi relatif setiap komponen dan memvalidasi keputusan desain arsitektural secara empiris. Perbandingan kuantitatif langsung dengan metode *deep learning* terkini (U-Net, DE-GAN, ERB-MultiTask, DocEnTr) tidak dilakukan karena perbedaan dataset pelatihan dan ketiadaan implementasi resmi yang dapat direproduksi, metode tersebut berfungsi sebagai konteks penelitian untuk memposisikan kontribusi yang diusulkan sebagaimana telah dibahas pada Bab II.

IV.4.3 Metrik Evaluasi

Evaluasi multi-objektif memerlukan metrik untuk mengukur kualitas visual dan keterbacaan teks secara simultan. Tabel IV.6 memetakan metrik dengan komponen arsitektur yang divalidasi, sedangkan Tabel IV.7 menyajikan spesifikasi implementasi teknis.

Tabel IV.6 Pemetaan metrik evaluasi dengan komponen arsitektur dan kebutuhan sistem.

Metrik	Aspek Diukur	Komponen Terkait	Kebutuhan
PSNR	Akurasi piksel	Generator ($\mathcal{L}_{\text{pixel}}$)	NFR-1
SSIM	Struktur perseptual	Generator ($\mathcal{L}_{\text{perc}}$)	NFR-1
CER	Keterbacaan karakter	<i>Frozen Recognizer</i> + $\mathcal{L}_{\text{CTC}}$	FR-3, NFR-2
WER	Keterbacaan kata	<i>Frozen Recognizer</i> + $\mathcal{L}_{\text{CTC}}$	FR-3, NFR-2

Tabel IV.7 Spesifikasi implementasi teknis metrik evaluasi.

Metrik	Library	Algoritma	Pra-pemrosesan
PSNR	scikit-image 0.21.0	$10\log_{10}(\text{MAX}^2/\text{MSE})$	float32 [0, 1]
SSIM	scikit-image 0.21.0	Gaussian weighted	grayscale [0, 1]
CER	editdistance 0.6.2	Levenshtein distance	CTC greedy, lowercase
WER	editdistance 0.6.2	Levenshtein distance	Tokenisasi kata

1. Formula Matematika Metrik

Metrik kualitas visual PSNR (*Peak Signal-to-Noise Ratio*) mengukur rasio antara nilai maksimum sinyal dan derau rekonstruksi:

$$\text{PSNR} = 10\log_{10}\left(\frac{\text{MAX}^2}{\text{MSE}}\right) \quad (\text{IV.23})$$

dengan $\text{MAX} = 1,0$ untuk citra ternormalisasi [0, 1], dan MSE merupakan *Mean Squared Error*.

Metrik SSIM (*Structural Similarity Index*) mengukur kesamaan struktural antara dua citra berdasarkan luminansi, kontras, dan struktur:

$$\text{SSIM}(I_1, I_2) = \frac{(2\mu_1\mu_2 + C_1)(2\sigma_{12} + C_2)}{(\mu_1^2 + \mu_2^2 + C_1)(\sigma_1^2 + \sigma_2^2 + C_2)} \quad (\text{IV.24})$$

dengan μ_1, μ_2 adalah rata-rata lokal; σ_1, σ_2 adalah variansi lokal; σ_{12} adalah kovariansi; dan C_1, C_2 adalah konstanta stabilisasi.

Metrik keterbacaan CER (*Character Error Rate*) dan WER (*Word Error Rate*) mengukur tingkat kesalahan pengenalan teks menggunakan algoritma *Levenshtein distance*:

$$\text{CER} = \frac{\text{EditDistance}(t_{\text{gt}}, t_{\text{pred}})}{|t_{\text{gt}}|} \times 100\% \quad (\text{IV.25})$$

$$\text{WER} = \frac{\text{EditDistance}(w_{\text{gt}}, w_{\text{pred}})}{|w_{\text{gt}}|} \times 100\% \quad (\text{IV.26})$$

dengan $t_{\text{gt}}, w_{\text{gt}}$ adalah teks/kata *ground truth*, $t_{\text{pred}}, w_{\text{pred}}$ adalah hasil prediksi, dan $|\cdot|$ menunjukkan panjang karakter atau jumlah kata.

2. Metrik Peningkatan Relatif

Selain metrik absolut, penelitian ini menggunakan metrik peningkatan relatif untuk mengukur efektivitas restorasi secara ternormalisasi terhadap kondisi awal dokumen terdegradasi:

$$\text{Improvement} = \frac{M_{\text{degraded}} - M_{\text{restored}}}{M_{\text{degraded}}} \times 100\% \quad (\text{IV.27})$$

dengan M_{degraded} adalah nilai metrik (CER/WER) pada citra terdegradasi dan M_{restored} adalah nilai pada citra hasil restorasi. Nilai positif menunjukkan penurunan tingkat kesalahan, dengan nilai lebih tinggi mengindikasikan efektivitas restorasi yang lebih besar.

Bab V Hasil dan Pembahasan

V.1 Pendahuluan

Bab ini menyajikan hasil evaluasi kerangka kerja restorasi dokumen berbasis GAN dengan diskriminator dual-modal dan strategi *frozen recognizer* yang dirancang dan diimplementasikan pada bab sebelumnya. Evaluasi dilakukan untuk menjawab pertanyaan penelitian yang dirumuskan pada Bab I, khususnya terkait dengan kemampuan kerangka kerja yang diusulkan dalam mengatasi kesenjangan antara optimasi visual dan keterbacaan teks.

Pembahasan dalam bab ini diorganisasikan sebagai berikut. Pertama, hasil kuantitatif yang menyajikan pengukuran kinerja model menggunakan metrik standar untuk kualitas visual (PSNR dan SSIM) serta metrik keterbacaan teks (CER dan WER). Kedua, evaluasi kualitatif pada dokumen historis nyata yang memperkuat temuan kuantitatif melalui visualisasi dan penilaian ahli. Ketiga, studi ablasi yang mengisolasi dan mengukur kontribusi dari setiap komponen yang diusulkan (diskriminator dual-modal, *frozen recognizer*, *curriculum learning*, dan konfigurasi fungsi *loss*). Keempat, pengujian hipotesis untuk memvalidasi signifikansi hasil secara formal. Kelima, posisi penelitian terhadap pustaka terkini untuk mengontekstualisasikan temuan dalam lanskap penelitian yang lebih luas. Terakhir, pembahasan yang menginterpretasikan temuan utama dan mengidentifikasi keterbatasan penelitian.

Organisasi pembahasan ini dirancang untuk memberikan pemahaman menyeluruh mengenai efektivitas kerangka kerja yang diusulkan, mulai dari bukti empiris kuantitatif, validasi visual, hingga identifikasi kontribusi spesifik dari setiap komponen yang diajukan dalam penelitian ini.

V.2 Hasil Kuantitatif pada Set Uji Semi-Sintetis Realistik

Bagian ini menyajikan hasil evaluasi kuantitatif model restorasi pada *set* uji semi-sintetis realistis. Pembahasan dibagi menjadi tiga subbagian yang saling melengkapi. Pertama, performa model pada *set* uji menyajikan metrik akhir restorasi (PSNR, SSIM, CER, WER) dan membandingkannya dengan metode *baseline*. Kedua, perkembangan metrik pelatihan menjelaskan bagaimana model mencapai performa tersebut melalui analisis dinamika metrik selama 50 *epoch*. Ketiga, analisis korelasi tingkat degradasi mengkuantifikasi hubungan antara kondisi citra masukan dan efektivitas restorasi.

V.2.1 Performa Model pada Set Uji

Tabel V.1 menyajikan hasil kuantitatif dari evaluasi model pada *set* uji yang sama ($n=712$). Evaluasi mencakup lima metrik utama: PSNR untuk kualitas visual piksel,

SSIM untuk kesamaan struktural, *F-measure* untuk akurasi binarisasi, serta CER dan WER untuk keterbacaan teks.

Tabel V.1 Hasil Kuantitatif pada Set Uji Semi-Sintetis Realistik

Metode	PSNR (dB) ↑	SSIM ↑	<i>F-measure</i> ↑	CER (%)	WER (%)
Tanpa Perbaikan	7,91±1,01	0,340±0,077	- ^a	83,4±18,5 ↓	98,7±7,3 ↓
Otsu <i>Thresholding</i>	4,75±2,00	0,261±0,099	0,748±0,085	85,7±56,7 ↓	112,9±69,5 ↓
Sauvola Adaptif	9,92±1,99	0,437±0,149	0,933±0,030	109,5±179,5 ↓	171,5±172,2 ↓
Yang Diusulkan	30,74±5,09	0,987±0,014	0,921±0,067	34,9±21,8 ↓	82,4±26,1 ↓
Batas Atas (<i>GT Bersih</i>)	-	-	-	34,1±22,7	82,1±27,3

^a*F-measure* tidak dapat diterapkan pada citra terdegradasi tanpa binarisasi.

Metode klasik menggunakan implementasi OpenCV standar dengan parameter global tetap ($k = 0.34, R = 128$).


Varians tinggi pada metode klasik mencerminkan sensitivitas terhadap parameter pada *dataset* heterogen.

WER > 100% disebabkan oleh tingginya *insertion error* akibat derau latar belakang yang terdeteksi sebagai karakter.


Hasil kuantitatif pada Tabel V.1 menunjukkan keunggulan signifikan metode yang diusulkan dalam menangani variabilitas degradasi. Metode usulan mencapai PSNR 30,74±5,09 dB dan CER 34,9±21,8%, mendekati batas atas teoretis citra bersih.

Sebaliknya, metode klasik menunjukkan keterbatasan signifikan dalam skenario parameter tunggal untuk seluruh sampel. Varians yang sangat tinggi pada Sauvola (CER $\sigma=179,5$) dan nilai WER yang melebihi 100% (171,5%) mengindikasikan terjadinya kegagalan total pada sebagian sampel; pada kondisi tersebut, sistem HTR mengenali derau latar belakang (*foxing*, *bleed-through*) sebagai teks tambahan (*insertion errors*). Hal ini bukan berarti metode klasik tidak valid, melainkan menegaskan bahwa metode berbasis aturan sangat sensitif terhadap penyetelan parameter. Tanpa penyetelan manual per-citra (yang tidak praktis untuk volume arsip besar), metode klasik gagal beradaptasi dengan heterogenitas degradasi dokumen paleografi. Metode pembelajaran mendalam yang diusulkan, di sisi lain, menunjukkan kehandalan yang jauh lebih baik ($\sigma=21,8$) karena kemampuannya mempelajari fitur degradasi secara adaptif. Gambar V.1 memvisualisasikan distribusi keempat metrik, sedangkan Gambar V.2 mengkuantifikasi besaran peningkatan relatif.

Gambar V.3 memvisualisasikan perbandingan kualitatif pada dua sampel terbaik, menunjukkan tiga keunggulan metode yang diusulkan: (1) menjaga kelancaran goresan, yaitu kontinuitas karakter tetap utuh tanpa fragmentasi yang terlihat pada metode binarisasi (CER rata-rata 13,2% berbanding Otsu/Sauvola 63,2–64,7%); (2) pembersihan selektif, yaitu eliminasi *foxing* dan noda penuaan tanpa merusak detail teks; (3) keselarasan antara kualitas visual dan keterbacaan, yaitu SSIM tinggi (0,990) berkorelasi dengan CER rendah, memvalidasi efektivitas optimasi dual-objektif. Metode klasik dengan parameter tetap kurang efektif karena ambang adaptif global



Gambar V.1 Distribusi metrik restorasi pada *set* uji dengan interval kepercayaan 95%: (a) PSNR, (b) SSIM, (c) CER, (d) WER. Metode usulan mencapai performa mendekati performa HTR pada citra bersih tanpa degradasi.



Gambar V.2 Peningkatan metrik dari kondisi terdegradasi ke hasil restorasi: (a) peningkatan absolut, (b) peningkatan relatif (%). CER menunjukkan pengurangan 58,2% (83,4% → 34,9%).

sulit mengakomodasi variasi degradasi lokal yang ekstrem pada dokumen paleografi. Untuk memberikan gambaran yang jelas mengenai berbagai nilai CER yang digunakan dalam penelitian ini, Tabel V.2 merangkum tiga kategori *baseline*: (1) performa *recognizer* pada citra bersih, (2) *input* terdegradasi tanpa restorasi, dan (3) hasil setelah restorasi.

Perbedaan CER antara *set* validasi dan uji ($\Delta=7,53$ poin persentase pada citra bersih,



Gambar V.3 Evaluasi kualitatif pada sampel optimal (PSNR > 30 dB, CER < 15%): (1) citra terdegradasi, (2) Otsu, (3) Sauvola, (4) metode usulan, (5) *ground truth*. Metode usulan mempertahankan detail goresan dan ligatur paleografi.

Tabel V.2 Ringkasan metrik CER pada berbagai kondisi: *baseline recognizer*, *input terdegradasi*, dan hasil restorasi.


Kondisi	Dataset	<i>n</i>	CER (%)
<i>Baseline Recognizer pada Citra Bersih (Ground Truth)</i>			
CER _{pretrain}	ANRI validasi awal	948	33,72
CER _{val-GT}	Validasi GT penelitian	710	26,57
CER _{test-GT}	Uji GT penelitian	712	34,1
<i>Input Terdegradasi (Tanpa Restorasi)</i>			
CER _{degraded}	Validasi & Uji	1422	83,4
<i>Hasil Restorasi Metode Usulan</i>			
CER _{val-restored}	Validasi	710	27,11
CER _{test-restored}	Uji	712	34,9
<i>Peningkatan Relatif</i>			
Validasi	83,4% → 27,11%	—	67,5%
Uji	83,4% → 34,9%	—	58,2%

$\Delta=7,79$ poin persentase pada hasil restorasi) mencerminkan variasi kompleksitas paleografi antardataset (bukan *overfitting*), yang dikonfirmasi oleh konsistensi rasio peningkatan (67,5% berbanding 58,2%).

V.2.2 Perkembangan Metrik Pelatihan

Subbagian sebelumnya menyajikan hasil akhir restorasi pada *set* uji. Subbagian ini menjelaskan *bagaimana* model mencapai performa tersebut dengan menganalisis perkembangan metrik validasi selama 50 *epoch* pelatihan. Analisis ini penting untuk memastikan dua hal: (1) konvergensi berjalan stabil tanpa osilasi berlebihan, dan (2) model tidak mengalami *overfitting* pada data pelatihan.

Gambar V.4 menyajikan perkembangan empat metrik validasi (PSNR, SSIM, CER, dan WER) dengan interval kepercayaan 95% yang menunjukkan keandalan statistik pengukuran.




Gambar V.4 Perkembangan metrik validasi selama 50 *epoch* dengan interval kepercayaan 95%: (a) PSNR, (b) SSIM, (c) CER, (d) WER. Model terbaik dipilih pada *epoch* 44 (bintang merah) berdasarkan kriteria gabungan PSNR-CER.

Terkait konvergensi metrik visual, proses pelatihan mengikuti strategi *curriculum learning* tiga fase yang dirancang pada Bab III.

Fase pertama (*epoch* 1–10) memfokuskan model pada rekonstruksi visual dasar tanpa penalti HTR, menghasilkan peningkatan PSNR yang cepat dari nilai awal. Fase kedua (*epoch* 11–30) secara bertahap mengaktifkan komponen CTC *loss* untuk menyelaraskan optimasi visual dengan keterbacaan teks. Pada fase ini, target kualitas visual tercapai: SSIM melampaui 0,95 pada *epoch* 22 dan PSNR mencapai 30,0 dB pada *epoch* 38. Fase ketiga (*epoch* 31–50) mempertahankan bobot penuh untuk konvergensi akhir.

Dari sisi stabilitas pelatihan, interval kepercayaan yang sempit ($\pm 0,42$ dB untuk

**Comprehensive Degradation Severity vs Restoration Quality Analysis
(Production V3 Best Model - Epoch 44)**



Gambar V.5 Analisis korelasi pada *set* validasi: (a) SNR berbanding peningkatan CER ($r = -0,963$), (b) PSNR berbanding CER pasca-restorasi, (c) SSIM berbanding CER, (d) korelasi CER sebelum-sesudah.

PSNR dan $\pm 0,001$ untuk SSIM pada model terbaik) menunjukkan bahwa model mempelajari pola restorasi yang konsisten. Stabilitas ini penting untuk aplikasi praktis karena menjamin konsistensi performa.

Untuk pemilihan model terbaik, model optimal dipilih pada *epoch* 44 (bukan *epoch* terakhir) berdasarkan kriteria gabungan PSNR-CER. Protokol *early stopping* dengan toleransi 25 *epoch* tanpa perbaikan diterapkan untuk mencegah *overfitting* yang mungkin terjadi pada fase akhir pelatihan.

Secara keseluruhan, analisis perkembangan metrik mengonfirmasi keberhasilan desain strategi pelatihan: konvergensi bertahap melalui tiga fase memfasilitasi optimasi yang stabil, dan mekanisme *early stopping* mencegah degradasi performa.

V.2.3 Analisis Korelasi Tingkat Degradasi

Untuk memahami hubungan antara tingkat degradasi dokumen dan efektivitas restorasi, dilakukan analisis korelasi menggunakan *set* validasi ($n=710$ sampel). Analisis ini menjawab pertanyaan penelitian kunci: “Apakah restorasi lebih efektif untuk dokumen dengan degradasi berat atau ringan?” Gambar V.5 menyajikan empat panel korelasi yang memvisualisasikan hubungan ini.

Berikut adalah temuan korelasi dari analisis tersebut:

1. SNR terhadap Peningkatan CER (Panel a)

- a) Korelasi negatif sangat kuat: Pearson's $r = -0,963$, $R^2 = 0,927$, $p < 0,001$
- b) Interpretasi: dokumen dengan SNR rendah (degradasi berat) mengalami penurunan CER yang lebih besar dibanding dokumen dengan SNR tinggi (degradasi ringan)
- c) Implikasi praktis: model menunjukkan efektivitas lebih tinggi untuk dokumen historis yang sangat terdegradasi
- d) Validasi empiris: korelasi kuat ($R^2 > 0,9$) mengonfirmasi bahwa tingkat degradasi awal merupakan prediktor signifikan untuk manfaat restorasi

2. PSNR terhadap CER Terestorasi (Panel b)

- a) Korelasi lemah: Pearson's r mendekati nol
- b) Interpretasi: setelah restorasi, PSNR tidak berkorelasi kuat dengan CER, mengindikasikan bahwa peningkatan kualitas visual tidak secara otomatis menjamin peningkatan akurasi pengenalan teks
- c) Implikasi praktis: model menyeragamkan performa HTR terlepas dari tingkat degradasi awal

3. SSIM terhadap CER (Panel c)

- a) Korelasi lemah teramati antara SSIM dan CER, mengindikasikan SSIM saja tidak cukup untuk memprediksi akurasi HTR
- b) Implikasi: justifikasi untuk evaluasi multimetrik (PSNR + SSIM + CER) daripada mengandalkan metrik tunggal

4. CER Sebelum berbanding Sesudah (Panel d)

- a) Mayoritas sampel terletak di bawah garis diagonal ($y=x$), mengonfirmasi bahwa restorasi umumnya meningkatkan atau mempertahankan akurasi HTR
- b) Distribusi poin menunjukkan manfaat konsisten pada spektrum tingkat degradasi

Terkait implikasi untuk digitalisasi, berdasarkan analisis korelasi: (1) arsip dapat memprioritaskan dokumen dengan degradasi berat untuk restorasi karena peningkatan akurasi lebih besar; (2) restorasi tetap bermanfaat untuk normalisasi kualitas pada degradasi ringan; (3) PSNR/SSIM berguna untuk pemantauan visual, tetapi CER/WER esensial untuk validasi efektivitas berorientasi HTR.

V.3 Hasil Kualitatif pada Dokumen Historis Nyata

Bagian sebelumnya mengevaluasi model pada data semi-sintetis dengan *ground truth* yang tersedia. Bagian ini melengkapi evaluasi tersebut dengan menguji model

pada dokumen ANRI autentik, yaitu dokumen historis nyata tanpa *ground truth*, untuk memvalidasi kemampuan generalisasi ke kondisi degradasi di luar distribusi pelatihan.

Pembahasan diorganisasikan dalam subbagian berikut: (1) karakteristik *dataset* dan prosedur inferensi menjelaskan dokumen uji; (2) hasil kualitatif dan observasi menyajikan temuan visual berdasarkan tingkat kontras; (3) evaluasi oleh ahli paleografi memberikan validasi independen dari pakar domain; (4) analisis kesenjangan domain dan keterbatasan evaluasi mengidentifikasi perbedaan antara data pelatihan dan dokumen nyata serta keterbatasan yang perlu dicatat; dan (5) kesimpulan evaluasi kualitatif merangkum temuan keseluruhan.

V.3.1 *Dataset dan Protokol Evaluasi Kualitatif*

Dataset evaluasi kualitatif terdiri dari 15 dokumen halaman penuh dari koleksi ANRI. Tabel V.3 merangkum karakteristik teknis dan jenis degradasi yang terdapat pada dokumen uji.

Tabel V.3 Karakteristik *dataset* evaluasi kualitatif ANRI

Aspek	Deskripsi
Jumlah dokumen	15 halaman penuh
Periode	1650–1800 (era VOC dan Hindia Belanda)
Resolusi	300 DPI (hasil pemindaian arsip)
Orientasi	Potret
<i>Jenis Degradasi Autentik</i>	
Penuaan kertas	Diskolorasi kuning/coklat intensitas tinggi
<i>Foxing</i>	Bercak kecoklatan dari <i>fungi</i> dan oksidasi selulosa
<i>Bleed-through</i>	Transparansi tinta dari halaman <i>verso</i>
Korosi tinta	Artefak <i>iron gall</i> dengan halo gelap
<i>Distribusi Kondisi</i>	
Degradasi parah	2 dokumen (13,3%)
Degradasi sedang	8 dokumen (53,3%)
Degradasi ringan-sedang	5 dokumen (33,3%)

1. Protokol Inferensi

Setiap dokumen diproses menggunakan *checkpoint* model dengan performa validasi terbaik. Mengingat dokumen ANRI memiliki orientasi potret dengan rasio aspek $< 1,5$, diterapkan strategi *adaptive tiling* bertingkat sebagai berikut:

- Segmentasi vertikal: Dokumen potret dibagi menjadi 2–3 kolom vertikal dengan *overlap* 25% untuk menghindari artefak batas.
- Segmentasi horizontal: Setiap kolom dipotong menjadi strip horizontal dengan target rasio aspek 6:1 (mendekati rasio pelatihan 8:1) dan *overlap* 15%.
- Pemrosesan *tile*: Setiap strip dinormalisasi ke rentang $[-1, 1]$ sesuai *pipeline*

pelatihan, diproses melalui generator, lalu dikonversi kembali ke $[0, 255]$.

- d. *Blending Gaussian*: Strip hasil restorasi digabungkan menggunakan *windowing Gaussian* untuk transisi mulus antar-*tile*.
- e. *Post-processing* (opsional): Tahap ini bersifat tidak mandatori dan dapat diterapkan sesuai kebutuhan, mencakup CLAHE (*Contrast Limited Adaptive Histogram Equalization*), operasi morfologi penutupan untuk konektivitas goresan, dan *unsharp masking* untuk ketajaman tepi.

2. Protokol Evaluasi Visual

Keluaran disimpan dalam format TIFF tanpa kompresi sesuai standar preservasi arsip digital. Evaluasi visual dilakukan melalui perbandingan langsung *side-by-side* antara citra masukan terdegradasi dan keluaran terestorasi berdasarkan lima kriteria:

- a. Pembersihan latar : Efektivitas penghapusan artefak degradasi tanpa merusak area teks.
- b. Kejelasan teks: Tingkat keterbacaan karakter setelah restorasi.
- c. Keberadaan artefak: Kemunculan artefak baru akibat proses restorasi (*hallucination, ringing*).
- d. Pelestarian goresan: Keutuhan karakteristik paleografi (ketebalan, kemiringan, ornamen).
- e. Kegunaan keseluruhan: Penilaian holistik kesiapan dokumen untuk transkripsi manual atau HTR.

V.3.2 Hasil Kualitatif dan Observasi

Subbagian ini menyajikan hasil restorasi pada dokumen ANRI autentik secara visual, diikuti dengan observasi sistematis berdasarkan kategori tingkat kontras. Penilaian dilakukan melalui perbandingan langsung antara citra masukan terdegradasi dan keluaran terestorasi untuk mengidentifikasi pola kekuatan dan keterbatasan model. Gambar V.6 menampilkan enam contoh representatif dari 15 dokumen yang diuji. Analisis visual mengungkapkan pola performa yang konsisten dengan karakteristik degradasi pada citra masukan.

Analisis visual 15 dokumen ANRI menunjukkan tiga pola performa utama berdasarkan tingkat kontras citra masukan (detail distribusi pada Tabel V.6):

1. Tinggi (≥ 60): pembersihan latar optimal dengan eliminasi *foxing* dan noda penuaan secara efektif, pelestarian morfologi karakter tanpa artefak, dan penghilangan *bleed-through* dengan preservasi teks *recto* yang baik.
2. Sedang (30–60): sukses parsial dengan reduksi derau substansial namun artefak residual pada wilayah *bleed-through* berat; peningkatan keterbacaan lebih konservatif untuk menghindari pembuatan teks palsu.



Gambar V.6 Hasil restorasi pada dokumen ANRI autentik: (kiri) masukan terdegradasi, (kanan) keluaran terestorasi. Baris 1 (a–b): sukses optimal pada kontras tinggi. Baris 2 (c–d): sukses tinggi hingga parsial pada kontras sedang. Baris 3 (e–f): kegagalan pada kontras sangat rendah dengan degradasi ekstrem.

3. Rendah (<30): peningkatan terbatas dengan strategi konservatif menghindari pembangkitan artefak palsu, mempertahankan autentisitas paleografi meskipun peningkatan visual minimal.

Meskipun model menunjukkan performa baik pada mayoritas dokumen ANRI, beberapa keterbatasan teridentifikasi:

1. Pemudaran ekstrem: dokumen dengan kontras <20 (1/15, 6,7%) mendapat peningkatan minimal karena distribusi kontras *dataset* pelatihan semi-sintetis berbeda.
2. Variansi *bleed-through*: pola *bleed-through* dunia nyata dengan tata letak halaman *verso* kompleks lebih sulit ditangani dibanding augmentasi semi-sintetis,

menghasilkan sukses parsial pada 4/15 kasus (26,7%).

3. Artefak tinta *iron gall*: degradasi kimiawi historis tidak sepenuhnya tercakup dalam pelatihan, menyebabkan *over-suppression* pada 2/15 dokumen (13,3%).

Hasil evaluasi dokumen riil ANRI memberikan indikasi awal bahwa model dapat menggeneralisasi ke dokumen historis nyata dengan karakteristik degradasi yang tumpang tindih dengan distribusi pelatihan (kontras ≥ 30 , penuaan sedang hingga berat). Untuk kasus ekstrem di luar domain pelatihan, strategi konservatif model menghindari kegagalan katastrofik seperti halusinasi; pendekatan ini sesuai dengan prinsip preservasi arsip.

V.3.3 Evaluasi Ahli Paleografi

Untuk melengkapi analisis visual sebelumnya, penelitian ini melakukan evaluasi independen oleh ahli paleografi. Evaluasi ini bertujuan mendapatkan perspektif praktisi lapangan mengenai kualitas restorasi dan kesesuaiannya untuk alur kerja digitisasi arsip. Pembahasan mencakup tiga aspek: (1) prosedur penilaian ahli, (2) hasil dan analisis penilaian, serta (3) kesimpulan evaluasi ahli.

1. Prosedur Penilaian Ahli

Evaluasi ahli melibatkan dua evaluator independen. Penting untuk dicatat bahwa evaluasi bersifat pendahuluan dengan ukuran sampel terbatas ($n = 15$) dan tidak dimaksudkan sebagai validasi statistik konklusif. Tabel V.4 merangkum prosedur yang digunakan.

2. Hasil dan Analisis Penilaian

Tabel V.5 menyajikan hasil penilaian kuantitatif dari dua ahli independen. Skor keseluruhan mencapai 3,42/4,0 dengan reliabilitas antarpemilai yang substansial (Cohen's $\kappa=0,78$), mengindikasikan konsistensi penilaian meskipun ukuran sampel terbatas.

Analisis berdasarkan kategori kontras menunjukkan korelasi kuat antara tingkat kontras dan skor penilaian ahli (lihat Tabel V.6). Pada kategori kontras tinggi, preservasi detail mikroskopis (goresan halus, modulasi tekanan pena) dinilai sangat penting untuk analisis paleografi komparatif. Kategori kontras sedang memperoleh evaluasi positif meskipun terdapat catatan sedikit penghalusan berlebih pada region *bleed-through* berat. Sementara itu, kategori kontras rendah mendapat apresiasi khusus untuk pendekatan konservatif yang menghindari rekonstruksi semu.

Berikut adalah umpan balik kualitatif dari para ahli:

- a) Penilai 1 (ahli paleografi): Restorasi menunjukkan pemahaman implisit terhadap karakteristik skrip Belanda abad ke-17, khususnya preservasi *aspect ratio*

Tabel V.4 Prosedur evaluasi oleh ahli paleografi

Aspek	Deskripsi
<i>Panel Evaluator</i>	
Penilai 1	Ahli paleografi, skrip Belanda abad 16–18, 16 tahun pengalaman
Penilai 2	Ahli restorasi arsip, digitisasi koleksi Hindia Belanda
<i>Protokol Asesmen</i>	
Jenis asesmen	Tertutup (<i>blind</i>), evaluasi independen
Sampel	15 pasangan dokumen (terdegradasi–terestorasi)
Skala	Likert 4 poin (1=Buruk, 4=Sangat Baik)
Reliabilitas	Cohen's κ untuk konsistensi antarpemilai
<i>Kriteria Evaluasi</i>	
Keterbacaan Teks	Kemudahan membaca karakter dan ligatur khas
Autentisitas	Preservasi <i>ductus</i> , tekanan pena, ketebalan goresan
Minimasi Artefak	Tingkat gangguan artefak (skor tinggi = minimal)
Kegunaan	Kesesuaian untuk digitisasi dan transkripsi

Tabel V.5 Penilaian kualitatif ahli paleografi pada dokumen ANRI: skor keterbacaan, preservasi struktur, dan kelayakan transkripsi

Kriteria	Penilai 1	Penilai 2	Rerata
Keterbacaan Teks	3,47	3,33	3,40
Autentisitas Paleografi	3,60	3,53	3,57
Minimasi Artefak (inv.)	3,27	3,13	3,20
Kegunaan Transkripsi	3,53	3,47	3,50
Skor Keseluruhan	3,47	3,37	3,42

Cohen's κ (antarpemilai): $\kappa = 0,78$ (kesepakatan substansial pada sampel ini)

Skala: 1=Buruk, 2=Cukup, 3=Baik, 4=Sangat Baik

95% CI untuk rerata keseluruhan: [3,28, 3,56]

huruf-huruf *Gothic minuscule* dan ligatur khas seperti 'st', 'ct', dan 'ck'. Pada dokumen kontras tinggi, pembersihan *foxing* sangat efektif tanpa mengorbankan detail superfisial seperti *pen lift marks* yang penting untuk analisis autentisitas. Catatan kritik: pada 2–3 kasus sedang, terdapat *slight blur* pada region dengan tinta *iron gall* terkorosi, namun ini tidak mengurangi utilitas untuk transkripsi semantik.

- b) Penilai 2 (ahli restorasi arsip): Dari perspektif arsip digital, keluaran model sangat sesuai untuk digitisasi massal dengan koreksi manual minimal. Reduksi derau

Tabel V.6 Performa restorasi pada dokumen ANRI berdasarkan tingkat kontras dan skor penilaian ahli paleografi

Kategori Kontras	n	% Total	Efektivitas Teramati	Skor Ahli ^d
Tinggi (≥ 60)	5	33,3%	Baik Sekali ^a	3,75/4,0
Sedang (30–60)	8	53,3%	Baik ^b	3,38/4,0
Rendah (< 30)	2	13,3%	Terbatas ^c	2,63/4,0

^aBaik Sekali: pembersihan latar $> 80\%$, artefak minimal

^bBaik: perbaikan substansial, derau residual minor

^cTerbatas: peningkatan konservatif, tanpa halusinasi

^dSkor Ahli: rerata penilaian 2 ahli paleografi independen

latar pada mayoritas dokumen sangat membantu proses OCR/HTR selanjutnya. Apresiasi khusus untuk pendekatan konservatif pada dokumen memudar ekstrem; model tidak melakukan *creative reconstruction* yang dapat menyesatkan interpretasi historis. Untuk alur kerja ANRI, disarankan penggunaan untuk praproses *batch* dengan verifikasi ahli pada kasus kontras < 30 .

- c) *Kesepakatan antarpenilai*: Ketidaksepakatan terbesar terjadi pada kriteria *Minimasi Artefak* untuk dokumen kontras sedang; Penilai 1 lebih toleran terhadap derau residual dibanding Penilai 2 yang memprioritaskan kebersihan untuk otomasi OCR. Namun, kedua penilai sepakat pada urutan relatif dokumen (Spearman's $\rho = 0,91$, $p < 0,001$).

3. Kesimpulan Evaluasi Ahli

Kesimpulannya, evaluasi awal oleh ahli paleografi (Cohen's $\kappa = 0,78$, skor keseluruhan 3,42/4,0) memberikan indikasi positif bahwa model memiliki potensi untuk aplikasi digitisasi arsip, dengan catatan keterbatasan generalisasi akibat ukuran sampel kecil. Aspek yang dinilai menjanjikan meliputi: (1) preservasi arsip digital, yaitu autentisitas fitur paleografi terjaga (3,57/4,0) memungkinkan analisis komparatif skrip dan identifikasi juru tulis; (2) kemudahan akses publik, yaitu peningkatan keterbacaan (3,40/4,0) mengurangi hambatan peneliti nonspesialis; (3) alur kerja semiotomatis, yaitu kegunaan transkripsi (3,50/4,0) mendukung integrasi *pipeline* HTR dengan supervisi minimal. Hasil evaluasi dokumen riil secara keseluruhan memberikan indikasi awal potensi generalisasi model ke dokumen historis nyata dalam rentang distribusi pelatihan, dengan strategi konservatif yang menjaga integritas arsip pada kasus kontras rendah ekstrem.

Tabel V.7 Perbandingan distribusi karakteristik: data pelatihan semi-sintetis berbanding dokumen riil. Analisis kesenjangan domain menjelaskan perbedaan performa kuantitatif dan kualitatif.

Aspek	Semi-Sintetis	Dokumen Riil
Degradasi	<i>Pipeline</i> terkontrol 6 tahap	Penuaan alami 250–450 tahun
Keseragaman	Relatif seragam	Sangat bervariasi
Keparahan	Sedang (15–25 dB)	Ekstrem (<10 dB)
Latar belakang	Tekstur sampel	Kimia kertas menua
Jenis tinta	Simulasi memudar	Korosi <i>iron gall</i>
<i>Ground truth</i>	Data berpasangan	Tanpa referensi

V.3.4 Analisis Kesenjangan Domain dan Keterbatasan Evaluasi

Performa yang konsisten pada dokumen riil menunjukkan bahwa *pipeline* degradasi semi-sintetis realistis berhasil mereplikasi karakteristik degradasi historis yang relevan. Tabel V.7 merangkum perbedaan karakteristik antara data pelatihan dan dokumen nyata.

Beberapa efek kesenjangan domain teramati pada evaluasi:

1. Bias restorasi konservatif: model cenderung melakukan peningkatan kurang optimal pada degradasi ekstrem (PSNR <10 dB) karena distribusi pelatihan tidak mencakup tingkat keparahan setara; namun ini merupakan kompromi yang dapat diterima untuk menghindari halusinasi.
2. Sensitivitas pola latar belakang: dokumen nyata dengan margin dekoratif kompleks atau tepi ornamental terkadang terhapus sebagian karena kebingungan dengan derau (frekuensi: 2/15 dokumen).
3. Variansi kimia tinta *iron gall*: pola korosi kimia berbeda dengan degradasi yang disimulasikan sehingga restorasi hanya parsial; data pelatihan perlu diaugmentasi dengan model degradasi spesifik korosi.

Selain kesenjangan domain, evaluasi pada dokumen riil juga memiliki keterbatasan metodologis inheren:

1. Tidak ada metrik HTR kuantitatif: dokumen riil berusia 250–450 tahun tidak memiliki transkripsi *ground truth* yang andal, sehingga CER/WER tidak dapat diukur secara objektif.

2. Ukuran sampel terbatas: evaluasi dilakukan pada 15 dokumen halaman penuh yang dipilih secara representatif, sehingga bias sampel mungkin ada.
3. Tidak ada pengukuran PSNR/SSIM: dokumen riil tanpa citra referensi bersih menyebabkan penilaian kualitas visual sepenuhnya bergantung pada evaluasi subjektif ahli.

Keterbatasan-keterbatasan ini memperkuat pentingnya menggunakan metrik semi-sintetis pada Bagian V.2 sebagai ukuran pengganti kuantitatif, sambil tetap mengacu pada penilaian ahli sebagai validasi praktis.

V.3.5 Kesimpulan Evaluasi Kualitatif

Meskipun dilatih secara eksklusif pada data berpasangan semi-sintetis, model menunjukkan generalisasi yang wajar ke pola degradasi dunia nyata. Dari 15 dokumen ANRI: 10 dokumen (66,7%) menunjukkan peningkatan signifikan dengan pembersihan latar >70% dan artefak minimal; 3 dokumen (20,0%) menunjukkan peningkatan moderat dengan derau residual yang dapat diterima; dan 2 dokumen (13,3%) dengan degradasi ekstrem (kontras <20) mendapat peningkatan terbatas karena berada di luar domain pelatihan. Secara keseluruhan, 13 dari 15 dokumen (86,7%) mendapat manfaat berguna untuk alur kerja transkripsi.

Penilaian ahli paleografi (skor 3,42/4,0, Cohen's $\kappa=0,78$) memberikan validasi independen terhadap potensi restorasi untuk alur kerja digitisasi arsip. Kesimpulannya, kesenjangan domain sintetis-ke-nyata dapat diatasi melalui desain *pipeline* degradasi yang hati-hati, dan bukti kualitatif ini memberikan dasar yang cukup untuk eksplorasi lebih lanjut dalam aplikasi arsip praktis.

V.4 Studi Ablasi

Bagian sebelumnya telah menunjukkan bahwa kerangka kerja yang diusulkan mencapai keseimbangan antara kualitas visual (PSNR 30,33 dB, SSIM 0,9537) dan keterbacaan teks (CER 27,41%). Namun, kerangka kerja ini terdiri dari beberapa komponen yang saling berinteraksi: fungsi *loss* multikomponen, strategi *frozen recognizer*, diskriminator *dual-modal*, dan *curriculum learning*. Pertanyaan mendasar yang muncul adalah: seberapa besar kontribusi masing-masing komponen terhadap performa keseluruhan?

Studi ablasi pada bagian ini dirancang untuk menjawab pertanyaan tersebut melalui serangkaian eksperimen terkontrol yang mengisolasi dan mengukur dampak setiap komponen secara independen. Sebagaimana telah dirancang pada Bab IV Subbab IV.4, pendekatan ablasi menggunakan metode inkremental, yaitu menambahkan komponen *loss* secara bertahap dari *baseline* hingga konfigurasi lengkap, untuk memahami kontribusi relatif setiap komponen.

Pembahasan diorganisasikan sebagai berikut: (1) ablasi komponen fungsi *loss* mengukur kontribusi inkremental lima komponen (piksel $\rightarrow$ *adversarial* $\rightarrow$ perseptual $\rightarrow$ CTC $\rightarrow$ fitur pengenalan); (2) ablasi strategi *frozen recognizer* membandingkan parameter beku dengan pelatihan bersama; (3) ablasi diskriminator *dual-modal* mengevaluasi arsitektur diskriminator hibrida; (4) ablasi *curriculum learning* menganalisis efek penjadwalan fase pelatihan; dan (5) analisis bobot fungsi *loss* menyajikan distribusi kontribusi efektif dan validasi sensitivitas konfigurasi.

V.4.1 Ablasi Komponen Fungsi Loss

Tabel V.8 menyajikan hasil dari studi ablasi inkremental lima komponen fungsi *loss*. Hasil ini mengukur kontribusi setiap komponen terhadap kualitas restorasi dokumen pada pelatihan 15 *epoch*.

Tabel V.8 Kontribusi inkremental komponen *loss* terhadap kualitas restorasi (15 *epoch*): (1) L1 piksel, (2) +*adversarial*, (3) +perseptual, (4) +CTC, (5) +fitur pengenalan. Komponen CTC memberikan peningkatan CER paling signifikan.

No.	Komponen <i>Loss</i>	PSNR (dB)	SSIM	CER (%)	Δ PSNR
1	$\mathcal{L}_{\text{pixel}}$ (L1)	$24,59 \pm 4,10$	$0,9614 \pm 0,0278$	N/A [†]	(acuan)
2	$\mathcal{L}_{\text{pixel}} + \mathcal{L}_{\text{adv}}$	$24,86^* \pm 4,21$	$0,9626 \pm 0,0279$	N/A [†]	+0,27
3	+ $\mathcal{L}_{\text{perc}}$ (VGG)	$24,55 \pm 4,69$	$0,9630^* \pm 0,0273$	N/A [†]	-0,04
4	+ $\mathcal{L}_{\text{ctc}}$	$24,76 \pm 4,71$	$0,9627 \pm 0,0294$	29,66 [*]	+0,17
5	+ $\mathcal{L}_{\text{rec-feat}}$	$24,75 \pm 4,60$	$0,9629 \pm 0,0312$	30,16	+0,16
[†] CER tidak tersedia karena <i>recognizer</i> tidak diaktifkan					
*Nilai tertinggi untuk metrik ini: PSNR (Eks 2), SSIM (Eks 3), CER (Eks 4)					

Berikut adalah analisis kontribusi per komponen:

1. Piksel L1 (*Baseline*)

Eksperimen pertama menggunakan hanya *loss* L1 sebagai *baseline*, mencapai PSNR 24,59 dB dan SSIM 0,9614. Konfigurasi ini setara dengan U-Net standar tanpa mekanisme *adversarial* dan tanpa kepekaan teks. Nilai ini menjadi acuan untuk mengukur kontribusi inkremental setiap komponen tambahan.

2. *Adversarial Loss*

Memberikan peningkatan PSNR terbesar (+0,27 dB dari *baseline*), mencapai 24,86 dB. Komponen ini meningkatkan realisme tekstur melalui mekanisme pelatihan *adversarial* tanpa mengorbankan stabilitas konvergensi. SSIM juga meningkat (+0,0012), mengindikasikan perbaikan kesamaan struktural.

3. *Perceptual Loss*

Mengoptimalkan kesamaan struktural dengan SSIM tinggi (0,9630), namun dengan sedikit penurunan PSNR sebagai konsekuensi (-0,04 dB menjadi 24,55 dB). Penurunan metrik berbasis piksel ini merupakan konsekuensi yang diharapkan dari optimisasi berbasis fitur (VGG-19); dalam hal ini, ketajaman visual dan konsistensi perseptual diprioritaskan di atas akurasi piksel absolut.

4. *CTC Loss*

Mengaktifkan kapabilitas kepekaan HTR, mencapai CER 29,66% sambil mempertahankan kualitas visual yang kompetitif (PSNR 24,76 dB, hanya -0,10 dB dari maksimum). Dalam konteks ablasi 15 *epoch*, ini adalah konfigurasi yang sesuai untuk evaluasi cepat, mencapai keseimbangan *Pareto* antara kualitas visual dan keterbacaan teks tanpa beban komputasi komponen kelima.

5. *Recognition Feature Loss*

Menunjukkan kontribusi marginal dalam ablasi singkat, dengan penurunan performa CER sebesar 0,50% (menjadi 30,16%) tanpa adanya peningkatan visual yang signifikan. Temuan ini mengindikasikan bahwa pada fase awal pelatihan, komponen ini bersifat *redundan* dibandingkan dengan sinyal kepekaan teks yang sudah disediakan oleh *CTC Loss*.

Temuan penting - perbandingan dengan pelatihan produksi:

Studi ablasi 15 *epoch* mencapai PSNR maksimal 24,86 dB (Eksperimen 02), jauh di bawah model produksi (30,91). Kesenjangan ini (6,05 dB) mengonfirmasi bahwa:

- a) Pelatihan diperluas (≥ 40 *epoch*) diperlukan untuk konvergensi penuh dan mencapai batas kinerja absolut
- b) Studi ablasi 15 *epoch* efektif untuk mengukur kontribusi relatif setiap komponen, bukan performa absolut
- c) Kontribusi komponen dapat berbeda antara fase awal (ablasi singkat) dan fase konvergensi penuh.

Rekomendasi konfigurasi berdasarkan konteks pelatihan:

- a) *Ablasi cepat/evaluasi awal* (<20 *epoch*): Eksperimen 04 (4-komponen: Piksel + *Adversarial* + *Perceptual* + *CTC*, CER 29,66%) memberikan hasil terbaik tanpa beban komputasi *RecFeat* yang belum berkontribusi di fase awal
- b) Pelatihan produksi (>40 *epoch*), direkomendasikan: Konfigurasi lengkap 5-komponen (Eksperimen 05) dengan *RecFeat*=8,0 untuk stabilitas konvergensi jangka panjang, mencapai PSNR 30,91 dB
- c) *Kualitas visual prioritas tanpa HTR*: Eksperimen 02 (Piksel + *Adversarial*, PSNR 24,86 dB) untuk aplikasi tampilan visual semata

V.4.2 Ablasi Strategi *Frozen Recognizer*

Bagian ini mengevaluasi efektivitas strategi *Frozen Recognizer* dalam mengatasi ketidakstabilan gradien dan *catastrophic forgetting* pada sistem *end-to-end*. Eksperimen komparatif dilakukan antara metode usulan (bobot pengenalan teks dibekukan) dibandingkan dengan metode konvensional *Joint Training* (semua bobot dilatih) pada dataset ANRI paleografi. Analisis difokuskan pada validasi hipotesis bahwa pembekuan bobot dapat mempertahankan kemampuan pengenalan teks sekaligus mempercepat konvergensi restorasi visual. Temuan utama disajikan dalam empat aspek berikut:

1. Stabilitas Gradien

Tabel V.9 Perbandingan stabilitas trajektori *loss*: *frozen recognizer* berbanding *joint training* (20 epoch)


Pendekatan	G Loss	D Loss	R Loss	Rentang G	Status
<i>Frozen (Baseline)</i>	$2,84 \pm 0,45$	$1,37 \pm 0,31$	$96,23 \pm 12,3$	2,15–3,62	Stabil
<i>Joint Training</i>	$89,09 \pm 7,45$	$0,037 \pm 0,067$	$30,45 \pm 1,59$	75,16–103,41	Tidak Stabil

Dalam aspek stabilitas trajektori *loss*, hasil eksperimen menunjukkan perbedaan substansial dalam stabilitas pelatihan. Pendekatan *frozen recognizer* menunjukkan trajektori *loss* yang halus dengan standar deviasi rendah (G *loss*: $\pm 0,45$), sementara *joint training* mengalami nilai tinggi yang konsisten (G *loss*: $89,09 \pm 7,45$). Rentang G *loss* pada *joint training* (75,16–103,41) mengindikasikan *magnitude loss* yang signifikan lebih tinggi dibandingkan dengan *frozen* (2,15–3,62), dengan rasio $26\times$ pada nilai minimum.

Lebih lanjut, analisis *loss* diskriminator mengungkapkan fenomena *mode collapse* yang signifikan pada *joint training* dengan D *loss* mendekati nol ($0,037 \pm 0,067$), mengindikasikan bahwa diskriminator terlalu dominan dan generator tidak dapat belajar secara optimal. Sebaliknya, *frozen recognizer* mempertahankan keseimbangan yang sehat antara generator dan diskriminator (D *loss*: $1,37 \pm 0,31$).

Stabilitas *frozen recognizer* yang teramati konsisten dengan mekanisme pembekuan bobot yang dirancang untuk mencegah kompetisi gradien (Bab IV.1.4), terbukti berhasil mengeliminasi konflik antara optimasi generator dan preservasi kemampuan *recognizer*. Gambar V.7 mengonfirmasi *mode collapse* pada *joint training* (D *loss* $\rightarrow 0$) dan fluktuasi besar *frozen* ($\sigma=136,6$) sebagai efek *curriculum learning*, bukan instabilitas yang merusak.

2. Performa Keterbacaan Teks Evaluasi performa keterbacaan teks dilakukan menggunakan metrik CER dan WER pada data validasi. Tabel V.10 menyajikan perbandingan antara kedua pendekatan.



Gambar V.7 Trajektori *loss* selama 20 *epoch*: (a) Generator, (b) Diskriminator, (c) CTC. Strategi *frozen* menunjukkan konvergensi stabil, sedangkan *joint training* mengalami osilasi ekstrem dan *mode collapse*.


Tabel V.10 Perbandingan metrik keterbacaan: *frozen recognizer* (CER 31,63%) berbanding *joint training* (CER 42,85%)

Pendekatan	CER (%)	Δ CER (%)	PSNR (dB)	SSIM
Acuan (Praterlatih)	33,72	-	-	-
<i>Frozen Recognizer</i>	31,63	-2,09	$23,09 \pm 3,88$	$0,9538 \pm 0,0306$
<i>Joint Training (Epoch 5)</i>	69,06	+35,34	$9,36 \pm \text{N/A}$	$0,623 \pm \text{N/A}$
<i>Joint Training (Epoch 20)</i>	42,85	+9,13	$10,71 \pm \text{N/A}$	$0,742 \pm \text{N/A}$
Degradasi <i>Joint</i> (Puncak)	-	+35,34	-13,73	-0,33
Degradasi <i>Joint</i> (Akhir)	-	+11,22	-12,38	-0,21


Secara spesifik, *Joint training* menyebabkan *catastrophic forgetting* dengan pola berikut:

- Epoch 5 (Degradasi Puncak): CER melonjak dari *baseline* 33,72% menjadi 69,06% (degradasi +35,34%), mengindikasikan ketidaksesuaian untuk domain paleografi kompleks
- Epoch 20 (Pemulihan Parsial): Pemulihan parsial hingga 42,85%, namun degradasi final tetap signifikan (+9,13% dari *baseline*)

Berbanding terbalik dengan kondisi tersebut, *frozen recognizer* justru meningkatkan performa menjadi 31,63% (perbaikan -2,09%), dengan keluaran yang tetap berkorelasi dengan masukan. Gambar V.8 menunjukkan perkembangan CER selama eksperimen.



Gambar V.8 Trajektori CER selama 20 *epoch*: *frozen* mencapai 31,63% (-2,09% dari *baseline*), *joint* mengalami *catastrophic forgetting* (puncak 69,06%) dan hanya pulih ke 42,85% (+9,13%).



Gambar V.9 Kualitas visual: *frozen* mencapai $23,09 \pm 3,88$ dB, sedangkan *joint* hanya 10,71 dB (*epoch* 20). Selisih 12,38 dB ($p < 0,001$) menunjukkan degradasi berat pada *joint training*.

Gambar V.9 menunjukkan ketidakstabilan *joint training* berdampak pada kualitas visual yang sangat rendah (*derau/distorsi* tinggi). *Frozen* unggul 12,38 dB (23,09 dB berbanding 10,71 dB, $p < 0,001$), atau peningkatan 115% dalam kualitas visual. Meskipun belum mencapai performa produksi (30,91 dB, 50

epoch), *frozen* menunjukkan keunggulan yang jelas.

Catatan: Fluktuasi *loss* pada *frozen* lebih terkendali (Rentang *G loss* 2,15–3,62) dibandingkan dengan *joint* (75,16–103,41). Metrik akhir membuktikan: *frozen* CER 31,63% (perbaikan -2,09%) berbanding *joint* 42,85% *epoch* 20 (degradasi +9,13%); stabilitas numerik *loss* berkorelasi dengan stabilitas kemampuan HTR.

3. Efisiensi Komputasi

Perbandingan efisiensi komputasi dilakukan dengan mengukur waktu pelatihan, penggunaan memori GPU, dan jumlah parameter yang dioptimasi. Tabel V.11 merangkum hasil analisis efisiensi.


Tabel V.11 Perbandingan efisiensi: *frozen* 7,4× lebih cepat (85s berbanding 630s per *epoch*) dengan parameter *trainable* 61,6% lebih sedikit

Metrik Efisiensi	<i>Frozen</i>	<i>Joint</i>
Waktu per <i>Epoch</i> (detik)	85,0 ± 2,1	630,5 ± 5,3
Durasi Total 20 <i>Epoch</i>	28,3 menit	210,2 menit
Penggunaan Memori GPU (GB)	13,6	~13,6
Parameter Dapat Dilatih (M)	17,4	~45,3
Parameter Tidak Dapat Dilatih (M)	27,9	–
<i>Steps</i> per <i>Epoch</i>	100	100
Stabilitas <i>Training</i>	Tinggi	Rendah

Data *joint training* dari log eksperimen 20 *epoch*. *Joint* 7,4× lebih lambat per *epoch* (630s berbanding 85s) karena beban tambahan *backpropagation* melalui *recognizer* yang dilatih (45,3M parameter berbanding 17,4M *frozen*), meskipun melakukan validasi setiap 5 *epoch*. Efisiensi komputasi menunjukkan perbedaan substansial: *frozen recognizer* 7,4× lebih cepat per *epoch* (85 detik berbanding 630 detik), dengan total durasi pelatihan 20 *epoch* hanya 28,3 menit dibanding 210,2 menit untuk *joint training*. Penggunaan memori GPU sebanding (~13,6 GB) karena *batch size* identik. Perbedaan kecepatan disebabkan oleh beban tambahan *backpropagation* melalui 45,3M parameter yang dapat dilatih pada *joint* (*generator* + diskriminator + *recognizer*) berbanding 17,4M pada *frozen* (*generator* + diskriminator saja, *recognizer* yang tidak dapat dilatih 27,9M tidak mengonsumsi gradien). Gambar V.10 menyajikan perbandingan efisiensi secara visual. Keunggulan ganda *frozen*: (1) Efisiensi komputasi 7,4× lebih tinggi, (2) Pelestarian kemampuan HTR yang lebih baik (CER 31,63% dengan perbaikan -2,09% berbanding *joint* 42,85% dengan degradasi +9,13%).

4. Sintesis dan Kesimpulan Perbandingan

Sintesis hasil eksperimen mengonfirmasi superioritas strategi *frozen recognizer* dibandingkan *joint training* di seluruh dimensi evaluasi. Tabel V.12 merangkum



Gambar V.10 Analisis efisiensi: (a) waktu per *epoch*, (b) penggunaan memori GPU, (c) jumlah parameter dapat dilatih. Strategi *frozen* mengurangi beban komputasi $7,4\times$ tanpa mengorbankan akurasi.

temuan kuantitatif, menunjukkan bahwa pendekatan *frozen* tidak hanya mencegah degradasi performa tetapi juga menawarkan efisiensi komputasi yang jauh lebih tinggi.

Tabel V.12 Ringkasan kuantitatif: *frozen recognizer* unggul di semua metrik dengan efisiensi komputasi $7,4\times$ lebih tinggi


Metrik	<i>Frozen</i>	<i>Joint</i> (Epoch 20)	Perbedaan
CER (%)	31,63	42,85	-26,2% (<i>frozen</i> lebih baik)
Δ CER dari <i>Baseline</i>	-2,09	+9,13	<i>Frozen</i> : perbaikan, <i>Joint</i> : degradasi
PSNR (dB)	$23,09 \pm 3,88$	10,71	+115% (<i>frozen</i> lebih baik)
SSIM	$0,954 \pm 0,031$	0,742	+28,5% (<i>frozen</i> lebih baik)
Parameter Dapat Dilatih (M)	17,4	45,3	reduksi 61,6%
<i>Training Speed</i> (s/epoch)	85	630	$7,4\times$ lebih cepat
<i>Catastrophic Forgetting</i>	Tidak	Ya (CER Puncak 69,06%)	—

Berdasarkan data tersebut, tiga kesimpulan utama yang dapat diambil adalah:

- Pencegahan Catastrophic Forgetting:** Mekanisme pembekuan bobot terbukti efektif melindungi kemampuan pengenalan teks. Sementara *joint training* mengalami lonjakan CER yang signifikan (+35,34% pada puncak), *frozen recognizer* justru mencatat perbaikan marjinal (-2,09%), memvalidasi hipotesis stabilitas gradien.
- Efisiensi Sumber Daya:** Dengan pengurangan 61,6% parameter yang dilatih, strategi ini mempercepat proses pelatihan hingga 7,4 kali lipat. Hal ini menjadikan eksperimen iteratif jauh lebih memungkinkan dan hemat biaya komputasi.
- Kualitas Visual lebih unggul:** Stabilitas pelatihan berdampak langsung pada kualitas restorasi visual. Absennya osilasi gradien ekstrem pada mode *frozen* menghasilkan citra dengan PSNR 115% lebih tinggi dibanding *joint training* pada *epoch* yang sama.

Dari segi implikasi praktis, temuan ini merekomendasikan penggunaan *frozen*

recognizer untuk lingkungan produksi yang memprioritaskan stabilitas dan efisiensi, serta untuk skenario ketika pelatihan ulang model pengenalan teks tidak dimungkinkan. Gambar V.11 memvisualisasikan dominasi menyeluruh pendekatan ini.



Gambar V.11 Perbandingan multi-dimensi: stabilitas *loss*, kualitas visual (PSNR/SSIM), keterbacaan (CER/WER), dan efisiensi. *Frozen recognizer* mengungguli *joint training* di seluruh dimensi.

Sebagai simpulan akhir, kombinasi *frozen recognizer* dengan CTC *loss* ditetapkan sebagai konfigurasi standar untuk eksperimen selanjutnya dalam penelitian ini, karena terbukti memberikan fondasi yang stabil (bebas *mode collapse*) dan efisien untuk pengembangan model restorasi dokumen paleografi.

V.4.3 Ablasi Diskriminator *Dual-Modal*

Setelah memvalidasi strategi *frozen recognizer* sebagai fondasi sistem (Bagian V.4.2), bagian ini mengevaluasi kontribusi arsitektur diskriminator dual-modal (cabang CNN+BiLSTM dengan bilateral cross-attention, 17,4M parameter, detail arsitektur dijelaskan pada Bagian IV.1.2). Evaluasi dilakukan melalui studi ablasi terkontrol menggunakan pelatihan produksi 50 *epoch* untuk mengisolasi dampak arsitektur diskriminator terhadap metrik restorasi.

1. Protokol Studi Ablasi

Untuk mengisolasi kontribusi arsitektur *dual-modal* dilakukan studi ablasi dengan membandingkan dua varian diskriminator yang dilatih dengan konfigurasi identik: *generator* Enhanced U-Net, 50 *epoch*, protokol *curriculum learning*, fungsi *loss* identik ($L_{adv} + L_{L1} + L_{perc} + L_{CTC}$), dan model terbaik dipilih pada

set validasi ($n=710$) berdasarkan kriteria gabungan PSNR-CER.

2. Hasil Perbandingan Kuantitatif Hasil eksperimen menunjukkan perbedaan yang

Tabel V.13 Ablasi arsitektur diskriminator (50 *epoch*): CNN tunggal berbanding *dual-modal*. Perbedaan performa tidak signifikan ($p > 0,05$).

Diskriminator	PSNR (dB)	SSIM	CER (%)
Hanya CNN (acuan)	30,63	0,9854	27,12
<i>Dual-Modal</i> (usulan)	30,91	0,9869	27,11
Δ (<i>Dual</i> -CNN)	+0,28	+0,0015	-0,01
Signifikansi statistik	$p > 0,05$ (tidak signifikan)		

sangat minimal antara kedua arsitektur (Δ PSNR = +0,28 dB, Δ SSIM = +0,0015, Δ CER = -0,01%), tidak signifikan secara statistik ($p > 0,05$). Dari perspektif pengguna, kedua arsitektur menghasilkan keluaran yang identik dengan metrik kualitas visual dan HTR yang sebanding.

3. Interpretasi Temuan

Hasil eksperimen menunjukkan bahwa hipotesis mengenai keunggulan diskriminator *dual-modal* tidak terdukung secara statistik dalam konfigurasi penelitian ini. Penambahan cabang tekstual (BiLSTM) dan mekanisme atensi tidak memberikan kontribusi signifikan terhadap kualitas restorasi maupun akurasi teks dibandingkan dengan diskriminator berbasis CNN tunggal. Hal ini mengindikasikan bahwa kompleksitas tambahan dari arsitektur *dual-modal* tidak terjustifikasi oleh peningkatan performa yang dihasilkan.

Temuan ini menegaskan bahwa dalam konteks restorasi dokumen dengan karakteristik *dataset* dan konfigurasi pelatihan yang digunakan, diskriminator visual (CNN) sudah memadai untuk membedakan citra asli dan hasil restorasi. Informasi tekstual yang diharapkan dapat membantu proses diskriminasi terbukti tidak memberikan dampak yang berarti pada hasil akhir.

4. Analisis Faktor Penyebab

Berdasarkan evaluasi hasil, teridentifikasi beberapa faktor yang menyebabkan tidak efektifnya kontribusi diskriminator *dual-modal*:

- Kualitas Data Teks Masukan: Diskriminator menerima masukan teks hasil prediksi yang masih mengandung kesalahan (CER ~27%). Hal ini merupakan kendala bawaan dalam desain GAN standar karena diskriminator harus mengevaluasi luaran aktual generator. Derau pada data teks ini kemungkinan besar menghambat cabang LSTM untuk mempelajari representasi tekstual yang akurat, namun penggunaan teks *ground truth* secara langsung juga berisiko menciptakan kesenjangan domain yang tidak realistis.

- b. Dominasi Komponen *Loss* Lain: Dalam konfigurasi *loss function* yang digunakan, bobot *adversarial* relatif kecil (3,0) dibandingkan dengan komponen lain seperti CTC (0,15 dengan *magnitude* besar) dan *Pixel* (50,0). Akibatnya, pengaruh diskriminator secara keseluruhan terhadap pembaruan bobot *generator* menjadi terbatas, sehingga perubahan arsitektur diskriminator tidak memberikan dampak signifikan.
- c. Kecukupan Fitur Visual: Untuk tugas restorasi dokumen ini, fitur-fitur visual (tekstur kertas, ketajaman tinta, derau latar belakang) tampaknya menjadi indikator utama keaslian citra. Diskriminator CNN tunggal sudah cukup efektif dalam menangkap fitur-fitur ini, sehingga penambahan analisis semantik teks menjadi redundan atau kurang relevan untuk tugas diskriminasi visual.

5. Implikasi Teoretis dan Arah Penelitian Masa Depan

Hasil negatif pada pengujian hipotesis diskriminator *dual-modal* memberikan implikasi teoretis bahwa penambahan kompleksitas model melalui integrasi fitur tekstual tidak selalu menjamin peningkatan kualitas restorasi. Temuan ini menggugurkan asumsi bahwa semakin kaya informasi yang diberikan kepada diskriminator (visual + tekstual), semakin baik performa *generator*. Dalam kasus ini, informasi visual terbukti sudah memadai.

Penelitian masa depan dapat mengeksplorasi strategi pelatihan alternatif seperti *Teacher Forcing* atau *Scheduled Sampling*; dalam pendekatan ini, diskriminator secara berkala diberikan akses ke teks *ground truth* untuk mempelajari representasi tekstual yang lebih baik. Namun, pendekatan ini harus diterapkan dengan hati-hati untuk menghindari risiko dominasi berlebihan diskriminator yang dapat menyebabkan hilangnya gradien bagi generator jika diskriminator menjadi terlalu kuat dibandingkan generator.

6. Implikasi untuk Desain Sistem GAN-HTR

Temuan dari studi ablasi diskriminator memberikan wawasan penting tentang prioritas desain dalam sistem GAN-HTR. Dalam konteks penelitian ini, performa optimal lebih ditentukan oleh strategi pelatihan (seperti *frozen recognizer* dan penyeimbangan *loss*) daripada kompleksitas arsitektur diskriminator.

Hal ini menegaskan prinsip parsimoni (*Occam's Razor*) dalam desain model: komponen yang lebih sederhana (CNN tunggal) lebih disukai karena komponen yang lebih kompleks (Dual-Modal) tidak memberikan peningkatan performa yang signifikan secara statistik. Oleh karena itu, meskipun model produksi dalam penelitian ini menggunakan arsitektur Dual-Modal sebagai bagian dari desain eksperimental awal, rekomendasi final untuk implementasi praktis

adalah menggunakan diskriminator visual standar (CNN tunggal) untuk efisiensi komputasi yang lebih baik dengan hasil yang setara. Penggunaan Dual-Modal pada model akhir dipertahankan semata-mata untuk menjaga konsistensi dengan konfigurasi eksperimen yang telah berjalan, namun tidak direkomendasikan untuk pengembangan selanjutnya.

V.4.4 Ablasi *Curriculum Learning*

Komponen ketiga dari studi ablasi difokuskan pada validasi strategi pelatihan bertahap atau *curriculum learning*. Strategi ini dirancang dengan hipotesis bahwa memperkenalkan kompleksitas tugas secara bertahap, dimulai dari rekonstruksi visual dasar sebelum mengaktifkan optimasi HTR secara penuh, dapat meningkatkan stabilitas konvergensi dan mencegah model terjebak pada *local minima* yang tidak optimal. Secara spesifik, eksperimen ini membandingkan pendekatan *Curriculum Learning* tiga fase yang menerapkan peningkatan bobot CTC secara gradual dari 0 ke 0,15 selama 20 *epoch* pembuka, berbanding dengan pendekatan *Non-Curriculum* (Clean Slate) yang menerapkan bobot penuh 0,15 secara simultan sejak awal pelatihan. Analisis ini bertujuan untuk memverifikasi secara empiris apakah kompleksitas tambahan dari mekanisme penjadwalan dinamis ini memberikan keuntungan performa yang signifikan, atau apakah arsitektur model sudah cukup handal untuk menangani optimasi multi-objektif secara langsung.

Tabel V.14 Perbandingan *curriculum learning* berbanding *non-curriculum*: dampak pada stabilitas konvergensi dan performa akhir

Metrik	<i>Curriculum</i>	<i>Non-Curriculum</i>	Selisih
Best PSNR (dB)	26,022	26,163	+0,141
Best CER	0,287	0,286	-0,001
Best Combined Score	25,448	25,591	+0,143
<i>Best Epoch</i>	45	41	-4
<i>Total Epoch</i>	50	50	0
PSNR Final (dB)	26,028	26,191	+0,163
CER Final	0,287	0,287	0,000
SSIM Final	0,9684	0,9692	+0,0008

1. Temuan Kuantitatif


Hasil menunjukkan perbedaan marginal: *non-curriculum* sedikit unggul (PSNR 26,16 berbanding 26,02 dB, $\Delta=0,14$ dB; CER 0,286 berbanding 0,287, $\Delta=0,001$) dengan konvergensi lebih cepat (*epoch* terbaik 41 berbanding 45). Uji statistik: perbedaan tidak signifikan (PSNR: $p=0,471$, Cohen's $d=0,146$; CER: $p=0,519$, $d=-0,131$).

Temuan menunjukkan bahwa *non-curriculum* justru lebih stabil secara keseluruhan dengan deviasi standar CTC loss $37\times$ lebih rendah ($\sigma = 4,09$ berbanding 151,62), meskipun *curriculum* dirancang untuk stabilitas. Temuan ini membuktikan bahwa pembelajaran simultan tanpa fase bertahap dapat menghasilkan konvergensi yang lebih konsisten pada arsitektur yang handal.

Penyebab temuan ini diidentifikasi sebagai berikut: (1) Komponen *loss* sudah optimal dengan keseimbangan stabil, (2) Dataset semi-sintetis terkontrol tidak memerlukan adaptasi bertahap kompleks, (3) Arsitektur U-Net *enhanced* + diskriminator dual-modal cukup handal untuk optimisasi simultan.

2. Analisis Komponen Loss

Dalam pelatihan model restorasi dokumen, sistem menggunakan lima komponen fungsi *loss* yang bekerja bersama untuk mengoptimalkan kualitas hasil. Setiap komponen memiliki peran spesifik: (1) *pixel loss* memastikan kemiripan piksel-per-piksel dengan gambar asli, (2) *adversarial loss* menjaga kealamian tekstur, (3) *recognition feature loss* menyelaraskan fitur pengenalan teks, (4) CTC *loss* memastikan teks tetap terbaca, dan (5) *perceptual loss* mempertahankan struktur visual secara keseluruhan. Gambar V.12 menampilkan evolusi kelima komponen ini selama pelatihan.



Gambar V.12 Evolusi komponen *loss* dalam tiga fase *curriculum learning*: *warmup* visual (hijau), transisi CTC (oranye), pelatihan penuh (biru).

Temuan per komponen menunjukkan bahwa pendekatan *non-curriculum* (tanpa pembelajaran bertahap) menghasilkan pelatihan yang lebih stabil. Secara spesifik:

(1) *Pixel loss* menunjukkan variasi lebih rendah pada *non-curriculum* ($\sigma = 0,015$ berbanding $0,020$), menandakan rekonstruksi piksel yang lebih konsisten. (2) *Adversarial loss* menunjukkan pola serupa pada kedua pendekatan dengan nilai diskriminator stabil di sekitar $0,79$. (3) *Recognition feature loss* sedikit lebih rendah pada *non-curriculum* ($0,075$ berbanding $0,078$). (4) *CTC loss* menunjukkan perbedaan paling signifikan; pendekatan *curriculum* mengalami fluktuasi 37 kali lebih tinggi dibandingkan *non-curriculum*.

Analisis hubungan antar-komponen mengungkapkan dinamika penting yang patut dicatat selama pelatihan. Pada fase transisi (*epoch* 11–30), *CTC loss* dan *pixel loss* menunjukkan hubungan negatif yang kuat ($r = -0,67$), artinya ketika sistem meningkatkan keterbacaan teks, terkadang terjadi pengorbanan pada rekonstruksi piksel. Namun, hubungan negatif ini melemah pada fase akhir ($r = -0,23$), menandakan bahwa generator berhasil menemukan keseimbangan antara rekonstruksi visual dan keterbacaan teks. Di sisi lain, *perceptual loss* justru berkorelasi positif dengan *CTC* ($r = 0,41$), mengonfirmasi bahwa fitur struktural yang baik mendukung keterbacaan.

Analisis kontribusi gradien memberikan pemahaman mengapa komponen *CTC* sangat berpengaruh meskipun bobotnya kecil ($0,15$). Meskipun kontribusi *CTC* terhadap total *loss* tertimbang adalah $67,5\%$, komponen ini menghasilkan $78,3\%$ dari total sinyal pembelajaran (magnitudo gradien). Hal ini terjadi karena *CTC* menghasilkan sinyal pembelajaran yang padat untuk setiap posisi karakter, berbeda dengan komponen lain yang menghasilkan sinyal tunggal. Sebaliknya, *recognition feature loss* yang berkontribusi hanya $0,1\%$ terhadap total *loss* juga hanya menghasilkan $0,08\%$ sinyal pembelajaran, mengonfirmasi ketidakefektifannya secara kuantitatif.


Implikasi praktis dari temuan ini menghasilkan tiga prinsip desain untuk sistem serupa: (1) Pembobotan harus mempertimbangkan skala nilai *loss* dan kepadatan sinyal pembelajaran, bukan hanya nilai nominal. (2) Hubungan antar-komponen berubah selama pelatihan, sehingga pembobotan adaptif berpotensi meningkatkan performa. (3) Analisis korelasi temporal dan gradien dapat mengidentifikasi komponen yang tidak efektif secara sistematis.

3. Validasi Statistik

Untuk memastikan kesimpulan yang dapat dipercaya, penelitian ini menerapkan serangkaian uji statistik yang ketat. Sebelum melakukan pengujian, terlebih dahulu dipastikan bahwa data memenuhi asumsi yang diperlukan. Uji Kolmogorov-Smirnov mengonfirmasi bahwa data PSNR dan CER pada kedua kondisi (dengan dan tanpa *curriculum*) terdistribusi normal ($p > 0,05$), sehingga penggunaan uji *t-test*

dapat dibenarkan. Hasil pengujian menunjukkan bahwa perbedaan antara kedua pendekatan tidak signifikan secara statistik. Untuk PSNR, nilai $p = 0,471$ (jauh di atas ambang batas 0,05), dan untuk CER, nilai $p = 0,519$. Artinya, perbedaan yang teramati kemungkinan besar terjadi secara kebetulan, bukan karena efek nyata dari *curriculum learning*.

Ukuran efek (*effect size*) Cohen's d digunakan untuk mengukur seberapa besar perbedaan praktis antara kedua pendekatan. Nilai Cohen's d untuk PSNR adalah 0,146 dan untuk CER adalah $-0,131$. Menurut pedoman interpretasi standar, nilai di bawah 0,2 dianggap sangat kecil atau dapat diabaikan. Dengan demikian, meskipun ada sedikit perbedaan numerik, perbedaan tersebut tidak bermakna secara praktis. Interval kepercayaan 95% untuk selisih PSNR adalah $[-1,41, 0,63]$ dB, yang mencakup nilai nol. Hal ini mengonfirmasi bahwa tidak ada perbedaan yang bermakna antara kedua pendekatan. Gambar V.13 menyajikan ringkasan visual dari analisis statistik yang dilakukan.



Gambar V.13 Analisis statistik: (a) distribusi metrik, (b) *box plot*, (c) *effect size* Cohen's d , (d) stabilitas, (e) signifikansi ($p < 0,05$ ditandai merah).

Untuk memastikan kesimpulan tidak dipengaruhi oleh keterbatasan jumlah sampel,

dilakukan analisis kekuatan statistik (*power analysis*). Dengan 50 *epoch* sebagai sampel, tingkat signifikansi 0,05, dan efek teramati ($d = 0,146$), kekuatan uji yang diperoleh adalah 0,08, yang memang rendah. Namun, jika efek yang dicari adalah efek bermakna praktis ($d = 0,5$), maka 50 sampel sudah memberikan kekuatan uji sebesar 0,70, yang memadai. Untuk mendeteksi efek sangat kecil ($d = 0,3$), diperlukan 352 sampel, yang tidak praktis. Kesimpulannya, ketiadaan signifikansi statistik mencerminkan bahwa efek nyata memang sangat kecil (kurang dari 0,2), bukan karena penelitian ini kekurangan sampel.

Untuk memvalidasi, dilakukan beberapa uji tambahan. Metode *bootstrap* dengan 10.000 iterasi menghasilkan interval kepercayaan $[-1,38, 0,61]$ dB, konsisten dengan hasil parametrik. Uji permutasi (10.000 iterasi) menghasilkan $p = 0,468$, konsisten dengan *t-test*. Analisis dengan menghapus 5% nilai ekstrem (rerata terpankang/*trimmed mean*) tidak mengubah kesimpulan ($p = 0,483$). Tidak ditemukan data pencilan yang berpengaruh besar (Cook's distance $< 0,5$), dan varians antar-kelompok terbukti homogen (uji Levene, $p = 0,68$). Keseluruhan uji tambahan ini mengonfirmasi bahwa kesimpulan bersifat tangguh dan tidak bergantung pada asumsi distribusi tertentu atau keberadaan data pencilan.


4. Analisis Fase *Curriculum*

Gambar V.14 menyajikan karakteristik tiga fase *curriculum learning*.

Temuan menunjukkan bahwa deviasi standar CTC *loss* total menunjukkan perbedaan signifikan ($\sigma = 151,62$ berbanding 4,09), namun analisis per-fase mengungkapkan bahwa perbedaan ini terutama disebabkan oleh efek transisi bobot CTC. Pada fase konvergensi akhir (*epoch* 31-50), kedua pendekatan menunjukkan stabilitas yang setara ($\sigma \approx 2,7$), mengindikasikan bahwa variabilitas tinggi pada *curriculum* adalah artefak dari aktivasi bertahap, bukan ketidakstabilan pelatihan yang inheren.

Dalam hal efisiensi konvergensi, *non-curriculum* mencapai performa puncak 4 *epoch* lebih cepat (*epoch* 45 berbanding 49), menghasilkan penghematan waktu komputasi tanpa pengorbanan kualitas. Ini membuktikan bahwa pemberian bobot CTC penuh dari awal (aktivasi langsung) memfasilitasi konvergensi yang lebih efisien dibandingkan aktivasi bertahap.

Faktor-faktor penyebab temuan ini diidentifikasi sebagai berikut: (1) Komponen *loss* sudah optimal dengan keseimbangan stabil, (2) Dataset semi-sintetis terkontrol tidak memerlukan adaptasi bertahap kompleks, (3) Arsitektur U-Net *enhanced* + diskriminator dual-modal cukup handal untuk optimisasi simultan multi-objektif dari *epoch* pertama tanpa memerlukan pemanasan visual terpisah.



Gambar V.14 Karakteristik tiga fase *curriculum*: (a) jadwal bobot CTC, (b) distribusi *loss*, (c) evolusi PSNR/CER, (d) kontribusi relatif komponen.

5. Rekomendasi Implementasi dan Klarifikasi Protokol

Penting untuk dicatat bahwa model produksi yang menghasilkan metrik utama dalam penelitian ini (PSNR 30,91 dB, CER 34,9%) dilatih menggunakan protokol *curriculum learning* (seperti tercantum pada Tabel IV.4 di Bab IV). Temuan mengenai efektivitas *non-curriculum* diperoleh melalui studi ablasi susulan setelah model produksi selesai dilatih. Oleh karena itu, meskipun *non-curriculum* direkomendasikan untuk implementasi masa depan karena efisiensi konvergensi (4 *epoch* lebih cepat, kompleksitas lebih rendah), konfigurasi final yang dilaporkan dalam tesis ini tetap menggunakan *curriculum learning* sebagai protokol yang menghasilkan data uji.

- Rekomendasi Masa Depan: Gunakan *non-curriculum* untuk efisiensi (4 *epoch* lebih cepat konvergensi, implementasi lebih sederhana, performa setara).
- Nilai Eksperimental: *Curriculum* tetap bernilai untuk eksplorasi dinamika pelatihan dan dataset riil kompleks, serta merupakan protokol yang memvalidasi hasil utama penelitian ini.
- Reproduksibilitas: Untuk mereplikasi hasil persis seperti yang dilaporkan dalam Bab ini, gunakan konfigurasi *curriculum* (Tabel IV.4 di Bab IV). Untuk optimasi sistem baru, gunakan *non-curriculum*.

Sebagai kesimpulan, *curriculum learning* tidak memberikan peningkatan performa signifikan ($\Delta\text{PSNR} -0,14 \text{ dB}$, $p=0,471$) dengan konvergensi 4 *epoch* lebih lambat. Arsitektur yang handal dapat mengoptimasi semua objektif secara simultan dari awal tanpa memerlukan aktivasi bertahap. Status hipotesis adalah *Tidak Didukung Penuh* sebagai peningkat performa, namun tetap didokumentasikan sebagai bagian dari riwayat eksperimen yang menghasilkan model produksi.

V.4.5 Analisis Bobot Fungsi Loss

Bagian sebelumnya telah membahas kontribusi masing-masing komponen arsitektur (fungsi *loss*, *frozen recognizer*, diskriminator *dual-modal*, dan *curriculum learning*) secara terpisah. Subbagian ini menganalisis konfigurasi bobot fungsi *loss* secara menyeluruh melalui dua pendekatan: (1) pengamatan proporsi pengaruh terbobot selama pelatihan produksi, dan (2) validasi sensitivitas melalui eksperimen *grid search*. Konfigurasi bobot yang digunakan ditetapkan pada Bab IV (Tabel IV.2).

1. Proporsi Pengaruh Terbobot

Konfigurasi bobot *loss* ditentukan secara empiris dan menunjukkan pola penskalaan terbalik (*inverse scaling*) terhadap besaran *loss* mentah. Tabel V.15 menyajikan proporsi pengaruh setiap komponen setelah pembobotan.

Tabel V.15 Konfigurasi bobot fungsi *loss* pelatihan produksi: nilai, besaran mentah, dan proporsi pengaruh terbobot setiap komponen

Komponen	Bobot	Rerata Mentah	Terbobot	Proporsi (%)
Pixel	50,0	0,0123	0,62	0,7%
Adversarial	3,0	0,8882	2,66	3,1%
RecFeat	8,0	0,0099	0,08	0,1%
CTC	0,15	392,01	58,80	67,5%
Perceptual	1,0	24,92	24,92	28,6%

Data dari 82.150 *batch* pelatihan (*epoch* 11–50, pasca-pemanasan pelatihan produksi)


Terbobot = mentah $\times$ bobot; Proporsi = bagian dari 5 komponen utama (dinormalkan 100%)

Konfigurasi terpilih [piksel=50,0, adv=3,0, RecFeat=8,0, perc=1,0, CTC=0,15] secara empiris menghasilkan pola yang berkorelasi terbalik dengan besaran *loss* mentah:


$$w_i \propto \frac{1}{\text{magnitude}_{\text{raw},i}} \quad (\text{V.28})$$

dengan w_i adalah bobot komponen ke- i . Pola ini merupakan sifat yang muncul dari proses penyetelan manual untuk mencapai konvergensi stabil. Proporsi menunjukkan CTC dominan (67,5%), *perceptual* mayor (28,6%), *adversarial* (3,1%), piksel (0,7%), dan RecFeat minimal (0,1%). Perbedaan besaran mentah mencapai 5

orde besaran (10^{-3} hingga 10^2), mengonfirmasi pentingnya penyeimbangan untuk mencegah dominasi satu komponen. Gambar V.15 dan V.16 memvisualisasikan proporsi ini.



Gambar V.15 Proporsi pengaruh terbobot komponen *loss*: CTC mendominasi (67,5%), *perceptual* (28,6%), komponen lain (<4%).




Gambar V.16 *Box plot* besaran *loss* mentah: CTC (median ~ 380), *perceptual* (~ 25), *adversarial* (~ 1), menunjukkan kesenjangan 4 orde besaran.

2. Validasi Optimalitas Konfigurasi

Untuk memvalidasi bahwa konfigurasi bobot yang dipilih berada pada titik optimal, dilakukan dua jenis validasi:

- Analisis Stabilitas *GradNorm*:** Algoritma *GradNorm* (penyeimbang *loss* adaptif) diawali dengan konfigurasi manual. Hasil menunjukkan stabilitas bobot 100% selama 50 *epoch*, yaitu tidak ada penyesuaian signifikan. Proporsi *GradNorm* [80,5/4,8/12,9/1,6/0,2] berbanding manual [81,0/4,9/13,0/1,6/0,2] menunjukkan kesamaan 99,5%, mengonfirmasi konfigurasi manual berada di titik keseimbangan optimal.
- Mini *Grid Search*:** Eksplorasi 27 konfigurasi dengan *orthogonal array sampling* (setiap komponen $\pm 50\%$ nilai acuan) tidak menemukan konfigurasi yang lebih



Gambar V.17 Mekanisme penyeimbangan: besaran mentah yang bervariasi 4 orde (10^{-2} – 10^2) dinormalkan menjadi proporsi terkontrol (CTC 67,5%, *perceptual* 28,6%) melalui pembobotan.

unggul pada fase awal pelatihan (3 *epoch*). Tabel V.16 menyajikan lima konfigurasi terbaik.

Tabel V.16 Lima konfigurasi terbaik dari 27 eksperimen *grid search* (3 *epoch*): analisis sensitivitas bobot fungsi *loss*

No.	Konfigurasi	PSNR (dB)	CER (%)	SSIM	Skor
1	Px=100, Adv=3,0, Perc=1,0, CTC=0,15, RecF=16	11,39	86,82	0,666	-5,97
2	Px=100, Adv=1,5, Perc=0,5, CTC=0,075, RecF=0	4,17	84,30	0,202	-12,69
3	Px=100, Adv=6,0, Perc=1,0, CTC=0,30, RecF=0	5,17	89,50	0,304	-12,73
4	Px=50, Adv=6,0, Perc=0,5, CTC=0,30, RecF=16	5,90	96,19	0,443	-13,34
5	Px=100, Adv=1,5, Perc=2,0, CTC=0,075, RecF=16	5,06	98,38	0,390	-14,62

Score = PSNR - 0,2×CER×100 (semakin tinggi semakin baik). Data dari 3 *epoch*, 20 langkah/*epoch* pelatihan ablasi.

Catatan: Hasil PSNR dari *grid search* (rentang 0,58–11,39 dB) tidak dapat dibandingkan langsung dengan pelatihan produksi (30,91 dB) karena perbedaan durasi pelatihan (3 berbanding 50 *epoch*). Fokus analisis adalah pada tren relatif dan sensitivitas komponen.

3. Analisis Sensitivitas Per Komponen

Berdasarkan agregasi hasil 27 konfigurasi (15 dengan metrik valid), diperoleh temuan mengenai sensitivitas setiap komponen. Pembahasan berikut menganalisis tiga komponen utama: bobot *pixel loss*, bobot *CTC loss*, dan *recognition feature loss*.

a. Bobot *Pixel Loss*

Pixel loss (L1) berfungsi sebagai penahan utama untuk mempertahankan kualitas visual dalam GAN, mencegah artefak halusinasi yang umum terjadi pada pelatihan *adversarial* tanpa kendala eksplisit. Tabel V.17 menyajikan hasil analisis sensitivitas terhadap tiga tingkat bobot.

Tabel V.17 Analisis sensitivitas bobot piksel (25, 50, 100) terhadap PSNR dan CER pada fase awal konvergensi (3 *epoch*)

Bobot Piksel	Pengali	Rerata PSNR (dB)	Rerata CER (%)	n
25	0,5× acuan	2,51 ± 1,36	98,13	5
50	1,0× acuan	2,40 ± 2,37	99,02	4
100	2,0× acuan	5,25 ± 3,19	92,14	6

Hasil analisis menunjukkan bahwa peningkatan bobot dari 50 ke 100 (2× acuan) menghasilkan peningkatan PSNR sebesar 118% (dari 2,40 dB ke 5,25 dB), dengan efek samping perbaikan CER (92,14% berbanding 99,02%). Bobot piksel 100 menempati 4 dari 5 posisi teratas pada *grid search*, mengonfirmasi dominasinya dalam optimasi visual. Meskipun demikian, konfigurasi produksi menggunakan bobot 50 untuk menjaga keseimbangan dengan komponen lain dalam konvergensi jangka panjang. Pelatihan produksi dengan bobot piksel 50 mencapai PSNR 30,91 dB, menunjukkan bahwa bobot moderat memadai ketika dikombinasikan dengan *curriculum learning*. Perlu diperhatikan bahwa bobot 100 berisiko mendominasi sinyal gradien sehingga dapat menghambat pembelajaran fitur semantik dari komponen CTC dan RecFeat.

b. Bobot CTC *Loss*

Komponen CTC *loss* berfungsi memberikan sinyal gradien yang mengarahkan generator untuk menghasilkan citra yang mudah dibaca oleh modul HTR. Salah satu pertanyaan kunci penelitian ini adalah: “Apakah bobot CTC *loss* mempengaruhi kualitas visual hasil restorasi?” Kekhawatiran teoretis adalah bahwa penekanan berlebihan pada keterbacaan dapat mendegradasi kualitas visual. Tabel V.18 menyajikan hasil analisis sensitivitas untuk menjawab pertanyaan ini.

Tabel V.18 Analisis sensitivitas bobot CTC (0,075; 0,15; 0,30) terhadap kualitas visual dan keterbacaan

Bobot CTC	Pengali	Rerata PSNR (dB)	Rerata CER (%)	n
0,075	0,5× acuan	3,16 ± 1,50	95,99	6
0,150	1,0× acuan	4,20 ± 4,92	96,49	4
0,300	2,0× acuan	3,59 ± 2,03	95,53	5

Hasil analisis menunjukkan bahwa variasi bobot CTC dalam rentang $\pm 50\%$ dari

nilai acuan (0,15) tidak menghasilkan perbedaan PSNR yang signifikan (rentang 3,16–4,20 dB). Ketiga konfigurasi menghasilkan CER yang sebanding ($\sim 96\%$), mengindikasikan bahwa sinyal CTC sudah memadai pada bobot 0,075 dan penggandaan hingga 0,30 tidak memberikan keuntungan tambahan. Temuan ini menjawab pertanyaan penelitian: pada rentang yang diuji, bobot CTC **tidak** menyebabkan degradasi kualitas visual yang berarti. Konfigurasi produksi menggunakan bobot 0,15 sebagai titik tengah yang seimbang.

c. *Recognition Feature Loss*

Komponen *recognition feature loss* (RecFeat) dirancang untuk menyelaraskan representasi fitur internal antara citra hasil restorasi dan *ground truth*. Konfigurasi produksi menggunakan RecFeat=8,0, namun studi ablasi 15 *epoch* (Bagian V.4.1) menunjukkan bahwa Eksperimen 04 (tanpa RecFeat) mencapai CER lebih baik (29,66%) dibanding Eksperimen 05 (dengan RecFeat, CER 30,16%). Tabel V.19 menyajikan klarifikasi lebih lanjut dari *grid search*.

Tabel V.19 Analisis sensitivitas *recognition feature loss*: perbandingan tiga tingkat bobot pada fase awal (3 *epoch*)

Bobot RecFeat	Status	Rerata PSNR (dB)	Rerata CER (%)	n
0,0	Nonaktif	$4,19 \pm 0,97$	91,00	3
8,0	Acuan	$1,90 \pm 1,03$	99,86	4
16,0	2× acuan	$4,19 \pm 3,44$	95,89	8

Dalam ablasi 3 *epoch*, RecFeat=0 dan RecFeat=16 menunjukkan PSNR yang sebanding (4,19 dB), sementara RecFeat=8 (acuan produksi) memberikan hasil terendah (1,90 dB). Hasil ini konsisten dengan temuan ablasi 15 *epoch* yang juga menunjukkan penurunan performa saat RecFeat diaktifkan. Penambahan komponen penyelarasan *loss* fitur memberikan beban optimisasi tambahan yang memperlambat konvergensi awal. Berdasarkan temuan ini, hasil kuantitatif secara konsisten tidak mendukung penyertaan komponen RecFeat (penurunan CER +0,50% pada *epoch* 15 dan performa rendah pada *grid search*). Keberadaan RecFeat dalam konfigurasi produksi merupakan warisan dari desain eksperimen awal, dan direkomendasikan untuk dihapus dalam iterasi pengembangan selanjutnya.

Sebagai sintesis, analisis sensitivitas menghasilkan tiga temuan utama: (1) bobot piksel merupakan faktor dominan dalam optimasi visual dengan sensitivitas tinggi, sehingga konfigurasi moderat (50) direkomendasikan untuk keseimbangan jangka panjang; (2) bobot CTC menunjukkan robustitas dalam rentang $\pm 50\%$, menjawab pertanyaan penelitian bahwa penekanan keterbacaan tidak mendegradasi kualitas

visual; dan (3) *recognition feature loss* terbukti tidak efektif bahkan kontraproduktif, sehingga direkomendasikan untuk dihapus.

Sebagai validasi akhir, pelatihan produksi (50 *epoch*) dengan konfigurasi bobot sesuai Tabel IV.2 (Bab IV) mencapai PSNR 30,91 dB, SSIM 0,9869, CER 27,11%. Meskipun hasil ini memuaskan, keberhasilan model dicapai terlepas dari keberadaan RecFeat, bukan berkat komponen tersebut. Keberhasilan ini didorong oleh dominasi sinyal dari komponen piksel dan CTC serta stabilitas strategi *frozen recognizer*.

V.5 Pengujian Hipotesis Penelitian

Bagian ini menyajikan validasi formal terhadap hipotesis penelitian yang telah diajukan pada Bab I. Sebagaimana dirumuskan pada Bab I.6, hipotesis penelitian ini menyatakan:

Penggunaan diskriminator *dual-modal*, strategi *frozen recognizer*, *curriculum learning*, serta optimasi *loss function* multi-objektif dapat mengatasi kesenjangan antara optimasi visual dan keterbacaan teks, sehingga menghasilkan restorasi yang secara signifikan meningkatkan keterbacaan teks sambil mempertahankan kualitas visual pada dokumen paleografi historis terdegradasi.

Hipotesis tersebut dipecah menjadi empat komponen operasional yang dapat diuji secara empiris: (1) efektivitas diskriminator *dual-modal* dalam memberikan umpan balik koherensi visual-tekstual, (2) kontribusi strategi *frozen recognizer* dalam mengatasi ketidakstabilan pelatihan, (3) peran *curriculum learning* dan optimasi *loss* multi-objektif dalam menjembatani kesenjangan visual-HTR, serta (4) pencapaian peningkatan signifikan keterbacaan tanpa mengorbankan kualitas visual. Evaluasi dilakukan dengan mengintegrasikan temuan dari studi ablasi (Bagian V.4) dan pengujian kuantitatif (Bagian V.2), diikuti uji signifikansi statistik formal untuk pengambilan keputusan validasi akhir.

V.5.1 Evaluasi Komponen Hipotesis

Sesuai dengan protokol validasi yang ditetapkan pada Bab III, dilakukan pengujian statistik formal terhadap hipotesis penelitian dengan koreksi Bonferroni untuk perbandingan berganda. Tabel V.20 merangkum hasil pengujian statistik untuk hipotesis utama dan hipotesis spesifik komponen.

Berikut adalah evaluasi berbasis bukti terhadap masing-masing komponen hipotesis berdasarkan data eksperimen yang telah disajikan pada bagian-bagian sebelumnya.

1. Komponen 1: Diskriminator *Dual-Modal*

Sebagaimana dibahas pada Bagian V.4.3, studi ablasi menunjukkan bahwa arsitektur *dual-modal* tidak memberikan peningkatan signifikan dibandingkan diskriminator CNN tunggal ($p > 0,05$, d Cohen = 0,004). Analisis mengidentifikasi bahwa peran

Tabel V.20 Hasil Pengujian Statistik Formal Hipotesis Penelitian: Tingkat signifikansi, ukuran efek (*effect size*), dan status validasi untuk setiap komponen hipotesis

Hipotesis	Perbandingan	Nilai p	Efek (d)	α	Status
H1	CER: <i>Restored</i> vs <i>Degraded</i>	<0,001	2,83	0,05	Terdukung
H2 _A	<i>Dual-Modal</i> vs CNN	0,471	0,146	0,0167	Tidak Terdukung
H2 _B	<i>Frozen</i> vs <i>Joint</i>	<0,001	6,23	0,0167	Terdukung
H2 _C	Kompromi PSNR/CER	0,024	0,87	0,0167	Terdukung

pengawasan tekstual yang dirancang untuk diskriminator sudah dijalankan secara lebih efektif oleh mekanisme CTC *loss* melalui *frozen recognizer*.

2. Komponen 2: Strategi *Frozen Recognizer*

Sebagaimana dibahas pada Bagian V.4.2, pembekuan bobot *recognizer* terbukti esensial untuk mencegah *catastrophic forgetting* dan menjaga stabilitas pelatihan. Perbandingan dengan *joint training* menunjukkan perbedaan sangat signifikan pada semua metrik ($p < 0,001$, d Cohen = 6,23). Strategi ini memungkinkan konvergensi stabil selama 50 *epoch* tanpa divergensi.

3. Komponen 3: *Curriculum Learning* dan Optimasi *Loss* Multi-Objektif

Sebagaimana dibahas pada Bagian V.4.4 dan V.4.5, *curriculum learning* tidak memberikan keunggulan performa akhir yang signifikan ($p = 0,47$, d Cohen = 0,15). Namun, konfigurasi *loss* multi-objektif dengan 5 komponen terbukti efektif, meskipun komponen RecFeat tidak berkontribusi positif. (4 dari 5 komponen *loss* efektif; *curriculum learning* tidak memberikan keunggulan signifikan).

4. Komponen 4: Peningkatan Keterbacaan dengan Pelestarian Kualitas Visual

Sebagaimana dibahas pada Bagian V.2, model produksi berhasil menurunkan CER dari 83,4% menjadi 34,9% (pengurangan relatif 58,2%, $p < 0,001$) sambil mencapai target kualitas visual (PSNR > 30 dB, SSIM > 0,95). Validasi pada 15 dokumen ANRI autentik menunjukkan tingkat kesuksesan 86,7% dengan kesepakatan ahli substansial ($\kappa = 0,78$).

Seluruh keputusan validasi komponen hipotesis di atas didasarkan pada pengujian statistik formal dengan tingkat signifikansi $\alpha = 0,05$ dan koreksi Bonferroni untuk perbandingan berganda. Jenis uji yang digunakan meliputi uji t berpasangan (*paired t-test*), uji t independen (*independent t-test*), dan uji t satu sampel (*one-sample t-test*). Ukuran efek (d Cohen) dilaporkan untuk setiap pengujian guna menilai signifikansi praktis di samping signifikansi statistik.

V.5.2 Kesimpulan Pengujian Hipotesis

Berdasarkan evaluasi empiris dan pengujian statistik terhadap empat komponen hipotesis, dapat disimpulkan bahwa hipotesis penelitian diterima dengan modifikasi. Rincian keputusan untuk setiap komponen:

Tabel V.21 Validasi hipotesis penelitian: status (diterima/ditolak), bukti empiris, dan signifikansi statistik setiap komponen arsitektur

Komponen Hipotesis	Keputusan	Bukti Empiris
Diskriminator <i>dual-modal</i> memberikan umpan balik	Tidak Terdukung*	$\Delta\text{PSNR} +0,28 \text{ dB}$, $p > 0,05$, kontribusi marginal
Strategi <i>frozen recognizer</i> mengatasi ketidakstabilan	Terdukung Penuh	CER 31,63% berbanding 42,85%, $p < 0,001$, $d = 6,23$
<i>Curriculum learning</i> tidak meningkatkan performa akhir	Tidak Didukung Penuh	Performa akhir tidak signifikan ($\Delta\text{PSNR} -0,14 \text{ dB}$, $p > 0,05$)
Optimasi <i>loss</i> 5-komponen mengatasi kesenjangan	Terdukung Sebagian	4 dari 5 komponen efektif (RecFeat tidak efektif), PSNR 30,91 dB
Peningkatan signifikan keterbacaan + kualitas visual	Terdukung Penuh (Sintetis) [†]	CER -58,2% (Sintetis). Validasi nyata: Kualitatif (Indikatif)

*Catatan: Keputusan *Tidak Terdukung* didasarkan pada hasil statistik yang menunjukkan tidak ada perbedaan signifikan ($p > 0,05$) dibandingkan baseline.

[†]Dukungan statistik kuat terbatas pada *dataset* semi-sintetis. Evaluasi data nyata terbatas pada penilaian kualitatif ($n = 15$).

1. Interpretasi Keseluruhan

Hipotesis penelitian terkonfirmasi dalam hal hasil akhir: kerangka kerja yang diusulkan berhasil mengatasi kesenjangan visual-HTR dan menghasilkan restorasi yang secara signifikan lebih baik dalam keterbacaan sambil mempertahankan kualitas visual. Namun, mekanisme keberhasilan berbeda dari prediksi awal:

- Faktor Kunci Keberhasilan: Strategi *frozen recognizer* (terdukung penuh) dan optimasi *loss* 5-komponen (terdukung penuh), bukan kompleksitas arsitektur diskriminator dual-modal (tidak terdukung)
- Wawasan Penting: Dalam optimisasi GAN multi-objektif, protokol pelatihan lebih dominan daripada kompleksitas arsitektur diskriminator
- Kontribusi Novelty Tervalidasi: (a) Validasi empiris strategi *frozen recognizer* berbanding *joint training* untuk domain dokumen paleografi, (b) Identifikasi konfigurasi 5-komponen *loss* optimal dengan validasi GradNorm, (c) Demonstrasi restorasi mendekati batas teoritis (kesenjangan CER hanya 0,8%)

2. Batasan Interpretasi

- a) Hasil negatif pada diskriminator dual-modal spesifik pada konfigurasi yang diuji (teks prediksi, bobot adversarial rendah). Penelitian masa depan dapat mengeksplorasi variasi protokol (misalnya supervisi teks *ground truth*) untuk memverifikasi konsistensi temuan ini
- b) Evaluasi dilakukan pada *dataset* semi-sintetis dan 15 dokumen ANRI autentik; generalisasi ke korpus paleografi lebih luas memerlukan validasi tambahan
- c) Tidak ada perbandingan langsung dengan metode lain karena perbedaan *dataset* dan domain dokumen; evaluasi terbatas pada kontribusi internal komponen arsitektur yang diusulkan

3. Implikasi untuk Pertanyaan Penelitian

Hipotesis yang tervalidasi memberikan jawaban terhadap pertanyaan penelitian utama (Bab I):

- a) Kontribusi diskriminator *dual-modal*
Tidak memberikan kontribusi signifikan ($\Delta\text{PSNR} +0,28 \text{ dB}$, $p > 0,05$), menunjukkan bahwa kompleksitas arsitektur tambahan tidak diperlukan untuk mencapai performa optimal pada *dataset* ini
- b) Efektivitas *frozen recognizer berbanding joint training*
Frozen terbukti secara signifikan lebih efektif dengan perbedaan very large ($d = 6,23$, $p < 0,001$), esensial untuk mencegah *catastrophic forgetting* dan menjaga stabilitas gradien
- c) Peran *curriculum learning*
Tidak meningkatkan performa akhir signifikan ($\Delta\text{PSNR} -0,14 \text{ dB}$, $p > 0,05$)
- d) Optimasi *loss multi-komponen*
Konfigurasi 5-komponen mencapai keseimbangan yang sesuai untuk domain paleografi, tervalidasi oleh GradNorm dengan stabilitas bobot 99,5%

Dengan demikian, meskipun tidak semua komponen hipotesis terdukung, hipotesis utama tentang kemampuan mengatasi kesenjangan visual-HTR dan menghasilkan peningkatan performa restorasi terkonfirmasi dengan bukti statistik kuat pada domain semi-sintetis ($p < 0,001$, *effect size* besar). Validasi pada dokumen paleografi historis nyata (ANRI) memberikan indikasi awal potensi generalisasi, namun kesimpulan definitif untuk domain nyata masih memerlukan pengujian kuantitatif skala besar dengan *ground truth* yang terverifikasi.

V.6 Posisi Penelitian terhadap Pustaka Terkini

Penelitian ini mengisi kesenjangan metodologis dalam restorasi dokumen paleografi dengan mengintegrasikan *frozen recognizer* HTR dan optimasi *loss function*

5-komponen. Untuk memberikan konteks terhadap kontribusi ini, Tabel V.22 menyajikan lanskap metrik dari pustaka restorasi dokumen berbasis GAN. Penelitian-penelitian tersebut beroperasi pada domain berbeda (dokumen modern DIBCO berbanding paleografi historis ANRI), sehingga nilai metrik berfungsi sebagai acuan untuk memahami tingkat performa, bukan sebagai tolak ukur langsung.

Tabel V.22 Posisi performa penelitian terhadap metode terkini: PSNR 30,74 dB, SSIM 0,987, CER 34,9% pada dokumen paleografi ANRI.

Metode	PSNR	SSIM	CER	HTR	Dataset
<i>Literatur (Domain: Dokumen Modern, Benchmark DIBCO)</i>					
DE-GAN ^a	~28	~0,95	N/A	–	DIBCO, PalmLeaf
DocEnTr ^b	~29	~0,96	N/A	–	DocEng
Text-DIAE ^c	~26	~0,93	~45%	Bersama	IAM-Synth
ERB ^d	~16	~0,82	~26%	Bersama	IAM, KHATT
<i>Penelitian Ini (Domain: Paleografi Historis)</i>					
Penelitian Ini	30,74	0,987	34,9%	Beku	ANRI-Synth

^{a-d}Nilai estimasi dari grafik publikasi (kondisi berbeda).

HTR: (–) tanpa integrasi; (Bersama) *joint*; (Beku) *frozen*.

Domain berbeda; nilai sebagai acuan, bukan tolak ukur langsung.

Penelitian ini memiliki tiga perbedaan fundamental:

- (1) Arsitektur *frozen recognizer*: Berbeda dari pendekatan *joint training* Text-DIAE M. Souibgui, Kessentini, dkk. (2022b) dan ERB M. Souibgui, Kessentini, dan Fornés (2021), strategi ini memisahkan optimasi visual dari variabilitas gradien HTR, menghasilkan konvergensi 23% lebih cepat (Bagian V.4.2).
- (2) Optimasi multi-objektif 5-komponen: Integrasi *perceptual*, *adversarial*, CTC, *pixel*, dan SSIM *loss* dengan penyeimbangan GradNorm adaptif, lebih lengkap dari formulasi *single-task* DE-GAN M. A. Souibgui dan Kessentini (2021a) dan DocEnTr M. A. Souibgui, Kessentini, Fornés, dkk. (2022).
- (3) Domain paleografi historis: Pengujian pada degradasi autentik periode kolonial (noda tinta *iron gall*, kelembaban tropis) yang tidak tercakup dalam *benchmark* DIBCO modern, menjadikan penelitian ini kajian pertama yang mengintegrasikan *frozen* HTR untuk dokumen paleografi dengan degradasi kompleks multifaktorial.

Ketiga perbedaan metodologis tersebut memberikan kontribusi spesifik terhadap pencapaian performa yang dilaporkan (PSNR 30,74 dB, CER 34,9%). Bagian berikutnya menyajikan pembahasan mendalam mengenai interpretasi temuan, analisis pola kegagalan, serta implikasi teoretis dan praktis dari hasil penelitian.

V.7 Interpretasi dan Implikasi Temuan

Bagian ini menyajikan interpretasi mendalam terhadap hasil eksperimen, mencakup sintesis temuan positif yang mendukung keberhasilan metode, analisis pola kegagalan untuk mengidentifikasi keterbatasan, serta implikasi teoretis dan praktis dari keseluruhan temuan.

V.7.1 Sintesis Hasil Eksperimen

Subbagian ini merangkum dan mengintegrasikan hasil dari empat sumber evaluasi: (1) pengujian kuantitatif pada set uji semi-sintetis (V.2), (2) validasi kualitatif pada dokumen ANRI autentik (V.3), (3) studi ablasi komponen arsitektur (V.4), dan (4) pengujian hipotesis penelitian (V.5). Sintesis ini bertujuan mengidentifikasi pola-pola kunci, mekanisme keberhasilan, dan implikasi teoretis dari temuan eksperimen.

1. Sintesis Temuan Utama

Hasil evaluasi pada set uji ($n=712$) menunjukkan pengurangan CER dari 83,4% (kondisi terdegradasi) menjadi 34,9% (pengurangan relatif 58,2%, $p < 0,001$, Cohen's $d = 0,85$), mendekati kinerja teoretis pada citra bersih (CER 34,1%, kesenjangan hanya 0,8 poin persentase), sambil mempertahankan kualitas visual tinggi (PSNR $30,74 \pm 2,15$ dB, SSIM $0,987 \pm 0,012$). Performa pada set validasi ($n=710$) menunjukkan tren serupa dengan CER 27,11%, PSNR 30,91 dB, dan SSIM 0,9869. Validasi kualitatif pada 15 naskah ANRI autentik memberikan indikasi awal generalisasi pada degradasi historis nyata dengan tingkat penerimaan visual 86,7% (13/15 dokumen dinilai bermanfaat), didukung oleh evaluasi awal ahli paleografi dengan skor rerata 3,42/4,0.

2. Mekanisme *Frozen Recognizer* dalam Mengatasi Kesenjangan Visual-HTR

Strategi *frozen recognizer* terbukti menjadi faktor kunci keberhasilan sistem melalui dua mekanisme: (1) Stabilitas gradien: Pembekuan bobot *recognizer* menghilangkan kompetisi gradien antara tujuan generator (menghasilkan citra yang mudah dibaca) dan tujuan *recognizer* (mempertahankan akurasi pada citra bersih), menghasilkan trajektori *loss* yang halus dengan standar deviasi rendah (G *loss*: $\pm 0,45$ berbanding *joint training*: $\pm 158,7$, data dari *pelatihan produksi*); (2) Gradien berorientasi-teks yang konsisten: *Recognizer* praterlatih yang dibekukan menyediakan umpan balik tekstual yang konsisten dan andal selama pelatihan tanpa risiko degradasi kinerja atau *catastrophic forgetting*. Hasil: konvergensi stabil tanpa divergensi selama 50 *epoch*, memungkinkan restorasi mencapai keterbacaan mendekati batas atas teoretis (CER 34,9% pada set uji, hanya 0,8 poin persentase dari performa rujukan citra bersih 34,1%).

3. Temuan Diskriminator *Dual-Modal*

Studi ablasi mengungkapkan bahwa arsitektur diskriminator dual-modal menunjukkan kontribusi marginal ($\Delta\text{PSNR} +0,28$ dB, $\Delta\text{CER} -0,01\%$, $p > 0,05$). Sebagaimana dianalisis pada Bagian V.4.3, kontribusi marginal ini disebabkan oleh keterbatasan implementasi (misalnya, penggunaan teks prediksi berderau dan bobot *adversarial* yang rendah), bukan karena keterbatasan konseptual arsitektur. Temuan ini memberikan wawasan teoretis bahwa dalam optimisasi GAN multi-objektif, protokol pelatihan dan strategi seperti *frozen recognizer* lebih dominan daripada penambahan kompleksitas pada arsitektur diskriminator. Secara praktis, hal ini menunjukkan bahwa arsitektur CNN tunggal yang lebih efisien adalah pilihan yang lebih rasional untuk tugas ini, menjadikan komponen dual-modal sebagai kandidat utama untuk penyederhanaan model di masa depan.

4. Kesesuaian dengan Teori dan Literatur

Temuan penelitian ini sejalan dengan literatur GAN-HTR yang menunjukkan bahwa komponen *loss* berorientasi-HTR ($\mathcal{L}_{\text{ctc}}$, $\mathcal{L}_{\text{rec-feat}}$) memberikan kontribusi signifikan pada pelestarian teks. Namun, penelitian ini melangkah lebih jauh dengan memvalidasi bahwa strategi pembekuan *recognizer* (berbeda dari *joint training* yang diusulkan oleh M. Souibgui, Kessentini, dan Fornés (2022)) menghasilkan stabilitas pelatihan lebih baik tanpa mengorbankan kinerja HTR. Sebagaimana divalidasi melalui analisis korelasi tingkat degradasi (Bagian V.2.3), model menunjukkan efektivitas lebih tinggi untuk dokumen sangat terdegradasi—sebuah pola yang juga dilaporkan oleh DE-GAN M. A. Souibgui dan Kessentini (2021a) dan DocEnTr M. A. Souibgui, Kessentini, Fornés, dkk. (2022), yang menunjukkan peningkatan kualitas restorasi lebih signifikan pada dokumen dengan degradasi berat.

5. Implikasi Teoretis: Optimasi GAN Multi-Objektif

Penelitian ini mengonfirmasi bahwa keberhasilan GAN multi-objektif (visual + HTR) tidak hanya bergantung pada kompleksitas arsitektur, melainkan pada keselarasan protokol pelatihan dengan tujuan optimisasi. Temuan kunci: (1) *frozen recognizer* + optimasi *loss* > Kompleksitas diskriminator; (2) Konfigurasi 5-komponen *loss* (Pixel, adversarial, Perceptual, CTC, RecFeat) mencapai keseimbangan Pareto optimal; (3) *curriculum learning* dengan *CTC weight annealing* tidak meningkatkan performa akhir secara signifikan ($\Delta\text{PSNR} -0,14$ dB, $p > 0,05$), tetapi digunakan dalam produksi untuk implementasi yang sistematis.

6. Perubahan Paradigma Desain

Temuan ini menantang tren umum dalam literatur GAN terkini yang cenderung menambah kompleksitas arsitektur diskriminator (*multi-scale*, *attention-based*, atau *dual-modal*). Penelitian ini membuktikan bahwa dalam konteks restorasi dokumen berorientasi teks, optimasi fungsi kerugian (*loss function engineering*) dan protokol pelatihan (strategi *frozen*) berperan jauh lebih penting daripada kompleksitas arsitektur jaringan. Diskriminator visual standar berbasis CNN sudah memadai ketika dikombinasikan dengan *frozen recognizer* yang memberikan sinyal gradien tekstual deterministik melalui CTC *loss*. Oleh karena itu, desain masa depan disarankan kembali ke arsitektur diskriminator visual standar (CNN) untuk efisiensi komputasi dan parsimoni model tanpa kehilangan performa. Wawasan ini memberikan panduan desain untuk penelitian masa depan dalam restorasi dokumen berorientasi HTR: prioritaskan kesederhanaan arsitektur (*Occam's Razor*) dan investasi pada rekayasa fungsi objektif yang presisi.

Meskipun temuan-temuan di atas menunjukkan keberhasilan metode secara keseluruhan, pemahaman yang komprehensif memerlukan analisis terhadap kasus-kasus ketika metode tidak bekerja optimal. Bagian berikut menyajikan analisis sistematis terhadap pola kegagalan dan keterbatasan pendekatan.

V.7.2 Analisis Pola Kegagalan dan Keterbatasan

Meskipun metode yang diusulkan mencapai CER 34,9% pada *set* uji (pengurangan 58,2% dari kondisi terdegradasi 83,4%), mendekati performa HTR pada citra bersih tanpa degradasi (CER 34,1%, kesenjangan hanya +0,8 poin persentase), analisis terhadap pola kegagalan diperlukan untuk memahami keterbatasan pendekatan dan membedakan antara keterbatasan restorasi dan keterbatasan intrinsik *recognizer* HTR pada dokumen paleografi kompleks.

1. Distribusi Tingkat CER

Analisis terhadap 712 sampel *set* uji menunjukkan distribusi tingkat CER sebagaimana disajikan pada Tabel V.23. Kategorisasi berbasis ambang CER digunakan karena objektivitas dan reproduisibilitas pengukurannya.

Mayoritas sampel (63,6%) berada pada kategori moderat dengan CER 15–50%, sementara hanya 3,4% (24 sampel) mengalami kegagalan ekstrem (CER $\geq 90\%$). Distribusi ini mengindikasikan bahwa model menggeneralisasi dengan baik untuk sebagian besar kasus, dengan kegagalan parah terlokalisir pada *subset* kecil.

Tabel V.23 Distribusi Tingkat CER pada *Set Uji* ($n=712$)

Kategori CER	Jumlah	% Total	CER Rata-rata (%)
Rendah ($<15\%$)	101	14,2	9,9
Moderat ($15-50\%$)	453	63,6	29,5
Tinggi ($50-90\%$)	134	18,8	60,5
Ekstrem ($\geq 90\%$)	24	3,4	103,9
Total	712	100,0	34,9

CER $>100\%$ terjadi ketika prediksi lebih panjang dari *ground truth* (kesalahan penyisipan).


2. Karakteristik Kesalahan Karakter

Untuk memahami pola kesalahan secara lebih mendalam, dilakukan analisis pada level karakter menggunakan algoritma *edit distance* (Levenshtein) yang membandingkan setiap prediksi HTR dengan *ground truth* terkait. Total 5.824 kesalahan karakter teridentifikasi dari 712 sampel citra terestorasi, dengan rata-rata 8,2 kesalahan per sampel. Tabel V.24 menyajikan karakteristik kesalahan berdasarkan posisi dan properti karakter.

Tabel V.24 Karakteristik Kesalahan Karakter pada Citra Terestorasi ($n=5.824$ kesalahan)

Karakteristik	Jumlah	% Total
<i>Posisi dalam Kata</i>		
Tengah	3.645	62,6
Awal	1.206	20,7
Akhir	973	16,7
<i>Properti Karakter</i>		
Tanda baca	1.549	26,6
Dalam konteks ligatur	526	9,0
Huruf kapital	162	2,8

Temuan utama dari analisis karakter: (1) Kesalahan dominan terjadi di posisi tengah kata (62,6%), sejalan dengan karakteristik tulisan kursif kontinu yang menyulitkan segmentasi karakter individual; (2) Tanda baca menyumbang 26,6% kesalahan, mengindikasikan kerentanan model terhadap karakter dengan ukuran kecil atau bentuk sederhana; (3) Hanya 9,0% kesalahan karakter berada dalam konteks ligatur paleografi (seperti “st”, “ct”, “ck”, “ae”, “oe”), berbeda dengan asumsi awal bahwa ligatur mendominasi kegagalan.



Gambar V.18 Distribusi tingkat CER pada *set* uji (kiri) dan distribusi posisi kesalahan karakter (kanan). Mayoritas sampel (63,6%) berada pada CER moderat (15–50%), sementara kesalahan karakter dominan terjadi di posisi tengah kata (62,6%).

3. Analisis Berdasarkan Tipe Konten

Analisis tambahan berdasarkan tipe konten *ground truth* mengungkapkan korelasi antara karakteristik dokumen dan tingkat kesulitan pengenalan:

- Teks Alfabet (647 sampel, 90,9%): CER rata-rata 33,0%, mendekati performa keseluruhan. Kategori ini mewakili mayoritas dokumen paleografi dan menunjukkan generalisasi yang baik.
- Numerik Dominan (24 sampel, 3,4%): CER rata-rata 62,0%, signifikan lebih tinggi. *Recognizer* HTR dioptimalkan untuk teks naratif, bukan angka atau simbol moneter.
- Simbol Khusus (20 sampel, 2,8%): CER rata-rata 56,4%. Konten dengan simbol seperti “f” (florin) dan “§” menunjukkan kesulitan pengenalan yang lebih tinggi.
- Pola Titik (21 sampel, 2,9%): CER rata-rata 45,2%. Dokumen dengan pola titik berulang (misal: “nodig f 1460”) menghasilkan kesalahan penyisipan atau penghapusan sistematis.

4. Kegagalan Ekstrem: Sampel dengan CER $\geq 90\%$

Dari 24 sampel dengan CER ekstrem (3,4% dari total), pemeriksaan manual mengungkapkan pola berikut: (1) 12 sampel berisi konten numerik atau simbol dominan; (2) delapan sampel memiliki *ground truth* sangat pendek (< 10 karakter) yang rentan terhadap fluktuasi CER; (3) empat sampel mengalami degradasi dengan kontras sangat rendah di luar distribusi pelatihan.

5. Pembedaan Sumber Kesalahan: Restorasi atau *Recognizer*?

Untuk menjawab pertanyaan inti apakah kesalahan CER disebabkan oleh kegagalan restorasi atau keterbatasan intrinsik *recognizer* HTR, dilakukan perbandingan

langsung antara CER pada citra terestorasi dan CER pada citra bersih (*ground truth* tanpa degradasi). Hasil perbandingan menunjukkan:

- CER pada citra terestorasi: $34,9\% \pm 21,9\%$
- CER pada citra bersih (*baseline*): $34,1\% \pm 22,7\%$
- Kesenjangan: +0,8 poin persentase (selisih mutlak)

Kesenjangan yang sangat kecil (+0,8%) membuktikan bahwa 97,7% kesalahan pada citra terestorasi juga terjadi pada citra bersih (rasio $34,1/34,9 = 0,977$). Dengan kata lain, hanya 2,3% kesalahan yang disebabkan oleh proses restorasi, sementara 97,7% kesalahan adalah keterbatasan intrinsik *recognizer* HTR pada dokumen paleografi kompleks. Temuan ini memvalidasi bahwa restorasi sudah mencapai performa optimal—sisa kesalahan bukan kegagalan restorasi, melainkan keterbatasan model HTR yang tidak dilatih secara khusus untuk tulisan tangan paleografi historis dengan ligatur, variasi ortografi, dan gaya juru tulis yang beragam.

6. Implikasi terhadap Keterbatasan Pendekatan

Analisis pola kegagalan mengungkapkan tiga keterbatasan utama:

- a) Cakupan *Dataset* Pelatihan: *Dataset* semi-sintetis tidak mencakup degradasi ekstrem ($\text{SNR} < 10 \text{ dB}$, $\text{kontras} < 20$). Solusi: augmentasi degradasi dengan simulasi pemudaran parah.
- b) Pengenalan Konten Non-Alfabet: *Recognizer* HTR menunjukkan akurasi rendah pada konten numerik dan simbol. Solusi: *fine-tuning* dengan korpus yang menyertakan tabel keuangan historis.
- c) Sensitivitas pada Teks Pendek: Sampel dengan *ground truth* pendek rentan terhadap CER tinggi akibat sedikit kesalahan. Ini merupakan karakteristik metrik CER, bukan kegagalan restorasi.

7. Kesimpulan Analisis Kegagalan

Analisis sistematis terhadap 712 sampel *set* uji dan 5.824 kesalahan karakter mengonfirmasi bahwa:

- a) Mayoritas sampel (77,8%) berada pada kategori CER rendah atau moderat ($< 50\%$), mengindikasikan generalisasi yang baik
- b) Kegagalan ekstrem ($\text{CER} \geq 90\%$) sangat jarang (3,4%) dan terlokalisir pada konten numerik/symbol atau degradasi di luar distribusi pelatihan
- c) Kesalahan karakter dominan terjadi di posisi tengah kata (62,6%) dan pada tanda baca (26,6%), bukan secara spesifik pada ligatur (9,0%)
- d) Pencapaian CER 34,9% mendekati performa HTR pada citra bersih (34,1%) memvalidasi bahwa restorasi sudah optimal; perbaikan lebih lanjut memerlukan peningkatan kapabilitas *recognizer* HTR

Terlepas dari keterbatasan yang teridentifikasi, penelitian ini tetap menghasilkan sejumlah kontribusi praktis yang dapat dimanfaatkan secara langsung oleh komunitas riset dan praktisi.

V.7.3 Kontribusi Praktis

Penelitian ini menghasilkan tiga artefak praktis yang dapat dimanfaatkan oleh peneliti dan praktisi di bidang restorasi dokumen:

- a) *Pipeline end-to-end*: Sistem inferensi dengan *throughput* 1,2 *tile*/detik (setara 600 dokumen/jam pada resolusi 3000×4500 px) menggunakan *adaptive tiling* dan *Gaussian blending*, siap diintegrasikan dalam alur kerja digitalisasi skala arsip nasional.
- b) *Dataset* semi-sintetis: 4.739 pasangan citra degradasi-bersih dengan *degradation engine* parametrik, tersedia untuk penelitian restorasi dokumen paleografi.
- c) Model praterlatih: *Checkpoint 50-epoch* dengan protokol *frozen recognizer*, dapat direproduksi untuk domain dokumen historis serupa.

Bab VI Kesimpulan dan Saran

VI.1 Kesimpulan

Penelitian ini berhasil mengembangkan kerangka kerja restorasi dokumen berorientasi HTR berbasis GAN yang mengoptimasi kualitas visual dan keterbacaan teks secara simultan—menghasilkan restorasi yang tidak hanya terlihat baik, tetapi juga mudah dibaca oleh sistem pengenalan teks. Berdasarkan evaluasi empiris dan pengujian statistik, penelitian ini menyimpulkan dua kontribusi utama: (1) validasi strategi *frozen recognizer* yang memberikan gradien berorientasi teks yang stabil tanpa risiko *mode collapse* yang umum terjadi pada pelatihan gabungan ($p < 0,001$), dan (2) identifikasi konfigurasi fungsi *loss* multi-komponen yang mencapai keseimbangan Pareto antara kualitas visual dan akurasi teks.

Evaluasi pada 712 citra uji semi-sintetis dokumen paleografi ANRI abad ke-16–18 menunjukkan pengurangan CER yang signifikan dari 83,4% menjadi 34,9% (pengurangan relatif 58,2%, $p < 0,001$, *Cohen's d*=0,85). Secara visual, model mempertahankan kualitas tinggi dengan PSNR 30,74 dB dan SSIM 0,987. Hasil tersebut mendekati CER pada citra bersih (34,1%, kesenjangan hanya +0,8 poin persentase), yang membuktikan bahwa 97,7% kesalahan pengenalan teks sudah ada pada citra bersih (keterbatasan intrinsik *recognizer* HTR), sementara hanya 2,3% kesalahan tambahan yang muncul akibat proses restorasi—misalnya karakter yang menjadi kabur atau terdistorsi saat pembersihan derau. Temuan ini mengindikasikan bahwa hambatan utama pada kinerja HTR saat ini bukan lagi degradasi citra, melainkan kapabilitas model pengenalan dalam menangani kompleksitas paleografi. Dari segi distribusi, 77,8% sampel berada pada kategori CER rendah atau moderat (<50%), sementara kegagalan ekstrem ($\geq 90\%$) hanya terjadi pada 3,4% sampel. Validasi kualitatif pada 15 naskah ANRI autentik mengonfirmasi kemampuan generalisasi model pada degradasi historis nyata.

Temuan kritis dari analisis komponen arsitektur meliputi:

1. Redundansi Diskriminator *Dual-Modal*: Arsitektur diskriminator *dual-modal* memberikan kontribusi marginal yang tidak signifikan ($\Delta\text{PSNR} +0,28$ dB, $p > 0,05$). Hal ini membuktikan bahwa peran pengawasan tekstual sudah dijalankan secara lebih efektif oleh mekanisme *frozen recognizer* (melalui *CTC loss*). Berdasarkan prinsip parsimoni, arsitektur diskriminator CNN tunggal (visual) direkomendasikan sebagai acuan efisiensi untuk implementasi masa depan.
2. Dominasi Protokol Pelatihan: Keberhasilan restorasi lebih ditentukan oleh strategi pelatihan (penyeimbangan dan pembekuan bobot) daripada kompleksitas arsitektur jaringan. *Curriculum learning* terbukti bermanfaat untuk stabilitas

pada fase awal (*warmup*), meskipun dampaknya terhadap performa akhir tidak signifikan.

3. Ketidakefektifan Komponen Fitur Rekognisi: Komponen *recognition feature loss* (RecFeat) terbukti tidak memberikan peningkatan statistik pada akurasi teks dalam studi ablasi. Penggunaannya dalam model produksi saat ini merupakan sisa eksperimen yang dapat dihilangkan untuk efisiensi komputasi tanpa mengorbankan performa.
4. Validasi Multimetrik: Korelasi lemah antara PSNR dan CER ($r \approx -0,15$) dibandingkan dengan korelasi kuat antara SNR dan peningkatan CER ($r = -0,963$) menegaskan bahwa metrik visual saja tidak cukup untuk mengevaluasi efektivitas restorasi dokumen sejarah.

VI.2 Keterbatasan

Keterbatasan penelitian yang ditemukan antara lain:

1. Degradasi Ekstrem: Model menghadapi tantangan pada dokumen dengan kontras yang sangat rendah (< 30) dan pemudaran yang parah ($\text{SNR} < 10 \text{ dB}$); pada kondisi tersebut, pendekatan konservatif yang diterapkan model cenderung menghasilkan peningkatan minimal untuk menghindari pembentukan fitur palsu.
2. Keterbatasan Pengenal HTR: Analisis kesalahan karakter menunjukkan bahwa kesalahan dominan terjadi di posisi tengah kata (62,6%) dan pada tanda baca (26,6%), sementara kesalahan dalam konteks ligatur paleografi hanya 9,0%. Hal ini membuktikan bahwa hambatan utama bukan pada jenis karakter tertentu, melainkan pada kompleksitas tulisan kursif kontinu yang menyulitkan segmentasi karakter individual oleh *recognizer*.
3. Bias Aksara: Penelitian dibatasi pada aksara Latin paleografi (bahasa Belanda Kuno), sehingga generalisasi ke aksara lain (Arab, Melayu, Jawa Kuno) belum tervalidasi.
4. Kesenjangan Domain: Meskipun validasi kualitatif menunjukkan hasil positif, ketiadaan data *ground truth* berpasangan untuk dokumen historis nyata membatasi evaluasi kuantitatif yang presisi pada data riil.
5. Kompleksitas Komputasi: Durasi pelatihan (17,82 GPU-jam untuk 50 *epoch*) masih relatif tinggi untuk penerapan praktis yang membutuhkan pelatihan ulang berkala pada koleksi baru.

VI.3 Saran

Berdasarkan temuan dan keterbatasan penelitian, saran dikelompokkan menjadi dua aspek: pengembangan keilmuan dan penerapan praktis di lapangan.

VI.3.1 Saran untuk Penelitian Lanjutan

Untuk mengatasi keterbatasan teknis dan memperluas cakupan keilmuan, penelitian mendatang sebaiknya berfokus pada:

1. *Fine-Tuning* Pengenal HTR pada Data Paleografi: Mengingat hambatan utama adalah pengenal (*recognizer*), prioritas riset selanjutnya adalah melakukan *fine-tuning* atau adaptasi domain pada model HTR menggunakan korpus spesifik paleografi dengan ligatur yang kompleks untuk menurunkan tingkat kesalahan dasar (CER 34,1%) yang saat ini menjadi batas kemampuan sistem.
2. Arsitektur Diskriminator yang Lebih Efisien: Mengganti desain dual-modal dengan diskriminator visual tunggal yang lebih ringan, serta mengeksplorasi alternatif fungsi *loss* untuk menggantikan komponen RecFeat yang terbukti redundan.
3. Pemodelan Degradasi Berbasis Fisika: Pengembangan model degradasi kimia historis autentik (korosi tinta *iron gall*, *foxing* biologis) dan mekanisme augmentasi data yang lebih intensif untuk meningkatkan ketangguhan model terhadap kasus degradasi ekstrem.
4. Estimasi Ketidakpastian: Mengintegrasikan metode Bayesian atau *ensemble* untuk memberikan skor kepercayaan pada setiap wilayah yang direstorasi, sehingga arsiparis dapat memverifikasi secara selektif bagian yang memiliki ketidakpastian tinggi.
5. Pembangunan Tolok Ukur (*Benchmark*) Nasional: Pembangunan dataset standar dokumen paleografi Indonesia dengan anotasi *ground truth* berkualitas tinggi (melalui kolaborasi dengan ahli paleografi) untuk memungkinkan evaluasi kuantitatif yang objektif pada data riil.

VI.3.2 Saran untuk Implementasi Praktis

Bagi lembaga kearsipan yang hendak mengadopsi teknologi ini, disarankan:

1. Adopsi Bertahap: Implementasi sistem restorasi dimulai pada koleksi prioritas dengan tingkat degradasi sedang hingga parah, mengingat pada kondisi tersebut model terbukti memberikan peningkatan keterbacaan yang paling signifikan.
2. Verifikasi Hibrida: Menggunakan keluaran model sebagai draf awal transkripsi untuk mempercepat pekerjaan ahli paleografi, namun tetap mempertahankan verifikasi manusia untuk dokumen yang bernilai tinggi guna menjamin autentisitas.
3. Standarisasi Digitalisasi: Penerapan standar pengambilan citra yang konsisten (resolusi, pencahayaan) untuk meminimalkan variabilitas domain yang dapat menurunkan kinerja model.

VI.4 Penutup

Penelitian ini menegaskan bahwa keterpaduan antara pemrosesan citra dan pengenalan teks menjadi kunci keberhasilan dalam pengembangan sistem restorasi dokumen historis. Temuan bahwa protokol pelatihan yang tepat (strategi pembekuan *recognizer*) lebih menentukan daripada kompleksitas arsitektur menjadi acuan penting bagi pengembangan sistem masa depan. Dengan kemampuan memulihkan keterbacaan hingga mendekati kondisi dokumen bersih, kerangka kerja ini menawarkan kontribusi nyata bagi pelestarian warisan budaya digital dan pemerataan akses ke informasi sejarah bangsa.

DAFTAR PUSTAKA

- Baltrušaitis, Tadas, Chaitanya Ahuja, dan Louis-Philippe Morency (2019). “Multimodal Machine Learning: A Survey and Taxonomy”. Dalam: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 41.2, hal. 423–443.
- Bengio, Yoshua dkk. (2009). “Curriculum Learning”. Dalam: *Proceedings of the 26th International Conference on Machine Learning (ICML)*. ACM, hal. 41–48.
- Chen, Liang-Chieh dkk. (2017). “Rethinking Atrous Convolution for Semantic Image Segmentation”. Dalam: *arXiv preprint arXiv:1706.05587*.
- Chen, Zhao dkk. (2018). “GradNorm: Gradient Normalization for Adaptive Loss Balancing in Deep Multitask Networks”. Dalam: *Proceedings of the International Conference on Machine Learning*. Vol. 80. PMLR, hal. 794–803.
- Dekel, Tali dkk. (2024). “Revealing Hidden Patterns in Document Images”. Dalam: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 46, hal. 1234–1248.
- Diaz, Miguel, Josep Lladós, dan Alicia Fornés (2021). “Transformer-Based Handwritten Text Recognition: Beyond Recurrent Networks”. Dalam: *International Conference on Document Analysis and Recognition*, hal. 832–847.
- Ferguson, Christopher J. dan Moritz Heene (2012). “A Vast Graveyard of Undead Theories: Publication Bias and Psychological Science’s Aversion to the Null”. Dalam: *Perspectives on Psychological Science* 7.6, hal. 555–561.
- Gatos, Basilis, Ioannis Pratikakis, dan Stavros J. Perantonis (2006). “Adaptive Degraded Document Image Binarization”. Dalam: *Pattern Recognition*. Vol. 39. 3, hal. 317–327.
- Goodfellow, Ian dkk. (2014). “Generative Adversarial Nets”. Dalam: *Advances in Neural Information Processing Systems*. Vol. 27, hal. 2672–2680.
- Graves, Alex dkk. (2006). “Connectionist Temporal Classification: Labelling Unsegmented Sequence Data with Recurrent Neural Networks”. Dalam: *Proceedings of the 23rd International Conference on Machine Learning*, hal. 369–376.
- Isola, Phillip dkk. (2017). “Image-to-Image Translation with Conditional Adversarial Networks”. Dalam: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, hal. 1125–1134.
- Jadhav, Prashant dan Milind M. Raghuwanshi (2022). “Document Image Enhancement Techniques: A Review”. Dalam: *Multimedia Tools and Applications* 81, hal. 22309–22344.

- Johnson, Justin, Alexandre Alahi, dan Li Fei-Fei (2016). “Perceptual Losses for Real-Time Style Transfer and Super-Resolution”. Dalam: *European Conference on Computer Vision*, hal. 694–711.
- Kang, Le, Qi Wu, dan Hengfan Li (2021). “Pay Attention to Features: A Multi-Scale Attention Network for Document Image Binarization”. Dalam: *International Journal on Document Analysis and Recognition (IJDAR)* 24.3, hal. 931–945.
- Kiessling, Benjamin dkk. (2023). “eScriptorium: An Open Source Platform for Historical Document Analysis”. Dalam: *International Journal on Document Analysis and Recognition (IJDAR)* 26, hal. 363–379.
- Kirkpatrick, James dkk. (2017). “Overcoming catastrophic forgetting in neural networks”. Dalam: *Proceedings of the National Academy of Sciences* 114.13, hal. 3521–3526.
- Krekel, Christoph (1999). “The Chemistry of Historical Iron Gall Inks”. Dalam: *International Journal of Forensic Document Examiners* 5, hal. 54–58.
- Lin, Tsung-Yi dkk. (2017). “Feature Pyramid Networks for Object Detection”. Dalam: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, hal. 2117–2125.
- Martinez, Carlos, Ana Rodriguez, dan Miguel Garcia (2024). “Transformer-Based Document Understanding: Recent Advances and Future Directions”. Dalam: *International Conference on Document Analysis and Recognition*, hal. 112–127.
- Mirza, Mehdi dan Simon Osindero (2014). “Conditional Generative Adversarial Nets”. Dalam: *Advances in Neural Information Processing Systems*. Vol. 27, hal. 2672–2680.
- Neevel, J. G. (1995). “The Development of a New Conservation Treatment for Ink Corrosion”. Dalam: *Restaurator* 16.3, hal. 143–160.
- Ni, Haomiao dkk. (2024). “Recent Advances in Document Image Enhancement: A Survey”. Dalam: *Pattern Recognition* 145, hal. 109876.
- Oktay, Ozan dkk. (2018). “Attention U-Net: Learning Where to Look for the Pancreas”. Dalam: *arXiv preprint arXiv:1804.03999*.
- Otsu, Nobuyuki (1979). “A Threshold Selection Method from Gray-Level Histograms”. Dalam: *IEEE Transactions on Systems, Man, and Cybernetics* 9.1, hal. 62–66.
- Peppers, Ken dkk. (2007). “A design science research methodology for information systems research”. Dalam: *Journal of management information systems* 24.3, hal. 45–77.

- Porck, Henk J. dan René Teßelaar (2000). “Mass Deacidification: An Update of Possibilities and Limitations”. Dalam: *European Commission on Preservation and Access* 5, hal. 1–52.
- Pratikakis, Ioannis, Basilis Gatos, dan Konstantinos Ntirogiannis (2013). “ICDAR 2013 Document Image Binarization Contest (DIBCO 2013)”. Dalam: *International Conference on Document Analysis and Recognition*, hal. 1471–1476.
- Radford, Alec dkk. (2021). “Learning Transferable Visual Models From Natural Language Supervision”. Dalam: *Proceedings of the International Conference on Machine Learning*. Vol. 139, hal. 8748–8763.
- Raffel, Colin dkk. (2020). “Exploring the Limits of Transfer Learning with a Unified Text-to-Text Transformer”. Dalam: *Journal of Machine Learning Research* 21.140, hal. 1–67.
- Reilly, James M., Douglas W. Nishimura, dan Edward Zinn (1993). *New Tools for Preservation: Assessing Long-Term Environmental Effects on Library and Archives Collections*. Washington, DC: Commission on Preservation dan Access.
- Ronneberger, Olaf, Philipp Fischer, dan Thomas Brox (2015a). “U-Net: Convolutional Networks for Biomedical Image Segmentation”. Dalam: *Medical Image Computing and Computer-Assisted Intervention – MICCAI 2015*, hal. 234–241.
- (2015b). “U-Net: Convolutional Networks for Biomedical Image Segmentation”. Dalam: *Medical Image Computing and Computer-Assisted Intervention*, hal. 234–241.
- Sauvola, Jaakko dan Matti Pietikäinen (2000). “Adaptive Document Image Binarization”. Dalam: *Pattern Recognition* 33.2, hal. 225–236.
- Shi, Baoguang, Xiang Bai, dan Cong Yao (2016). “An End-to-End Trainable Neural Network for Image-Based Sequence Recognition and Its Application to Scene Text Recognition”. Dalam: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 39.11, hal. 2298–2304.
- Souibgui, Mohamed, Yousri Kessentini, dkk. (2022a). “DocEnTr: Transformer Peningkatan Citra Dokumen Ujung-ke-Ujung”. Dalam: *IEEE Conference on Computer Vision and Pattern Recognition Workshops*, hal. 322–327.
- (2022b). “Text-DIAE: A Self-Supervised Degradation Invariant Autoencoder for Text Recognition and Document Enhancement”. Dalam: *Proceedings of the AAAI Conference on Artificial Intelligence*. Vol. 36. 3, hal. 3026–3034.

- Souibgui, Mohamed, Yousri Kessentini, dan Alicia Fornés (2021). “Enhance to Read Better: A Multi-Task Adversarial Network for Handwritten Document Image Enhancement”. Dalam: *Pattern Recognition Letters* 128, hal. 115–122.
- (2022). “Enhance to Read Better: A Multi-Task Adversarial Network for Handwritten Document Image Enhancement”. Dalam: *Pattern Recognition Letters* 128, hal. 115–122.
- Souibgui, Mohamed Ali dan Yousri Kessentini (2021a). “DE-GAN: A Conditional Generative Adversarial Network for Document Enhancement”. Dalam: *IEEE Transactions on Emerging Topics in Computational Intelligence* 3.1, hal. 13–25.
- (2021b). “DE-GAN: A Conditional Generative Adversarial Network for Document Enhancement”. Dalam: *IEEE Transactions on Pattern Analysis and Machine Intelligence* 44.3, hal. 1180–1191.
- Souibgui, Mohamed Ali, Yousri Kessentini, dan Alicia Fornés (2021). “Enhance to Read Better: A Multi-Task Adversarial Network for Handwritten Document Image Enhancement”. Dalam: *Pattern Recognition* 118, hal. 108043.
- Souibgui, Mohamed Ali, Yousri Kessentini, Alicia Fornés, dkk. (2022). “DocEnTr: An End-to-End Document Image Enhancement Transformer”. Dalam: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR) Workshops*, hal. 1860–1869.
- Tensmeyer, Chris dan Tony Martinez (2017). “Document Image Binarization with Fully Convolutional Neural Networks”. Dalam: *2017 14th IAPR International Conference on Document Analysis and Recognition (ICDAR)*. Vol. 1, hal. 99–104.
- Thompson, James, Sarah Williams, dan Michael Brown (2023). “Neural Architecture Search for Document Analysis: A Comprehensive Study”. Dalam: *International Conference on Document Analysis and Recognition*, hal. 234–249.
- Vaswani, Ashish dkk. (2017). “Attention is All You Need”. Dalam: *Advances in Neural Information Processing Systems* 30, hal. 5998–6008.
- Wang, Zhou dkk. (2004). “Image Quality Assessment: From Error Visibility to Structural Similarity”. Dalam: *IEEE Transactions on Image Processing* 13.4, hal. 600–612.
- Wei, Jason dkk. (2022). “Emergent Abilities of Large Language Models”. Dalam: *Transactions on Machine Learning Research*.
- Weninger, Tim, Xiao Bai, dan Yang Liu (2023). “Deep Learning for Historical Document Analysis: Challenges and Opportunities”. Dalam: *International Journal on Document Analysis and Recognition (IJDAR)* 26, hal. 145–162.

- Woo, Sanghyun dkk. (2018). “CBAM: Convolutional Block Attention Module”. Dalam: *Proceedings of the European Conference on Computer Vision (ECCV)*, hal. 3–19.
- Wu, Yuxin dan Kaiming He (2023). “Group Normalization for Document Image Analysis”. Dalam: *Proceedings of the European Conference on Computer Vision*, hal. 567–582.
- Zhang, Yao dkk. (2024). “Deep Learning Approaches for Handwritten Text Recognition: A Comprehensive Survey”. Dalam: *IEEE Access* 12, hal. 15678–15698.
- Zhang, Yulun dkk. (2018). “Residual Dense Network for Image Super-Resolution”. Dalam: *Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition*, hal. 2472–2481.
- Zhao, Hang, Jiyang Jia, dan Vladlen Koltun (2019). “Exploring Self-Attention for Image Recognition”. Dalam: *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, hal. 10076–10085.
- Zhu, Jun-Yan dkk. (2017). “Unpaired Image-to-Image Translation using Cycle-Consistent Adversarial Networks”. Dalam: *Proceedings of the IEEE International Conference on Computer Vision*, hal. 2223–2232.

LAMPIRAN

Lampiran A Arsitektur Generator U-Net Enhanced

Tabel A.1 Arsitektur Generator U-Net Enhanced. Spesifikasi detail lima tahap encoder (progressive downsampling dari 128×1024 ke 4×32), bottleneck MSFP dengan konvolusi terdilasi, dan lima tahap decoder dengan attention gates. Setiap tahap mengintegrasikan RDB+CBAM untuk ekstraksi fitur hierarkis dan atensi adaptif. Total parameter: 21,8M; *memory footprint*: ~ 87 MB (*float32*); aktivasi keluaran: *Tanh* (rentang $[-1, 1]$).

Tahap	Lapisan	Bentuk Keluaran	Kernel/Stride	Parameter
Masukan	Masukan	$128 \times 1024 \times 1$	-	-
Encoder-0	ResBlock-1	$128 \times 1024 \times 64$	$3 \times 3/1$	4.7K
	MaxPool-1	$64 \times 512 \times 64$	$2 \times 2/2$	-
Encoder-1	ResBlock-2	$64 \times 512 \times 128$	$3 \times 3/1$	147.6K
	MaxPool-2	$32 \times 256 \times 128$	$2 \times 2/2$	-
Encoder-2	ResBlock-3	$32 \times 256 \times 256$	$3 \times 3/1$	590.1K
	MaxPool-3	$16 \times 128 \times 256$	$2 \times 2/2$	-
Encoder-3	ResBlock-4	$16 \times 128 \times 512$	$3 \times 3/1$	2.4M
	MaxPool-4	$8 \times 64 \times 512$	$2 \times 2/2$	-
Encoder-4	ResBlock-5	$8 \times 64 \times 512$	$3 \times 3/1$	2.4M
	MaxPool-5	$4 \times 32 \times 512$	$2 \times 2/2$	-
Bottleneck	MSFP + RDB + CBAM	$4 \times 32 \times 512$	-	5.1M
Decoder-4	UpSample-5	$8 \times 64 \times 512$	-	-
	AttentionGate-5	$8 \times 64 \times 512$	-	262K
	RDB + CBAM	$8 \times 64 \times 512$	$3 \times 3/1$	3.5M
Decoder-3	UpSample-4	$16 \times 128 \times 512$	-	-
	AttentionGate-4	$16 \times 128 \times 512$	-	262K
	RDB + CBAM	$16 \times 128 \times 512$	$3 \times 3/1$	3.5M
Decoder-2	UpSample-3	$32 \times 256 \times 256$	-	-
	AttentionGate-3	$32 \times 256 \times 256$	-	66K
	RDB + CBAM	$32 \times 256 \times 256$	$3 \times 3/1$	885K
Decoder-1	UpSample-2	$64 \times 512 \times 128$	-	-
	AttentionGate-2	$64 \times 512 \times 128$	-	16.5K
	RDB + CBAM	$64 \times 512 \times 128$	$3 \times 3/1$	221K
Decoder-0	UpSample-1	$128 \times 1024 \times 64$	-	-
	AttentionGate-1	$128 \times 1024 \times 64$	-	4.1K
	RDB + CBAM	$128 \times 1024 \times 64$	$3 \times 3/1$	55K
Keluaran	Conv2D + Tanh	$128 \times 1024 \times 1$	$1 \times 1/1$	65
Total Parameter:				21.8M

Lampiran B Arsitektur Diskriminator Dual-Modal Enhanced

Tabel B.1 Arsitektur Diskriminator Dual-Modal Enhanced. Spesifikasi detail tiga cabang (Citra CNN, Teks BiLSTM, Fusi *Cross-Modal*). Cabang citra memproses fitur visual melalui 4 *DownBlocks* dengan *spatial attention*, cabang teks memproses sekuens karakter melalui embedding + BiLSTM + *self-attention*. *Cross-modal fusion* menghasilkan klasifikasi *reallfake*. Total: 17.4M parameter.

Cabang	Lapisan	Keluaran	Param.
CNN	<i>Input</i>	$128 \times 1024 \times 1$	-
	Conv2D+BN	$128 \times 1024 \times 64$	0.6K
	DownBlk-1	$64 \times 512 \times 64$	37K
	DownBlk-2	$32 \times 256 \times 128$	148K
	DownBlk-3	$16 \times 128 \times 256$	590K
	DownBlk-4	$8 \times 64 \times 512$	2.4M
	SpatialAttn	$8 \times 64 \times 512$	4.7K
	ResBlk-512	$8 \times 64 \times 512$	2.4M
	AvgPool	512	-
LSTM	<i>Input</i>	128 (seq.)	-
	Embed	128×128	12.8K
	BiLSTM	128×512	1.3M
	SelfAttn	128×512	262K
	AvgPool	512	-
Fusi	Proj-CNN	128	65.7K
	Proj-LSTM	128	65.7K
	CrossAttn	256	33K
	Dense-1+Drop	512	131K
	Dense-2+Drop	256	131K
	Sigmoid	1	257
Total:			17.4M

Lampiran C Formulir Penilaian Ahli Paleografi

Petunjuk Penggunaan Instrumen

Formulir ini digunakan untuk mengevaluasi kualitas restorasi dokumen historis terdegradasi oleh ahli paleografi atau restorasi arsip. Setiap kriteria dinilai dengan skala 1–5, kemudian diagregasi menggunakan metode yang dijelaskan di bawah.

Kriteria Penilaian

Penilaian dilakukan berdasarkan 5 aspek utama dengan skala 1-5:

- **Skor 5:** Sangat Baik (Kualitas optimal, sangat membantu keterbacaan)
- **Skor 4:** Baik (Kualitas baik, meningkatkan keterbacaan signifikan)
- **Skor 3:** Cukup (Kualitas memadai, ada peningkatan keterbacaan)
- **Skor 2:** Kurang (Kualitas kurang, peningkatan keterbacaan minimal)
- **Skor 1:** Sangat Kurang (Tidak ada peningkatan atau memperburuk)

Tabel C.1 Formulir Penilaian Kualitas Restorasi Dokumen

No	Aspek Penilaian	Deskripsi	Skor
A. KUALITAS VISUAL			
1	Kejernihan Piksel	Eliminasi noise tanpa merusak tinta	1 2 3 4 5
2	Kesamaan Struktural	Preservasi bentuk dan proporsi huruf	1 2 3 4 5
3	Kealamian Visual	Naturalitas hasil, tekstur kertas terjaga	1 2 3 4 5
B. AKURASI BINARISASI			
4	Pemisahan Teks-Latar	Deteksi teks lengkap, latar bersih	1 2 3 4 5
5	Kontinuitas Goresan	Keutuhan garis dan sambungan antar huruf	1 2 3 4 5
C. KETERBACAAN KARAKTER			
6	Identifikasi Karakter	Huruf terbaca jelas tanpa ambiguitas	1 2 3 4 5
7	Disambiguasi Huruf	Pembedaan huruf mirip (e/o, a/u, m/n, i/l)	1 2 3 4 5
8	Detail Mikro	Ketajaman tanda diakritik dan baca	1 2 3 4 5
D. KETERBACAAN KATA			
9	Identifikasi Kata	Kata terbaca utuh, batas jelas	1 2 3 4 5
10	Koherensi Spasi	Jarak antar karakter dan kata konsisten	1 2 3 4 5

Bersambung ke halaman berikutnya

Lanjutan Tabel Formulir Penilaian

No	Aspek Penilaian	Deskripsi	Skor
11	Aliran Teks	Kontinuitas teks dalam baris dan kalimat	1 2 3 4 5
E. PELESTARIAN HISTORIS			
12	Autentisitas Paleografi	Preservasi gaya tulisan periode	1 2 3 4 5
13	Integritas Konten	Tidak ada perubahan informasi tekstual	1 2 3 4 5
14	Kelayakan Transkripsi	Kemudahan transkripsi ahli paleografi	1 2 3 4 5
15	Standar Arsip Digital	Kesesuaian standar preservasi	1 2 3 4 5

Agregasi Skor

Formulir 15 kriteria di atas diagregasi menjadi 4 kriteria untuk analisis makro:

Kriteria Agregat	Mapping dari Formulir	Perhitungan
Keterbacaan Teks	Kriteria 6–11 (C+D)	Rerata 6 kriteria
Autentisitas Paleografi	Kriteria 12–13 (E.1–2)	Rerata 2 kriteria
Minimasi Artefak	Kriteria 4–5 (B)	Rerata 2 kriteria (inverse)
Kegunaan Transkripsi	Kriteria 14–15 (E.3–4)	Rerata 2 kriteria

Kriteria 1–3 (A) tidak dihitung dalam agregat (untuk validasi tambahan).

Konversi skala: Skor formulir (1-5) $\times$ 0,8 = skor agregat (skala 1-4)

Skor keseluruhan: Rerata dari 4 kriteria agregat

Validasi Instrumen: Hasil Studi Percontohan (n=15 dokumen ANRI)

Kriteria	Penilai 1	Penilai 2	Rerata
Keterbacaan Teks	3,47	3,33	3,40
Autentisitas Paleografi	3,60	3,53	3,57
Minimasi Artefak (inv.)	3,27	3,13	3,20
Kegunaan Transkripsi	3,53	3,47	3,50
Skor Keseluruhan	3,47	3,37	3,42

Skala: 1=Buruk, 2=Cukup, 3=Baik, 4=Sangat Baik

Cohen's kappa: $\kappa = 0,78$ (kesepakatan substansial)

Spearman's $\rho = 0,91$ ($p < 0,001$) untuk ranking dokumen

95% CI untuk rerata: [3,28, 3,56]