

addtoresetsubsectionsectionaddtoresetsubsubsectionssubsection

BAB V. Hasil dan Pembahasan

etoolbox remreset ifundefinednewcounter chngcntr addtoresetsectionchapter
addtoresetsubsectionsection addtoresetsubsubsectionssubsection etoolbox remreset
chngcntr addtoresetsectionchapter addtoresetsubsectionsection addtoresetsub-
subsectionssubsection etoolbox remreset chngcntr addtoresetsectionchapter
addtoresetsubsectionsection addtoresetsubsubsectionssubsection etoolbox remreset
chngcntr addtoresetsectionchapter addtoresetsubsectionsection addtoresetsubsub-
sectionssubsection

11 Nopember 2025

I Hasil dan Pembahasan

Bab ini menyajikan hasil dari serangkaian eksperimen yang telah dilakukan untuk mengevaluasi performa kerangka kerja restorasi dokumen yang diusulkan. Pembahasan akan difokuskan pada analisis kuantitatif dan kualitatif dari hasil yang diperoleh, serta mengaitkannya kembali dengan tujuan penelitian dan hipotesis yang telah dirumuskan.

I.1 Skenario Eksperimen dan Metodologi Evaluasi

Bagian ini menguraikan secara rinci tentang bagaimana proses evaluasi dilakukan untuk memastikan hasil yang objektif dan dapat dipercaya.

I.1.1 Dataset Evaluasi

Evaluasi dilakukan pada dua set data:

- **Dataset Sintetis:** Sebuah set data uji yang dibuat menggunakan pipeline degradasi yang sama dengan data training, namun menggunakan gambar bersih yang tidak pernah dilihat oleh model selama training.
- **Dataset Riil:** Sampel gambar dokumen historis asli dari koleksi Arsip Nasional untuk menguji kemampuan generalisasi model pada kasus dunia nyata.

I.1.2 Model Pembandingan (Baselines)

Untuk mengukur keunggulan model yang diusulkan, performanya akan dibandingkan dengan beberapa metode pembandingan, antara lain:

- **Gambar Asli Terdegradasi (No-Op):** Performa HTR pada gambar rusak tanpa restorasi, sebagai batas bawah (lower bound).
- **Model GAN Standar:** Sebuah versi model yang dilatih hanya dengan L1 Loss dan Adversarial Loss, tanpa komponen HTR-Oriented Loss (L_{CTC}).

- **Metode Restorasi Lain (jika ada):** Misalnya, hasil dari metode DE-GAN atau metode binarisasi tradisional seperti Sauvola.

I.1.3 Metrik Evaluasi

Evaluasi dilakukan berdasarkan kebutuhan non-fungsional (NFR) yang telah didefinisikan di Bab IV:

- **Metrik Kualitas Visual (NFR-1):** PSNR dan SSIM.
- **Metrik Keterbacaan Teks (NFR-2):** CER dan WER.

I.2 Evaluasi Kuantitatif

Bagian ini menyajikan hasil numerik dari evaluasi.

I.2.1 Hasil Hyperparameter Optimization

Sesuai dengan metodologi yang dijelaskan pada Bab III, dilakukan *Hyperparameter Optimization* (HPO) sistematis menggunakan *Bayesian Optimization* dengan *TPE sampler* (Optuna) untuk menentukan bobot *loss* yang optimal. HPO dilakukan dengan 29 *trial* terkontrol, masing-masing dilatih selama 2 *epoch* dengan 30 *steps per epoch*.

Tabel 1: Hasil *Top 10 Trials* dari *Bayesian Optimization* (dari 29 *trial*)

Trial	Score	Pixel	RecFeat	Adv	PSNR	SSIM	CER	WER
8	0.1464	120	80	2.5	13.09	0.746	0.707	0.811
14	0.1370	110	55	5.0	13.01	0.696	0.597	0.817
22	0.0870	120	90	4.5	10.44	0.628	0.787	0.856
15	0.0867	100	70	5.0	10.47	0.647	0.823	0.899
13	0.0770	170	50	4.5	10.73	0.585	0.716	0.855
29	0.0632	110	60	3.5	10.20	0.612	0.815	0.881
5	0.0600	90	45	3.0	9.88	0.598	0.841	0.892
11	0.0544	150	75	4.0	9.75	0.589	0.823	0.887
7	0.0489	140	35	2.0	9.50	0.577	0.856	0.901
19	0.0401	80	90	5.5	9.12	0.561	0.879	0.915

Rangkuman Hasil HPO:

Analisis Kepentingan Parameter (fANOVA): Untuk memahami kontribusi relatif setiap *hyperparameter* terhadap performa model, dilakukan analisis *functional ANOVA* (fANOVA) pada hasil 29 *trial*:

Tabel 2: Kepentingan parameter dari analisis fANOVA

Parameter	Kepentingan	Interpretasi
adv_loss_weight	66.4%	PARAMETER PALING PENTING. Memiliki dampak terbesar pada skor objektif. Korelasi negatif kuat: nilai tinggi → performa buruk (risiko <i>mode collapse</i>)
rec_feat_loss_weight	24.3%	Dampak SEDANG. Berkorelasi positif lemah dengan skor objektif. Penting untuk keseimbangan visual-HTR
pixel_loss_weight	9.3%	Dampak LEMAH. <i>Range</i> lebar (50-200) masih memberikan hasil acceptable

Temuan Kunci dari HPO:

1. Sensitivitas Signifikan Bobot Adversarial:

- *Range* optimal: 2.0 - 5.0
- Zona bahaya: ≥ 6.0 (risiko tinggi *mode collapse*)
- **Kegagalan Katastropik:** *Trial* 16 dengan $\text{adv_loss_weight}=8.5$ mengalami *mode collapse* total (PSNR=1.30 dB, SSIM=0.057, model tidak konvergen)
- Implikasi: Bobot adversarial harus dikontrol ketat untuk mencegah destabilisasi training

2. Keseimbangan Optimal Rekonstruksi vs. HTR Guidance:

- *Trial* terbaik (#8) menggunakan rasio $\text{pixel}:\text{rec_feat} = 1.5:1$ (120:80)
- Bobot *pixel* lebih tinggi → kualitas visual superior (PSNR/SSIM tinggi)
- Bobot *rec_feat* sedang → panduan HTR cukup tanpa degradasi visual
- Rasio ini memberikan *sweet spot* antara metrik visual dan metrik keterbacaan

3. Variabilitas Tinggi Antar Trial:

- Standar deviasi skor objektif: 0.080 (variansi tinggi)

- *Range* skor: -0.171 (terburuk) hingga +0.146 (terbaik) — rentang 0.317
- Menunjukkan *hyperparameter* sangat sensitif dan pentingnya optimasi sistematis
- Validasi bahwa pendekatan *trial-and-error* manual tidak efisien untuk ruang pencarian kompleks

4. Konfigurasi Optimal (Trial 8):

- Skor objektif tertinggi: 0.1464 (terbaik dari 29 *trial*)
- Keseimbangan metrik: PSNR=13.09 dB, SSIM=0.746, CER=0.707, WER=0.811
- Stabilitas training terjamin (tidak ada *mode collapse*)
- Digunakan untuk pelatihan penuh (100+ *epoch*)

Validasi Pendekatan HPO: Pendekatan *Bayesian Optimization* terbukti efektif dibandingkan manual tuning:

- **Efisiensi:** Menemukan konfigurasi optimal dalam 29 *trial* vs. ratusan eksperimen manual
- **Sistematis:** Eksplorasi ruang pencarian terkontrol dengan TPE *sampler*
- **Reproducible:** Semua *trial* tercatat dalam *database* Optuna dan MLflow
- **Insight:** Analisis fANOVA memberikan pemahaman mendalam tentang sensitivitas parameter

I.2.2 Analisis Kualitas Visual (PSNR & SSIM)

Hasil perbandingan metrik PSNR dan SSIM antara model yang diusulkan dengan model pembanding disajikan dalam Tabel 3.

Tabel 3: Perbandingan Metrik Kualitas Visual pada Dataset Uji Sintetis.

Metode	PSNR (dB) ↑	SSIM ↑
Manual Tuning (Baseline)	10-11	0.60
Bayesian Optimization (HPO)	13.09	0.746
<i>Improvement</i>	+20%	+24%

I.2.3 Analisis Keterbacaan Teks (CER & WER)

Hasil perbandingan metrik CER dan WER, yang merupakan evaluasi utama dari penelitian ini, disajikan dalam Tabel 4.

Tabel 4: Perbandingan Metrik Keterbacaan Teks pada Dataset Uji.

Metode	CER (%) ↓	WER (%) ↓
Gambar Asli Terdegradasi	[Isi Hasil]	[Isi Hasil]
Manual Tuning (Baseline)	0.85-0.90	0.90-0.95
Bayesian Optimization (HPO)	0.707	0.811
<i>Improvement</i>	-17%	-10%

Justifikasi Ilmiah Konfigurasi yang Dipilih: Konfigurasi bobot *loss* yang digunakan dalam model final (pixel=120.0, rec_feat=80.0, adv=2.5) **bukan hasil trial-and-error**, melainkan ditemukan melalui *Hyperparameter Optimization* sistematis dengan 29 *trial* terkontrol. Konfigurasi ini memberikan:

- Skor objektif tertinggi (0.1464) di antara semua kombinasi yang diuji
- Keseimbangan optimal antara kualitas visual dan keterbacaan teks
- Stabilitas pelatihan terjamin (tidak ada *mode collapse*)
- *Reproducible* dan dapat diverifikasi melalui *database* Optuna dan pelacakan MLflow

I.3 Analisis Kualitatif

Selain evaluasi kuantitatif, analisis kualitatif dilakukan dengan membandingkan hasil restorasi secara visual. Gambar 1 menunjukkan perbandingan antara gambar terdegradasi, hasil restorasi dari model baseline, dan hasil restorasi dari model yang diusulkan.

Gambar 1: Perbandingan visual hasil restorasi pada sampel dokumen. Dari kiri ke kanan: Gambar Asli Terdegradasi, Hasil Restorasi GAN Standar, Hasil Restorasi Model Usulan, Gambar Ground Truth.

I.4 Pembahasan

Bagian ini menginterpretasikan hasil yang telah disajikan dan mengaitkannya kembali dengan pertanyaan penelitian dan hipotesis yang dirumuskan di Bab I.

I.4.1 Validasi Hipotesis Penelitian

Sesuai dengan kriteria pengujian hipotesis pada Bab I.5, evaluasi menggunakan *paired t-test* ($\alpha = 0.05$) untuk membandingkan CER/WER framework usulan dengan baseline.

Tabel 5: Hasil *Paired T-Test* untuk Validasi Hipotesis

Metrik	Mean Diff	t-statistic	p-value	Cohen's d
CER	[PLACEHOLDER]	[PLACEHOLDER]	[PLACEHOLDER]	[PLACEHOLDER]
WER	[PLACEHOLDER]	[PLACEHOLDER]	[PLACEHOLDER]	[PLACEHOLDER]

Hasil Uji Statistik: Keputusan:

- **Jika p-value < 0.05:** Hipotesis Nol (H_0) ditolak. Framework yang diusulkan terbukti menghasilkan penurunan CER/WER yang signifikan secara statistik dibandingkan baseline. Hipotesis Alternatif (H_1) diterima.
- **Analisis Ukuran Efek:** Cohen's d menunjukkan [INTERPRETASI: small/medium/large effect size]

I.4.2 Jawaban atas Pertanyaan Penelitian

PR1: Arsitektur Dual-Modal *"Bagaimana merancang arsitektur Diskriminator Dual-Modal yang dapat mengevaluasi koherensi antara konten visual dan representasi tekstual secara simultan?"*

Jawaban: [PLACEHOLDER - Analisis hasil menunjukkan Diskriminator Dual-Modal berhasil/tidak berhasil...]

Bukti empiris:

- Discriminator accuracy: [PLACEHOLDER] pada epoch ke-[X]
- Perbandingan dengan Discriminator visual-only: [PLACEHOLDER]
- Analisis attention weights pada cabang tekstual: [PLACEHOLDER]

PR2: Integrasi HTR Eksplisit *"Bagaimana mengintegrasikan sinyal CTC loss dari model HTR ke dalam fungsi objektif Generator untuk optimasi end-to-end keterbacaan teks tanpa menyebabkan ketidakstabilan training?"*

Jawaban: [PLACEHOLDER - CTC loss dengan annealing strategy terbukti...]

Bukti empiris:

- Stabilitas training: [PLACEHOLDER - training loss convergence analysis]
- Impact CTC annealing: [PLACEHOLDER - perbandingan warmup vs no-warmup]
- Gradient flow analysis: [PLACEHOLDER]

PR3: Optimasi Multi-Objective *"Bagaimana menyeimbangkan bobot antara komponen loss (adversarial, reconstruction, recognition) untuk mencapai trade-off optimal antara kualitas visual dan keterbacaan teks?"*

Jawaban: Bayesian Optimization dengan 29 trial menemukan konfigurasi optimal (pixel=120, rec_feat=80, adv=2.5) yang memberikan skor objektif tertinggi (0.1464). Analisis fANOVA menunjukkan adversarial loss weight memiliki kepentingan 66.4% terhadap performa.

Bukti empiris:

- Optimal weight configuration: pixel=120, rec_feat=80, adv=2.5
- Performance gain: PSNR +20%, SSIM +24%, CER -17%, WER -10% vs manual tuning
- Sensitivitas parameter: adv_loss_weight paling penting (66.4% importance)

PR4: Evaluasi Komprehensif *"Apakah framework yang diusulkan dapat menghasilkan peningkatan signifikan dalam metrik keterbacaan (minimal 25% penurunan CER)?"*

Jawaban: [PLACEHOLDER - Berdasarkan hasil Table 4...]

Bukti empiris:

- CER improvement: [PLACEHOLDER]% vs baseline
- WER improvement: [PLACEHOLDER]% vs baseline
- PSNR: [PLACEHOLDER] dB (target: > 35 dB)
- SSIM: [PLACEHOLDER] (target: > 0.95)

I.4.3 Analisis Trade-off Visual vs Keterbacaan

Temuan Kunci: [PLACEHOLDER - Analisis korelasi antara PSNR/SSIM dengan CER/WER. Apakah model dengan PSNR tertinggi juga menghasilkan CER terendah?]

Gambar 2: [PLACEHOLDER] Scatter plot PSNR vs CER menunjukkan korelasi negatif: PSNR tinggi → CER rendah

Interpretasi:

- **Sinergis vs Antagonis:** [PLACEHOLDER - Optimasi visual dan keterbacaan bersifat sinergis/antagonis]
- **Sweet Spot:** Konfigurasi Trial 8 menemukan keseimbangan optimal
- **Implikasi:** Multi-objective optimization dengan proper weight tuning esensial

I.4.4 Analisis Kegagalan dan Limitasi

Gambar 3: [PLACEHOLDER] Contoh kegagalan model: (a) degradasi ekstrem, (b) layout kompleks, (c) karakter rare

Failure Cases: Analisis Penyebab:

- **Degradasi Ekstrem:** Model kesulitan ketika PSNR input < 10 dB
- **Layout Kompleks:** Overlapping text lines belum tertangani optimal
- **Out-of-Distribution:** Karakter rare/special symbols tidak cukup terwakili dalam training
- **Frozen Recognizer Limitation:** Recognizer performance ceiling (CER $\sim 33\%$) membatasi improvement maksimal

Mitigasi dan Future Work:

- Augmentasi data lebih agresif untuk edge cases
- Fine-tuning recognizer pada domain-specific vocabulary
- Arsitektur multi-scale untuk handling berbagai tingkat degradasi

I.4.5 Ketercapaian Tujuan Penelitian

Evaluasi terhadap tujuan khusus yang dirumuskan di Bab I.3:

Tabel 6: Evaluasi Ketercapaian Tujuan Penelitian

Tujuan	Metrik/Kriteria Keberhasilan	Status
T1: Dual-Modal	Discriminator accuracy 60-80% (Nash equilibrium)	[PLACEHOLDER]
T2: HTR Integration	Training stable tanpa mode collapse, CTC loss converged	[PLACEHOLDER]
T3: Multi-Objective	Optimal weights via HPO, balanced PSNR/CER	✓
T4: Comprehensive Eval	CER reduction > 25%, PSNR > 35 dB, SSIM > 0.95	[PLACEHOLDER]

Ringkasan Ketercapaian:

- **Tujuan Utama:** [PLACEHOLDER - Tercapai/Tercapai Sebagian/Belum Tercapai]
- **Kontribusi Ilmiah:** [PLACEHOLDER]
- **Implikasi Praktis:** [PLACEHOLDER]

I.4.6 Perbandingan dengan State-of-the-Art

Tabel 7: Perbandingan dengan Metode State-of-the-Art

Metode	PSNR (dB)	SSIM	CER (%)	WER (%)
DE-GAN [?]	[PLACEHOLDER]	[PLACEHOLDER]	[PLACEHOLDER]	[PLACEHOLDER]
DocEnTr [?]	[PLACEHOLDER]	[PLACEHOLDER]	[PLACEHOLDER]	[PLACEHOLDER]
Text-DIAE [?]	[PLACEHOLDER]	[PLACEHOLDER]	[PLACEHOLDER]	[PLACEHOLDER]
Framework Usulan	[PLACEHOLDER]	[PLACEHOLDER]	[PLACEHOLDER]	[PLACEHOLDER]

Analisis Keunggulan:

- **CER/WER:** [PLACEHOLDER - Framework usulan unggul X% dibanding DE-GAN]
- **PSNR/SSIM:** [PLACEHOLDER - Kompetitif dengan DocEnTr]
- **Trade-off:** [PLACEHOLDER - Balance superior antara visual dan readability]